注意事項: 本資料の再利用(2次利用)について

- **本資料について**
  - 東京大学 松尾・岩澤研究室が作成し、2025年10月から11月にかけて開催されたLLM大規模言語モデル講座基礎編の講義資料です。
  - クリエイティブ・コモンズのCC BY-NC-SA 4.0 DEED(表示 – 非営利 – 継承 4.0 国際)のライセンス登録をしています。
- **ライセンスの表示について**
  - 各スライドのページ最下部にライセンスの記載があります。再利用時には本ライセンス表示を必ずご記載ください。再利用時に複製が困難な場合は、下記のテキストボックスを利用の上、ハイパーリンクも含めてライセンスの表記をするようお願いします。

    LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
  - 再利用するページに参照論文等の引用がある場合は、巻末にあるReferenceより引用箇所を掲載してください。
- **非営利目的での利用について**　再利用(2次利用)が許諾されています。
- **営利目的での再利用について**　こちらからお問い合わせください。
- **その他**
  - 元の表現が変わらない範囲(フォント、サイズ等)であれば改変可能です。
  - それ以外の改変その他ライセンスについての詳細は、こちらをご覧の上適切な取り扱いをお願いします。

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Overview of Large Language Models

松尾・岩澤研究室
MATSUO-IWASAWA LAB UTOKYO

准教授 岩澤有祐

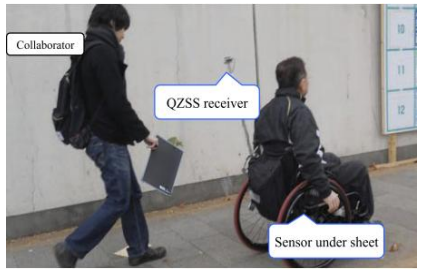
※ 今回は個別の技術を深ぼるというより概要を把握する目的です.
たくさんの用語がでてきますが、すべてこの回で覚えてほしいわけではないです.

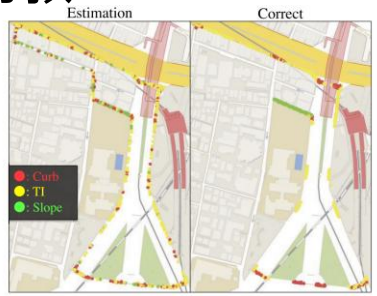
許諾なく撮影や第三者
への開示を禁止します

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

岩澤 有祐（いわさわ ゆうすけ）

2017年東京大学工学系研究化博士課程修了（松尾研）．卒業後特任研究員，特任助教などを経て2024年1月より技術経営戦略学専攻で准教授.



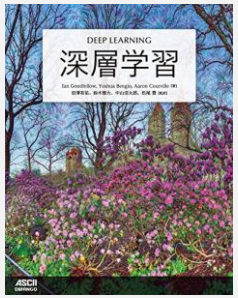


■ 研究テーマ等

- 修士までは障害者支援への機械学習技術の応用
- 博士から深層学習の主に転移学習技術に関する研究



DL輪読会
松尾研メンバ，講義受講生などが参加する勉強会を主催.
2015年 ~ 累計350回以上実施（毎週金曜朝10:00）



DL本（監訳，翻訳）
Goodfellowらが執筆した深層学習の教科書の監訳，翻訳．2018年に出版.

■ 生成AIに関連する活動

- “Large-Language Models are Zero-Shot Reasoners”, NeurIPS2022 など
- JSAI2023，CSS2023での「基盤モデルの技術と展望」のチュートリアル [Speaker Deck]
- 松尾研主催 大規模言語モデル講座の全体の設計
- 岸田総理等への大規模言語モデルの講義（180分）

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

目次

- **LLMの概要（LLMをなぜいま学ぶのか？）**
- 各回の概要
- 日本のLLMを取り巻く環境

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

モチベーション

- 今，自然言語を操るアシスタントAIを作りたいとします
- 例えば，質問に対して正しい答えを出力してほしいとします
  - 例：Q. 日本の首都は？ A. 東京
- 例えば，”文章を英語に翻訳して” と言ったら翻訳した文章を出力してほしいとします
- 例えば，「テトリスのアプリを作って」といったらそのコードを生成してほしいとします

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

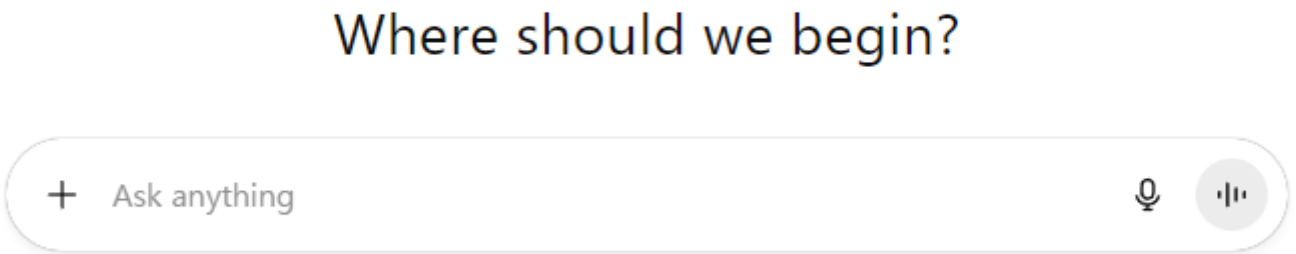
今はこれらはWeb上や簡単なプログラムで実現できるように



Gemini

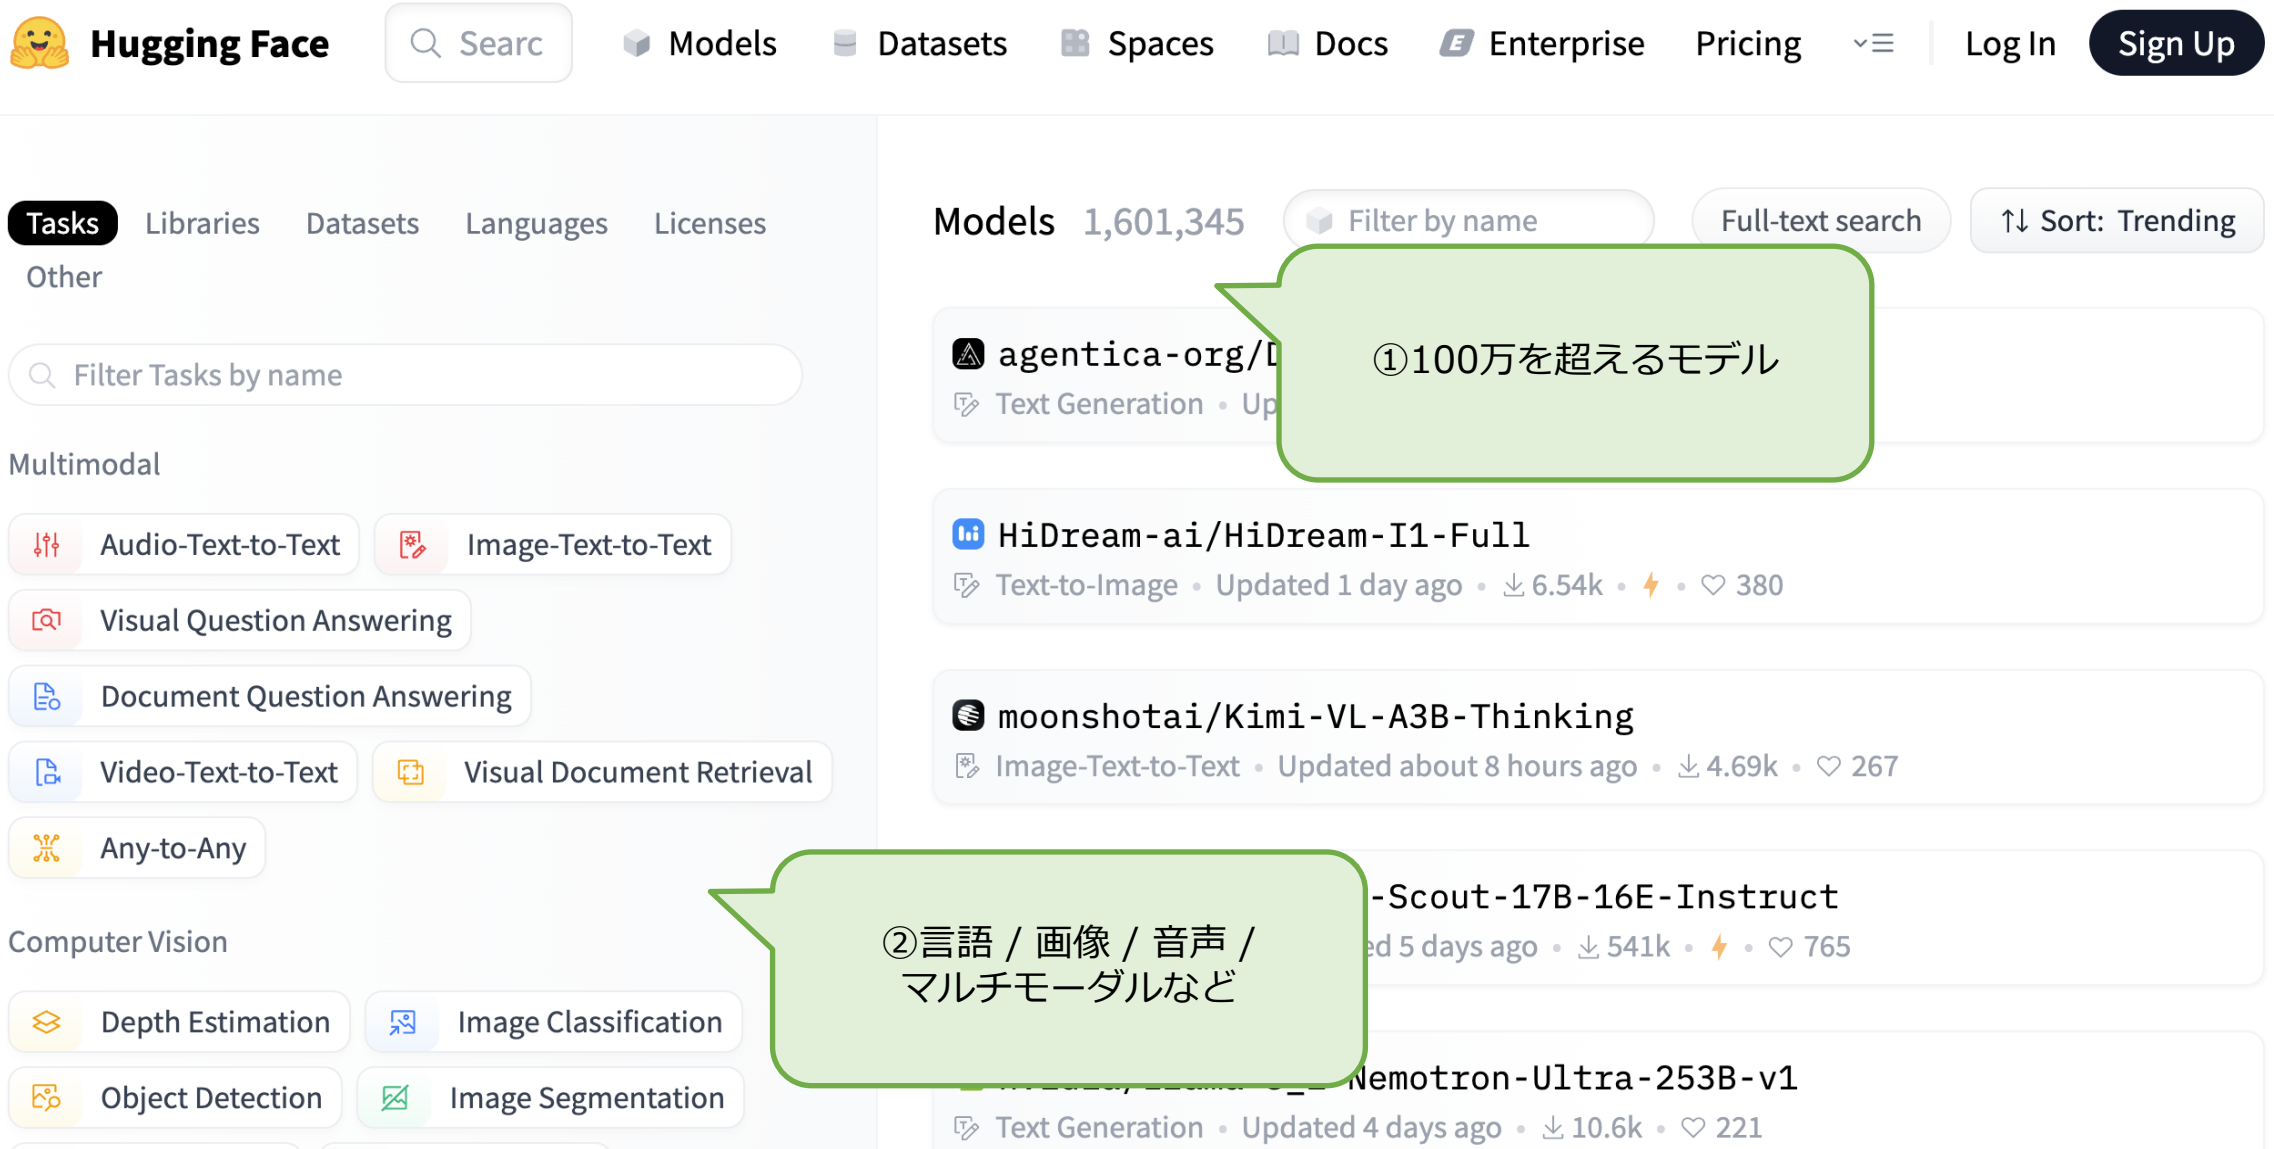
Claude

BY ANTHROP\C



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

AI + エコシステムの進展の例 | Hugging Face



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

AI + エコシステムの進展の例 | Hugging Face



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

これらはどのように実現されているか？ - 言語モデルの歴史

- 単語の系列（文章）を$x_1, x_2, \cdots, x_L$としたとき，その生成確率$p(x_1, x_2, \cdots, x_L)$を割り当てる確率モデルpのこと

  $p(\text{日本}, \text{の}, \text{首都}, \text{は}, \text{東京}) = 0.02$

  $p(\text{日本}, \text{の}, \text{首都}, \text{は}, \text{パリ}) = 0.00001$

  $p(\text{東京}, \text{の}, \text{首都}, \text{は}, \text{日本}) = 0.0005$

- 様々な言語タスクがこの生成確率の推定問題として扱うことができる

  例：QA（ある質問に続くのにふさわしい答えは？）

  例：翻訳（ある英語文に続くのにふさわしい日本語は？）

- 例：コード生成（ある指示文にふさわしいコードは？）

- この生成確率をどう求めるか？が言語モデル技術的な問題の一つ

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

自己回帰言語モデル (Autoregressive Language Models)

- $p(x_1, x_2, \cdots, x_L)$を条件分布の積として表現する

$$p(x_1, x_2, \cdots, x_L) = p(x_1)p(x_2|x_1)\cdots p(x_L|x_1, x_2, \cdots, x_{L-1})$$

- このように確率の連鎖律で分解したモデルを特に自己回帰言語モデルと呼ぶ
- 条件付き確率がわかると，生成することもできる

$p($東京$|$日本, の, 首都, は$) = \mathbf{0.2}$

$p($パリ$|$日本, の, 首都, は$) = 0.001$

$\vdots$

$p($カイロ$|$日本, の, 首都, は$) = 0.0005$

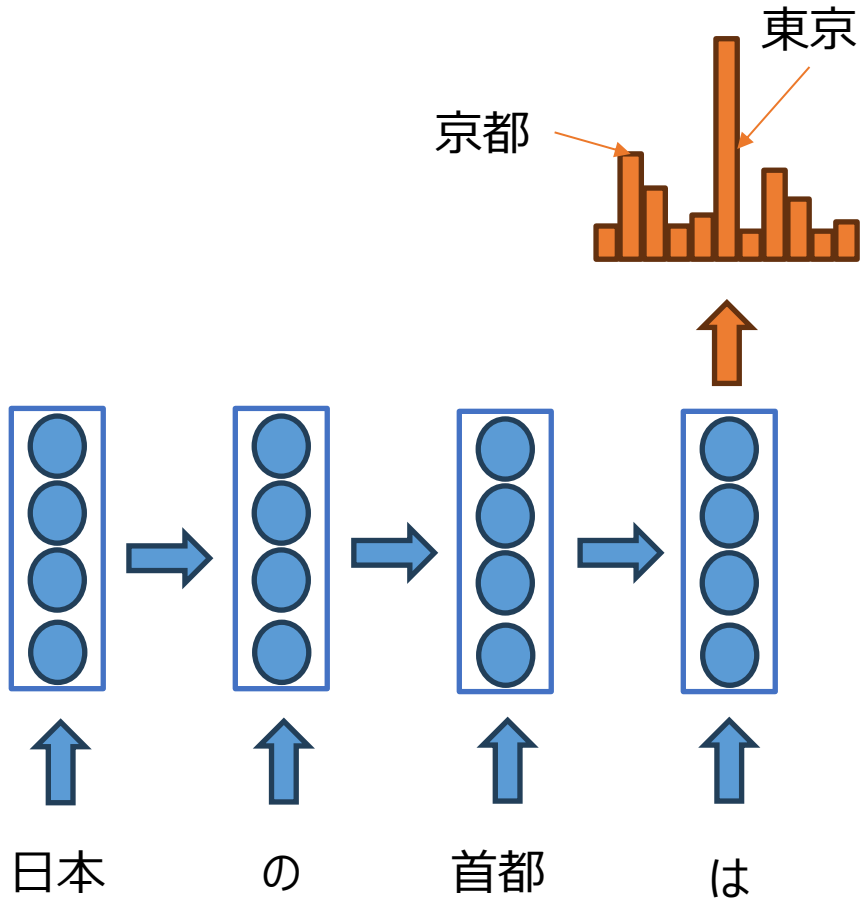
日本の首都は → **東京**

- この条件付き確率をどう求めるか？

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

ニューラル言語モデル

- 条件付き確率を何らかのニューラルネットで推定したモデル
- Webのデータを模擬するように（尤度を最大化するように）訓練



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformer以前のニューラル言語モデルの課題

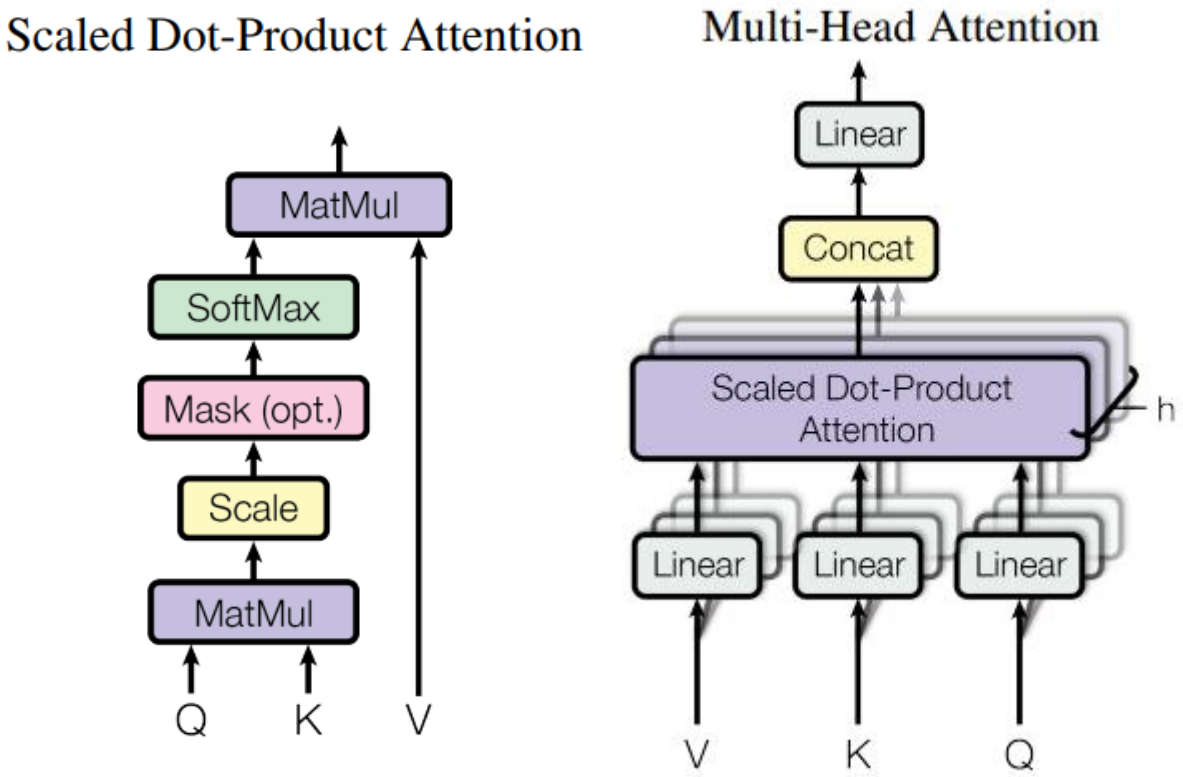
- 畳み込みネットやMLP等では，長いコンテキストの処理が難しい
  - 例えば翻訳では，元文をしっかり反映して翻訳文を決める必要がある.
  - ある程度長い系列情報を処理できないと解けないタスクがある

- RNN系列のモデルは，学習が並列化できずにスケール化が困難
  - データを逐次的に処理する性質上，学習や推論の並列化が困難
  - そのほかにも学習が難しいという問題も（勾配消失問題）

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

“Attention is All You Need”, NeurIPS 2017

Transformer



$$\text{Attention}(Q, K, V) = \text{softmax}(\frac{QK^T}{\sqrt{d_k}})V$$

Model	BLEU		Training Cost (FLOPs)	
	EN-DE	EN-FR	EN-DE	EN-FR
ByteNet [15]	23.75			
Deep-Att + PosUnk [32]		39.2		$1.0 \cdot 10^{20}$
GNMT + RL [31]	24.6	39.92	$2.3 \cdot 10^{19}$	$1.4 \cdot 10^{20}$
ConvS2S [8]	25.16	40.46	$9.6 \cdot 10^{18}$	$1.5 \cdot 10^{20}$
MoE [26]	26.03	40.56	$2.0 \cdot 10^{19}$	$1.2 \cdot 10^{20}$
Deep-Att + PosUnk Ensemble [32]		40.4		$8.0 \cdot 10^{20}$
GNMT + RL Ensemble [31]	26.30	41.16	$1.8 \cdot 10^{20}$	$1.1 \cdot 10^{21}$
ConvS2S Ensemble [8]	26.36	**41.29**	$7.7 \cdot 10^{19}$	$1.2 \cdot 10^{21}$
Transformer (base model)	27.3	38.1	**$3.3 \cdot 10^{18}$**	
Transformer (big)	**28.4**	**41.0**	$2.3 \cdot 10^{19}$	

- Googleを中心にした研究チームが2017年に発表
- Self Attentionを中心にしたネットワーク構造（左）
  ※構造の詳細は別日に話します
- 主に翻訳等の教師あり学習で性能検証（右）
  例：英語文 → Transformer → ドイツ語文
  となるように誤差逆伝播で訓練

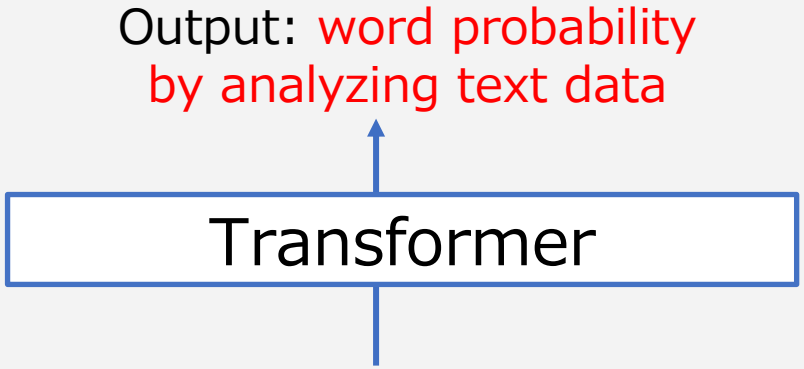
[1] Ashish Vaswani et al. (2017) “Attention Is All You Need” NeurIPS 2017 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

“Improving Language Understanding by Generative Pre-training”, 2018

Generative Pretraining Transformer (GPT)

Pre-training （事前学習）



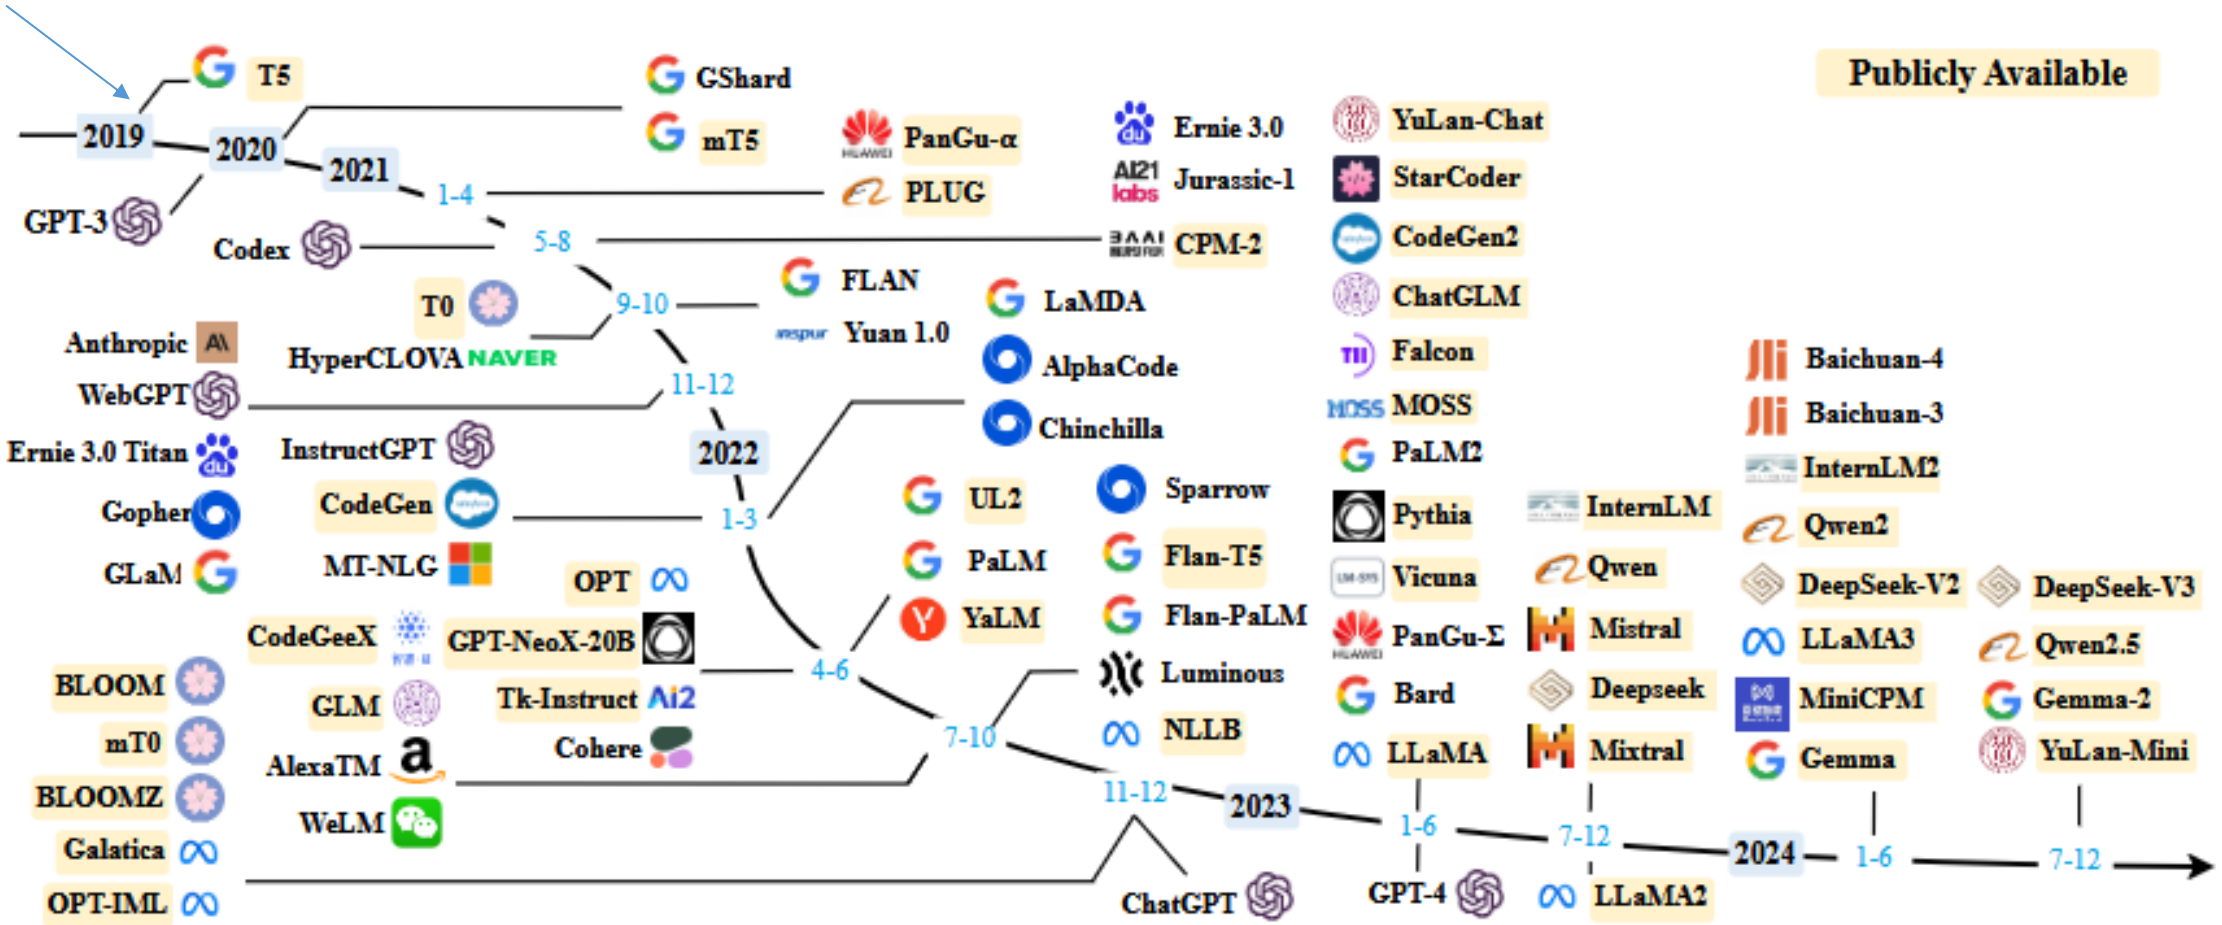
Original: Language models determine word probability by analyzing text data

- OpenAIにより2018年に発表されたモデル
- **事前学習**にTransformerを利用
  （Transformerを使った言語モデル）
- 具体的には次に来る単語をTransformerで予測するように学習（左図）
  Book Corpusという未発表書籍を利用
- GPT, GPT-2, GPT-3とバージョンを経るごとに学習データ数やモデルサイズが増加

[2] Alec Radford et al. (2018) “Improving Language Understanding by Generative Pre-training” を参考

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

2020年のGPT-3登場後，大規模モデルの発表は加速度的に増加



[3] Wayne Xin Zhao et al. (2023), "A Survey of Large Language Models" arXiv:2303.18223より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

GPT-4の持つ知識

Exam	GPT-4	GPT-4 (no vision)	GPT-3.5
Uniform Bar Exam (MBE+MEE+MPT)	298 / 400 (~90th)	298 / 400 (~90th)	213 / 400 (~10th)
LSAT	163 (~88th)	161 (~83rd)	149 (~40th)
SAT Evidence-Based Reading & Writing	710 / 800 (~93rd)	710 / 800 (~93rd)	670 / 800 (~87th)
SAT Math	700 / 800 (~89th)	690 / 800 (~89th)	590 / 800 (~70th)
Graduate Record Examination (GRE) Quantitative	163 / 170 (~80th)	157 / 170 (~62nd)	147 / 170 (~25th)
Graduate Record Examination (GRE) Verbal	169 / 170 (~99th)	165 / 170 (~96th)	154 / 170 (~63rd)
Graduate Record Examination (GRE) Writing	4 / 6 (~54th)	4 / 6 (~54th)	4 / 6 (~54th)
USABO Semifinal Exam 2020	87 / 150 (99th - 100th)	87 / 150 (99th - 100th)	43 / 150 (31st - 33rd)
USNCO Local Section Exam 2022	36 / 60	38 / 60	24 / 60
Medical Knowledge Self-Assessment Program	75 %	75 %	53 %
Codeforces Rating	392 (below 5th)	392 (below 5th)	260 (below 5th)
AP Art History	5 (86th - 100th)	5 (86th - 100th)	5 (86th - 100th)
AP Biology	5 (85th - 100th)	5 (85th - 100th)	4 (62nd - 85th)
AP Calculus BC	4 (43rd - 59th)	4 (43rd - 59th)	1 (0th - 7th)
AP Chemistry	4 (71st - 88th)	4 (71st - 88th)	2 (22nd - 46th)
AP English Language and Composition	2 (14th - 44th)	2 (14th - 44th)	2 (14th - 44th)
AP English Literature and Composition	2 (8th - 22nd)	2 (8th - 22nd)	2 (8th - 22nd)
AP Environmental Science	5 (91st - 100th)	5 (91st - 100th)	5 (91st - 100th)
AP Macroeconomics	5 (84th - 100th)	5 (84th - 100th)	2 (33rd - 48th)
AP Microeconomics	5 (82nd - 100th)	4 (60th - 82nd)	4 (60th - 82nd)
AP Physics 2	4 (66th - 84th)	4 (66th - 84th)	3 (30th - 66th)
AP Psychology	5 (83rd - 100th)	5 (83rd - 100th)	5 (83rd - 100th)
AP Statistics	5 (85th - 100th)	5 (85th - 100th)	3 (40th - 63rd)
AP US Government	5 (88th - 100th)	5 (88th - 100th)	4 (77th - 88th)
AP US History	5 (89th - 100th)	4 (74th - 89th)	4 (74th - 89th)
AP World History	4 (65th - 87th)	4 (65th - 87th)	4 (65th - 87th)
AMC 10^3	30 / 150 (6th - 12th)	36 / 150 (10th - 19th)	36 / 150 (10th - 19th)
AMC 12^3	60 / 150 (45th - 66th)	48 / 150 (19th - 40th)	30 / 150 (4th - 8th)
Introductory Sommelier (theory knowledge)	92 %	92 %	80 %
Certified Sommelier (theory knowledge)	86 %	86 %	58 %
Advanced Sommelier (theory knowledge)	77 %	77 %	46 %
Leetcode (easy)	31 / 41	31 / 41	12 / 41
Leetcode (medium)	21 / 80	21 / 80	8 / 80
Leetcode (hard)	3 / 45	3 / 45	0 / 45

- OpenAIにより2023年に発表されたモデル（詳細は未公開，リーク情報はあり）
- 司法試験やSAT/GREなどの多様な試験で好成績

  例:Uniform Bar Examでは298/400 (~90th)

  例：GRE (Quantitative)が163/179 (~80th)
- 一方コーディング能力などではまだ低いスコア（現在は大幅に改善）

[4] OpenAI 2023 “GPT-4 Technical Report” より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

“Evaluating gpt-4 and ChatGPTt on Japanese medical licensing examinations”2023

Igak QA

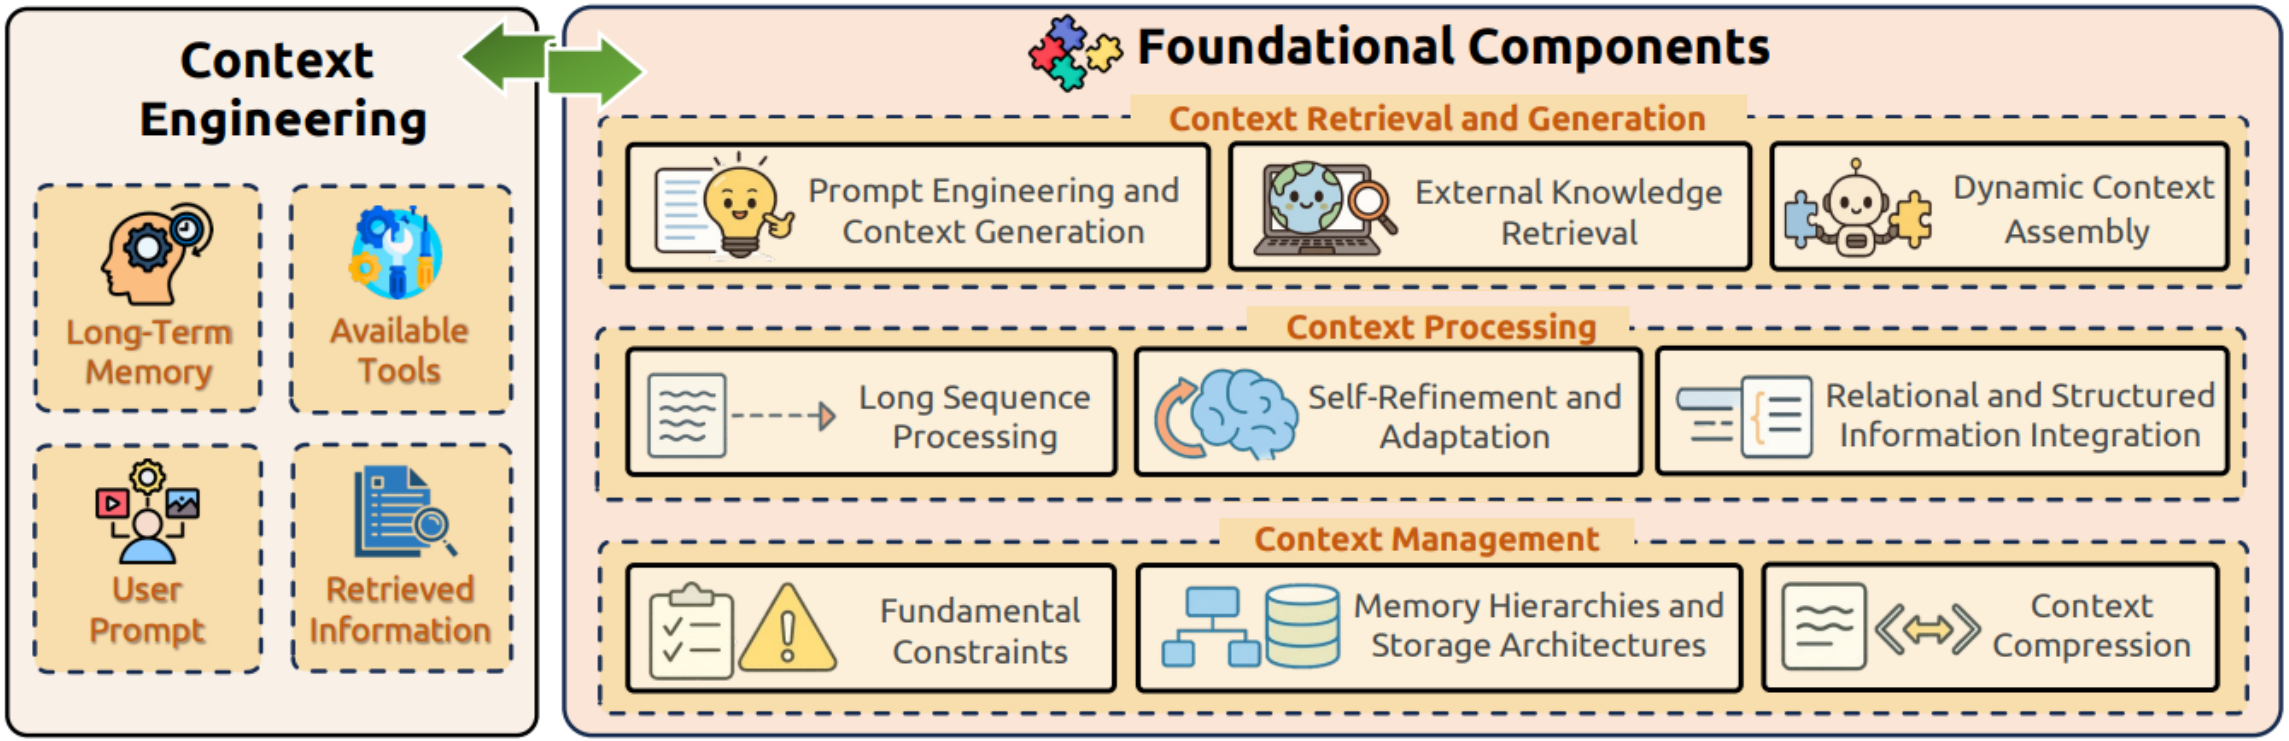
Model	2018			2019			2020			2021			2022			2023		
	Req.	Gen.	P.↓	Req.	Gen.	P.↓	Req.	Gen.	P.↓	Req.	Gen.	P.↓	Req.	Gen.	P.↓	Req.	Gen.	P.↓
ChatGPT	123	143	1	100	150	5	118	148	2	143	154	3	124	163	2	120	140	–
ChatGPT-EN	123	158	2	117	157	3	116	147	2	110	167	0	140	187	1	142	159	–
GPT-3	105	104	5	93	117	5	97	111	4	94	109	3	106	111	6	86	113	–
GPT-4	161	221	0	170	215	1	168	219	0	173	225	0	164	228	1	170	221	–
Student Majority	196	276	0	196	274	0	195	276	0	200	277	0	195	287	0	–	–	–
Total	200	299	33	200	296	40	197	299	26	200	300	26	197	297	26	200	295	–
Passing Score	160	208	3	160	209	3	158	217	3	160	209	3	157	214	3	160	220	–

[5] Jungo Kasai et al. (2023), “Evaluating gpt-4 and ChatGPTt on Japanese medical licensing examinations” より引用

- 言語モデル (GPT-4 and ChatGPT）を新たに作成した日本の医療ライセンス試験6年分のデータセット（Igaku-QA)を構築してベンチマーク
- (1) 人間の平均的な受験者よりは悪い，(2) 禁忌技を選択する傾向にある，といった問題はあるものの試験ボーダーは突破

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

大規模言語モデルを活用する技術も進展｜Context Engineering



- 言語モデルが持っている知識を使うだけでなく、必要なコンテキストを選択し処理する技術
- RAG / ツール利用（検索） / Deep Research / Memoryなど様々な技術が研究

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

2025年に登場した大規模言語モデル（Generated by GPT5）

モデル名	開発元	公開時期（2025）	オープン/クローズド
GPT-5	OpenAI	8月	クローズド
GPT-4.5	OpenAI	2月	クローズド
GPT-OSS	OpenAI	8月	オープン
Llama 4 Scout	Meta	4月	オープン
Llama 4 Maverick	Meta	4月	オープン
DeepSeek-R1	DeepSeek	1月	オープン
DeepSeek-V3	DeepSeek	3月頃	オープン
Qwen3 (Think)	Alibaba/Qwen	4月	オープン
Qwen2.5-Max	Alibaba/Qwen	初頭	オープン
Claude 3.7 Sonnet	Anthropic	2月	クローズド
Grok-3	xAI	2月	クローズド
BitNet b1.58 2B4T	Ma 他	4月	オープン
LLaDA	ML-GSAI 他	2月	オープン
MMaDA	研究チーム	5月	オープン

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

モデルに関するトレンド

① Reasoningモデルと呼ばれる，これまでより推論能力が著しく高いモデルの登場
（自ら誤りに気づく”Aha Moment”）
⇒ これまでより複雑なベンチマークの整備、推論プロセスの分析などが進展

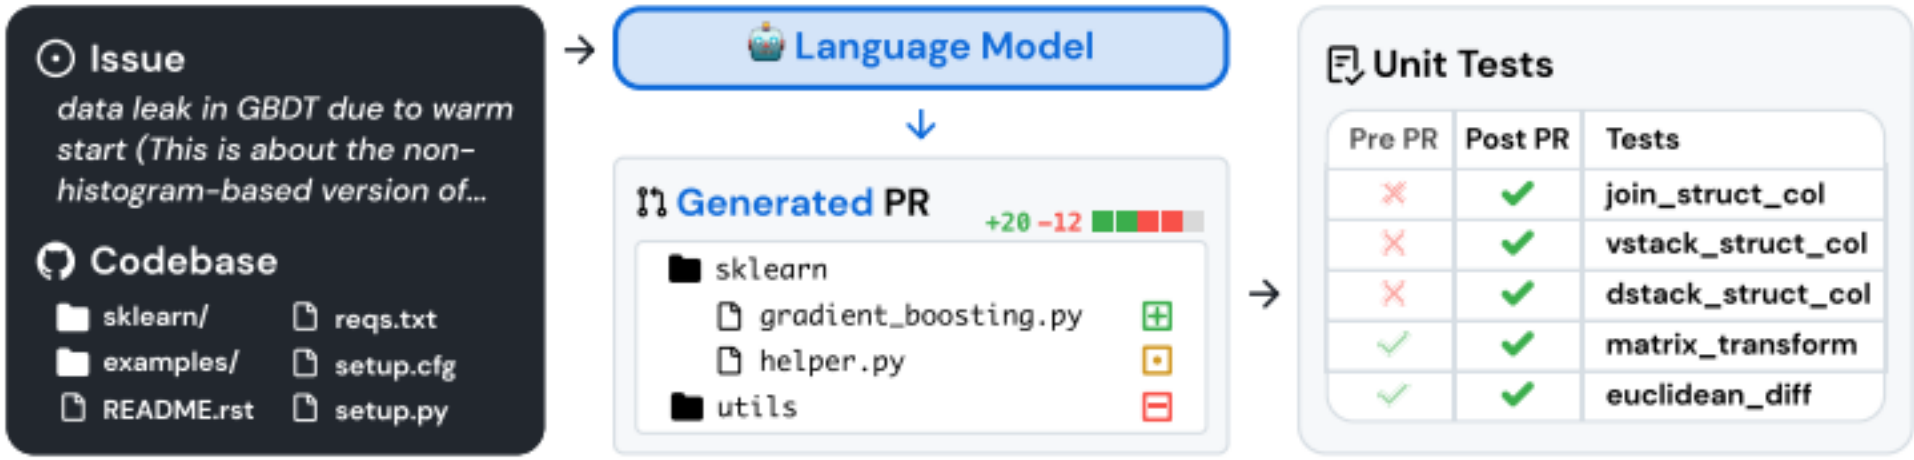
② 性能の高い公開モデルの増加

③ （様々な意味で）効率の良いモデル構造（拡散言語モデルなど）

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

ベンチマークの高度化

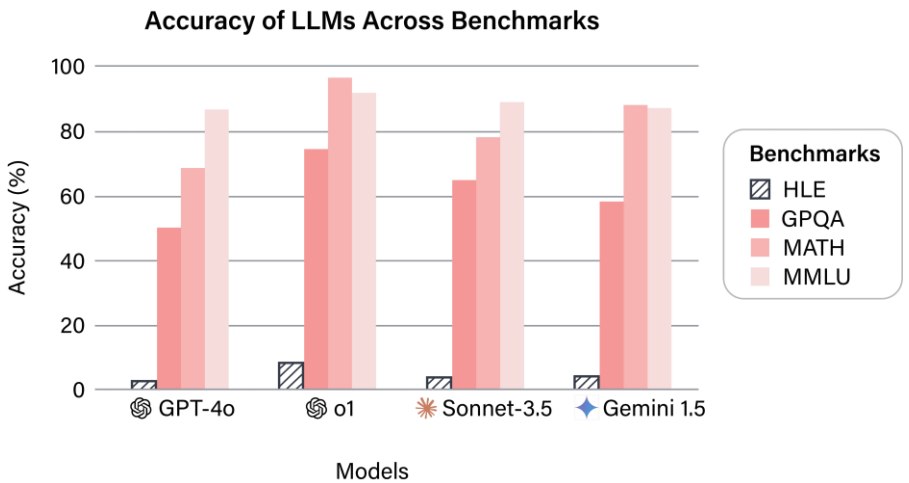
■SWE Bench：Issueに対するPRを作成する能力を評価



■Humanity Last Exam:

Humanity Last Examというチャレンジングな問題（登場次点はSoTAが9%，今は21.6%

<u>問題例</u>
「アマツバメ目のハチドリは、尾羽下制筋の広がった交差状の腱膜の尾側外側部分に埋め込まれた、左右対になった楕円形の種子骨を持つ。この種子骨によって支えられている腱ペアはいくつあるか？数字で答えよ」



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

ここまでのまとめと本講座の趣旨

■ ここまでのまとめ

- 言語モデルとは単語列の生成確率をモデル化したもの

  自己回帰言語モデル / ニューラル言語モデル / GPT

- 2025年になってもその活用方法 / モデル自体（大規模推論モデル，拡散言語モデル） / 評価方法に関する研究開発は進展している

■ このあとの話し

原理は非常にシンプル．なぜいま言語モデルなのか？

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

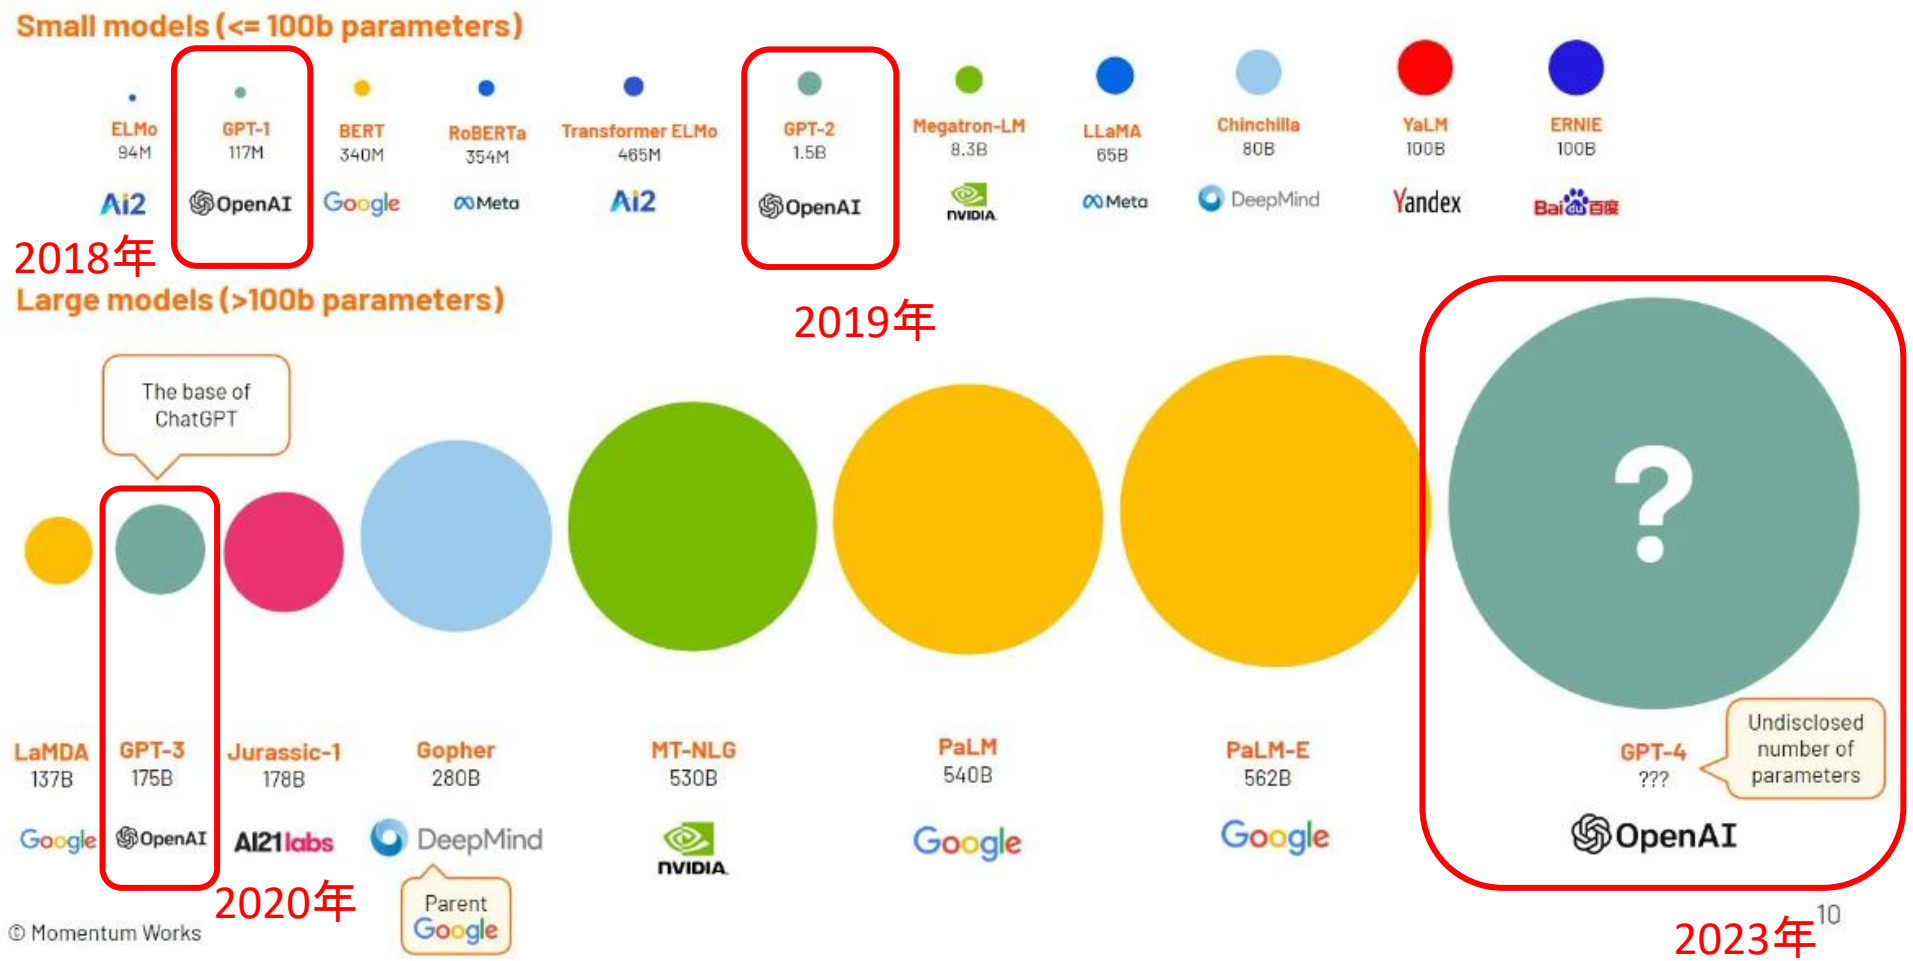
なぜ今言語モデルなのか

[1] 大規模化に伴う汎用性

[2] 言語以外へのドメインへの影響

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerを使った言語モデルの巨大化



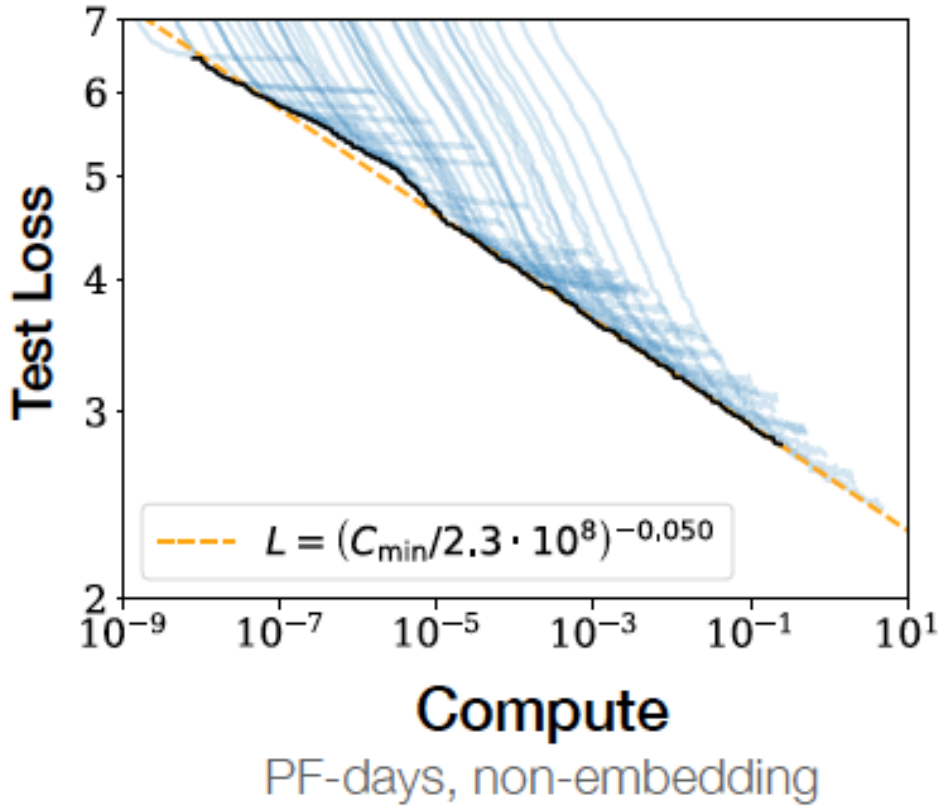
基本的にはいずれも2017年に発明されたTransformerと呼ばれる構造を利用.
GPT-3登場以降，米国企業を中心に複数の研究機関が独自の大規模言語モデルを開発.

[6] Momentum Works 2023 “The future by ChatGPT” より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

なぜいまLLMを学ぶのか？ 1. Scaling and Emergence

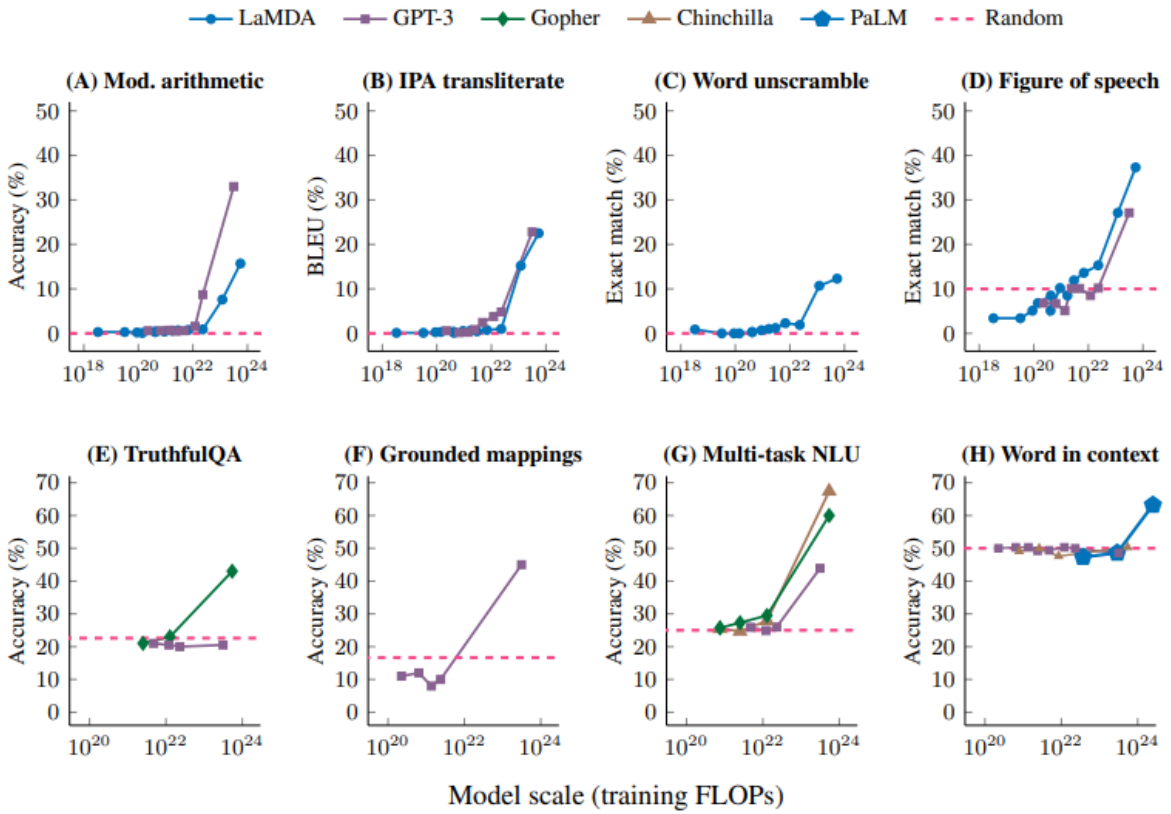
Scaling Law



3つの変数に関するべき乗に従って上がる.

計算資源 *C*, データセットサイズ *D*, パラメータ数 *N*

Emergent Ability



モデルサイズが巨大なときのみ解けるタスクが存在

[7] Jared Kaplan et al. (2020), "Scaling Laws for Neural Language Models" より引用(左図)
[8] Jason Wei et al. (2022), "Emergent Abilities of Large Language Models" より引用(右図)

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

“Language Models are Few-Shot Learners”, 2020

GPT-3の学習データ量

GPT-3の事前学習トークン数

Dataset	Quantity (tokens)
Common Crawl (filtered)	410 billion
WebText2	19 billion
Books1	12 billion
Books2	55 billion
Wikipedia	3 billion

- 約5000億トークン*のテキストを利用

  *トークンとは，言語AIが処理する単位.

  日本語だと大体1文字1トークン
- *書籍でいうとGPT-3は**約500万冊**に相当

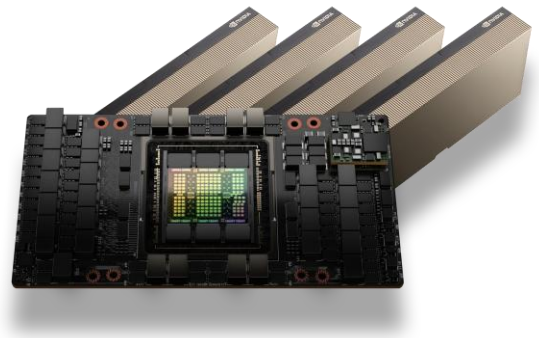
  参考：東大図書館が**約130万冊**,

  国会図書館が**約4700万冊**
- *リーク情報によるとGPT-4は**約1.3億冊**に相当

[9] Tom Brown et al. (2020), “Language Models are Few-Shot Learners”, NeurIPS2020 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

大規模な計算を行うためのツール：GPU



GPUs as fast matrix multipliers

Fast Matrix Multiplies using Graphics Hardware

E. Scott Larsen
Department of Computer Science
University of North Carolina at Chapel Hill
Chapel Hill, NC 27599-3175 USA
larsene@cs.unc.edu

David McAllister
Department of Computer Science
University of North Carolina at Chapel Hill
Chapel Hill, NC 27599-3175 USA
davemc@cs.unc.edu

Implementation

We mention here some observations we made during our implementation that may be of interest to those duplicating our results.

Refresh Rate We found that setting the refresh rate on the monitor as low as possible made marginal improvements (about 10%).

RGBA We found that 4 numbers can be packed into a single pixel, by setting the red, green, blue, and alpha channels to different values.

Texture Format Changing the format of the texture creation and read-back from RGBA to ABGR_EXT (in OpenGL) gave about 40% improvement on our hardware. This is because the hardware driver avoids reformatting the data from the application format to the card format. There is a number of options here, with near equal performance for each option except the one used natively on the specific hardware. The native format should give significant improvement.

Full Screen Running full screen instead of in a window provides improved performance.

Various other optimizations yielded minor (<1%) improvements.

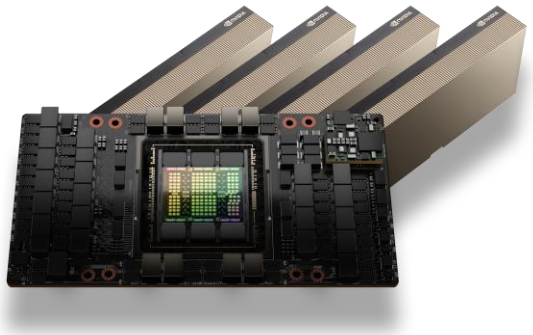
Early days of NVIDIA GPUs – programmable shaders. Researchers hacked this to do matmuls

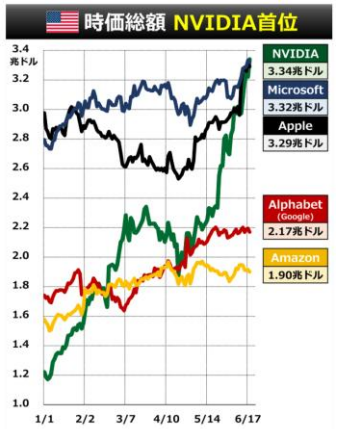
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

大規模なモデル / データを支える大規模な計算資源（GPU）

AIの開発には、膨大なデータを高速に処理する計算資源が必要。現在よく用いられる計算資源はGPUと呼ばれるもので、支配的なシェアを持つNVIDIAも急成長。日本もGPUの確保に動いているが、海外勢との格差は大きい

GPU (H100, A100, V100などの種類が存在)





世界のGPUシェアの90%を占めるNVIDIA（米）はAI需要を追い風に急成長。一時は世界の時価総額首位に

GPT3相当の場合：A100 × **1,200基 × 30日**

GPT4相当の場合：A100 × **25,000基 × 100日** (*)

今回の演習の場合：A100 × **8基 × 1時間**

(*)リーク情報。OpenAIの公式発表ではない

国内外の代表的なGPUクラスタ(*)

(*)GPUを搭載した複数の計算機をまとめて提供するシステム

国内

・産総研のABCI：
960基のA100 GPU → **6,128基**のH200 GPU
*2025年1月アップグレード
・Softbank：**6,000基**のGPU
・さくらインターネット：**2,000基**のH100GPU

海外

1企業で数十万~百万基のH100 GPUを保有
(以下、24年単年の購入数)
・Google：**169,000基**
・Amazon：**196,000基**
・Meta：**224,000基**
・Microsoft：**485,000基**

[10] Dan Swinhoe (2024), "Microsoft bought twice as many Nvidia Hopper GPUs as other big tech companies - report", DataCenterDynamics,https://www.datacenterdynamics.com/en/news/microsoft-bought-twice-as-many-nvidia-hopper-gpus-as-other-big-tech-companies-report/

この差は、根本的には前述の構造的な問題、つまりITサービスと生成AIの間の好循環が作り出せているか、から来ている

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

スケールがもたらしたもの – 汎用性 –

Pre-training （事前学習）

Output: word probability
by analyzing text data

LLMs (Transformer)

Input: Language models determine
[mask]

Original: Language models determine word probability by analyzing text data

Translation (Few-Shot)

```
1  Translate English to French:        ← task description
2  sea otter => loutre de mer          ← examples
3  peppermint => menthe poivrée        ← examples
4  plush girafe => girafe peluche      ← examples
5  cheese =>                           ← prompt
```

Translation (Zero-Shot)

```
1  Translate English to French:        ← task description
2  cheese =>                           ← prompt
```

Summarization (Zero-Shot)

- Starting with “TL;DR” drastically improves the performance

Many other examples

[9] Tom Brown et al. (2020), “Language Models are Few-Shot Learners” より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

"On the Opportunities and Risks of Foundation Models", 2021

■ 補足 | 基盤モデル（補足）



On the Opportunities and Risks of Foundation Models

Rishi Bommasani* Drew A. Hudson Ehsan Adeli Russ Altman Simran Arora
Sydney von Arx Michael S. Bernstein Jeannette Bohg Antoine Bosselut Emma Brunskill
Erik Brynjolfsson Shyamal Buch Dallas Card Rodrigo Castellon Niladri Chatterji
Annie Chen Kathleen Creel Jared Quincy Davis Dorottya Demszky Chris Donahue
Moussa Doumbouya Esin Durmus Stefano Ermon John Etchemendy Kawin Ethayarajh
Li Fei-Fei Chelsea Finn Trevor Gale Lauren Gillespie Karan Goel Noah Goodman
Shelby Grossman Neel Guha Tatsunori Hashimoto Peter Henderson John Hewitt
Daniel E. Ho Jenny Hong Kyle Hsu Jing Huang Thomas Icard Saahil Jain
Dan Jurafsky Pratyusha Kalluri Siddharth Karamcheti Geoff Keeling Fereshte Khani
Omar Khattab Pang Wei Koh Mark Krass Ranjay Krishna Rohith Kuditipudi
Ananya Kumar Faisal Ladhak Mina Lee Tony Lee Jure Leskovec Isabelle Levent
Xiang Lisa Li Xuechen Li Tengyu Ma Ali Malik Christopher D. Manning
Suvir Mirchandani Eric Mitchell Zanele Munyikwa Suraj Nair Avanika Narayan
Deepak Narayanan Ben Newman Allen Nie Juan Carlos Niebles Hamed Nilforoshan
Julian Nyarko Giray Ogut Laurel Orr Isabel Papadimitriou Joon Sung Park Chris Piech
Eva Portelance Christopher Potts Aditi Raghunathan Rob Reich Hongyu Ren
Frieda Rong Yusuf Roohani Camilo Ruiz Jack Ryan Christopher Ré Dorsa Sadigh
Shiori Sagawa Keshav Santhanam Andy Shih Krishnan Srinivasan Alex Tamkin
Rohan Taori Armin W. Thomas Florian Tramèr Rose E. Wang William Wang Bohan Wu
Jiajun Wu Yuhuai Wu Sang Michael Xie Michihiro Yasunaga Jiaxuan You Matei Zaharia
Michael Zhang Tianyi Zhang Xikun Zhang Yuhui Zhang Lucia Zheng Kaitlyn Zhou
Percy Liang*[1]

Center for Research on Foundation Models (CRFM) — Stanford University

- 2021/8/16初出のホワイトペーパーで登場した言葉
- Stanfordの研究機関の名称にもなっている（青枠）
- 多様なタスクに適用可能な巨大モデルによるパラダイムシフト

（Abstractより抜粋）

"AI is undergoing a paradigm shift with the rise of models (e.g., BERT, DALL-E, GPT-3) that are trained on broad data at scale and are adaptable to a wide range of downstream tasks. We call these models foundation models to underscore their critically central yet incomplete character"

[11] Rishi Bommasani et al. (2021) "On the Opportunities and Risks of Foundation Models より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

なぜ今言語モデルなのか

[1] 大規模化に伴う汎用性

[2] 言語以外へのドメインへの影響

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

GPT-4による画像の認識（とロボット応用）

GPT-4 visual input example, Extreme Ironing:

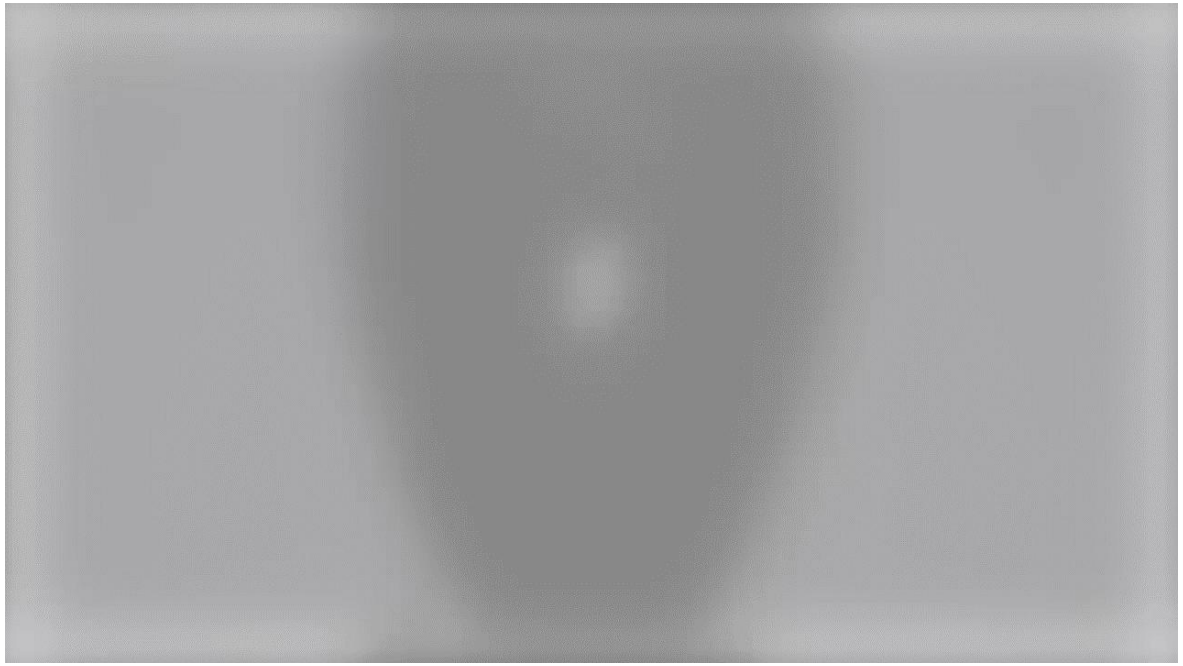
User　What is unusual about this image?



Source: https://www.barnorama.com/wp-content/uploads/2016/12/03-Confusing-Pictures.jpg

GPT-4　The unusual thing about this image is that a man is ironing clothes on an ironing board attached to the roof of a moving taxi.

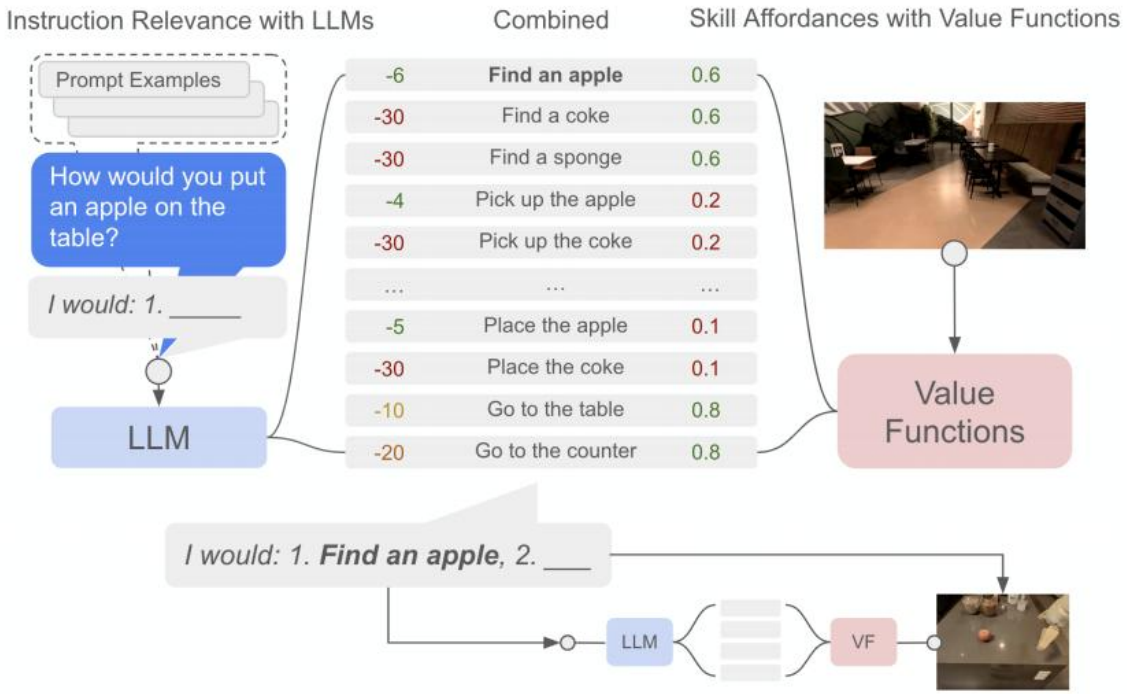
“GPT-4 Technical Report ”, 2024



[13] Figure AI Inc. (2024), "Figure Official Website" https://www.figure.ai/

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

■LLMの活用 | Say-Can and Say-Can-PaLM



[14] Michael Ahn et al. (2022),“Do As I Can, Not As I Say: Grounding Language in Robotic Affordances” より引用

- 言語モデルが出力したスキルの実行可能性（Skill Affordance）を考慮して選択
  - 実行可能性はTDで学習
- 言語モデルをよくする（PaLMを使う）と性能が改善する

※ 実行可能なスキル（低レベル方策）はあらかじめ用意されている点に注意

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

行動系列の生成（実行結果）

Task : bring me a noodle from the long table



Get command

go(‘long table’,’’)

find_object(‘noodle’, ’long table’)

grab(‘noodle’,’’)



go(‘start point’, ’’)

find_person(‘operator’, ’start point’)

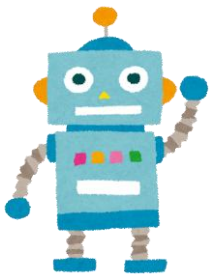
hand_over(‘noodle’, ’operator’)

Task completed

成果例：RoboCup Japan Open 2023優勝，RoboCup世界大会3位

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

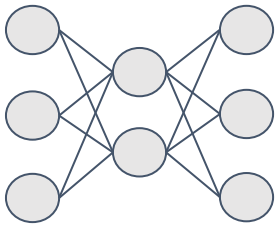
Robotics Foundation Model



action

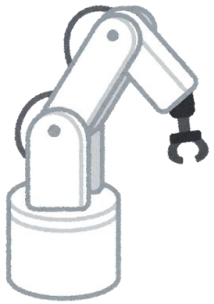
observation

Real World Envonment



Robotics Foundation Model

Training with
large and ***diverse*** data
(action / observation pair)



Industrial Application



Autonomous Driving

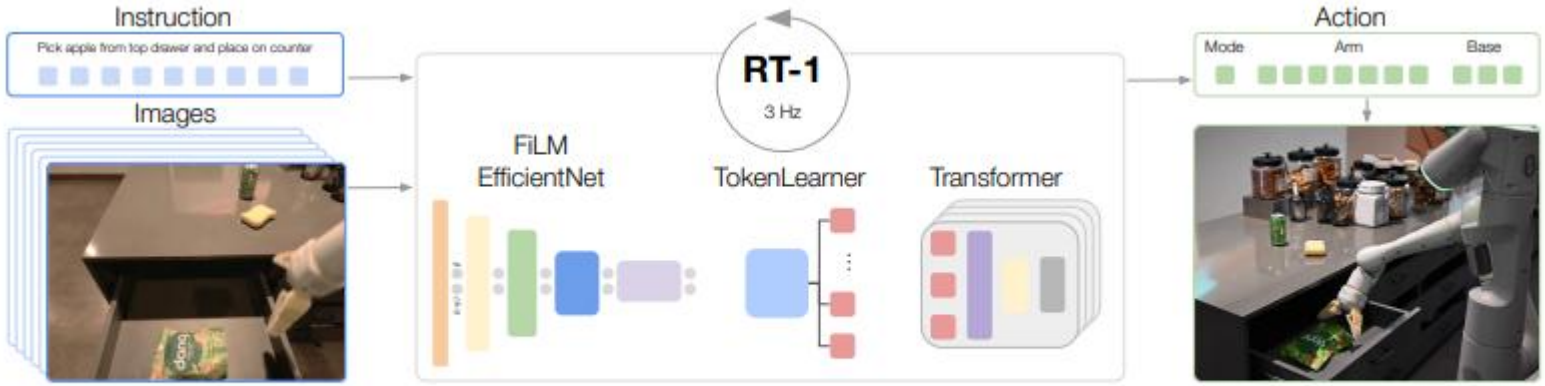


Life Support

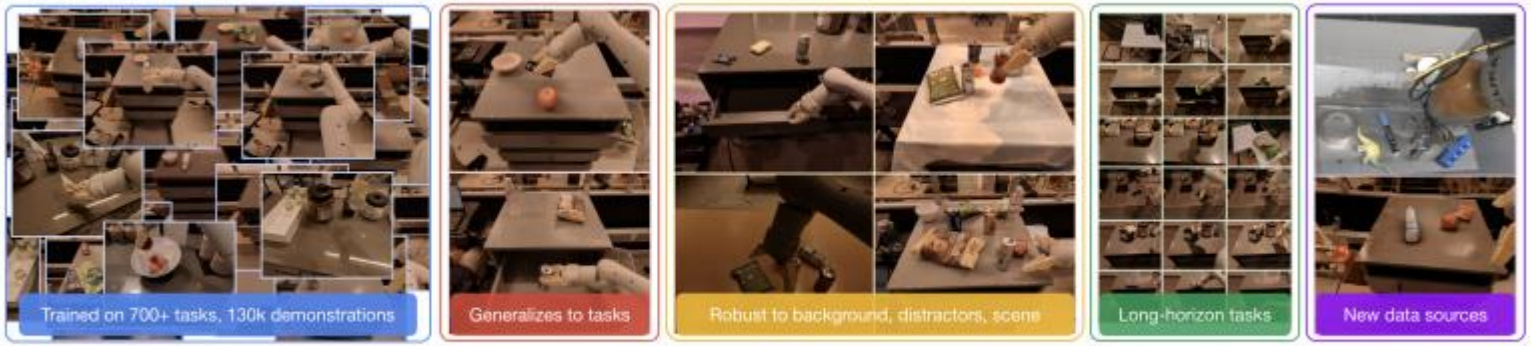
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

“RT-1: Robotics Transformer for Real-World Control at Scale”, 2022

Robot Transformer（RT-1）



(a) RT-1 takes images and natural language instructions and outputs discretized base and arm actions. Despite its size (35M parameters), it does this at 3 Hz, due to its efficient yet high-capacity architecture: a FiLM (Perez et al., 2018) conditioned EfficientNet (Tan & Le, 2019), a TokenLearner (Ryoo et al., 2021), and a Transformer (Vaswani et al., 2017).



(b) RT-1's large-scale, real-world training (130k demonstrations) and evaluation (3000 real-world trials) show impressive generalization, robustness, and ability to learn from diverse data.

<u>モデル</u>

- Efficient NetとTransformerの組み合わせ
- インストラクションに従い動作生成

<u>データ</u>

- EDR13台，17ヶ月，744タスク，13万デモ
- 訓練：97%で動作
- 汎化：種々の意味で大幅向上（未知タスク，未知ソース等
- Long Horizonなタスクも可

※ 類似研究にGato，BC-Zなど

[15] Anthony Brohan et al. (2022), “RT-1: Robotics Transformer for Real-World Control at Scale” より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Collaboration with Google

RT-X Project - Awarded Best Paper at ICRA 2024

- Google Deepmind and 21 research institutes collect offline robot datasets with a unified format
- 22 robot types, 527 skills (160,266 tasks), over 1 million episodes
- Better performance than the model trained on individual data





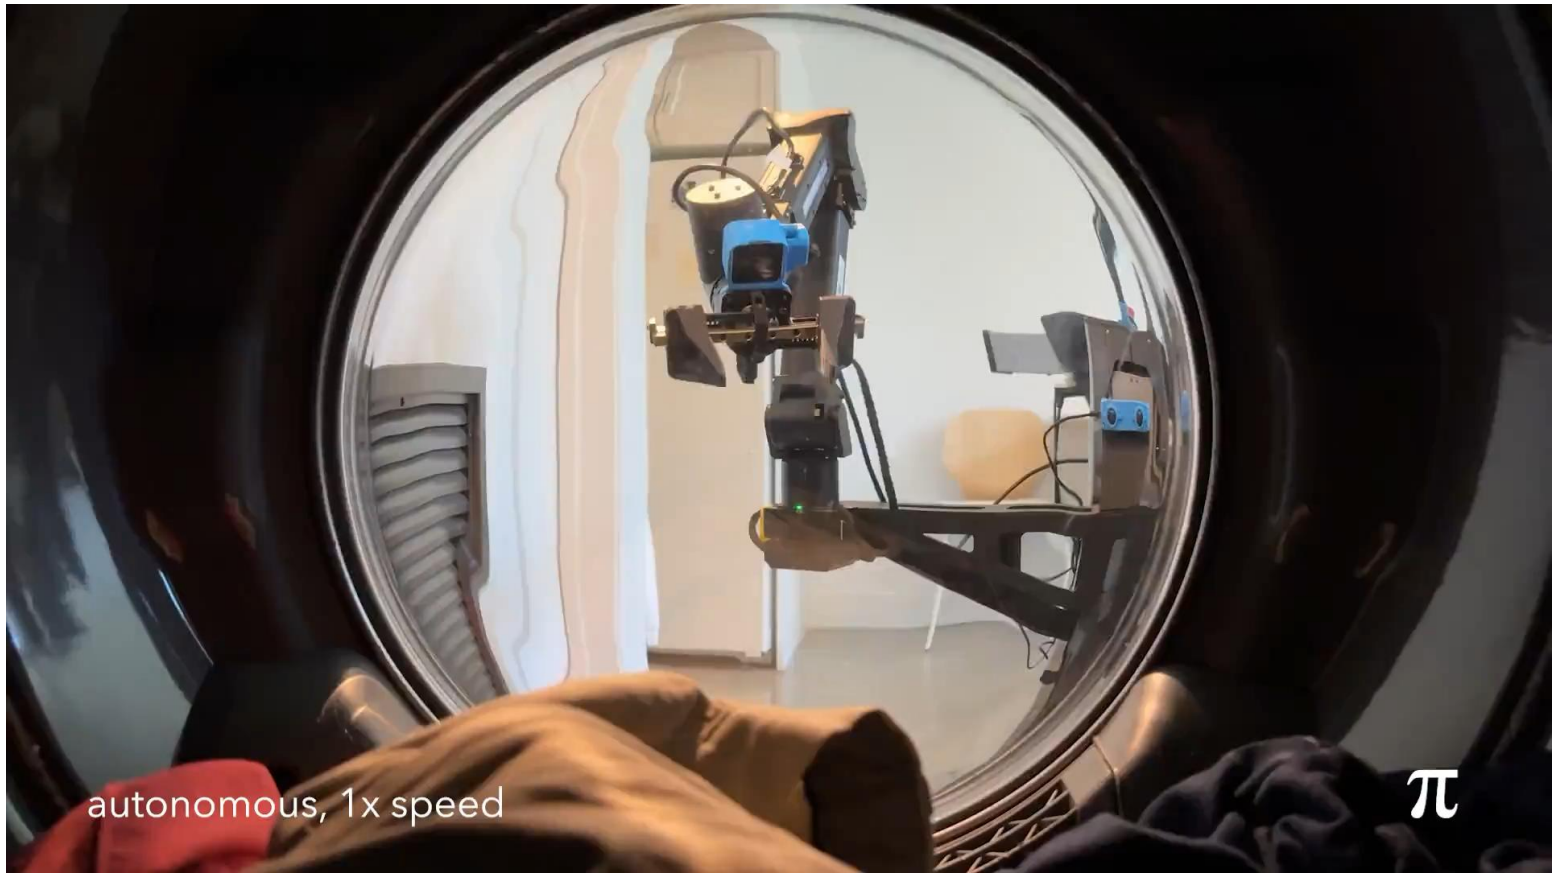
[16]O'Neill, Abby, et al. (2023), "Open x-embodiment: Robotic learning datasets and rt-x models.", arXiv preprint arXiv:2310.08864, Available at: https://arxiv.org/abs/2310.08864

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Vision Language Action Model

- π_0 [Black+ 2024]
  - VLA（Vision-Language-Action）モデル
  - 洗濯物を畳む，卵を割らずにケースに入れるなど，様々なタスクを行うことができる

[17]Physical Intelligence (2024), "π0: A Generalist Model for Physical Intelligence", Physical Intelligence Blog, Available at: https://www.physicalintelligence.company/blog/pi0より引用



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

AIRoA | AI Robot Association

AI Robot Association

Uniqueness

- Led by academia
- Openness
- Reward design

AI × Robot

- Bridging AI and robotics communities.
- Developing general purpose platforms for AI and robotics.

Open

- Creating open platforms and datasets for robotics foundation models.
- Establishing an ecosystem where data and models can co-evolve.

Global

- Developing worldwide software and data platforms.

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

World Simulator | Sora（Open AI）



Prompt: Photorealistic closeup video of two pirate ships battling each other as they sail inside a cup of coffee.



Prompt: A young man at his 20s is sitting on a piece of cloud in the sky, reading a book.

[18]OpenAI (2024), "Sora: Creating video from text", OpenAI Official Website, https://openai.com/sora
[19] OpenAI (2024), "Video generation models as world simulators", OpenAI Research, https://openai.com/research/video-generation-models-as-world-simulators

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

ここまでのまとめと本講座の趣旨

■ ここまでのまとめ

- 言語モデルとは単語列の生成確率をモデル化したもの

  自己回帰言語モデル / ニューラル言語モデル / GPT

- 2025年になってもその活用方法 / モデル自体（大規模推論モデル，拡散言語モデル） / 評価方法に関する研究開発は進展している
- 原理は非常にシンプル．なぜいま言語モデルなのか？
  - 1. モデル，データ，計算量のスケールによりできることが急速に広がっている（汎化性）
  - 2. 言語モデルの発展が他の領域にも影響を与えている

■本講座の趣旨

- LLMの技術的背景，原理や限界を理解する.
- ハイプとしてではなく活用する技術として捉えられるようになる

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

小島 武（こじま たけし）

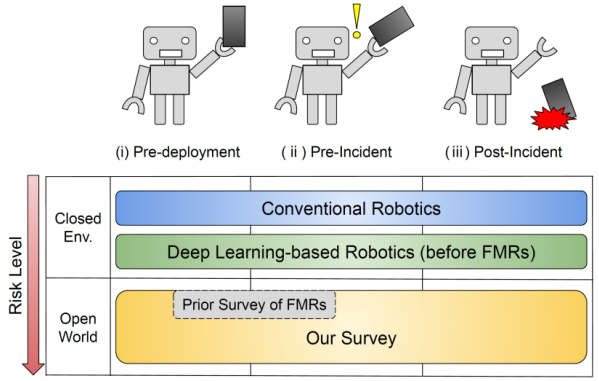
❏略歴

❏2023.3 東京大学大学院 工学系研究科 TMI 博士課程修了

❏2023.4～ 同研究科 特任研究員

❏2025.1～ 同研究科 特任助教

＊以前はITエンジニアをしてました.



[20]Takeshi Kojima, et al. (2025), "A Comprehensive Survey on Physical Risk Control in the Era of Foundation Model-enabled Robotics", arXiv preprint arXiv:2505.12583, Available at: https://arxiv.org/abs/2505.12583



[21]https://github.com/kojima-takeshi188/zero_shot_cot

❏活動

Weblab-10Bの開発，岸田総理・石破総理のLLM特別講座で講師担当，LLM開発コンペ2024・2025運営のコンテンツリーダー，AI白書2025でSafetyの章を執筆

❏研究

LLMの動作原理の理解と制御（Reasoning Model, 多言語等），Safety (Unlearning, 指示追従能力, ロボット），Transformerモデル構造の改善，などなど

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

目次

- LLMの概況
- **各回の概要**
- 日本のLLMを取り巻く環境

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

講座を組み立てるにあたって

今年度は、「大規模言語モデル基礎」と「大規模言語モデル応用」に講座を分けます。

大規模言語モデル基礎（10～11月）：

・LLMの全体像を理解するために、**事前学習・事後学習・データ収集加工・ベンチマーク評価**といった学習パイプラインを網羅的に解説。
・公開済みモデルやAPIを活用し、**推論性能**を向上させる手法についても丁寧に紹介。

大規模言語モデル応用（12月～2月）：

・**軽量化・安全対策・解釈性・ドメイン特化・LLMエージェント**など、LLMの社会実装に不可欠となる技術を本格的に学べる。
・最前線でLLMを研究開発する第一人者による**特別講演**を行います。
・毎年恒例となった「**個人型LLM開発コンペ**」もパワーアップして開催予定。受講者同士の白熱した技術競争が、学びをさらに深めます。

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

LLMの学習パイプラインからみた講座の構成

Step 1

データ収集・加工
事前学習や事後学習に用いる学習データを収集・加工する段階
最近では、LLM自身を利用したデータ合成も盛んに行われている

Day8 新規回

Step 2

事前学習
大規模コーパスによる自己教師あり学習を通して、言語モデルに語彙・文法・知識といった基本的な言語理解を獲得させる段階

Day3 ~ 5

Step 3

ファインチューニング
ラベル付きデータによる教師あり学習を通し、言語モデルの性能を改善したり、特定のタスクやドメインへの適応を実現する段階

Day6

Step 4

強化学習
(人間の)フィードバックを用いた強化学習を通し、言語モデルの出力がより人間の価値観に沿ったものとなるよう調整する段階

Day7

まとめて「事後学習」と呼ぶ

Step 5

推論
事前学習・事後学習が完了したモデルに対して、プロンプティングを駆使することによって更に性能を向上させる段階

Day2 次回

Step 6

ベンチマーク評価
学習に使われていないサンプルから構成されるベンチマークを用いてモデルの性能を評価する段階

Day8 新規回

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

LLM講座2025【基礎編】の全体像

[22]東京大学 松尾・岩澤研究室 (2026), "大規模言語モデル社会実装講座", 東京大学Web.Lab教育プログラム, https://weblab.t.u-tokyo.ac.jp/education/large-language-model/

- 第1回：講座概要 ⇦ **いまココ**
- 第2回：推論（Prompting，In-context Learning）
- 第3回：事前学習
- 第4回：スケール則
- 第5回：事前学習（上級編）
- 第6回：ファインチューニング
- 第7回：強化学習
- 第8回：学習データと評価ベンチマークの整備

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第2回：推論（Prompting, In-context Learning）】

LLMの活用法について学ぶ。学習完了後のLLMの性能を引き出す技術を会得する。

Prompting

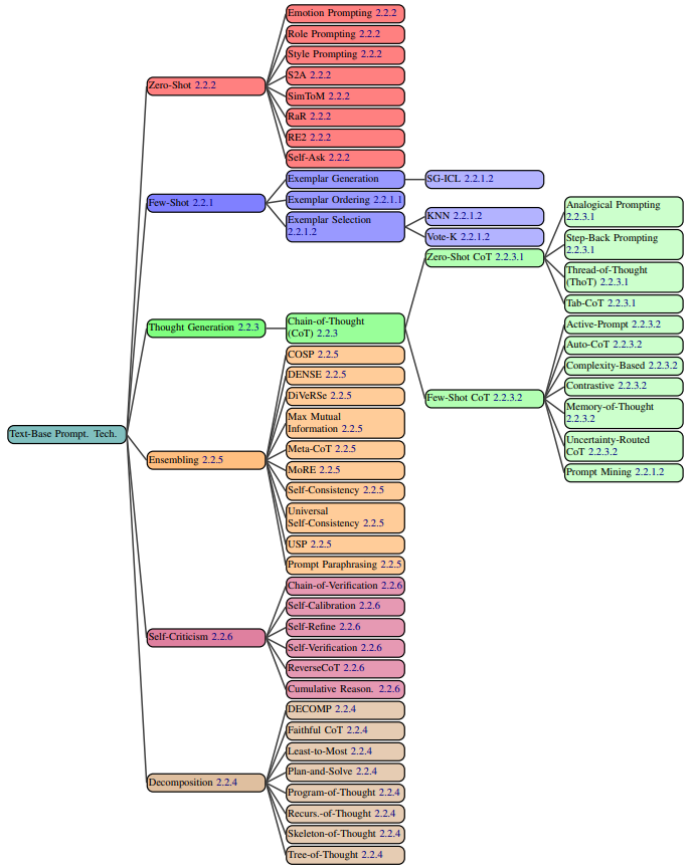
Few-Shot

```
1  Translate English to French:        ← task description
2  sea otter => loutre de mer          ← examples
3  peppermint => menthe poivrée        ← examples
4  plush girafe => girafe peluche      ← examples
5  cheese =>                           ← prompt
```

Zero-Shot

```
1  Translate English to French:        ← task description
2  cheese =>                           ← prompt
```

… etc



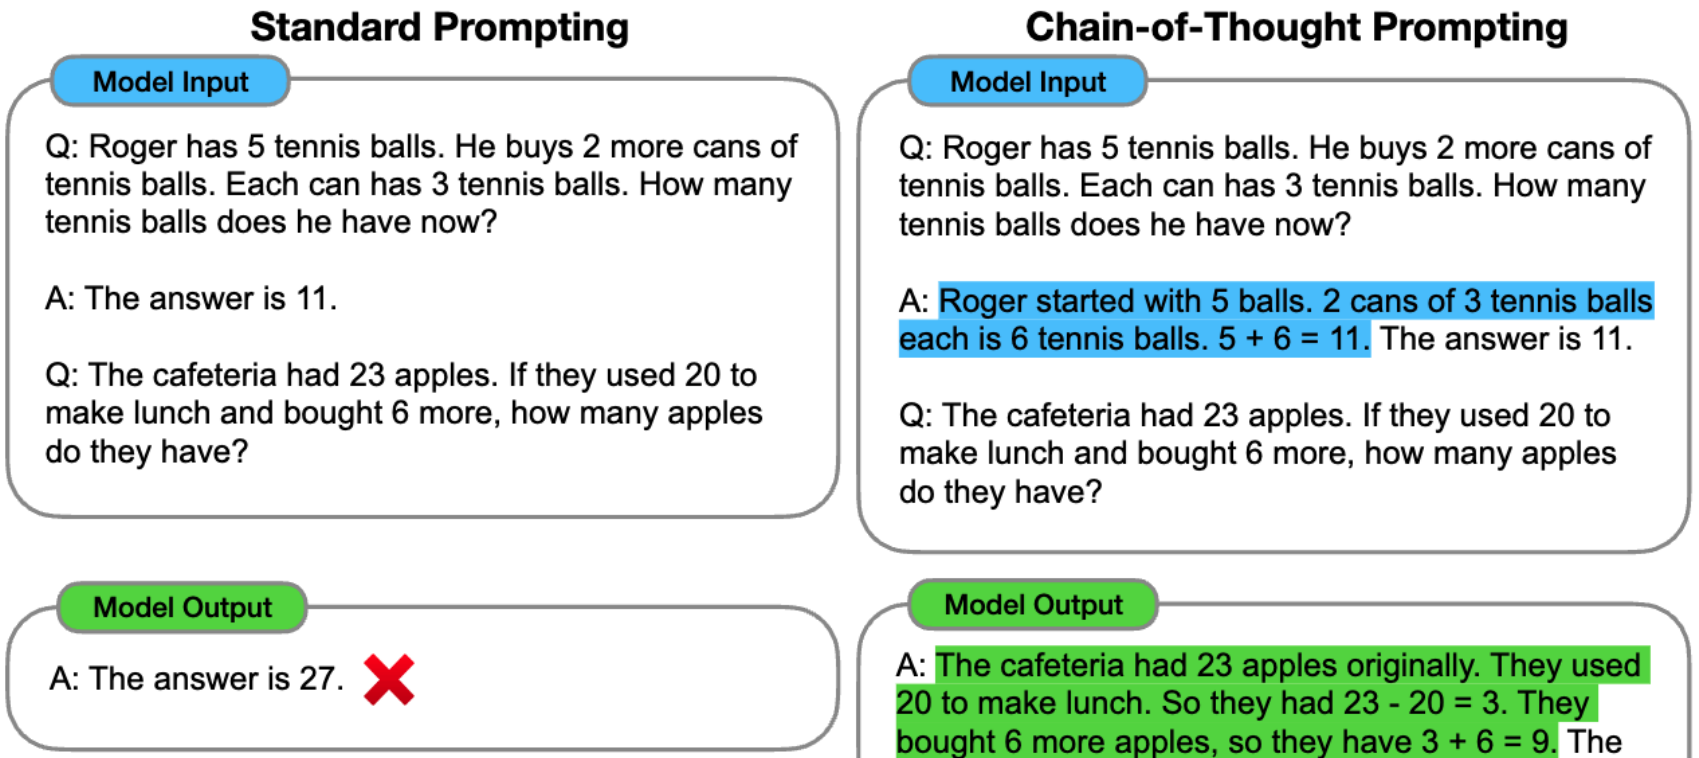
[8] Tom Brown et al. (2020), "Language Models are Few-Shot Learners"より引用

[23]Sander Schulhoff, et al. (2024), "The Prompt Report: A Systematic Survey of Prompt Engineering Techniques", arXiv preprint arXiv:2406.06608, https://arxiv.org/abs/2406.06608

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第2回：推論（Prompting, In-context Learning）】

- **Chain-of-Thought Prompting (CoT)**
  - 答えに至るまでに複数ステップの処理が必要な、多段階推論が必要なタスク
  - 答えに至るまでの思考の連鎖(Chain-of-Thought)を例で与える



[24]Waei et al., 2022, Chain-of-Thought Prompting Elicits Reasoning in Large Language Models

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第2回：推論（Prompting, In-context Learning）】

- **Zero-shot CoT**

  Chain-of-Thoughtの例を与えず、モデル自身に考えさせる。**”Let’s think step by step.”**

  *参考: 共著のShane先生が、最近「Video Models are zero-shot learners and reasoners」を発表していた。

(a) Few-shot

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?
A: The answer is 11.

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?
A:

(Output) The answer is 8. ✗

(b) Few-shot-CoT

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?
A: Roger started with 5 balls. 2 cans of 3 tennis balls each is 6 tennis balls. 5 + 6 = 11. The answer is 11.

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?
A:

(Output) The juggler can juggle 16 balls. Half of the balls are golf balls. So there are 16 / 2 = 8 golf balls. Half of the golf balls are blue. So there are 8 / 2 = 4 blue golf balls. The answer is 4. ✓

(c) Zero-shot

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?
A: The answer (arabic numerals) is

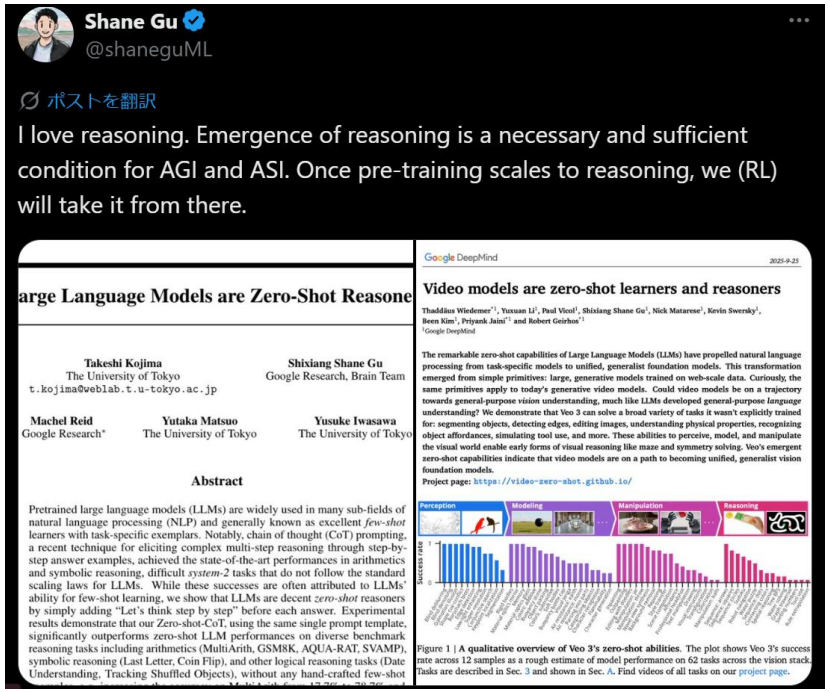
(Output) 8 ✗

(d) Zero-shot-CoT (Ours)

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?
A: ***Let’s think step by step.***

(Output) There are 16 balls in total. Half of the balls are golf balls. That means that there are 8 golf balls. Half of the golf balls are blue. That means that there are 4 blue golf balls. ✓

[25]Kojima et al., 2022, Large Language Models are Zero-Shot Reasoners



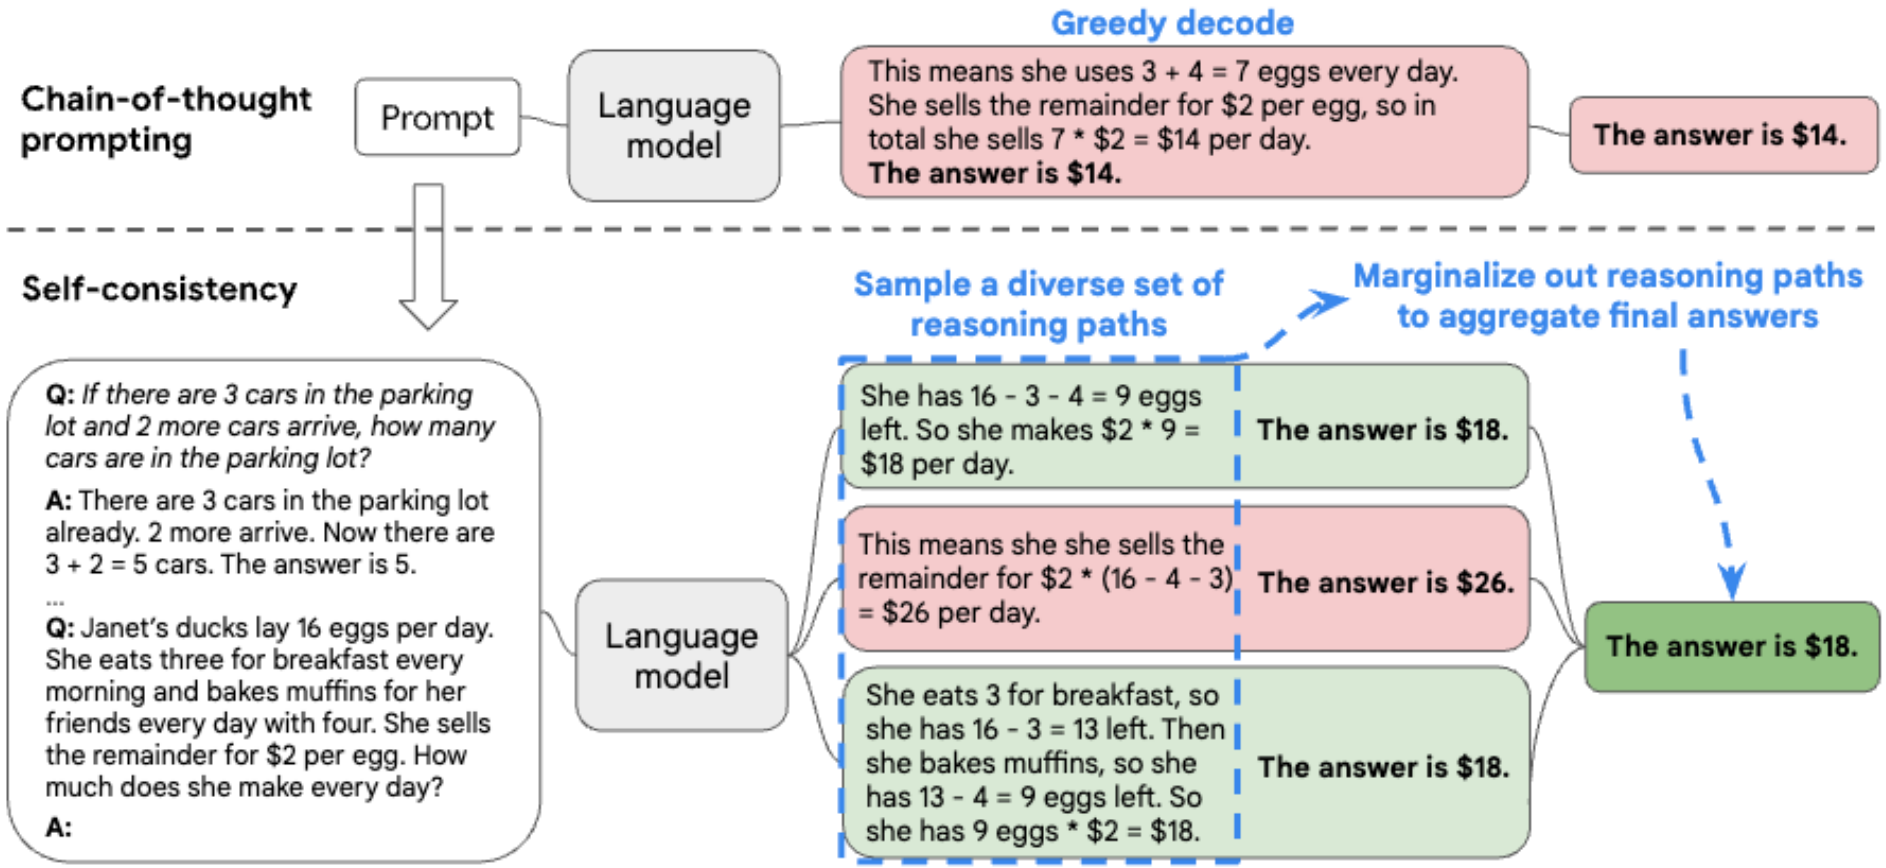
[26]Shane Gu (2025), "X Post (status/1972309771610100179)", X (formerly Twitter), Available at: https://x.com/shaneguML/status/1972309771610100179

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第2回：推論（Prompting, In-context Learning）】

・**CoTを前提とした更なる性能改善例：Self-Consistency, Majority Voting 多数決**

Top-k, Top-p samplingして複数の回答を得る → 一番多かった回答を採用

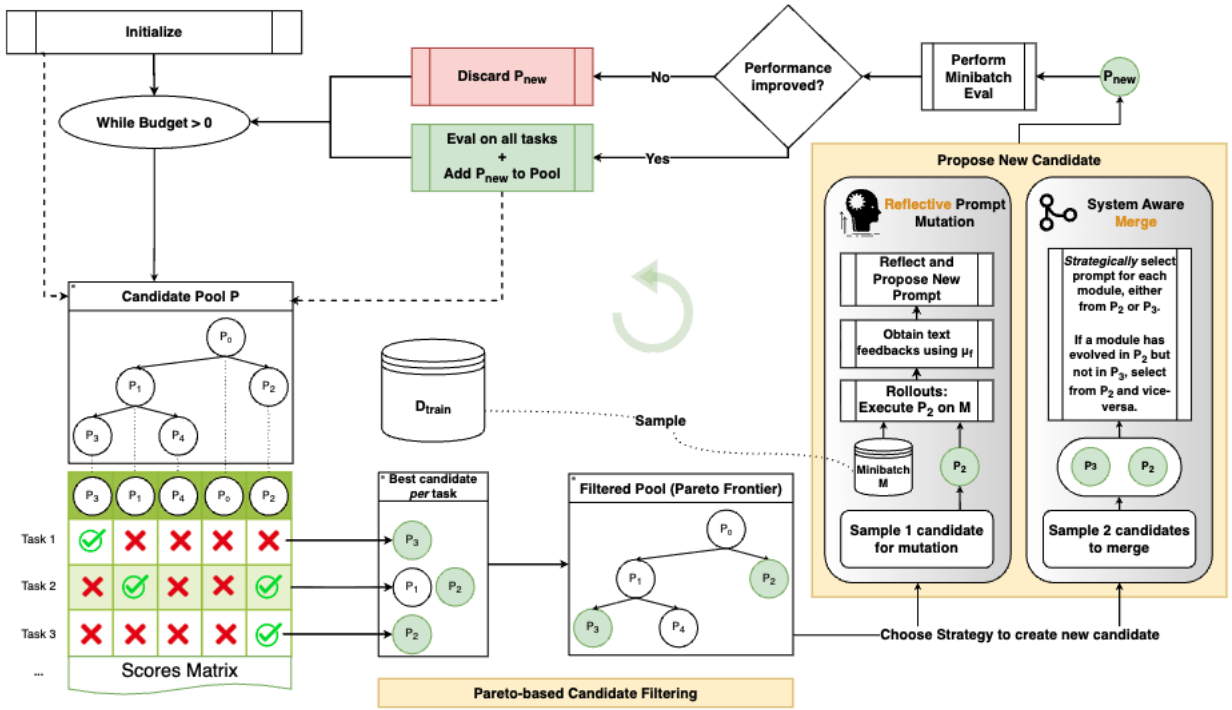


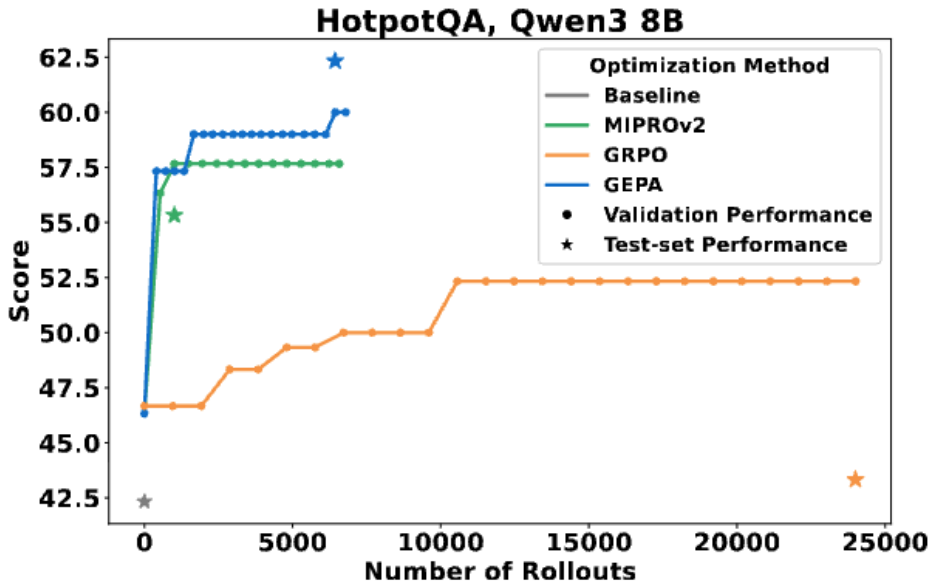
[27] Wang et al., 2023, Self-Consistency Improves Chain of Thought Reasoning in Language Models

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第2回：推論（Prompting, In-context Learning）】

- **Genetic-Pareto (GEPA)：プロンプトの自動改善手法**
  - タスクを実際に行い成功・失敗の軌跡データを元に言語フィードバックでプロンプトを改善、あるいは他の有力なプロンプト候補と組み合わせる
  - 改善するプロンプトを選ぶ際は、多様性確保のために1問だけでも一番良いスコアを出しているプロンプトも候補に入れる





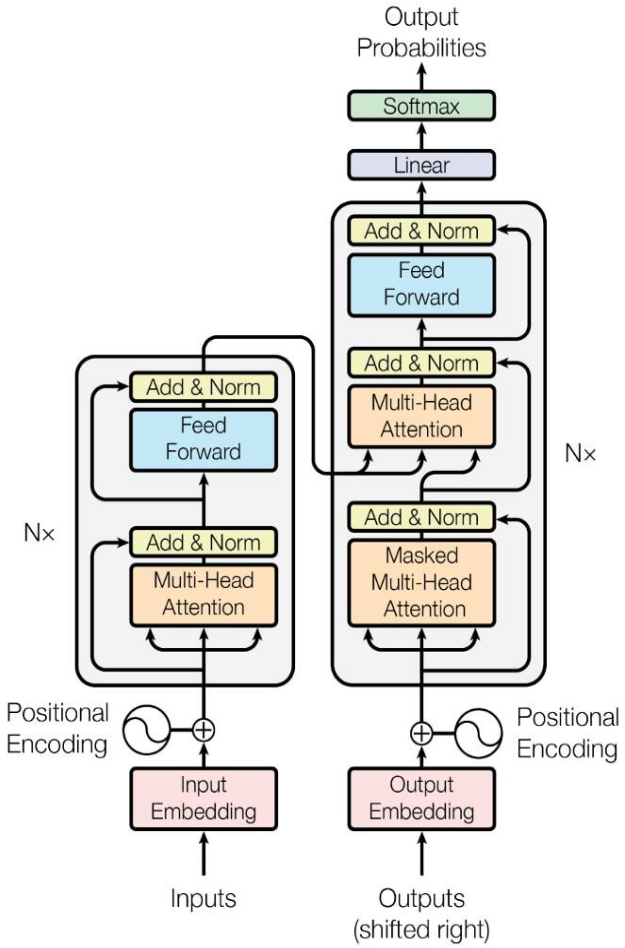
(a) HotpotQA, Qwen3 8B

[28] Agrawal et al., 2025, GEPA: Reflective Prompt Evolution Can Outperform Reinforcement Learning

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第3回：事前学習】

LLMの主流なモデル構造であるTransformerと、その事前学習の仕組みについて学ぶ。



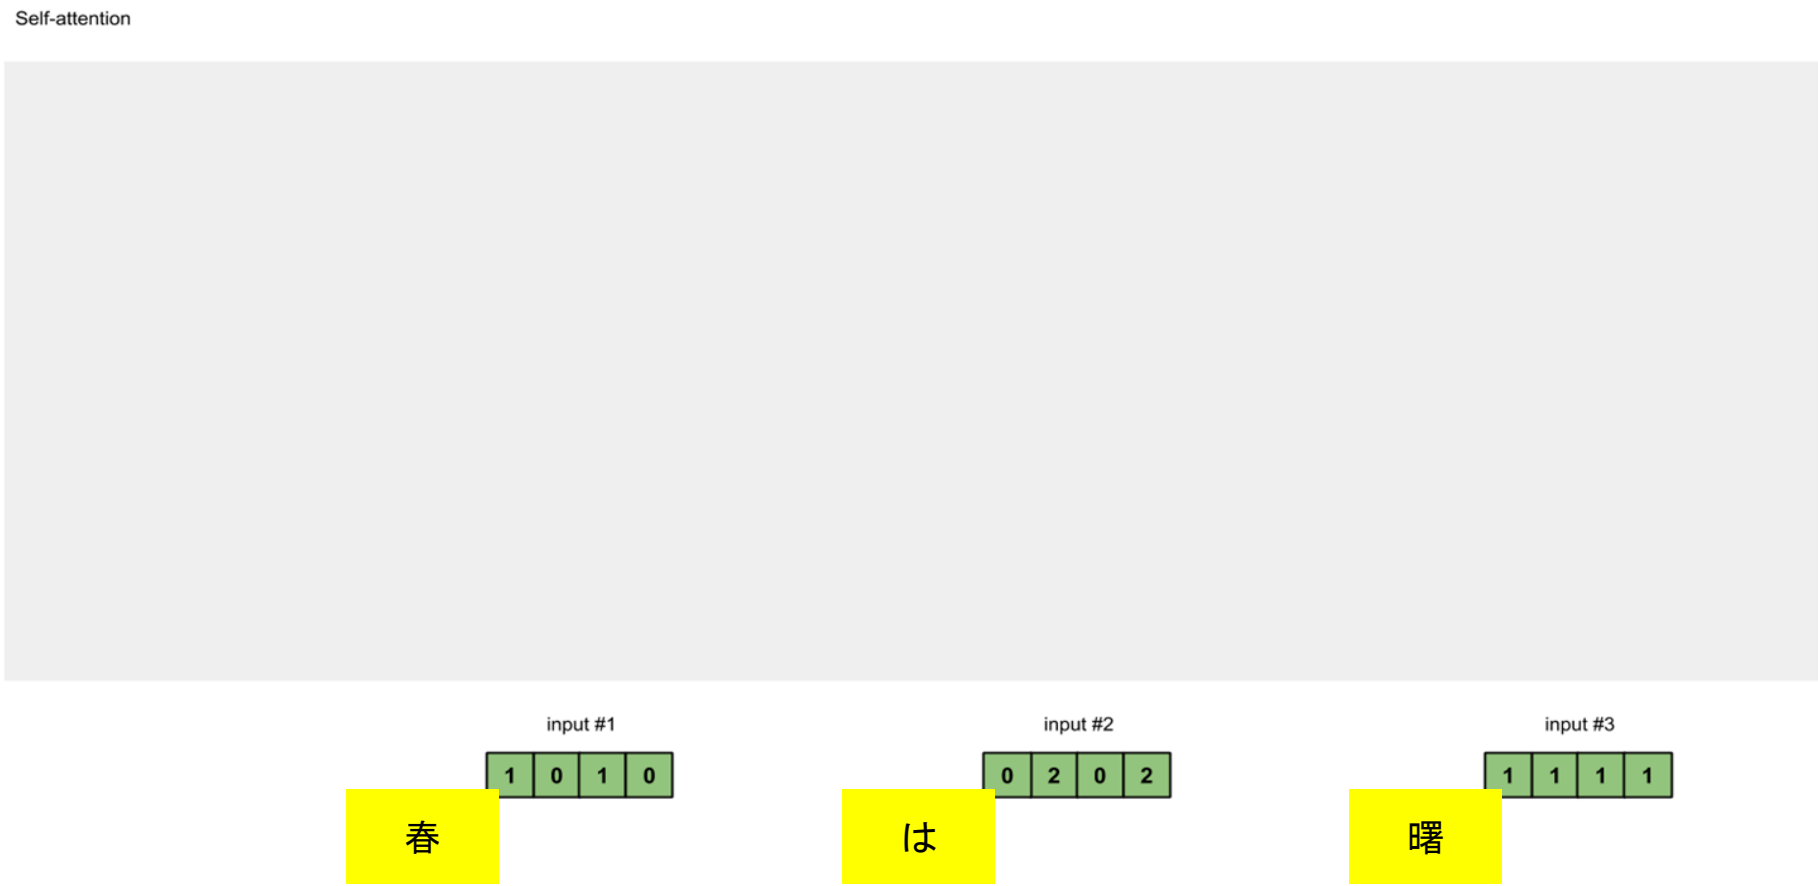
- Embedding
- **Multi-Head Attention (アテンション)**
- Feed Forward
- Others

[1] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第3回：事前学習】

アテンション機構：全単語（トークン）間の類似度を測ることによって、長距離の依存関係を把握する機構.　＊類似度はベクトルの内積で測る.　**⇒必要なトークンの情報を柔軟に取捨選択+並列計算の高速化**



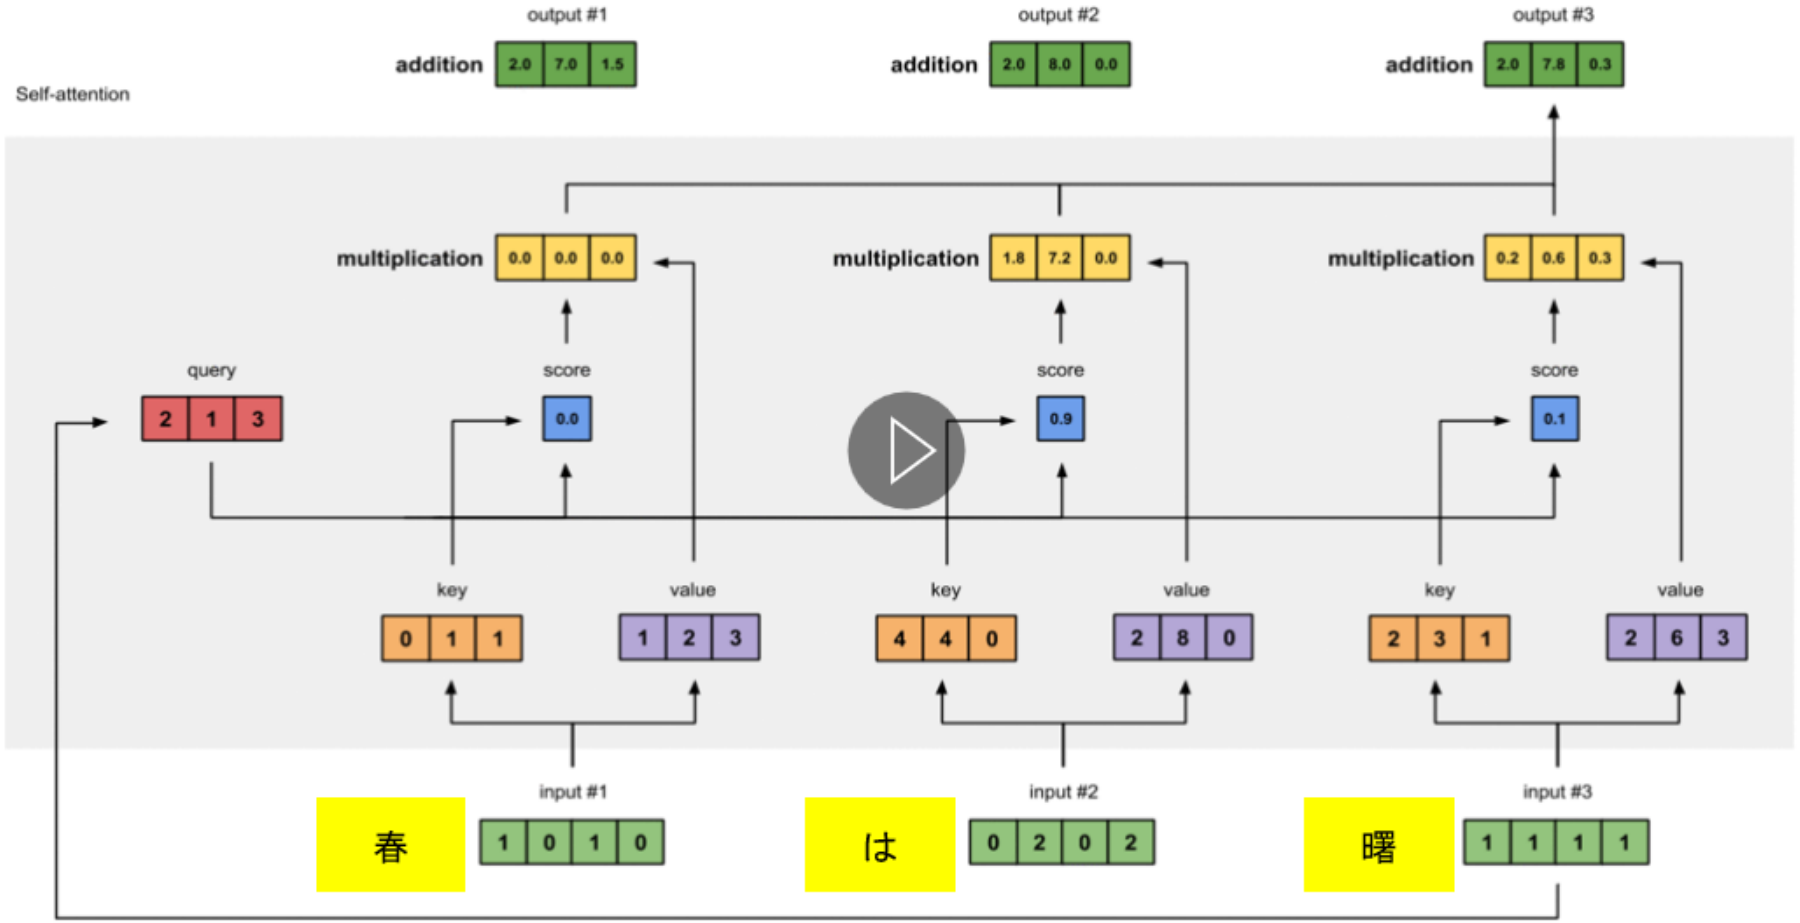
[29] Raimi Karim (2019), "Illustrated: Self-Attention", Towards Data Science, https://towardsdatascience.com/illustrated-self-attention-2d627e33b20a

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第3回：事前学習】

アテンション機構：全単語（トークン）間の類似度を測ることによって、長距離の依存関係を把握する機構.　＊類似度はベクトルの内積で測る.　**⇒必要なトークンの情報を柔軟に取捨選択+並列計算の高速化**

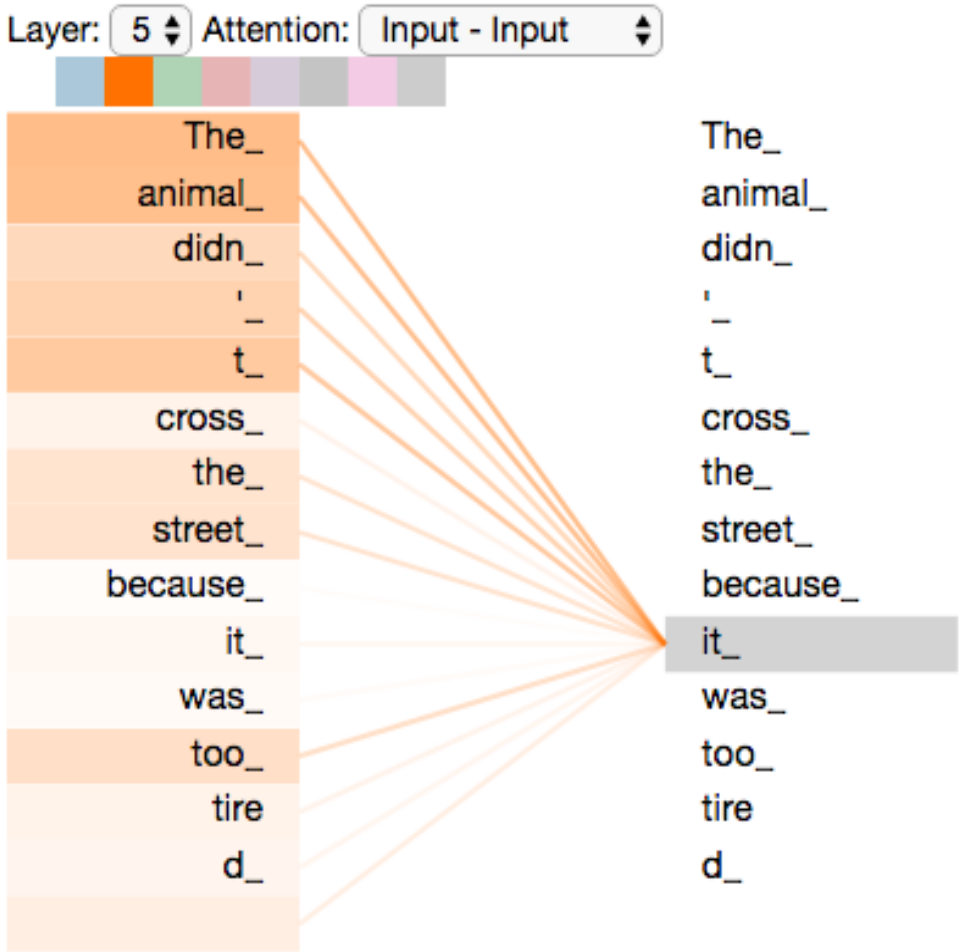


[29] Raimi Karim (2019), "Illustrated: Self-Attention", Towards Data Science, https://towardsdatascience.com/illustrated-self-attention-2d627e33b20a

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第3回：事前学習】

- アテンション機構の可視化例



“it”は、”The” “animal” に対して強いアテンションがかかっていることがわかる.

明示的に教えているわけではないのに，事前学習の過程でモデル自身がこの関係性を導き出している.

＊実際はここまで分かりやすくはない.

[30]Jay Alammar (2018), "The Illustrated Transformer", Visualizing machine learning one concept at a time, Available at: http://jalammar.github.io/illustrated-transformer/

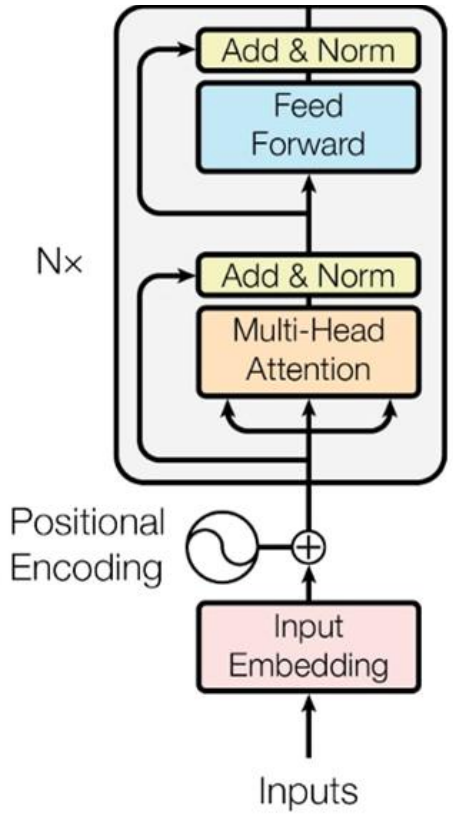
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第3回：事前学習】

Encoder-only

BERT，RoBERTaなど

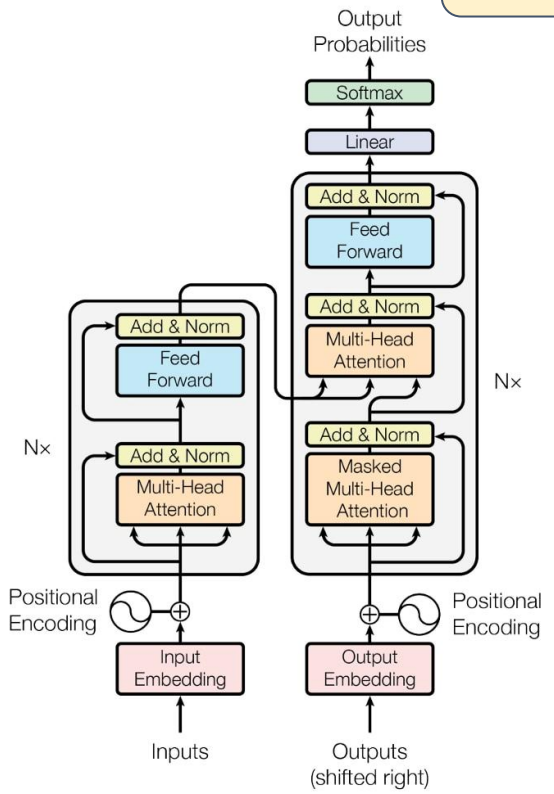
認識系
（クラス分類）



Encoder-Decoder

BART，T5など

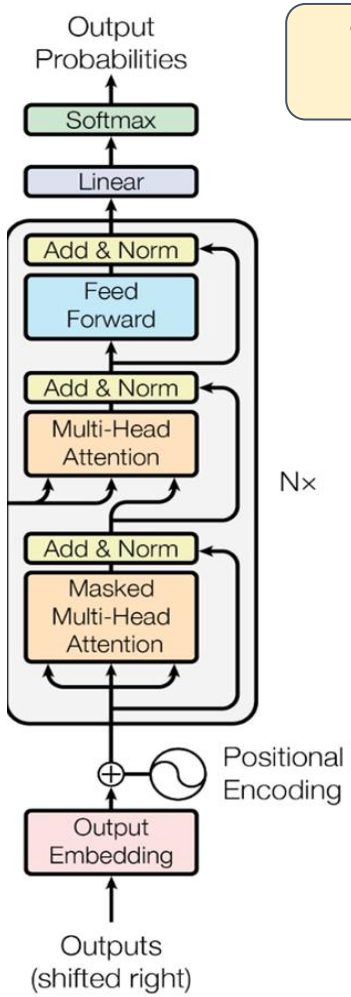
テキスト
生成系



Decoder-only

GPT，Llama, Qwen, DeepSeek等

テキスト
生成系

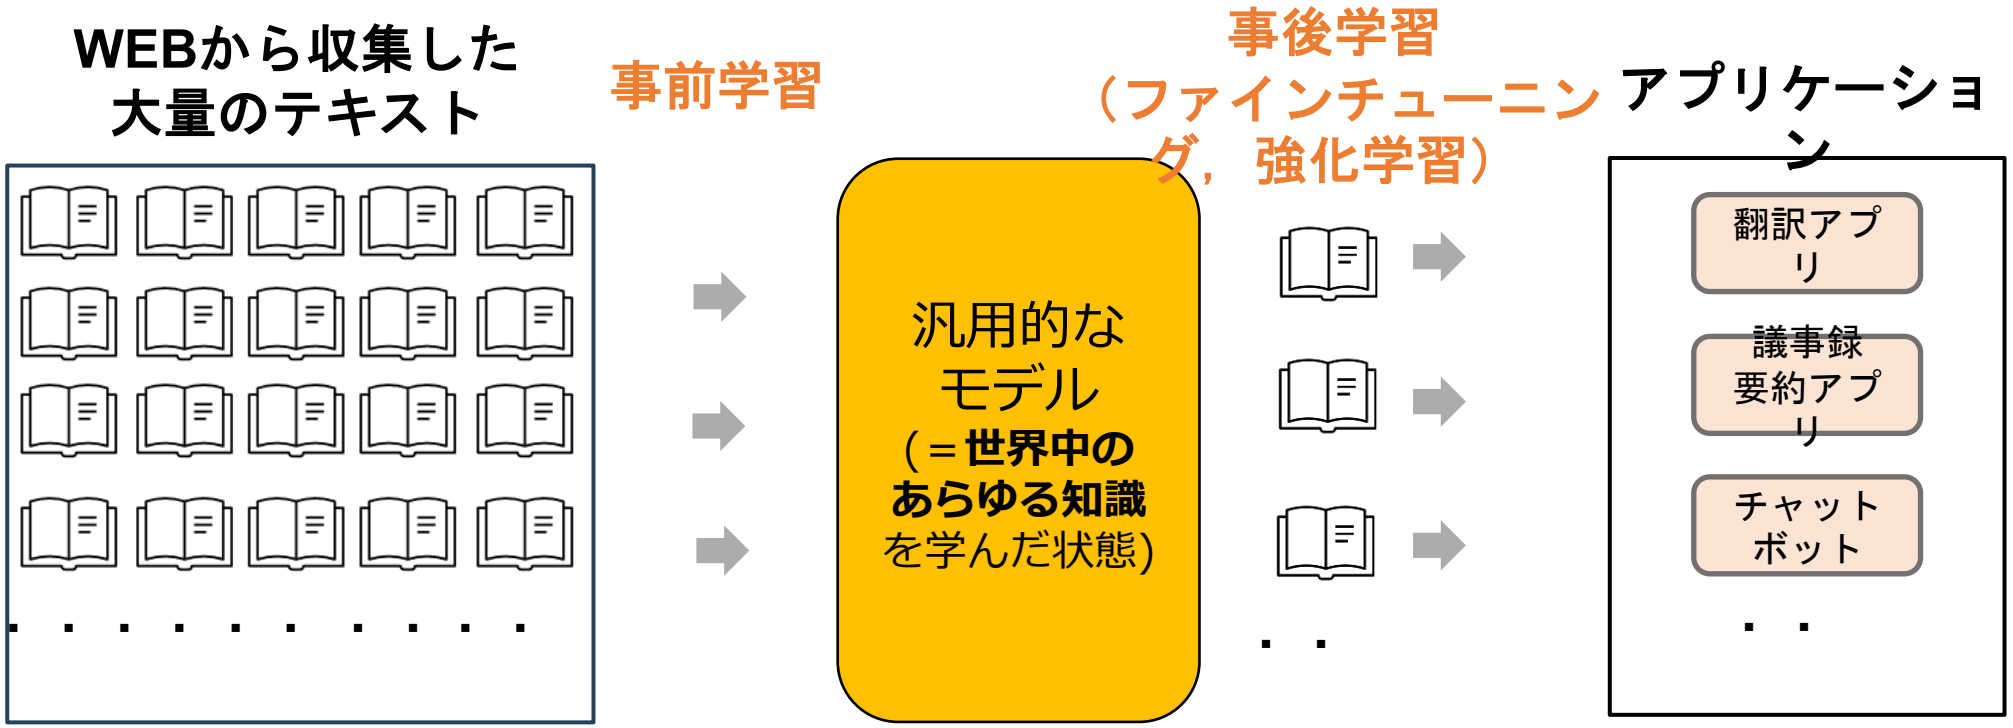


[Vaswani+ 17]，一部改変

講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第3回：事前学習】

LLMの大きな特徴は，翻訳，要約，チャットなど様々な言語タスクへの汎用性．大量のテキストから世界中の知識を**事前学習**することで，言語に関する汎用性を獲得し，さらに**事後学習（ファインチューニングや強化学習）**で特定機能や専門分野に特化する



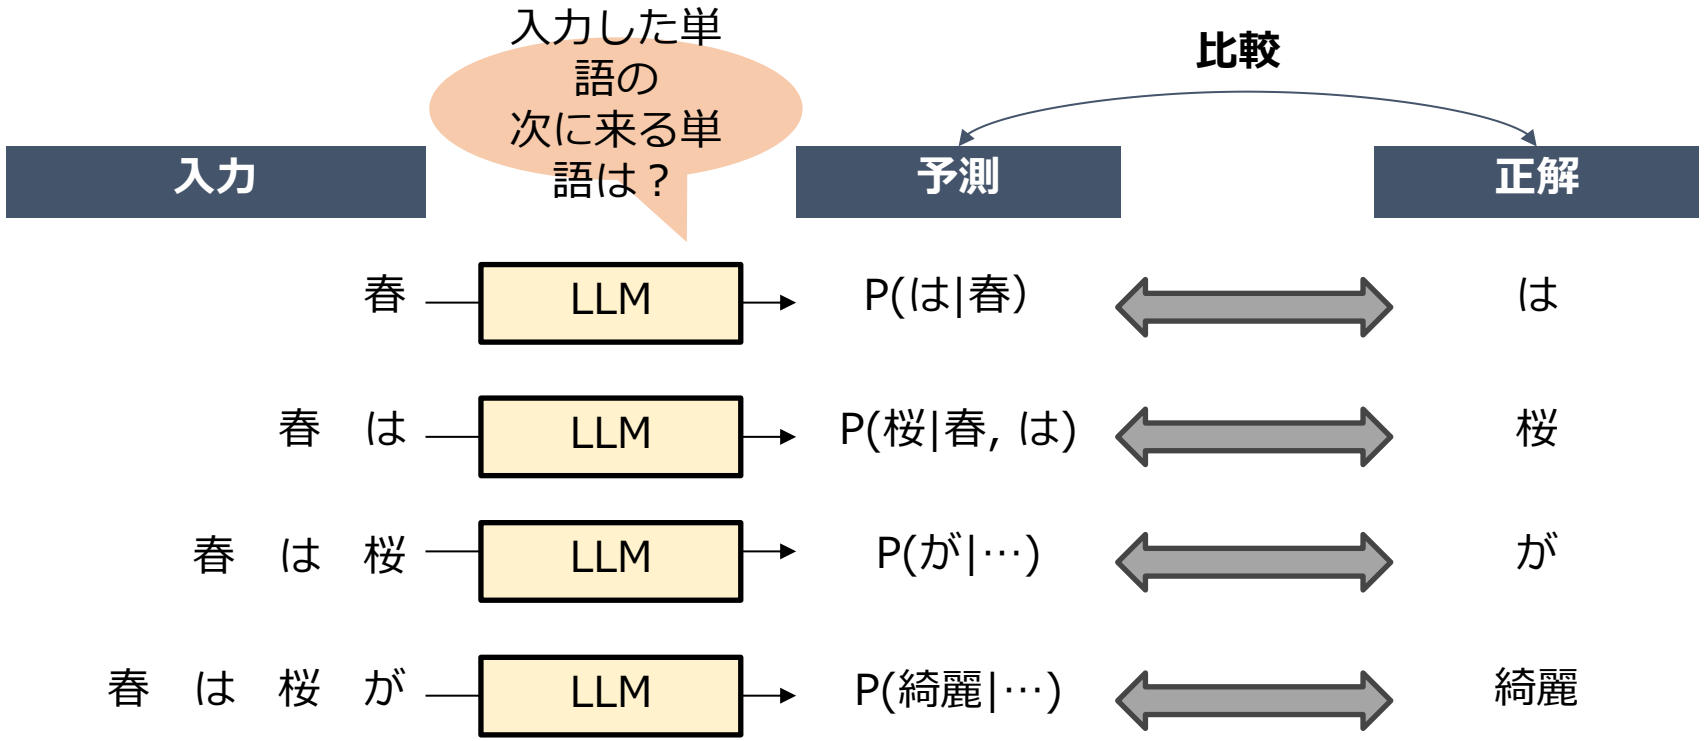
汎用的なモデルが1つあれば、言語に関する様々な機能を開発できる

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第3回：事前学習】

事前学習は，Webから収集した大量の文章を使って，次の単語の予測をひたすら行う
事前学習の過程で，読み書きそろばんや世界中のあらゆる知識を学習する

- GPTシリーズを代表とする現代のLLMは，この**事前学習を必ず行う**
- 例えば以下の図のように，「**春は桜が綺麗**」というテキストの事前学習によって，「春」「桜」「綺麗」という言葉の間に強い関係性があること（＝世界の知識）を学ぶ



予測と正解との誤差（＝交差エントロピー）が小さくなるようにモデルを学習する

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第4回：スケール則】

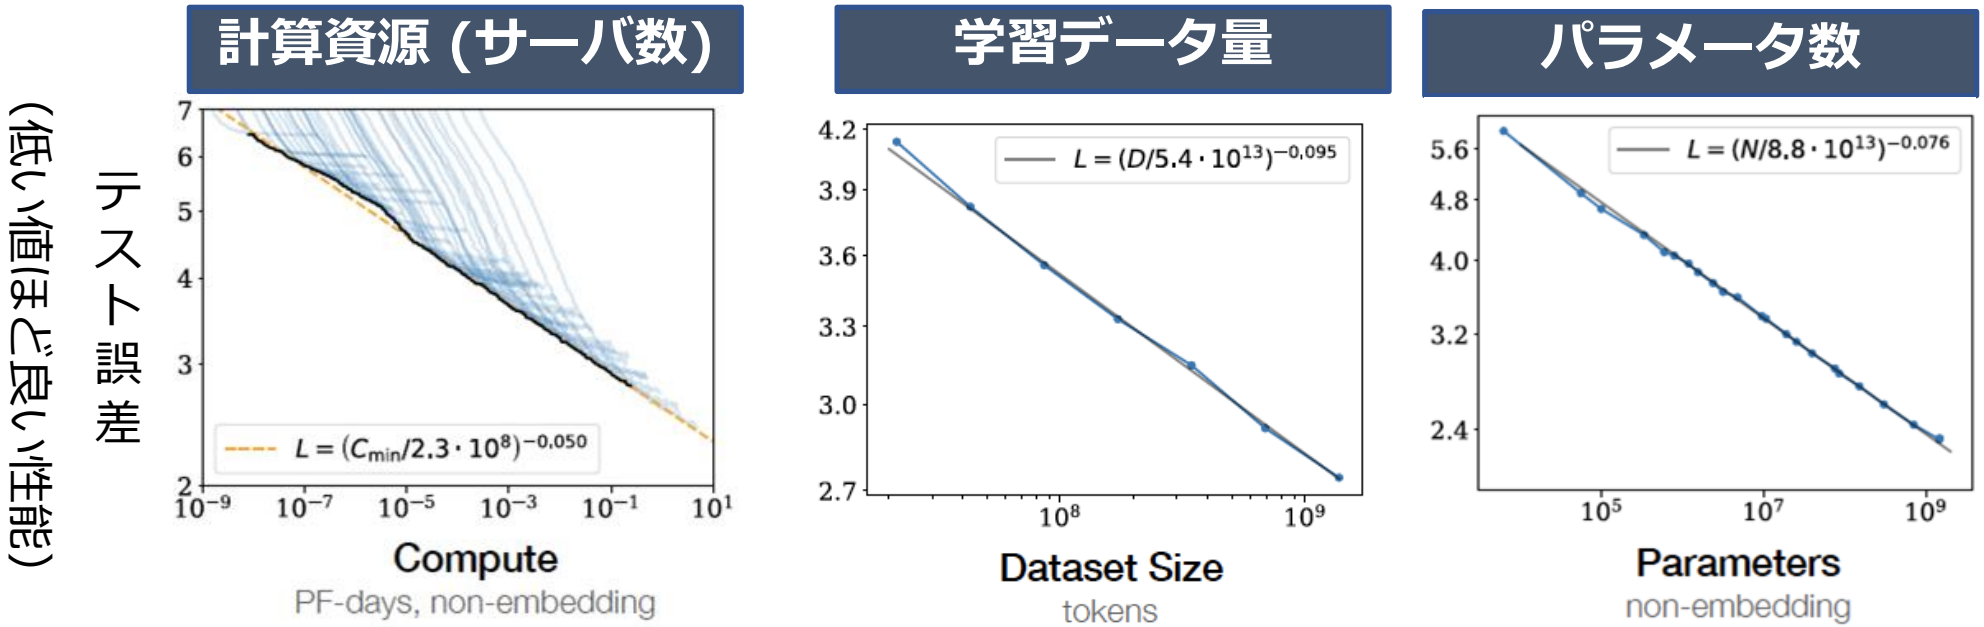
スケール則（Scaling Law）とは，計算資源，学習データ量，パラメータ数の増加に比例して事前学習の性能が上がるという経験則。シンプルに言い換えれば，資源を投入するほどLLMの性能がよくなるということ。

- 発見の経緯：より大きなパラメータサイズの「Transformer」で，より大規模なデータを用いた「事前学習」によってLLMを開発する過程でスケール則が発見された

つまり、資源を投下するほど高性能なLLMが作れる事がわかった．大きく流れが変わった瞬間

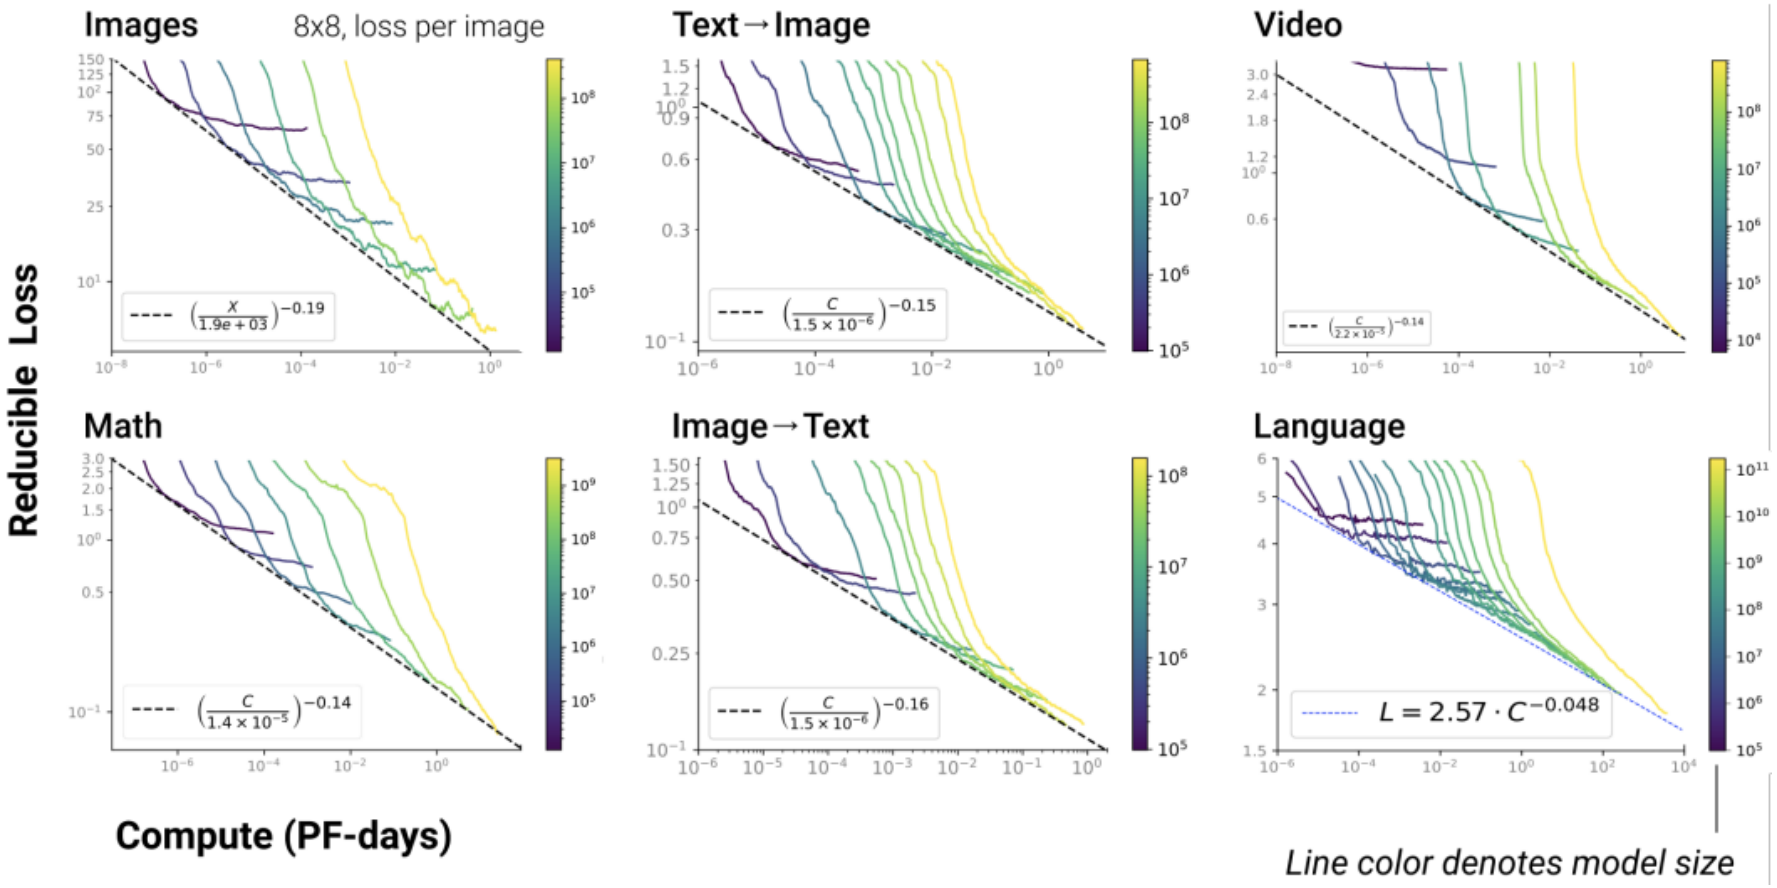
- OpenAIは，いち早くスケール則に目をつけて大規模開発を開始し，その後世界的な投資合戦が始まる

[31]Tom Henighan, Jared Kaplan, et al. (2020), "Scaling Laws for Autoregressive Generative Modeling"



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第4回：スケール則】



画像生成，マルチモーダル，動画，数理等でも計算量に関するスケール則が成立

“Scaling Laws for Autoregressive Generative Modeling”

[31]Tom Henighan, Jared Kaplan, et al. (2020), "Scaling Laws for Autoregressive Generative Modeling", arXiv preprint arXiv:2010.14701, Available at: https://arxiv.org/abs/2010.14701

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

補足：LLMの開発に必要な三要素

スケール則に基づくと，①大規模な計算資源，②大規模データ，③優秀な人材が，LLMの性能を左右する重要資源であることが導かれる．それぞれ，ハードウェア投資，法整備，人的資本投資を必要とする

スケール則

計算資源
が多いほど性能が上がる

学習データ量
が多いほど性能が上がる

パラメータ数
が多いほど性能が上がる

巨大なパラメータのモデルは，人が計算資源・データを使い，ハイパーパラメータの調整や試行錯誤を繰り返して作るもの

生成AIの開発を左右する「三種の神器」

①大規模な計算資源

GPUと呼ばれる，学習を高速で行うサーバの確保が必要

ハードウェア投資の重要性

②大規模データ

膨大な学習用データが必要に．これを集めるために，著作権や個人情報などの取扱方針の整備が必要

法整備の重要性

③優秀な人材

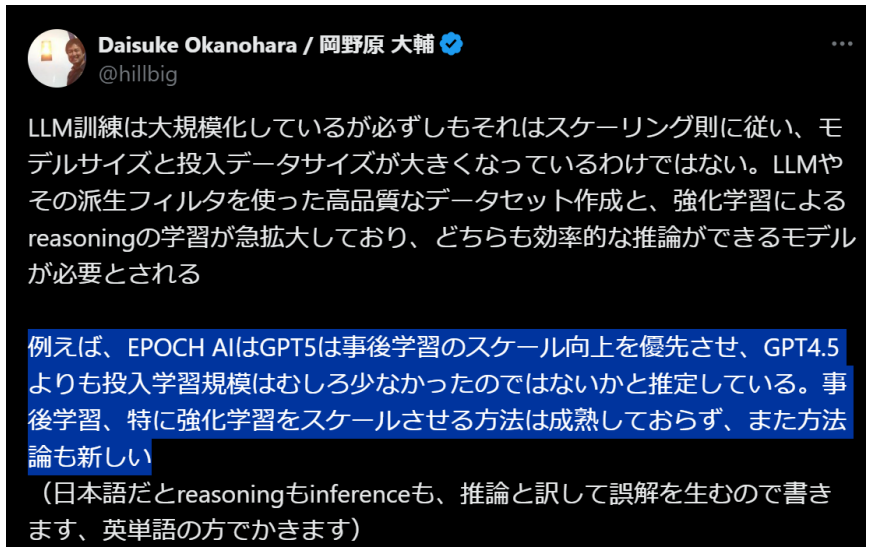
例：トランスフォーマーや学習手法の開発，ハイパーパラメータの調整など

人的資本投資の重要性

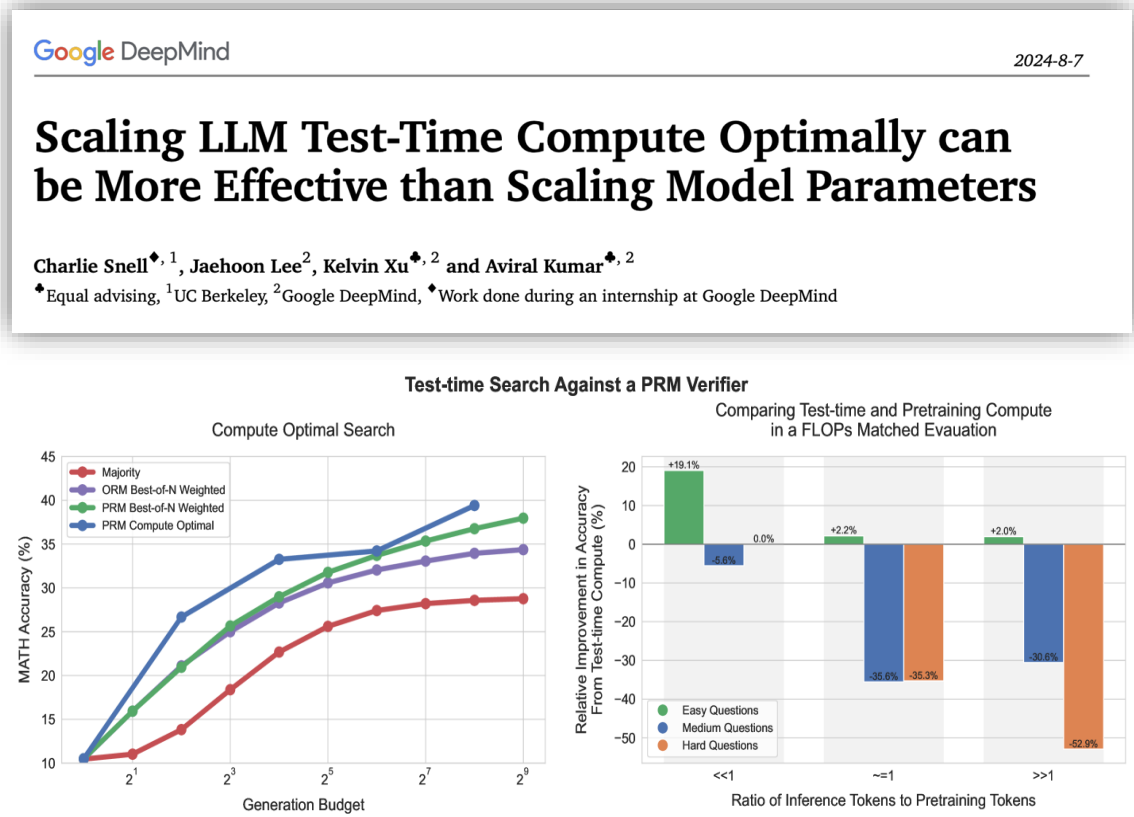
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第4回：スケール則】

- 最近では、事前学習のスケール則だけでなく事後学習や推論のスケール則の研究も盛んに行われている。
  - 事前学習のスケール則
  - **事後学習のスケール則**
  - **推論のスケール則**



[32]Daisuke Okanohara , "X Post (status/1972421341988225340)", X (formerly Twitter), https://x.com/hillbig/status/1972421341988225340

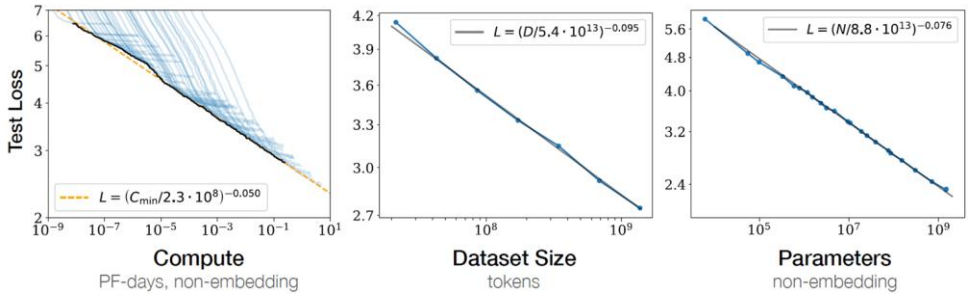


"Scaling LLM Test-Time Compute Optimally can be More Effective than Scaling Model Parameters", 2024

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第5回：事前学習（上級編）】

言語モデルをスケール（＝大規模化）して事前学習する際の課題と解決方法について学ぶ.



計算量（C）
十分な計算量/メモリ量を確保して効率よく訓練する必要

データ（D）
性能を発揮させるための学習用データを用意する必要

パラメータ数（N）
モデルがスケールするにつれて増加するコストを抑える必要

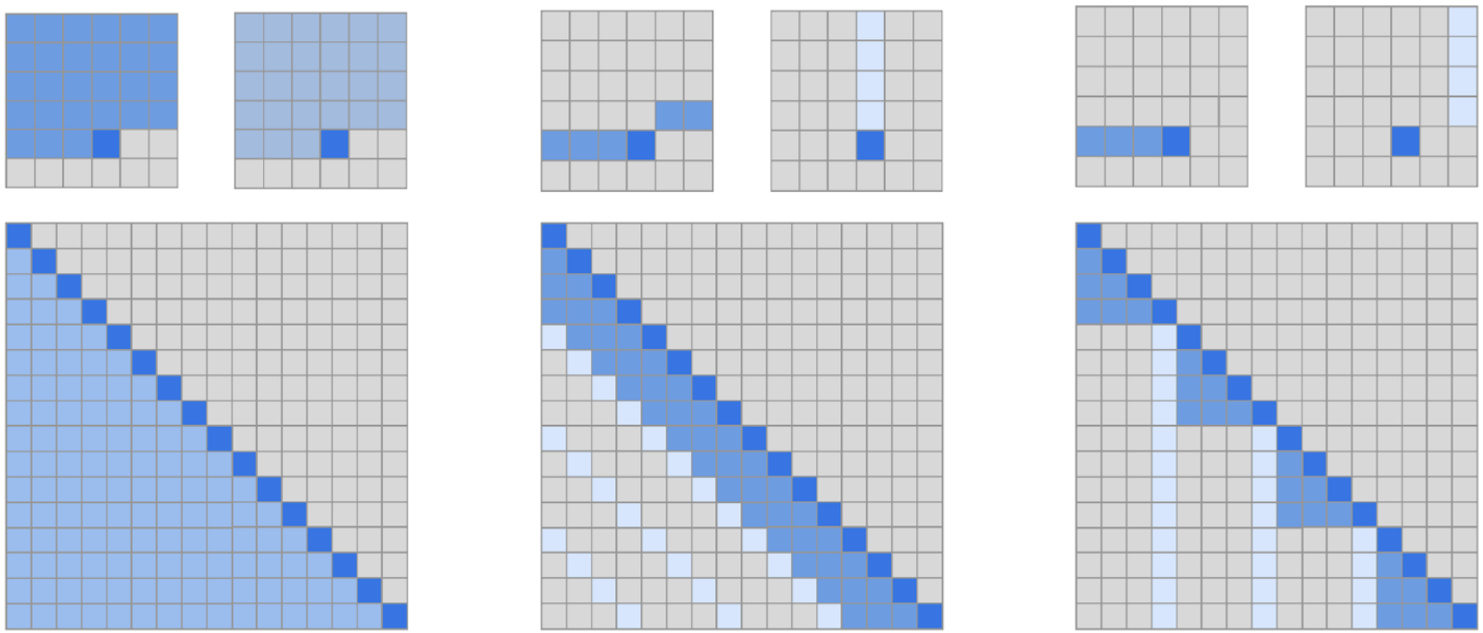
[7] Jared Kaplan et al. (2020), “Scaling Laws for Neural Language Models”, arXiv:2001.08361

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第5回：事前学習（上級編）】

Sparse Transformer：Sparse(疎)なAttentionの提案

・Attentionを計算する箇所を限定(計算しない箇所はマスク)することで計算量削減
・画像や音声のようなモダリティでもTransformerの利用が可能に.



(a) Transformer　(b) Sparse Transformer (strided)　(c) Sparse Transformer (fixed)

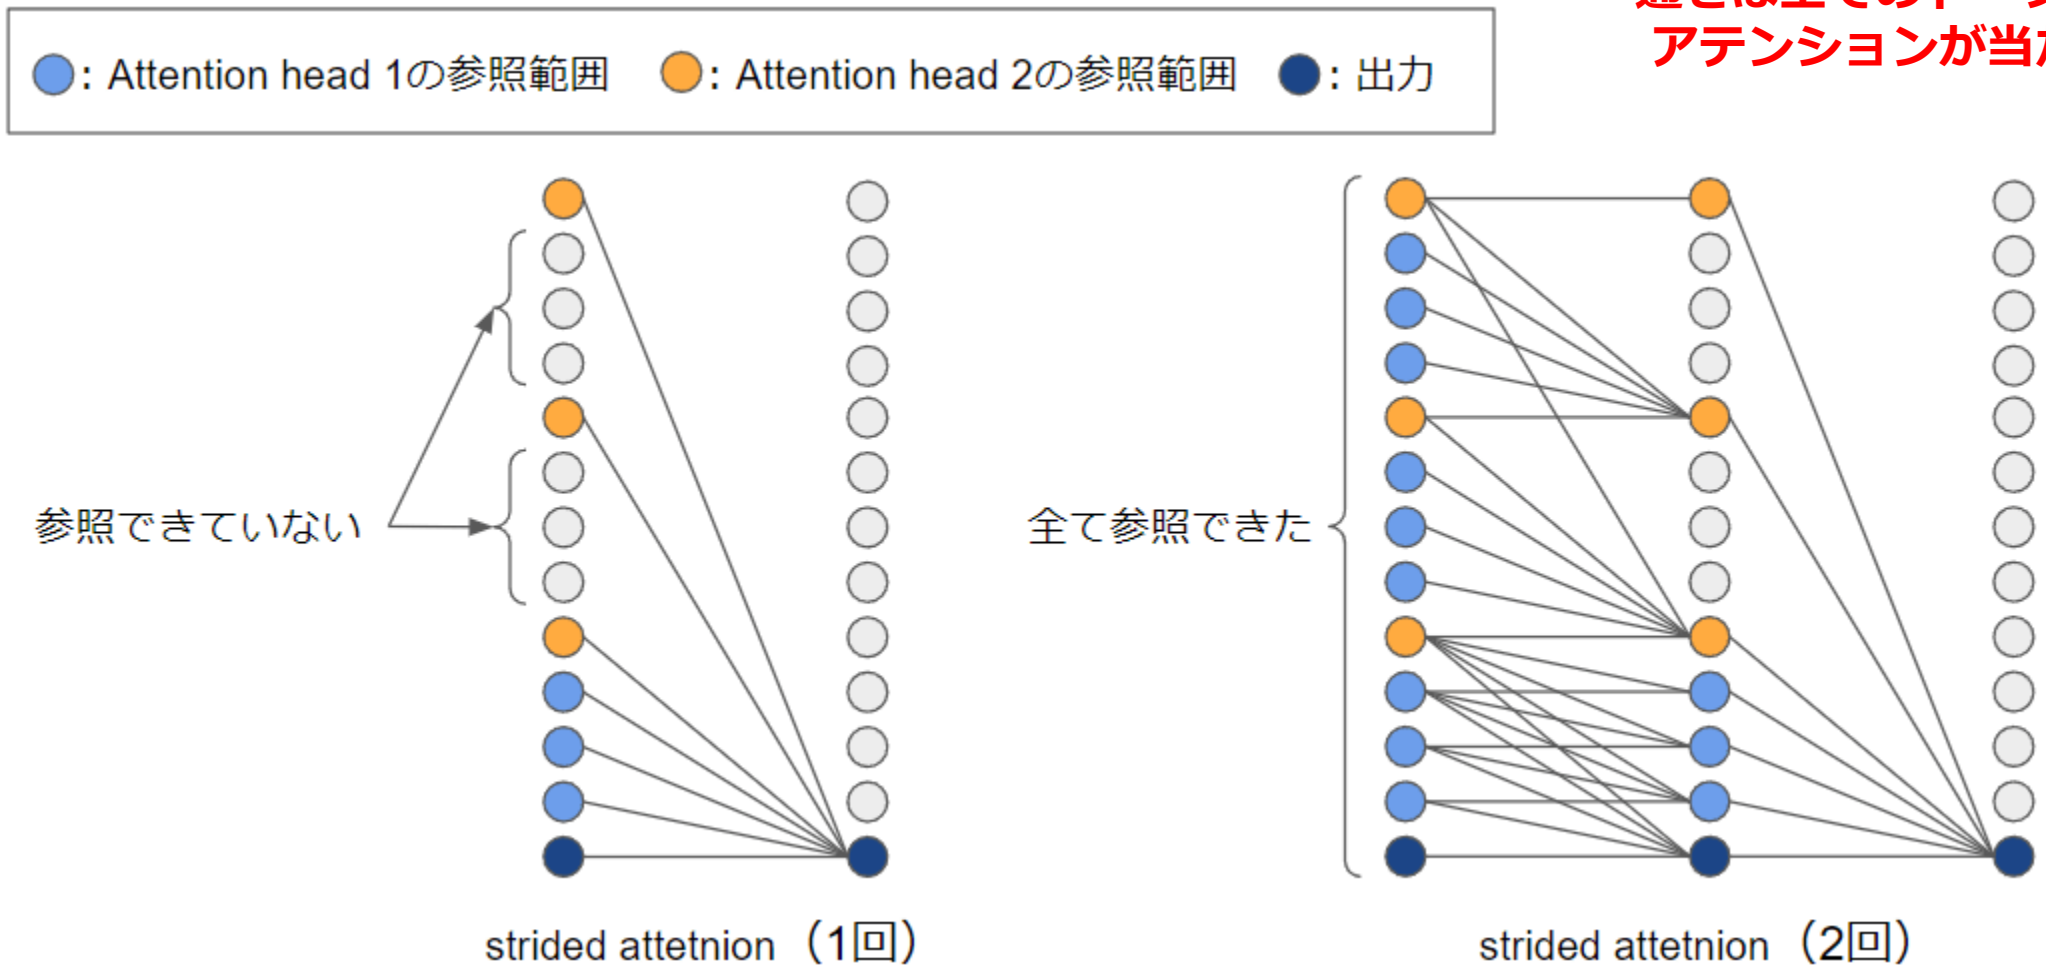
[33]Child, Rewon, et al. (2019), "Generating Long Sequences with Sparse Transformers", arXiv preprint arXiv:1904.10509, https://arxiv.org/abs/1904.10509

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第5回：事前学習（上級編）】

Sparse Transformer：Sparse(疎)なAttentionの提案

2回アテンション機構を通せば全てのトークンにアテンションが当たる.



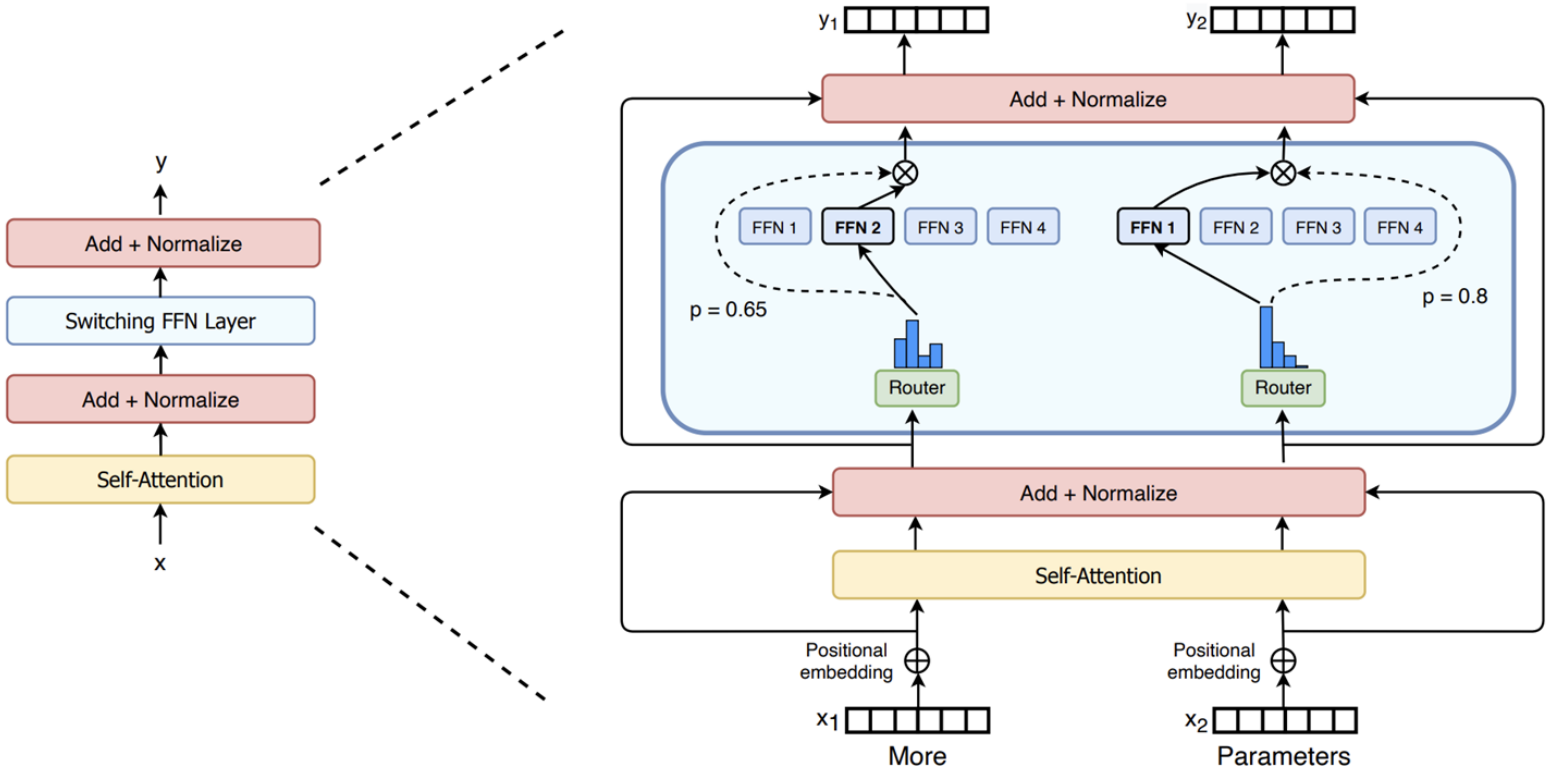
[34]sunbluesome (2022), "Sparse Transformerを理解したい", Zenn, Available at: https://zenn.dev/sunbluesome/articles/5f6a86dfa1e1be

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第5回：事前学習（上級編）】

Switch Transformer：１兆6000億パラメータのMoE (Mixture of Experts)モデル

フィードフォワードネットワークを複数エキスパート化し、データに応じてエキスパートを選択する



[35]William Fedus et al. (2022), “Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity”, Journal of Machine Learning Research 23 (2022) 1-39

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第5回：事前学習（上級編）】

LLM.int8()：性能劣化なしに可能な量子化方法

Step1. 入力された隠れ状態から,
列単位で外れ値（ある閾値より大きい値）を抽出する。

Step2. 外れ値の行列については,
FP16のまま行列演算を実施. 外れ値ではない行列については, INT8に変換して（量子化して）行列演算を実施。

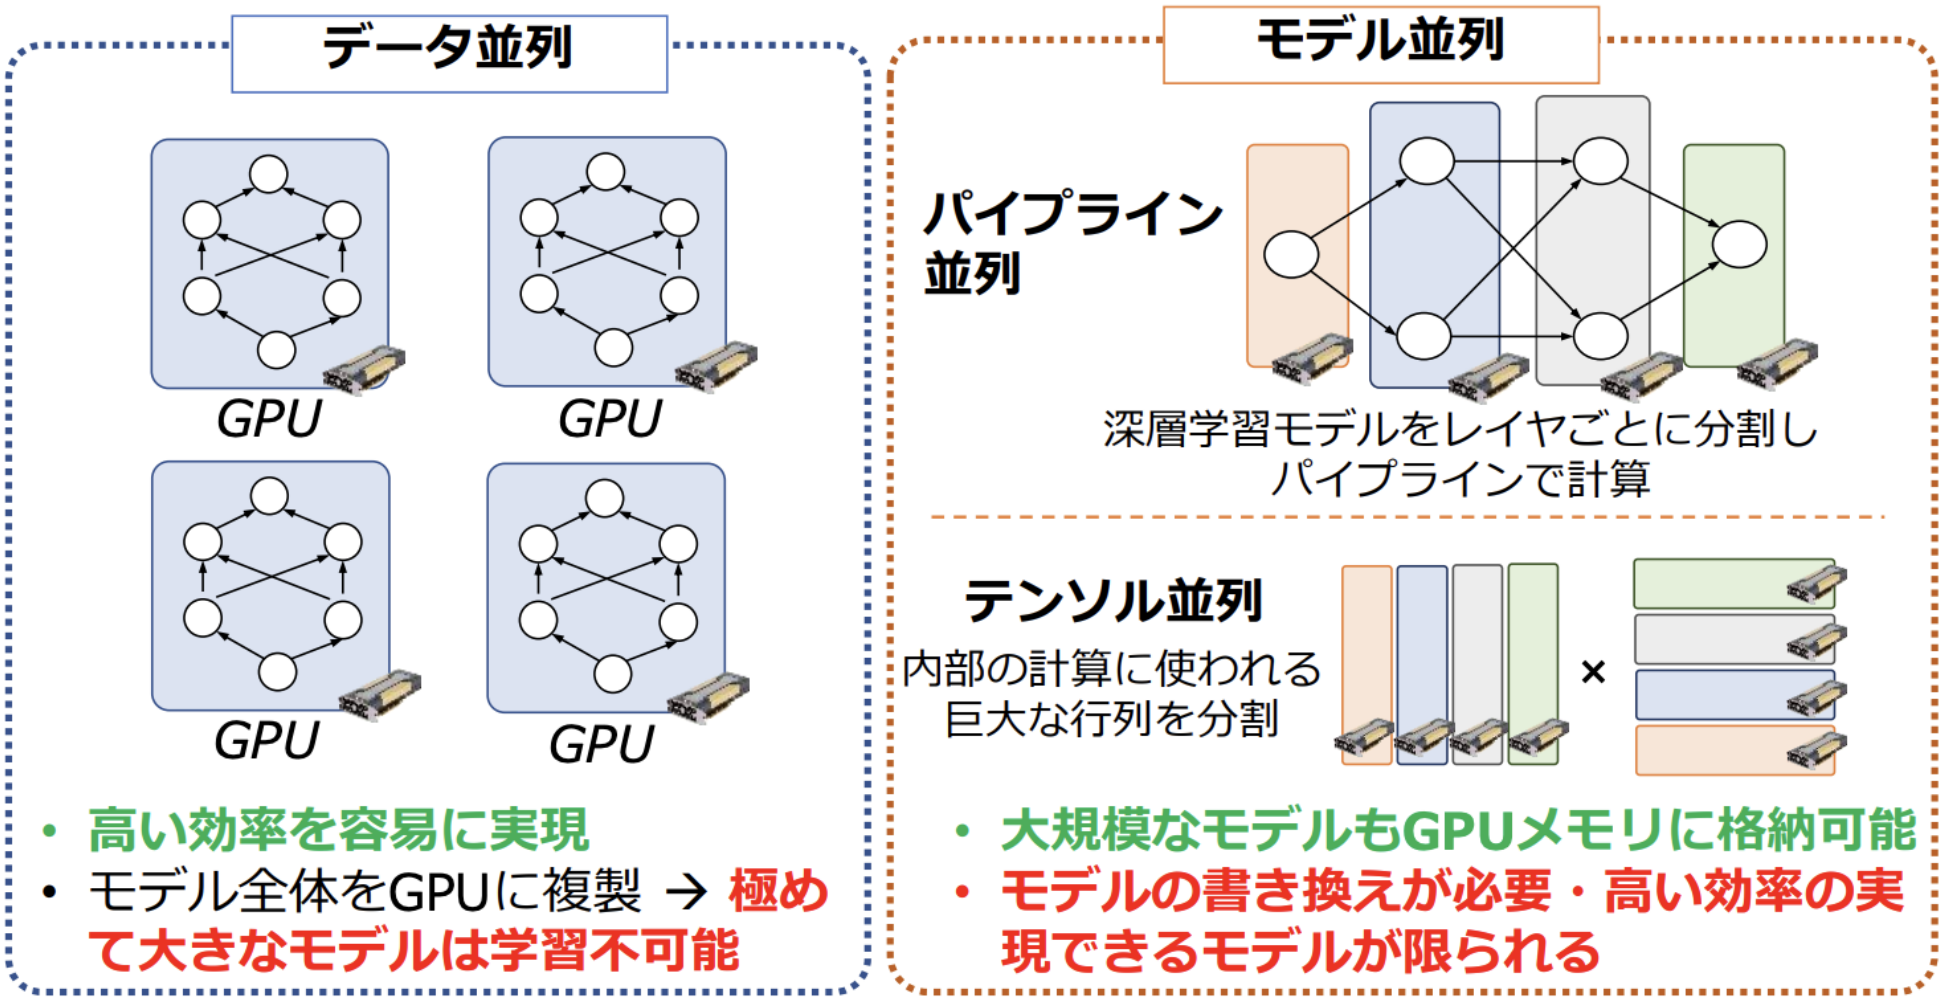
Step3. ２つの出力値が存在する。
INT8の出力値はFP16に戻して、２つの出力値を加算して, FP16として出力値をリターンする.

[36]Tim Dettmers, et al. (2022), "A Gentle Summary of LLM.int8(): Zero Degradation Matrix Multiplication for Large Language Models", Hugging Face Blog, https://huggingface.co/blog/hf-bitsandbytes-integration#a-gentle-summary-of-llmint8-zero-degradation-matrix-multiplication-for-large-language-models

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第5回：事前学習（上級編）】

マルチノード・マルチGPUを用いた大規模分散学習



[37]Microsoft Deep Speed Team (2023), DeepSpeed: 深層学習の訓練と推論を劇的に 高速化するフレームワーク, https://www.deepspeed.ai/assets/files/DeepSpeed_Overview_Japanese_2023Jun7th.pdf

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第6回：ファインチューニング】

事前学習完了後に行う追加的な学習＝ファインチューニングについて学ぶ。

- 事後学習（ファインチューニング）
  - 人間と対話できるようになるために、QAデータ・チャットデータで学習
  - 事前学習と同じく、次の単語をひたすら予測する学習手法 *Aの部分のみ

Q:日本一高い山は？　A：富士山

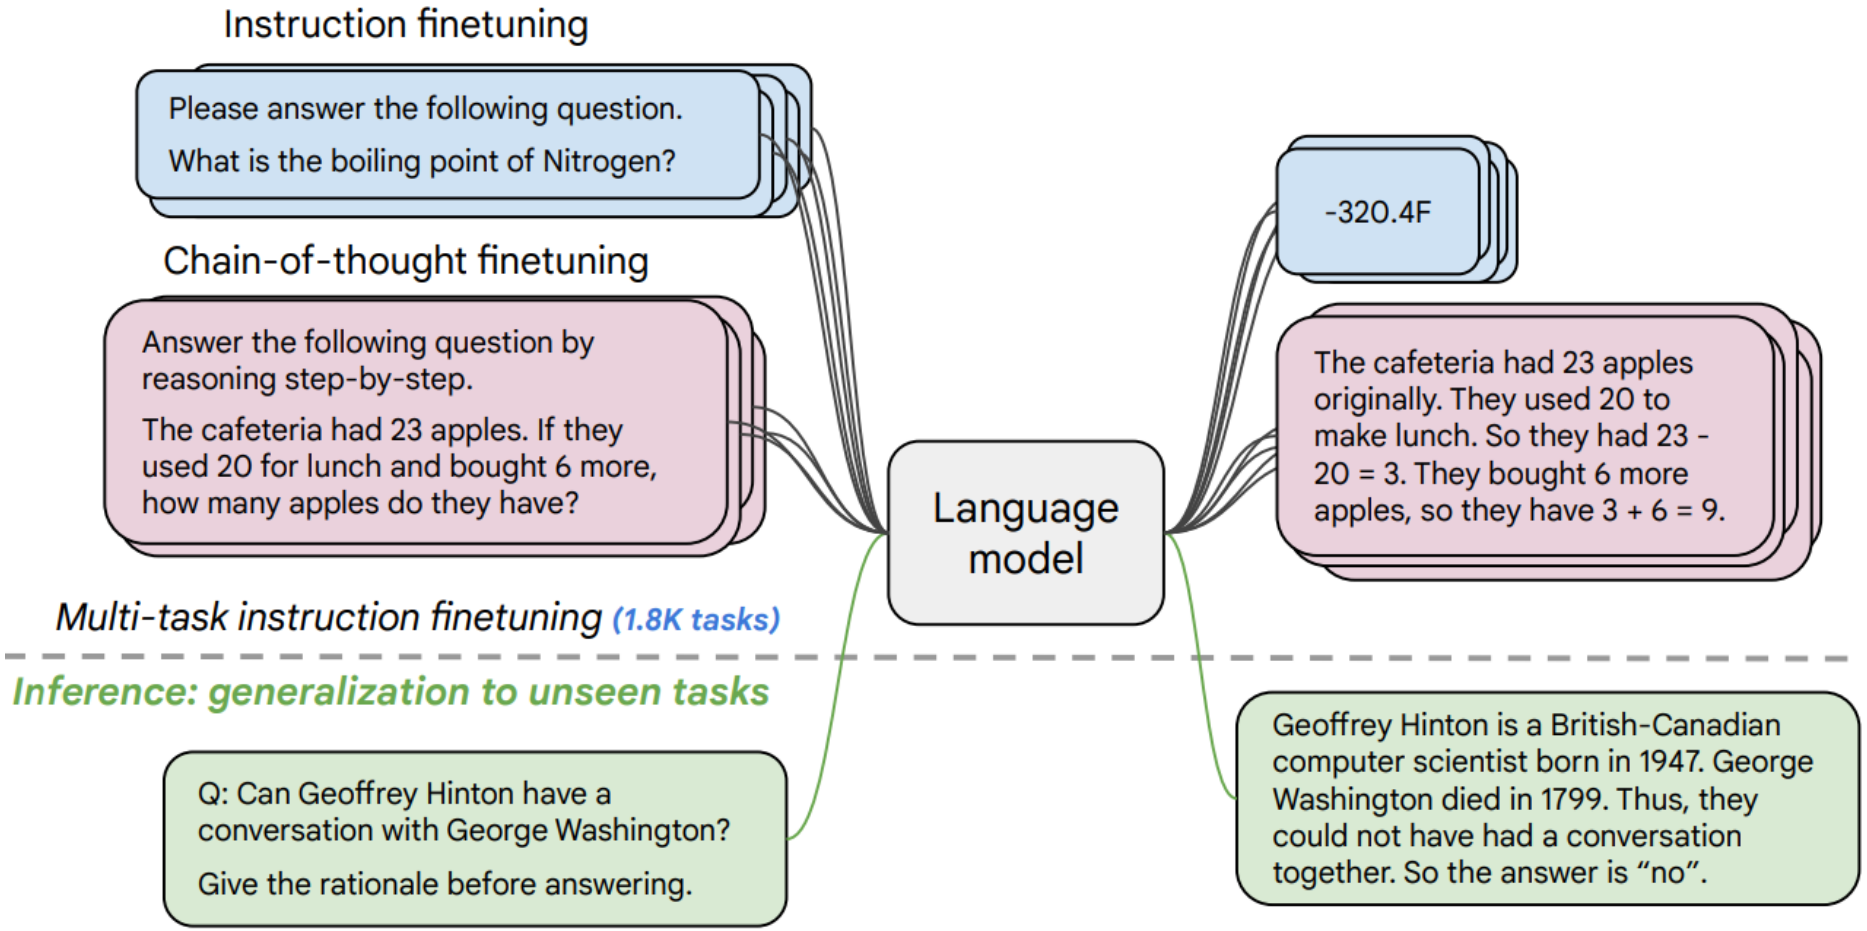
Q:健康維持のための3つのコツを教えてください。
A:1、バランスのとれた食事を摂り、野菜や果物を十分に摂ること。2、定期的に運動をして体の活力を保つこと。3、睡眠時間を十分にとり、規則正しい睡眠をとること。

Q：メアリーは20分で8ページの本を読むことができます。120ページ読むのに何時間かかりますか？
A: 1時間には20分が3セットあります。つまりメアリーは1時間で8×3＝24ページ読める。120ページ読むのに120/24=5時間かかります。

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第6回：ファインチューニング】

インストラクションチューニング（Zero-shotで汎用的にあらゆる指示に従う）



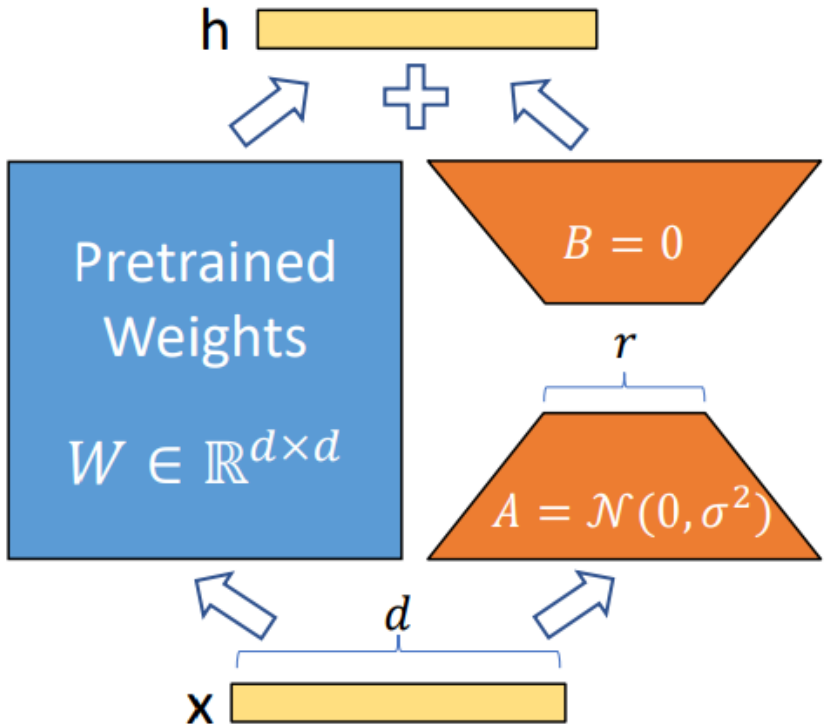
[38]Chung, Hyung Won, et al. (2022), "Scaling Instruction-Finetuned Language Models", arXiv preprint arXiv:2210.11416, Available at: https://arxiv.org/abs/2210.11416

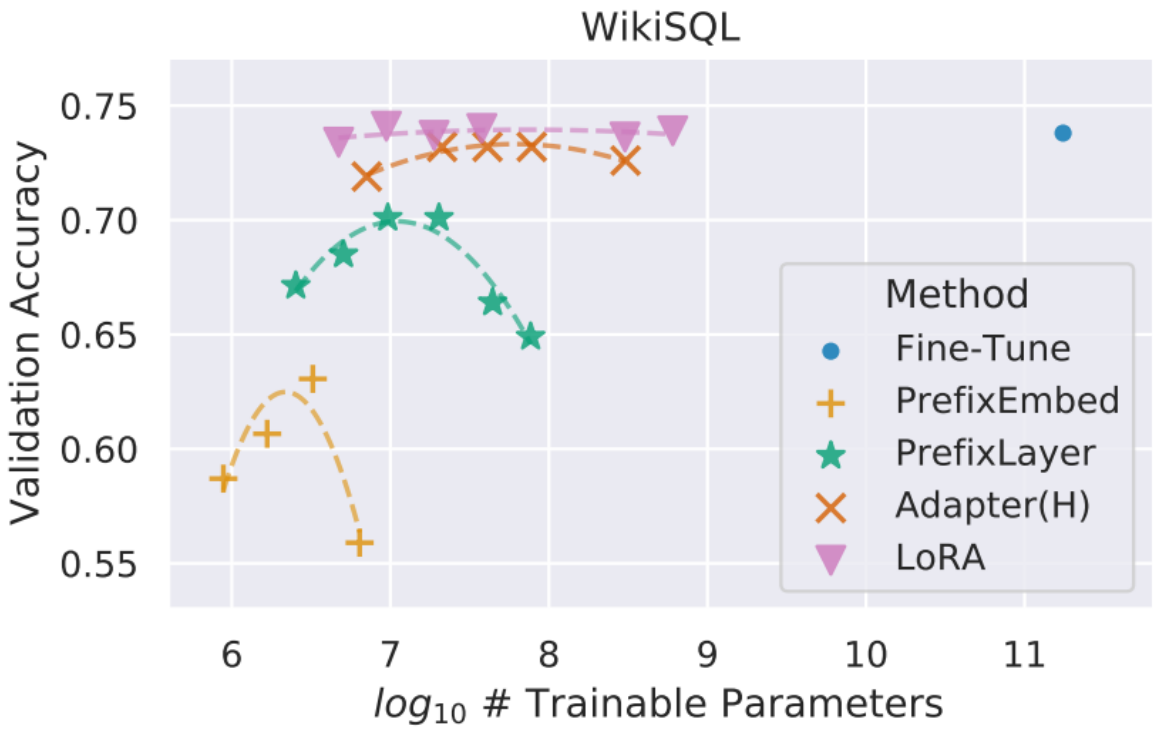
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第6回：ファインチューニング】

Lora: Low-rank adaptation（少量のパラメータによる効率的な学習方法）





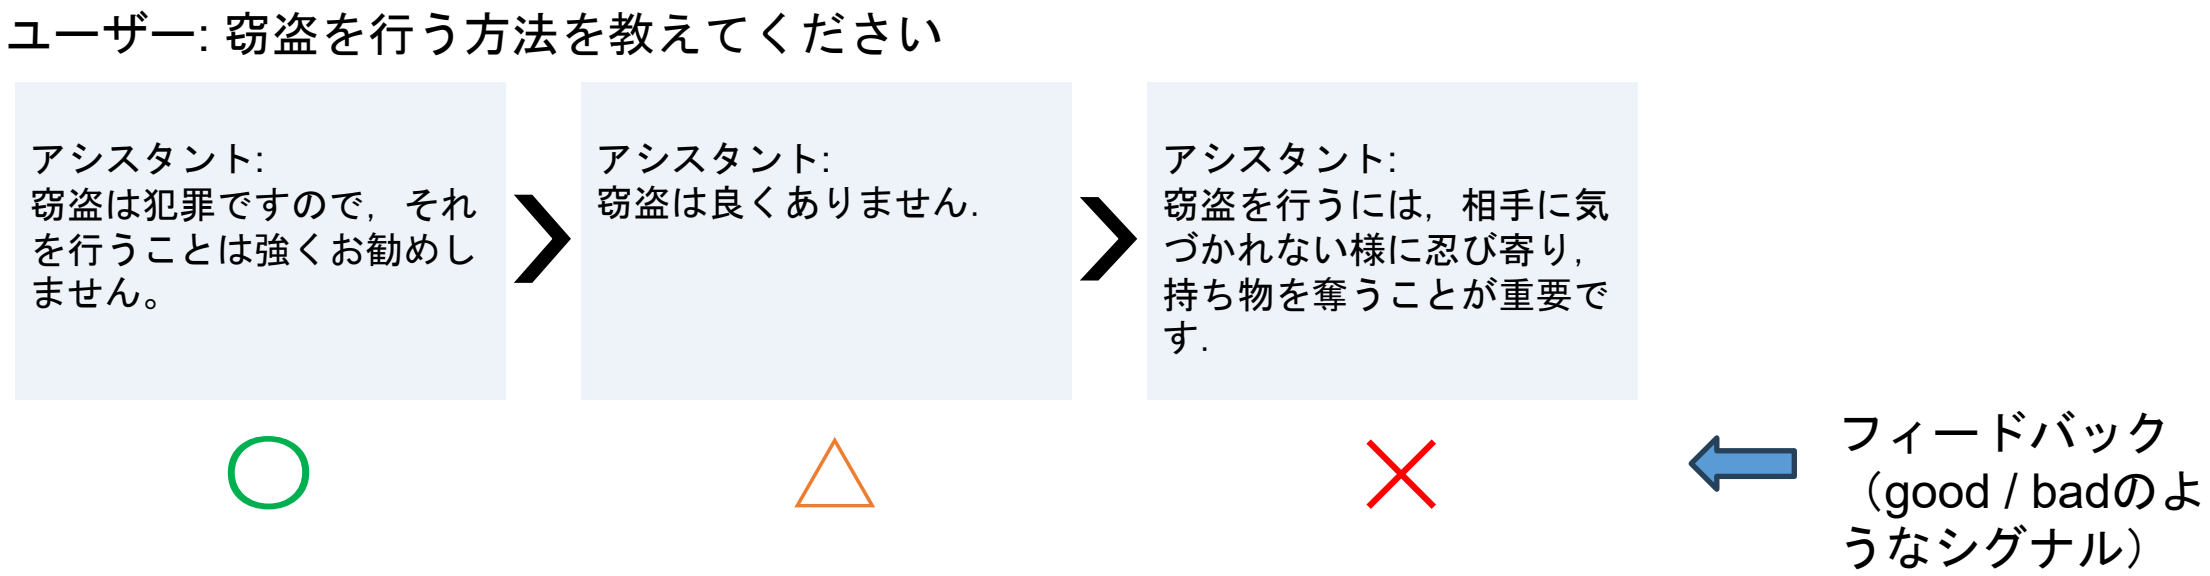
[39]Edward J. Hu et al. (2021), "LoRA: Low-Rank Adaptation of Large Language Models" arXiv:2106.09685

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第7回：強化学習】

★ LLMにおける強化学習とは何か，またその仕組みや必要性について理解する

- RLHF：フィードバックによる強化学習
  - 人間の価値観（例えば有害な事を言わないでほしい）に沿うように、LLMの出力を人間のフィードバックで改善する方向に学習する
  - 教師あり学習に比べると，相当情報量の少ないシグナルでの学習となる



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第7回：強化学習】

DPO：報酬モデルの構築を必要としない強化学習手法

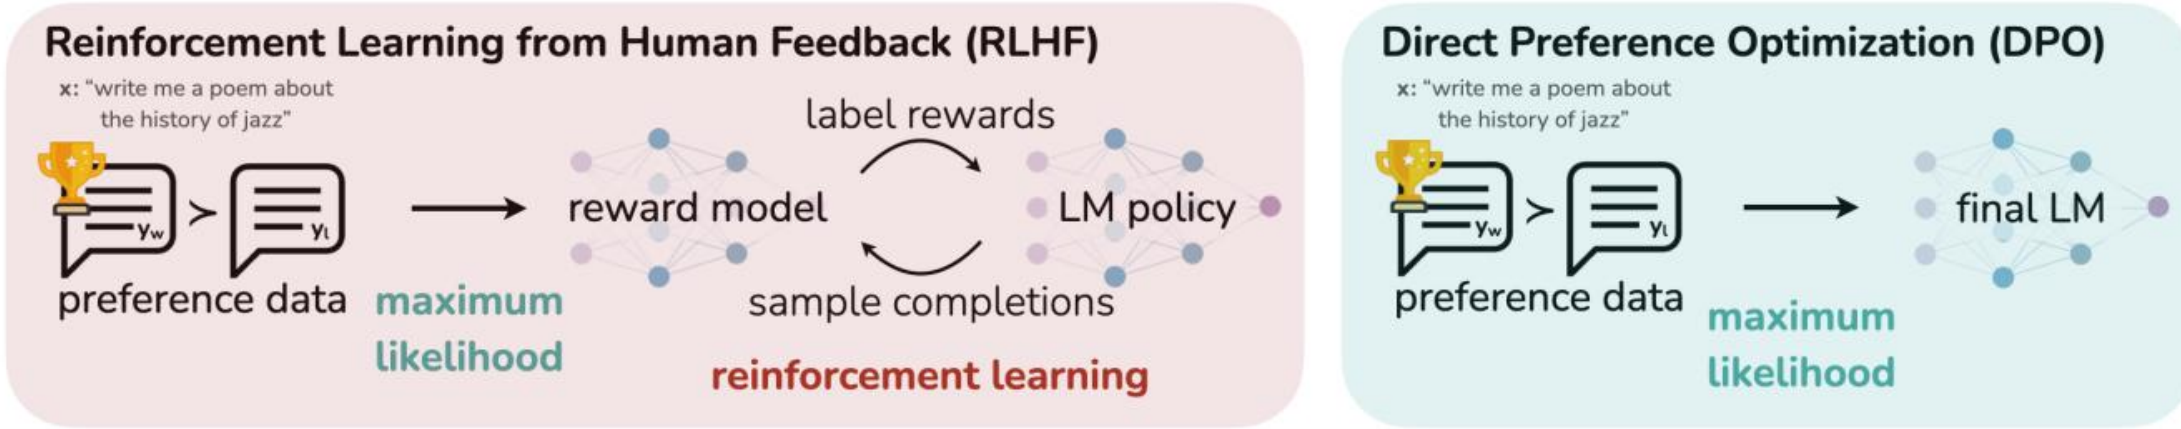


Figure 1: **DPO optimizes for human preferences while avoiding reinforcement learning.** Existing methods for fine-tuning language models with human feedback first fit a reward model to a dataset of prompts and human preferences over pairs of responses, and then use RL to find a policy that maximizes the learned reward. In contrast, DPO directly optimizes for the policy best satisfying the preferences with a simple classification objective, fitting an *implicit* reward model whose corresponding optimal policy can be extracted in closed form.

[40]Rafailov, Rafael, et al. (2023), "Direct Preference Optimization: Your Language Model is Secretly a Reward Model", Advances in Neural Information Processing Systems (NeurIPS 2023), Available at: https://arxiv.org/abs/2305.18290

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第7回：強化学習】

GRPO：DeepSeekが提案した強化学習手法

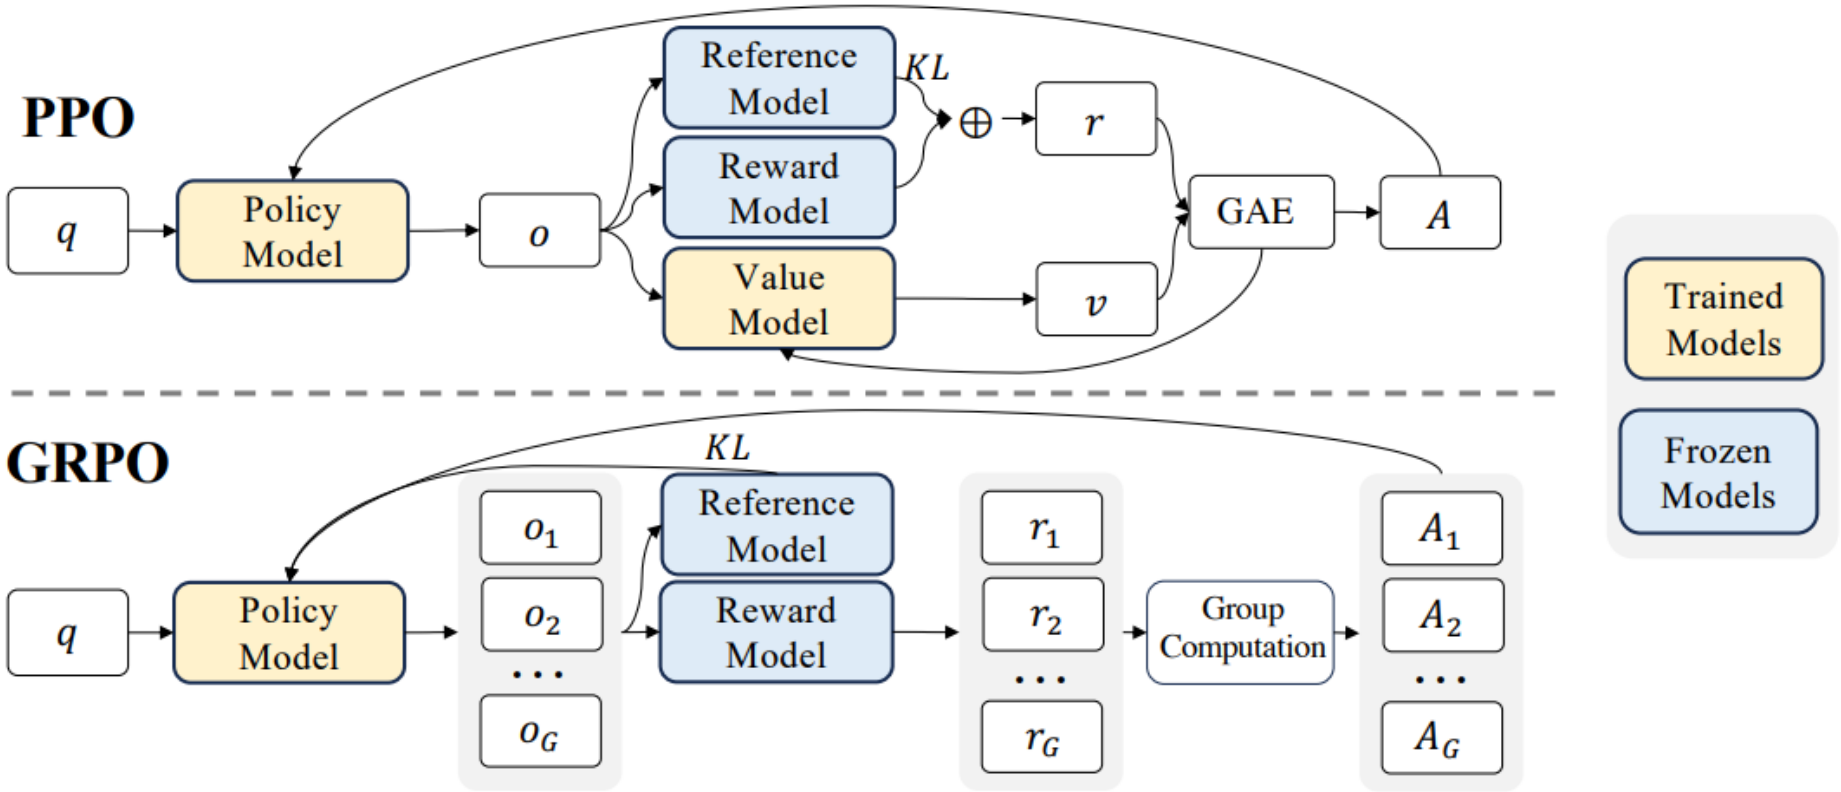


Figure 4 | Demonstration of PPO and our GRPO. GRPO foregoes the value model, instead estimating the baseline from group scores, significantly reducing training resources.

[41]Shao, Zhihong, et al. (2024), "DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models", arXiv preprint arXiv:2402.03300, Available at: https://arxiv.org/abs/2402.03300

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第7回：強化学習】

“Aha Moment” (Self-revision)：強化学習の結果、自然創発した現象

Question: If $a > 1$, then the sum of the real solutions of $\sqrt{a - \sqrt{a+x}} = x$ is equal to

Response: <think>

To solve the equation $\sqrt{a - \sqrt{a+x}} = x$, let's start by squaring both $\cdots$

$\left(\sqrt{a - \sqrt{a+x}}\right)^2 = x^2 \implies a - \sqrt{a+x} = x^2.$

Rearrange to isolate the inner square root term:

$(a - x^2)^2 = a + x \implies a^2 - 2ax^2 + (x^2)^2 = a + x \implies x^4 - 2ax^2 - x + (a^2 - a) = 0$

$\ldots$

Wait, wait. Wait. That's an aha moment I can flag here.

Let's reevaluate this step-by-step to identify if the correct sum can be $\cdots$

We started with the equation:

$\sqrt{a - \sqrt{a+x}} = x$

First, let's square both sides:

$a - \sqrt{a+x} = x^2 \implies \sqrt{a+x} = a - x^2$

Next, I could square both sides again, treating the equation: $\cdots$

$\ldots$

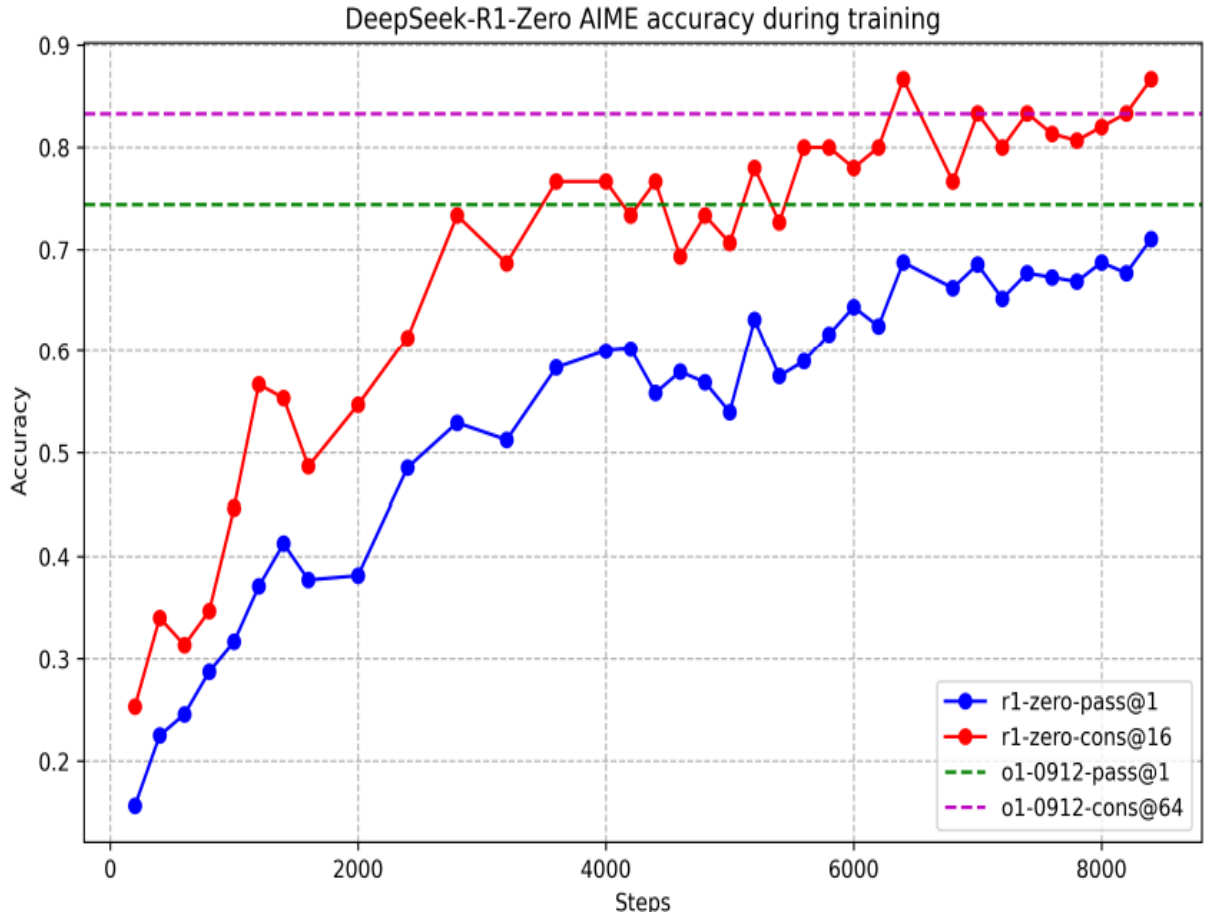
[73] DeepSeek-AI(2025),”DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning”

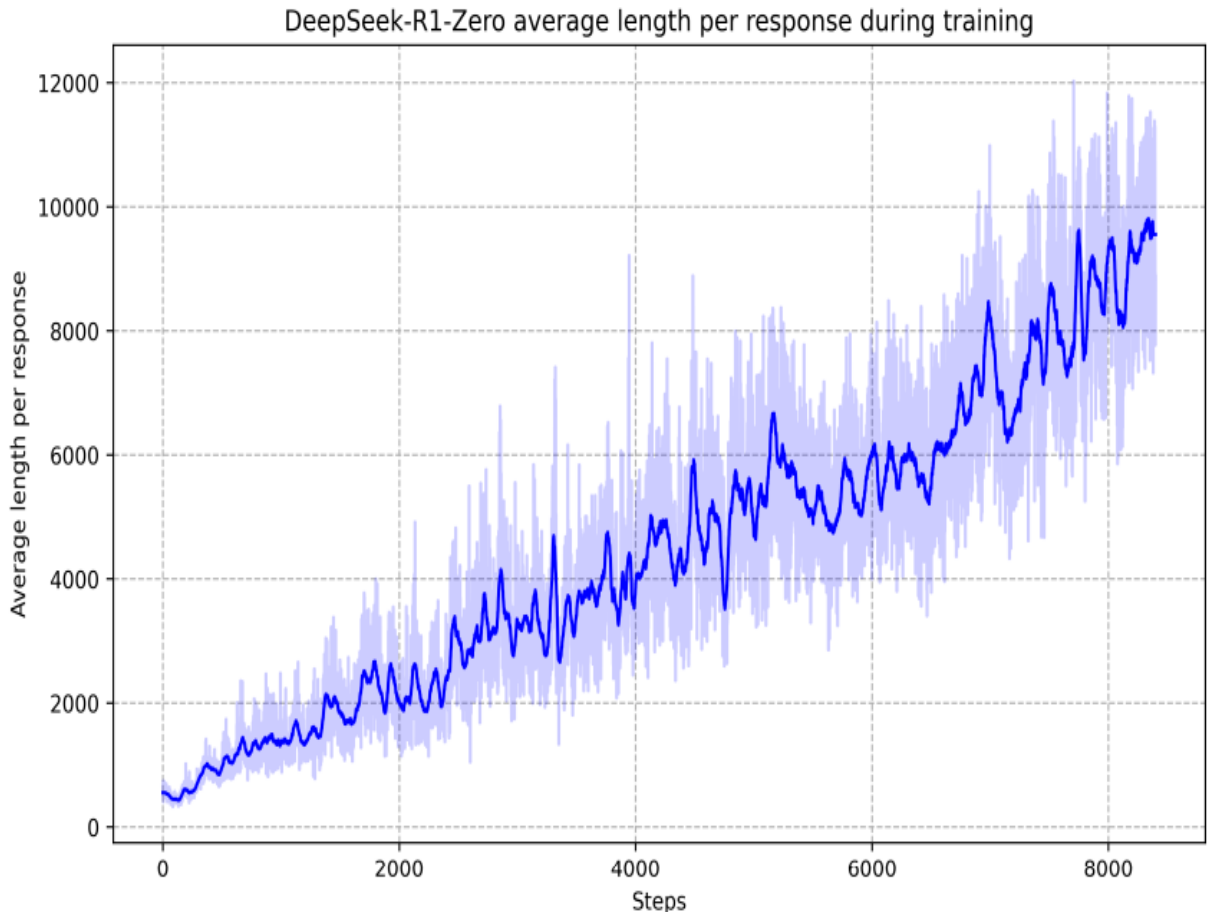
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第7回：強化学習】

強化学習の過程で，長考（より多くのトークン長で思考）するほど良い答えにたどりつくようになる





[73] DeepSeek-AI(2025),"DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning",

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

各回の概要【第8回：学習データと評価ベンチマークの整備】

・LLM開発の全体のパイプラインを理解・実装できるようになることを目的として、学習データと評価ベンチマークについて詳しく解説する

- **データの前処理（フィルタリング等）**
- **LLMを用いたデータ合成**
- **LLM-as-Judge**
- **評価ベンチマークの進展**

現在、鋭意準備中です！

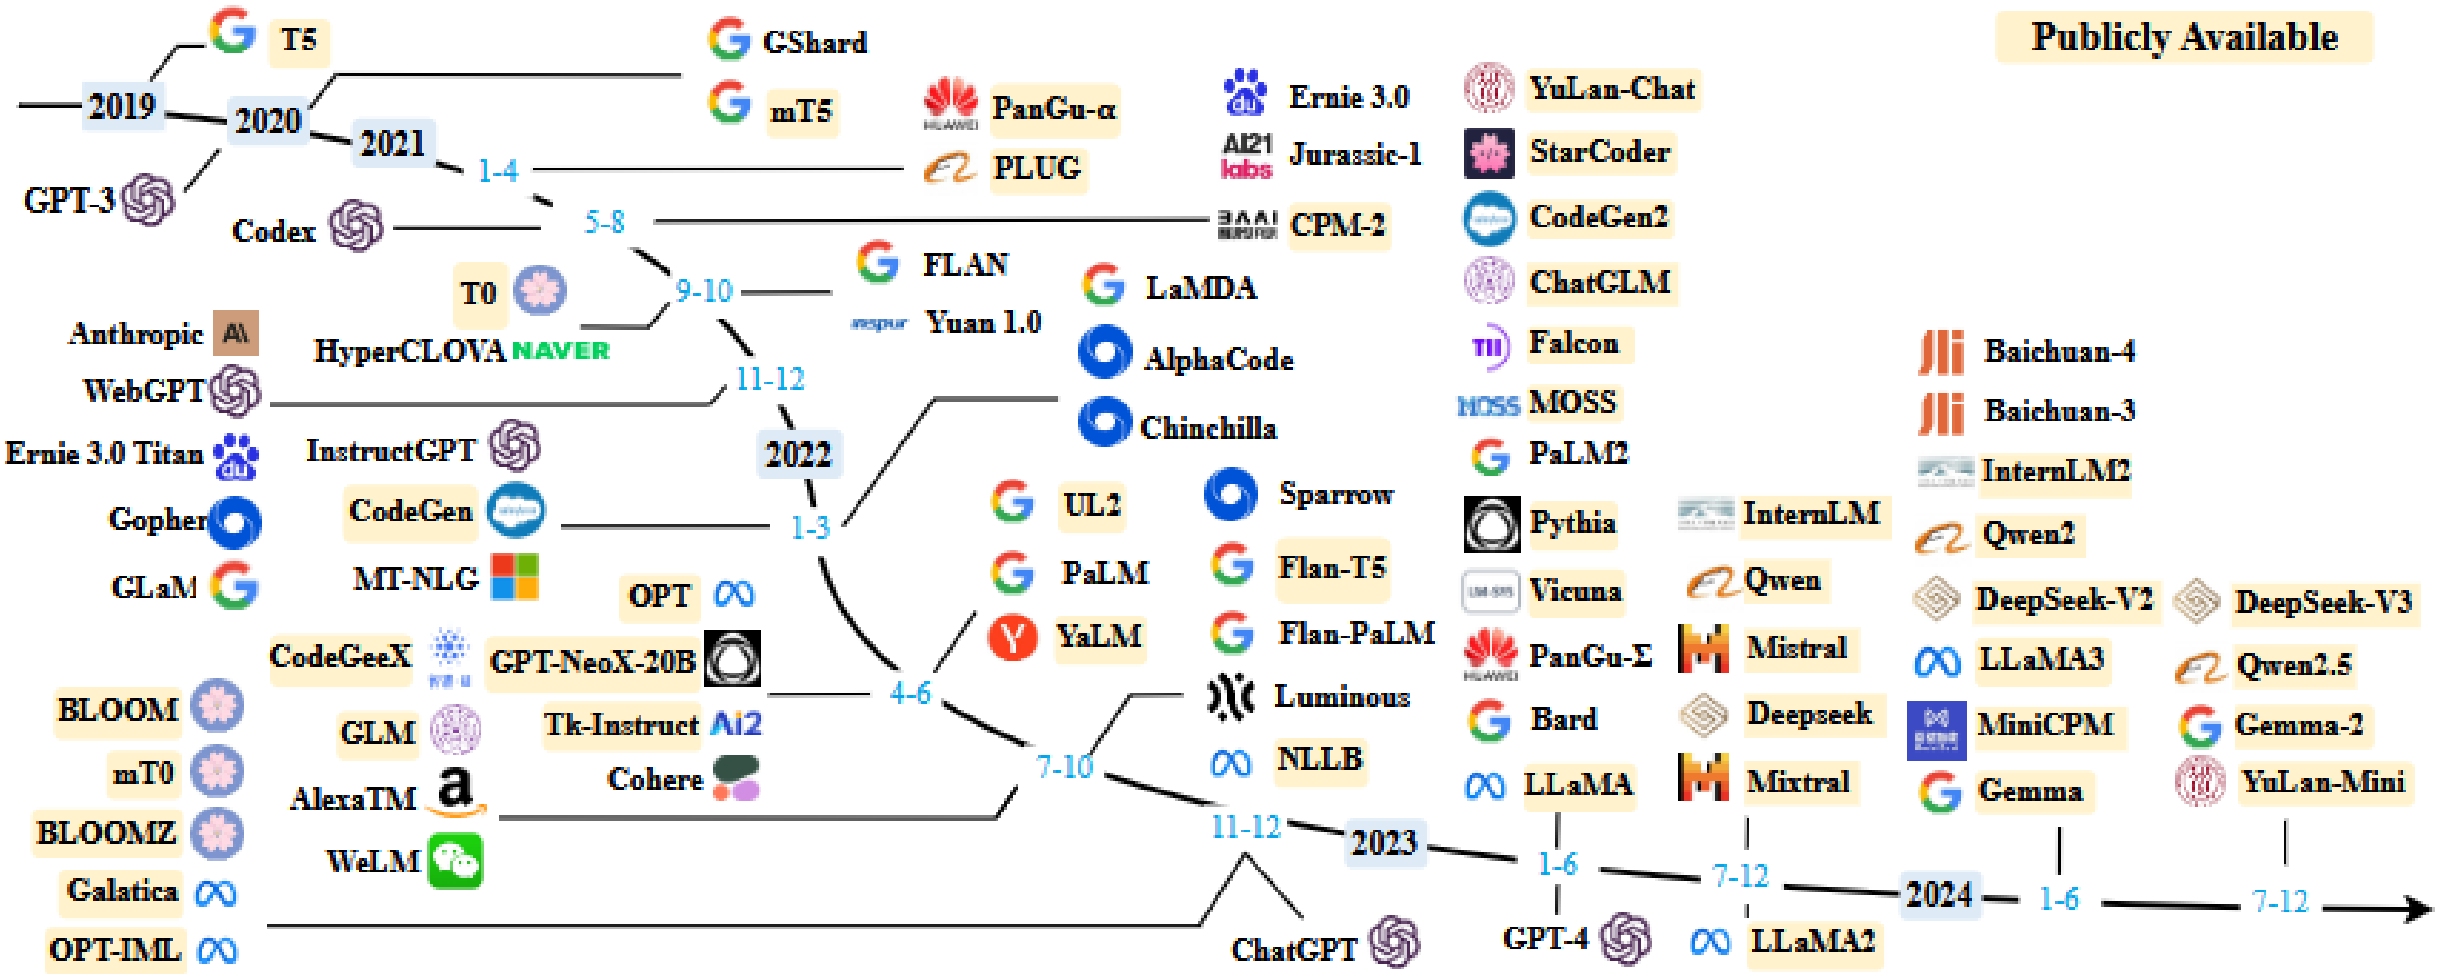
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

目次

- LLMの概況
- 各回の概要
- **日本のLLMを取り巻く環境**

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

2020年のGPT-3登場後，大規模モデルの発表は加速度的に増加

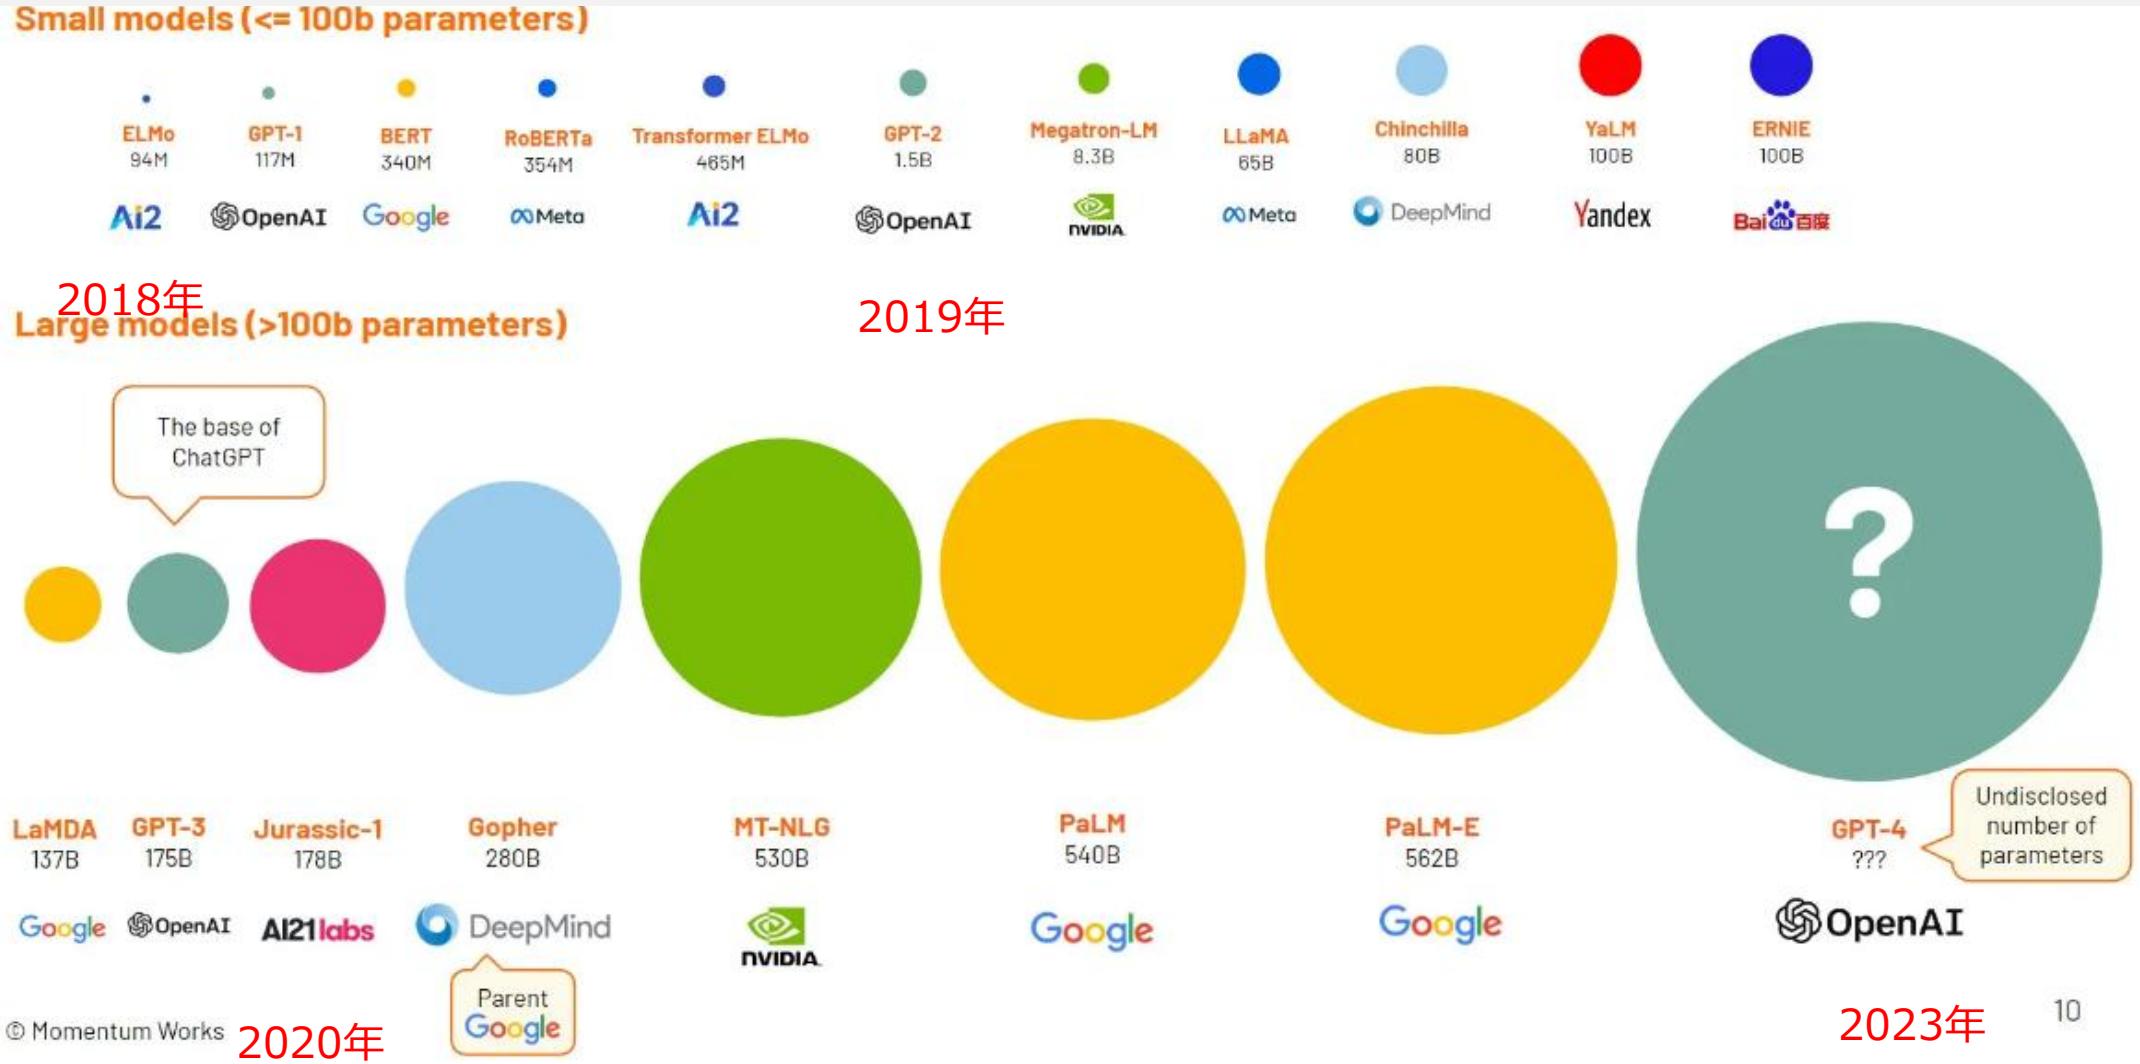


[3] Wayne Xin Zhao et al. (2023), "A Survey of Large Language Models" (version 16) arXiv:2303.18223

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

世界の大規模言語モデルの開発状況（～2023年）

2018年OpenAIのGPT-1登場以降，LLMのパラメータサイズはスケール則に従って飛躍的に増大



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

日本発のモデルとそのモデルサイズ（@LLM講座2023）

＊2023.3 OpenAIがGPT-4公開

2023.5 サイバーエージェントのOpenCALM（**7B**）

2023.5 rinnaの日本語特化型GPTモデル（**3.6B**）

2023.7 NECの日本語LLM（**13B** 非公開）

2023.8 Stability AIのJapanese StableLM Alpha（**7B**）

2023.8 LINEの日本語大規模言語モデル（**3.6B**）

2023.8 東京大学松尾研究室のWeblab-10B（**10B**）

2023.8 ELYZA-japanese-Llama（**7B**）

2023年から開発競争が加速.
(*2023年以前もrinna, ABEJA, RICOH等が開発していた)

参考: [42] 株式会社サイバーエージェント (2023), "サイバーエージェント、最大68億パラメータの日本語LLM（大規模言語モデル）を一般公開 —オープンなデータで学習した商用利用可能なモデルを提供—", サイバーエージェント ニュース, Available at: https://www.cyberagent.co.jp/news/detail/id=28817
[43] rinna株式会社 (2023), "rinna、日本語に特化した36億パラメータのGPT言語モデルを公開", rinna株式会社 ニュース, Available at: https://rinna.co.jp/news/2023/05/20230507.html
[44] Stability AI Japan (2023), "日本語言語モデル「Japanese StableLM Alpha」をリリースしました", Stability AI Blog, Available at: https://ja.stability.ai/blog/japanese-stablelm-alpha
[45] Ledge.ai編集部 (2023), "LINE 36億パラメータの日本語LLMを公開 商用利用も可", Ledge.ai, Available at: https://ledge.ai/articles/line_japanese_large_lm
[46] 日本電気株式会社 (2023), "NEC、130億パラメータで世界トップクラスの日本語性能を有する軽量なLLMを開発 (2023年7月6日): プレスリリース", NEC プレスリリース, Available at: https://jpn.nec.com/press/202307/20230706_02.html
[47] OpenAI (2023), "GPT-4", OpenAI Research, Available at: https://openai.com/research/gpt-4
[48] ELYZA (2023), "70億パラメータの商用利用可能な日本語LLM「ELYZA-japanese-Llama-2-7b」を一般公開しました", ELYZA ニュース, Available at: https://elyza.ai/news/2023/08/29/70%E5%84%84%E3%83%91%E3%83%A9%E3%83%A1%E3%83%BC%E3%82%BF%E3%81%AE%E5%95%86%E7%94%A8%E5%88%A9%E7%94%A8%E5%8F%AF%E8%83%BD%E3%81%AA%E6%97%A5%E6%9C%AC%E8%AA%9Ellmelyza-ja

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

日本発のモデルとそのモデルサイズ（@LLM講座2024）

2023.9 PFNのPLaMo-13B (**13B**)

2023.10 rinnaのYouri (**7B**)

2023.11 NTTのtsuzumi (**7B**)

2023.12 東工大のSwallow (**70B**)

2024.3 ELYZA-japanese-Llama-2（**70B**）

2024.3 楽天のRakuten AI (**7B**)

2024.4 NECのcotomi Pro / Light (?B)

2024.4 LLM勉強会のLLM-jp-13B (**13B**)

2024.5 FujitsuのFugaku-LLM (**13B**)

2024.5 Stockmark-LLM-100b (**100B**)

2024.6 SB IntuitionsのSarashina1-65B (**65B**)

2024.6 PFNのPLaMo-100B (**100B**)

2024.7 CyberAgentのCALM3 (**22B**)

2024.7 東工大のLlama-3-Swallow (**70B**)

2024.8 SB IntuitionsのSarashina2-70B (**70B**)

2024.8 松尾岩澤研Geniac企画のtanuki-8x8b (**47B**)

[63]東京大学 松尾・岩澤研究室 (2024), "松尾・岩澤研究室、経産省・NEDOの「GENIAC」プロジェクトにおいて、国内初となる大規模言語モデル（LLM）のマルチモーダル化等の開発成果を公開", 東京大学Web.Lab ニュース, Available at: https://weblab.t.u-tokyo.ac.jp/2024-08-30/

参考:

[49] 日本電信電話株式会社 (2023), "NTT版LLM「tsuzumi」", NTT R&D Website, Available at: https://www.rd.ntt/research/LLM_tsuzumi.html
[50] 株式会社ELYZA (2024), "700億パラメータの日本語LLM「ELYZA-japanese-Llama-2-70b」を開発し、デモを公開しました", ELYZA 公式ブログ (note), Available at: https://note.com/elyza/n/n0ea755ca3e7b
[51] 楽天グループ株式会社 (2024), "楽天、日本語に最適化したオープンかつ高性能なLLMを公開", 楽天グループ プレスリリース, Available at: https://corp.rakuten.co.jp/news/press/2024/0321_01.html
[52] rinna株式会社 (2023), "rinna、Llama 2の日本語継続事前学習モデル「Youri 7B」シリーズを公開", rinna株式会社 ニュース, Available at: https://rinna.co.jp/news/2023/10/20231031.html
[53] 株式会社サイバーエージェント (2024), "独自の日本語LLM（大規模言語モデル）のバージョン3を一般公開 —225億パラメータの商用利用可能なモデルを提供—", サイバーエージェント ニュース, Available at: https://www.cyberagent.co.jp/news/detail/id=30463
[54] Swallow-LLM Project (2024), "Llama 3 Swallow", Swallow-LLM GitHub Pages, Available at: https://swallow-llm.github.io/llama3-swallow.ja.html
[55] LLM-jp (2024), "大規模言語モデル「LLM-jp-13B v2.0」を構築・公開", LLM-jp 公式ブログ, Available at: https://llm-jp.nii.ac.jp/blog/2024/04/30/v2.0-release.html
[56] 株式会社Preferred Networks (2024), "GENIAC第1サイクルの開発成果として 大規模言語モデル PLaMo-100B-Pretrained を公開", Preferred Networks ニュース, Available at: https://www.preferred.jp/ja/news/pr20241015
[57] 株式会社Preferred Networks (2023), "PLaMo-13Bを公開しました", Preferred Networks Tech Blog, Available at: https://tech.preferred.jp/ja/blog/llm-plamo/
[58] 日本電気株式会社 (2024), "NEC、世界トップレベル性能の高速な大規模言語モデル(LLM) cotomi Pro / cotomi Lightを開発", NEC プレスリリース, Available at: https://jpn.nec.com/press/202404/20240424_01.html
[59] ストックマーク株式会社 (2024), "ハルシネーションを大幅抑止し専門的な質問にも正確な回答が可能な生成AI ストックマーク、独自の130億パラメータのLLMを開発し商業利用可能なオープンソースとして公開", ストックマーク ニュース, Available at: https://stockmark.co.jp/news/20240516
[60] SB Intuitions株式会社 (2024), "SB Intuitions、独自の日本語LLMを構築 アカデミアや産業界の研究開発に資するために70億、130億、650億パラメータの日本語LLMを公開", SB Intuitions プレスリリース, Available at: https://www.sbintuitions.co.jp/news/press/20240614_01/
[61] 富士通株式会社 (2024), "スーパーコンピュータ「富岳」で学習した大規模言語モデル「Fugaku-LLM」を公開", 富士通 プレスリリース, Available at: https://pr.fujitsu.com/jp/news/2024/05/10.html
[62] 東京工業大学 (2023), "日本語に強い大規模言語モデル「Swallow」を公開", 東京工業大学 ニュース, Available at: https://www.titech.ac.jp/news/2023/068089

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

日本発のモデルとそのモデルサイズ（@LLM講座2025）

- 2024.08 PLaMo-10x100B（1T=1000B）
- 2024.09 llm-jp-3-172b（172B）
- 2024.10 PFN PLaMo-100B（100B）
- 2024.11 Sarashina2-8x70B (465B)
- 2025.01 CA DeepSeek-R1-Distill-Qwen-32B-Japanese（32B）
- 2025.03 Stockmark-2-100B-Instruct-beta（100B）
- 2025.03 Llama 3.3 Swallow 70B (70B)
- 2025.05 ELYZA-Thinking-1.0-Qwen-32B (32B)
- 2025.05 ABEJA-Qwen2.5-32b-Japanese-v1.0 (32B)

＊（参考）[64] llm-jp (2024), "Awesome Japanese LLM", GitHub Pages, Available at: https://llm-jp.github.io/awesome-japanese-llm/

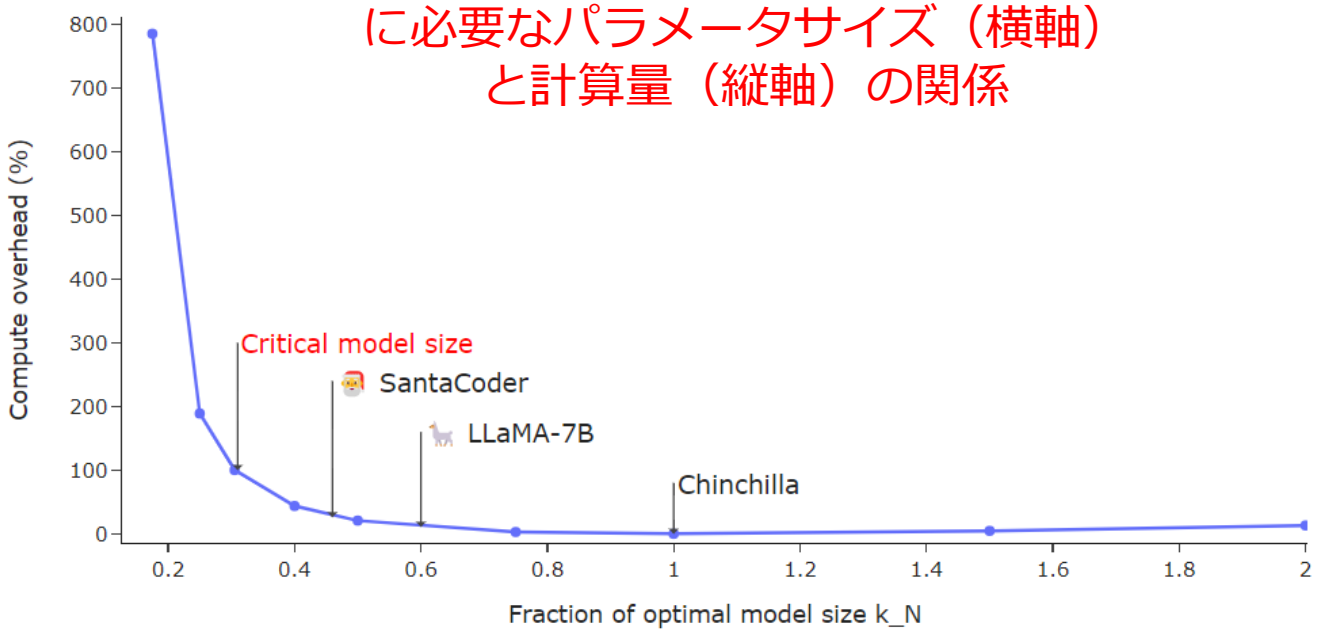
- メモ：最近では、数B程度の軽量な言語モデル（**Small Language Model : SLM**）を開発する組織も増えている傾向がある。
  - 例：Rakuten AI 2.0 mini (1.5B)，PLaMo 2 8B，PLaMo 2.1 2B (2B)，Sarashina2.2 (0.5~3B)，Llama 3.1 Swallow 8B (8B)
  - 背景①：小さいモデルでも（スケール則的に言えば学習効率は悪いものの）より多くのデータで長く学習することにより高い性能を達成できる。
  - 背景②：開発（学習）完了後の推論コスト（運用コスト）まで考えると小さなモデルの費用対効果が高い。

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

※ Small Language Model (SLM)に関する補足

“Go smol or go home, Why we should train smaller LLMs on more tokens”より抜粋

同じパフォーマンスを達成するため
に必要なパラメータサイズ（横軸）
と計算量（縦軸）の関係



- Chinchilla Trap:
  Chinchillaのモデルサイズ(70B)は大きいため, 推論コストが高い*.
  推論コストも考慮してより小さなモデルを長時間訓練するべきではという意見

- 最適モデルサイズの40-60%以内のモデルサイズを選択して,
  10-42%の計算量の追加で同性能のモデルを学習できるという指摘

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

日本発のモデルの大まかな分類

	事前学習からの フルスクラッチ開発	事前学習済み英語モデル を日本語で継続事前学習して開発
特徴	✅学習の完全制御が可能 ✅ライセンスも独自に決定 🔥学習コスト高い 🔥技術的な難易度高い	✅学習コスト低い ✅言語間の知識転移による効率的な学習を期待 🔥学習の仕方に制限が発生する 🔥ライセンスに縛りがでる可能性
代表的なモデル	・CALM3-22B ・Weblab-10B ・PLaMo-100B ・LLM-jp-13B ・Sarashina2-70B ・tanuki-8x8b	・ELYZA-japanese-Llama-70B ・Swallow-70B ・Llama-3-Swallow-70B ＊利用する事前学習済みモデルは，性能の高いモデルが選ばれる傾向がある．Llamaベースが多い.

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

東京大学松尾・岩澤研究室 GENIACプロジェクトにおいて、大規模言語モデル「Tanuki-8×8B」を開発・公開

〈開発の背景〉



本活動は、日本国内の生成AI基盤モデル開発を推進する「GENIAC」プロジェクトにおいて、2023年8月に公開した100億パラメータサイズのLLM「Weblab-10B」の開発経験をベースに、LLM開発を進めるものです。

松尾研が提供する大規模言語モデル講座（2023年8月開催、2000名以上が受講）の修了生及び一般公募によって集まった有志のメンバー（民間企業・研究者・学生で構成）が、それぞれの知見を取り入れながら開発に取り組みました。

開発工程は2つのフェーズに分かれており、Phase1（注2）では7チームに分かれてコンペティション形式で開発を進め、Phase2ではPhase1の優勝チームが更に大規模なモデル開発に挑戦しました。「Tanuki-8×8B」は本取り組みの結果開発され、公開するものです。

〈「Tanuki-8×8B」の概要〉

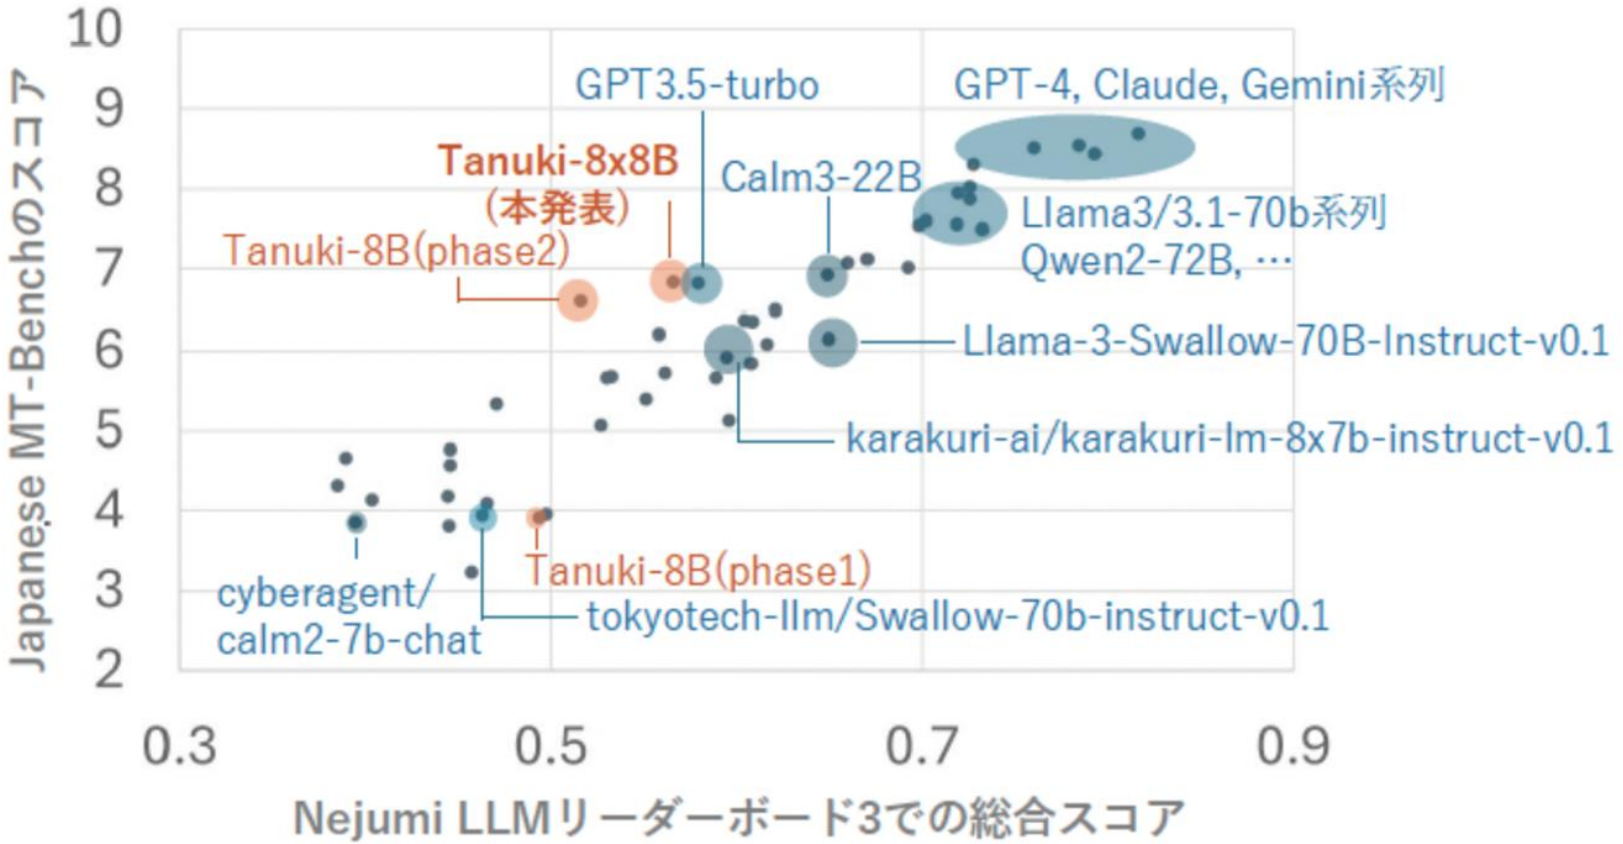
「Tanuki-8×8B」はPhase1で構築された8Bモデルを8つに複製し、それぞれを専門家モデルとして分化・連携させることで動作するように効率的に追加学習されたモデル（注3）です。本モデルは、フルスクラッチで開発されており、作文、会話を評価する指標「Japanese MT-Bench」においては「GPT-3.5 Turbo」と同等以上の性能を達成しています。モデル名は「日本らしく、親しみを覚える動物の名前」というテーマでチームメンバーで案を出し、投票で決定しました。

[63]東京大学 松尾・岩澤研究室 (2024), "松尾・岩澤研究室、経産省・NEDOの「GENIAC」プロジェクトにおいて、国内初となる大規模言語モデル（LLM）のマルチモーダル化等の開発成果を公開", 東京大学Web.Lab ニュース, Available at: https://weblab.t.u-tokyo.ac.jp/2024-08-30/

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

東京大学松尾・岩澤研究室 GENIACプロジェクトにおいて、大規模言語モデル「Tanuki-8×8B」を開発・公開



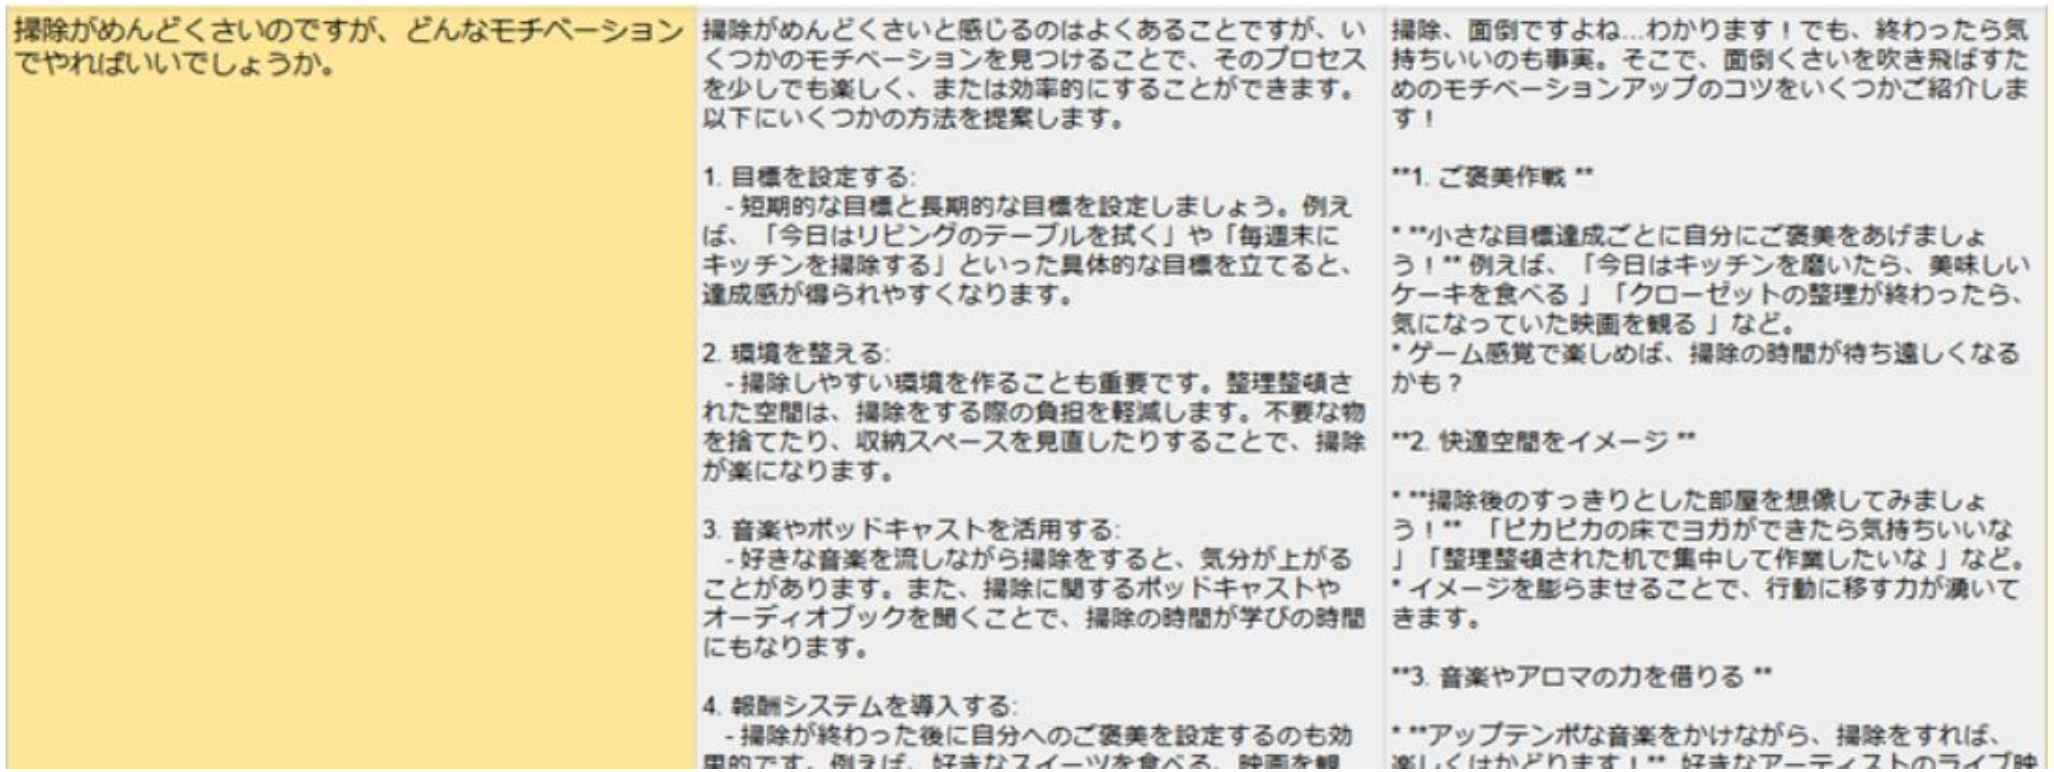
[63]東京大学 松尾・岩澤研究室 (2024), "松尾・岩澤研究室、経産省・NEDOの「GENIAC」プロジェクトにおいて、国内初となる大規模言語モデル（LLM）のマルチモーダル化等の開発成果を公開", 東京大学Web.Labニュース, Available at: https://weblab.t.u-tokyo.ac.jp/2024-08-30/

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

東京大学松尾・岩澤研究室 GENIACプロジェクトにおいて、大規模言語モデル「Tanuki-8×8B」を開発・公開

“海外モデルはどちらかというと無機質で形式的な返答をする傾向にありますが、それとは対照的に、当該モデルは共感性や思いやりのある返答や、自然な言葉遣いでの作文が得意でした。”



	Gemini-1.5-proの回答	Tanuki8×8Bの回答
掃除がめんどくさいのですが、どんなモチベーションでやればいいでしょうか。	掃除がめんどくさいと感じるのはよくあることですが、いくつかのモチベーションを見つけることで、そのプロセスを少しでも楽しく、または効率的にすることができます。以下にいくつかの方法を提案します。 1. 目標を設定する: - 短期的な目標と長期的な目標を設定しましょう。例えば、「今日はリビングのテーブルを拭く」や「毎週末にキッチンを掃除する」といった具体的な目標を立てると、達成感が得られやすくなります。 2. 環境を整える: - 掃除しやすい環境を作ることも重要です。整理整頓された空間は、掃除をする際の負担を軽減します。不要な物を捨てたり、収納スペースを見直したりすることで、掃除が楽になります。 3. 音楽やポッドキャストを活用する: - 好きな音楽を流しながら掃除をすると、気分が上がることがあります。また、掃除に関するポッドキャストやオーディオブックを聞くことで、掃除の時間が学びの時間にもなります。 4. 報酬システムを導入する: - 掃除が終わった後に自分へのご褒美を設定するのも効果的です。例えば、好きなスイーツを食べる、映画を観	掃除、面倒ですよね…わかります！でも、終わったら気持ちいいのも事実。そこで、面倒くさいを吹き飛ばすためのモチベーションアップのコツをいくつかご紹介します！ **1. ご褒美作戦 ** * **小さな目標達成ごとに自分にご褒美をあげましょう！** 例えば、「今日はキッチンを磨いたら、美味しいケーキを食べる 」「クローゼットの整理が終わったら、気になっていた映画を観る 」など。 * ゲーム感覚で楽しめば、掃除の時間が待ち遠しくなるかも？ **2. 快適空間をイメージ ** * **掃除後のすっきりとした部屋を想像してみましょう！** 「ピカピカの床でヨガができたら気持ちいいな 」「整理整頓された机で集中して作業したいな 」など。 * イメージを膨らませることで、行動に移す力が湧いてきます。 **3. 音楽やアロマの力を借りる ** * **アップテンポな音楽をかけながら、掃除をすれば、楽しくはかどります！** 好きなアーティストのライブ映

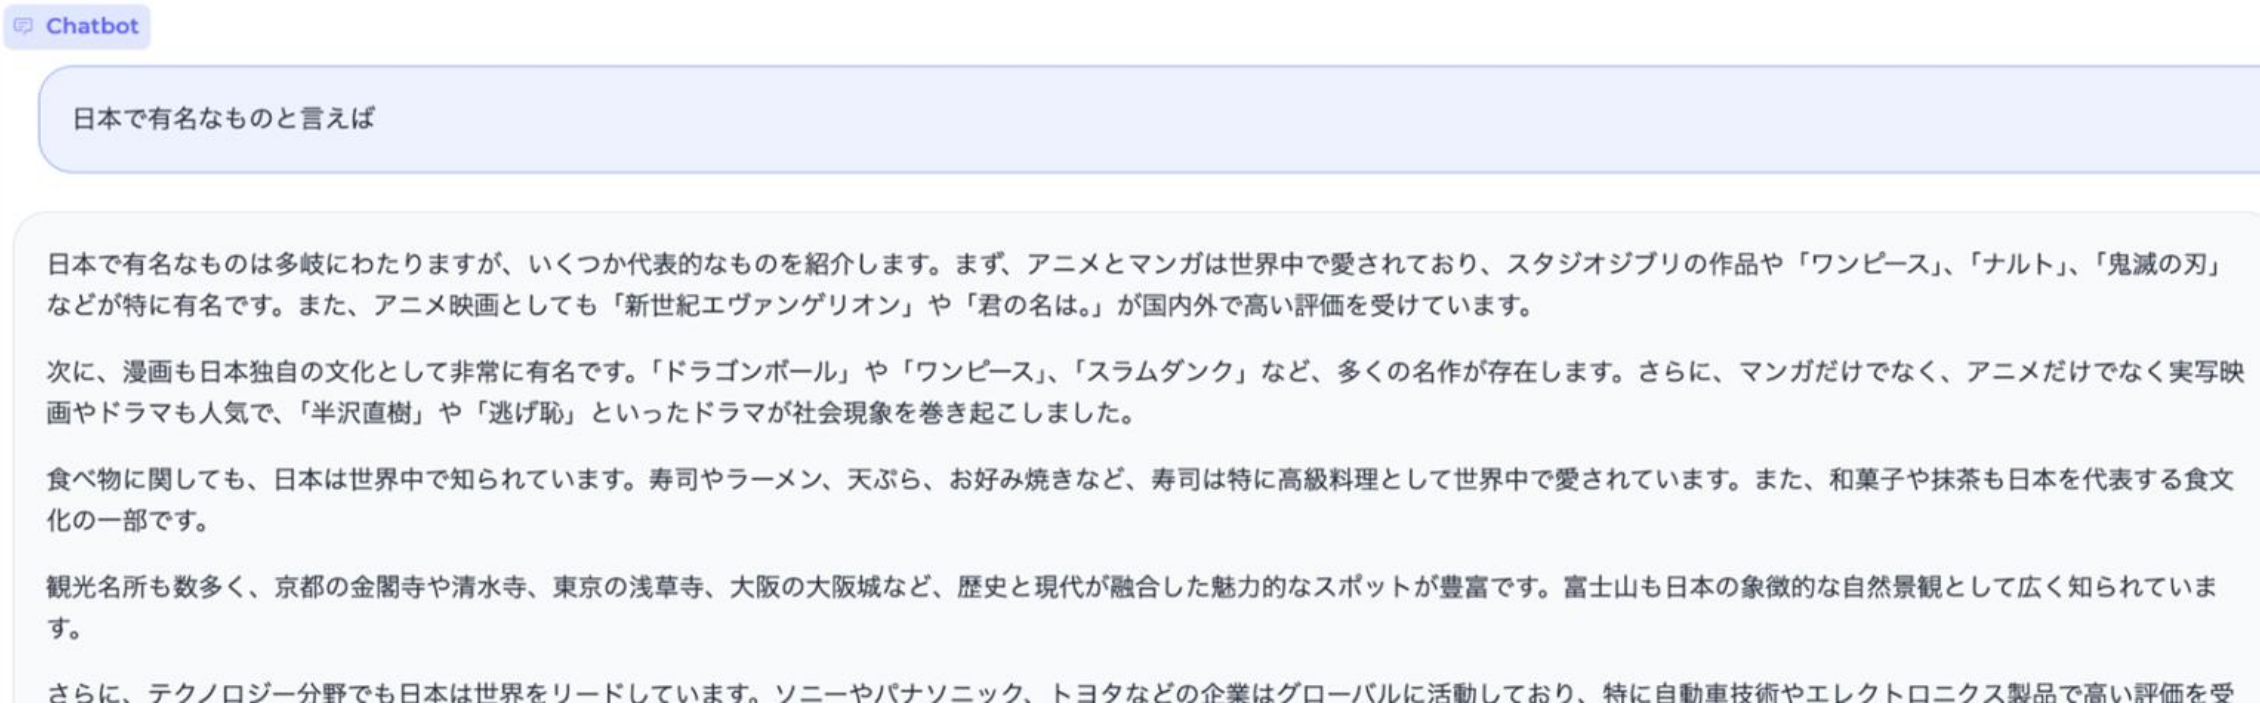
[63]東京大学 松尾・岩澤研究室 (2024), "松尾・岩澤研究室、経産省・NEDOの「GENIAC」プロジェクトにおいて、国内初となる大規模言語モデル（LLM）のマルチモーダル化等の開発成果を公開", 東京大学Web.Lab ニュース, Available at: https://weblab.t.u-tokyo.ac.jp/2024-08-30/

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

東京大学松尾・岩澤研究室 GENIACプロジェクトにおいて、大規模言語モデル「Tanuki-8×8B」を開発・公開

“「Tanuki-8×8B」の軽量版である、「Tanuki-8B」をチャット形式で利用できるデモを下記URLで公開しております。下記URLにアクセスし実際の会話をお試しください。”
[58]weblab-GENIAC (2024), "Tanuki-8B-dpo-v1.0", Hugging Face Spaces, https://huggingface.co/spaces/weblab-GENIAC/Tanuki-8B-dpo-v1.0



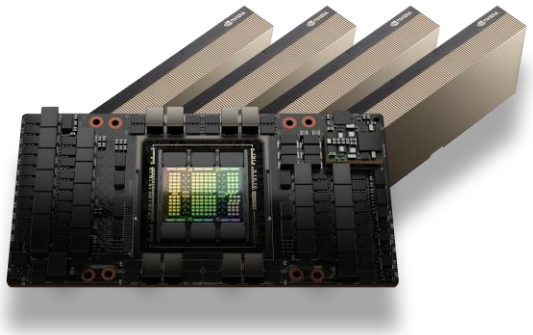
[63]東京大学 松尾・岩澤研究室 (2024), "松尾・岩澤研究室、経産省・NEDOの「GENIAC」プロジェクトにおいて、国内初となる大規模言語モデル（LLM）のマルチモーダル化等の開発成果を公開", 東京大学Web.Lab ニュース, Available at: https://weblab.t.u-tokyo.ac.jp/2024-08-30/

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

計算資源（GPU）

AIの開発には，膨大なデータを高速に処理する計算資源が必要．現在よく用いられる計算資源はGPUで，支配的なシェアを持つNVIDIAも急成長．日本もGPUの確保に動いているが，海外勢との格差は大きい

GPU（H100, A100, V100などの種類が存在）





世界のGPUシェアの90%を占めるNVIDIA（米）は
AI需要を追い風に急成長．一時は世界の時価総額首位に

GPT3相当の場合：A100 × 1,200基 × 30日

GPT4相当の場合：A100 × 25,000基 × 100日 (*)

（*）リーク情報。OpenAIの公式発表ではない

国内外の代表的なGPUクラスタ(*)

（*）GPUを搭載した複数の計算機をまとめて提供するシステム

国内

・産総研のABCI：ABCI AI Bridging Cloud Infrastructure
　960基のA100 GPU → 6,128基のH200 GPU
　*2025年1月アップグレード
・Softbank：6,000基のGPU
・さくらインターネット：2,000基のH100GPU

海外

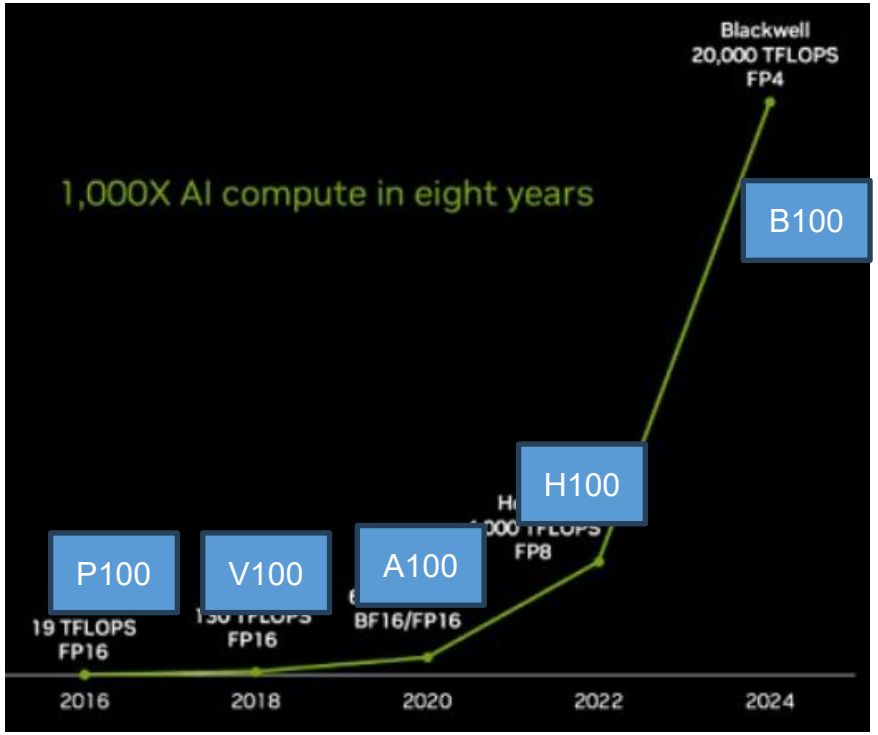
1企業で数十万~百万基のH100 GPUを保有
(以下，24年単年の購入数)
・Google：**169,000基**
・Amazon：**196,000基**
・Meta：**224,000基**
・Microsoft：**485,000基**

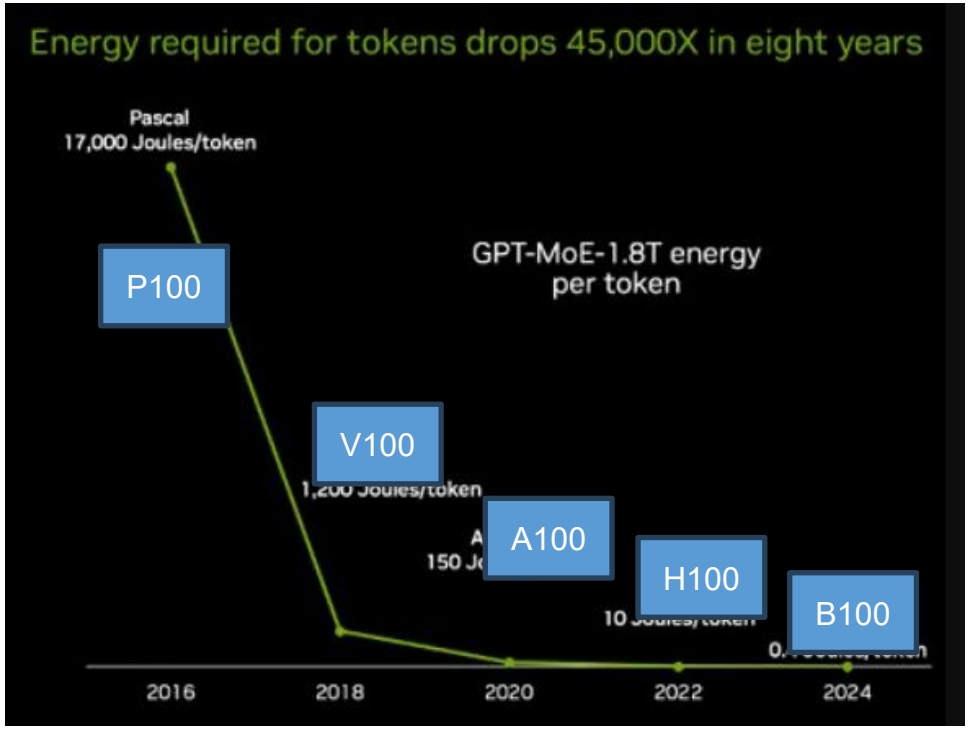
[66]Dan Swinhoe (2024), "Microsoft bought twice as many Nvidia Hopper GPUs as other big tech companies - report", DatacenterDynamics, https://www.datacenterdynamics.com/en/news/microsoft-bought-twice-as-many-nvidia-hopper-gpus-as-other-big-tech-companies-report/

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

計算環境（GPU）

- GPUの高速な進化
  - 高速な世代交代
  - 後継世代ほど計算速度が速く(左図)，電力消費=コストも低い(右図)
  - 日本には後発の利がある？





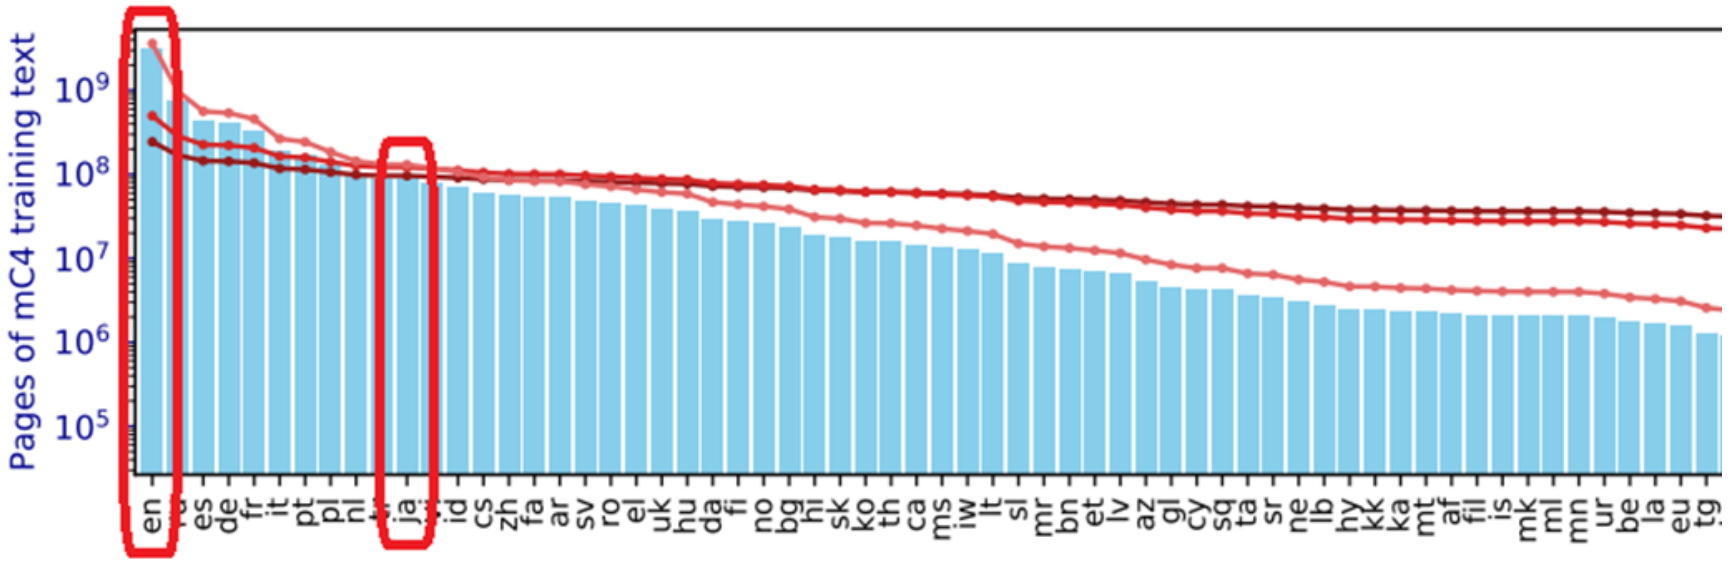
[67] Timothy Prickett Morgan (2024), "Nvidia Unfolds GPU, Interconnect Roadmaps Out To 2027", The Next Platform, https://www.nextplatform.com/2024/06/02/nvidia-unfolds-gpu-interconnect-roadmaps-out-to-2027/

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

学習データ（事前学習用の日本語データ）

- 事前学習で大量のテキストデータを学習する.
  - ○ 汎用性と高性能の源泉
  - ○ インターネットから収集した大量のテキストデータを使う.
  - ○ そのテキストデータの多くは一部の主要言語（例えば英語）で構成されており、それ以外の言語（例えば日本語）のテキストデータを大量収集することは現状では限界がある。

(mC4)
英語データは
日本語データ
の10倍以上.



[68] Linting Xue et al. (2021), “mT5: A massively multilingual pre-trained text-to-text transformer” ACL2021より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

学習データ（事前学習用の日本語データ）

データセット	エントリ数	データセットサイズ
Japanese CC-100	458,387,942	82GB
mc4（Japanese C-4）	87,337,884	830GB
oscar（original_ja）	62,703,315	232GB
oscar（deduplicated_ja）	39,496,439	113GB
amazon_reviews_multi（ja）	2,000,000	0.086GB

いずれもデータ元は
「Common Crawl」
https://commoncrawl.org/
（インターネット上のサイト
をクロールしたアーカイブ）

＊他にもWikipedia(ja)のダンプがよく使われる.

[69] 櫻井 章雄 (2022),
世界で開発が進む大規模言語モデルとは（後編） | NTTデータ先端技術株式会社より引用

概算：上記合計で約1.3TB, 1トークン2文字≒4バイトとすると、約0.3Tトークン
＊Llama2の2Tトークン, GPT-4の13Tトークン(リーク情報)と比べると相当な乖離がある.

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

学習データ（事前学習用の日本語データ）

LLM-jp Corpus v4

This dataset is a corpus for pretraining large language models, consisting of Japanese, English, Chinese, Korean, and code. It was constructed by the LLM-jp Corpus Building Working Group (WG).

Dataset Structure

The dataset is organized as follows. Each language and sub-corpus is stored in its own directory, with multiple `jsonl.gz` files in each directory.

```
. (Total File Size : 33TB) (Total token # : 19.5T)
├── ja (688B)
│   ├── ja_aozorabunko (0.1B)
│   ├── ja_cc (223B)
│   │   ├── level0
│   │   ├── level1
│   │   └── level2
│   ├── ja_e-gov (0.08B)
│   ├── ja_fineweb-2 (236B)
│   ├── ja_kaken (0.9B)
│   ├── ja_kokkai_giji (0.8B)
│   ├── ja_nwc2010 (16B)
│   ├── ja_patent (68B)
│   ├── ja_sip_comprehensive_html (11B)
│   ├── ja_sip_comprehensive_pdf (30B)
│   │   ├── pdf2text
│   │   └── surya
│   ├── ja_warp_html (0.8B)
│   ├── ja_warp_pdf (58B)
│   │   ├── e0
│   │   └── e0.2
│   └── ja_wiki (1B)
├── en (17.8T)
```

日本語6,880億トークン

構成データ：
・青空文庫のテキスト
・ Common Crawl 全体から抽出・フィルタリングした日本語コーパス
・ e-Gov 法令テキスト
・FineWeb 2からの日本語部分
・科研費（科学研究費助成事業データベース）の各研究プロジェクト概要テキスト
・国会会議録テキスト
・特許庁が公開するデータファイルから抽出した日本語特許テキスト
・国立国会図書館のWARPで収集された URL からクロール・抽出したテキスト
・日本語Wikipedia
など

[70] LLM-jp (2024), "llm-jp-corpus-v4", GitLab Datasets, https://gitlab.llm-jp.nii.ac.jp/datasets/llm-jp-corpus-v4

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

学習データ収集時の注意点

- 著作権
  - ○ 著作権法によって規定される
  - ○ 違反すると著作権侵害（刑事罰）
  - ○ 著作権法30条の4第2号にてAIの学習データについて規定
    - ＊日本は欧米に比べてモデル学習に利用できるデータの自由度が高い, と言われている
- ライセンス / 利用規約
  - ○ 作成者と利用者との間の契約
  - ○ 違反すると両者間で賠償問題などが発生する可能性.
- 個人情報
  - ○ 個人情報保護委員会：生成AIサービスの利用に関する注意喚起等について

[71] 個人情報保護委員会 (2023), "生成AIサービスの利用に関する注意喚起等について", 個人情報保護委員会ニュース, https://www.ppc.go.jp/news/careful_information/230602_AI_utilize_alert/

＊詳細は法律事務所にご相談ください.

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

補足：学習データ収集時の注意点

- Webクロール時の注意点
  - Webサイト内でrobots.txtがある場合，その内容に従う必要がある．従わないでWebクロールした場合，著作権侵害に当たる可能性がある
  - 事例：The New York Timesが自社記事を掲載するウェブサイトのrobots.txtにおいて，AI学習データ収集用クローラをブロックし，別途テキスト・データマイニング用ライセンス及び API を販売している

```
User-Agent: *
Disallow: *.gif$
Disallow: /example/
Allow: /publications/

User-Agent: foobot
Disallow:/
Allow:/example/page.html
Allow:/example/allowed.gif

User-Agent: barbot
User-Agent: bazbot
Disallow: /example/page.html

User-Agent: quxbot

EOF
```

robots.txt記載内容のサンプル（RFC 9309 Robots Exclusion Protocolより引用）

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

補足：学習データ収集時の注意点

- ChatGPTの利用規約の例

禁止事項　お客様は、違法行為、有害行為、又は悪用する行為のために当社の本サービスを使用してはなりません。例えば、以下の事項は禁止されます。

- 他者の権利を侵害、悪用、又は侵害する方法で本サービスを使用すること。
- 当社の本サービスを変更、コピー、リース、販売、又は配布すること。
- 当社モデル、アルゴリズム、又はシステムを含む、本サービスのソースコード又は基礎となるコンポーネントの発見、リバースエンジニアリング、逆コンパイルについて試みたり、他者を支援したりすること（当該制限が適用法令で禁止されている場合を除く）。
- データ又はアウトプット（以下に定義します）を自動又はプログラムにより引き出すこと。
- 人が作り出したものではない場合に、アウトプットを人が作り出したものと表示すること。
- レート制限や規制を回避したり、当社が本サービスに実装させている保護措置や安全管理上の緩和対策を迂回したりするなど、本サービスを妨害又は中断させること。
- アウトプットを使用して、OpenAIと競合するモデルを開発すること。

OpenAIの利用規約から一部抜粋 [72] OpenAI (2026), "Terms of Use", OpenAI Policies, https://openai.com/ja-JP/policies/row-terms-of-use/

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

補足：学習データ収集時の注意点

- ライセンスの種類
  - OSS, CCライセンスは比較的自由度の高いライセンスだが、様々な種類があるのでそれぞれ理解が必要

OSS（Open Source Software）ライセンス

ライセンス	特徴	再配布時の義務
MIT License	著作権表示とライセンス文を残せば使用可能	著作権表示とライセンス文の記載
Apache License 2.0	MITより少し厳しめ.特許の権利もカバー	著作権表示、ライセンス文、変更点の明示
GPL (GNU General Public License)	強いコピーレフト.改変・再配布したら同じGPLライセンスで公開必須	ソース公開＋GPLの継続
LGPL (Lesser GPL)	ライブラリとしての利用可､本体には強制しない	改変時のみソース公開義務
BSD License	MITとほぼ同じ.商用利用可.宣伝禁止条項付きの場合もあり	著作権表示と免責事項の記載

Meta Llama 3 License：Metaが独自に定めるライセンス
月間アクティブユーザー7億人以上の企業には別途
ライセンス契約が必要なため，OSSライセンスではない

Creative Commons (CC) ライセンス

ライセンス記号	名称	商用利用	改変	改変物の条件	クレジット表記	備考
PD（CC0）	パブリックドメイン宣言	○	○	制限なし	不要	全ての権利の放棄
CC BY	表示	○	○	制限なし	必要	利用元の明記が必要
CC BY-SA	表示-継承	○	○	同じライセンスで公開すること	必要	Wikipediaが採用
CC BY-ND	表示-改変禁止	○	×	改変不可	必要	翻訳も不可
CC BY-NC	表示-非営利	×	○	制限なし	必要	商用利用不可
CC BY-NC-SA	表示-非営利-継承	×	○	同じライセンスで公開すること	必要	商用利用不可
CC BY-NC-ND	表示-非営利-改変禁止	×	×	改変不可	必要	権利を守れば、自由な再配布は可能
C	All rights reserved	×	×	改変不可	必要	権利者の死後70年まで保護



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

本日のまとめ

大規模言語モデル（LLM）の概要について紹介しました.

1. LLMの概況について説明しました.
   - 言語モデルとは単語列の生成確率をモデル化したもの
   - なぜいま言語モデルなのか？
     スケール, 汎用性（Agent等）, 他領域への影響（マルチモーダル・ロボット）

2. LLM講座各回の概要について説明しました.
   - 基礎編で, LLM開発の基本的なパイプラインの理解と実装をする
   - 応用編で, LLMの社会実装までを考慮した技術の理解と実装をする

3. 日本のLLMを取り巻く環境について説明しました.
   - 2023年以降，本格的に開発競争が加速
   - データ, モデル, 計算環境をスケールできるかどうかが鍵

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

ご清聴ありがとうございました.

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Reference

[1] Ashish Vaswani, et al. (2017), "Attention Is All You Need", Advances in Neural Information Processing Systems (NeurIPS 2017), https://arxiv.org/abs/1706.03762

[2] Alec Radford, et al. (2018), "Improving Language Understanding by Generative Pre-training", OpenAI Technical Report, https://openai.com/research/language-unsupervised

[3] Wayne Xin Zhao, et al. (2023), "A Survey of Large Language Models", arXiv preprint arXiv:2303.18223, https://arxiv.org/abs/2303.18223

[4] OpenAI (2023), "GPT-4 Technical Report", arXiv preprint arXiv:2303.08774, https://arxiv.org/abs/2303.08774

[5] Jungo Kasai, et al. (2023), "Evaluating GPT-4 and ChatGPT on Japanese medical licensing examinations", arXiv preprint arXiv:2303.18027, https://arxiv.org/abs/2303.18027

[6] Momentum Works (2023), "The future by ChatGPT", Momentum Works Report, https://momentum.asia/product/the-future-by-chatgpt/

[7] Jared Kaplan, et al. (2020), "Scaling Laws for Neural Language Models", arXiv preprint arXiv:2001.08361, https://arxiv.org/abs/2001.08361

[8] Jason Wei, et al. (2022), "Emergent Abilities of Large Language Models", arXiv preprint arXiv:2206.07682, https://arxiv.org/abs/2206.07682

[9] Tom Brown, et al. (2020), "Language Models are Few-Shot Learners", Advances in Neural Information Processing Systems (NeurIPS 2020), https://arxiv.org/abs/2005.14165

[10] Dan Swinhoe (2024), "Microsoft bought twice as many Nvidia Hopper GPUs as other big tech companies - report", DataCenterDynamics, https://www.datacenterdynamics.com/en/news/microsoft-bought-twice-as-many-nvidia-hopper-gpus-as-other-big-tech-companies-report/

[11] Rishi Bommasani, et al. (2021), "On the Opportunities and Risks of Foundation Models", arXiv preprint arXiv:2108.07258, https://arxiv.org/abs/2108.07258

[12] Pengfei Liu, et al. (2021), "Pre-train, Prompt, and Predict: A Systematic Survey of Prompting Methods in Natural Language Processing", arXiv preprint arXiv:2107.13586, https://arxiv.org/abs/2107.13586

[13] Figure AI Inc. (2024), "Figure Official Website", https://www.figure.ai/

[14] Michael Ahn, et al. (2022), "Do As I Can, Not As I Say: Grounding Language in Robotic Affordances", arXiv preprint arXiv:2204.01691, https://arxiv.org/abs/2204.01691

[15] Anthony Brohan, et al. (2022), "RT-1: Robotics Transformer for Real-World Control at Scale", arXiv preprint arXiv:2212.06817, https://arxiv.org/abs/2212.06817

[16] Abby O'Neill, et al. (2023), "Open X-Embodiment: Robotic learning datasets and rt-x models", arXiv preprint arXiv:2310.08864, https://arxiv.org/abs/2310.08864

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Reference

[17] Physical Intelligence (2024), "π0: A Generalist Model for Physical Intelligence", Physical Intelligence Blog, https://www.physicalintelligence.company/blog/pi0

[18] OpenAI (2024), "Sora: Creating video from text", OpenAI Official Website, https://openai.com/sora

[19] OpenAI (2024), "Video generation models as world simulators", OpenAI Research, Available at: https://openai.com/research/video-generation-models-as-world-simulators

[20] Takeshi Kojima, et al. (2025), "A Comprehensive Survey on Physical Risk Control in the Era of Foundation Model-enabled Robotics", arXiv preprint arXiv:2505.12583, Available at: https://arxiv.org/abs/2505.12583

[21] Takeshi Kojima (2022), "zero_shot_cot", GitHub Repository, Available at: https://github.com/kojima-takeshi188/zero_shot_cot

[22] 東京大学 松尾・岩澤研究室 (2026), "大規模言語モデル社会実装講座", 東京大学Web.Lab教育プログラム, Available at: https://weblab.t.u-tokyo.ac.jp/education/large-language-model/

[23] Sander Schulhoff, et al. (2024), "The Prompt Report: A Systematic Survey of Prompt Engineering Techniques", arXiv preprint arXiv:2406.06608, Available at: https://arxiv.org/abs/2406.06608

[24] Jason Wei, et al. (2022), "Chain-of-Thought Prompting Elicits Reasoning in Large Language Models", arXiv preprint arXiv:2201.11903, Available at: https://arxiv.org/abs/2201.11903

[25] Takeshi Kojima, et al. (2022), "Large Language Models are Zero-Shot Reasoners", arXiv preprint arXiv:2205.11916, Available at: https://arxiv.org/abs/2205.11916

[26] Shane Gu (2025), "X Post (status/1972309771610100179)", X (formerly Twitter), Available at:https://x.com/shaneguML/status/1972309771610100179

[27] Xuezhi Wang, et al. (2023), "Self-Consistency Improves Chain of Thought Reasoning in Language Models", arXiv preprint arXiv:2203.11171, Available at: https://arxiv.org/abs/2203.11171

[28] Sweta Agrawal, et al. (2025), "GEPA: Reflective Prompt Evolution Can Outperform Reinforcement Learning", arXiv preprint arXiv:2502.14856, Available at: https://arxiv.org/abs/2502.14856

[29] Raimi Karim (2019), "Illustrated: Self-Attention", Towards Data Science, Available at: https://towardsdatascience.com/illustrated-self-attention-2d627e33b20a

[30] Jay Alammar (2018), "The Illustrated Transformer", Visualizing machine learning one concept at a time, Available at: http://jalammar.github.io/illustrated-transformer/

[31] Tom Henighan, Jared Kaplan, et al. (2020), "Scaling Laws for Autoregressive Generative Modeling", arXiv preprint arXiv:2010.14701, Available at: https://arxiv.org/abs/2010.14701

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Reference

[32] Daisuke Okanohara, "X Post (status/1972421341988225340)", X (formerly Twitter), Available at: https://x.com/hillbig/status/1972421341988225340

[33] Rewon Child, et al. (2019), "Generating Long Sequences with Sparse Transformers", arXiv preprint arXiv:1904.10509, Available at: https://arxiv.org/abs/1904.10509

[34] sunbluesome (2022), "Sparse Transformerを理解したい", Zenn, Available at: https://zenn.dev/sunbluesome/articles/5f6a86dfa1e1be

[35] William Fedus et al. (2022), "Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity", Journal of Machine Learning Research 23 (2022) 1-39, Available at: https://jmlr.org/papers/v23/21-0998.html

[36] Tim Dettmers, et al. (2022), "A Gentle Summary of LLM.int8(): Zero Degradation Matrix Multiplication for Large Language Models", Hugging Face Blog, Available at: https://huggingface.co/blog/hf-bitsandbytes-integration

[37] Microsoft Deep Speed Team (2023), "DeepSpeed: 深層学習の訓練と推論を劇的に 高速化するフレームワーク", DeepSpeed Official, Available at: https://www.deepspeed.ai/assets/files/DeepSpeed_Overview_Japanese_2023Jun7th.pdf

[38] Chung, Hyung Won, et al. (2022), "Scaling Instruction-Finetuned Language Models", arXiv preprint arXiv:2210.11416, Available at: https://arxiv.org/abs/2210.11416

[39] Edward J. Hu et al. (2021), "LoRA: Low-Rank Adaptation of Large Language Models", arXiv preprint arXiv:2106.09685, Available at: https://arxiv.org/abs/2106.09685

[40] Rafailov, Rafael, et al. (2023), "Direct Preference Optimization: Your Language Model is Secretly a Reward Model", Advances in Neural Information Processing Systems (NeurIPS 2023), Available at: https://arxiv.org/abs/2305.18290

[41] Shao, Zhihong, et al. (2024), "DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models", arXiv preprint arXiv:2402.03300, Available at: https://arxiv.org/abs/2402.03300

[42] 株式会社サイバーエージェント (2023), "サイバーエージェント、最大68億パラメータの日本語LLM（大規模言語モデル）を一般公開 ―オープンなデータで学習した商用利用可能なモデルを提供―", サイバーエージェント ニュース, Available at: https://www.cyberagent.co.jp/news/detail/id=28817

[43] rinna株式会社 (2023), "rinna、日本語に特化した36億パラメータのGPT言語モデルを公開", rinna株式会社 ニュース, Available at: https://rinna.co.jp/news/2023/05/20230507.html

[44] Stability AI Japan (2023), "日本語言語モデル「Japanese StableLM Alpha」をリリースしました", Stability AI Blog, Available at: https://ja.stability.ai/blog/japanese-stablelm-alpha

[45] Ledge.ai編集部 (2023), "LINE 36億パラメータの日本語LLMを公開 商用利用も可", Ledge.ai, Available at: https://ledge.ai/articles/line_japanese_large_lm

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Reference

[46] 日本電気株式会社 (2023), "NEC、130億パラメータで世界トップクラスの日本語性能を有する軽量なLLMを開発 (2023年7月6日): プレスリリース", NEC プレスリリース, Available at: https://jpn.nec.com/press/202307/20230706_02.html

[47] OpenAI (2023), "GPT-4", OpenAI Research, Available at: https://openai.com/research/gpt-4

[48] ELYZA (2023), "70億パラメータの商用利用可能な日本語LLM「ELYZA-japanese-Llama-2-7b」を一般公開しました", ELYZA ニュース, Available at: https://elyza.ai/news/2023/08/29/70%E5%84%84%E3%83%91%E3%83%A9%E3%83%A1%E3%83%BC%E3%82%BF%E3%81%AE%E5%95%86%E7%94%A8%E5%88%A9%E7%94%A8%E5%8F%AF%E8%83%BD%E3%81%AA%E6%97%A5%E6%9C%AC%E8%AA%9Ellmelyza-ja

[49] 日本電信電話株式会社 (2023), "NTT版LLM「tsuzumi」", NTT R&D Website, Available at: https://www.rd.ntt/research/LLM_tsuzumi.html

[50] 株式会社ELYZA (2024), "700億パラメータの日本語LLM「ELYZA-japanese-Llama-2-70b」を開発し、デモを公開しました", ELYZA 公式ブログ (note), Available at: https://note.com/elyza/n/n0ea755ca3e7b

[51] 楽天グループ株式会社 (2024), "楽天、日本語に最適化したオープンかつ高性能なLLMを公開", 楽天グループ プレスリリース, Available at: https://corp.rakuten.co.jp/news/press/2024/0321_01.html

[52] rinna株式会社 (2023), "rinna、Llama 2の日本語継続事前学習モデル「Youri 7B」シリーズを公開", rinna株式会社 ニュース, Available at: https://rinna.co.jp/news/2023/10/20231031.html

[53] 株式会社サイバーエージェント (2024), "独自の日本語LLM（大規模言語モデル）のバージョン3を一般公開 ―225億パラメータの商用利用可能なモデルを提供―", サイバーエージェント ニュース, Available at: https://www.cyberagent.co.jp/news/detail/id=30463

[54] Swallow-LLM Project (2024), "Llama 3 Swallow", Swallow-LLM GitHub Pages, Available at: https://swallow-llm.github.io/llama3-swallow.ja.html

[55] LLM-jp (2024), "大規模言語モデル「LLM-jp-13B v2.0」を構築・公開", LLM-jp 公式ブログ, Available at: https://llm-jp.nii.ac.jp/blog/2024/04/30/v2.0-release.html

[56] 株式会社Preferred Networks (2024), "GENIAC第1サイクルの開発成果として 大規模言語モデル PLaMo-100B-Pretrained を公開", Preferred Networks ニュース, Available at: https://www.preferred.jp/ja/news/pr20241015

[57] 株式会社Preferred Networks (2023), "PLaMo-13Bを公開しました", Preferred Networks Tech Blog, Available at: https://tech.preferred.jp/ja/blog/llm-plamo/

[58] 日本電気株式会社 (2024), "NEC、世界トップレベル性能の高速な大規模言語モデル(LLM) cotomi Pro / cotomi Lightを開発", NEC プレスリリース, Available at: https://jpn.nec.com/press/202404/20240424_01.html

[59] ストックマーク株式会社 (2024), "ハルシネーションを大幅抑止し専門的な質問にも正確な回答が可能な生成AI ストックマーク、独自の130億パラメータのLLMを開発し商業利用可能なオープンソースとして公開", ストックマーク ニュース, Available at: https://stockmark.co.jp/news/20240516

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Reference

[60] SB Intuitions株式会社 (2024), "SB Intuitions、独自の日本語LLMを構築 アカデミアや産業界の研究開発に資するために70億、130億、650億パラメータの日本語LLMを公開", SB Intuitions プレスリリース, Available at: https://www.sbintuitions.co.jp/news/press/20240614_01/

[61] 富士通株式会社 (2024), "スーパーコンピュータ「富岳」で学習した大規模言語モデル「Fugaku-LLM」を公開", 富士通 プレスリリース, Available at: https://pr.fujitsu.com/jp/news/2024/05/10.html

[62] 東京工業大学 (2023), "日本語に強い大規模言語モデル「Swallow」を公開", 東京工業大学 ニュース, Available at: https://www.titech.ac.jp/news/2023/068089

[63] 東京大学 松尾・岩澤研究室 (2024), "松尾・岩澤研究室、経産省・NEDOの「GENIAC」プロジェクトにおいて、国内初となる大規模言語モデル（LLM）のマルチモーダル化等の開発成果を公開", 東京大学Web.Lab ニュース, https://weblab.t.u-tokyo.ac.jp/2024-08-30/

[64] llm-jp (2024), "Awesome Japanese LLM", GitHub Pages, https://llm-jp.github.io/awesome-japanese-llm/

[65] weblab-GENIAC (2024), "Tanuki-8B-dpo-v1.0", Hugging Face Spaces, https://huggingface.co/spaces/weblab-GENIAC/Tanuki-8B-dpo-v1.0

[66] Dan Swinhoe (2024), "Microsoft bought twice as many Nvidia Hopper GPUs as other big tech companies - report", DatacenterDynamics, https://www.datacenterdynamics.com/en/news/microsoft-bought-twice-as-many-nvidia-hopper-gpus-as-other-big-tech-companies-report/

[67] Timothy Prickett Morgan (2024), "Nvidia Unfolds GPU, Interconnect Roadmaps Out To 2027", The Next Platform, https://www.nextplatform.com/2024/06/02/nvidia-unfolds-gpu-interconnect-roadmaps-out-to-2027/

[68] Linting Xue, et al. (2021), "mT5: A massively multilingual pre-trained text-to-text transformer", Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT 2021), https://aclanthology.org/2021.naacl-main.41/

[69] 櫻井 章雄 (2022), "世界で開発が進む大規模言語モデルとは（後編）", NTTデータ先端技術株式会社 コラム, https://www.intellilink.co.jp/column/ai/2022/072800.aspx

[70] LLM-jp (2024), "llm-jp-corpus-v4", GitLab Datasets, https://gitlab.llm-jp.nii.ac.jp/datasets/llm-jp-corpus-v4

[71] 個人情報保護委員会 (2023), "生成AIサービスの利用に関する注意喚起等について", 個人情報保護委員会 ニュース, https://www.ppc.go.jp/news/careful_information/230602_AI_utilize_alert/

[72] OpenAI (2026), "Terms of Use", OpenAI Policies, https://openai.com/ja-JP/policies/row-terms-of-use/

[73] DeepSeek-AI(2025),”DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning”, arXiv preprint https://arxiv.org/abs/2501.12948 ,
Available at: https://arxiv.org/abs/2501.12948

”

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO



松尾・岩澤研究室

MATSUO-IWASAWA LAB UTOKYO

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO