注意事項: 本資料の再利用(2次利用)について

- **本資料について**
  - 東京大学 松尾・岩澤研究室が作成し、2025年10月から11月にかけて開催されたLLM大規模言語モデル講座基礎編の講義資料です。
  - クリエイティブ・コモンズのCC BY-NC-SA 4.0 DEED(表示 – 非営利 – 継承 4.0 国際)のライセンス登録をしています。
- **ライセンスの表示について**
  - 各スライドのページ最下部にライセンスの記載があります。再利用時には本ライセンス表示を必ずご記載ください。再利用時に複製が困難な場合は、下記のテキストボックスを利用の上、ハイパーリンクも含めてライセンスの表記をするようお願いします。

    LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
  - 再利用するページに参照論文等の引用がある場合は、巻末にあるReferenceより引用箇所を掲載してください。
- **非営利目的での利用について**　再利用(2次利用)が許諾されています。
- **営利目的での再利用について**　こちらからお問い合わせください。
- **その他**
  - 元の表現が変わらない範囲(フォント、サイズ等)であれば改変可能です。
  - それ以外の改変その他ライセンスについての詳細は、こちらをご覧の上適切な取り扱いをお願いします。

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

3. Pre-training

松尾・岩澤研究室
MATSUO-IWASAWA LAB UTOKYO

内山史也

許諾なく撮影や第三者への開示を禁止します

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Pre-training（Day3）

- 目的：
  - ○ LLM(大規模言語モデル)の主流なモデル構造であるTransformerと、その事前学習の仕組みを理解する

- 目標：
  - ○ 言語モデルにおけるTransformerの位置づけについて説明できる
  - ○ LLMで主流となっているTransformerのモデル構造について説明できる
  - ○ LLMの事前学習のパイプラインについて説明できる

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

全体の流れ

- 講義：
  - ○ 言語モデルとは何か？
  - ○ Transformer
  - ○ 事前学習
  - ○ 発展的話題

- 演習：
  - ○ PyTorchを用いてTransformerを実装・学習

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

目次

- 言語モデルとは何か？
- Transformer
- 事前学習
- 発展的話題

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

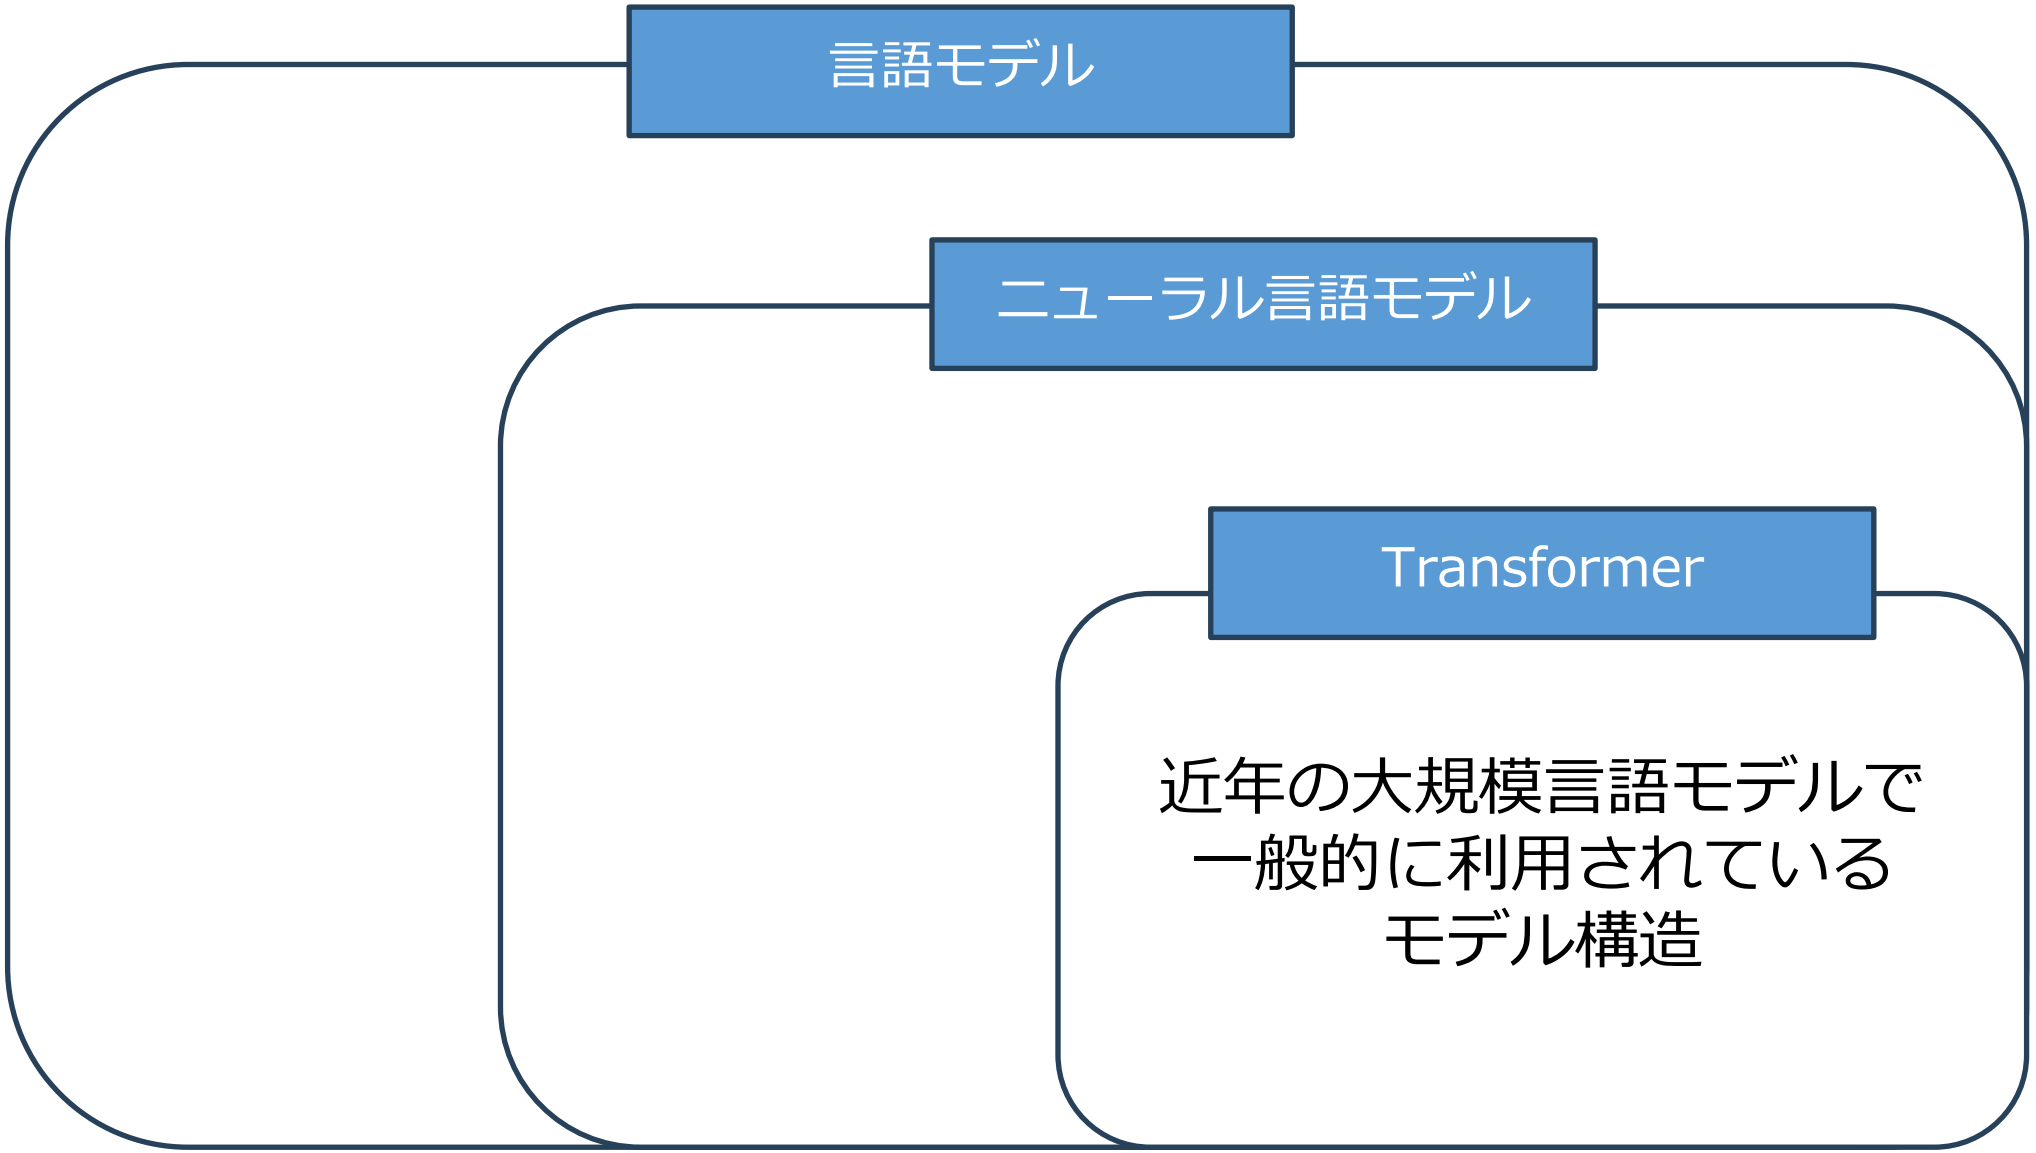
目次

- **言語モデルとは何か？　＊大規模言語モデル**
- Transformer
- 事前学習
- 発展的話題

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

言語モデルとTransformerの関係



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

言語モデル (Language Models)とは

Day1の復習

- 単語の系列（≒文章）の生起確率$p(x_1, x_2, \cdots, x_L)$をモデル化したもの
- $p(x_1, x_2, \cdots, x_L)$を連鎖律で分解したものは**自己回帰言語モデル**と呼ばれる

$$p(x_1, x_2, \cdots, x_L) = P(x_1)p(x_2|x_1)\cdots p(x_L|x_1, \cdots, x_{L-1})$$

- 条件付き確率がわかると**生成**ができる

$$p(\text{東京}|\text{日本}, \text{の}, \text{首都}, \text{は}) = 0.2$$
$$p(\text{パリ}|\text{日本}, \text{の}, \text{首都}, \text{は}) = 0.001$$
$$\vdots$$
$$p(\text{カイロ}|\text{日本}, \text{の}, \text{首都}, \text{は}) = 0.0005$$

日本の首都は → **東京**

$= \arg\max p\,(x|\text{日本}, \text{の}, \text{首都}, \text{は})$

- x_Lとしてふさわしい予測は、$\arg\max p\,(x_L|x_1, \cdots, x_{L-1})$
- この条件付き確率をニューラルネットで表現したのが**ニューラル言語モデル**

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

（参考）DL以前の代表的な言語モデル

- 条件付き確率を統計的に求める方法
  - 大規模コーパス内の単語列の出現頻度から求める
  - 単語列 s の出現回数を#(s)とすると、

$$p(\text{東京} \mid \text{日本}, \text{の}, \text{首都}, \text{は}) = \frac{\#(\text{日本}, \text{の}, \text{首都}, \text{は}, \text{東京})}{\#(\text{日本}, \text{の}, \text{首都}, \text{は})}$$

200回

1000回

- 課題
  - データスパースネス問題
    単語列が長くなると、その出現回数が急速に減少し、条件付き確率の推定が困難になる
  - 類義語問題
    類義語が個別の事象として扱われてしまう．言い方を微妙に変えただけでも異なる出現頻度の語として扱われてしまう（例：”日本の首都は？”と”日本国の首都は？”）

[1] 岡崎直観 (2023), 大規模言語モデルの驚異と脅威 - Speaker Deck を参考

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

（参考）DL以前の代表的な言語モデル

- N-gram言語モデル
  - 直近のN-1個の単語を使って次の単語を予測する
  - 各単語の出現確率は出現頻度で推定する
  - （例）3-gram言語モデル

$$p(\text{東京} \mid \text{日本}, \text{の}, \text{首都}, \text{は}) \approx p(\text{東京} \mid \text{首都}, \text{は})$$

直近の２単語”首都は”だけから
”東京”と特定することは難しい

- データスパースネス問題をある程度回避できる
- 長距離の単語間の関係性を把握しづらいことが課題
  👉Transformerで解決（後述）

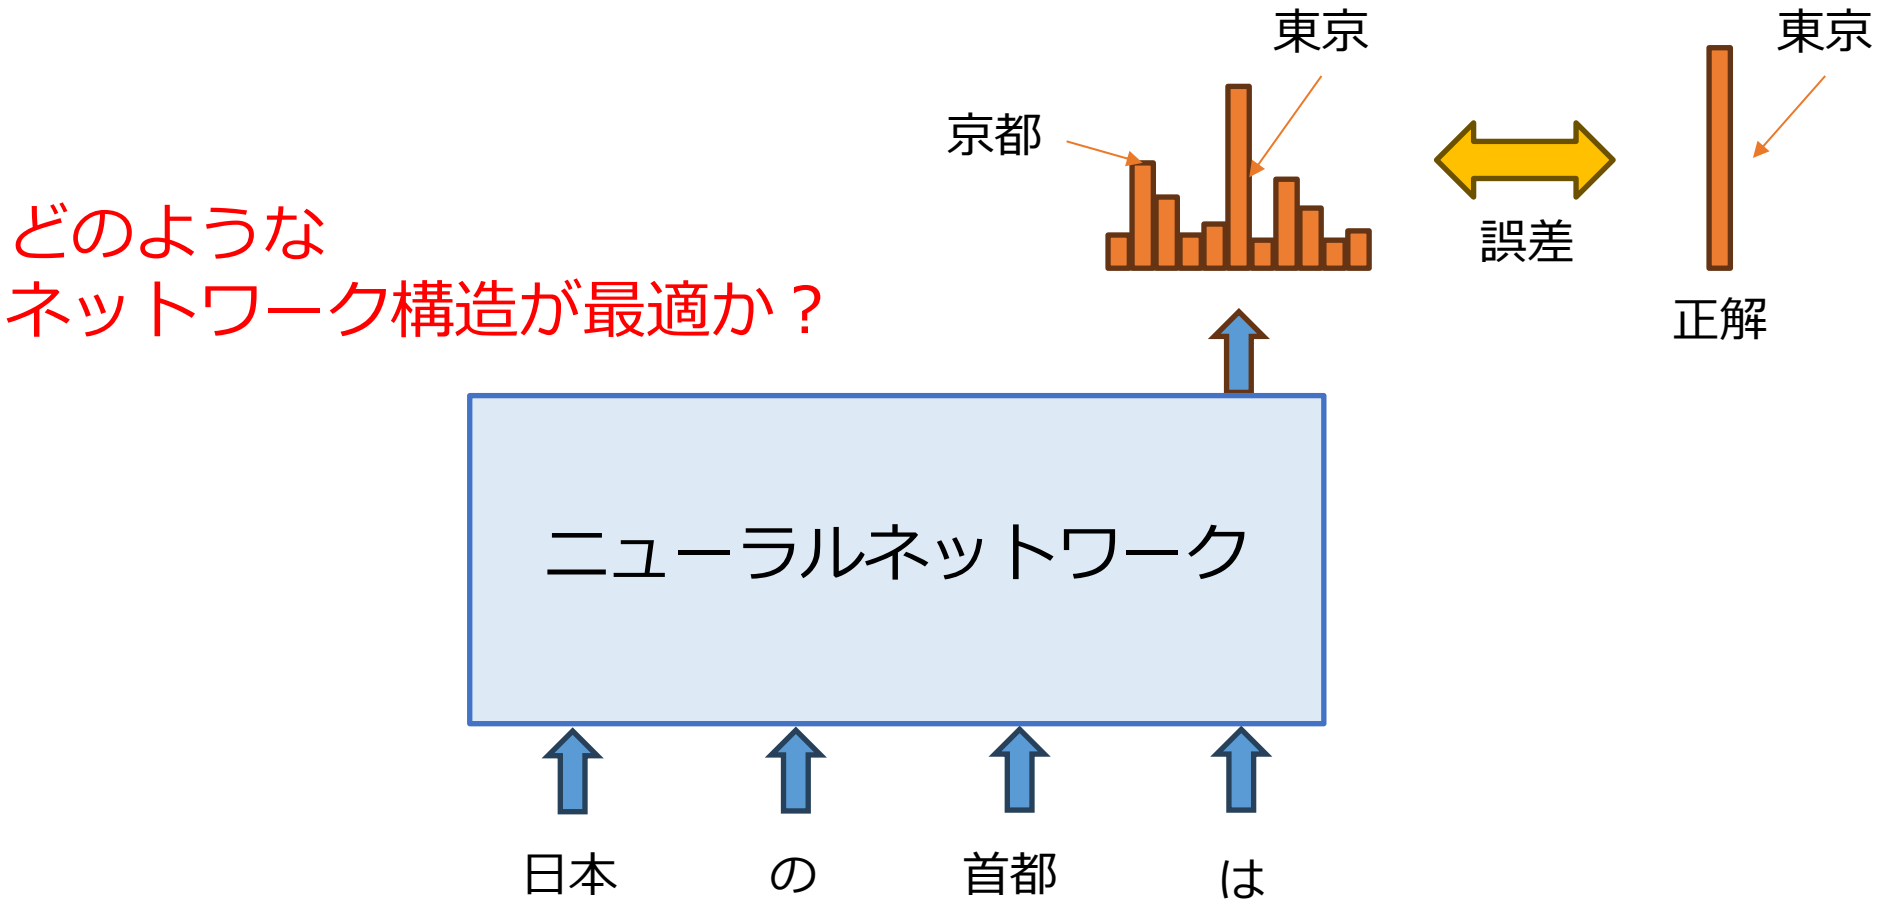
[1] 岡崎直観 (2023), 大規模言語モデルの驚異と脅威 - Speaker Deck を参考

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

ニューラル言語モデル

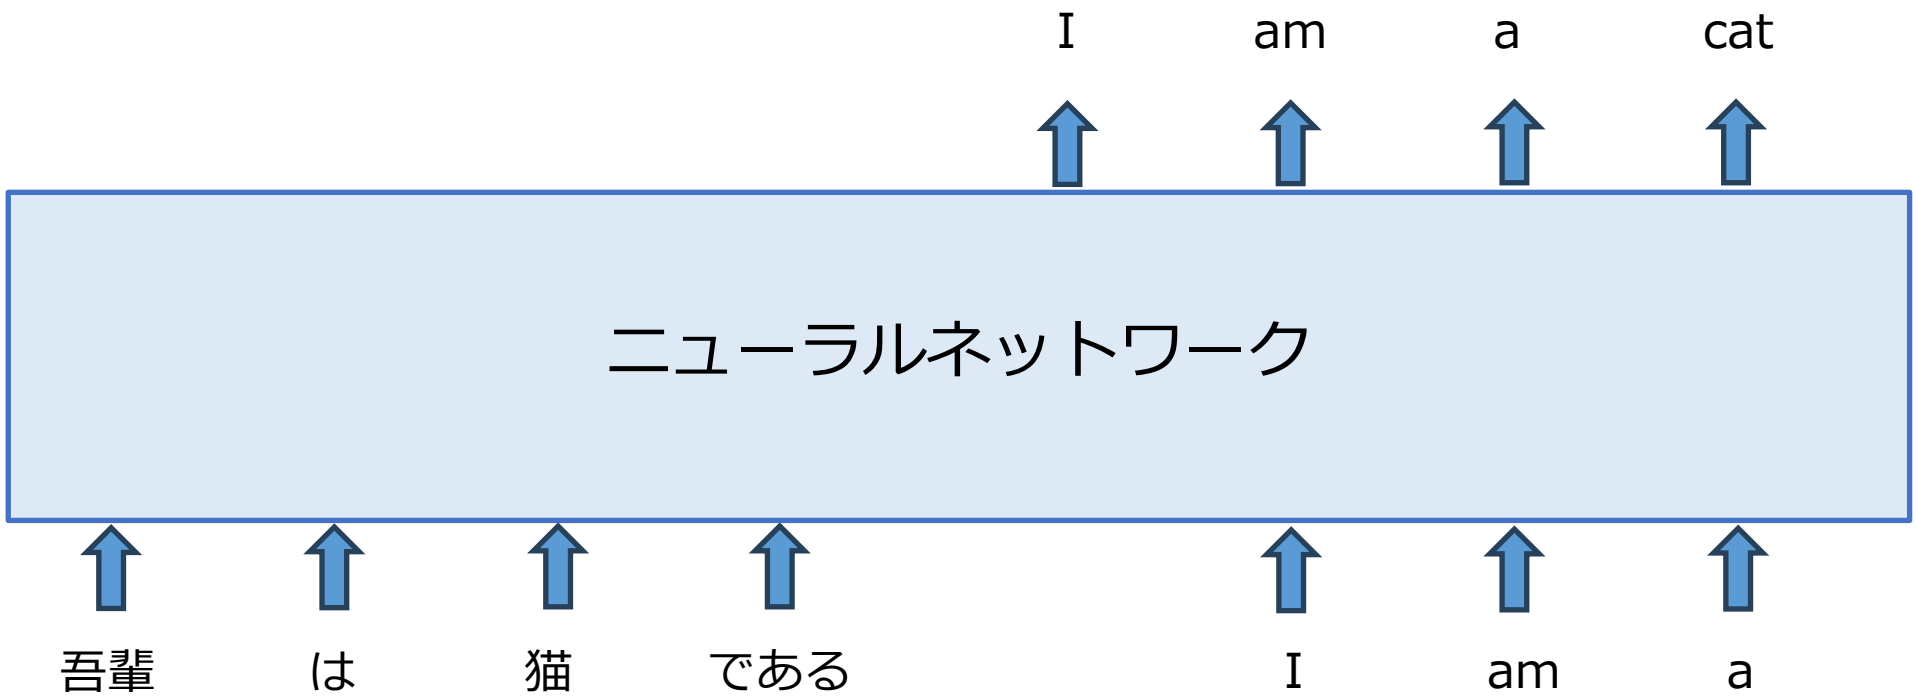
- 条件付き確率を何らかのニューラルネットで推定したモデル
- 他の機械学習と同様尤度を最大化するように訓練（誤差逆伝播）



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

ニューラル言語モデル

- ニューラル言語モデルは, 機械翻訳の分野で大きく発展してきた
- ここから機械翻訳のタスクを例として検討する



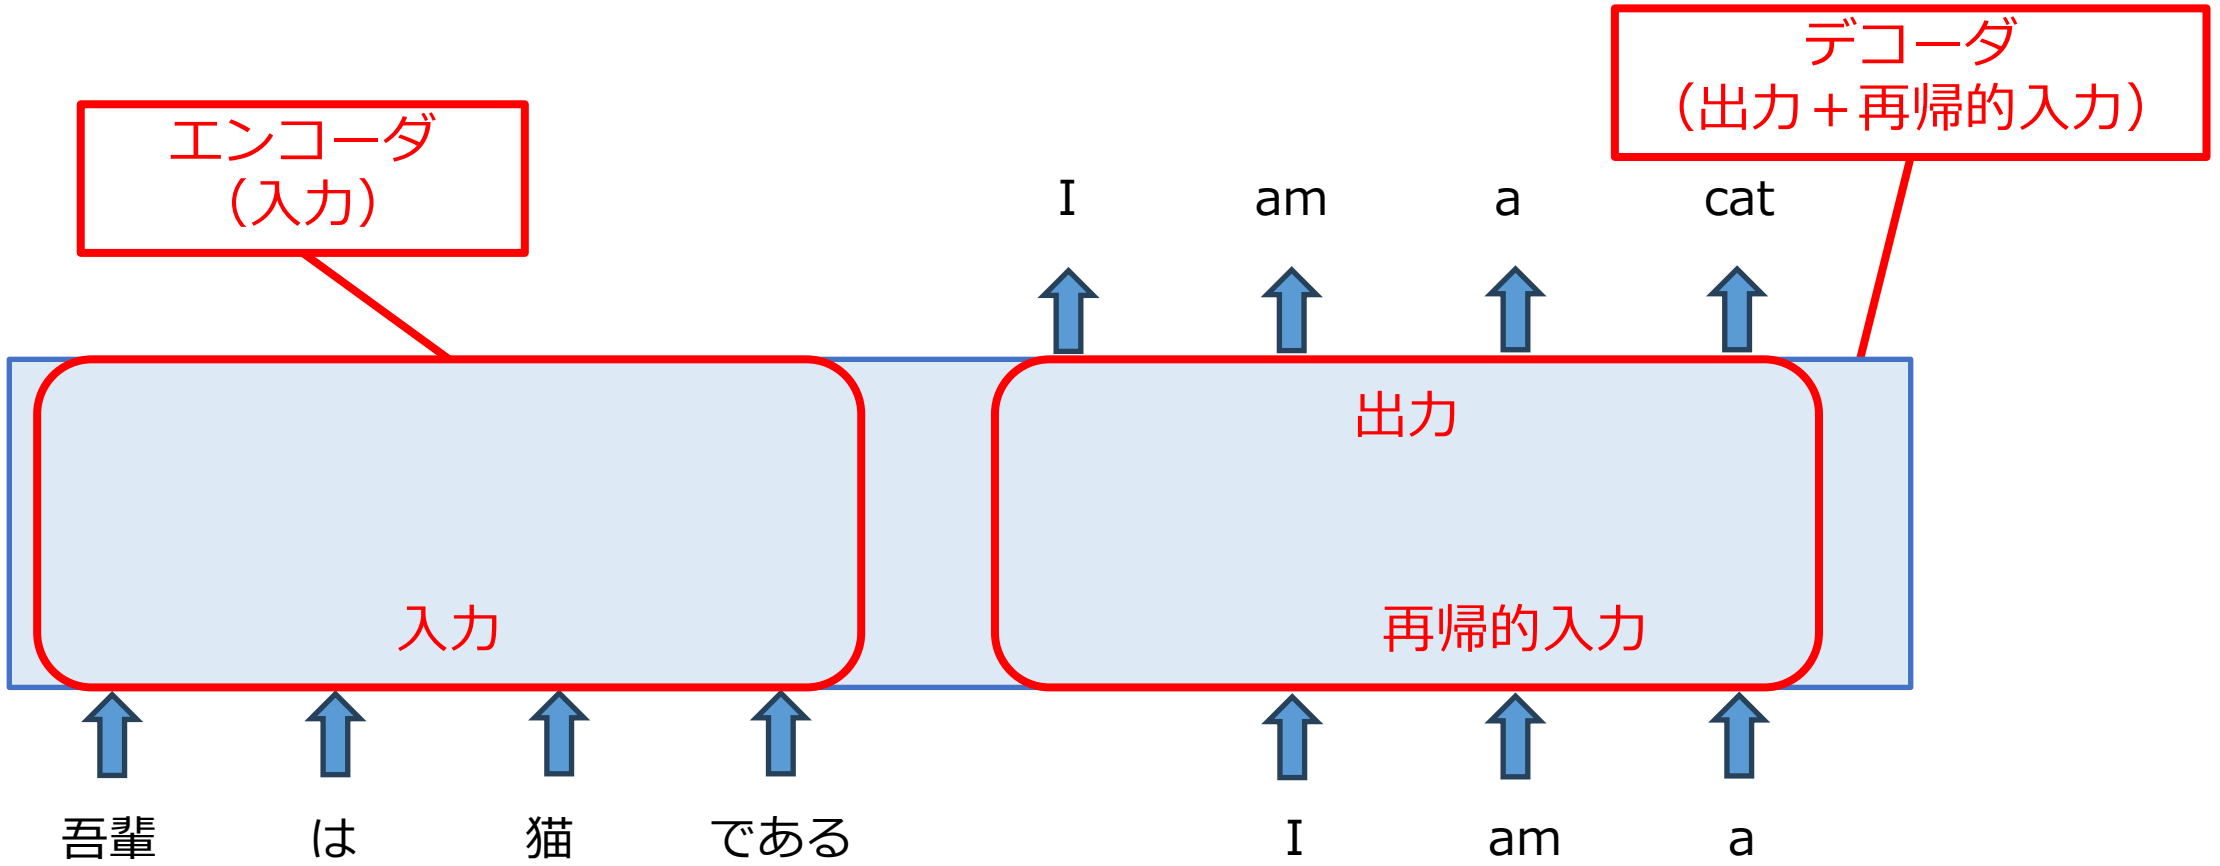
[1] 岡崎直観 (2023), 大規模言語モデルの驚異と脅威 - Speaker Deck を参考

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

ニューラル言語モデル

- エンコーダ：文（翻訳元言語）の入力機構を持つニューラルネット
- デコーダ：文（翻訳先言語）の出力機構および再帰的入力機構を持つNN

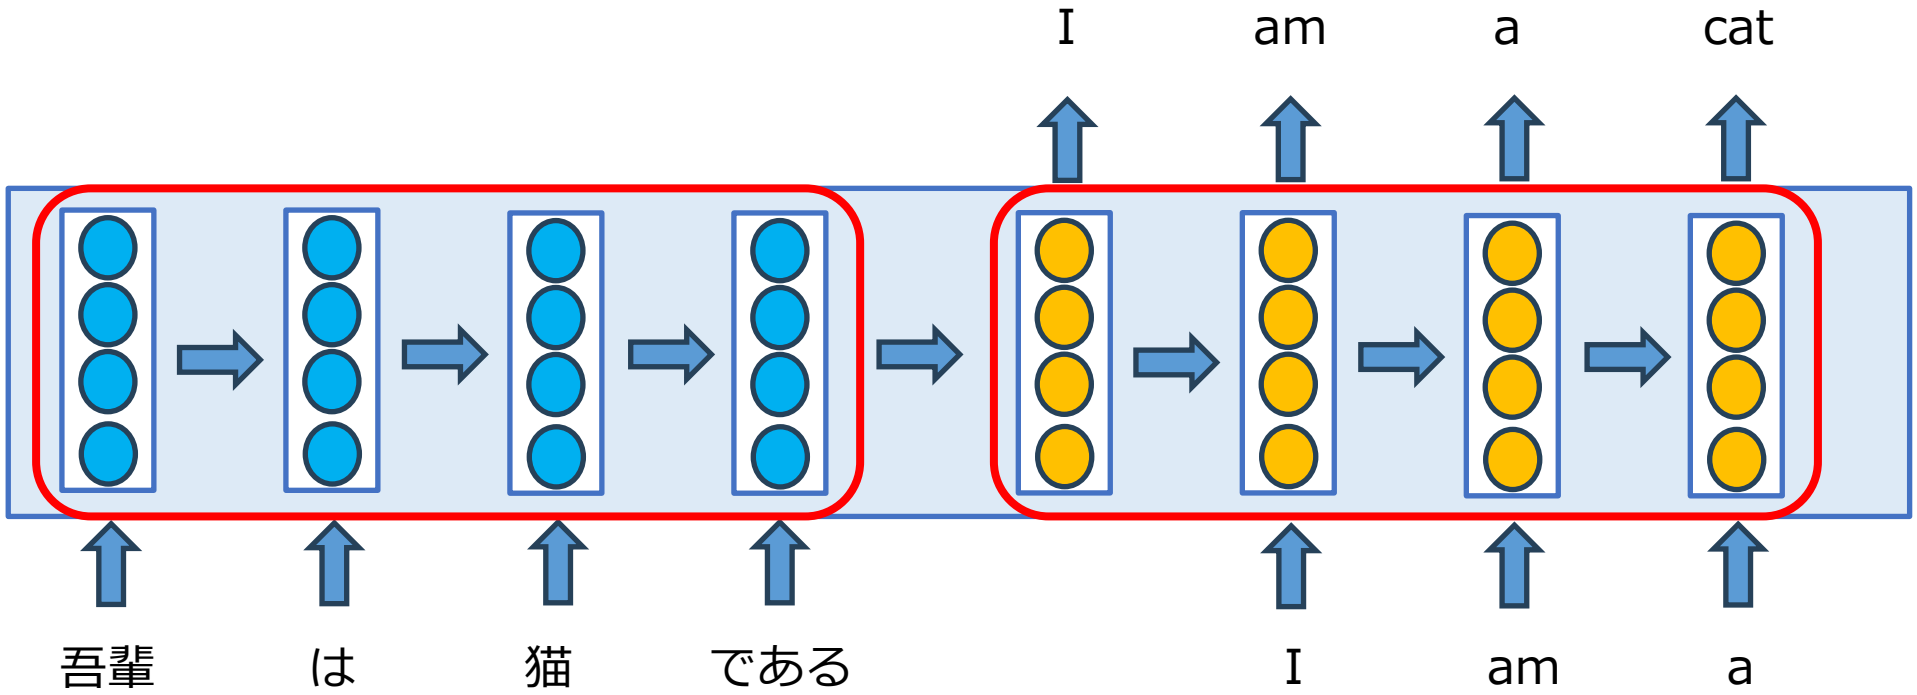


[1] 岡崎直観 (2023), 大規模言語モデルの驚異と脅威 - Speaker Deck を参考
[2] Ilya Sutskever et al. (2014), “sequence to sequence learning with neural networks”, NeurIPS2014 を参考

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

ニューラル言語モデル

- RNN型言語モデル (代表的モデル：Seq2Seq)
  - RNN: Recurrent Neural Network
  - 冒頭の単語から一単語ずつニューラルネットワークに入力してニューロンを逐一更新
  - パラメータは使いまわし
  - 原理的には単語をいくつでも入力＆出力できる

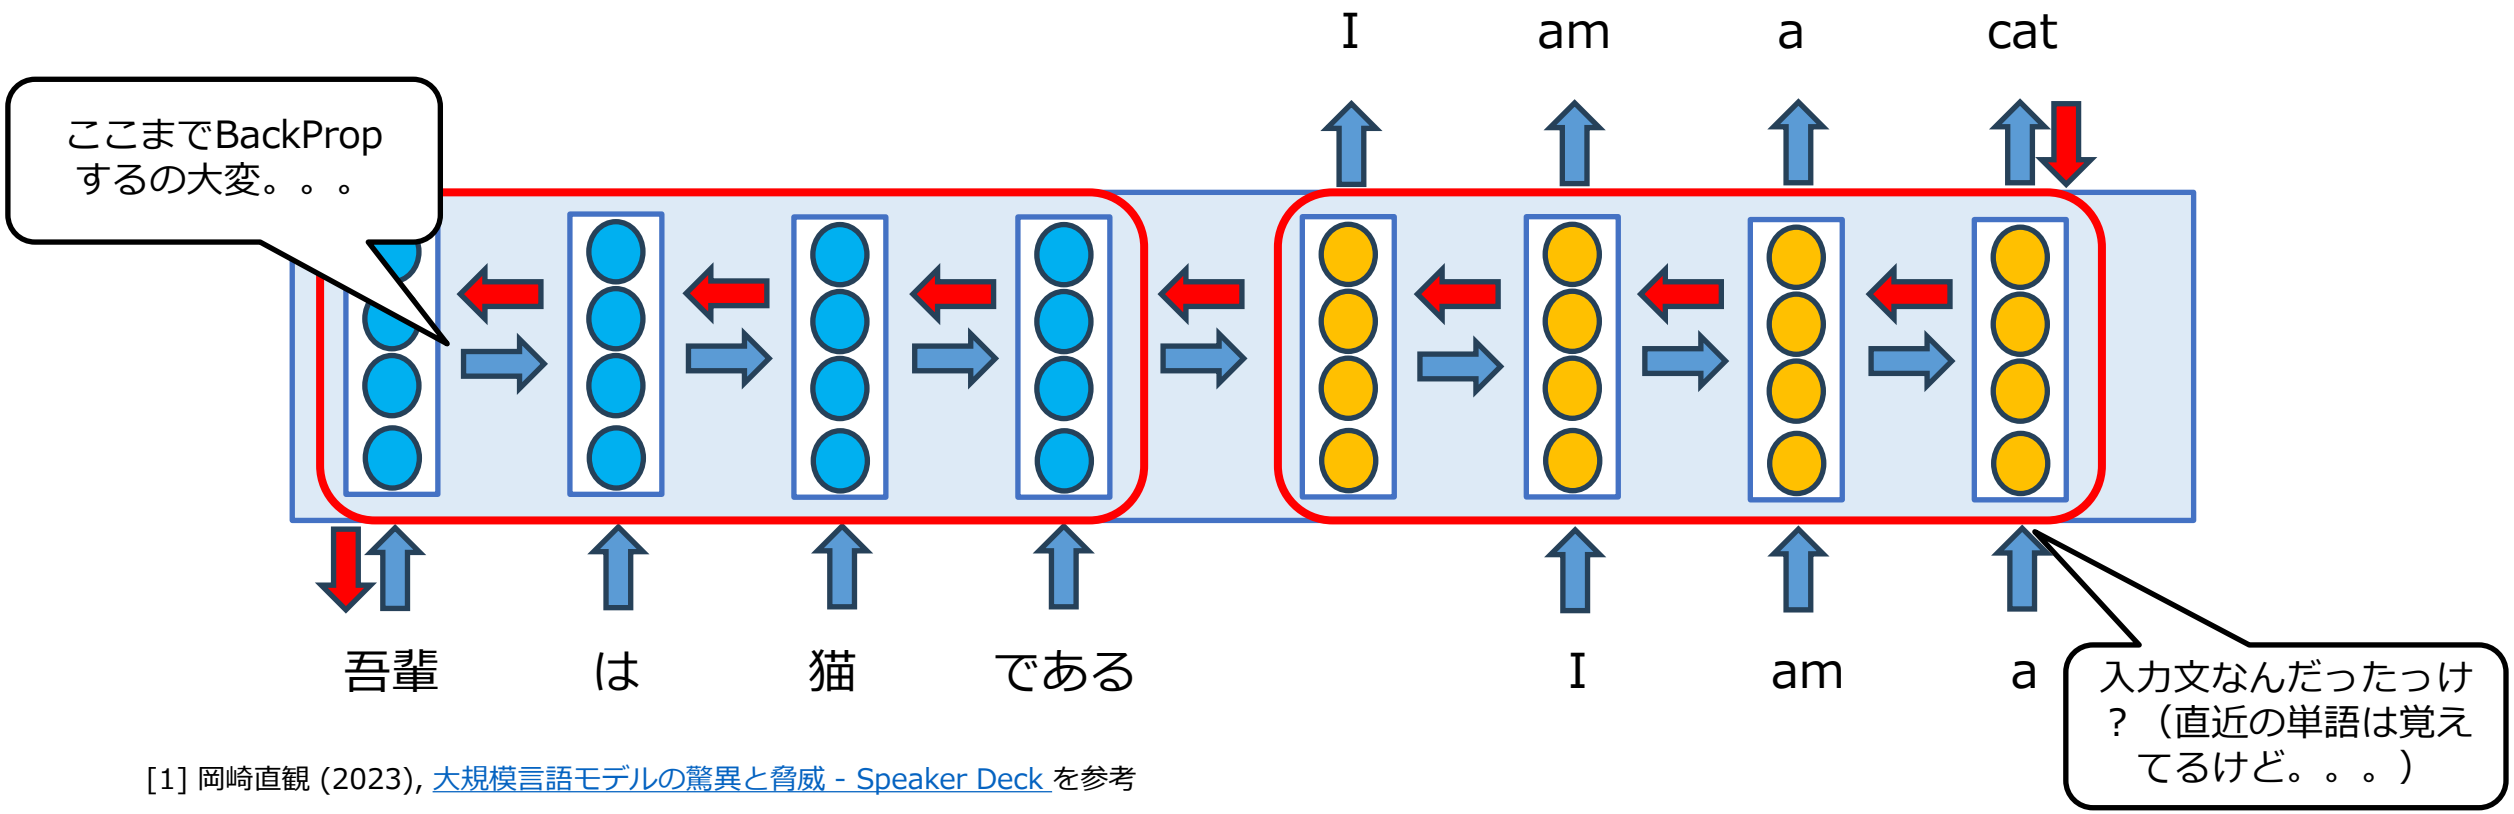


[1] 岡崎直観 (2023), 大規模言語モデルの驚異と脅威 - Speaker Deck を参考
[3] Tomáš Mikolov et al. (2010), "recurrent neural network based language model", INTERSPEECH2010

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

ニューラル言語モデル

- RNN型言語モデル (代表的モデル：Seq2Seq)
  - 課題①：ニューロンが固定長なので、長文になると全ての情報を覚えきれない
    結局、単語間の長距離依存性の把握が困難
  - 課題②：ネットワークが単語方向に深くなるため、学習が不安定(勾配消失, 勾配爆発)
    ＆ 学習が遅い

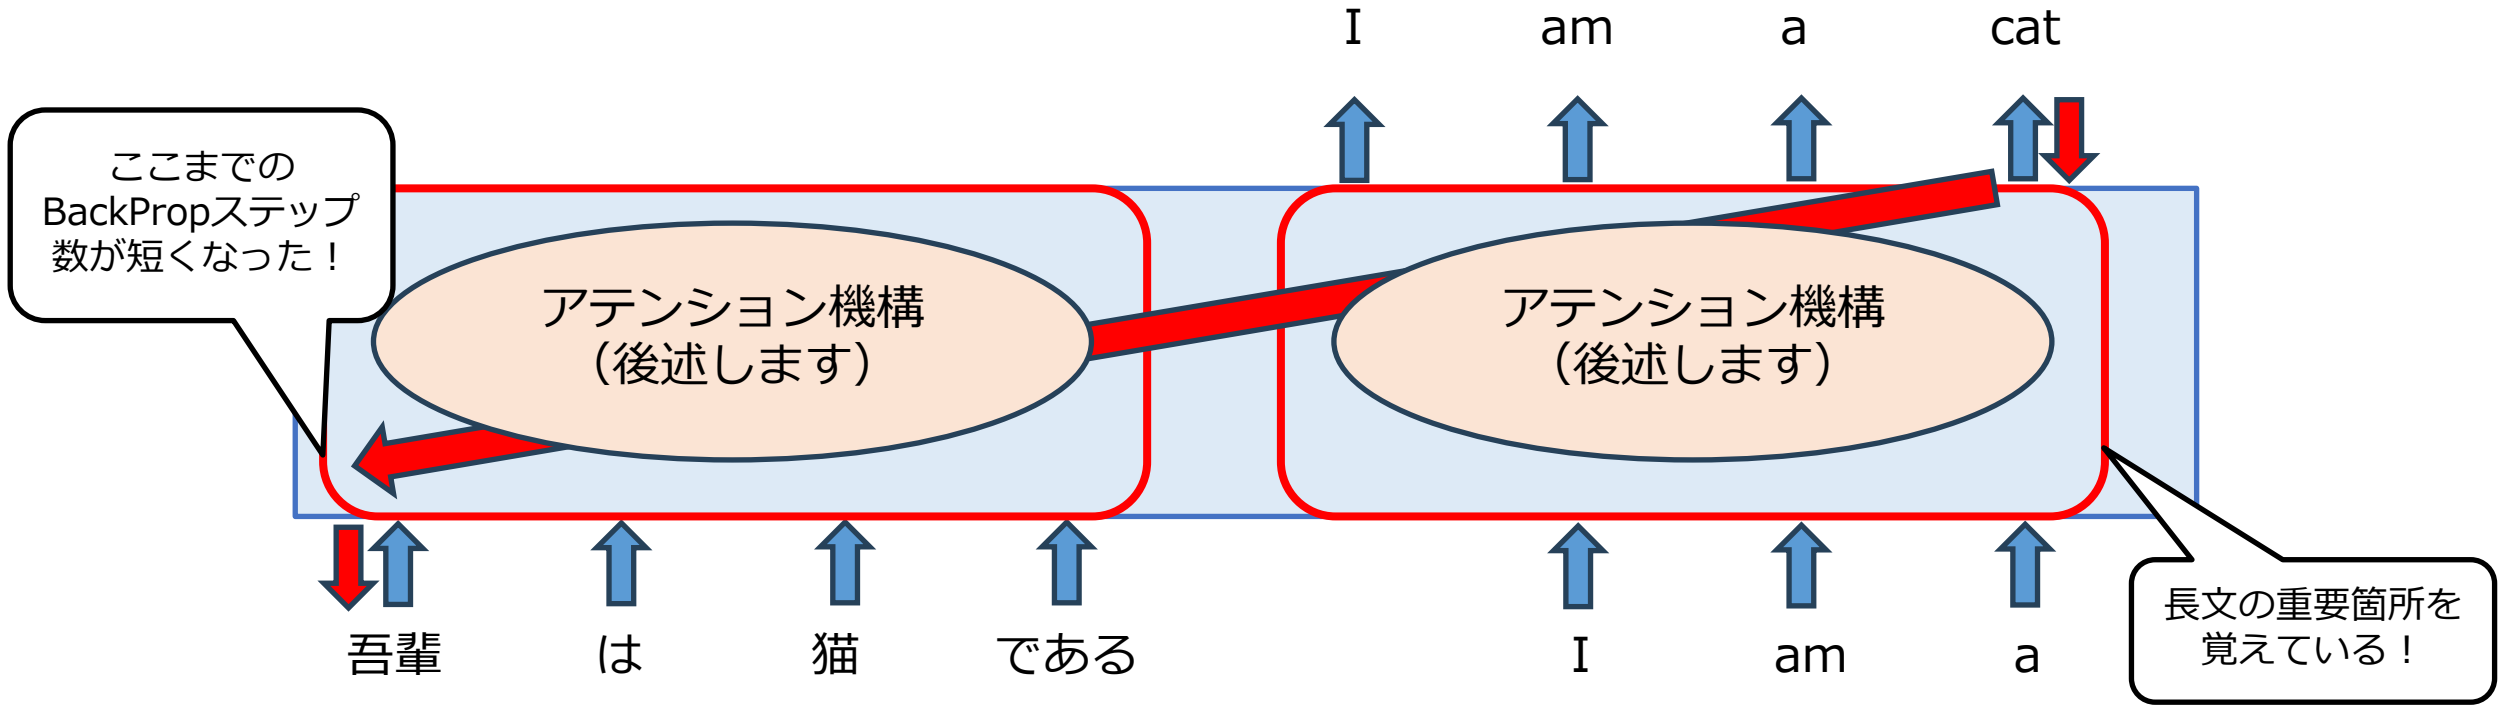


[1] 岡崎直観 (2023), 大規模言語モデルの驚異と脅威 - Speaker Deck を参考

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

ニューラル言語モデル

- Transformer（モデル構造については後述します）
  - アテンション機構を最大限活用することで, 先述したRNN型の問題を解決(*)
  - 単語間の長距離依存性を把握できるようになった
  - 誤差逆伝播 (BackProp) のステップ数が単語数に依存しなくなり(短くなり)、学習の安定化 & 高速化を実現



(*) RNNにアテンション機構を導入する先行研究は存在するが, 全単語間ではなかった. Transformerは全単語間にアテンション機構を導入した. マルチヘッドアテンションも新規.
[4]Dzmitry Bahdanau et al. (2014),"Neural machine translation by jointly learning to align and translate" / 技術の差分についての解説は以下がわかりやすい.
[5]Masaki Hayashi (2022),Transformer と seq2seq with attention の違いは？系列変換モデル【Q and A 記事】 | CVMLエキスパートガイド

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

目次

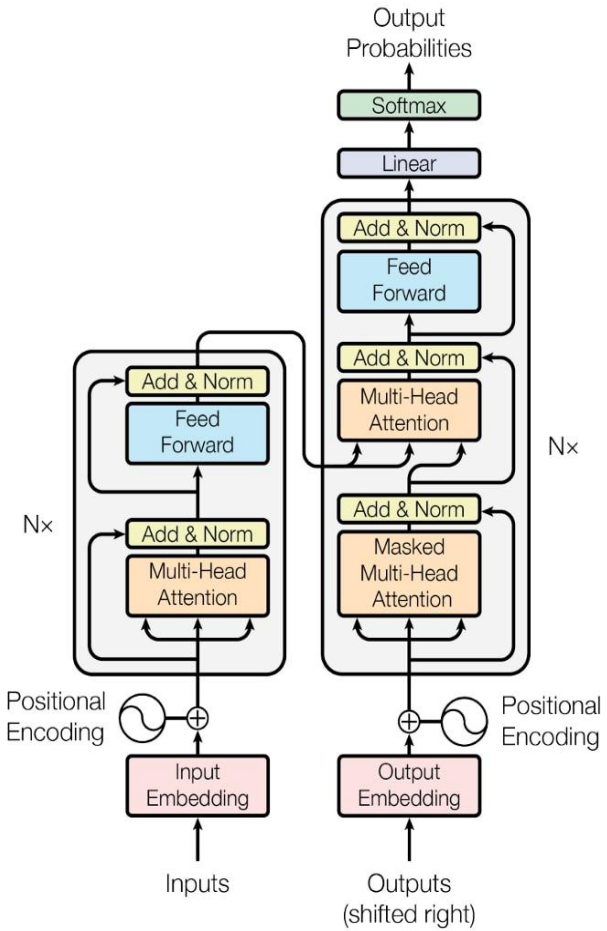
- 言語モデルとは何か？
- **Transformer**
- 事前学習
- 発展的話題

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

LLMのモデル構造

Transformerが主流（”Attention Is All You Need”という論文で初出）



Attention is all you need

A Vaswani, N Shazeer, N Parmar… - Advances in neural …, 2017 - proceedings.neurips.cc

… to attend to **all** positions in the decoder up to and including that position. **We need** to prevent … **We** implement this inside of scaled dot-product **attention** by masking out (setting to −∞) …

☆ 保存　99 引用　被引用数: 128159　関連記事　全 91 バージョン　»

2024/08/07 Gooogle Scholarにアクセス

- Googleを中心とした研究チームが発表
- Attention機構の採用で単語（トークン）の長距離依存関係を効率的に学習
- 学習時の並列計算も効率化できたことで大規模化（分散学習）しやすくなった

“Attention Is All You Need”, 2017

[6] Ashish Vaswani et al. (2017), “Attention Is All You Need”, NeurIPS2017 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

LLMのモデル構造

Transformerの凄さ

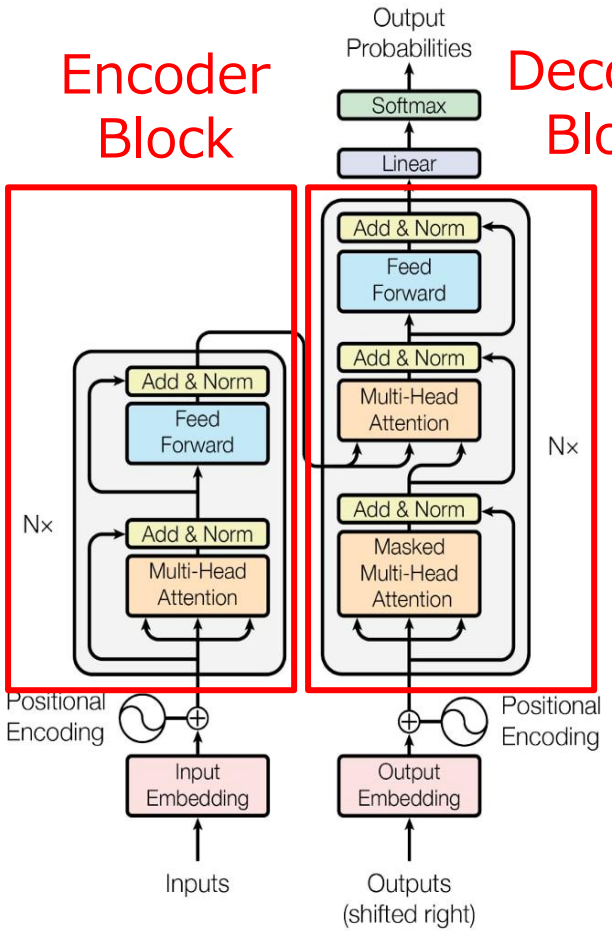
- 2017年の発表以降, モデルの改良およびスケールによって、
  数多くのベンチマークで当時の最高性能（SOTA）を達成し続けている
- GPT-1~4、gpt-oss、Gemini 2.5等はTransformerが採用されている
  - GPT-4はモデルの詳細な構造については非公開だが、
    Transformerベースであると Technical Reportにて記載あり
  - GPT-5のアーキテクチャは不明だが、system cardにはLLMとして記述されている
- GPT-5の評価事例
  - AIME 2025（米国の高校生向け数学競技）で94.6%（ツールなし）を記録
  - 医療分野では、HealthBench Hardで46.2%
- Gemini 2.5の評価事例
  - AIME 2025（米国の高校生向け数学競技）で88.0%を記録
  - 最適化されたフレームワークにて、ポケットモンスター青を406.5時間でクリア

[7] OpenAI (2023), “GPT-4 Technical Report”
[8] OpenAI (2025), “GPT-5 System Card”
[9] OpenAI (2025), “GPT-5 が登場”
[10] Google (2025), “Gemini 2.5 tech report”

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Transformerのモデル構造

Transformer



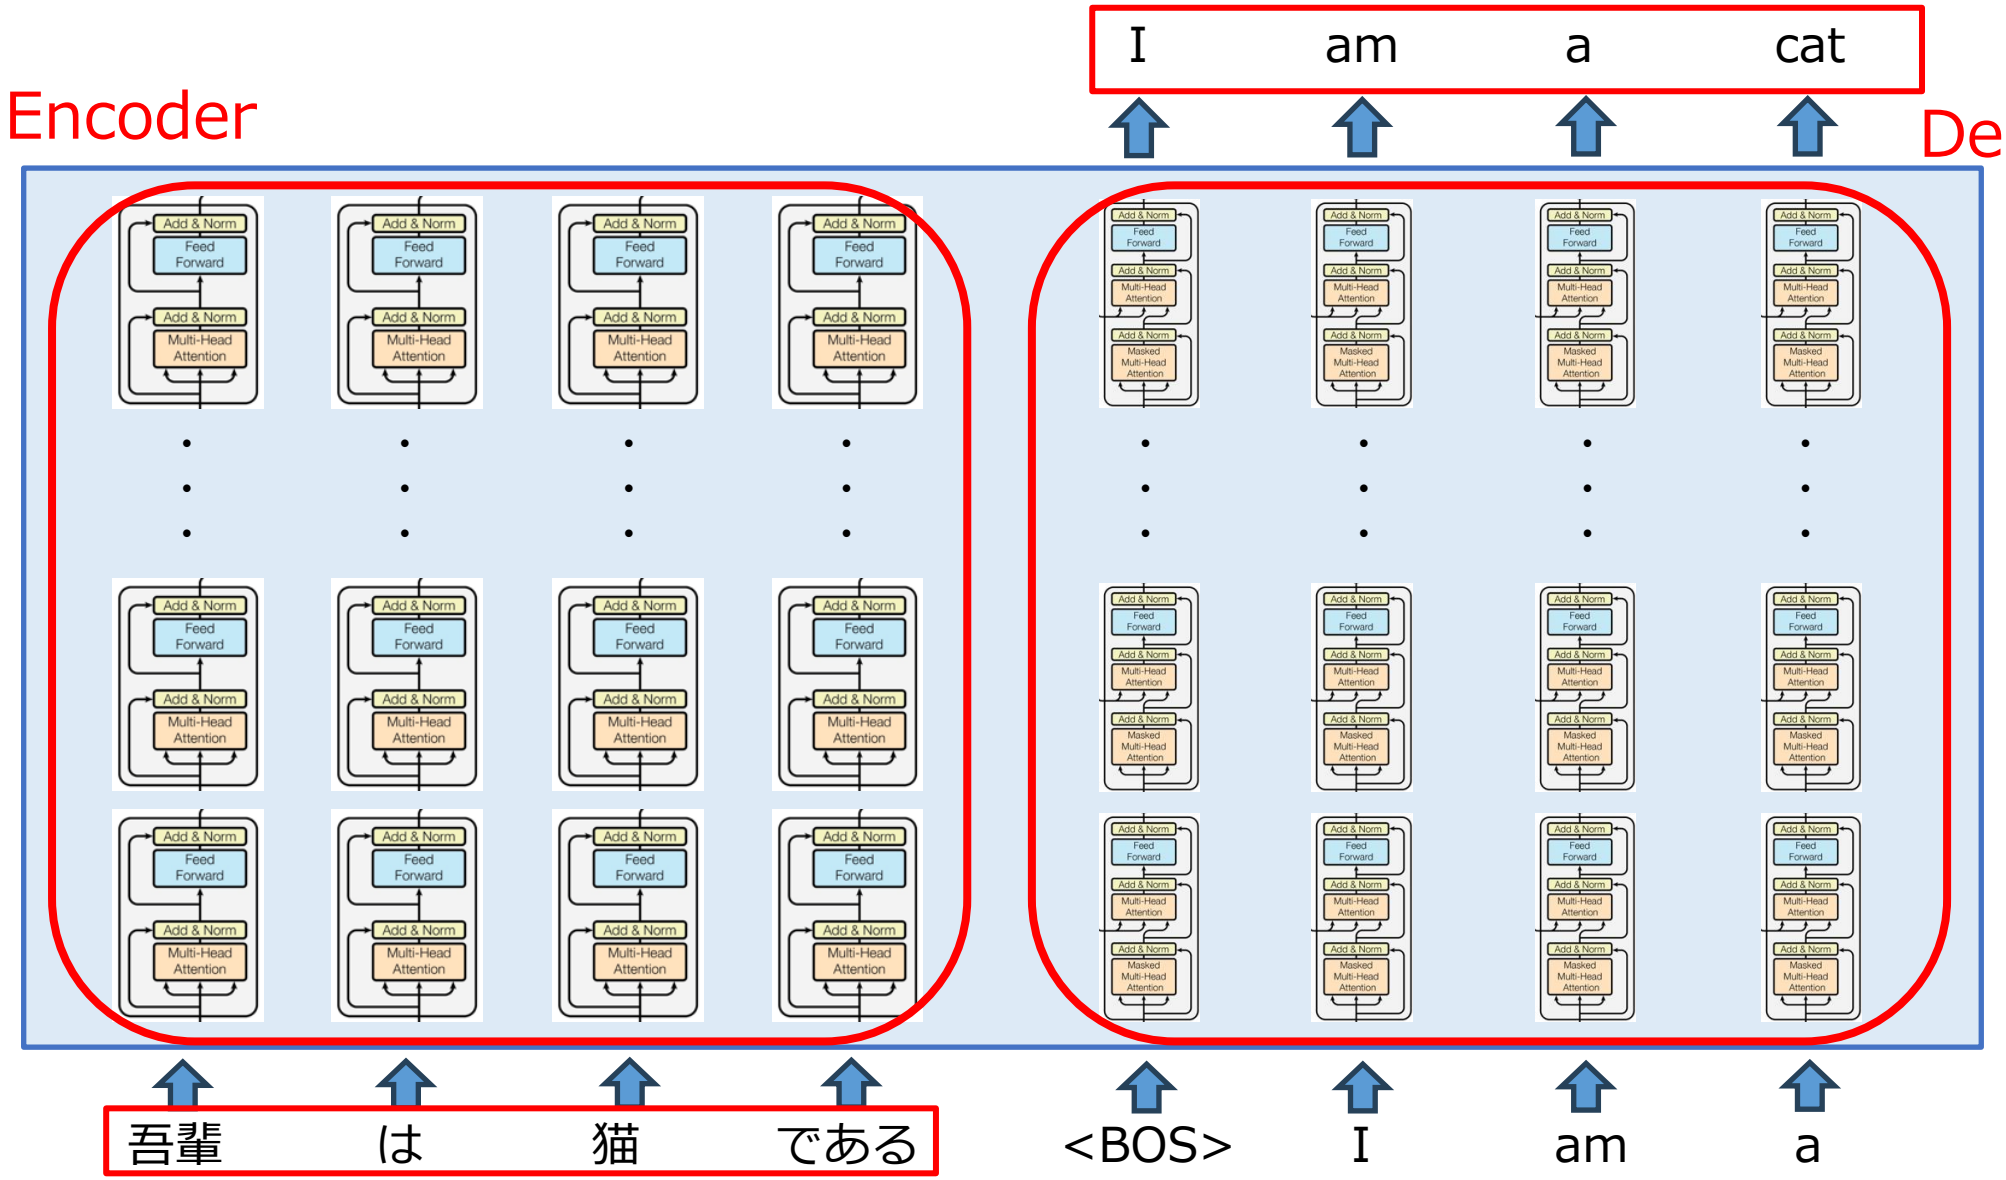
- ”ブロック”：Transformerを構成する最小単位
- 左側のEncoderブロックを縦にN層、
  右側のDecoderブロックも縦にN層並べて構成

[6] Ashish Vaswani et al. (2017), “Attention Is All You Need”, NeurIPS2017 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのモデル構造 | イメージ



Encoder/Decoderブロックがそれぞれ縦に積み重なる

トークンの数だけブロックが横に増えていく

Attention機構によって横のブロック同士はつながる(情報伝達を行う)

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

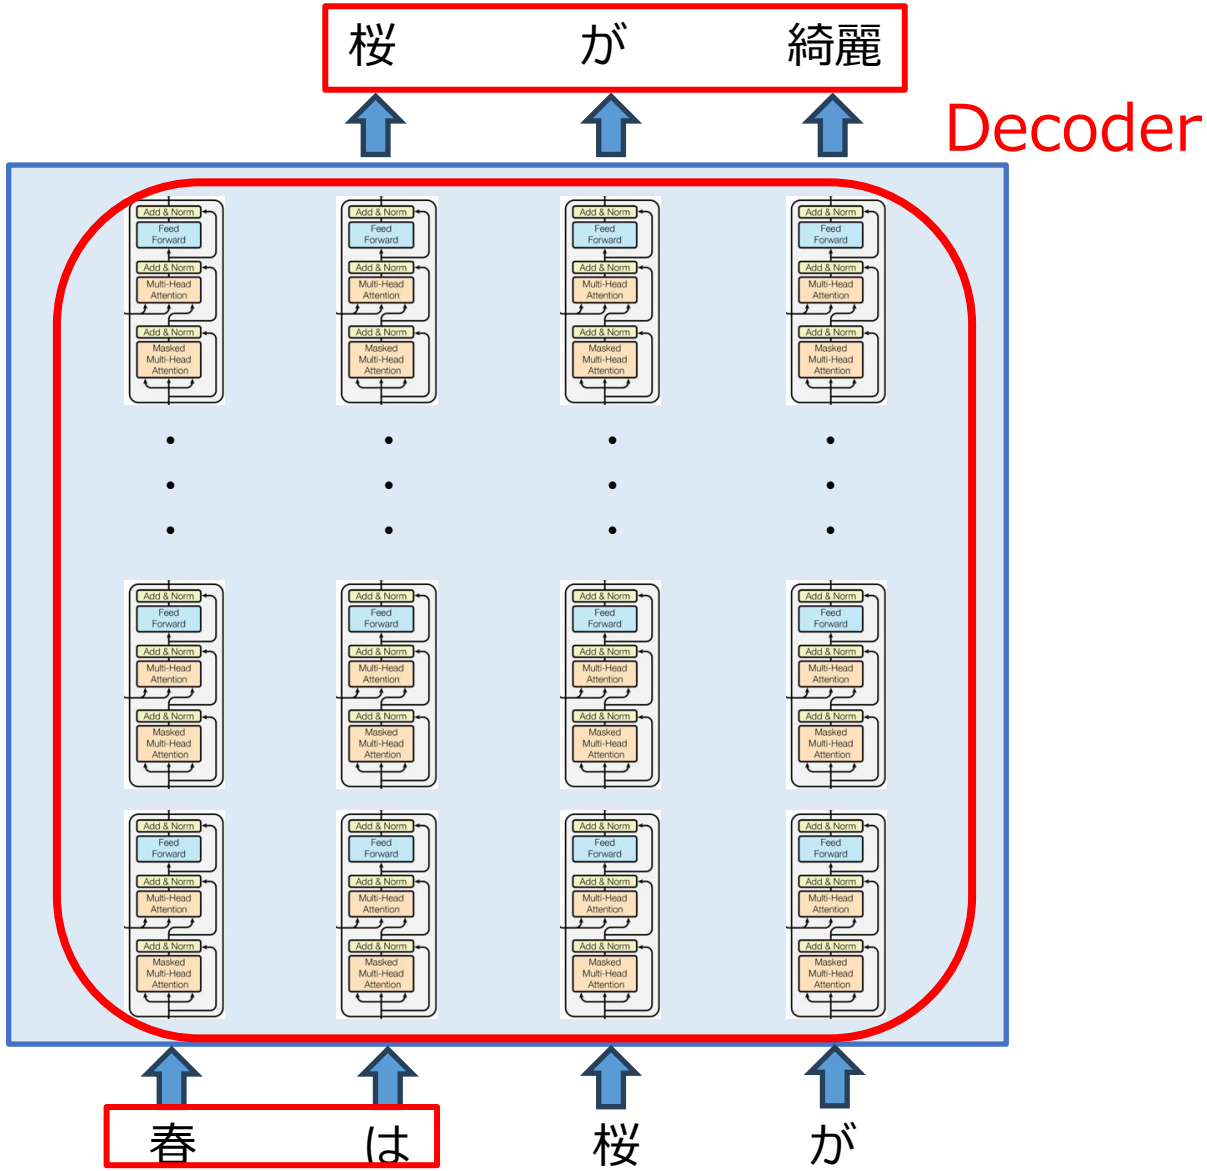
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのモデル構造 | イメージ（GPTシリーズ）

＊実はEncoderがなくても
Decoderだけでテキスト生成可能
（出力と再帰入力があるから）

＊GPTシリーズはこの形式

＊Transformerが当初提案された
領域が機械翻訳だったため、
先行研究のEncoder-Decoder形式に
倣う形でモデル構造が提案された

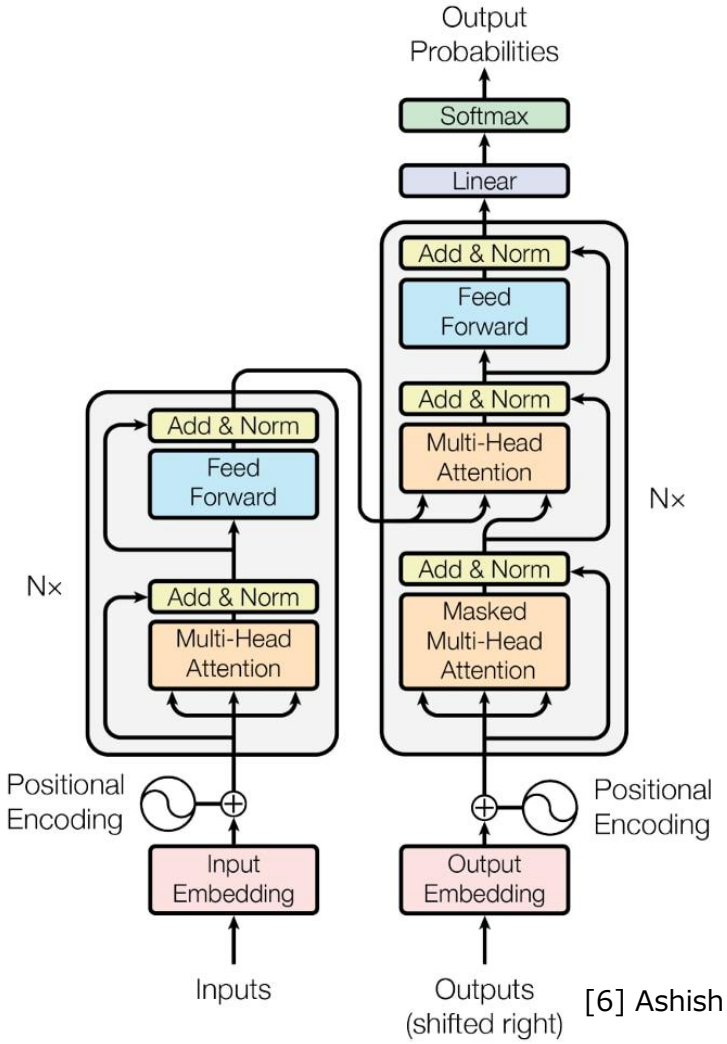


LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ

各パーツごとに解説



- Embedding
- Multi-Head Attention
- Feed Forward
- Others

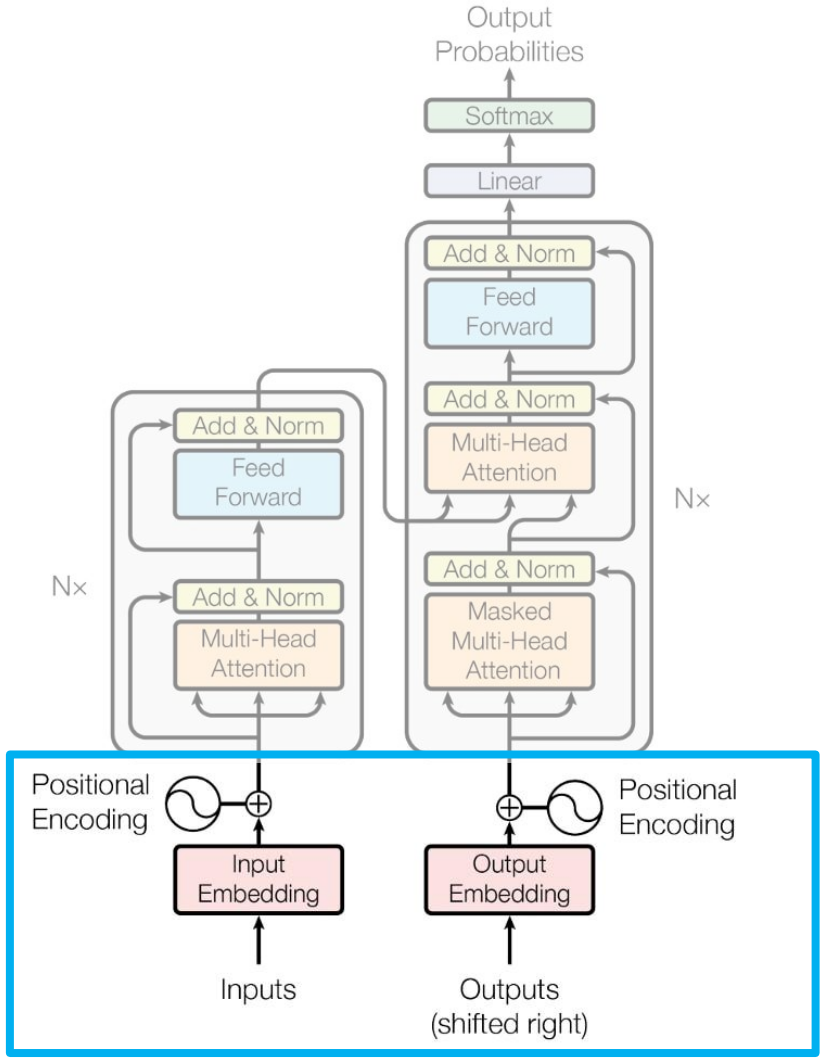
[6] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

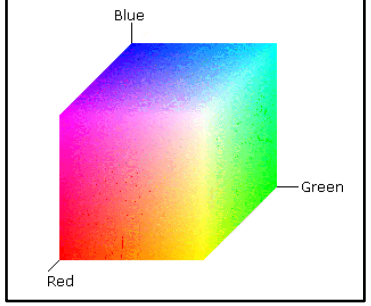
Transformerのパーツ | Embedding

各パーツごとに解説



- **Embedding：単語のベクトル変換**
- Multi-Head Attention
- Feed Forward
- Others

色をRGBの3次元ベクトルに変換するのと似ている



[6] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Embedding テキストをどうやってBlockに取り込むか？

Word Embedding
単語の分散表現,
単語埋め込み

[0.2,-0.5,…,…0.4]　[-0.3,1.0,…,…0.8]　[1.7,-0.9,…,…-0.6]

MLPによるより低次元への変換（学習対象）

👇**1050番目**　👇**80番目**　👇**24567番目**

One-hotベクトル

[0,0,…,0,1,0,…0]　[0,0,…,0,1,0,…0]　[0,0,…,0,1,0,…0]

**{トークンID}番目だけ1で、
他はすべて0であるベクトルの構成**

トークンID

1050, 80, 24567

**各トークンに一対一で割り当てられている
トークンIDへの変換**

トークン

“春”, “は”, “曙”

トークナイザー（*後述）による分割

テキスト

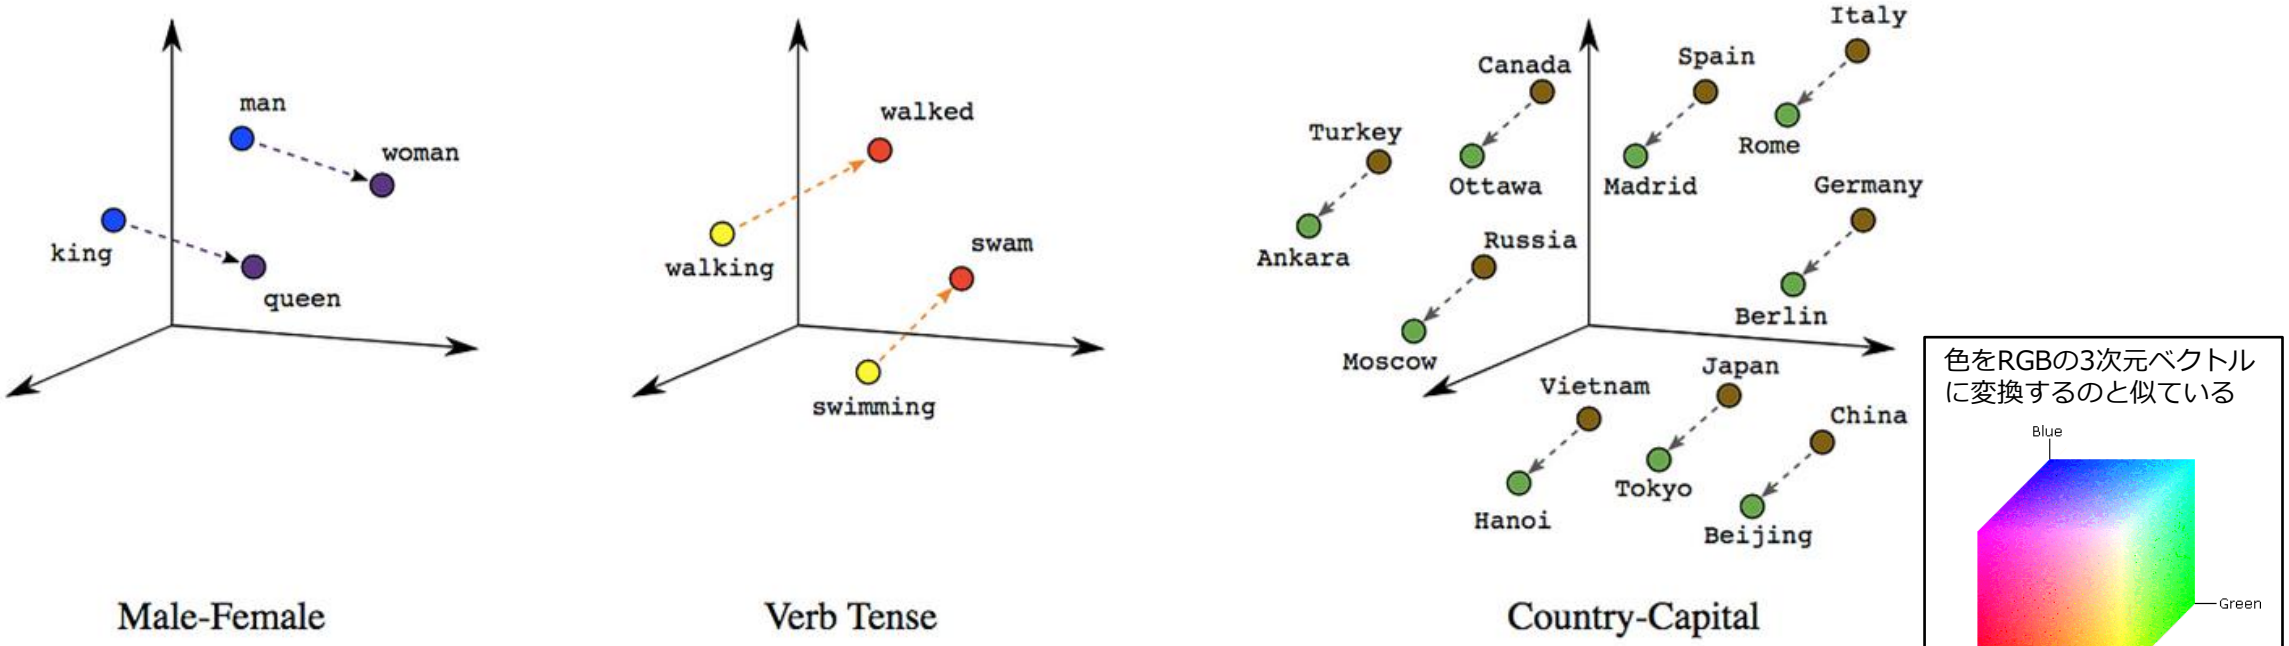
“春は曙”

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Embedding Word Embedding (WE)

- 単語(Sparseな情報)をDenseな表現に変換
  - Transformerなどのモデルの入力値として扱える
- 学習完了後のWord Embeddingには、単語間の意味の近さや関係性が埋め込まれている（下図はイメージ）



Male-Female　　Verb Tense　　Country-Capital

[15] Shraddha Anala (2020), ”A Guide to Word Embedding. What are they? How are they more useful… | by Shraddha Anala | Towards Data Science”より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

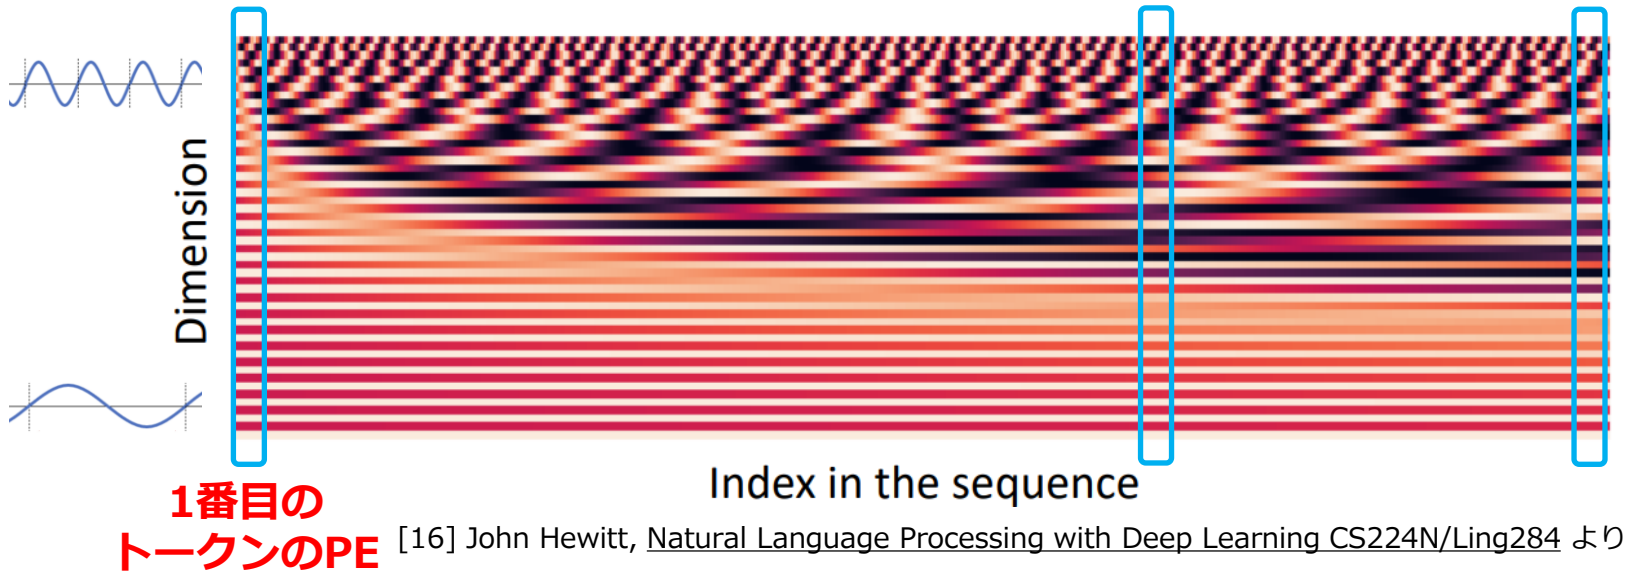
Transformerのパーツ | Embedding Positional Encoding (PE)

- Transformerブロックに取り込む前に、Word Embeddingに位置情報を追加
  - Transformerブロックのアルゴリズムはトークンの位置情報に依存しない
    - このままだと単語の位置関係が考慮されないので事前にベクトルに埋め込む.
  - 実装例：トークンの位置によって異なるPEを各WEに加える
    - WE(“春”) + PE(“これは1番目のトークンです”)
    - WE(“は”) + PE(“これは2番目のトークンです”)
    - WE(“曙”) + PE(“これは3番目のトークンです”)

$$\boldsymbol{p}_i = \begin{pmatrix} \sin(i/10000^{2*1/d}) \\ \cos(i/10000^{2*1/d}) \\ \vdots \\ \sin(i/10000^{2*\frac{d}{2}/d}) \\ \cos(i/10000^{2*\frac{d}{2}/d}) \end{pmatrix}$$

i番目のトークンのPE

d: ベクトルの次元数

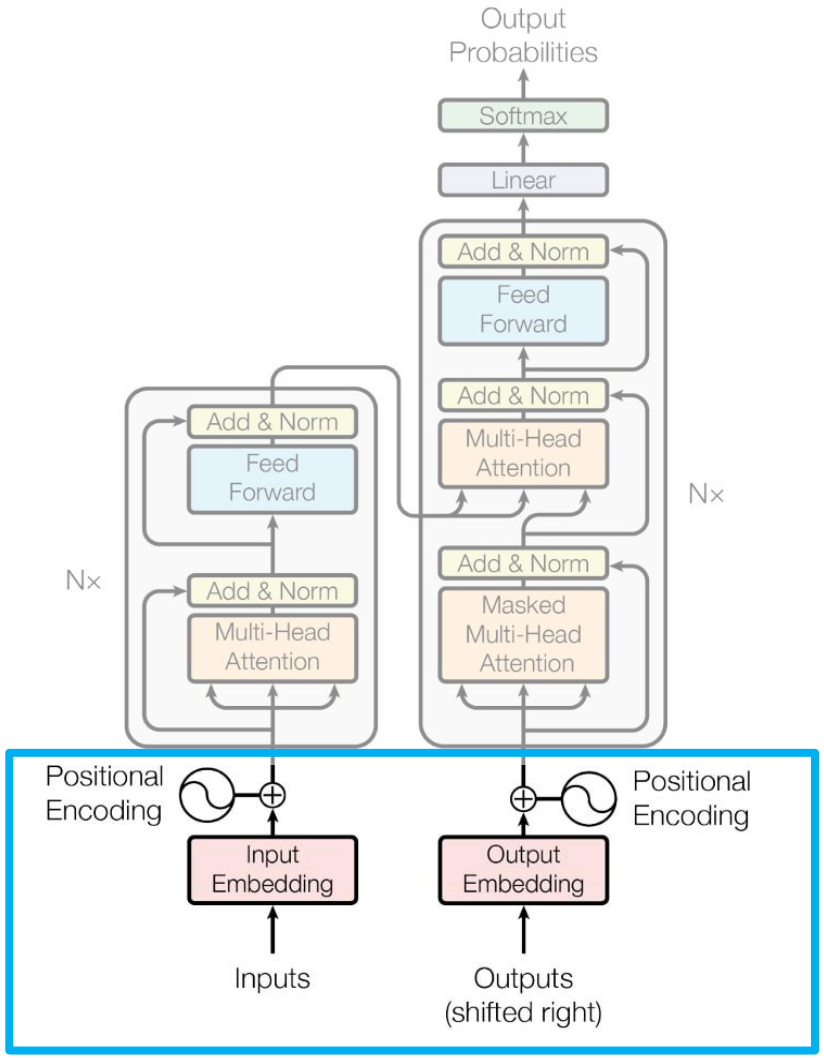


[16] John Hewitt, Natural Language Processing with Deep Learning CS224N/Ling284 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Transformerのパーツ | Embedding

各パーツごとに解説



テキストをトークンに分割
Word Embedding（ベクトル）に変換
Positional Encodingと足し合わせて
Transformerに入力

- **Embedding：単語のベクトル変換**
- Multi-Head Attention
- Feed Forward
- Others

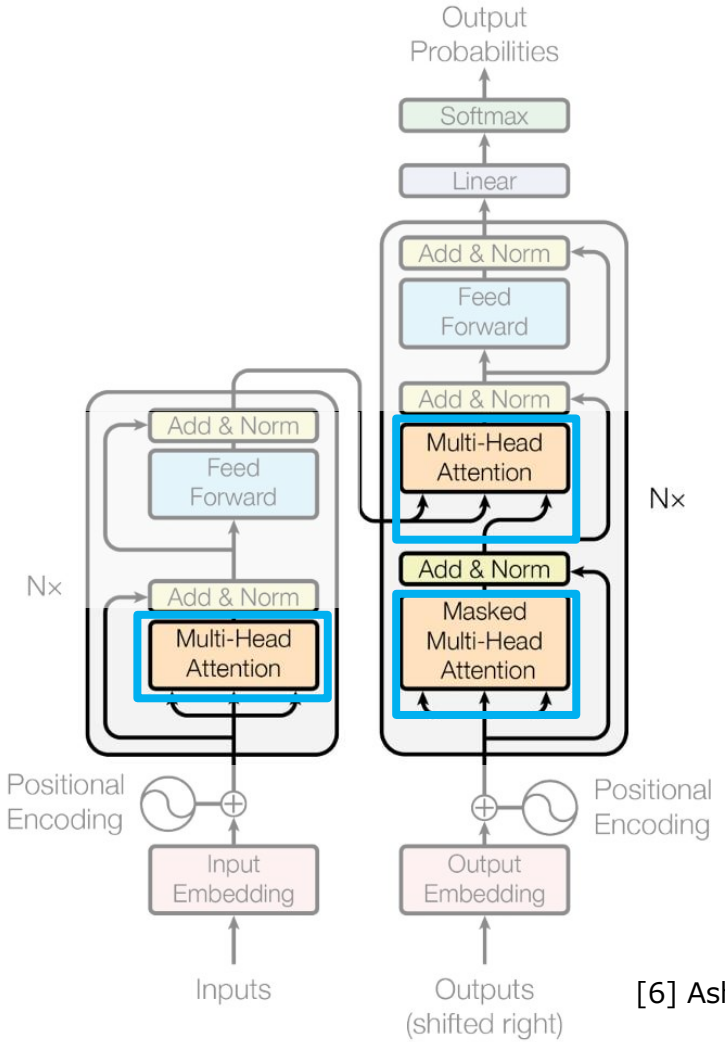
[6] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Multi-Head Attention

各パーツごとに解説



- Embedding
- **Multi-Head Attention**
- Feed Forward
- Others

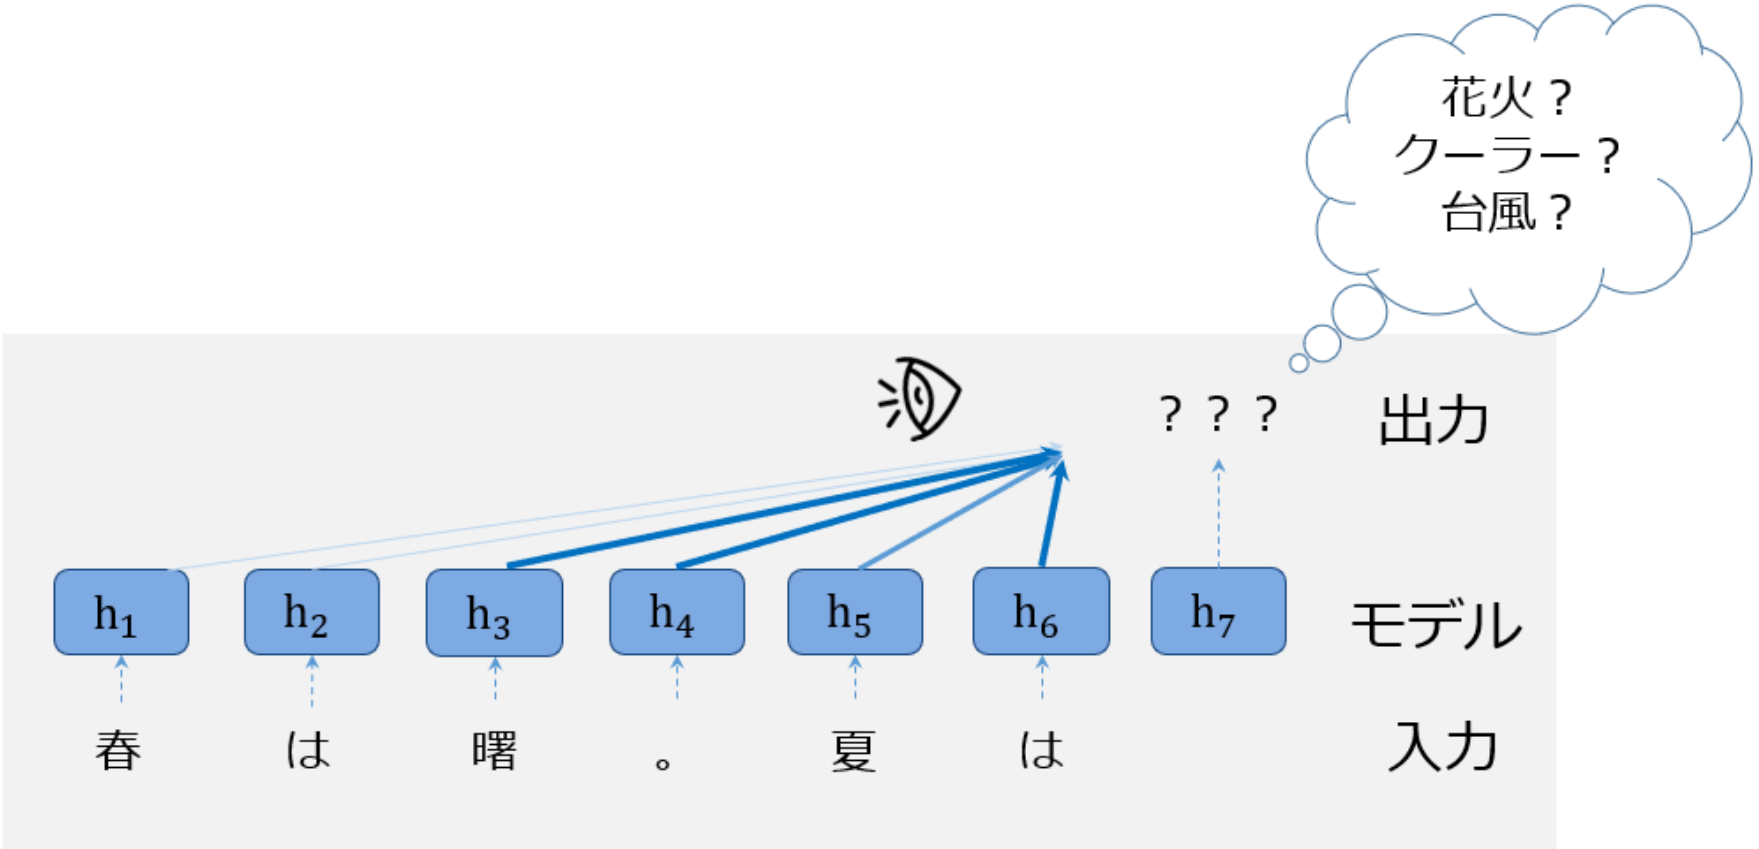
[6] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Attention

全トークン間の類似度を測ることによって、**長距離のトークン間の依存関係**を把握することを可能にした機構



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Transformerのパーツ | Attention

数式による整理

次頁からこの数式を
アニメーションで説明する

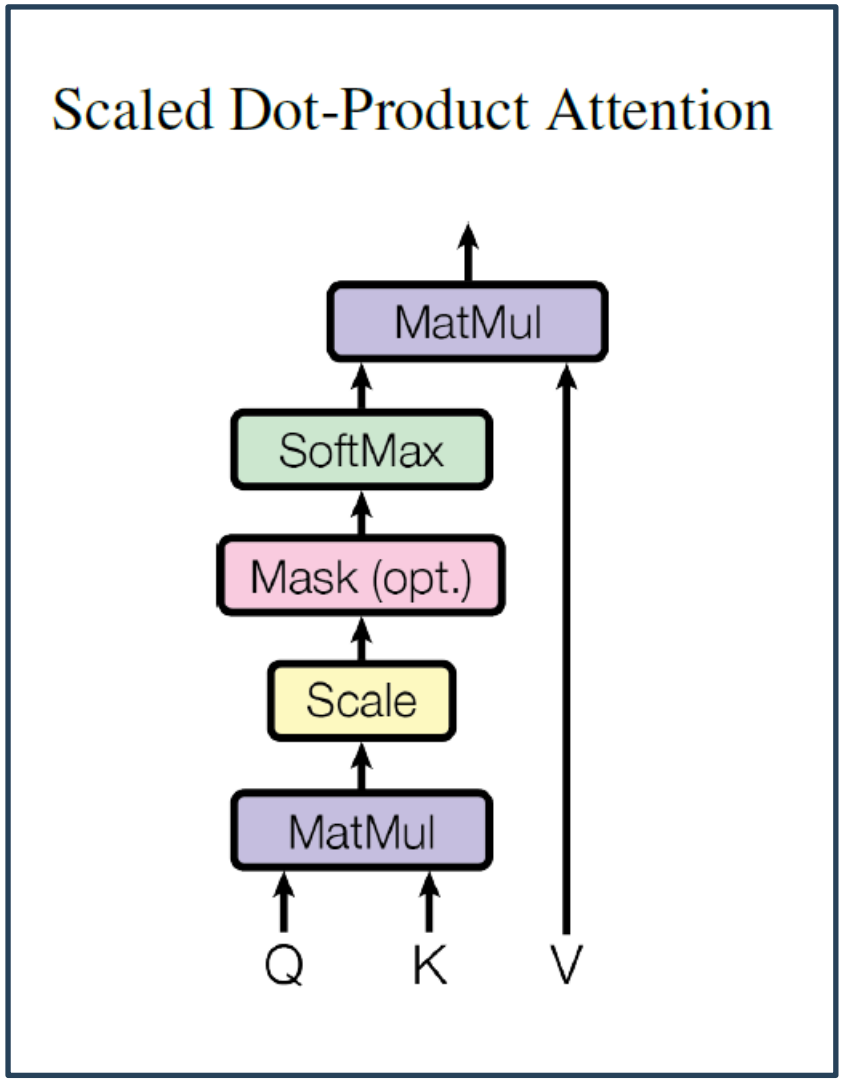
$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}(\frac{QK^T}{\sqrt{d_k}})V$$

Q：Queryベクトル

K：Keyベクトル

V：Valueベクトル

d_k：ベクトルの次元数



[6] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用

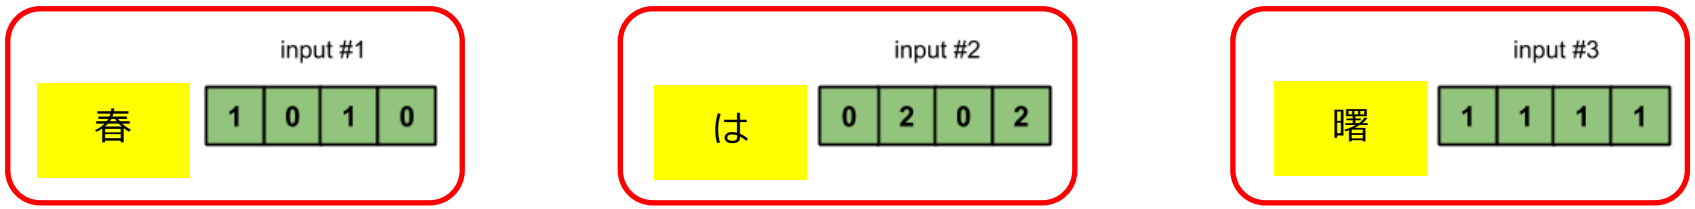
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Attention

Self-attention

アテンション機構の入力値：
トークンのベクトル表現

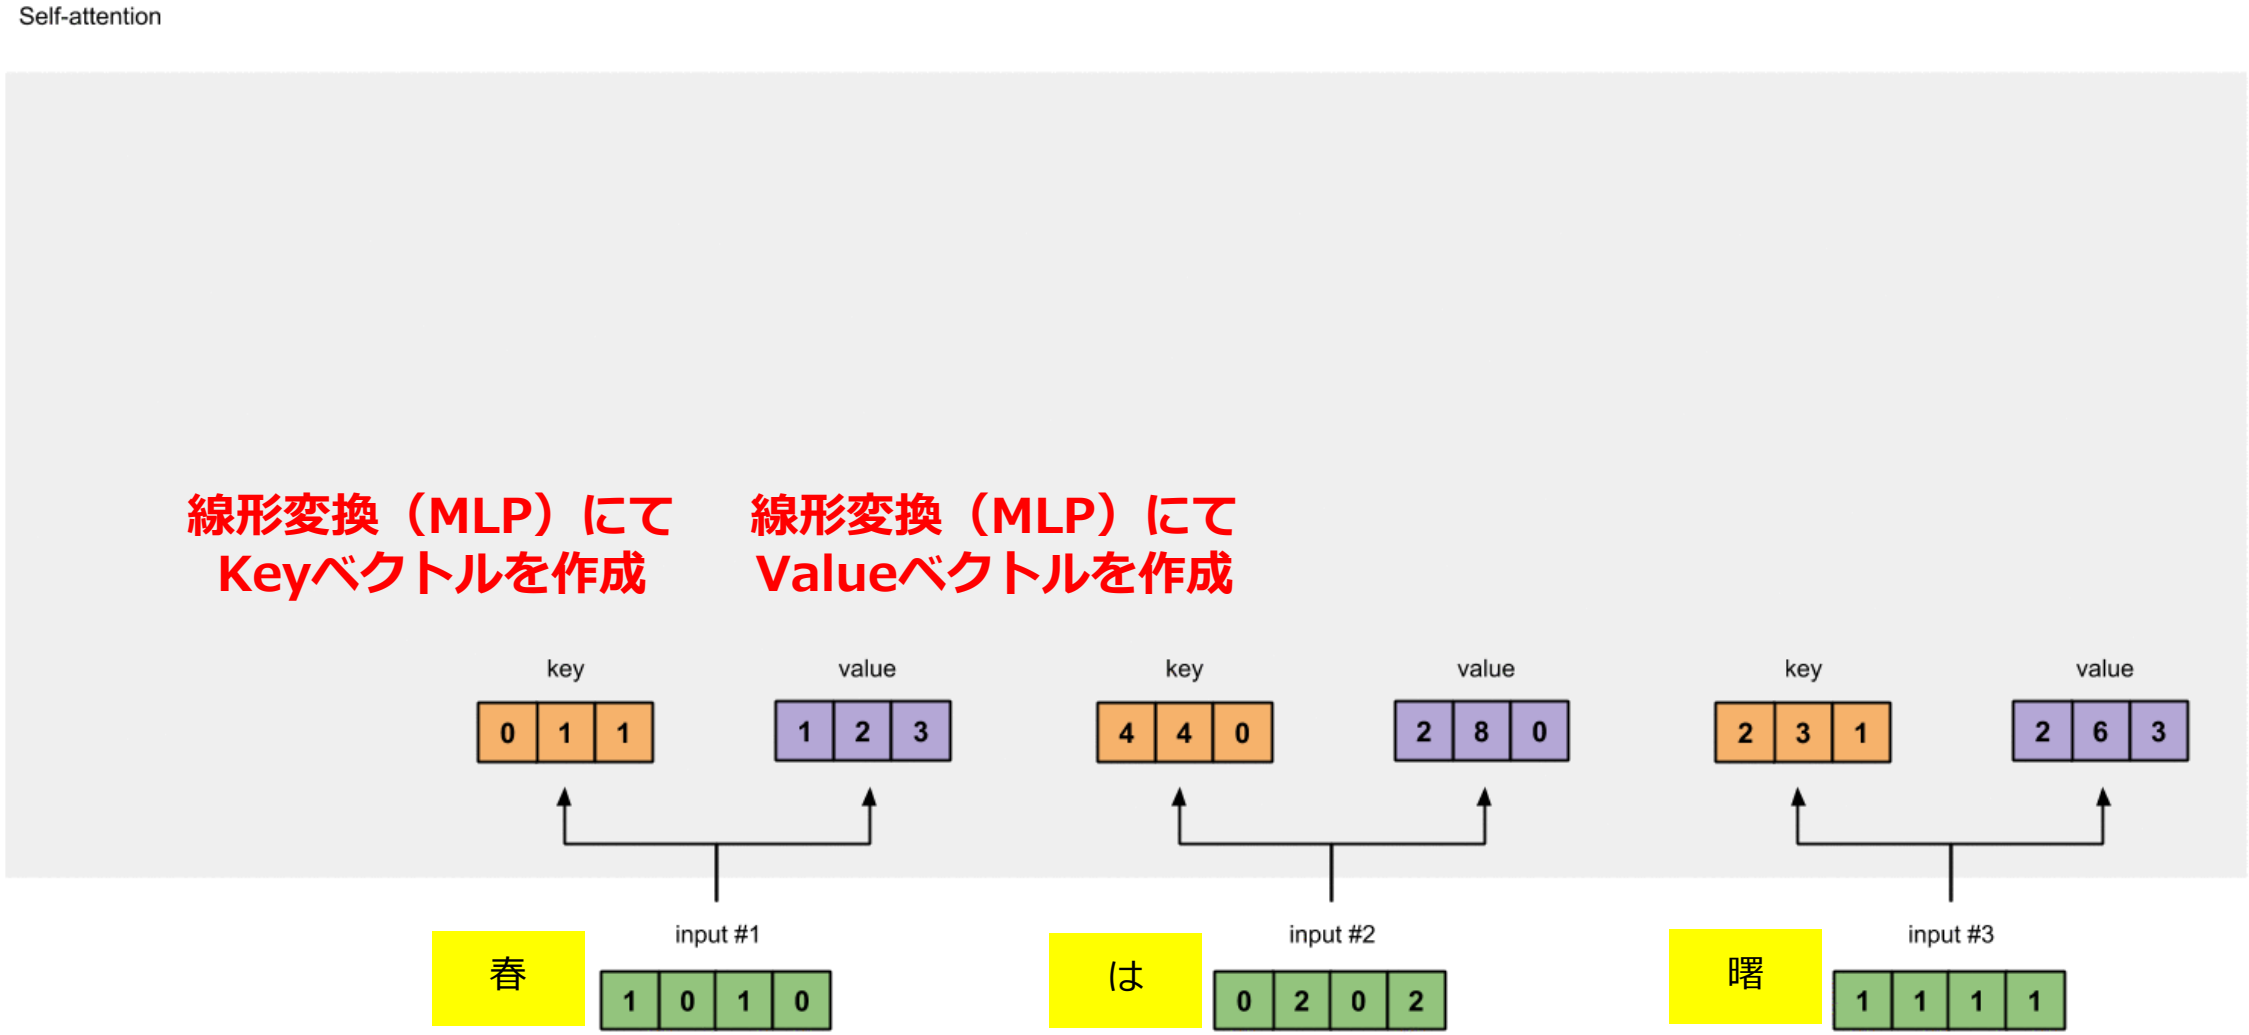


[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Attention

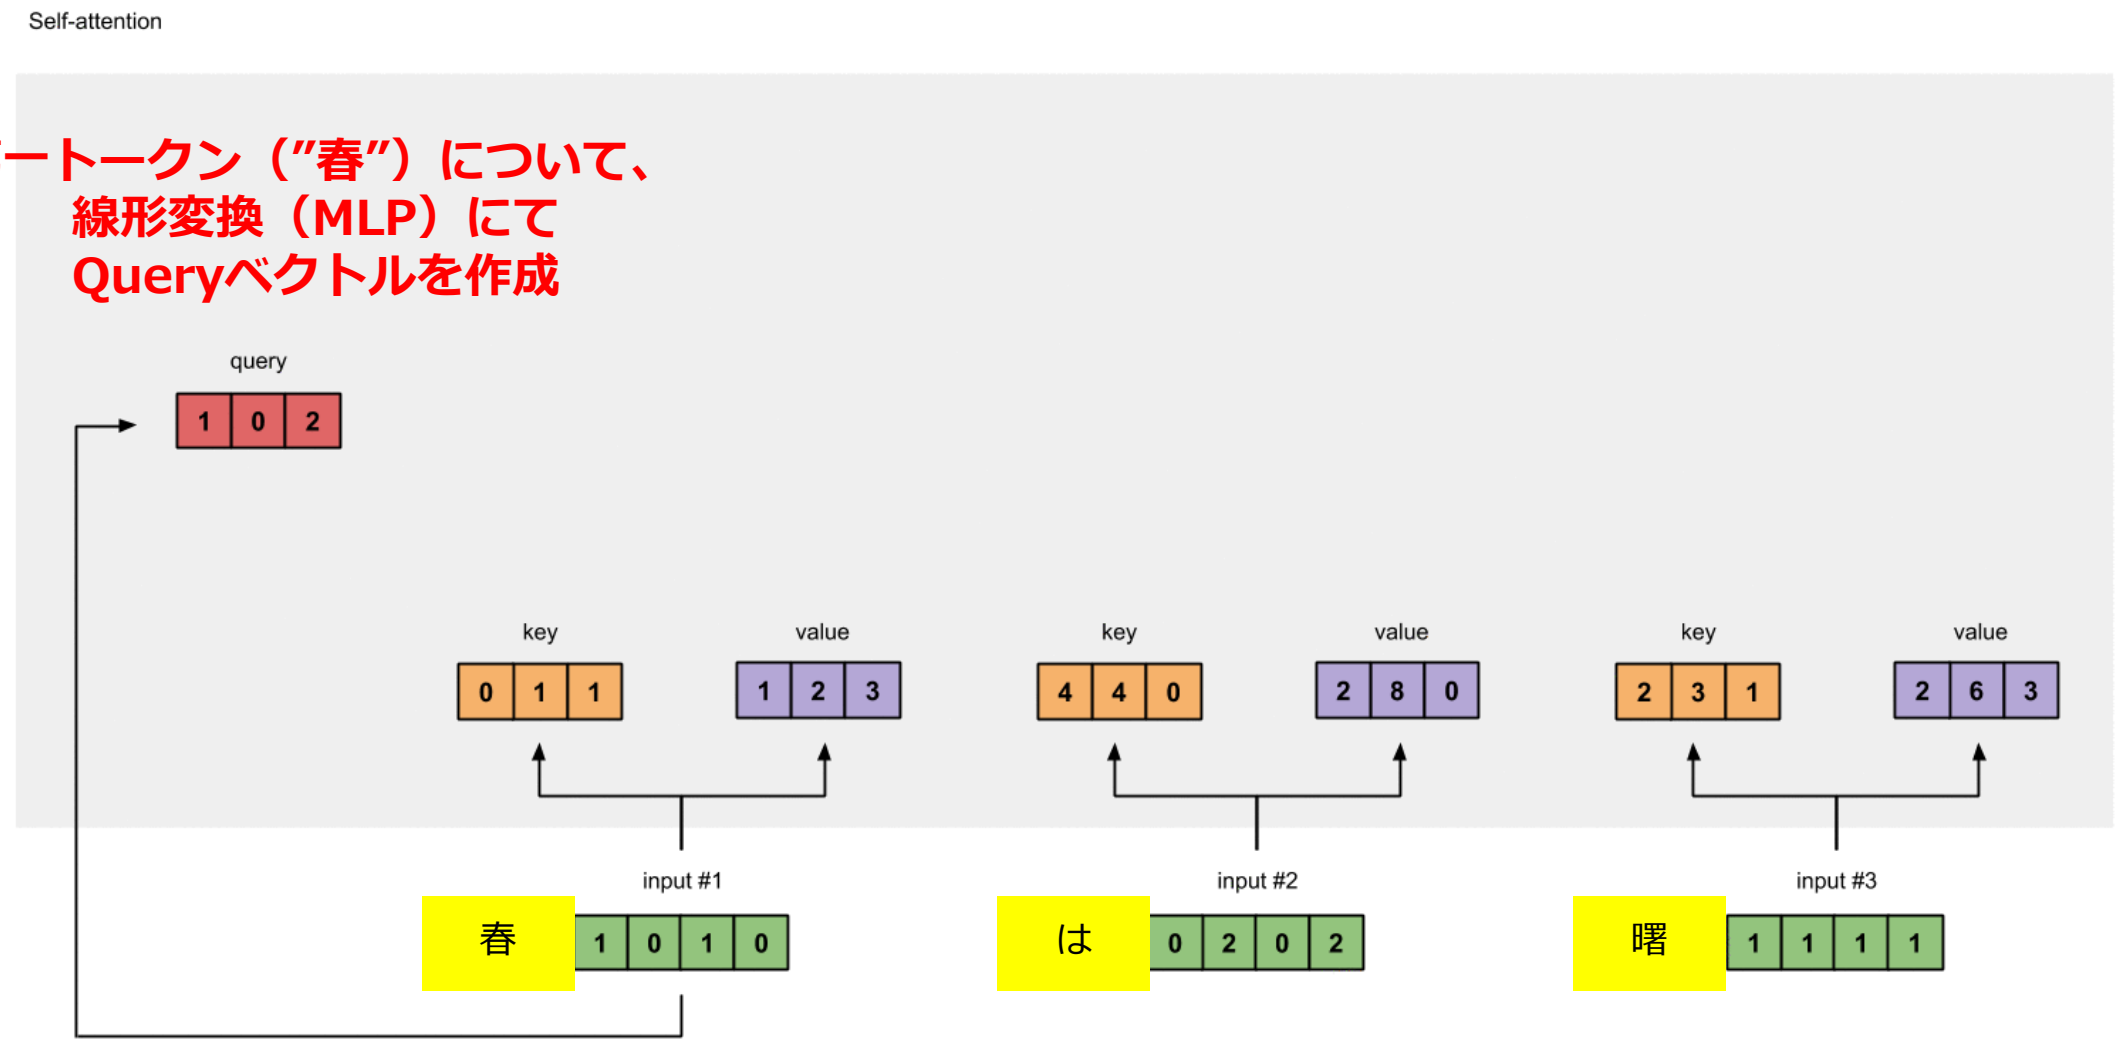


[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Attention

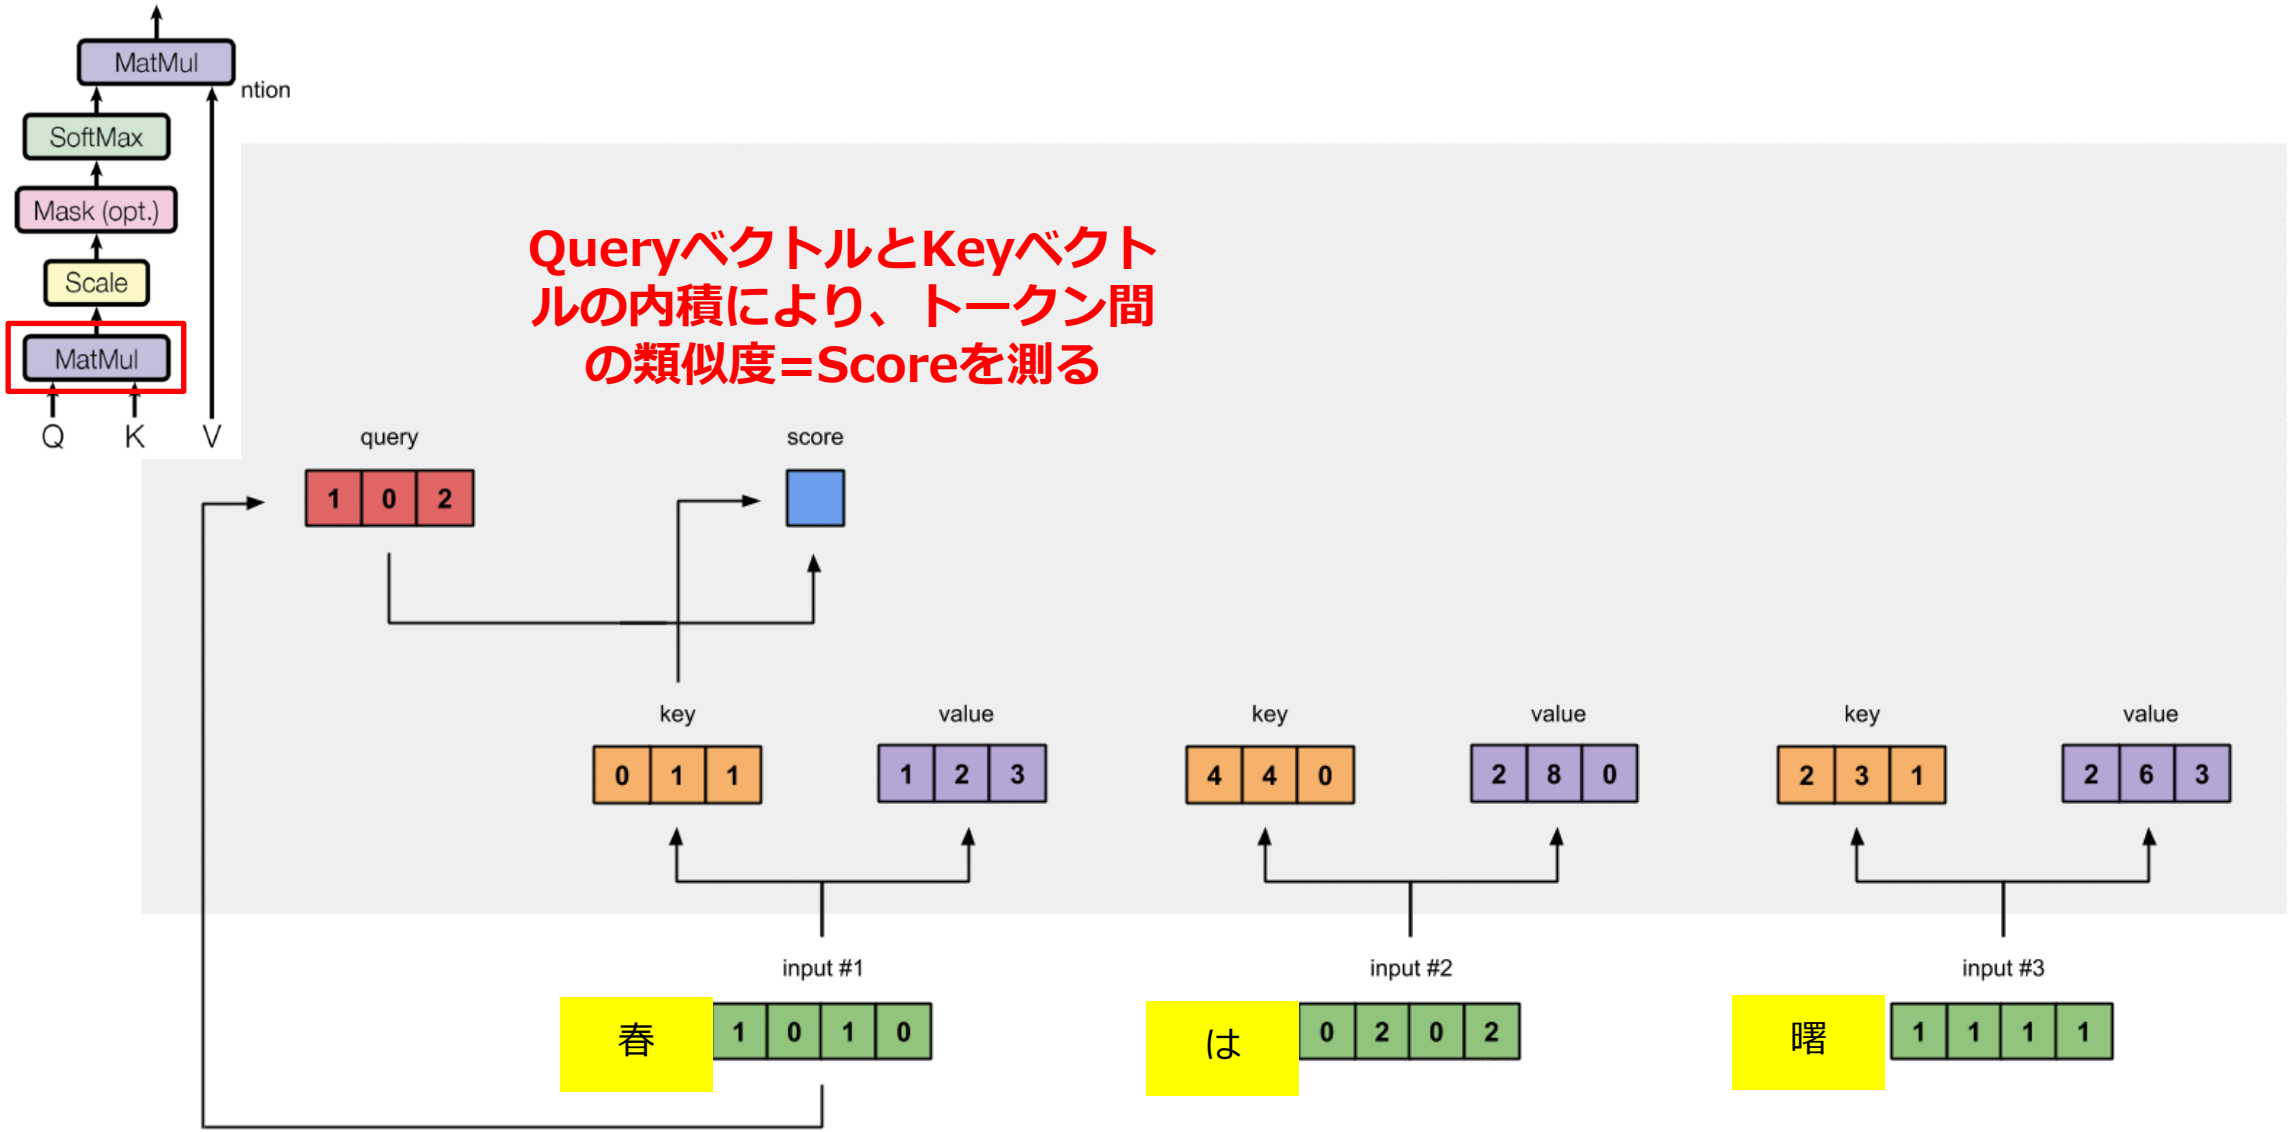


[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

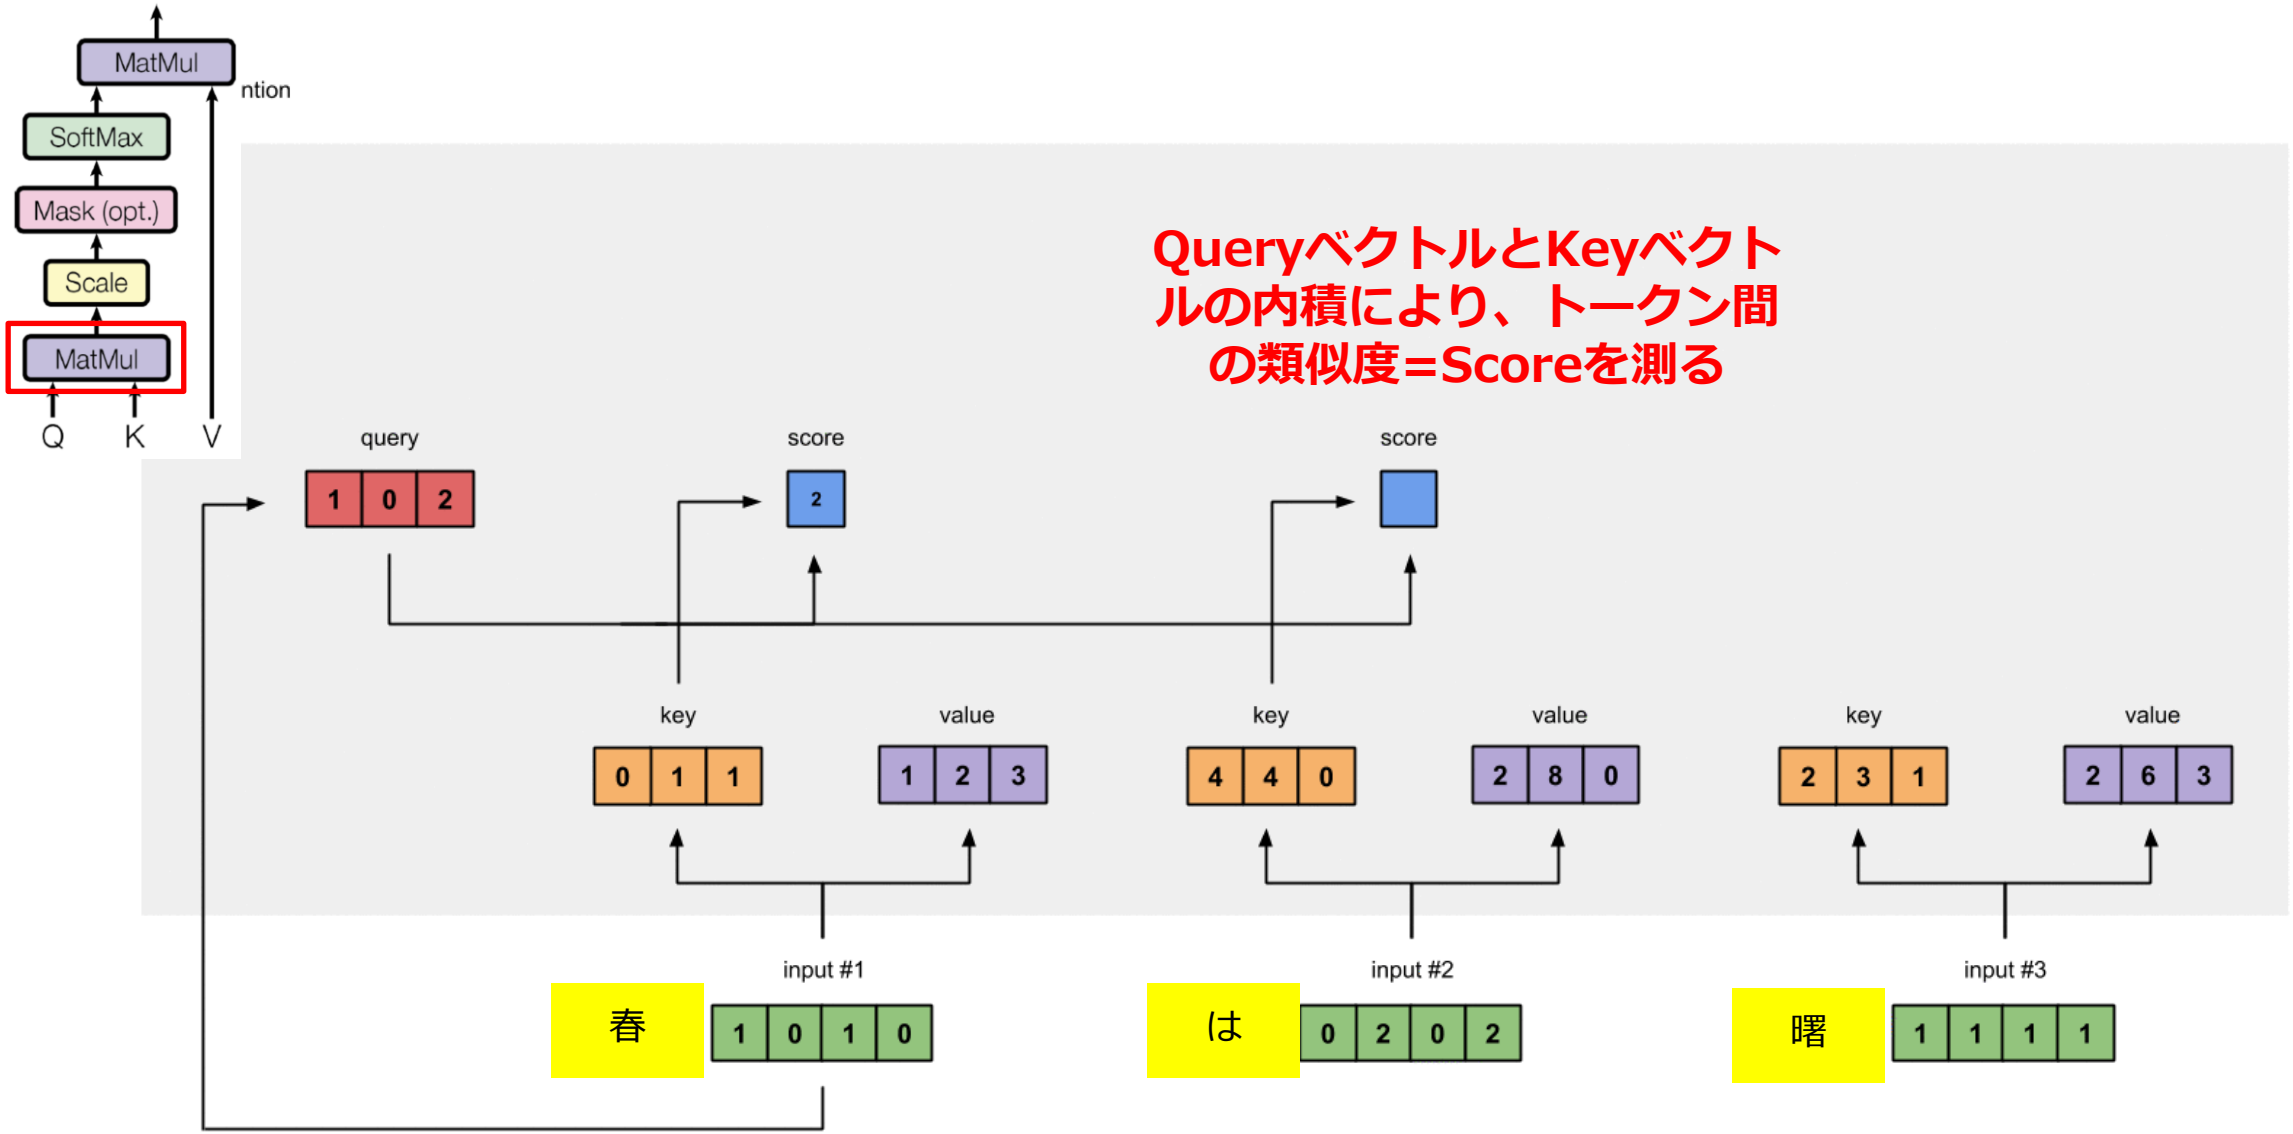
Transformerのパーツ | Attention



[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Transformerのパーツ | Attention

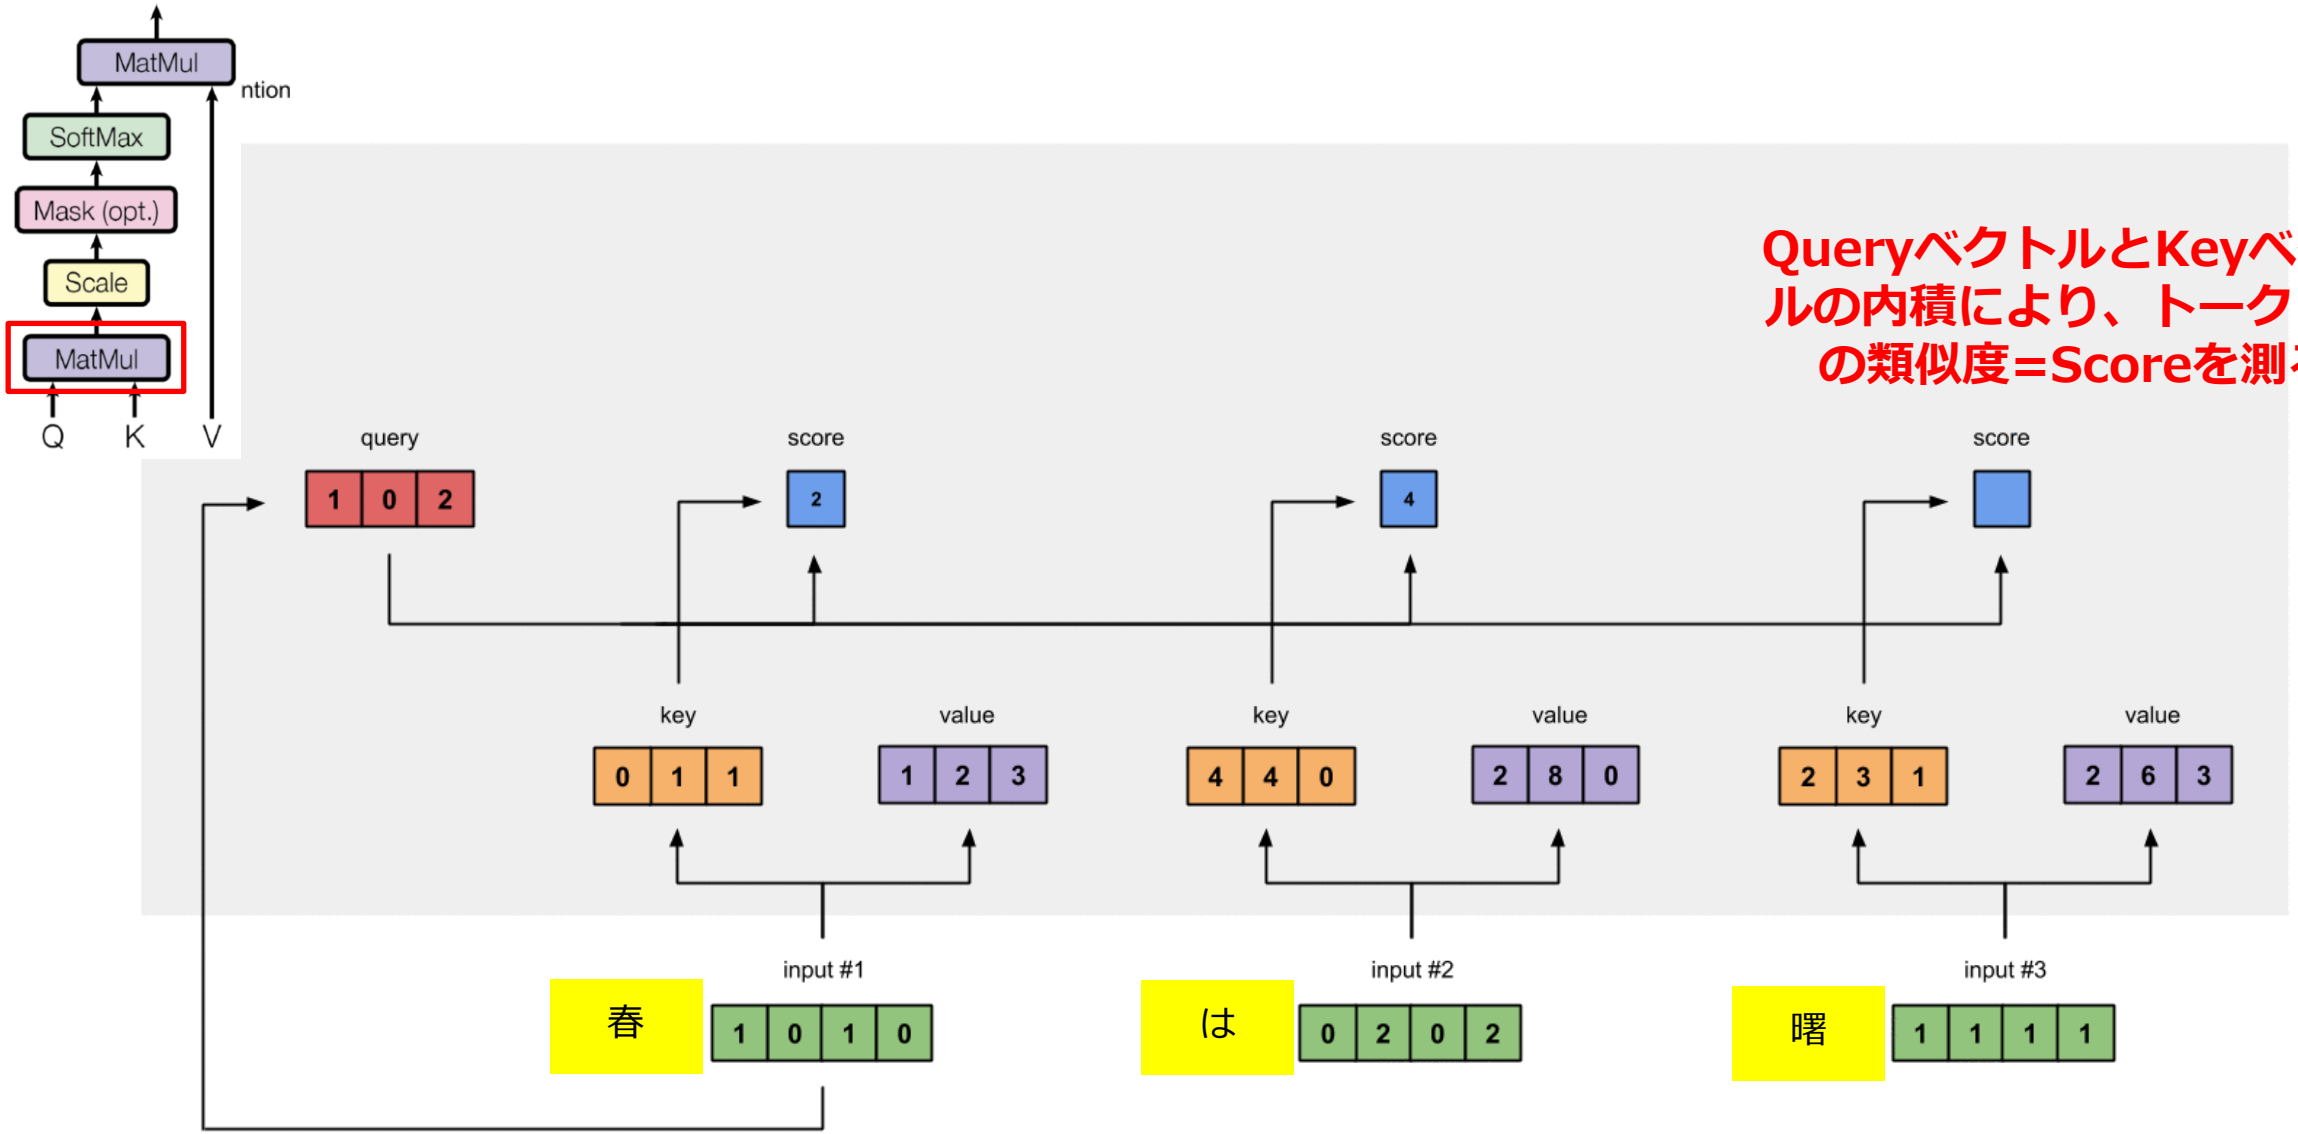


[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Attention



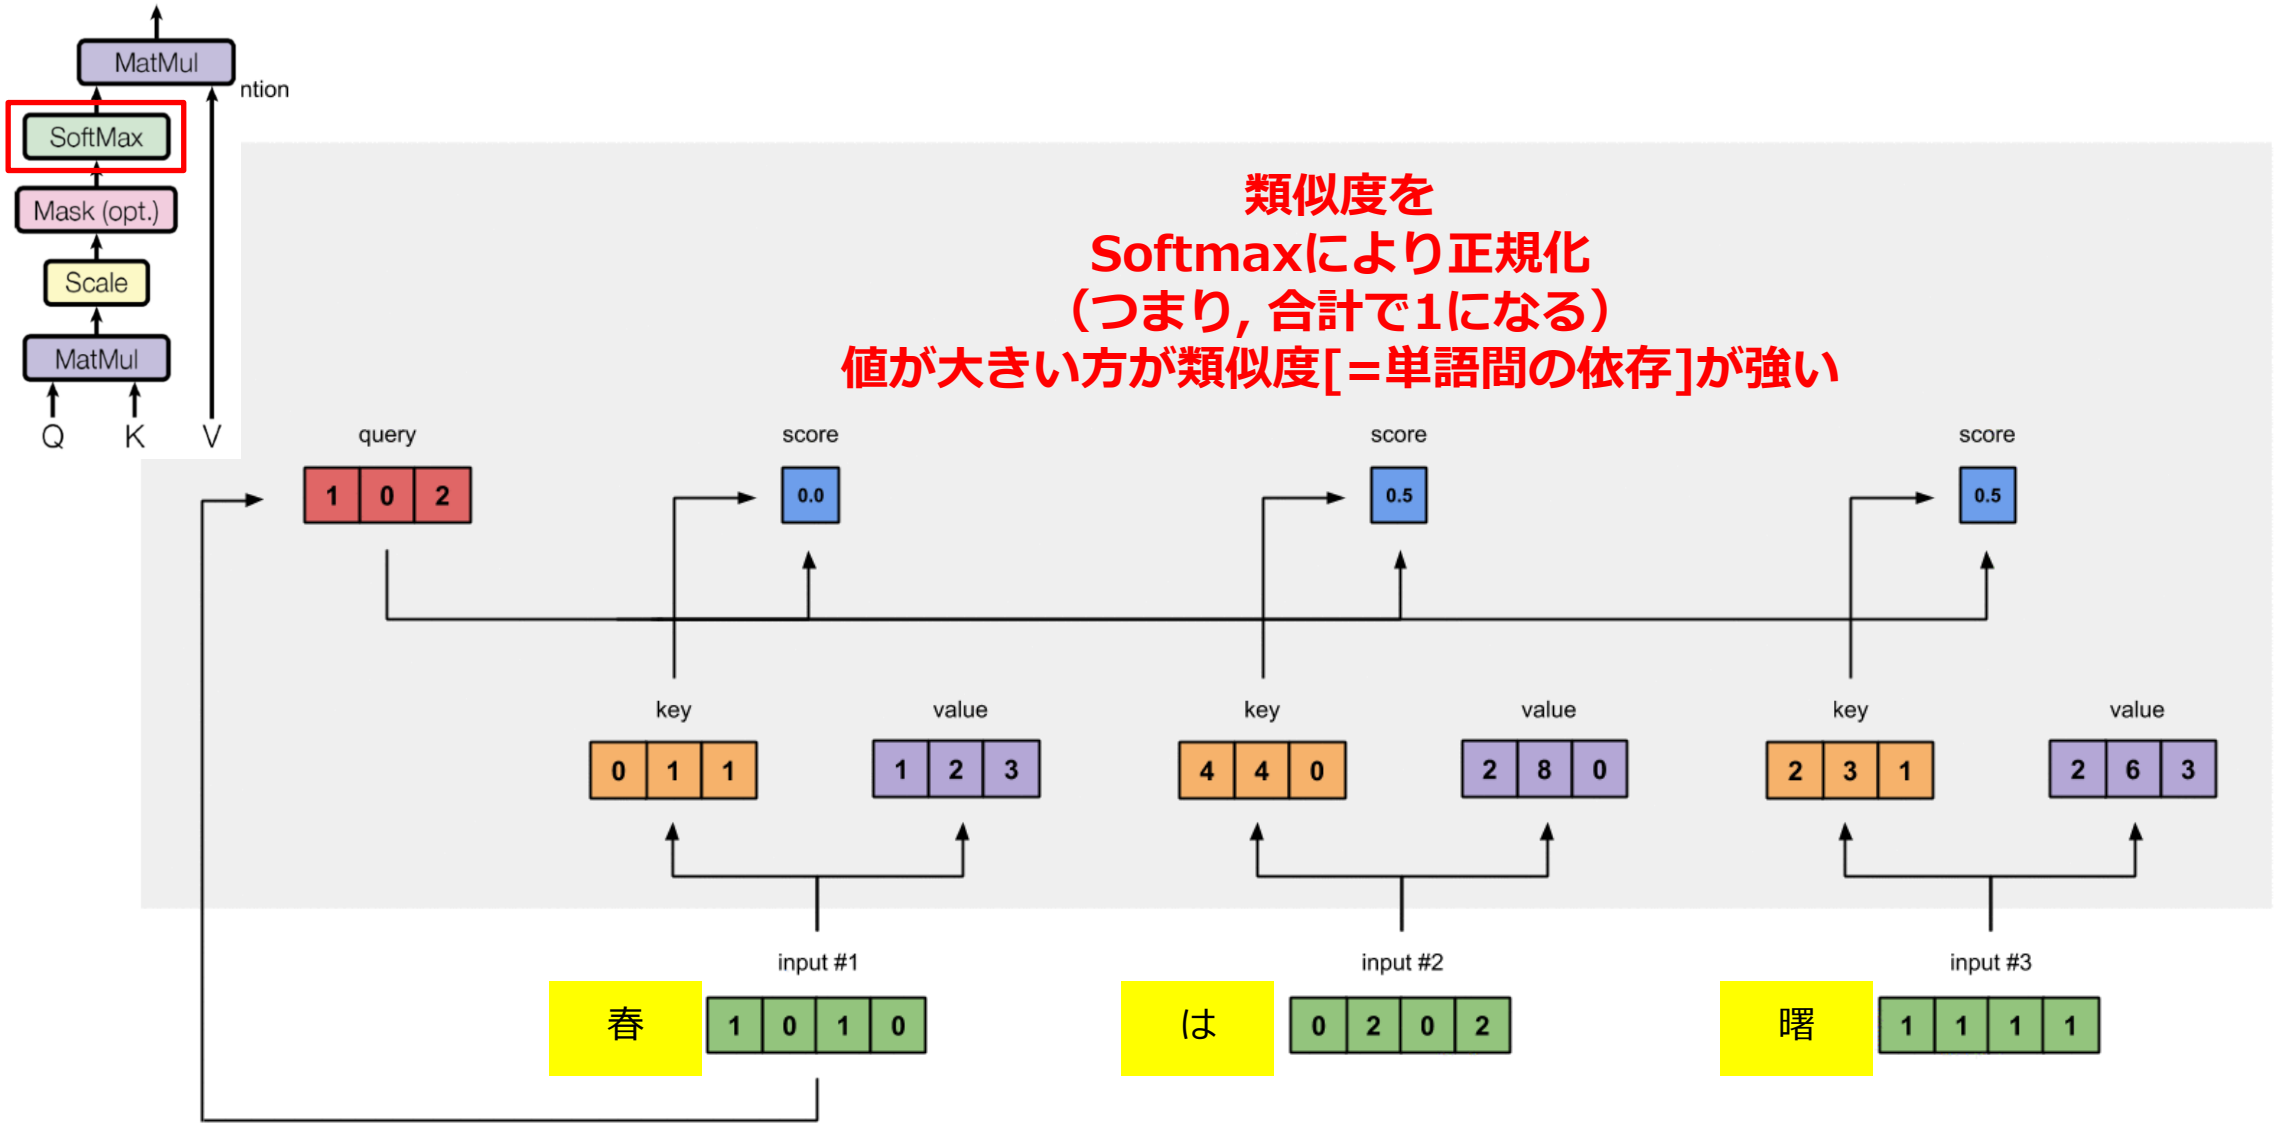
QueryベクトルとKeyベクトルの内積により、トークン間の類似度=Scoreを測る

[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Attention

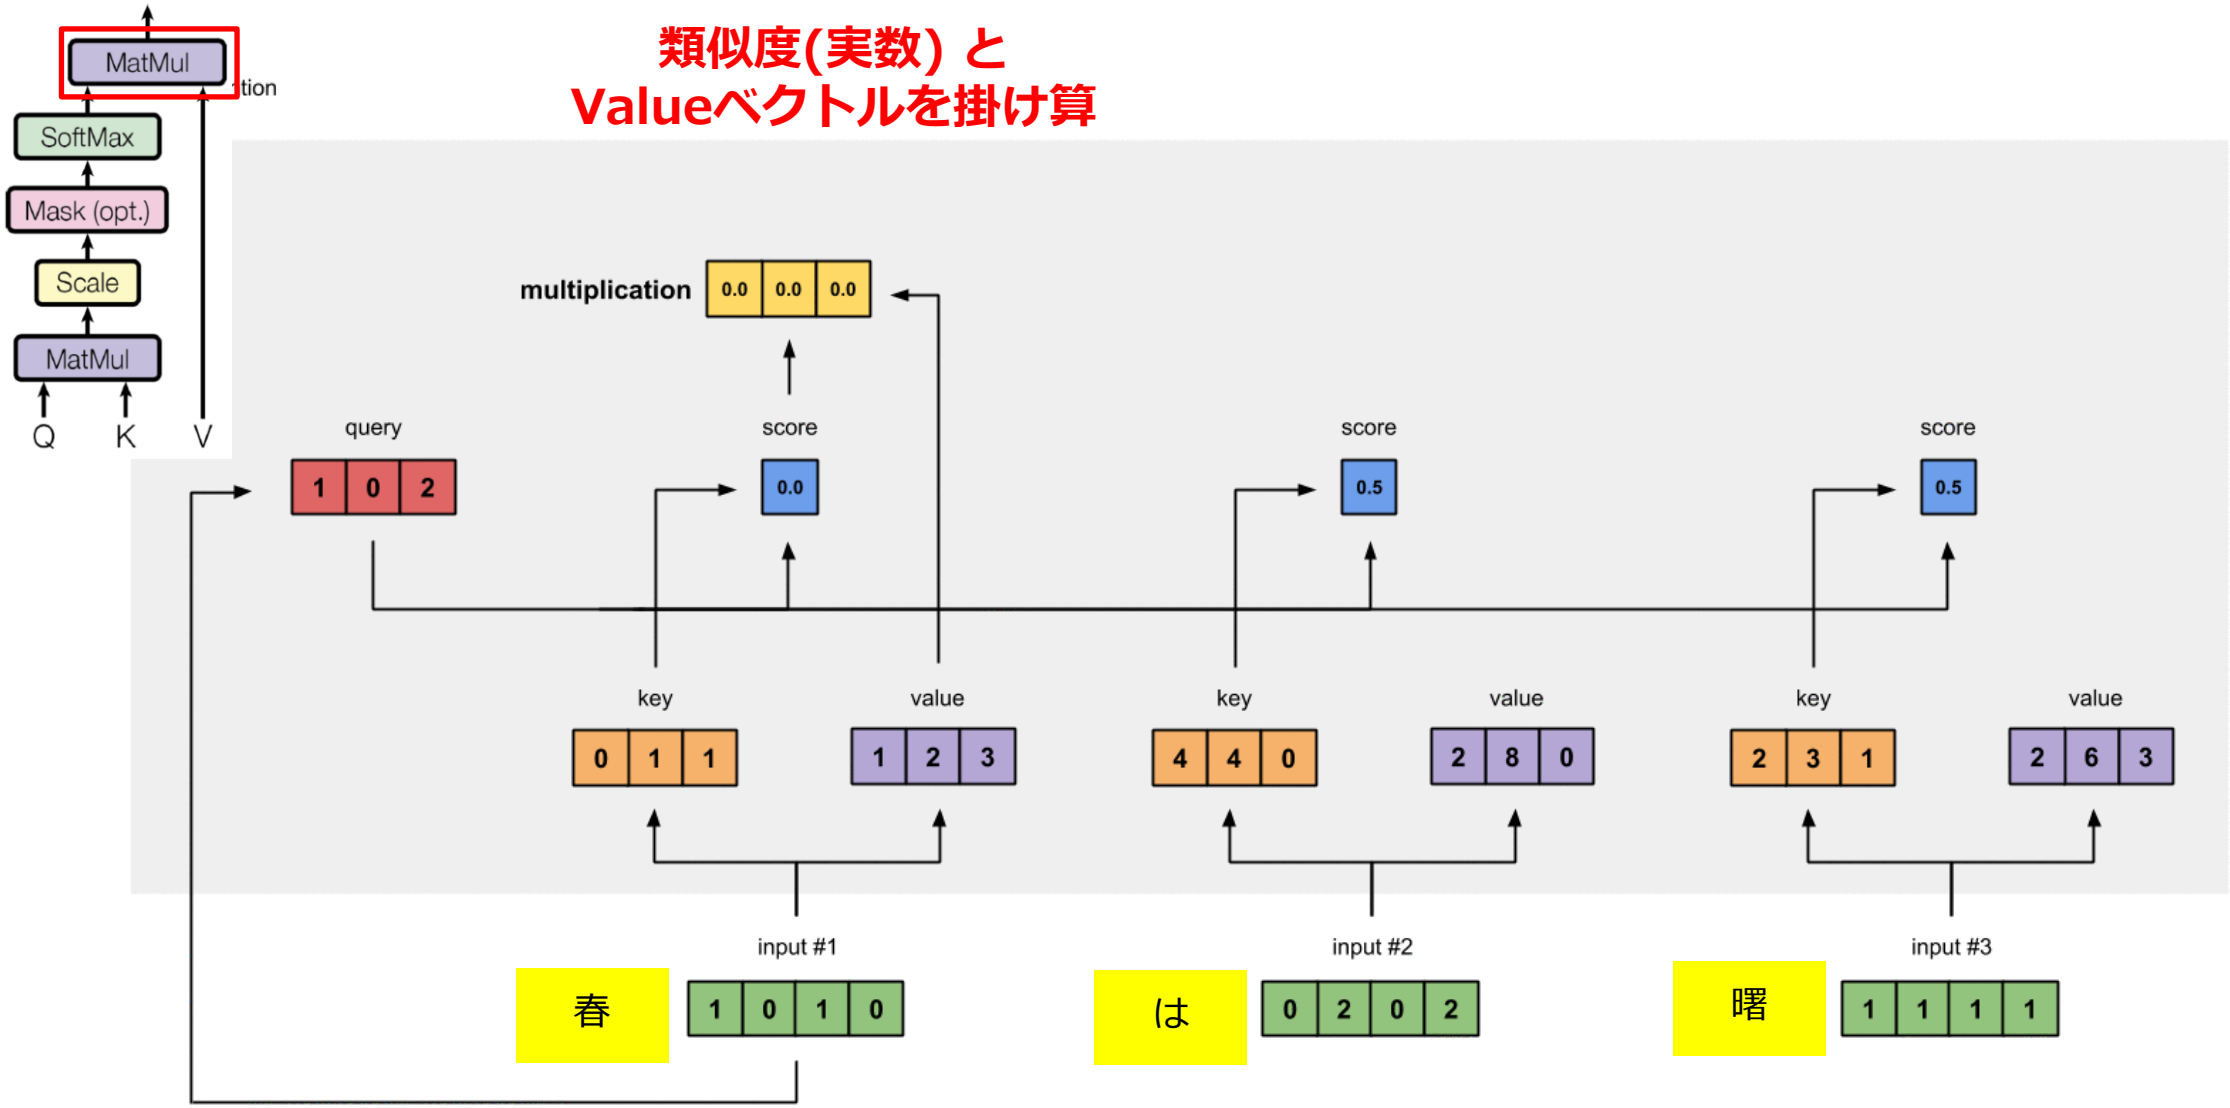


[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

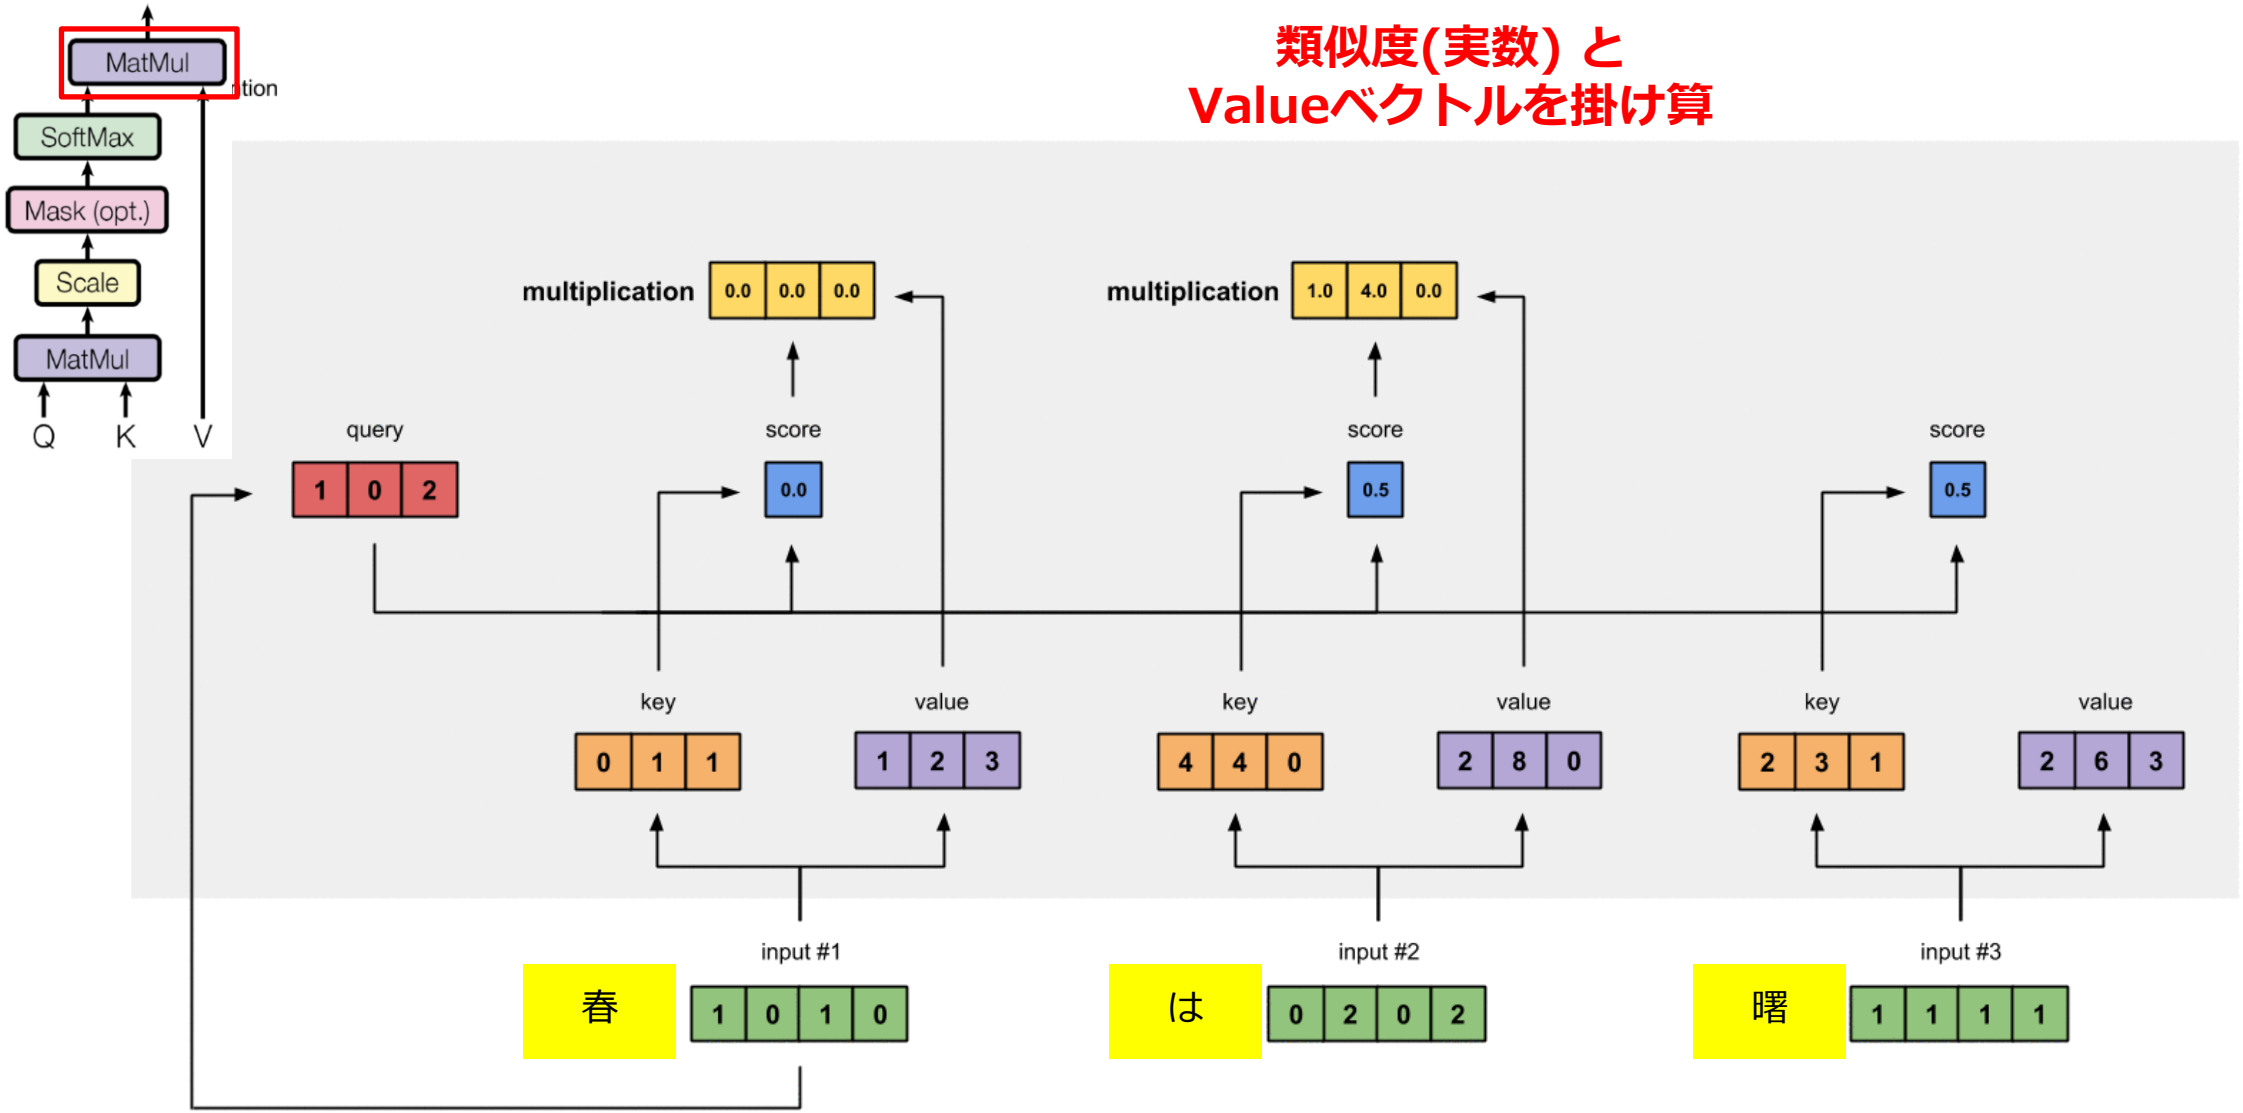
Transformerのパーツ | Attention



[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Transformerのパーツ | Attention

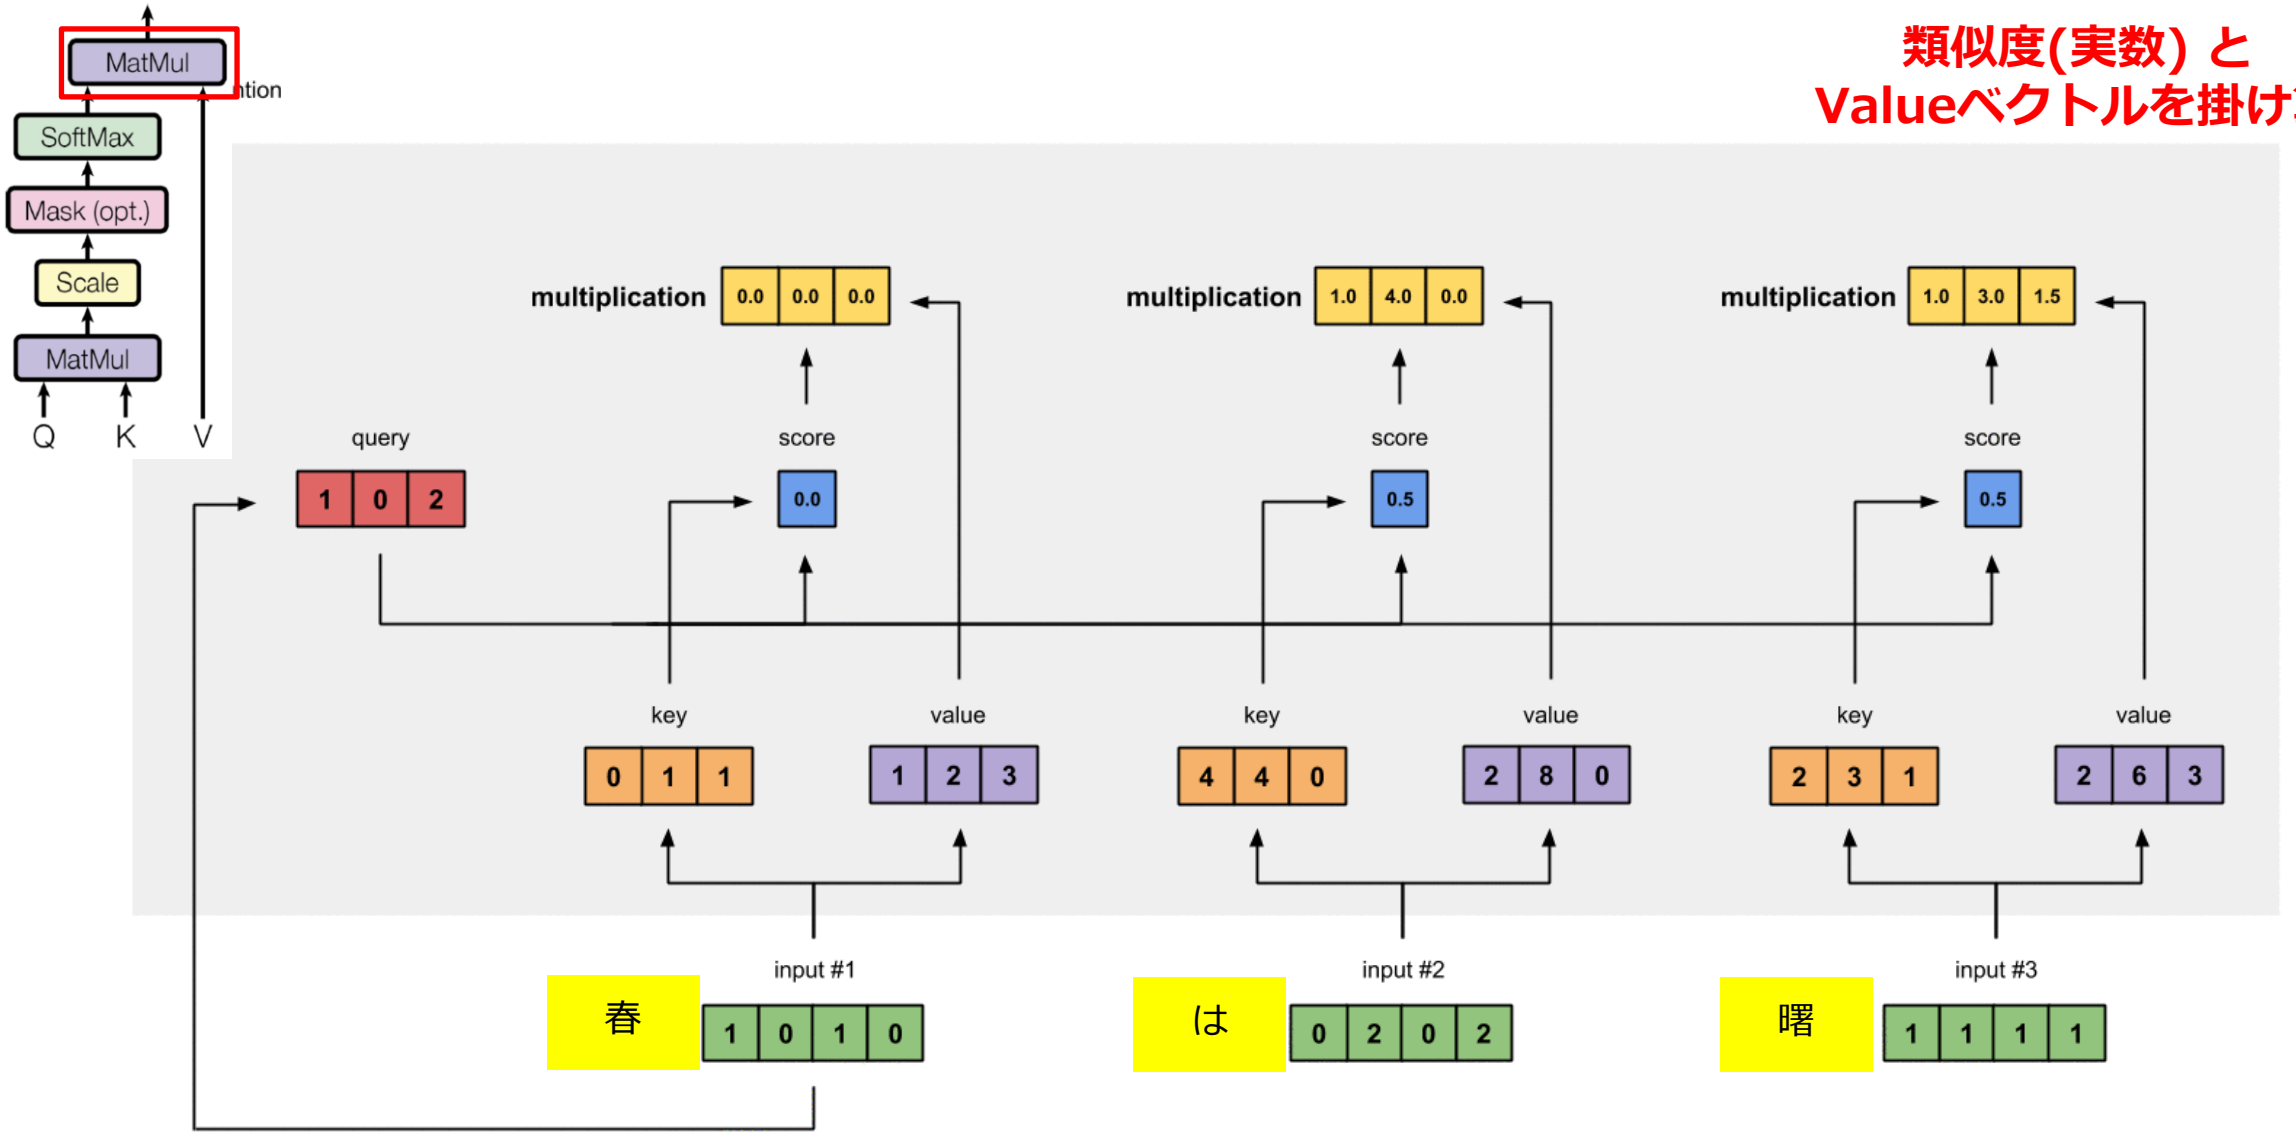


[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Attention

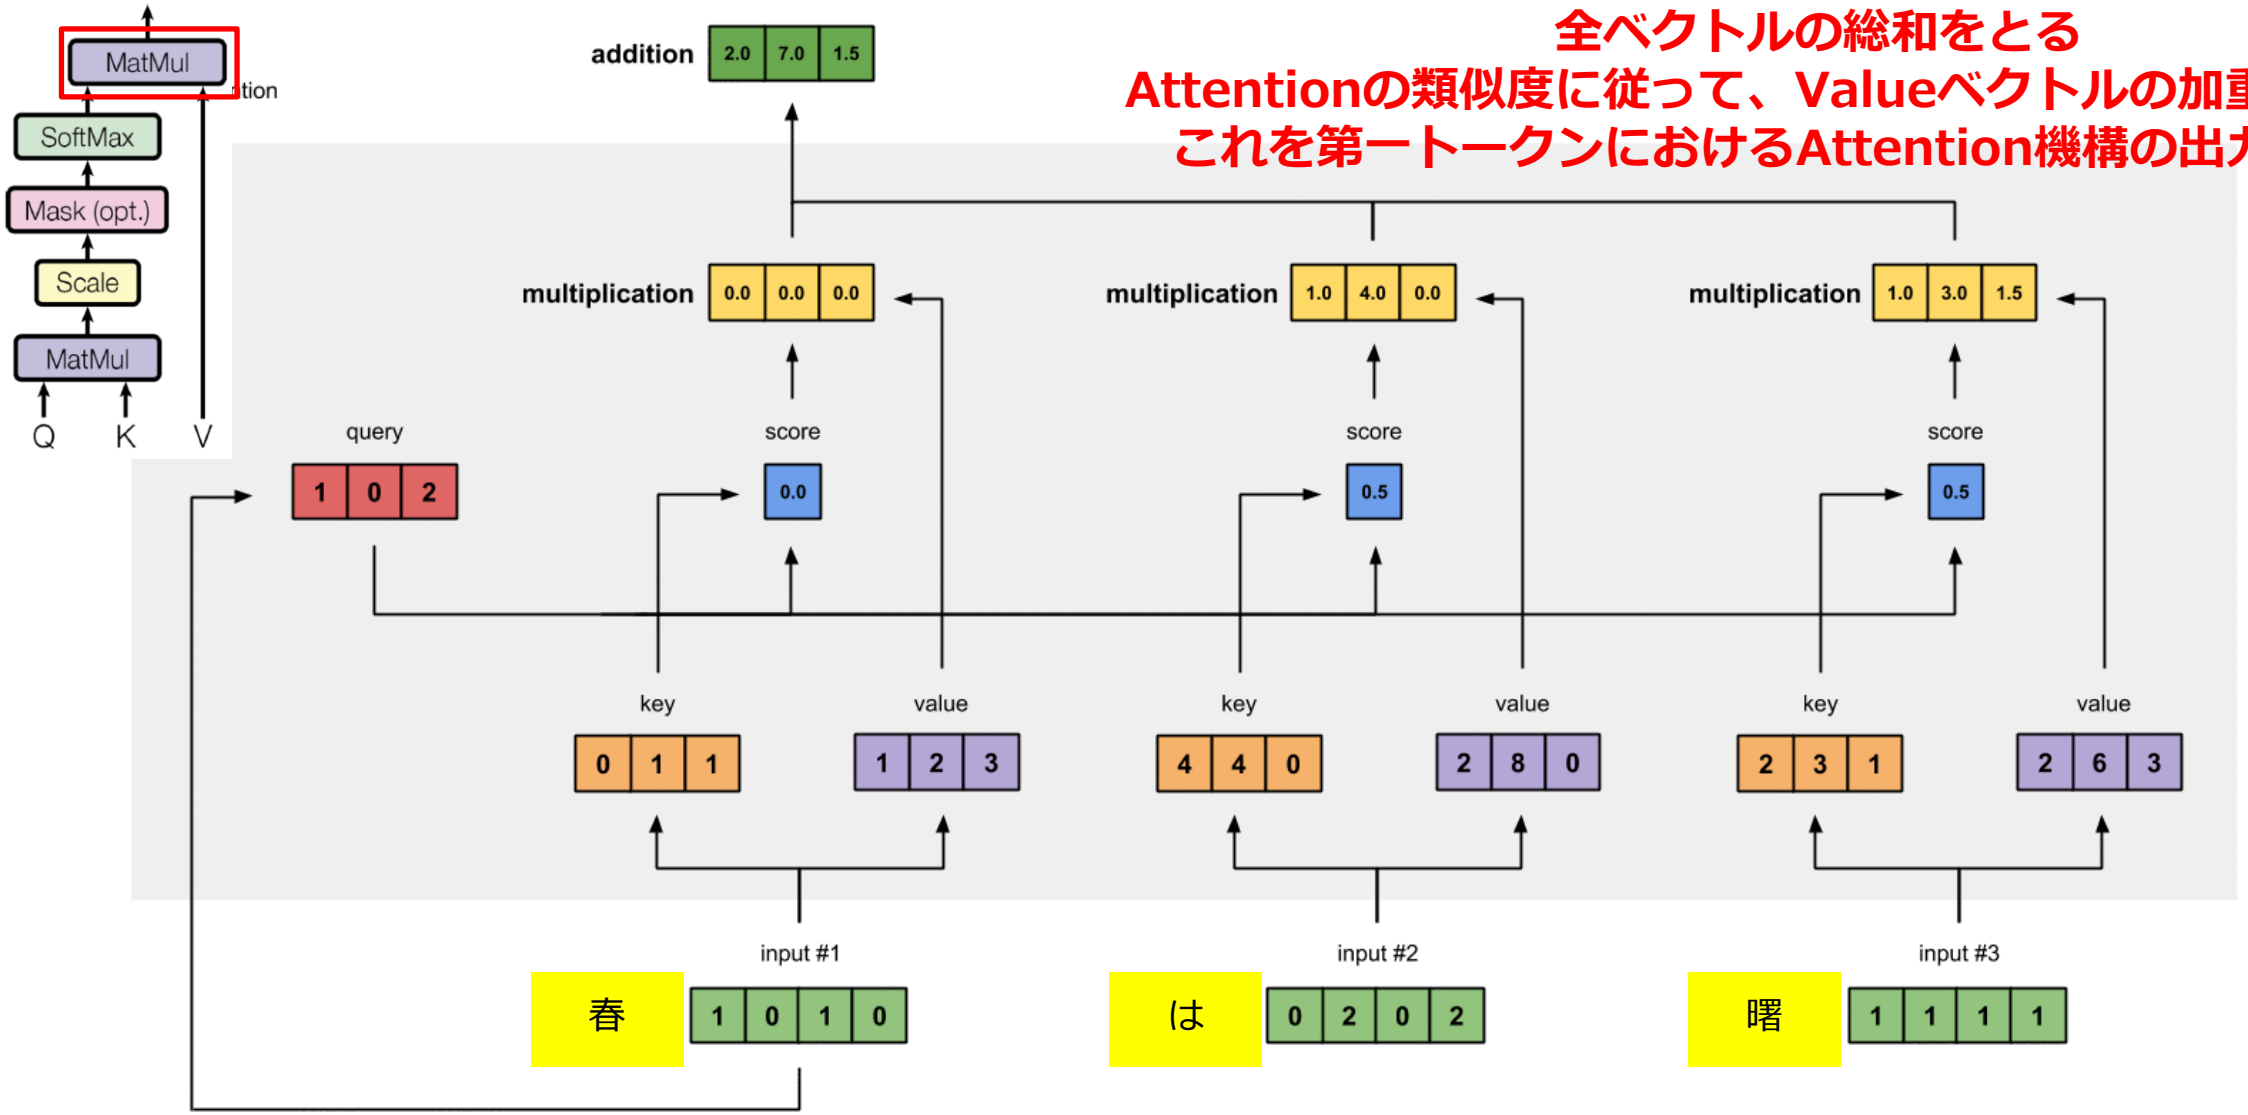


類似度(実数) と
Valueベクトルを掛け算

[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Transformerのパーツ | Attention

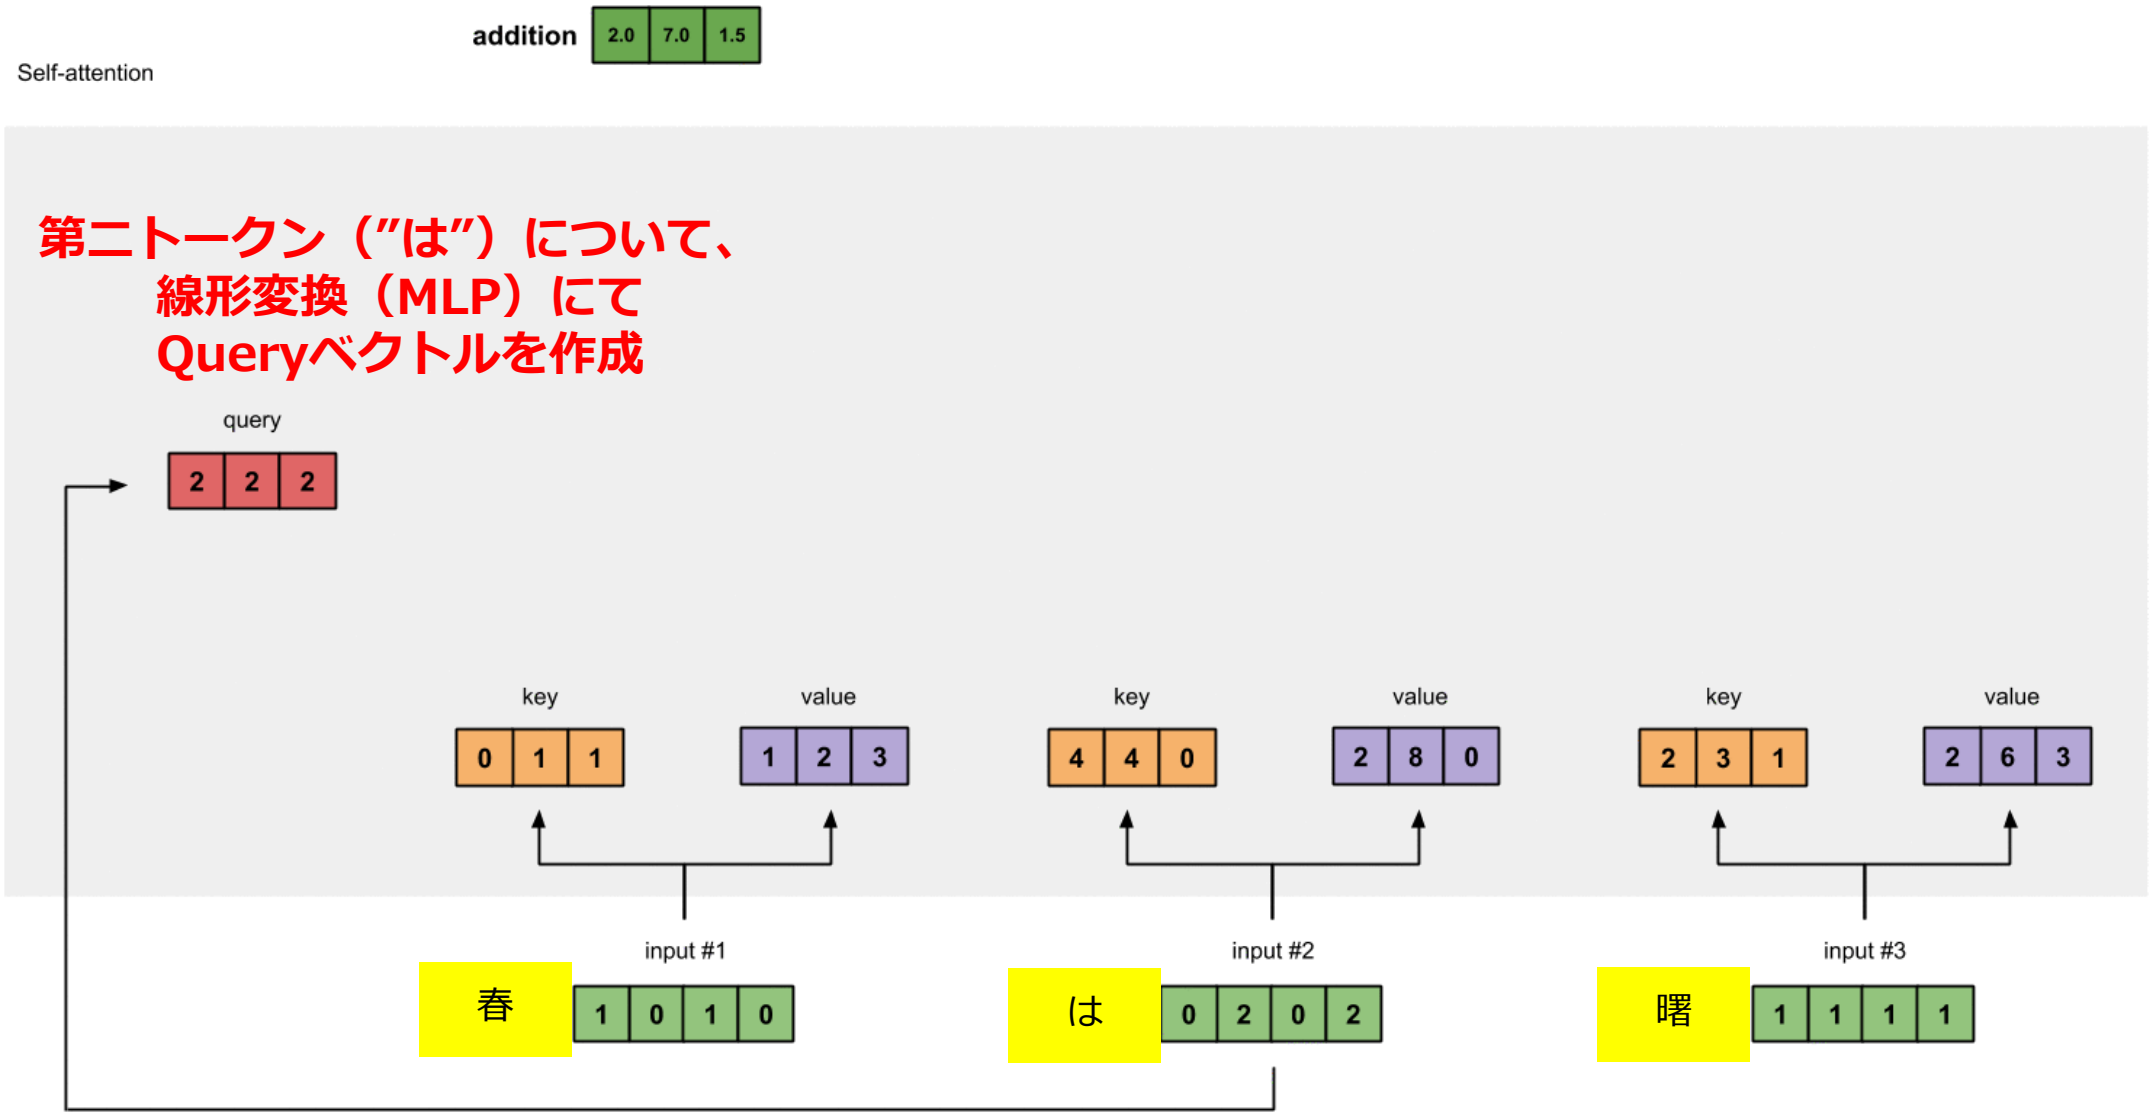


全ベクトルの総和をとる
Attentionの類似度に従って、Valueベクトルの加重平均を算出
これを第一トークンにおけるAttention機構の出力値とする

[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Transformerのパーツ | Attention



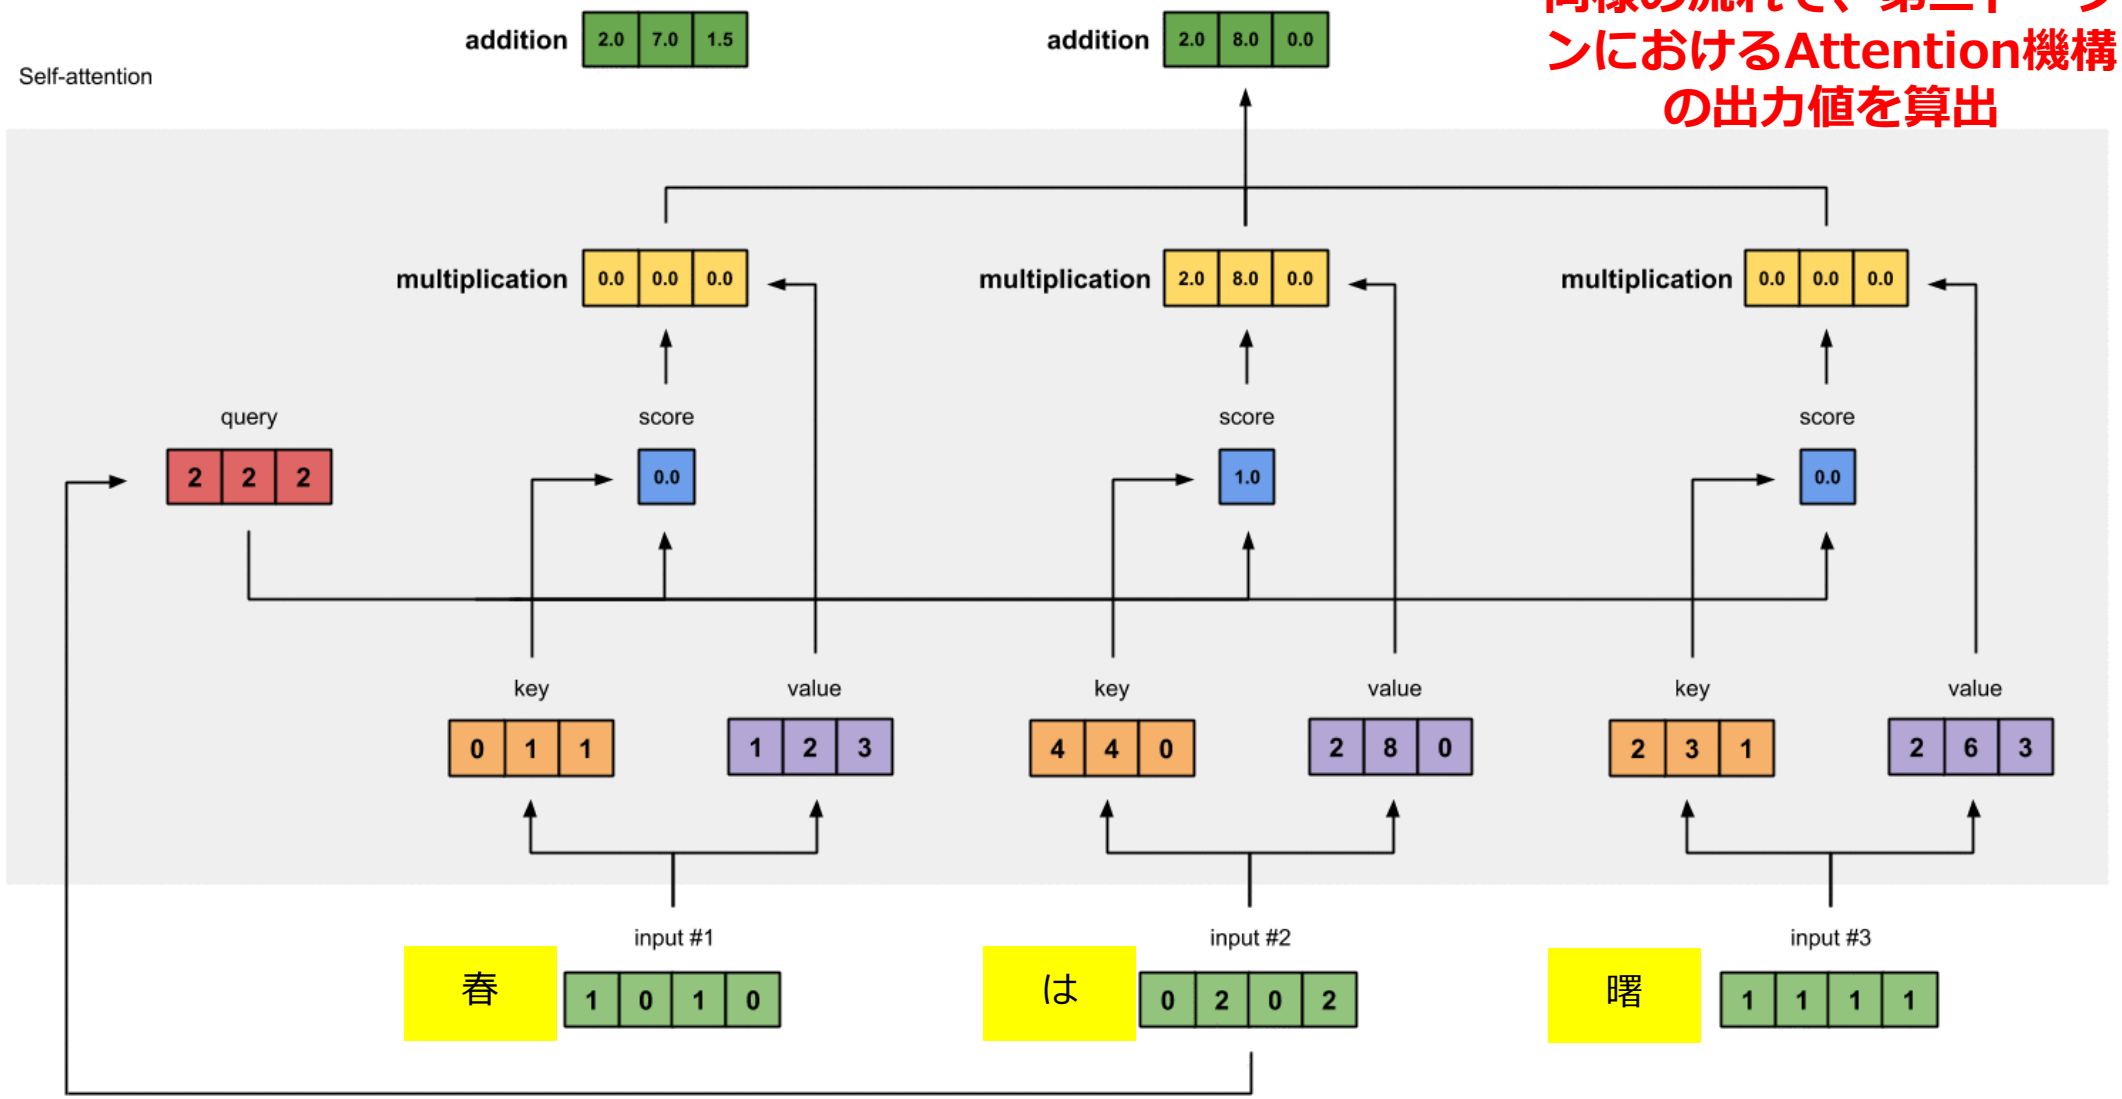
[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Attention

同様の流れで、第二トークンにおけるAttention機構の出力値を算出

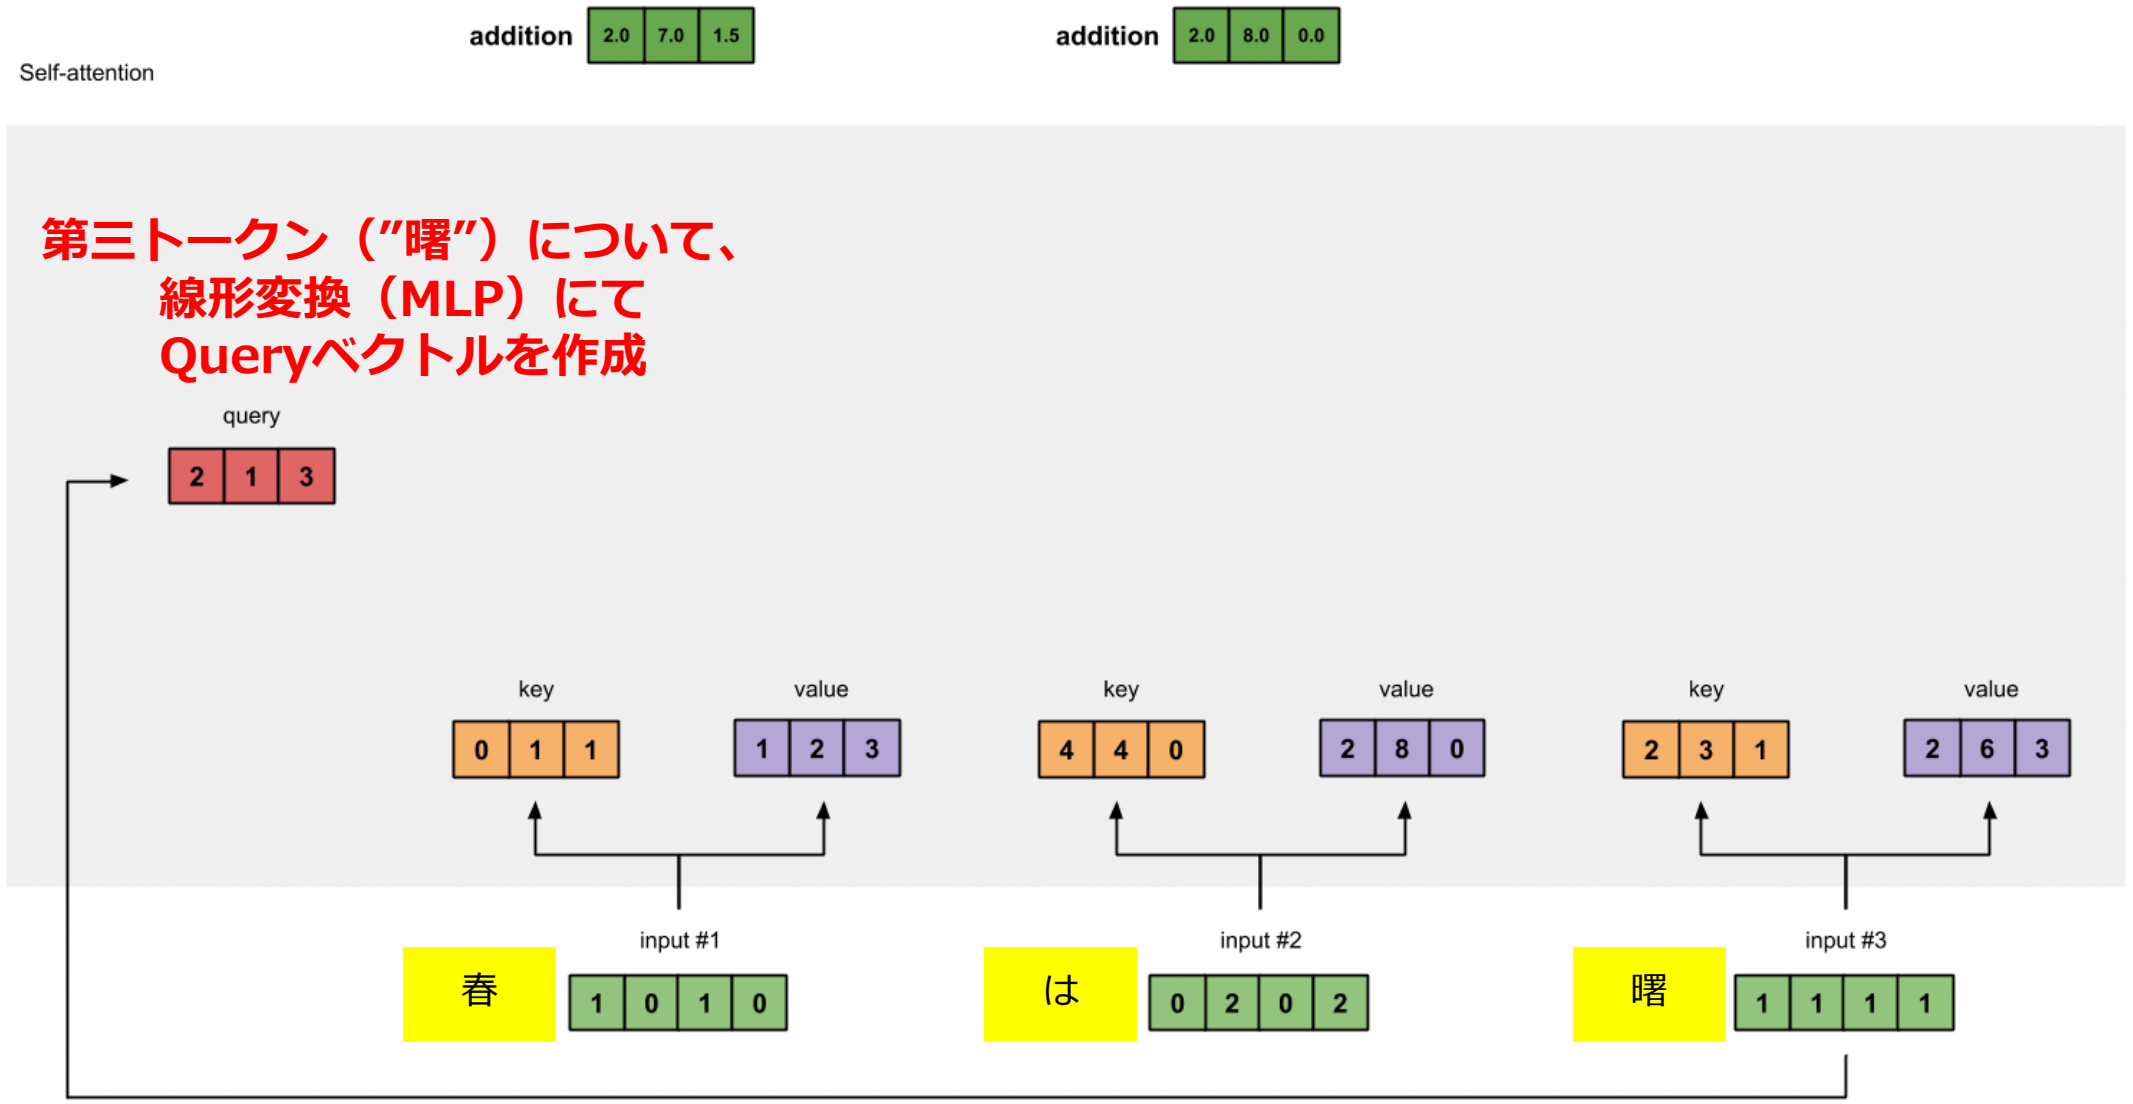


[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Attention

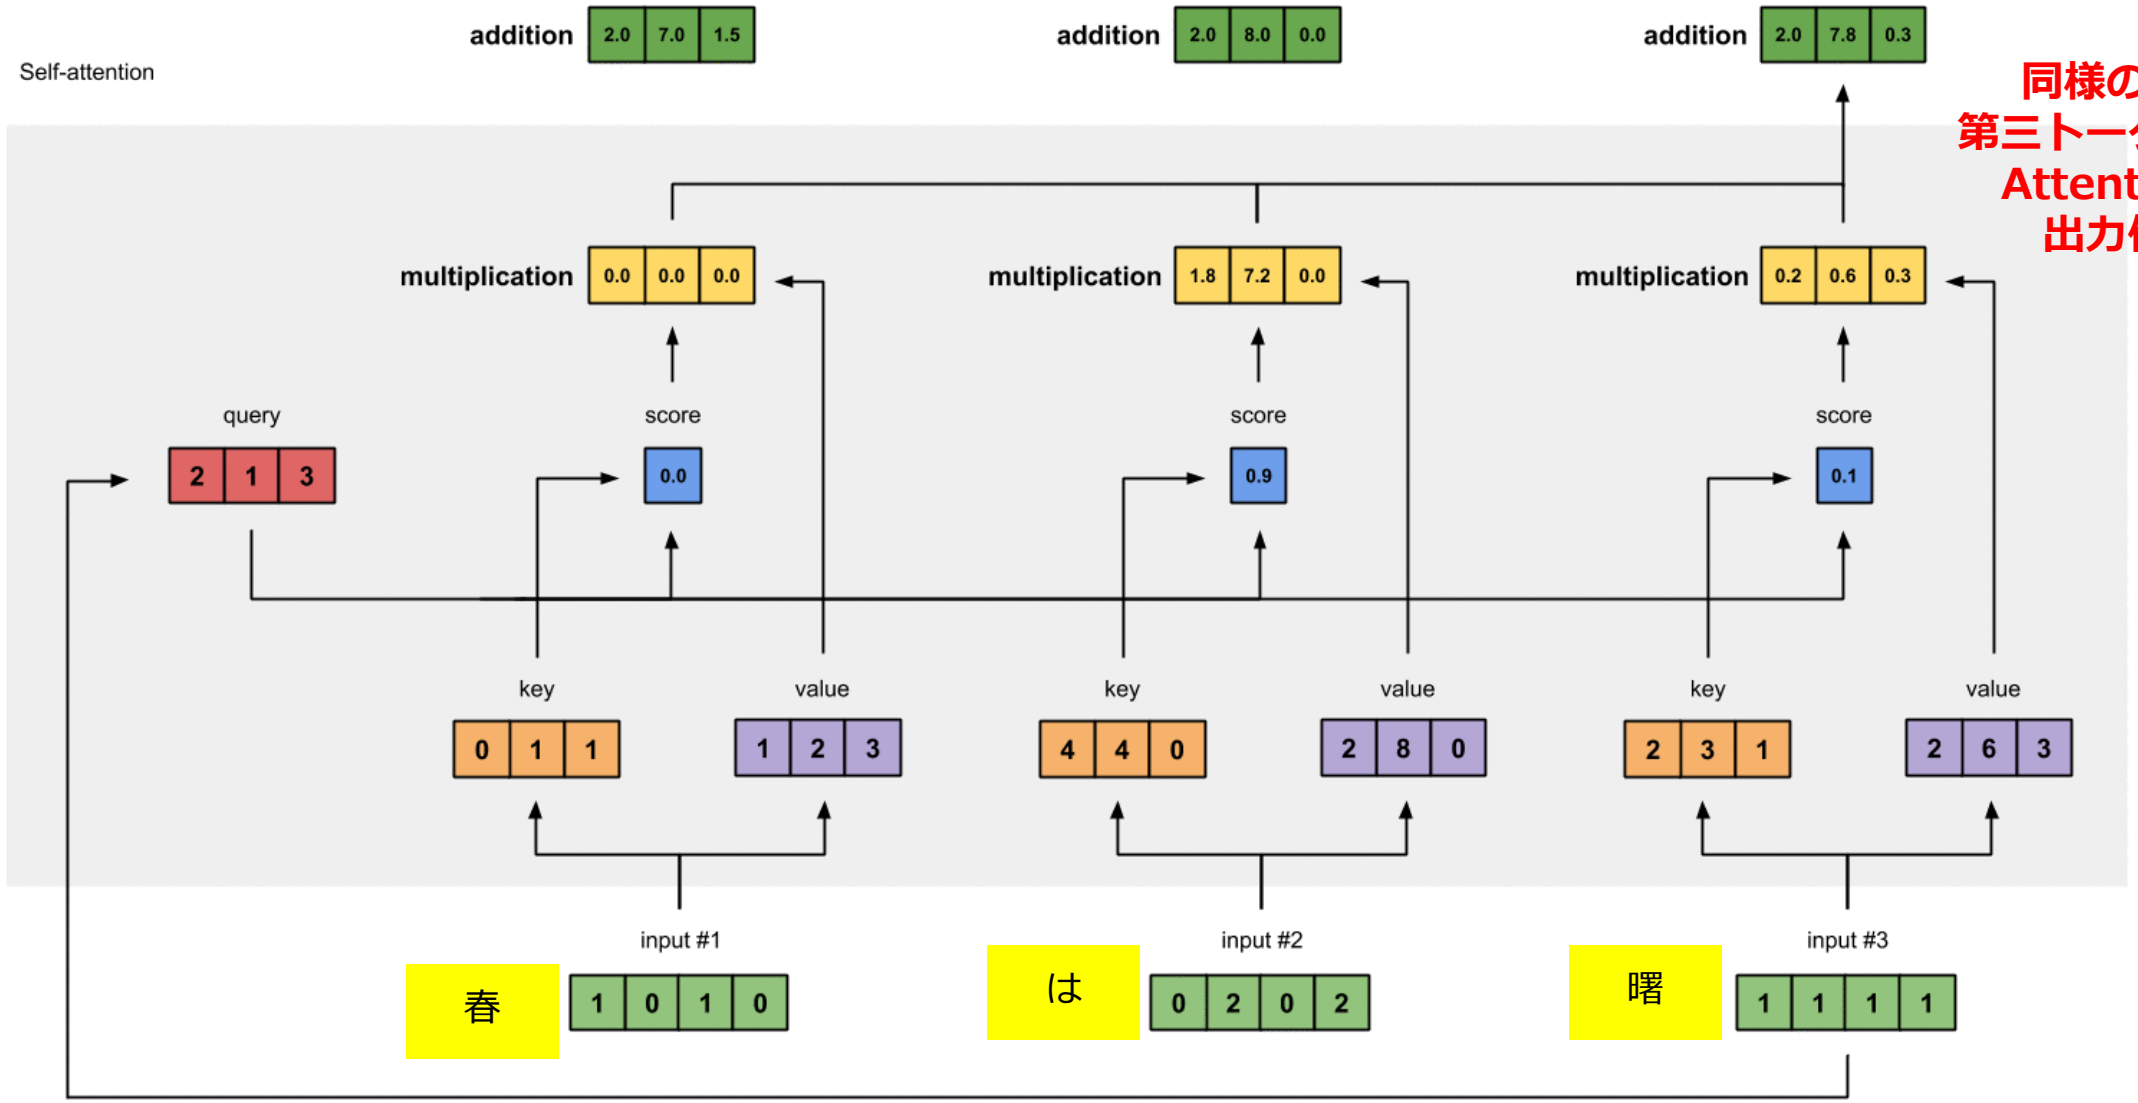


[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Attention



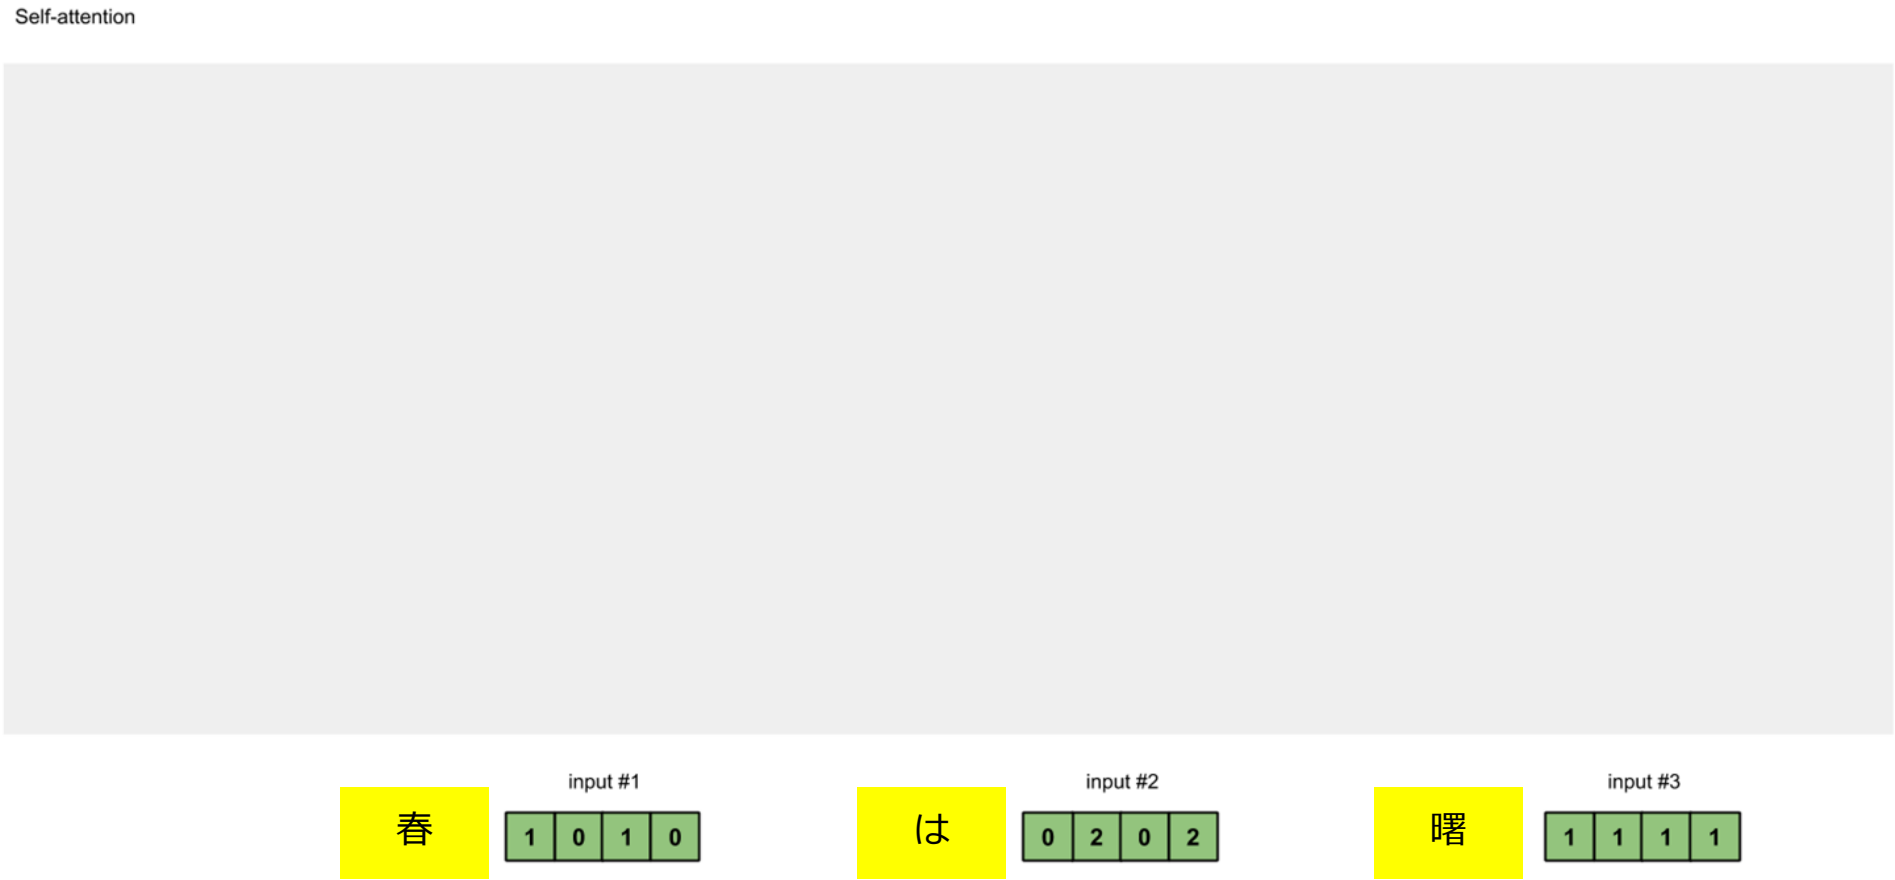
同様の流れで、
第三トークンにおける
Attention機構の
出力値を算出

[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Attention（高速で復習）

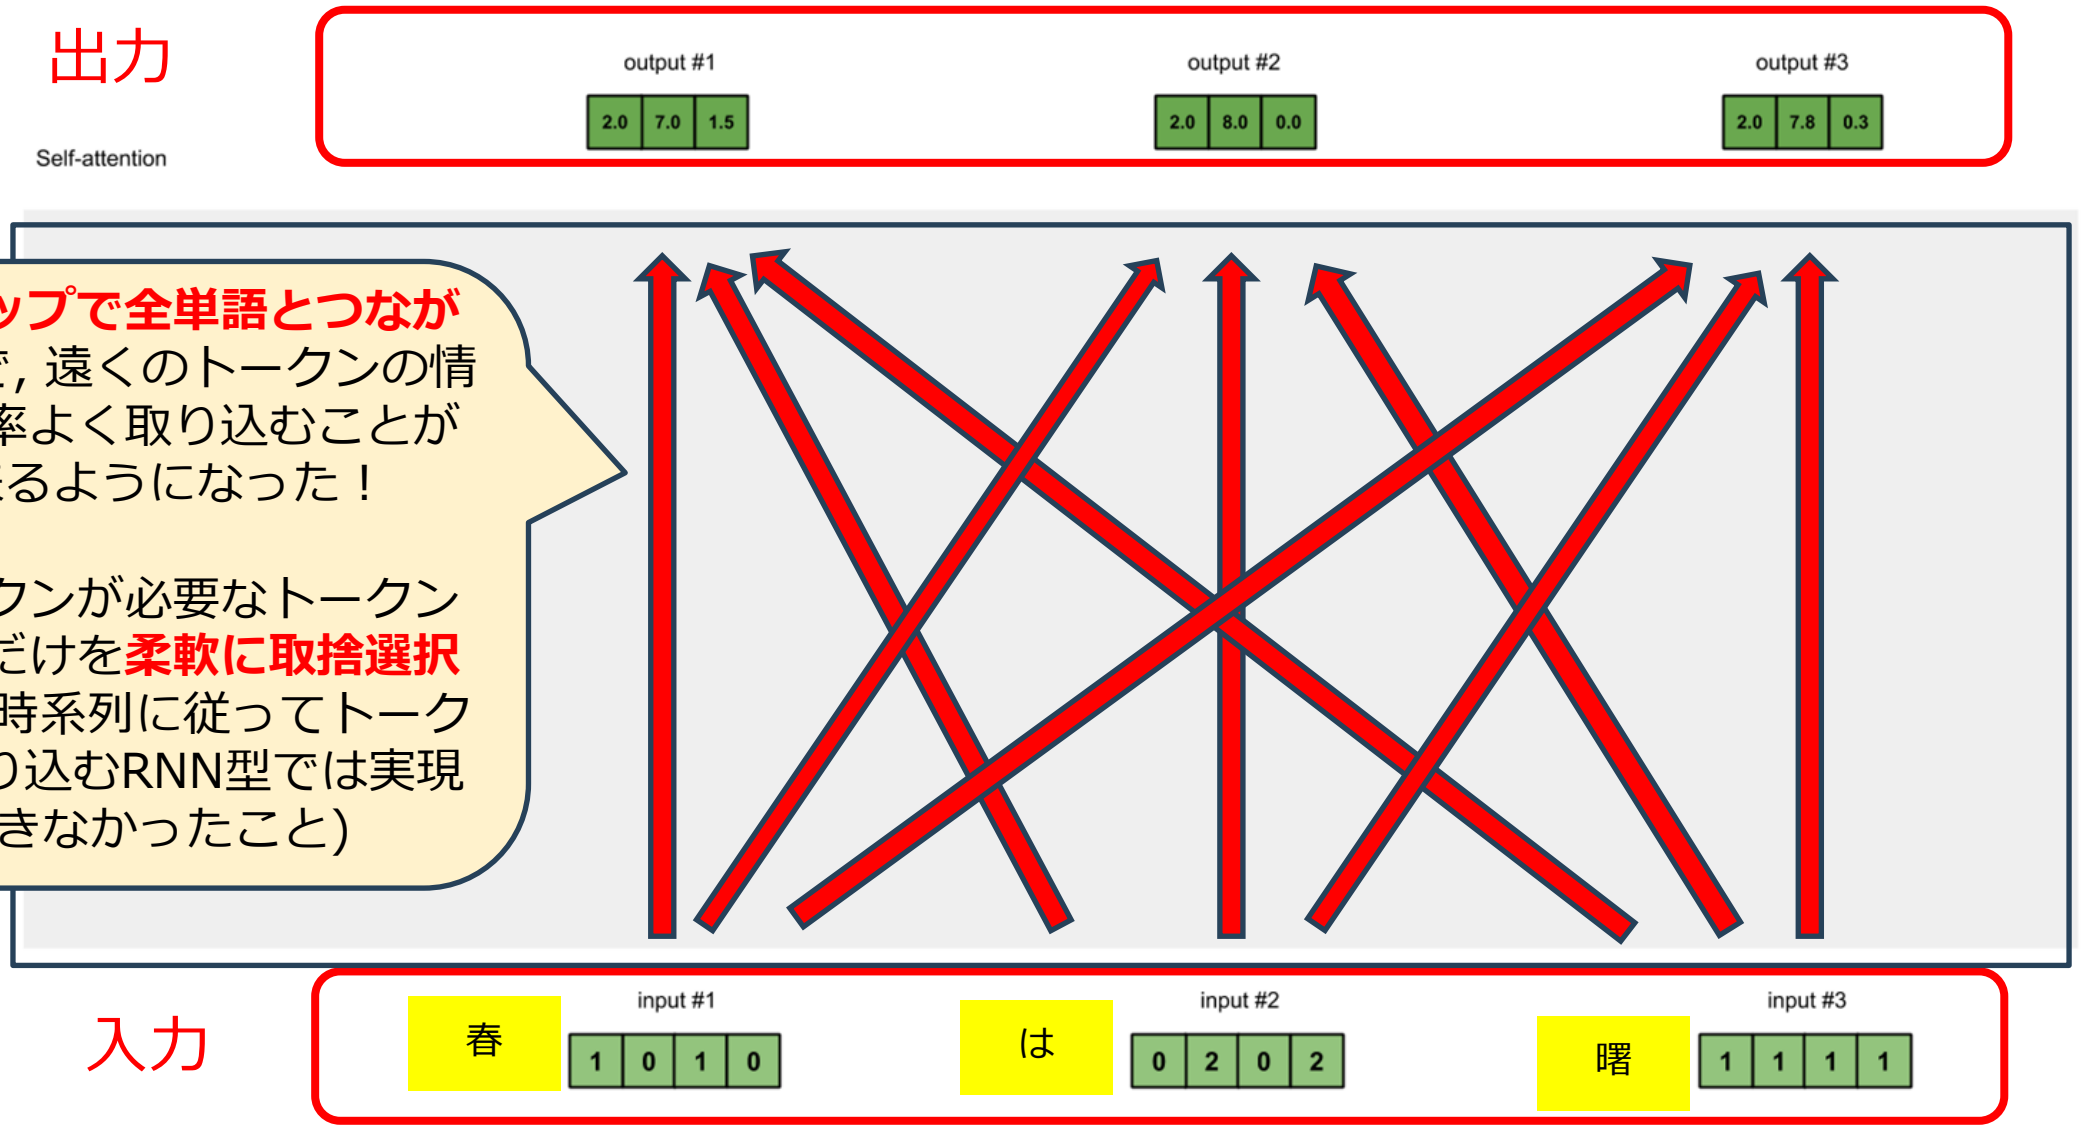


[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Attention



1ステップで全単語とつながることで, 遠くのトークンの情報を効率よく取り込むことが出来るようになった！

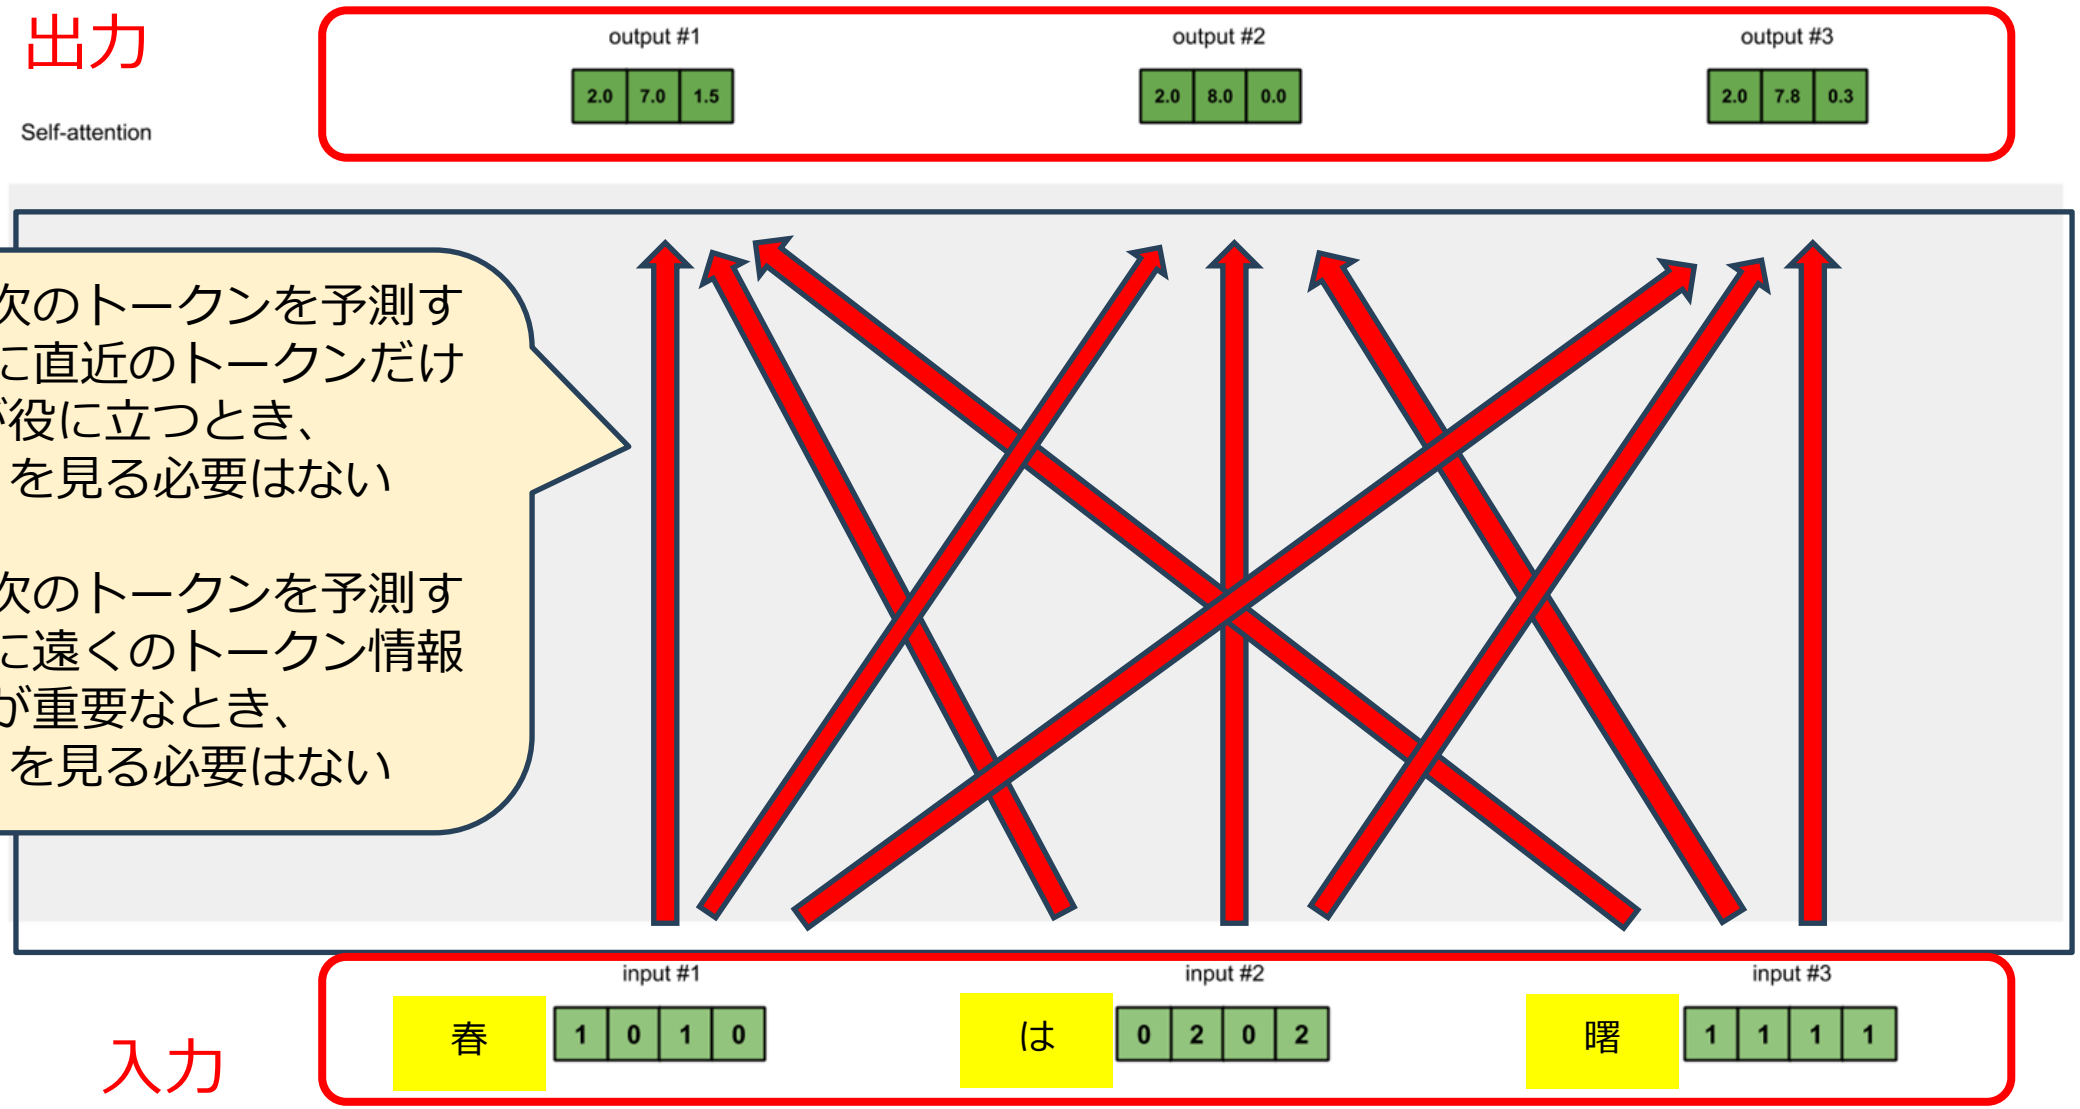
各トークンが必要なトークンの情報だけを**柔軟に取捨選択**(これは時系列に従ってトークンを取り込むRNN型では実現できなかったこと)

[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Attention

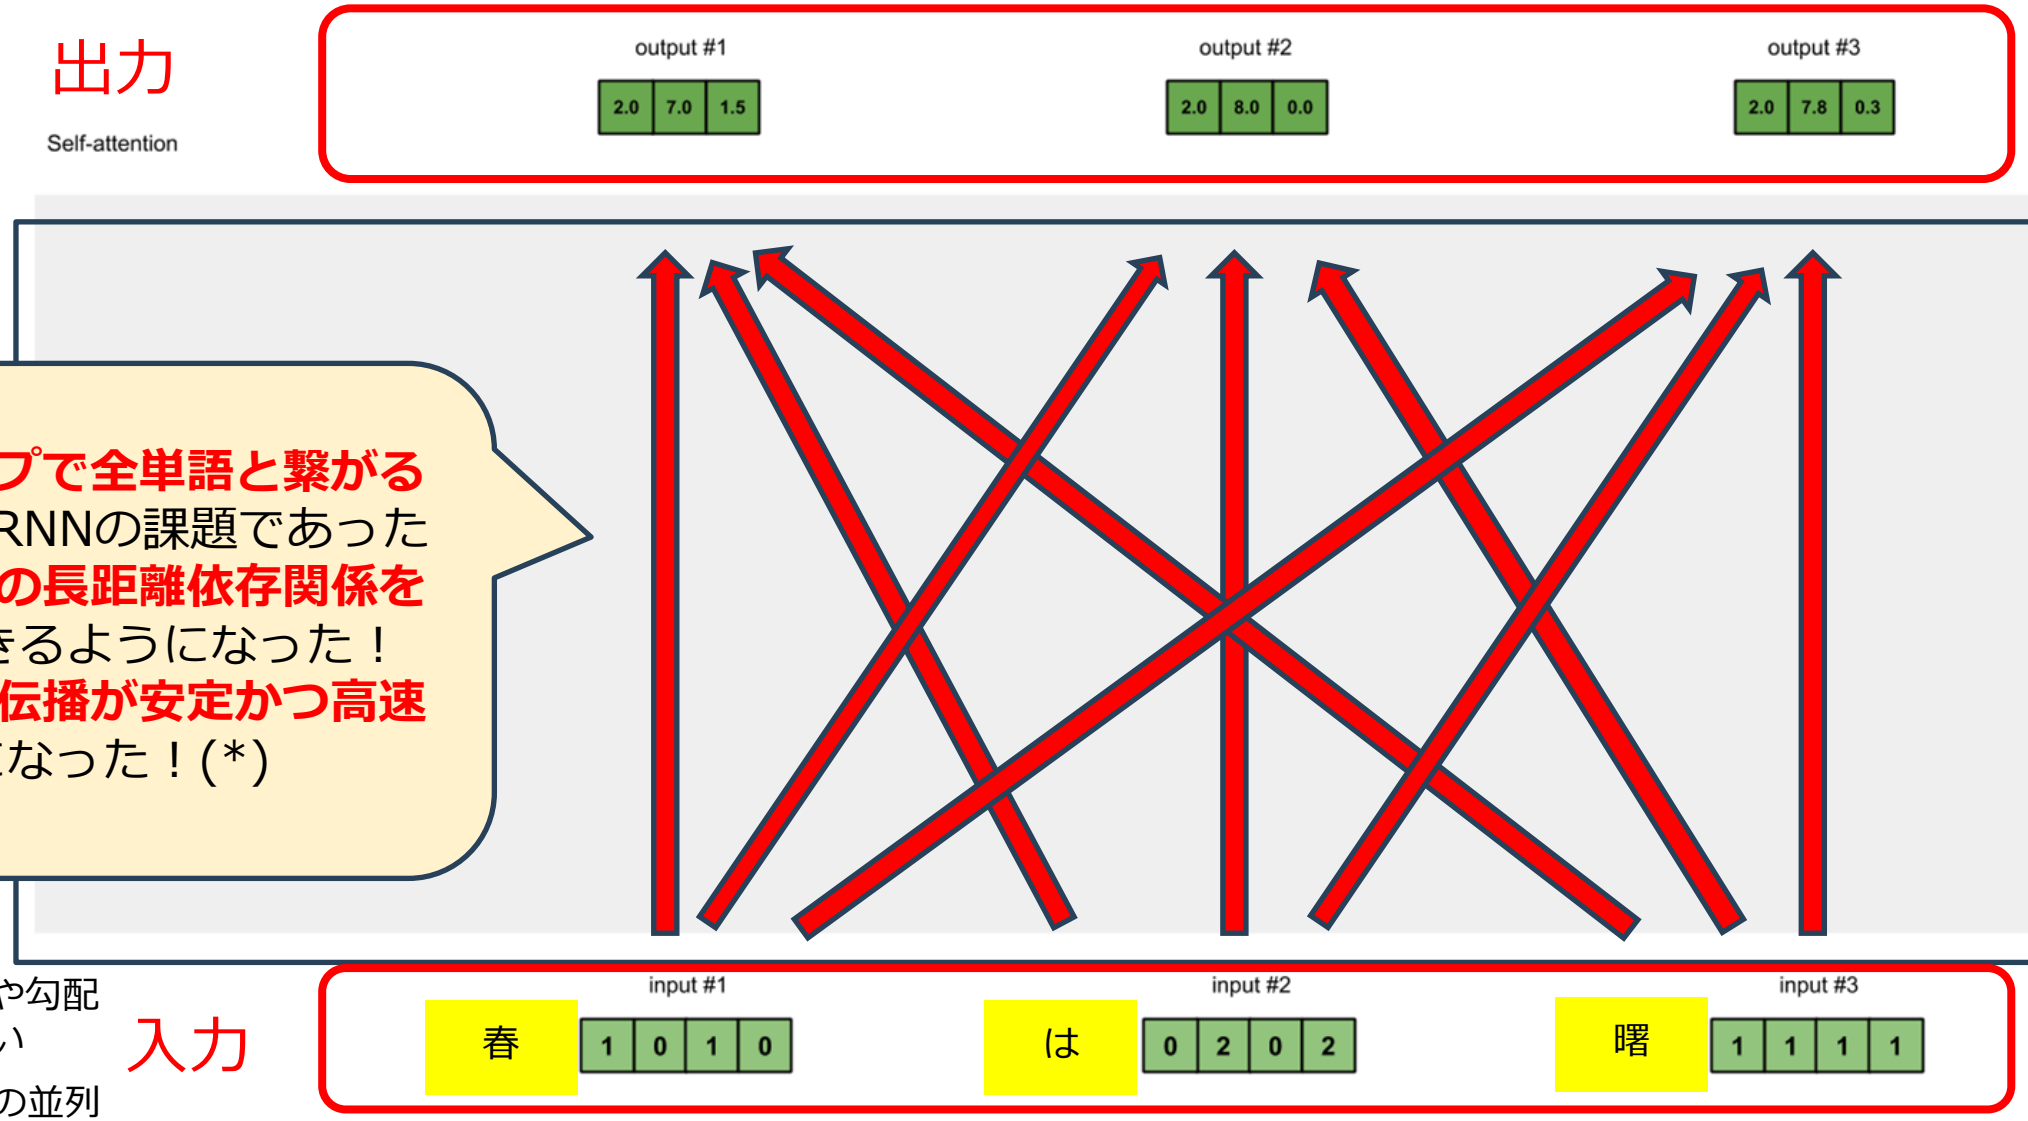


[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Attention



１ステップで全単語と繋がる
ことで、RNNの課題であった
①**単語間の長距離依存関係を把握**できるようになった！
②**誤差逆伝播が安定かつ高速**になった！(*)

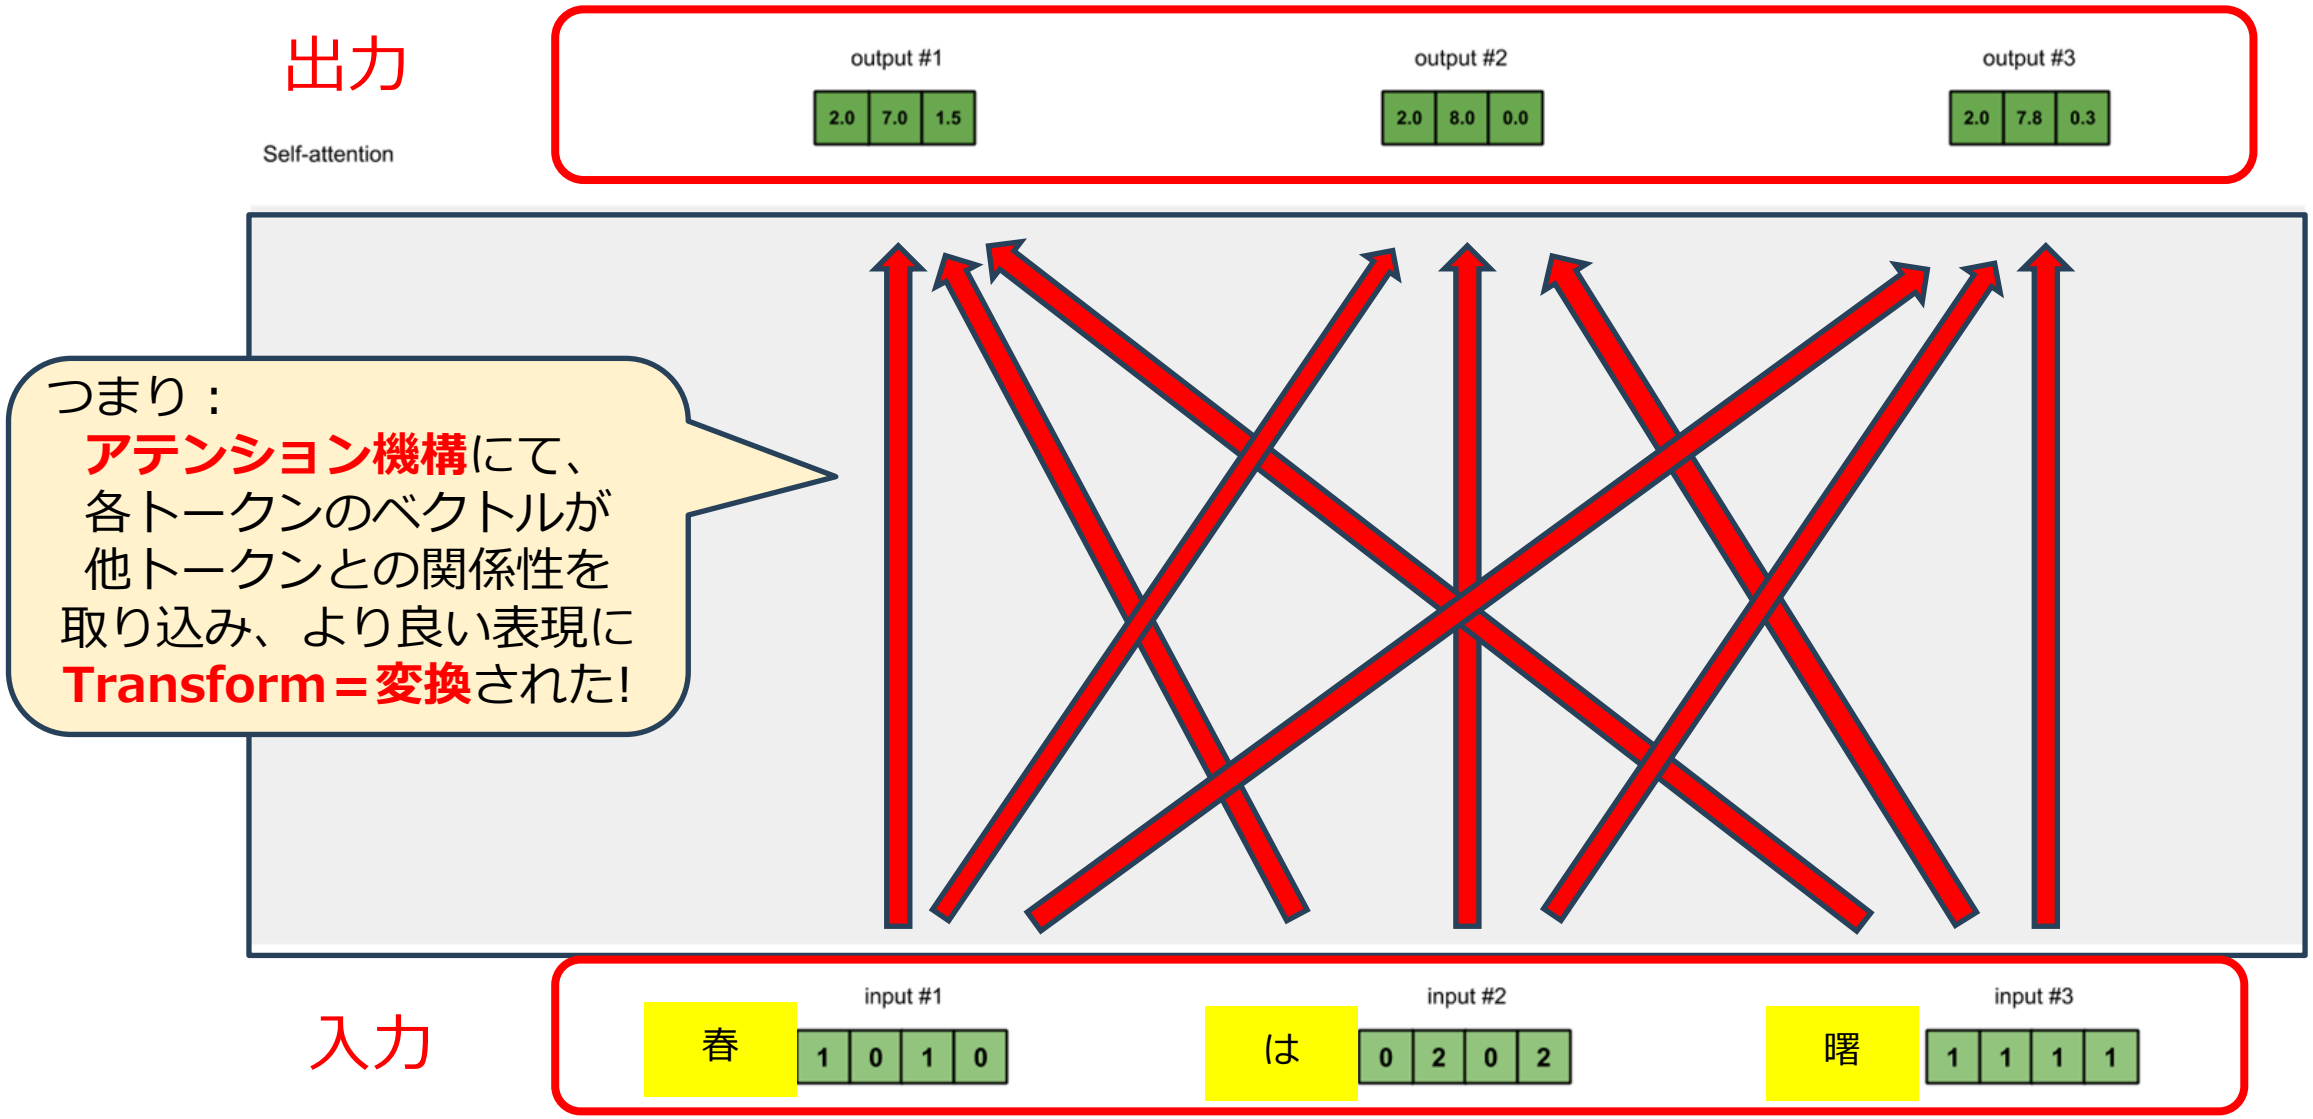
(*)
安定：勾配消失や勾配爆発が発生しない

高速：GPU等での並列演算処理しやすい

[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Transformerのパーツ | Attention

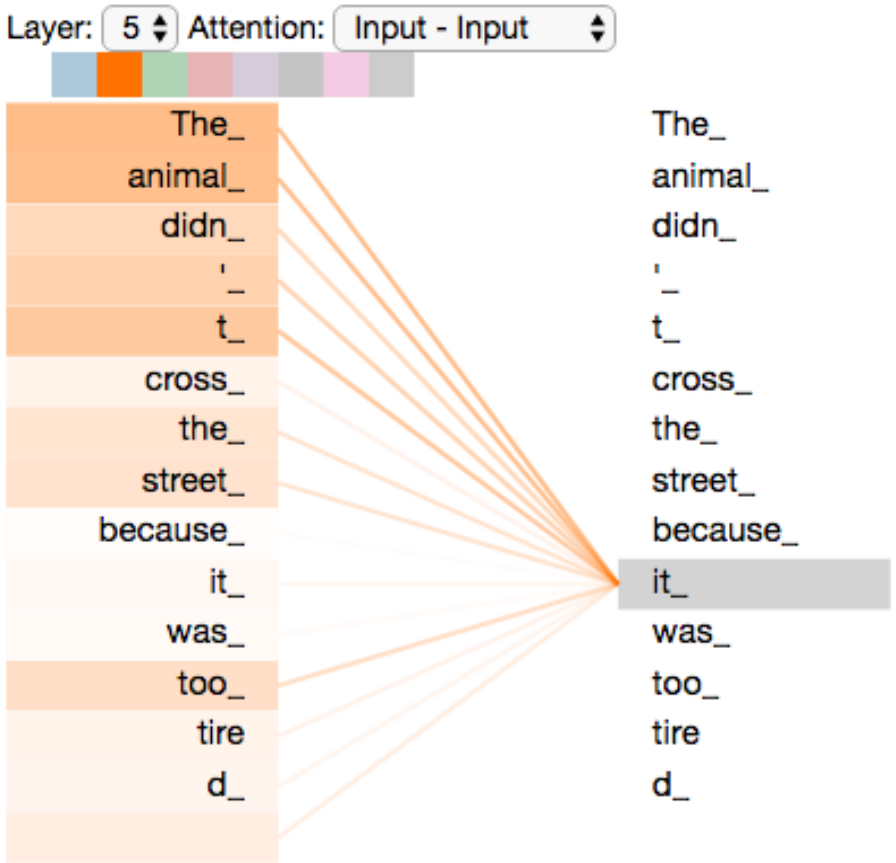


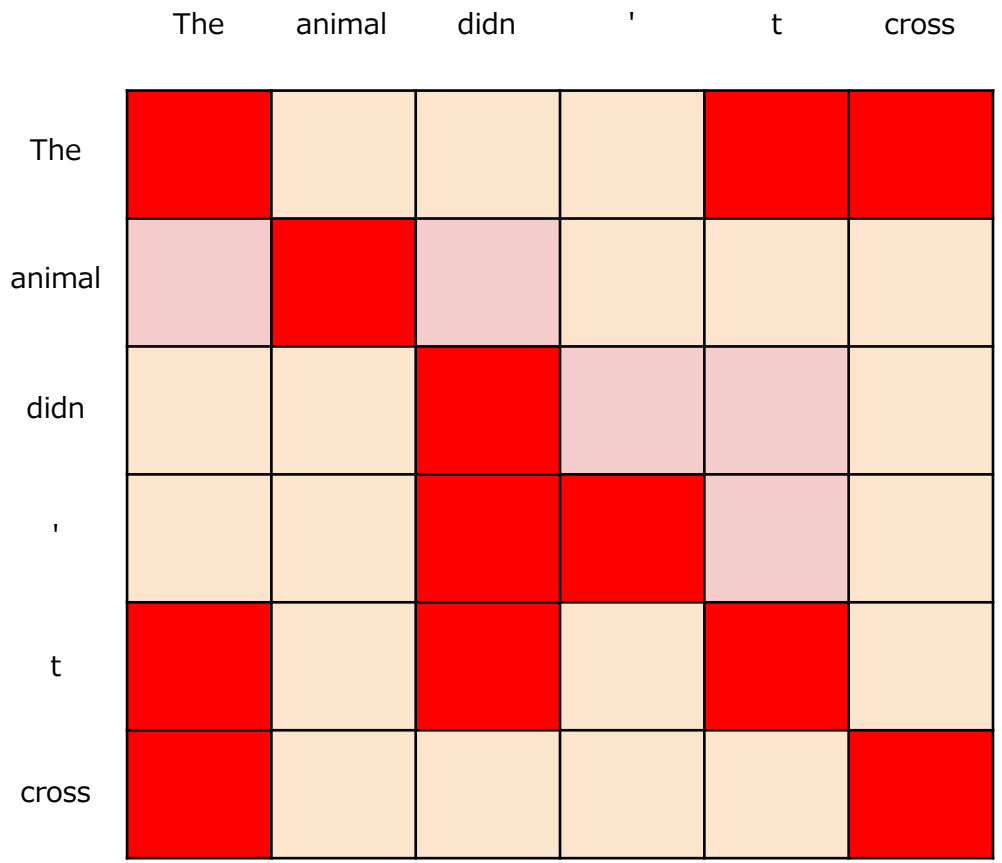
[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Attentionの可視化例





“it”は、”The” “animal” に対して強いアテンションがかかっていることがわかる

全単語間のAttention Map（ヒートマップ）が作れる

＊常にこのくらい分かりやすい関係が得られるとは限らない

[18] Jay Alammar (2018) The Illustrated Transformer – Jay Alammar – Visualizing machine learning one concept at a time. より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Attention

数式による整理（復習）

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}(\frac{QK^T}{\sqrt{d_k}})V$$

Q：Queryベクトル

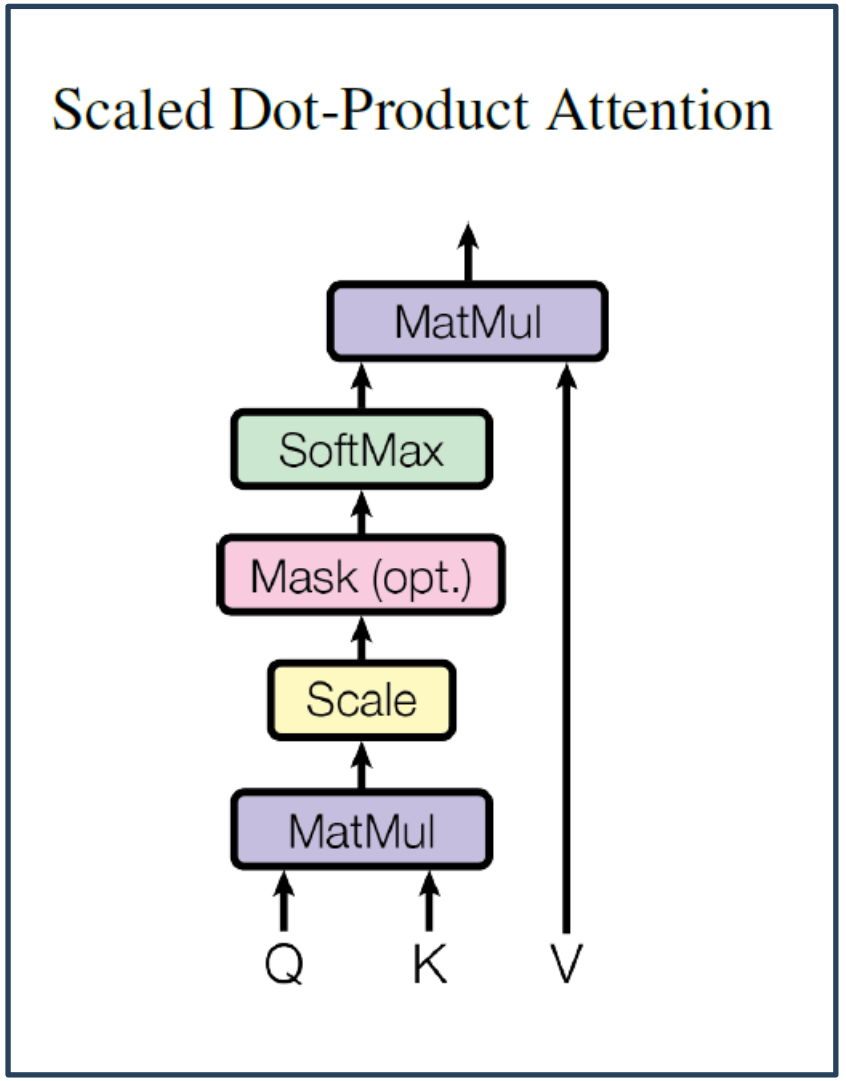
K：Keyベクトル

V：Valueベクトル

d_k：ベクトルの次元数

ベクトルの次元数が増えるとQとKの内積の値(分散)が増大

それを抑えるためベクトルの次元数(の平方根で)割り算.



[6] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

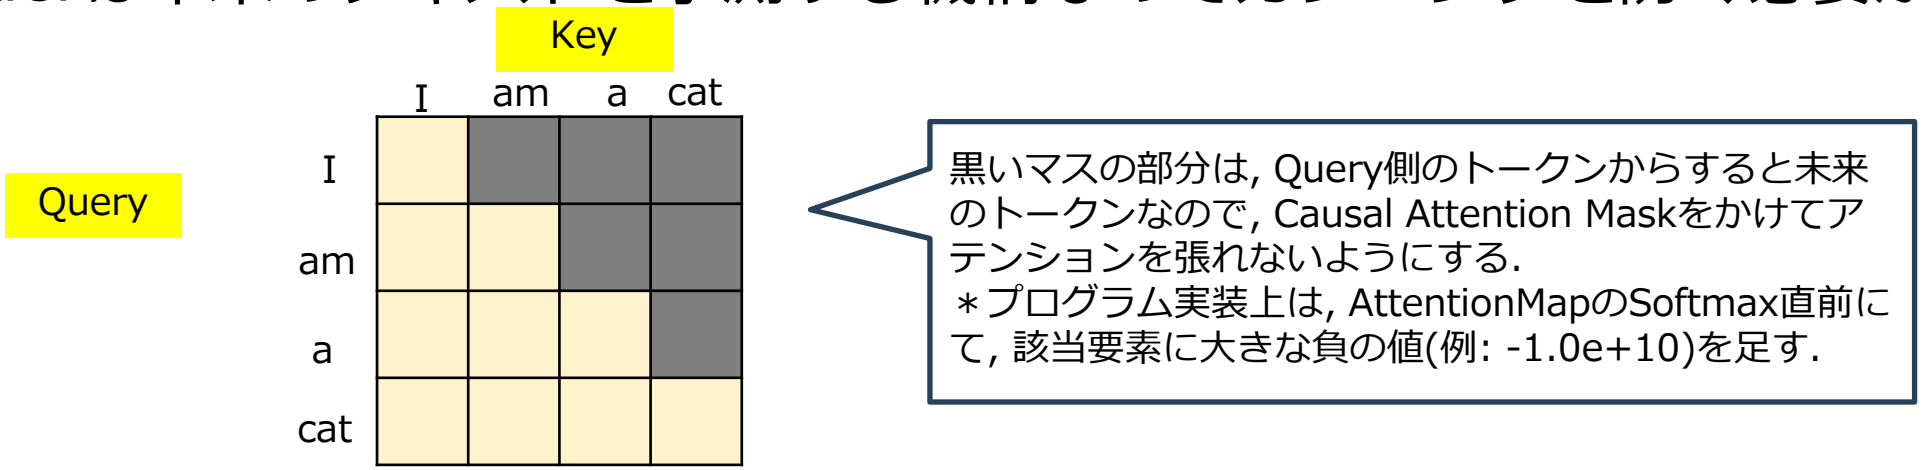
Transformerのパーツ | Attention

Encoder側のアテンション機構

- 入力テキスト内でのアテンション（Self-Attention）

Decoder側のアテンション機構

- 入力テキストと出力テキストを跨ったアテンション（Cross-Attention）
- 出力テキスト内でのアテンション（Self-Attention）
- 出力テキストについて：自身より未来のトークンについてアテンションを張れないようにマスク (Causal Attention Mask)をかける
  Decoderは未来のテキストを予測する機構なのでカンニングを防ぐ必要がある

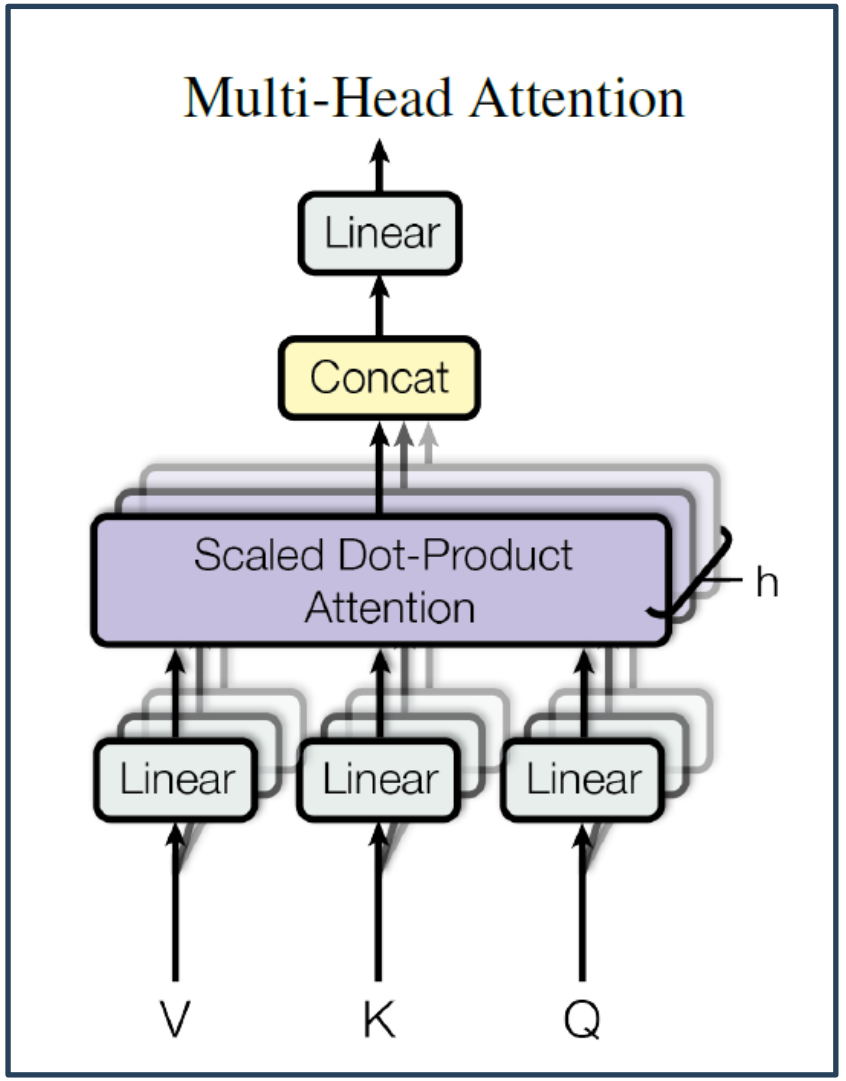


黒いマスの部分は, Query側のトークンからすると未来のトークンなので, Causal Attention Maskをかけてアテンションを張れないようにする.
＊プログラム実装上は, AttentionMapのSoftmax直前にて, 該当要素に大きな負の値(例: -1.0e+10)を足す.

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Transformerのパーツ | Multi-Head Attention

- アテンション処理を複数個並列で行う
  その後、出力を一つのベクトルに統合する
- 1つのトークンが様々なトークンに、異なる形式のアテンションをあてることが可能となる



h個のアテンション機構からの出力(ベクトル)をConcatenate

$$\mathrm{MultiHead}(Q,K,V) = \mathrm{Concat}(\mathrm{head}_1,...,\mathrm{head}_\mathrm{h})W^O$$

$$\text{where } \mathrm{head}_\mathrm{i} = \mathrm{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

(⇒)の出力　　**i番目のアテンション機構**

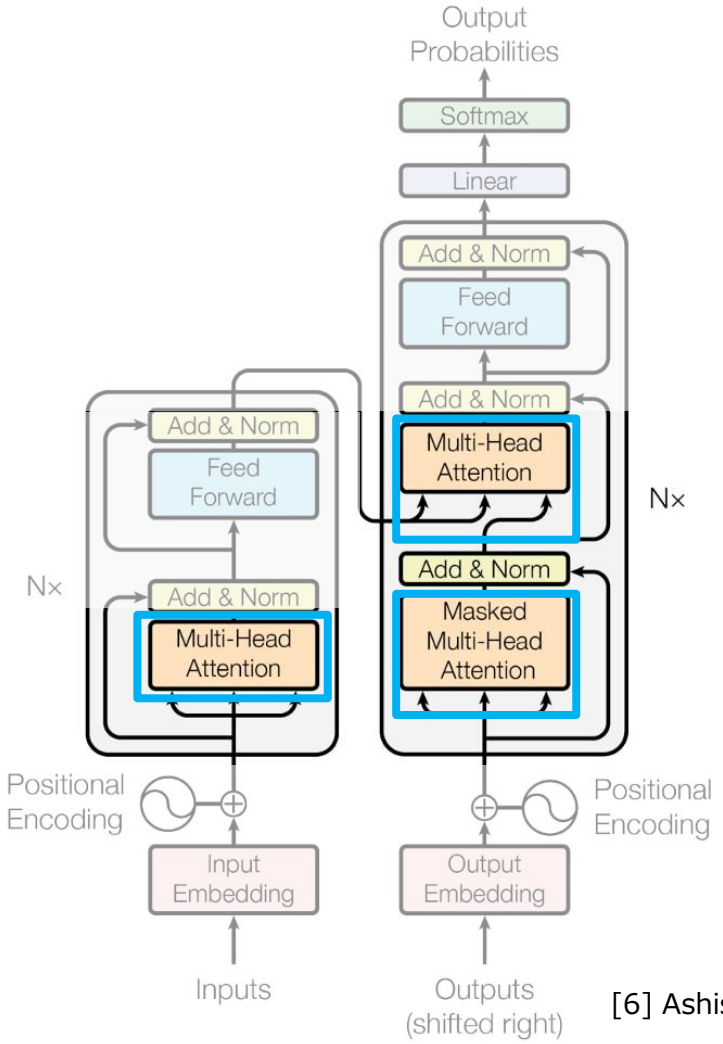
[6] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Multi-Head Attention

各パーツごとに解説



- Embedding

各トークンのベクトルを
他トークンとの関係性を取り込むことで
より良い表現に変換

- **Multi-Head Attention**
- Feed Forward
- Others

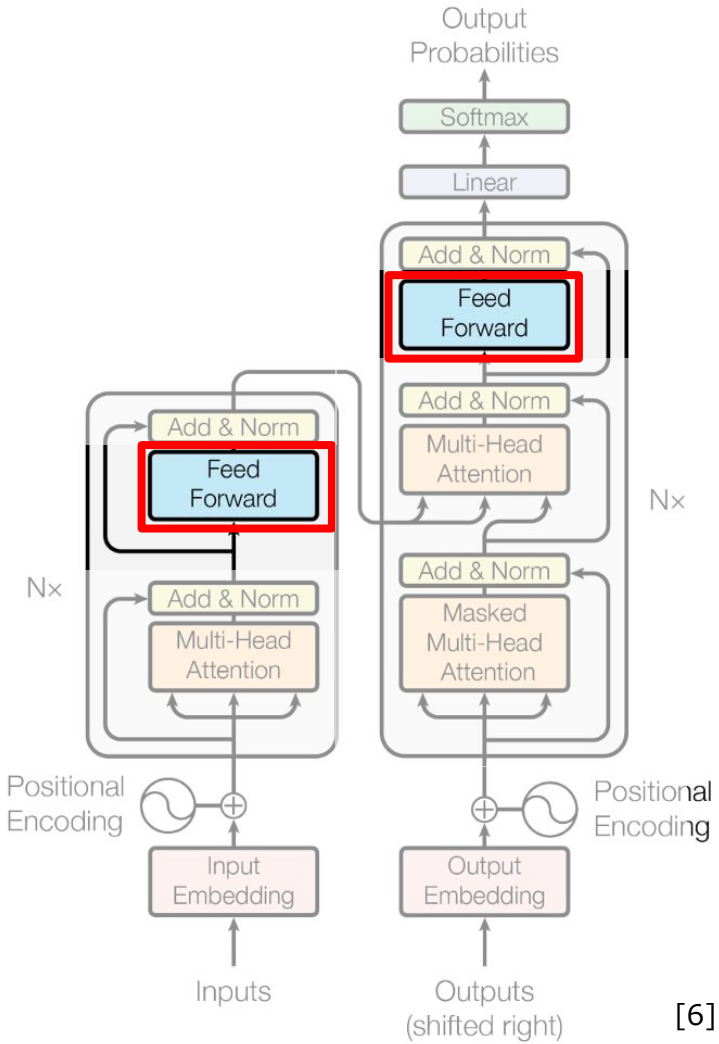
[6] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Feed Forward

各パーツごとに解説



- Embedding
- Multi-Head Attention
- **Feed Forward**
- Others

[6] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用し、一部改変

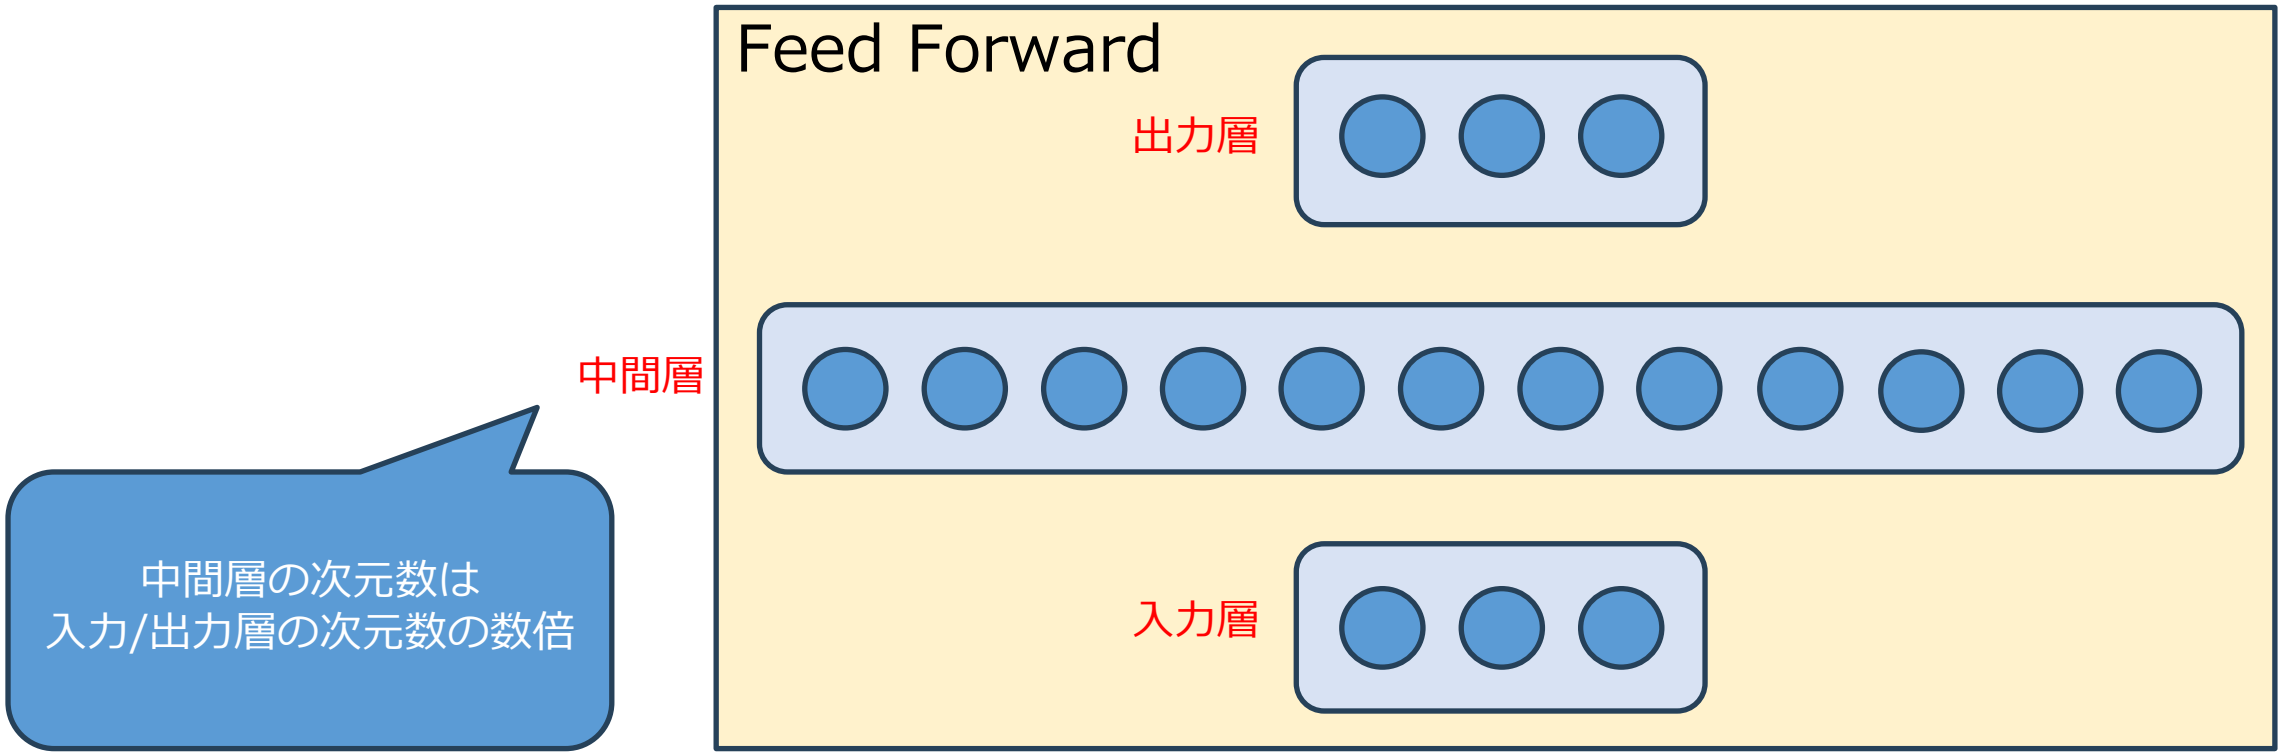
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Transformerのパーツ | Feed Forward

巨大な２階建てのMLP

$$\mathrm{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

出力　活性化関数（ReLU）　入力　学習パラメータ



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Transformerのパーツ | Feed Forward

巨大な２階建てのMLP

$$\mathrm{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

出力　活性化関数（ReLU）　入力　学習パラメータ

例えば GPT-3の場合,

・入力層/出力層の次元数：12,288

・中間層の次元数：12,288×4=49,152

・総ブロック数：96

つまり,

Feed Forwardのパラメータ数：$(12{,}288\times 49{,}152)_{[\text{ﾊﾟﾗﾒｰﾀ/層}]}\times 2_{[\text{層/ﾌﾞﾛｯｸ}]}\times 96_{[\text{ﾌﾞﾛｯｸ}]}\fallingdotseq 116\text{B}_{[\text{ﾊﾟﾗﾒｰﾀ}]}$

GPT-3の総パラメータ数：$175\text{B}_{[\text{ﾊﾟﾗﾒｰﾀ}]}$

Feed Forwardの全体に占めるパラメータの割合：約66%

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Transformerのパーツ | Feed Forward

巨大な２階建てのMLP

$$\mathrm{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

出力　活性化関数（ReLU）　入力　学習パラメータ

最近の各モデルシリーズの最大モデルのパラメータ構成*

	gpt-oss120B	Llama3.1	DeepSeek-v3	Qwen3
FFのパラメータ数（Billions）	3.6 (115)	329	23 (657)	14 (227)
全体パラメータ数（Billions）	5.1 (117)	405	37 (671)	22 (235)
パラメータ数におけるFFの割合（%）	71 (98.3)	81.4	62 (97.8)	64 (96.7)

*
（ ）内はMoEモデルの総パラメータ数を示す。MoEモデルは入力に応じて使用するパラメータを変えるため、実際の予測時には（）の左側にある数のパラメータしか使用されない
近年のモデルは上の数式と若干異なるアルゴリズムが採用されている（SwiGLUなど）
huggingfaceのconfigに登録されているmlp層のパラメータ数をもとに計算
gpt-ossについてはModel CardのTable1, DeepSeek-v3についてはTechnical ReportのSection 4.2も参考にした

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Transformerのパーツ | Feed Forwardは何をやっているのか？

Feed Forwardは、パラメータ数が大きいだけに重要？

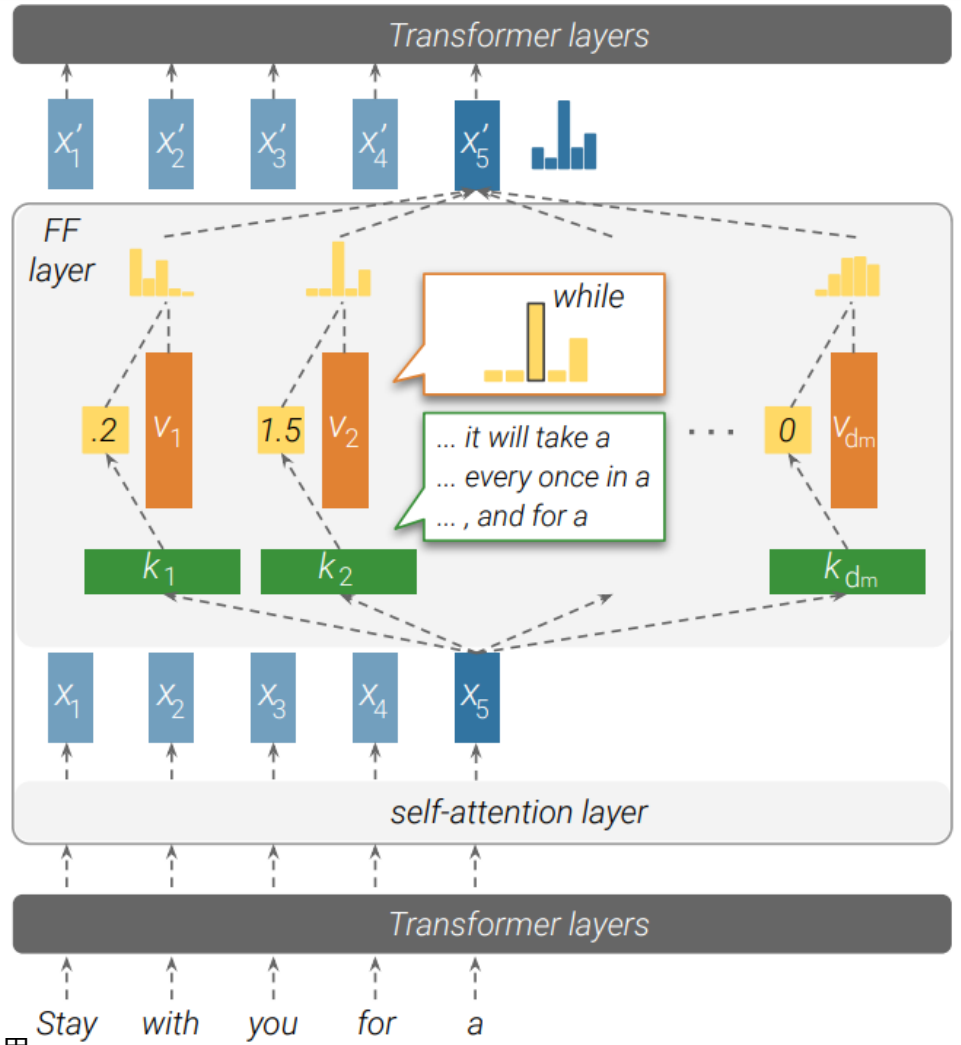
・第一層のパラメータをKey(K)とおく
  ・入力のパターンを抽出
・第二層のパラメータをValue(V)とおく
  ・パターンが何を意味しているか表現

$$\mathrm{FF}(\mathbf{x}) = f(\mathbf{x} \cdot K^\top) \cdot V$$

・ニューラルメモリ（↓）を模倣していると解釈できる

$$\mathrm{MN}(\mathbf{x}) = \mathrm{softmax}(\mathbf{x} \cdot K^\top) \cdot V$$

⇒ 知識を蓄える場所と考えられる.



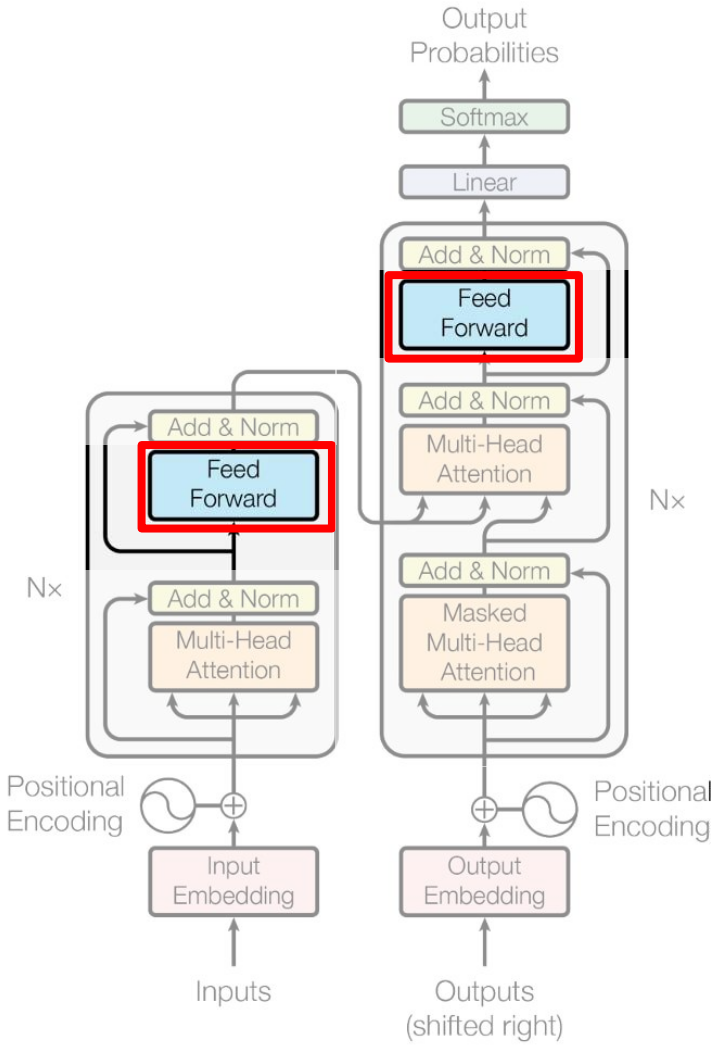
[19] Mor Geva et al. (2021), "Transformer Feed-Forward Layers Are Key-Value Memories", ACL2021 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Feed Forward

各パーツごとに解説



- Embedding
- Multi-Head Attention
- **Feed Forward**
- Others

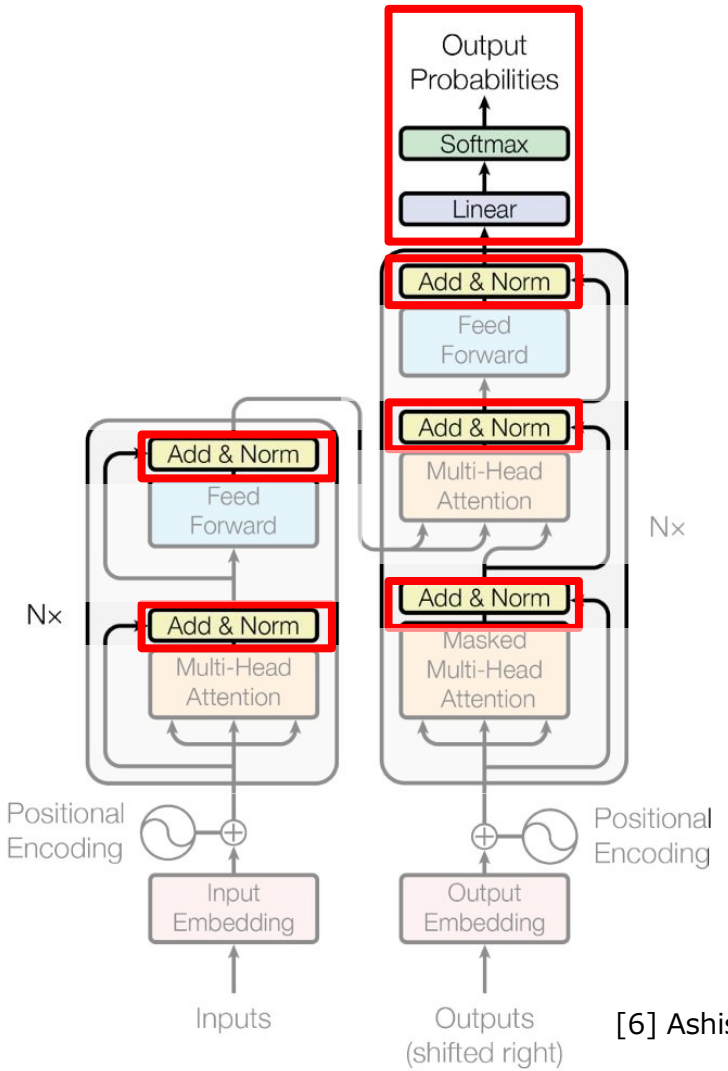
巨大な2階層のMLP
Key-Valueで蓄積した知識を
抽出する機構として考えられている

[6] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Transformerのパーツ | Others

各パーツごとに解説



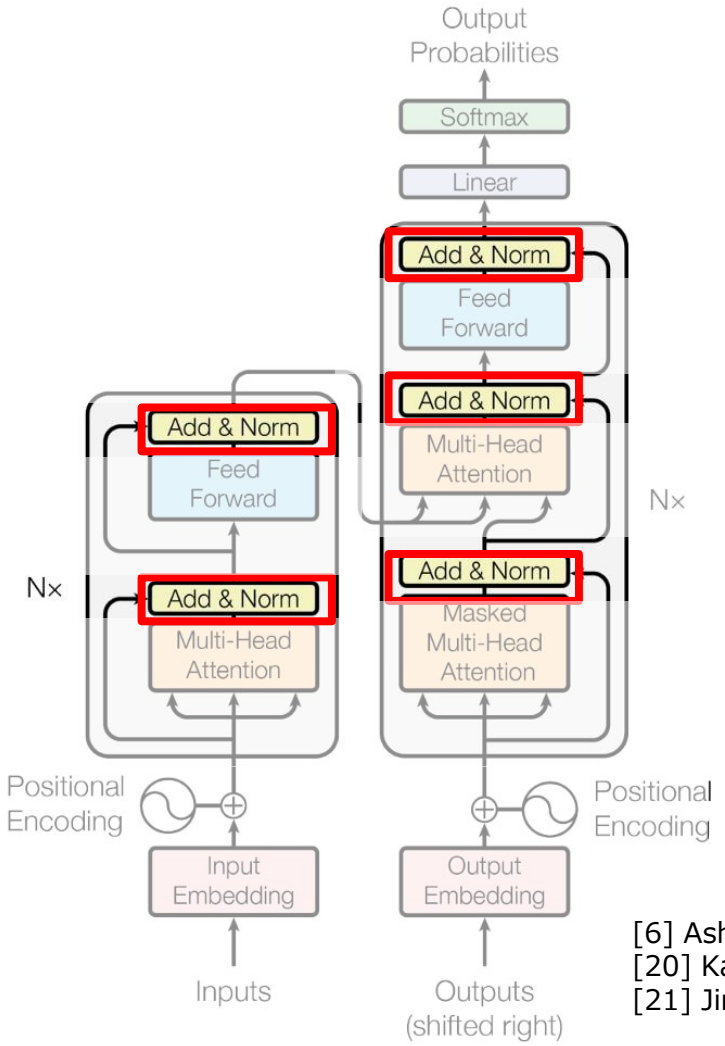
- Embedding
- Multi-Head Attention
- Feed Forward
- **Others**

[6] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | Add & Norm



Add：残差接続(residual connection)
深い層の学習をする時のテクニック
Feed Forward / Attentionの後で適用

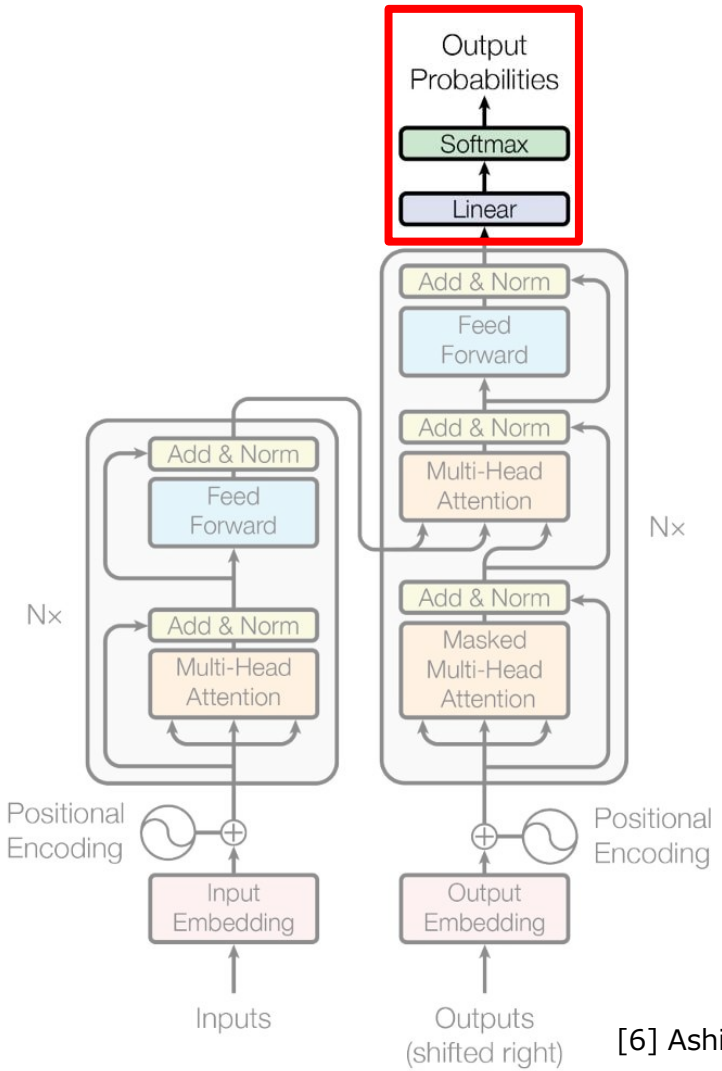
Norm：レイヤ正規化(Layer Normalization)
学習を安定させるテクニック
隠れ層の次元軸で平均と分散をとり
正規化

[6] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用し,一部改変
[20] Kaiming He et al. (2016), "Deep Residual Learning for Image Recognition", IEEE2016 を参考
[21] Jimmy Lei Ba et al. (2016), "Layer Normalization" を参考

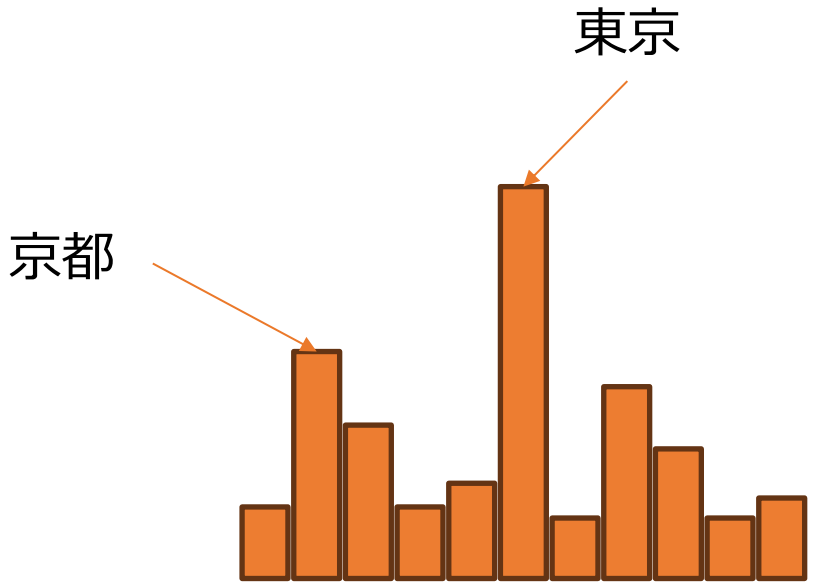
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ | 出力層



- 線形変換後、Softmax関数を適用
- 次の単語の生起確率を出力する

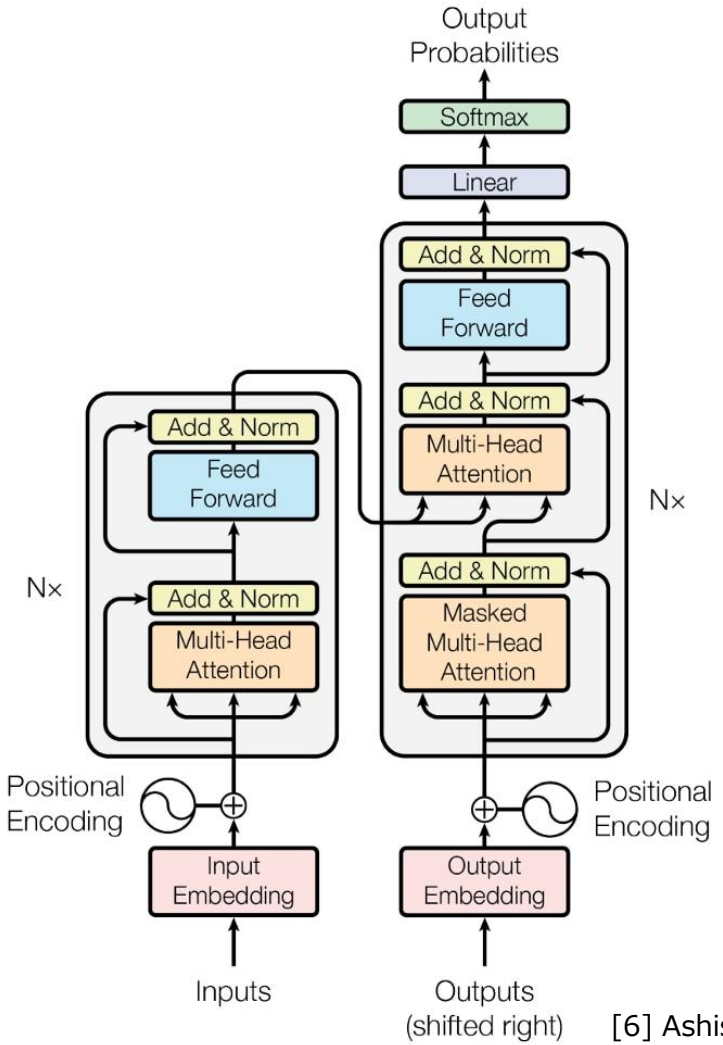


[6] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerのパーツ（復習）



テキストをトークンに分割
Word Embedding（ベクトル）に変換
Positional Encodingと足し合わせて
Transformerに入力

- Embedding

各トークンのベクトルを
他トークンとの関係性を取り込むことで
より良い表現に変換

- Multi-Head Attention
- Feed Forward

巨大な2階層のMLP
Key-Valueで蓄積した知識を
抽出する機構として考えられている

- Others

残差接続
レイヤー正規化
出力層

[6] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

目次

- 言語モデルとは何か？
- Transformer
- **事前学習**
- 発展的話題

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

LLMの学習の流れ

Step 1

事前学習

Day3（本日）

大規模コーパスによる自己教師あり学習を通し、大規模言語モデルに
語彙・文法・基本知識といった基礎的な言語理解を獲得させる段階

Step 2

ファインチューニング

Day6

ラベル付きデータによる教師あり学習を通し、事前学習済みモデルの
性能を改善したり、特定のタスクやドメインへの適応を実現する段階

Step 3

強化学習

Day7

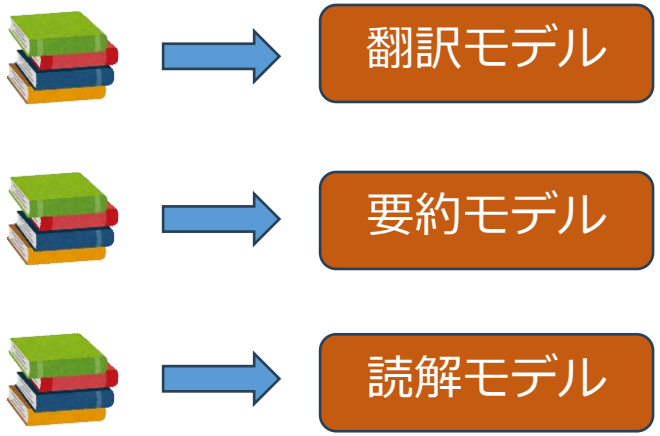
人間からのフィードバックを用い、大規模言語モデルの出力が
より人間の価値観に沿ったものとなるよう調整する段階

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

事前学習とは

LLM以前

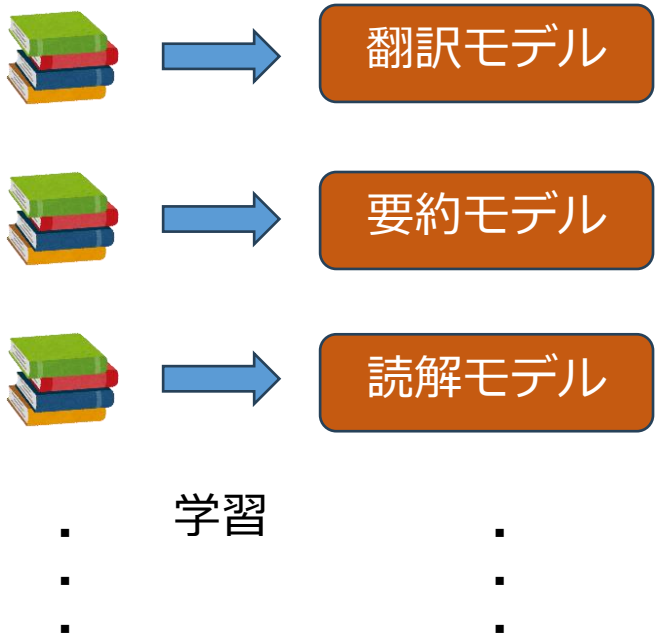


LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

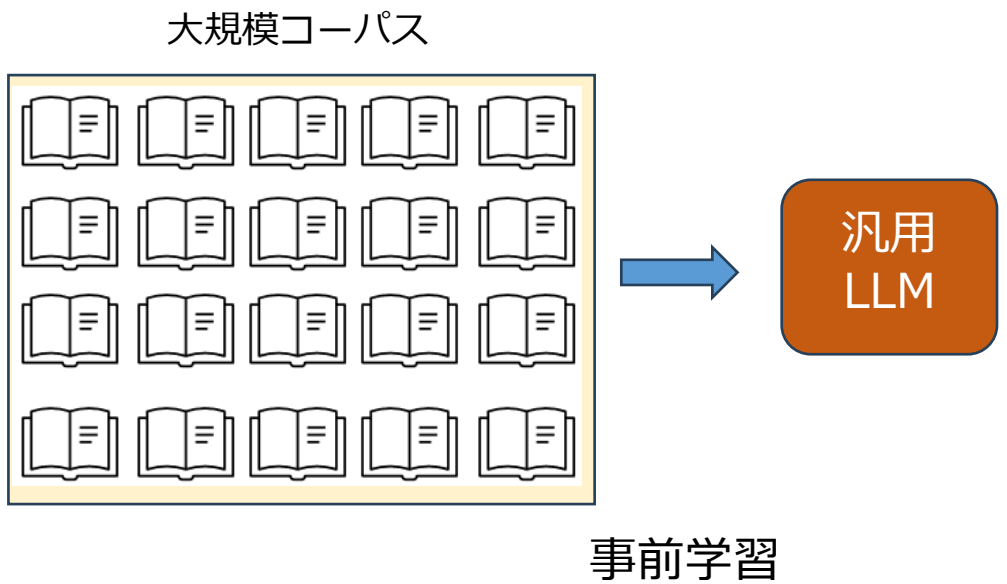
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

事前学習とは

LLM以前



LLM

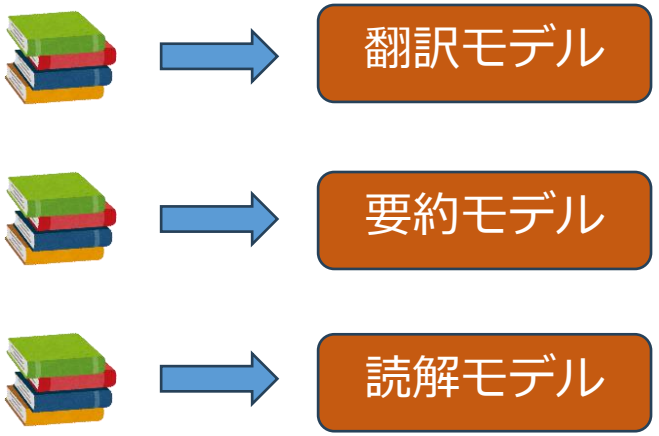


LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

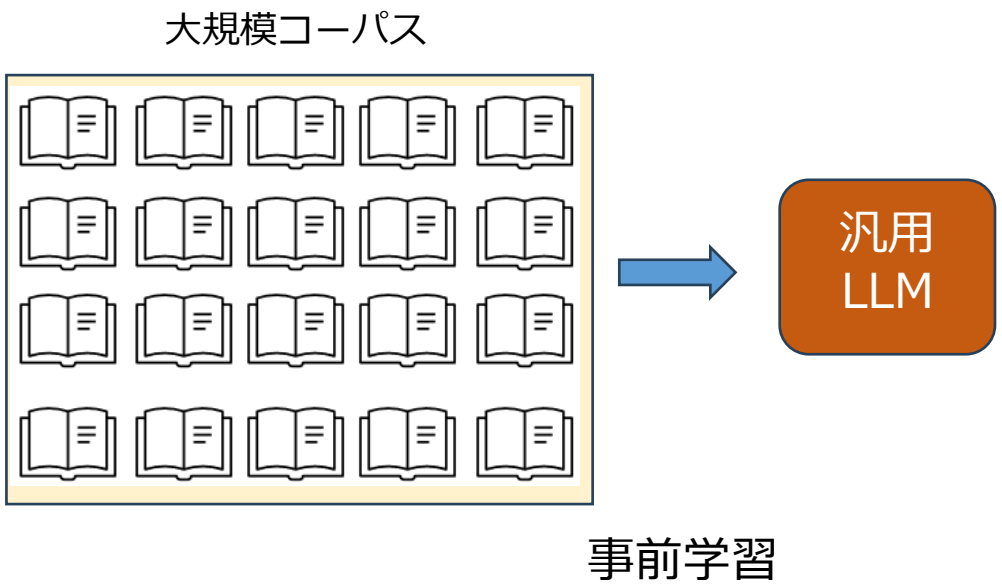
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

事前学習とは

LLM以前



LLM



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

事前学習とは

・事前学習の目的
  ・後続タスクに共通して必要な汎用知識（例：読み書きそろばん）を学習し
    その知識を後続タスクに転移する（c.f. Transfer Learning）
  ・後続タスクのための良いパラメータの初期値が得られるとも解釈できる
    ＊後続タスク：最終的に解きたいタスク（要約, 翻訳, 読解 …）

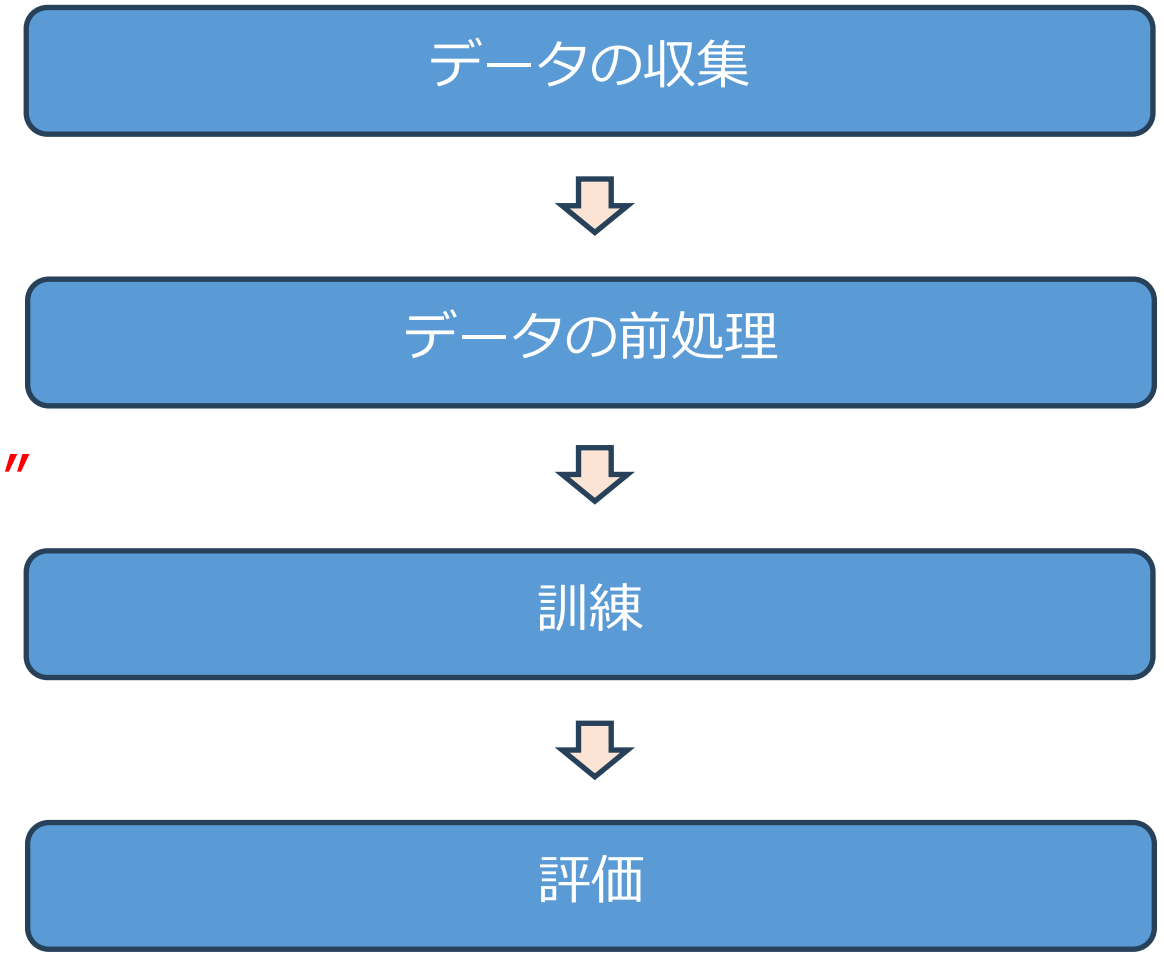
foundation models are enabled by *transfer learning* [Thrun 1998] and *scale*. The idea of transfer learning is to take the "knowledge" learned from one task (e.g., object recognition in images) and apply it to another task (e.g., activity recognition in videos). Within deep learning, *pretraining* is the dominant approach to transfer learning: a model is trained on a surrogate task (often just as a means to an end) and then adapted to the downstream task of interest via *fine-tuning*.

[22] Rishi Bommasani et al. (2021), "On the Opportunities and Risks of Foundation Models"より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

事前学習のパイプライン

詳細な解説は
本資料“発展的話題”
のセクションにて



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

データの収集 | データの構成要素

- 例として、昨年リリースされかつデータソースの割合が公開されているOLMo2の事例が下図
- 事前学習用データは、一般的にWEBからの大規模クロールデータ

一般的なWEBサイト(ニュース, ブログ, HP)

コード

論文

数学特化データ

百科事典

Source	Type	Tokens	Words	Bytes	Docs
Pretraining ✦ OLMo 2 1124 Mix					
DCLM-Baseline	Web pages	3.71T	3.32T	21.32T	2.95B
StarCoder filtered version from OLMoE Mix	Code	83.0B	70.0B	459B	78.7M
peS2o from Dolma 1.7	Academic papers	58.6B	51.1B	413B	38.8M
arXiv	STEM papers	20.8B	19.3B	77.2B	3.95M
OpenWebMath	Math web pages	12.2B	11.1B	47.2B	2.89M
Algebraic Stack	Math proofs code	11.8B	10.8B	44.0B	2.83M
Wikipedia & Wikibooks from Dolma 1.7	Encyclopedic	3.7B	3.16B	16.2B	6.17M
Total		**3.90T**	**3.48T**	**22.38T**	**3.08B**

[12] Allen Institute for AI, Univ. of Washington, NYU (2025), "2 OLMo 2 Furious" より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

データの収集 | データの量

最近のモデルの事前学習トークン数

	トークン数 [兆]
gpt-oss120B	数兆
Llama3.1	15~
DeepSeek-v3	14.8
Qwen3	36
GPT-3	0.5
OLMo 2	3.9

- 1～40兆トークン*のテキストを利用

  *トークン：言語AIが処理することばの単位

  日本語だと大体1文字1トークン

- 書籍でいうと（1冊10万トークンとして）

  1兆トークンは**約1000万冊**に相当

  参考：東大図書館が**1000万冊以上**

  国会図書館が**約4800万冊**

[13] OpenAI (2025), “gpt-oss-120b & gpt-oss-20b Model Card”
[14] Qwen (2025), “Qwen3 Technical Report”
[12] Allen Institute for AI, Univ. of Washington, NYU (2025), “2 OLMo 2 Furious”
[24] Tom Brown et al. (2020), “Language Models are Few-Shot Learners”, NeurIPS2020 より引用
Llama3.1, DeepSeek-v3はHuggingfaceレポジトリの記載を引用

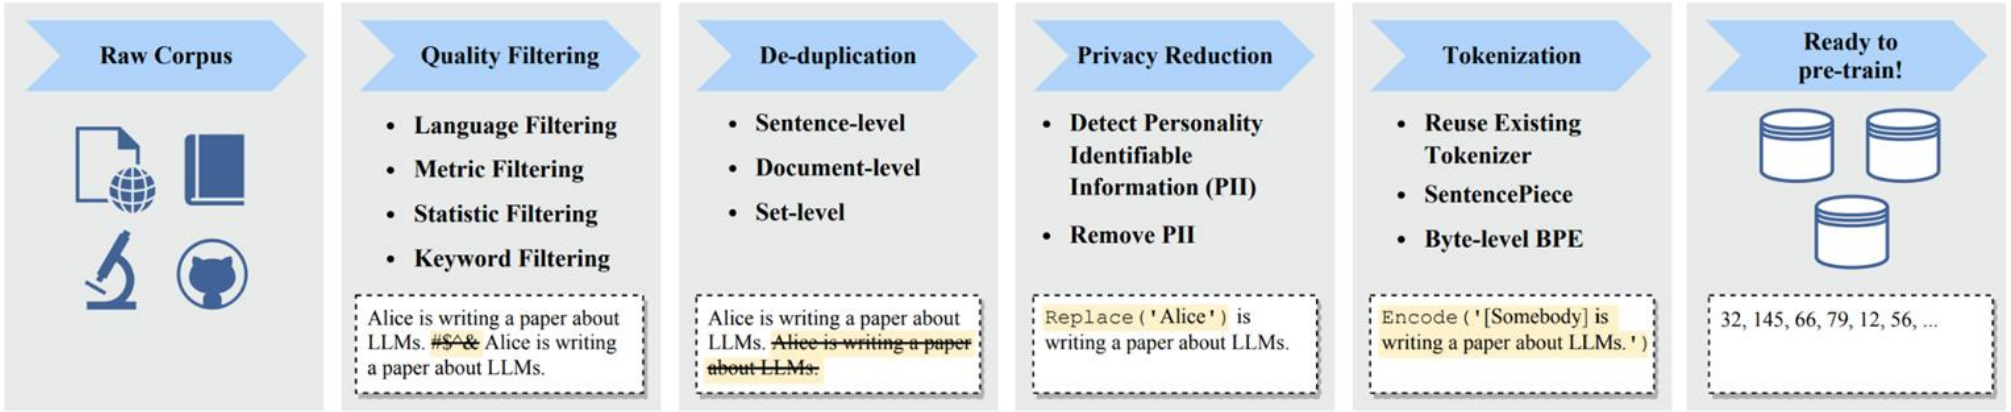
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

データの前処理

LLMの事前学習のおいて典型的な前処理のパイプライン

＊データセットによって前処理の仕組みは異なります.本資料”発展的話題”も参照.



[26] Wayne Xin Zhao et al. (2023), “A Survey of Large Language Models” より引用

- Quality Filtering
  分類器やヒューリスティックにより質の低いデータを取り除く
- De-dup
  近い場所で重複があると学習への悪影響が大きいため、文、文書、データセットなど様々な粒度で重複を排除する
- Privacy Reduction
  個人を特定できる情報を取り除く（＊）
- Tokenization
  （次ページにて説明）

（＊）Our approach relies on a combination of logistic classifiers (content tagging) and regular expressions (**PII detection**). *In practice: We detect and mask email addresses, phone numbers, and IP addresses.*
[25]Luca Soldaini (2023), AI2 Dolma: 3 Trillion Token Open Corpus for LLMs | AI2 Blog

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

データの前処理 | Tokenization：テキストのトークン化

- トークン化：テキストを”トークン“と呼ばれる最小単位に分割すること
- トークナイザー：トークン化を行うためのプログラム
  - 例：Byte Pair Encoding (BPE)、SentencePiece
  - 効率的にトークン化したい → 一般に語彙の出現頻度に基づくアルゴリズムで実現
  - コーパスから定義したアルゴリズムに従ってトークナイザーが語彙辞書を作成した後 トークン化を行う（詳細は本資料”発展的話題”にて解説）

トークン化のイメージ

“吾輩は猫である。”

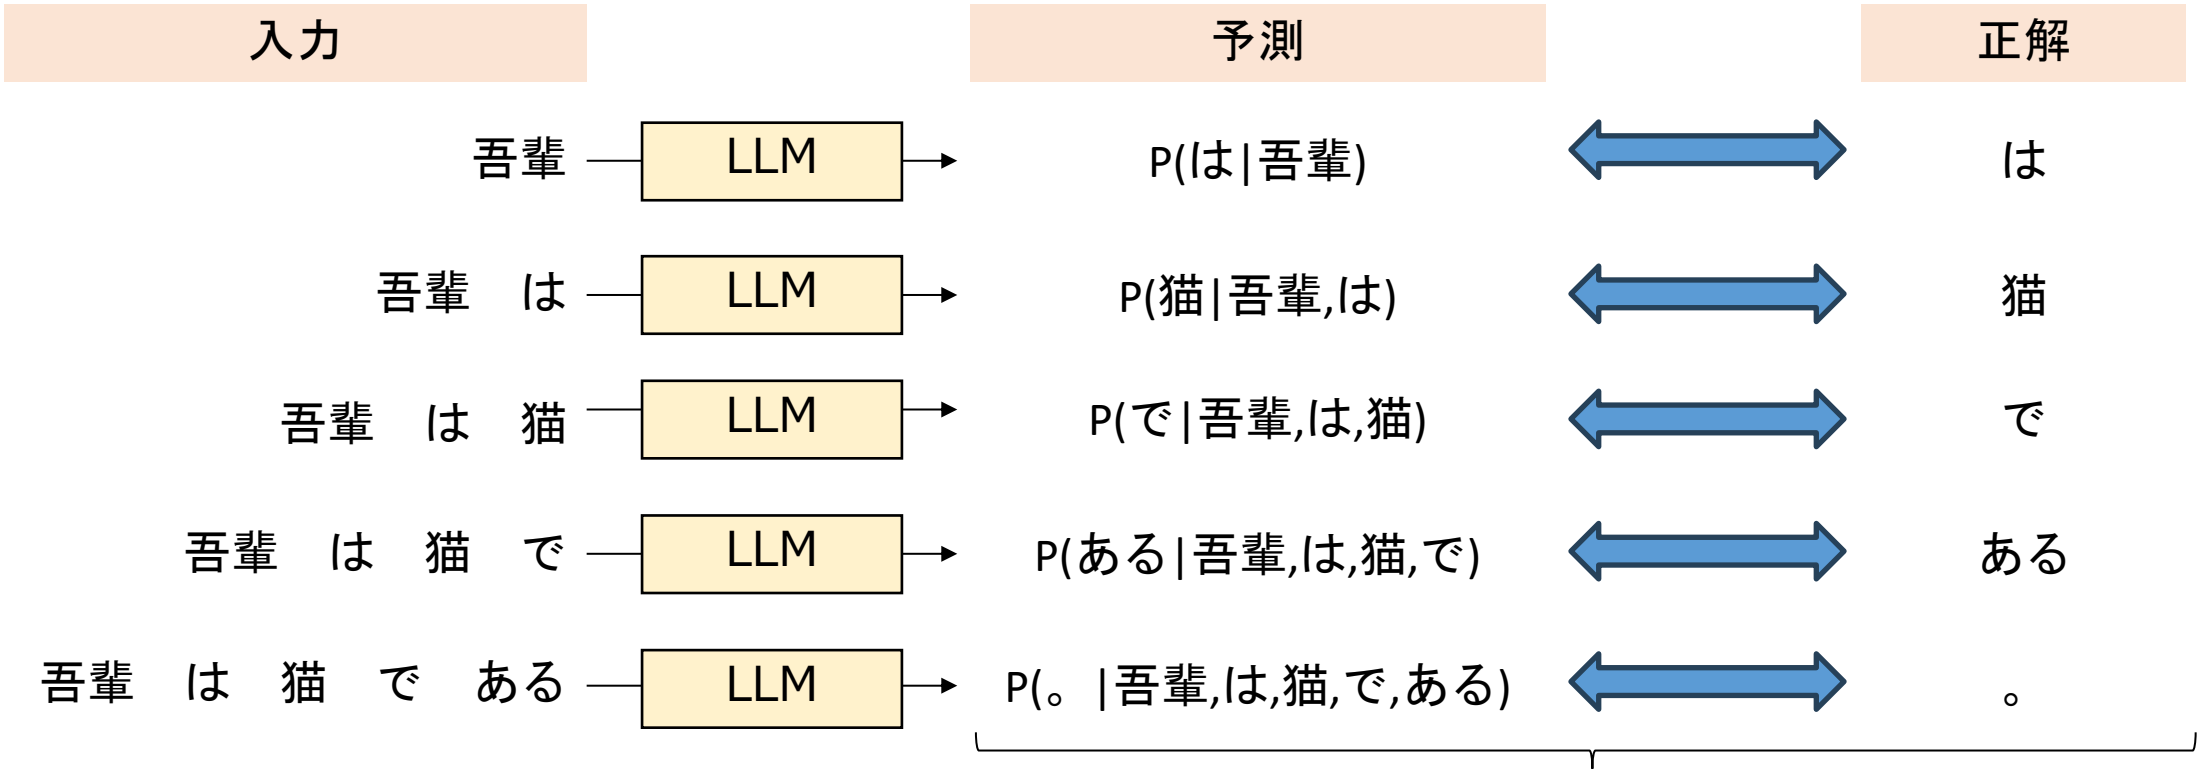
↓

“吾輩”, “は”, “猫”, “で”, “ある”, “。”

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

訓練（事前学習） | Next Token Prediction

- 学習用のテキストデータを使って、次のトークンの生成確率をひたすら予測
- 自己教師あり学習の一種



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

訓練（事前学習） | Next Token Prediction

- 学習用のテキストデータを使い、次トークンの生起確率をひたすら予測
- 予測と正解の誤差（**交差エントロピー**）が小さくなるように学習する
- つまり事前学習の目的関数としてminimize(交差エントロピー)を用いる

$$loss = -\log p(x)$$

$$= -\log p(x_1, x_2, \cdots, x_L)$$

$$= -\sum_l \log p(x_l | x_1, \ldots, x_{l-1})$$

$$= -\sum_l \log p(x_l | x_1, \ldots, x_{l-1})$$

＊上記サンプル文単位の交差エントロピーを、ミニバッチ内で
各サンプル文毎に計算して平均したものをLossとする

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

訓練（事前学習） | Next Token Prediction

- 一般的に1epochのみ学習させる（1～3の範囲）

- **Differences in pretraining.** Finally, we note that Biderman et al. (2023) chooses to perform a partial extra epoch on the deduplicated data to reach 300GT, while we always perform a single epoch. Their setting corresponds to a data-constrained scenario, which is more realistic for the curated data they study; for us, web data is plentiful, so deduplication never truly limits the size of the datasets we can use.

[27] Guilherme Penedo et al.(2023), "The RefinedWeb Dataset for Falcon LLM: Outperforming Curated Corpora with Web Data, and Web Data Only" より引用

Training Details. We train for one epoch over the training data. In earlier experiments, we found that training longer can lead to over-fitting. We use the same optimizer parameters as for the base model. The maximum learning rate is 5×10^{-6} for the 70B parameter LLAMA 2-CHAT and 1×10^{-5} for the rest. The learning rate is decreased on a cosine learning rate schedule, down to 10% of the maximum learning rate. We use a warm-up of 3% of the total number of steps, with a minimum of 5. The effective batch size is kept fixed at 512 pairs, or 1024 rows per batch.

[28] Hugo Touvron et al. (2023), "Llama 2: Open Foundation and Fine-Tuned Chat Models" より引用

[23]

Dataset	Sampling prop.	Epochs	Disk size
CommonCrawl	67.0%	1.10	3.3 TB
C4	15.0%	1.06	783 GB
Github	4.5%	0.64	328 GB
Wikipedia	4.5%	2.45	83 GB
Books	4.5%	2.23	85 GB
ArXiv	2.5%	1.06	92 GB
StackExchange	2.0%	1.03	78 GB

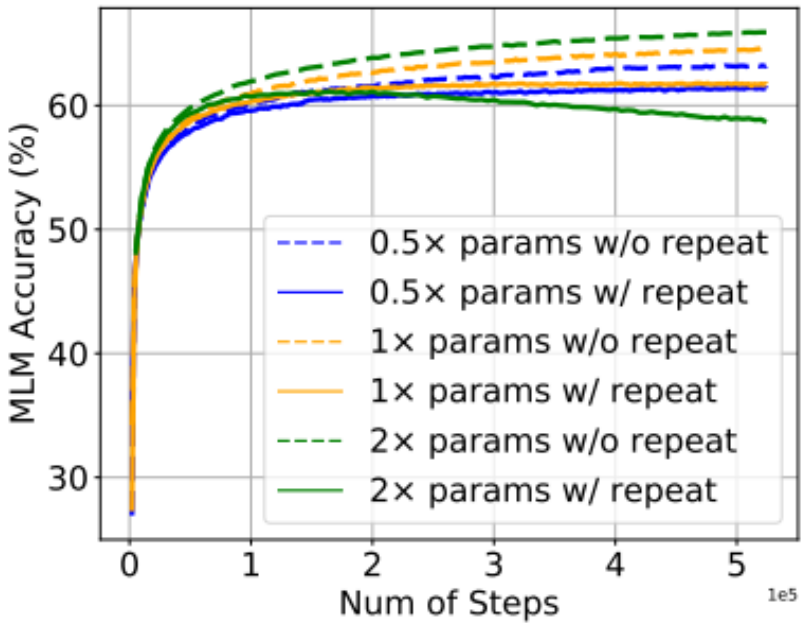
[23] Hugo Touvron et al. (2023), "LLaMA: Open and Efficient Foundation Language Models" より引用

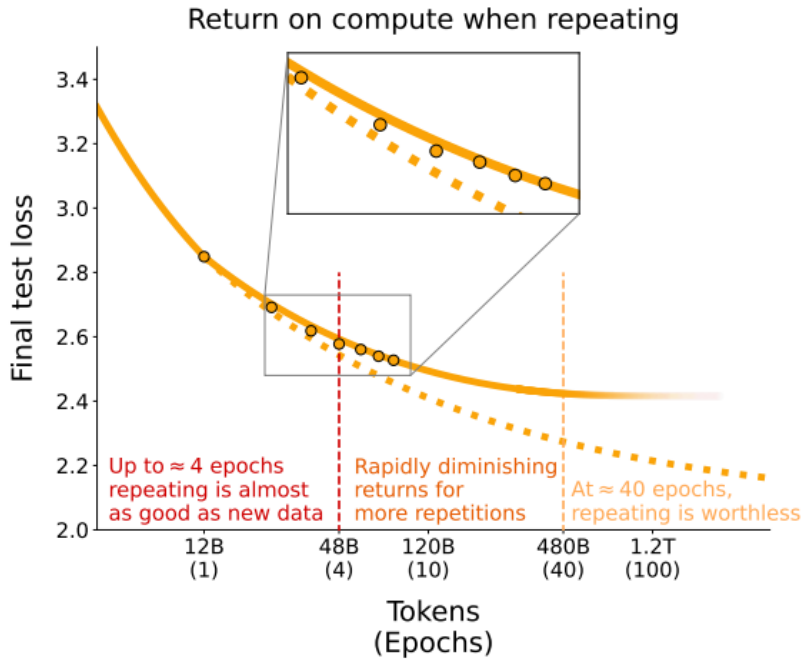
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

訓練（事前学習） | Next Token Prediction

- 一般的に1epochのみ学習させる（1～3の範囲）
- 複数epoch学習しすぎると, 過学習となりdegredationするか、差がない
- モデルサイズが大きくなるほどdegredationの傾向が強くなる





[29] Fuzhao Xue et al. (2023), “To Repeat or Not To Repeat: Insights from Scaling LLM under Token-Crisis” より引用(左図)
[30] Niklas Muennighoff et al. (2023), “Scaling Data-Constrained Language Models”より引用(右図)

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

訓練（事前学習） | Next Token Prediction

- 原理的には簡単だが、実際にやってみると難しい
- 小規模なモデルの訓練だと発生しないが、大規模なモデルでの学習(+複数ノードでの分散学習)を行うと発生する現象
  - 交差エントロピーの発散（Lossのスパイク）
  - ハードウェア、ネットワークなど低レイヤでのエラー




```
2021-12-21 19:39:23 ERROR nccl | node-77: max bandwidth 145.15 below threshold 180
2021-12-21 19:39:23 ERROR nccl | node-80: max bandwidth 145.67 below threshold 180
2021-12-21 19:39:23 ERROR nccl | node-85: max bandwidth 149.82 below threshold 180
2021-12-21 19:39:23 ERROR nccl | node-86: max bandwidth 149.54 below threshold 180
2021-12-21 19:39:23 ERROR nccl | node-87: max bandwidth 144.02 below threshold 180
2021-12-21 19:39:23 ERROR nccl | node-93: max bandwidth 144.57 below threshold 180
2021-12-21 19:39:23 ERROR nccl | node-94: max bandwidth 140.92 below threshold 180
2021-12-21 19:39:23 ERROR nccl | node-95: max bandwidth 146.5 below threshold 180
2021-12-21 19:39:23 ERROR nccl | node-97: max bandwidth 146.5 below threshold 180
2021-12-21 19:39:23 ERROR nccl | node-98: max bandwidth 143.02 below threshold 180
2021-12-21 19:39:23 ERROR nccl | node-124: max bandwidth 148.34 below threshold 180
```

計算する数値フォーマットによっても安定性が変わる（近年はbfloat16が主流）

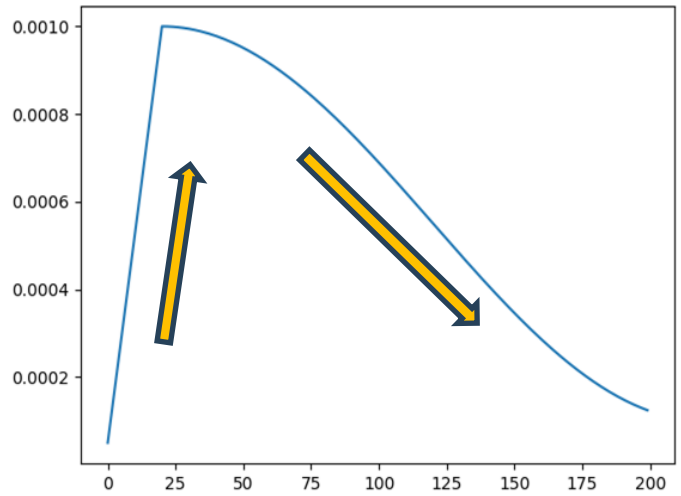
[31] Stas Bekman (2022) The Technology Behind BLOOM Training より引用(左図)
[32] suchenxang (2023), metaseq/projects/OPT/chronicles/OPT175B_Logbook.pdf at main · facebookresearch/metaseq · GitHub より引用(右図)

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

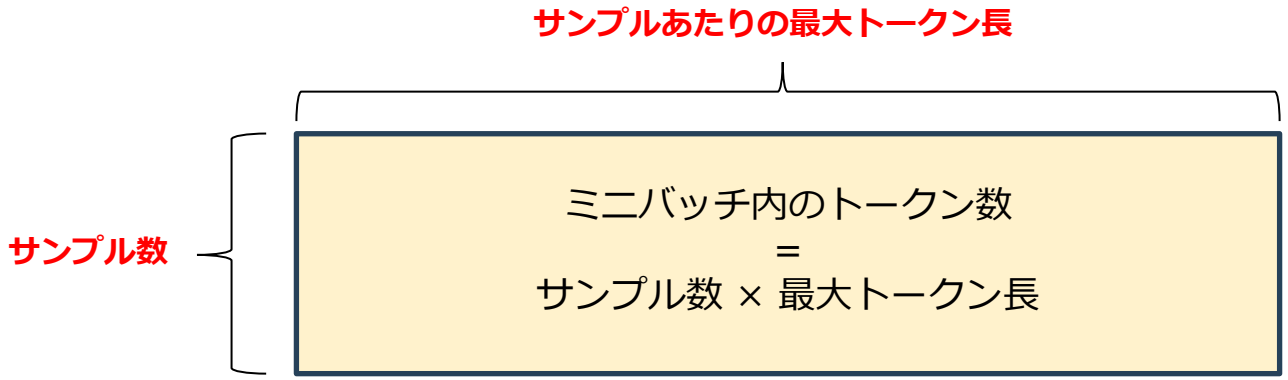
訓練（事前学習） | ハイパーパラメータの例

- Optimizer: Adam[33], AdamW[34]
- Scheduler: Learning RateのWarmup + Decay
- 浮動小数点精度：近年はBF16が主流
- Batch Size: 数百万トークンが一般的



params	dimension	n heads	n layers	learning rate	batch size	n tokens
6.7B	4096	32	32	$3.0e^{-4}$	4M	1.0T
13.0B	5120	40	40	$3.0e^{-4}$	4M	1.0T
32.5B	6656	52	60	$1.5e^{-4}$	4M	1.4T
65.2B	8192	64	80	$1.5e^{-4}$	4M	1.4T

Table 2: **Model sizes, architectures, and optimization hyper-parameters.**



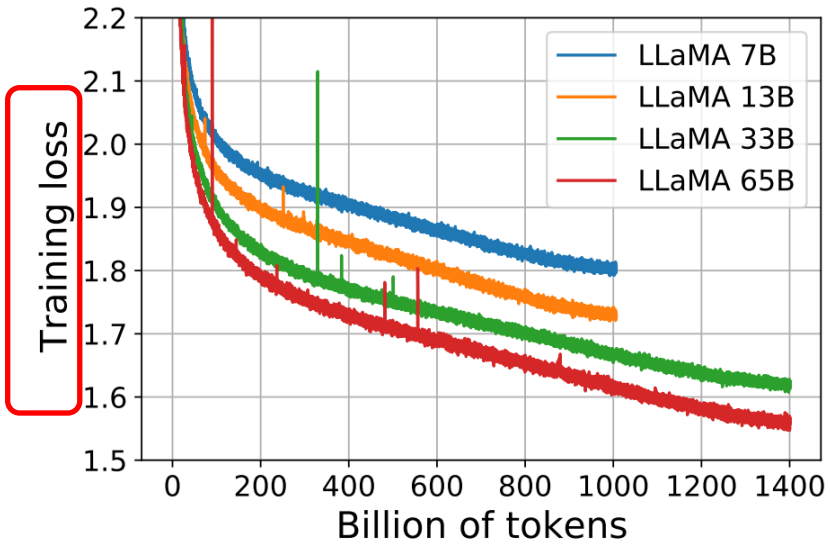
[33] Diederik P. Kingma & Jimmy Ba, (2014), “Adam: A Method for Stochastic Optimization”を参考
[34] Ilya Loshchilov & Frank Hutter, (2017), “Decoupled Weight Decay Regularization”, を参考
[23] Hugo Touvron et al. (2023), “LLaMA: Open and Efficient Foundation Language Models” より引用し,一部改変(左下表)
[35] Shikoan’s ML Blog (2021), Cosine DecayとWarmupを同時にこなすスケジューラー（timm）| Shikoan’s ML Blog より引用し,一部改変(右上図)

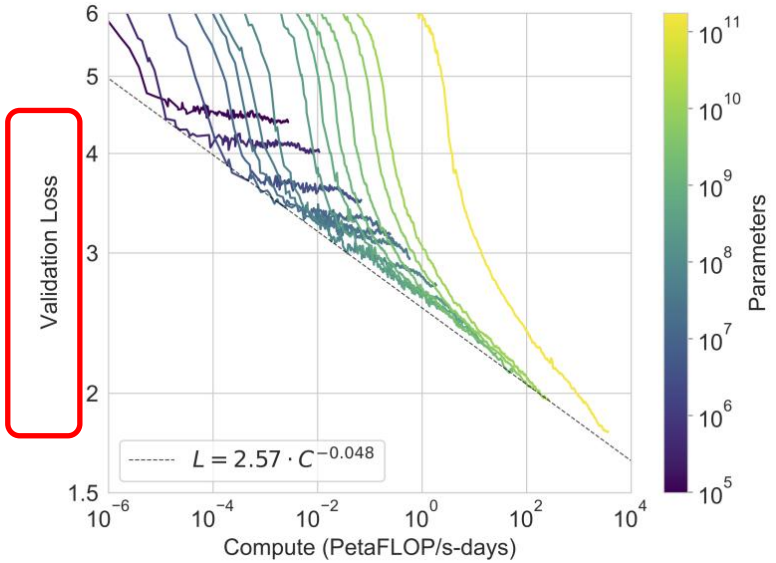
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

評価 | 定量評価（Upstream）

- 交差エントロピーのValidation Loss:
  - Lossが下がっているか(事前学習自体が崩壊していないか)をモニタ
  - モデルごとのパフォーマンスの違いを確認する
  - Test Lossは論文上では(ほとんど)見ない *事前学習は, 1エポック学習が一般的なのでOverfitしない前提だから？
  - 場合によっては, Training Lossだけで完結していることも多い.



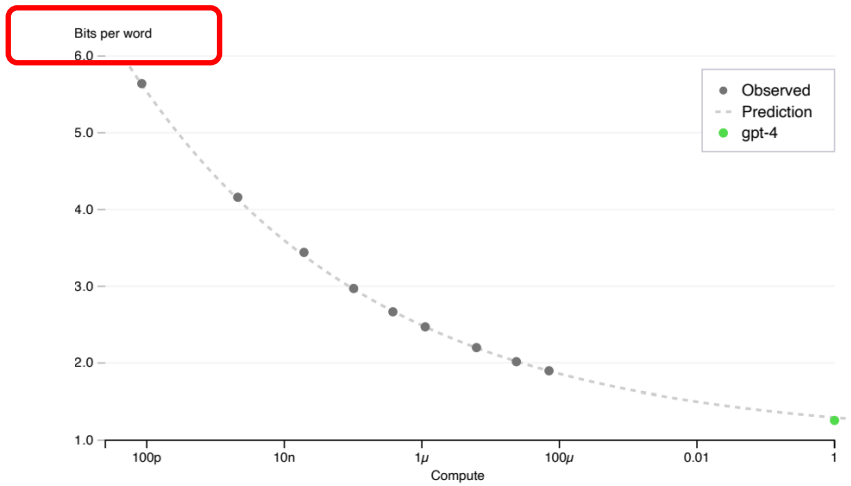


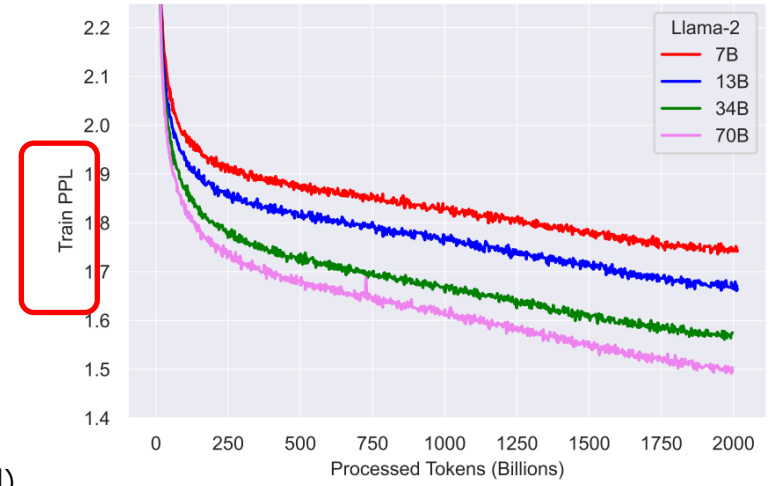
[23] Hugo Touvron et al. (2023), “LLaMA: Open and Efficient Foundation Language Models” より引用し,一部改変(左図)
[24] Tom Brown et al. (2020), “Language Models are Few-Shot Learners”,のarXiv版より引用(右図)

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

評価 | 定量評価（Upstream）

- 交差エントロピーの様々な呼び方
  - 交差エントロピー
  - Cross Entropy Loss
  - CELoss
- 式変形したら交差エントロピーと実質同じ指標.
  - Perplexity (PPL)
  - Bits-Per-Character (BPC)
  - Bits-Per-Word (BPW)





[7] OpenAI (2023) “GPT-4 Technical Report”より引用し,一部改変(右上図)
[28] Hugo Touvron et al. (2023), “Llama 2: Open Foundation and Fine-Tuned Chat Models” より引用し,一部改変(右下図)
参考：[36] Chip Huyen (2019), Evaluation Metrics for Language Modeling

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

評価 | 定量評価（Downstream）

- 様々な下流タスク(最終的に解きたいタスク) (*1)で評価
- In-Context Learning (Zero-shot, Few-shot) (*2)で評価することが多い
- 事後学習(ファインチューニングやRLHF) (*3)で下流タスク性能は更に向上

(*1) 本講義の“発展的話題”に評価ベンチマークについての説明あり． (*2) Day2を復習してください． (*3) Day5,Day7で説明する予定です．

下流タスク

			Fine-tune		Zero-Shot								One-Shot								Few-Shot								
Name	Metric	Split	SOTA	K	Small	Med	Large	XL	2.7B	6.7B	13B	175B	Small	Med	Large	XL	2.7B	6.7B	13B	175B	Small	Med	Large	XL	2.7B	6.7B	13B	175B	175B (test server)
HellaSwag	acc	dev	85.6	20	33.7	43.6	51.0	54.7	62.8	67.4	70.9	78.9	33.0	42.9	50.5	53.5	61.9	66.5	70.0	78.1	33.5	43.1	51.3	54.9	62.9	67.3	71.3	79.3	
LAMBADA	acc	test	68.0	15	42.7	54.3	60.4	63.6	67.1	70.3	72.5	76.2	22.0	47.1	52.6	58.3	61.1	65.4	69.0	72.5	22.0	40.4	63.2	57.0	78.1	79.1	81.3	86.4	
LAMBADA	ppl	test	8.63	15	18.6	9.09	6.53	5.44	4.60	4.00	3.56	3.00	165.0	11.6	8.29	6.46	5.53	4.61	4.06	3.35	165.0	27.6	6.63	7.45	2.89	2.56	2.56	1.92	
StoryCloze	acc	test	91.8	70	63.3	68.5	72.4	73.4	77.2	77.7	79.5	83.2	62.3	68.7	72.3	74.2	77.3	78.7	79.7	84.7	62.3	70.2	73.9	76.1	80.2	81.2	83.0	87.7	
NQs	acc	test	44.5	64	0.64	1.75	2.71	4.40	6.01	5.79	7.84	14.6	1.19	3.07	4.79	5.43	8.73	9.78	13.7	23.0	1.72	4.46	7.89	9.72	13.2	17.0	21.0	29.9	
TriviaQA	acc	dev	68.0	64	4.15	7.61	14.0	19.7	31.3	38.7	41.8	64.3	4.19	12.9	20.5	26.5	35.9	44.4	51.3	68.0	6.96	16.3	26.5	32.1	42.3	51.6	57.5	71.2	71.2
WebQs	acc	test	45.5	64	1.77	3.20	4.33	4.63	7.92	7.73	8.22	14.4	2.56	6.20	8.51	9.15	14.5	15.1	19.0	25.3	5.46	12.6	15.9	19.6	24.8	27.7	33.5	41.5	
Ro→En 16	BLEU-mb	test	39.9	64	2.08	2.71	3.09	3.15	16.3	8.34	20.2	19.9	0.55	15.4	23.0	26.3	30.6	33.2	35.6	38.6	1.25	20.7	25.8	29.2	33.1	34.8	37.0	39.5	
Ro→En 16	BLEU-sb	test		64	2.39	3.08	3.49	3.56	16.8	8.75	20.8	20.9	0.65	15.9	23.6	26.8	31.3	34.2	36.7	40.0	1.40	21.3	26.6	30.1	34.3	36.2	38.4	41.3	
En→Ro 16	BLEU-mb	test	38.5	64	2.14	2.65	2.53	2.50	3.46	4.24	5.32	14.1	0.35	3.30	7.89	8.72	13.2	15.1	17.3	20.6	1.25	5.90	9.33	10.7	14.3	16.3	18.0	21.0	
En→Ro 16	BLEU-sb	test		64	2.61	3.11	3.07	3.09	4.26	5.31	6.43	18.0	0.55	3.90	9.15	10.3	15.7	18.2	20.8	24.9	1.64	7.40	10.9	12.9	17.2	19.6	21.8	25.8	
Fr→En 14	BLEU-mb	test	35.0	64	1.81	2.53	3.47	3.13	20.6	15.1	21.8	21.2	1.28	15.9	23.7	26.3	29.0	30.5	30.2	33.7	4.98	25.5	28.5	31.1	33.7	34.9	36.6	39.2	
Fr→En 14	BLEU-sb	test		64	2.29	2.99	3.90	3.60	21.2	15.5	22.4	21.9	1.50	16.3	24.4	27.0	30.0	31.6	31.4	35.6	5.30	26.2	29.5	32.2	35.1	36.4	38.3	41.4	
En→Fr 14	BLEU-mb	test	45.6	64	1.74	2.16	2.73	2.15	15.1	8.82	12.0	25.2	0.49	8.00	14.8	15.9	20.3	23.3	24.9	28.3	4.08	14.5	19.3	21.5	24.9	27.3	29.5	32.6	
En→Fr 14	BLEU-sb	test	45.9	64	2.44	2.75	3.54	2.82	19.3	11.4	15.3	31.3	0.81	10.0	18.2	19.3	24.7	28.3	30.1	34.1	5.31	18.0	23.6	26.1	30.3	33.3	35.5	39.9	
De→En 16	BLEU-mb	test	40.2	64	2.06	2.87	3.41	3.63	21.5	17.3	23.0	27.2	0.83	16.2	22.5	24.7	28.2	30.7	33.0	30.4	3.25	22.7	26.2	29.2	32.7	34.8	37.3	40.6	
De→En 16	BLEU-sb	test		64	2.39	3.27	3.85	4.04	22.5	18.2	24.4	28.6	0.93	17.1	23.4	25.8	29.2	31.9	34.5	32.1	3.60	23.8	27.5	30.5	34.1	36.5	39.1	43.0	
En→De 16	BLEU-mb	test	41.2	64	1.70	2.27	2.31	2.43	12.9	8.66	10.4	24.6	0.50	7.00	12.9	13.1	18.3	20.9	22.5	26.2	3.42	12.3	15.4	17.1	20.9	23.0	26.6	29.7	
En→De 16	BLEU-sb	test	41.2	64	2.09	2.65	2.75	2.92	13.7	9.36	11.0	25.3	0.54	7.40	13.4	13.4	18.8	21.7	23.3	27.3	3.78	12.9	16.1	17.7	21.7	24.1	27.7	30.9	
Winograd	acc	test	93.8	7	66.3	72.9	74.7	76.9	82.4	85.7	87.9	88.3	63.4	68.5	72.9	76.9	82.4	84.6	86.1	89.7	63.4	67.4	73.6	76.9	84.3	85.4	82.4	88.6	
Winogrande	acc	dev	84.6	50	52.0	52.1	57.4	58.7	62.3	64.5	67.9	70.2	51.3	53.0	58.3	59.1	61.7	65.8	66.9	73.2	51.3	52.6	57.5	59.1	62.6	67.4	70.0	77.7	
PIQA	acc	dev	77.1	50	64.6	70.2	72.9	75.1	75.6	78.0	78.5	81.0	64.3	69.3	71.8	74.4	74.3	76.3	77.8	80.5	64.3	69.4	72.0	74.3	75.4	77.8	79.9	82.3	82.8

[24] Tom Brown et al. (2020), “Language Models are Few-Shot Learners”のarXiv版 より一部を抜粋し,改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

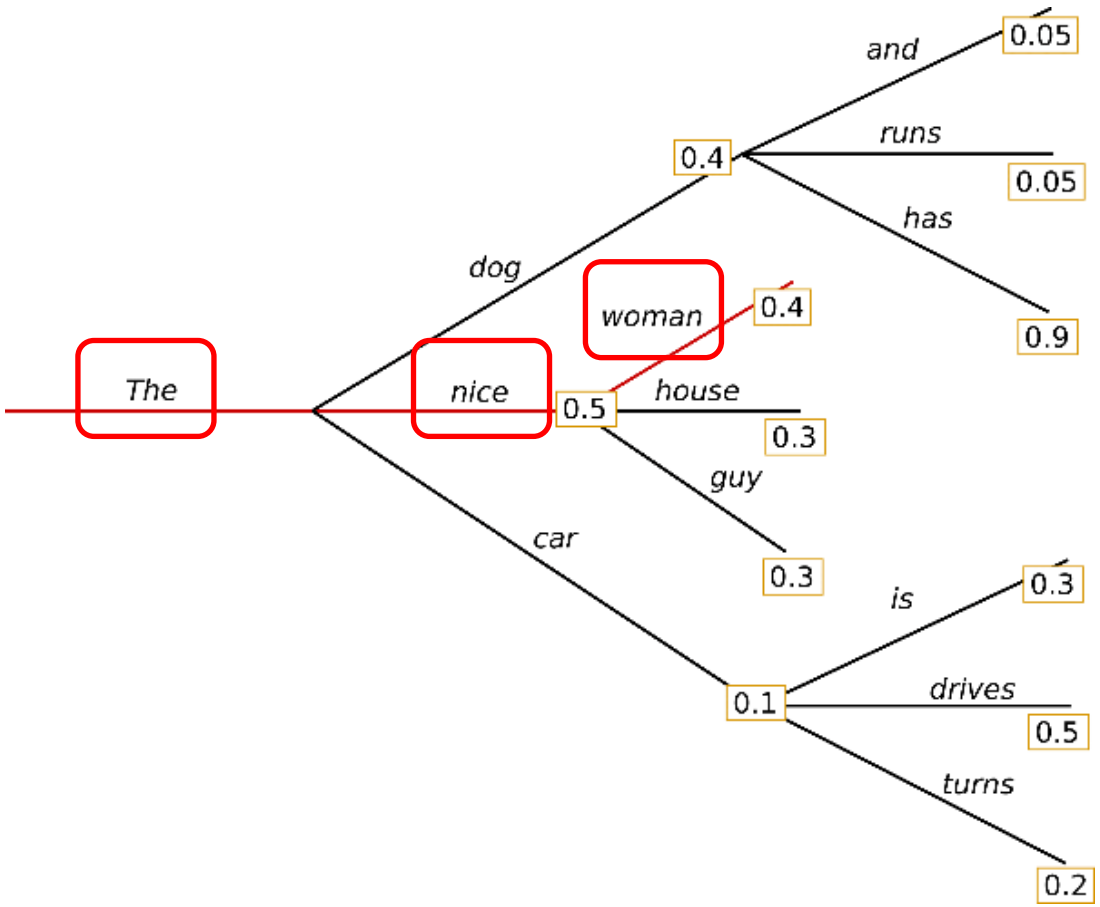
評価 | 定性評価（サンプル評価）

- 事前学習済みLLMを使って, テキストを出力（デコード）してみる
- デコードには様々な方式が存在する
  - Greedy Decoding
  - Beam Search
  - Random Sampling

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

評価 | 事前学習済モデルによるテキストの生成（デコード）方法

- デコード方式①：Greedy Decoding
  - 生起確率が一番高い次のトークンを逐一選んでいく



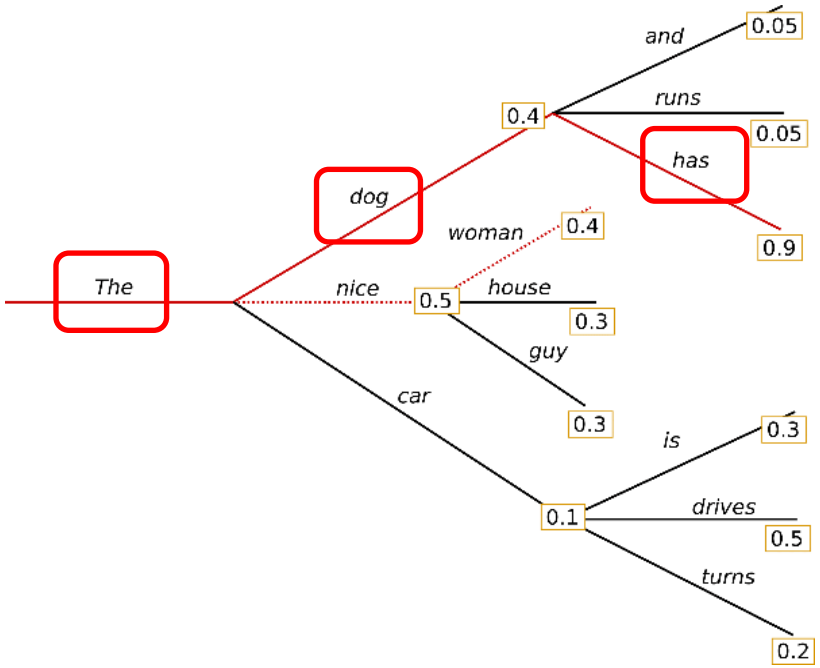
[37] Kaito Sugimoto (2021) テキスト生成における decoding テクニック: Greedy search, Beam search, Top-K, Top-p より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

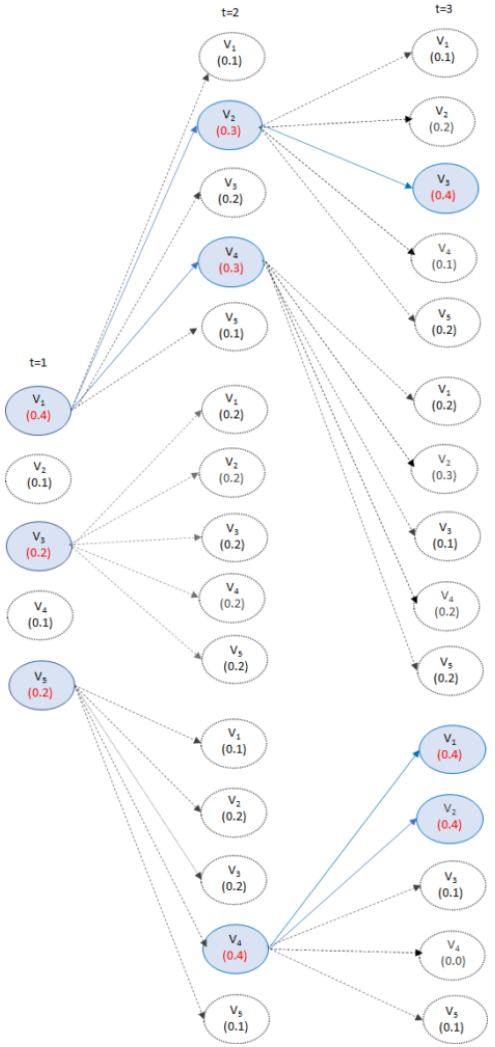
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

評価 | 事前学習済モデルによるテキストの生成（デコード）方法

- デコード方式②： Beam Search
  - 高い生起確率となるようなトークン**系列**を探索して見つける
    直近だけじゃなくその先まで見て決める
  - ただし全系列を探索(Exhaustive Search)すると計算量が爆発
    事前に決めておいたビームサイズ内で探索する



ビームサイズ=3の場合



[37] Kaito Sugimoto (2021) テキスト生成における decoding テクニック: Greedy search, Beam search, Top-K, Top-p より引用し,一部改変
[38] mm_0824 (2020) ビームサーチ(Beam Search)を理解する | 楽しみながら理解するAI・機械学習入門より引用(右図)

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

評価 | 事前学習済モデルによるテキストの生成（デコード）方法

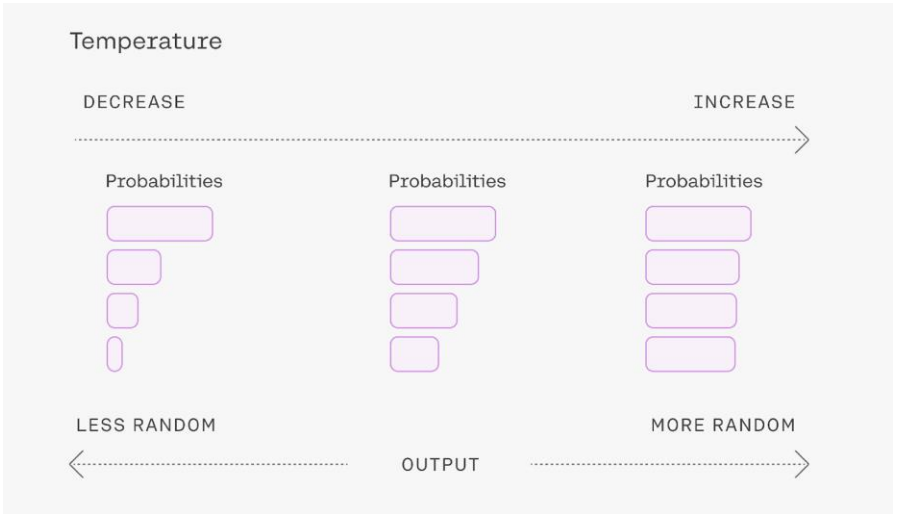
- デコード方式③：Random Sampling
  - 次のトークンの生起確率分布に従い, ランダムに選択する.
    - Top_p: 上位p%のトークンから選択する. (例) 0.9
    - Top_k: 上位k個のトークンから選択する. (例) 10
  - Temperature: 0以上の実数(スカラー値). Softmax手前のLogitの分母にかける. Temperature = 1だと普通のSoftmaxと同じ.

SOFTMAX WITHOUT TEMPERATURE (T=1)

$$\frac{e^{z_i}}{\sum_j e^{z_j}}$$

SOFTMAX WITH TEMPERATURE

$$\frac{e^{z_i/T}}{\sum_j e^{z_j/T}}$$



[39] cohere, Temperature より引用
[68] Harshit Sharma (2022), "Softmax Temperature" より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

評価 | 事前学習済モデルによるテキストの生成（デコード）方法

- 状況により望ましいデコード方式は変わる
  - 分類問題を解く場合は, 決定的な解答をするgreedy Decodingが好まれる
  - Beam Searchは機械翻訳のタスクを解くときに見ることが多い
  - 長文生成をする場合は, random samplingを行うことが多い

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

目次

- 言語モデルとは何か？
- Transformer
- 事前学習
- **発展的話題**

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

発展的話題

データ	• 主要なデータセット • データ処理(クレンジング、トークナイズ)
モデル	• 主要なモデル • アーキテクチャの構成要素
学習	• Attention • 目的関数
評価、分析	• 評価 • 分析

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

発展的話題

データ	• 主要なデータセット • データ処理(クレンジング、トークナイズ)
モデル	• 主要なモデル • アーキテクチャの構成要素
学習	• Attention • 目的関数
評価、分析	• 評価 • 分析

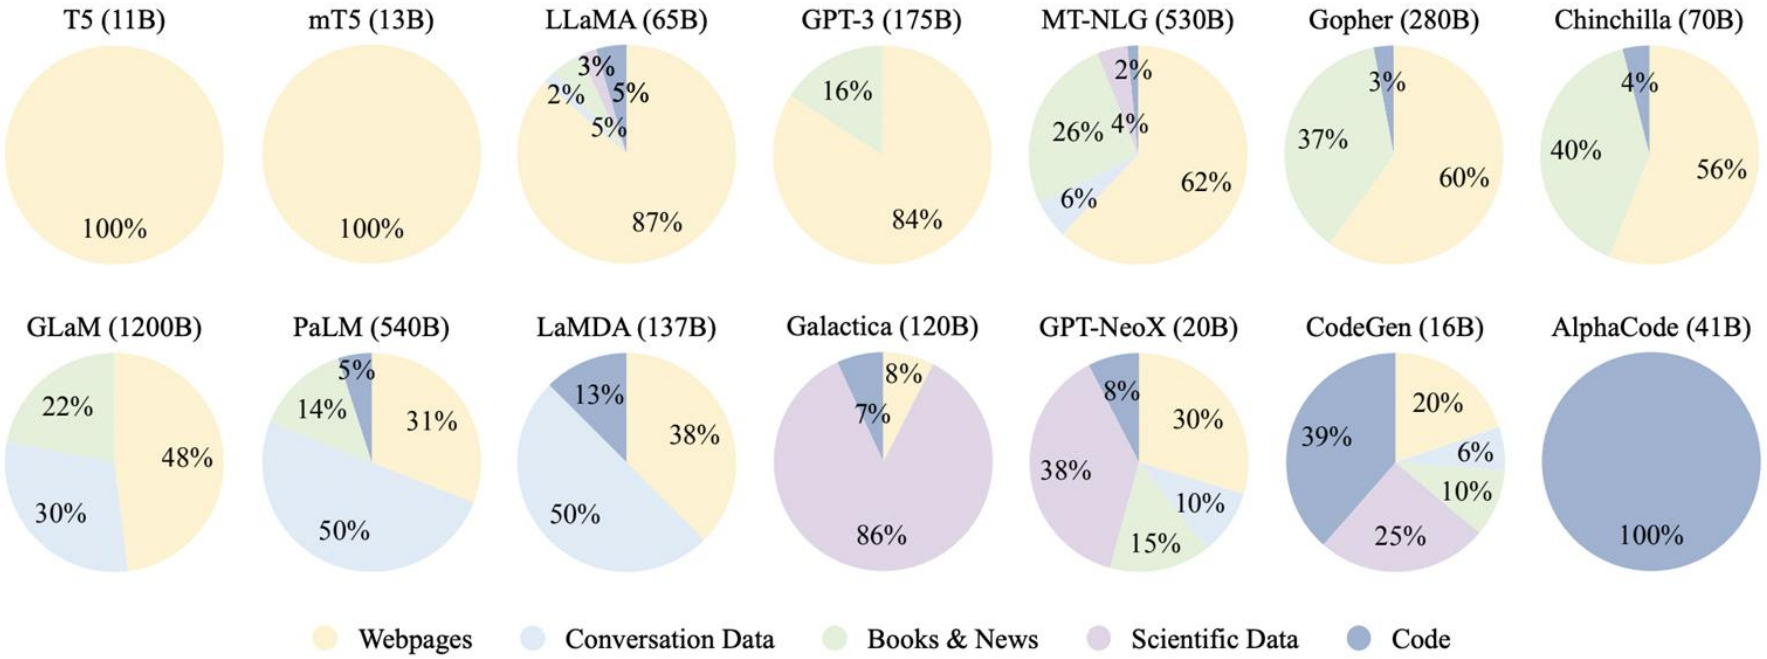
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

学習に用いるデータセットの変遷

“A Survey of Large Language Models”, 2023

■ 主要なモデルの学習データの構成



- GPT-2ではWebページのコーパス(約40GB)のみで学習を行っていた
- 近年はCodeや会話データなど多様なデータで学習するモデルが増加

[26] Wayne Xin Zhao et al. (2023), “A Survey of Large Language Models” より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

C4 | フィルタリングされた巨大なWebページ英語コーパス

"Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer", 2019

■ C4由来のデータセットと既存のデータセットで学習した場合の性能の比較

Data set	Size	GLUE	CNNDM	SQuAD	SGLUE	EnDe	EnFr	EnRo
★C4	745GB	83.28	**19.24**	80.88	71.36	**26.98**	**39.82**	**27.65**
C4, unfiltered	6.1TB	81.46	19.14	78.78	68.04	26.55	39.34	27.21
RealNews-like	35GB	**83.83**	**19.23**	80.39	72.38	**26.75**	**39.90**	**27.48**
WebText-like	17GB	**84.03**	**19.31**	**81.42**	71.40	**26.80**	**39.74**	**27.59**
Wikipedia	16GB	81.85	**19.31**	81.29	68.01	**26.94**	39.69	**27.67**
Wikipedia + TBC	20GB	83.65	**19.28**	**82.08**	**73.24**	**26.77**	39.63	**27.57**

C4由来のデータセット

既存のデータセット

[41] Colin Raffel et al. (2020), "Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer" より引用し,一部改変

- Common Crawl…一般に公開されているウェブアーカイブをスクレイピングして収集したデータセット。月当たり約20TBのデータ量が存在。
- C4… 2019年4月のWeb抽出データの中から、言語判定の結果が英語となり、複数のデータフィルタリング、クレンジングを経て集められたデータセット

[41] Colin Raffel et al. (2020), "Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer" より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

多言語にわたって収集されたテキストコーパス

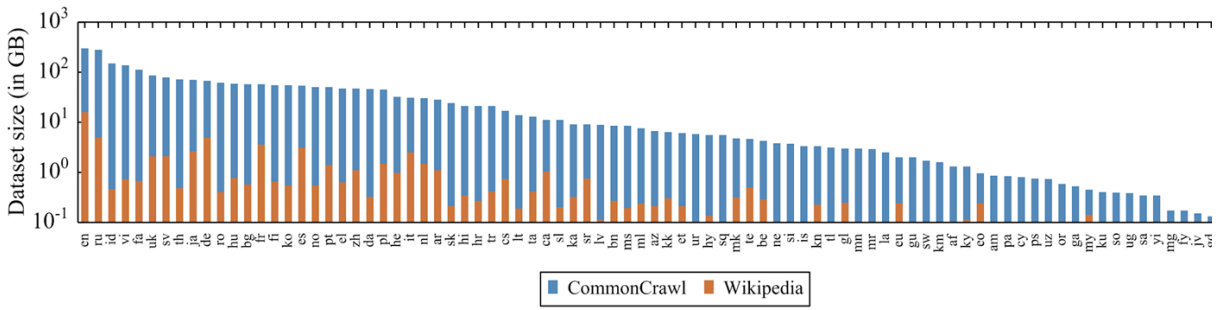
“Unsupervised Cross-lingual Representation Learning at Scale”, ACL2020
“mT5: A Massively Multilingual Pre-trained Text-to-Text Transformer”, NAACL2021

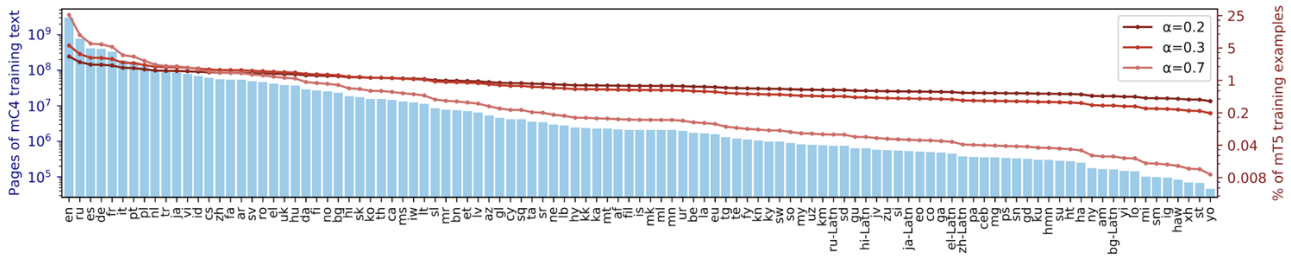
CC-100

- 100言語に渡って、収集されたテキストコーパス
- 各言語で訓練したモデルとfastTextを用いてフィルタリングを行う

mC4

- 前述したC4と同様に、言語判定したのちに、フィルタリングを行った101言語を含むテキストコーパス



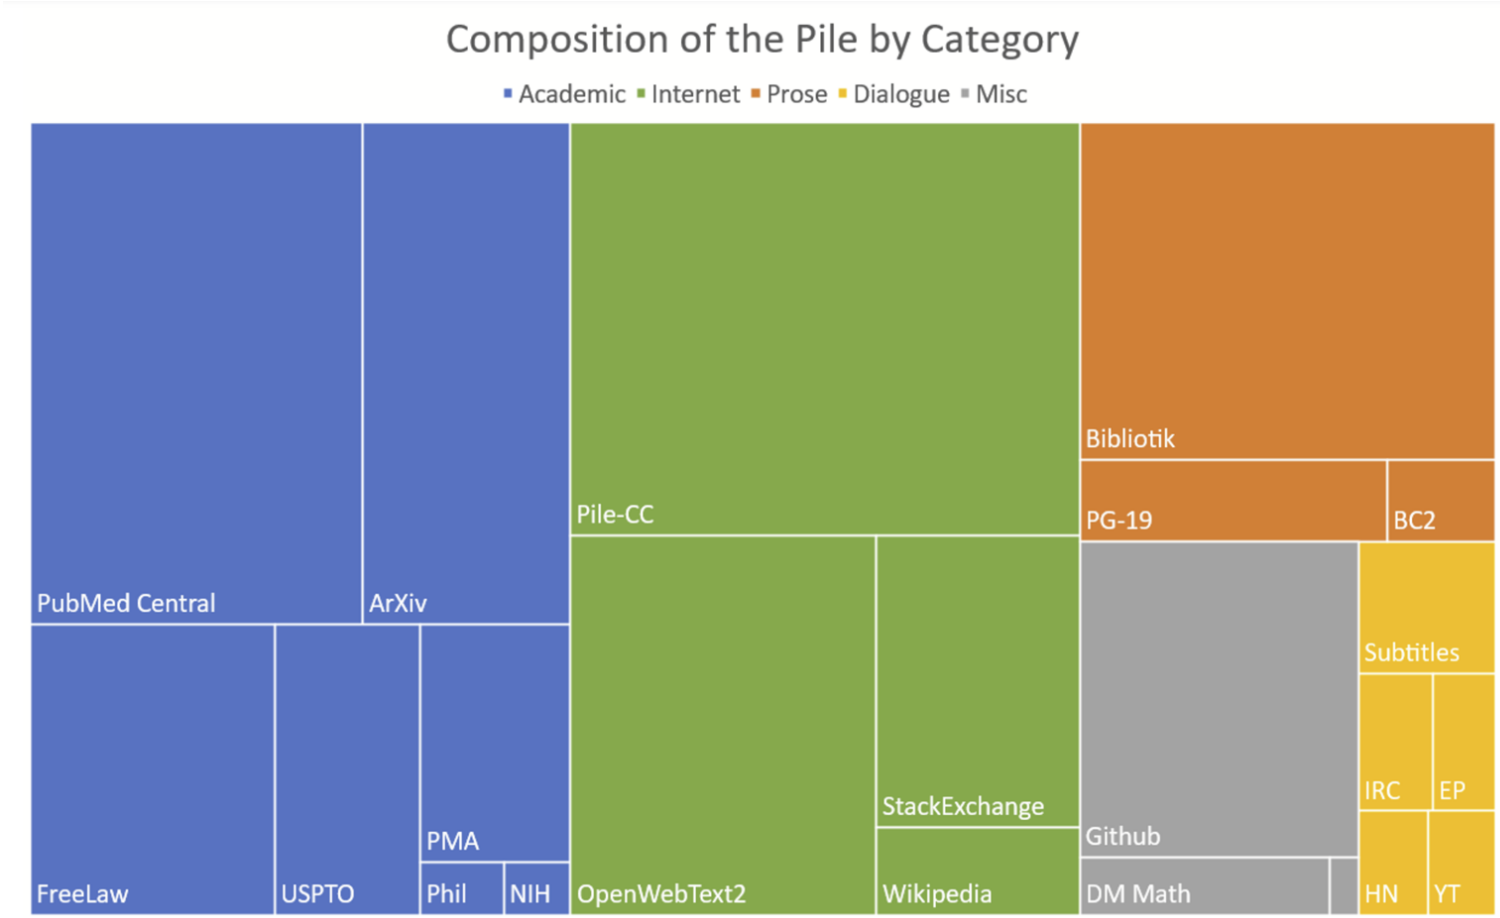


[42] Alexis Conneau et al. (2020), “Unsupervised Cross-lingual Representation Learning at Scale”, ACL2020 より引用
[43] Linting Xue et al. (2021), “mT5: A massively multilingual pre-trained text-to-text transformer”, ACL2021 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

The Pile | 多様なソースを含む英語コーパス

“The Pile: An 800GB Dataset of Diverse Text for Language Modeling”, 2020



- the Pile…22の多様なソースを組み合わせた言語モデリング用の825.18GBのデータセット

  学習データセットの多様性を高めることで、クロスドメインの性能を期待

- the Pileで学習したモデルがCC-100やCommon Crawlで学習したモデルの性能を上回る

[44] Leo Gao et al. (2020), “The Pile: An 800GB Dataset of Diverse Text for Language Modeling” より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Dolma：最大級の混合事前学習用公開データセット

“Dolma: An Open Corpus of 3 Trillion Tokens for Language Model Pretraining Research”, 2023

Subset		Size		
Source	*Kind*	*Gzip files (GB)*	*Documents (millions)*	*Tokens (billions)*
Common Crawl 24 shards, 2020-05 to 2023-06	web	4,197	4,600	2,415
C4 [24] [8]	web	302	364	175
peS2o [27]	academic	150	38.8	57
The Stack [16]	code	675	236	430
Project Gutenberg	books	6.6	0.052	4.8
Wikipedia, Wikibooks (*en*, *simple*)	encyclopedic	5.8	6.1	3.6
Total		**5,334**	**5,245**	**3,084**

Table 1: Composition of Dolma.

- Dolma…
ウェブコンテンツ、学術出版物、コード、書籍、百科事典の多様な組み合わせからなる5334GB(3T tokens)の公開データセット
- 過去の研究も踏まえ、データ処理のベストプラクティス(後述)に従ったと言及

[25] Luca Soldaini et al. (2023) “Dolma: An Open Corpus of 3 Trillion Tokens for Language Model Pretraining Research” より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Dolmaにおけるテキストデータ処理プロセス(1)

“Dolma: An Open Corpus of 3 Trillion Tokens for Language Model Pretraining Research”, 2023

1. fastTextの言語識別モデルを使用し、英語である可能性が50%以上の文書を保持

2. 出典のURLを元に重複を削除する

3. 句読点で終わらない全ての段落をフィルタリングする



[25] Luca Soldaini et al. (2023) “Dolma: An Open Corpus of 3 Trillion Tokens for Language Model Pretraining Research” より引用、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Dolmaにおけるテキストデータ処理プロセス(2)

"Dolma: An Open Corpus of 3 Trillion Tokens for Language Model Pretraining Research", 2023

4. 有害または猥褻なである可能性が60%以上と判定されたものを削除
個人情報も正規表現で検出しマスクする

5. 文書内で重複する段落を削除する

6. 評価セットに含まれる13トークン以上の段落を学習セットから除去する



[25] Luca Soldaini et al. (2023) "Dolma: An Open Corpus of 3 Trillion Tokens for Language Model Pretraining Research" より引用、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

■補足 | 事前学習用データセットの前処理の違い

"AI2 Dolma: 3 Trillion Token Open Corpus for Language Model Pretraining", 2023

Dataset	Example language models	Tokens**	Sources	License	PII Filter	Toxicity Filter	Language	Quality Filtering	Dedup	Decontam
OSCAR (Jul 2019)	BLOOM (via ROOTS)	1.08B	Common Crawl	Varies by data subset*	○	○	Multilingual (152 langs)	○	●	○
C4 (Oct 2019)	T5, FLAN-T5	156B	Common Crawl	ODC-BY	○	●	English	●	○	○
The Pile (Dec 2020)	GPT-J, GPT-NeoX, Pythia	300B	22 datasets e.g. Common Crawl, scientific text, books, code, Wikipedia, news	Varies by data subset	○	○	English	●	●	●***
ROOTS (Mar 2023)	BLOOM	341B	517 datasets e.g. Github, news, books, scientific text, Wikipedia	Varies by data subset	●	●	Multilingual (59 langs)	●	●	○
RedPajama (Apr 2023)	LLaMa reproduction	1.2T	Common Crawl, C4, Github, Arxiv, Books, Wikipedia, StackExchange	Varies by data subset	○	○	English	●	●	○
RefinedWeb (Jun 2023)	Falcon	600B****	Common Crawl	ODC-By 1.0	○	●	English	●	●	○
Ours (Dolma)	OLMo (Ongoing)	3.08T	Common Crawl, C4, peS2o, Gutenberg, Github, Wikipedia + Wikibooks	ImpACT MR	●	●	English	●	●	●

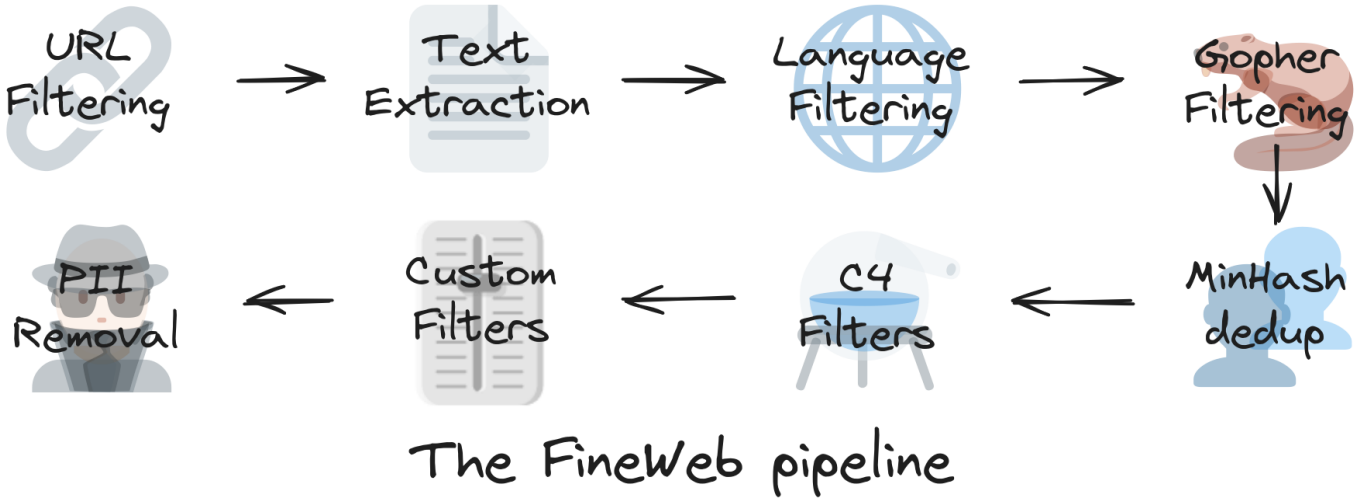
[25] Luca Soldaini et al. (2023) "Dolma: An Open Corpus of 3 Trillion Tokens for Language Model Pretraining Research" より引用、一部改変

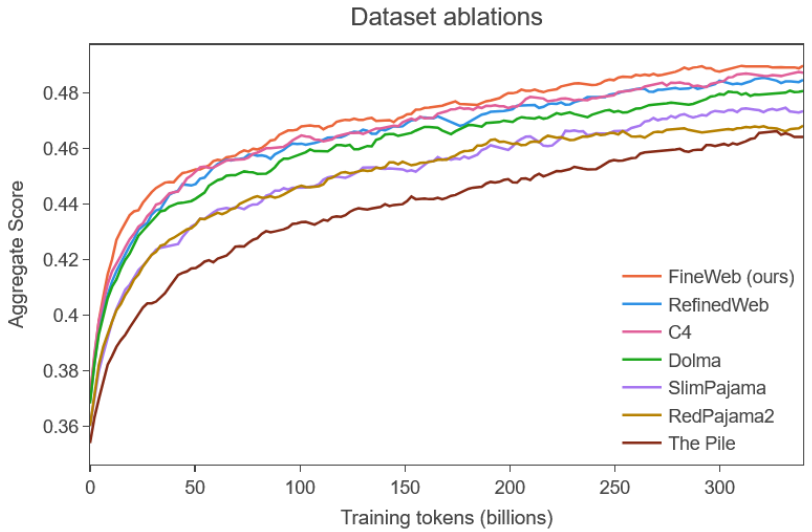
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

FineWeb | WEBデータに特化したさらに大きなデータセット

“The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale”

- Llamaアーキテクチャの小規模モデルを70個以上学習して行ったアブレーション実験による経験的なベストプラクティスを発見
- CommonCrawlから精製した18.5 T tokensからなるデータセット
  - WEBからの精製に特化することでより大きなデータセットを整備できる（c.f. RefinedWeb（5T）、RedPajama-v2（英仏西独伊の合計で30T））





小規模モデルでの実験で他の公開データセットより高い学習効率を実現

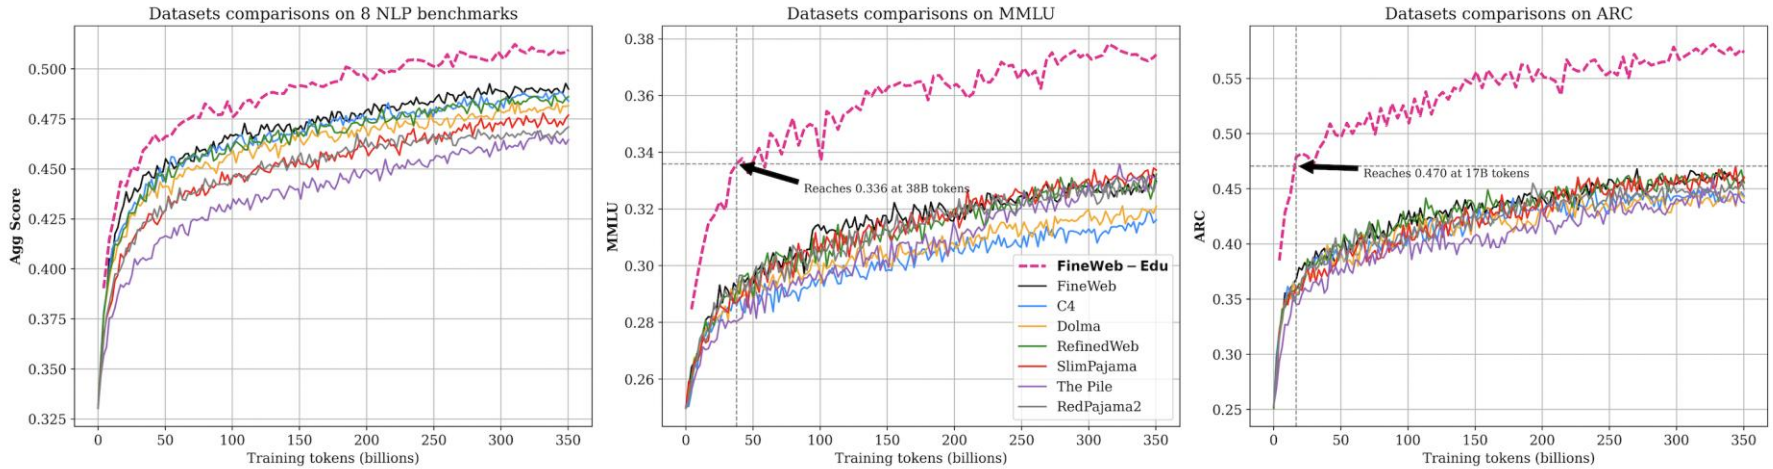
[40] Hugging Face (2024) The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scaleの ブログ より引用
[27] Guilherme Penedo et al.(2023), The RefinedWeb Dataset for Falcon LLM:Outperforming Curated Corpora with Web Data, and Web Data Only
[45] Weber, et. Al. (2024), RedPajama: an Open Dataset for Training Large Language Models

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

FineWeb | WEBデータに特化したさらに大きなデータセット

“The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale”

- 派生データセット
  - FineWeb-edu
    分類器を使用した、FineWebの「教育的」なサブセット1.3T tokens
  - FineWeb 2
    “FineWeb2: One Pipeline to Scale Them All -- Adapting Pre-Training Data Processing to Every Language”
    多言語版FineWeb
    日本語は331Billion words含まれており比較的豊富



[40] Hugging Face (2024) The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale
[69] Hugging Face, EPFL (2025) FineWeb2: One Pipeline to Scale Them All — Adapting Pre-Training Data Processing to Every Language
図はFineWeb-eduのHFレポジトリより引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

テキストのトークン化

代表手法:Byte Pair Encoding (BPE)

- テキストをサブワード(単語よりも細かい塊)に分割
- トークナイザーの語彙作成方法は右図を参照.
- 語彙サイズ（基本語彙数＋マージ数）は
  ハイパーパラメータ
- GPT、GPT-2、RoBERTa、BART、DeBERTaなど多くのTransformerで用いられる
- 絵文字などの処理
  - コーパスにない文字を使用する場合、その文字は<unk>に変換される
  - そのため、多くのNLPモデルが絵文字でコンテンツを分析するのが苦手としている
  - GPT-2とRoBERTaのトークナイザは、これに対処するためにbyteレベルでBPEをおこなう

例）コーパスが次の５つの単語でできていると仮定

‘hug’, ‘pug’, ‘pun’, ‘bun’, ‘hugs’

1. **それぞれの単語の出現回数をカウント**

   (‘hug’, 10), (‘pug’, 5), (‘pun’, 12),

   (‘bun’, 4), (‘hugs’, 5)

2. **単語を文字に分割**

   (‘h’ ‘u’ ‘g’, 10), (‘p’ ‘u’ ‘g’, 5), (‘p’ ‘u’ ‘n’, 12),

   (‘b’ ‘u’ ‘n’, 4), (‘h’ ‘u’ ‘g’ ‘s’, 5)

3. **最も頻出の隣接ペア (‘u’, ’g’) を(‘ug’) にマージ**

   (‘h’ ‘ug’, 10), (‘p’ ‘ug’, 5), (‘p’ ‘u’ ‘n’, 12),

   (‘b’ ‘u’ ‘n’, 4), (‘h’ ‘ug’ ‘s’, 5)

4. **希望の語彙数まで頻度の高い組のマージを繰り返す**

   (‘h’ ’ug’, 10), (‘p’ ‘ug’, 5), (‘p’ ‘un’, 12),

   ('b' 'un', 4), (‘h’ ’ug' 's', 5) …

[46] Hugging Face (2025), Hugging Face LLM Course のChapter6.5より例を引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

BPE以外のサブワード単位でのトークン化

その他のトークナイザ

WordPiece

- BPEと違い、隣接ペアの２要素の出現頻度が低いペア(その組み合わせ以外であまりないペア)優先的にマージ

$$\text{Score} = \frac{\text{隣接ペア(a,b)の出現回数}}{\text{aの出現回数} \times \text{bの出現回数}}$$

- 例１：(un, ##able)
  各要素は他の単語でも頻出する可能性大（このままにしたい）
- 例２：(hug, ##ging)
  各要素は他で頻出ではないのでマージしてOK
- BERT、ELECTRAなどで使用

SentencePiece

- 事前の単語分割を必要とせず、そのままのテキストを分割する
- 語彙の集合にスペースを追加し、BPEやUnigramなどのアルゴリズムを用いて語彙をマージ
- 日本語など英語以外の様々な言語でも容易にトークナイザを作成でき、サブワード分割アルゴリズムも選択可能
- T5、ALBERTなどで使用

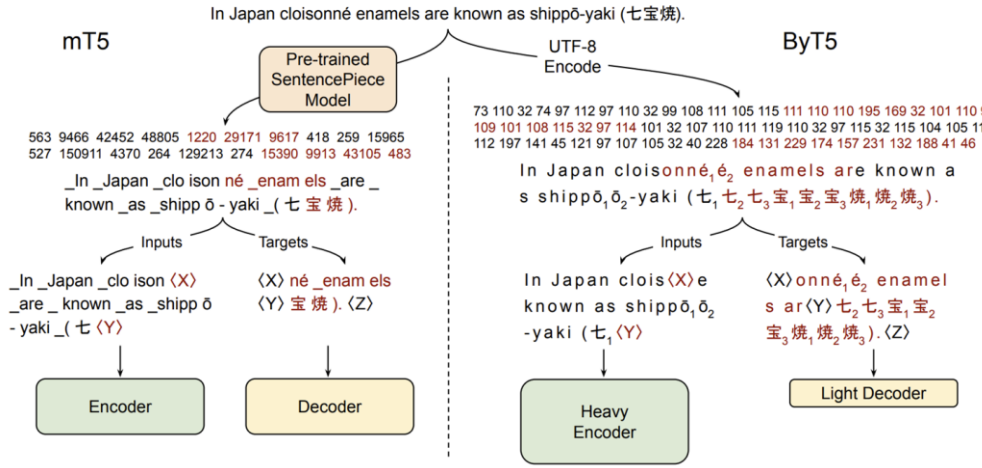
[46] Hugging Face (2025), Hugging Face LLM Course のChapter6.6より例を引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

■補足 | ByT5：トークンフリーな言語モデル

"ByT5: Towards a token-free future with pre-trained byte-to-byte models", 2021



Model	GEM-XSum (BLEU)		TweetQA (BLEU-1)		DROP (F1 / EM)	
	mT5	ByT5	mT5	ByT5	mT5	ByT5
Small	6.9	**9.1**	54.4	**65.7**	40.0 / 38.4	**66.6 / 65.1**
Base	8.4	**11.1**	61.3	**68.7**	47.2 / 45.6	**72.6 / 71.2**
Large	10.1	**11.5**	67.9	**70.0**	58.7 / 57.3	**74.4 / 73.0**
XL	11.9	**12.4**	68.8	**70.6**	62.7 / 61.1	**68.7 / 67.2**
XXL	14.3	**15.3**	70.8	**72.0**	71.2 / 69.6	**80.0 / 78.5**

Table 3: mT5 vs. ByT5 on three English generation tasks, reporting the best score on the validation set.

方法

テキスト列をトークンで表現せず、代わりに文字コード(UTF-8)で読み込んだバイト列で表現

結果

サブワードでトークナイズし、学習を行ったモデル(mT5)に匹敵する性能を示す

[47] Linting Xue et al. (2022), "ByT5: Towards a token-free future with pre-trained byte-to-byte models" ACL2022 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

発展的話題

データ	• 主要なデータセット • データ処理(クレンジング、トークナイズ)
モデル	• 主要なモデル • アーキテクチャの構成要素
学習	• Attention • 目的関数
評価、分析	• 評価 • 分析

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

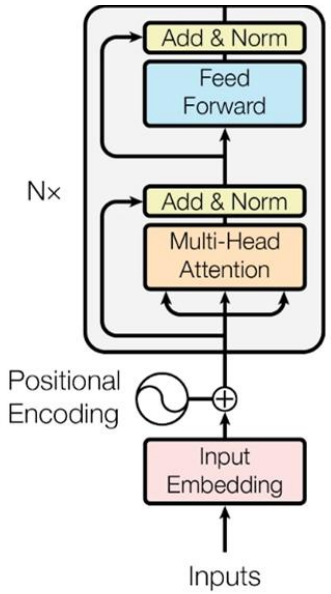
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerの分類

Encoder-only

BERT、RoBERTaなど

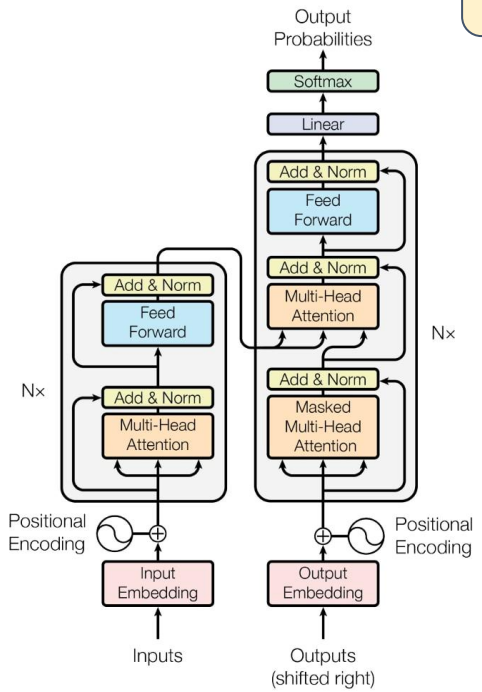
認識系
（クラス分類）



Encoder-Decoder

BART、T5など

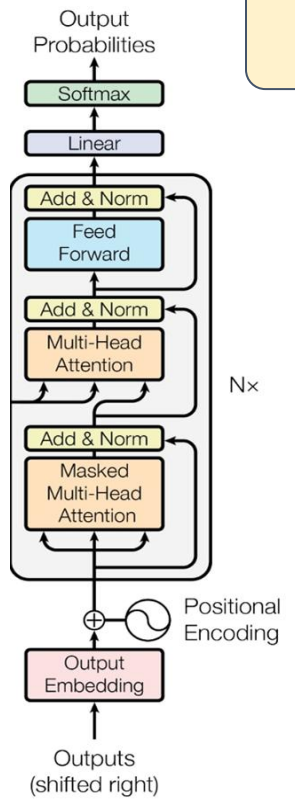
テキスト
生成系



Decoder-only

GPT、Llamaなど

テキスト
生成系



[6] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

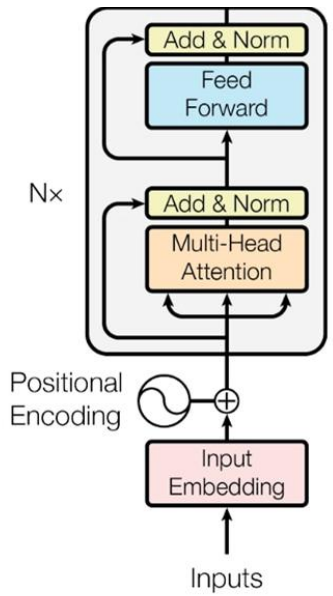
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerの分類

Encoder-only

BERT、RoBERTaなど

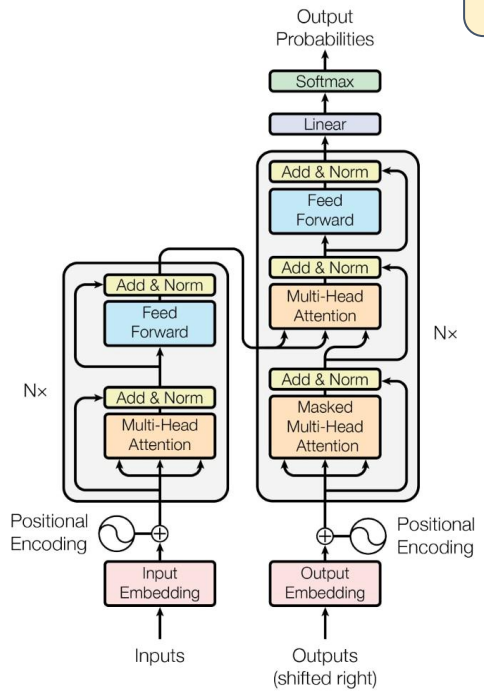
認識系
（クラス分類）



Encoder-Decoder

BART、T5など

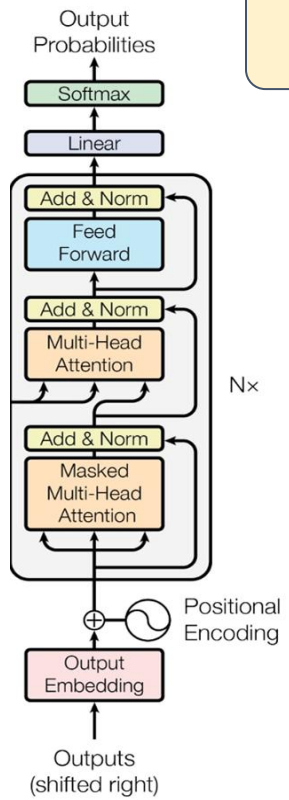
テキスト
生成系



Decoder-only

GPT、Llamaなど

テキスト
生成系



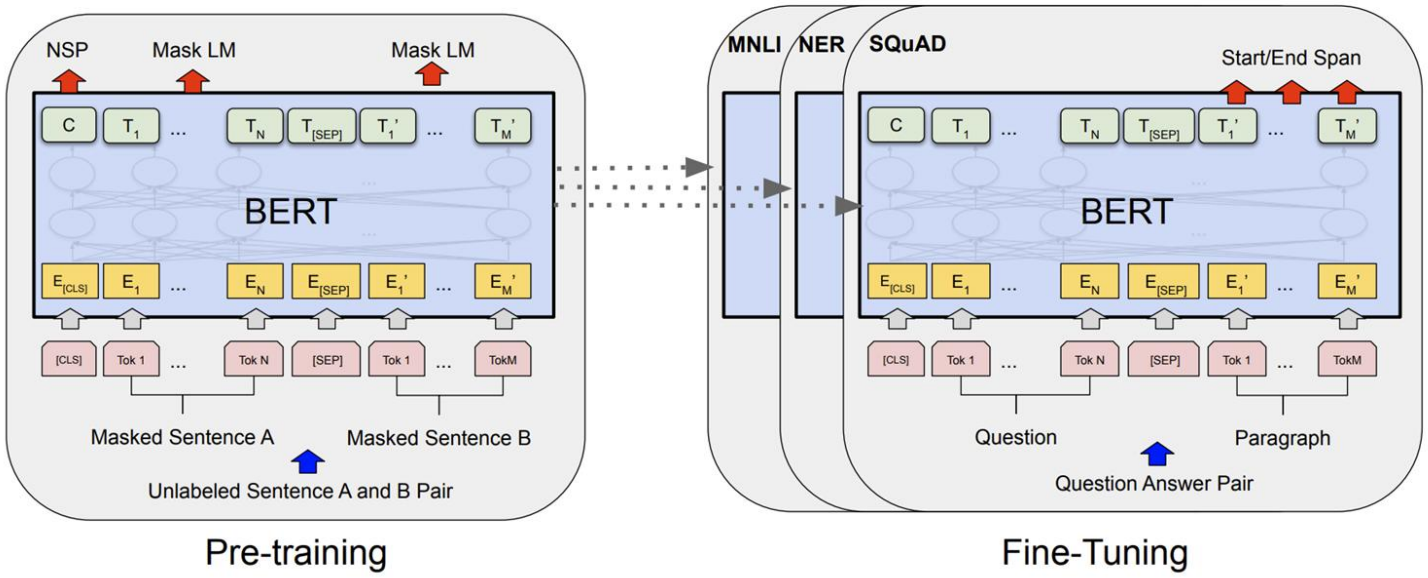
[6] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

BERT：複数タスクでSoTAを達成した双方向型事前学習モデル

“BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”, NAACL2019



IsNext my dog is cute [SEP] he likes **play** ##ng [SEP]

次の文予測 (NSP)

穴埋め (MLM)

[CLS] my dog is cute [SEP] he likes [MASK] ##ng [SEP]

方法

- TransformerのEncoderを24層積み重ねた双方向言語モデル
- 事前学習において穴埋めタスクと次の文予測タスクを学習し、目的とするタスクのデータセットでファインチューニングすることで性能を発揮

結果

- 11個のNLPタスクでSoTA

[48] Jacob Devlin et al. (2019), “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”, ACL2019 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

RoBERTa：BERTを改良し性能向上

“RoBERTa: A Robustly Optimized BERT Pretraining Approach”, 2019

	MNLI	QNLI	QQP	RTE	SST	MRPC	CoLA	STS	WNLI	Avg
Single-task single models on dev										
$\text{BERT}_{\text{LARGE}}$	86.6/-	92.3	91.3	70.4	93.2	88.0	60.6	90.0	-	-
$\text{XLNet}_{\text{LARGE}}$	89.8/-	93.9	91.8	83.8	95.6	89.2	63.6	91.8	-	-
RoBERTa	**90.2/90.2**	**94.7**	**92.2**	**86.6**	**96.4**	**90.9**	**68.0**	**92.4**	**91.3**	-
Ensembles on test (from leaderboard as of July 25, 2019)										
ALICE	88.2/87.9	95.7	**90.7**	83.5	95.2	92.6	**68.6**	91.1	80.8	86.3
MT-DNN	87.9/87.4	96.0	89.9	86.3	96.5	92.7	68.4	91.1	89.0	87.6
XLNet	90.2/89.8	98.6	90.3	86.3	**96.8**	**93.0**	67.8	91.6	**90.4**	88.4
RoBERTa	**90.8/90.2**	**98.9**	90.2	**88.2**	96.7	92.3	67.8	**92.2**	89.0	**88.5**

Model	SQuAD 1.1		SQuAD 2.0	
	EM	F1	EM	F1
Single models on dev, w/o data augmentation				
$\text{BERT}_{\text{LARGE}}$	84.1	90.9	79.0	81.8
$\text{XLNet}_{\text{LARGE}}$	**89.0**	94.5	86.1	88.8
RoBERTa	88.9	**94.6**	**86.5**	**89.4**
Single models on test (as of July 25, 2019)				
$\text{XLNet}_{\text{LARGE}}$			$86.3^{\dagger}$	$89.1^{\dagger}$
RoBERTa			86.8	89.8
XLNet + SG-Net Verifier			$\mathbf{87.0}^{\dagger}$	$\mathbf{89.9}^{\dagger}$

方法

- BERTと同じアーキテクチャで一部の要素を変更
  - データセットサイズを13GB→160GB
  - バッチサイズを256→8K
  - NSPを使用しない
  - マスクを動的に行う

結果

- GLUEやSQuADでBERTを上回る性能

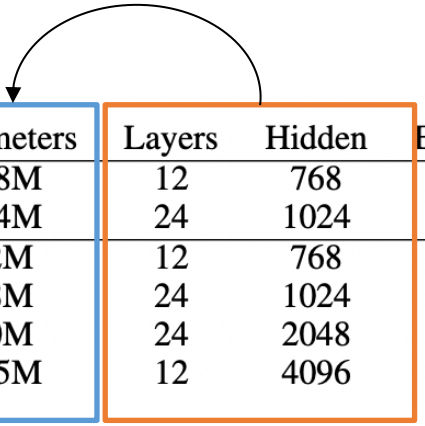
[49] Yinhan Liu et al. (2019), “RoBERTa: A Robustly Optimized BERT Pretraining Approach”より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

ALBERT：パラメータ共有により、学習を高速化

“ALBERT: A Lite BERT for Self-supervised Learning of Language Representations”, ICLR2020



Model		Parameters	Layers	Hidden	Embedding	Parameter-sharing
BERT	base	108M	12	768	768	False
	large	334M	24	1024	1024	False
ALBERT	base	12M	12	768	128	True
	large	18M	24	1024	128	True
	xlarge	60M	24	2048	128	True
	xxlarge	235M	12	4096	128	True

Model		Parameters	SQuAD1.1	SQuAD2.0	MNLI	SST-2	RACE	Avg	Speedup
BERT	base	108M	90.4/83.2	80.4/77.6	84.5	92.8	68.2	82.3	4.7x
	large	334M	92.2/85.5	85.0/82.2	86.6	93.0	73.9	85.2	1.0
ALBERT	base	12M	89.3/82.3	80.0/77.1	81.6	90.3	64.0	80.1	5.6x
	large	18M	90.6/83.9	82.3/79.4	83.5	91.7	68.5	82.4	1.7x
	xlarge	60M	92.5/86.1	86.1/83.1	86.4	92.4	74.8	85.5	0.6x
	xxlarge	235M	**94.1/88.3**	**88.1/85.1**	**88.0**	**95.2**	**82.3**	**88.7**	0.3x

方法

- 層間でパラメータを共有することで、BERT-largeと同様のアーキテクチャと比較して、パラメータが18倍少なくなり、1.7倍高速に学習が可能に

結果

- ALBERT-xxlargeにおいてBERT-largeよりも少ないパラメータ数であるにも関わらず、GLUE、SQuADでSoTA

[50] Zhenzhong Lan et al. (2020), “ALBERT: A Lite BERT for Self-supervised Learning of Language Representations” ICLR2020 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

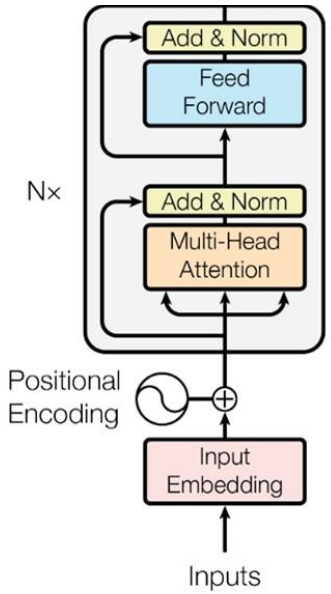
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerの分類

Encoder-only

BERT、RoBERTaなど

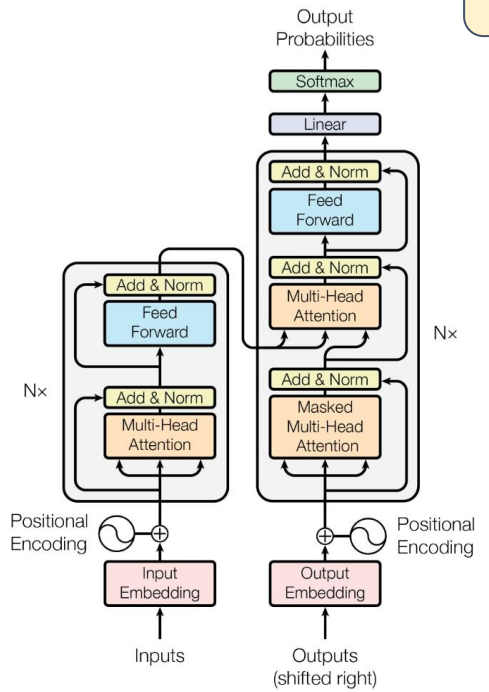
認識系
（クラス分類）



Encoder-Decoder

BART、T5など

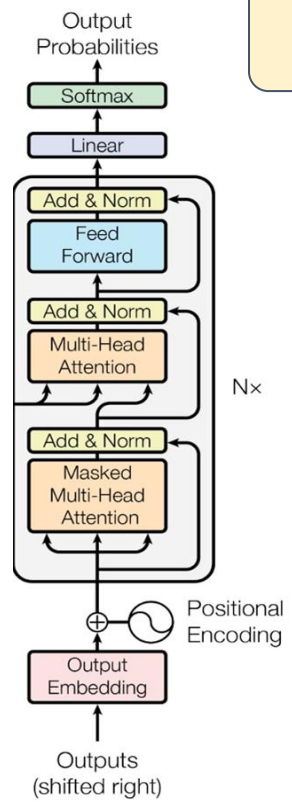
テキスト
生成系



Decoder-only

GPT、Llamaなど

テキスト
生成系



[6] Ashish Vaswani et al. (2017), “Attention Is All You Need”, NeurIPS2017 より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

BART：双方向エンコーダーと自己回帰型デコーダーの組み合わせ

“BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension”, 2019

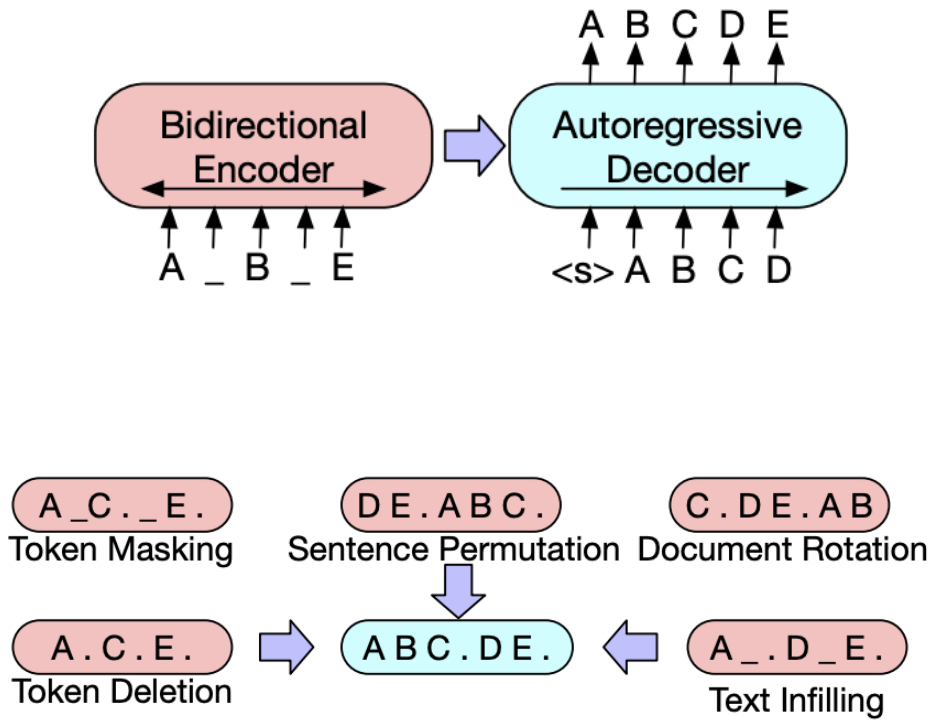


Figure 2: Transformations for noising the input that we experiment with. These transformations can be composed.

方法

- BERTのような双方向エンコーダーとGPTのような自己回帰型デコーダーを組み合わせたモデル
- ランダムに入力文書の一部を破損させ、その再構成を行う複数のタスクの組み合わせで事前学習を行う

結果

- CNN/DailyMail XSumといったタスクでSoTA

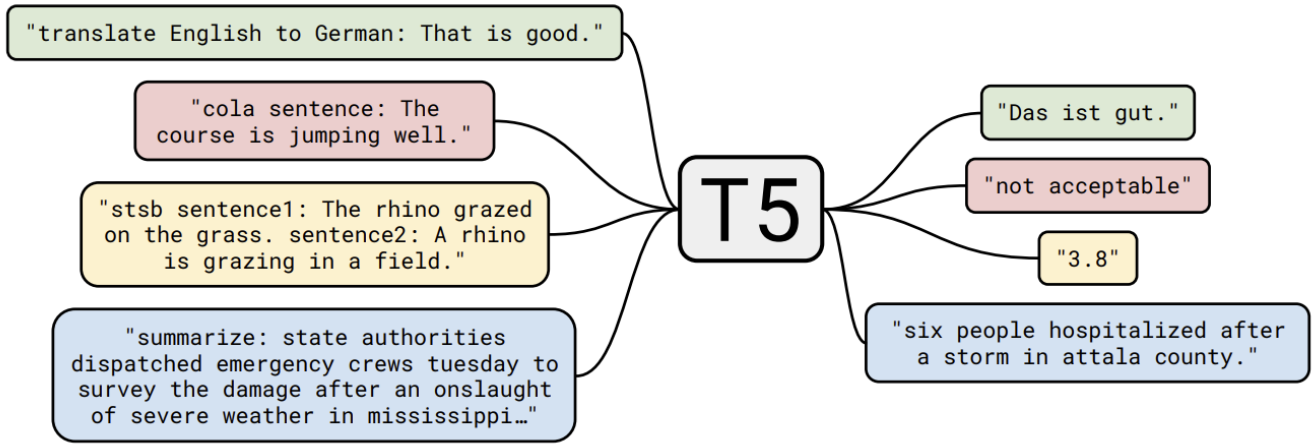
[51] Mike Lewis et al. (2020), “BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension” より引用

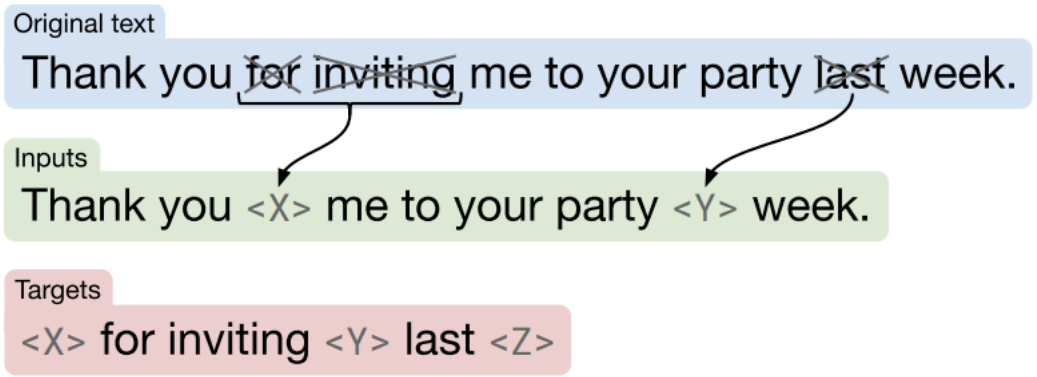
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

T5：全てのタスクをText-to-Textと扱うEncDecモデル

“Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer”, 2019





方法

- 多くの自然言語処理タスクをText-to-Textの形に変換し、統一したフレームワークで学習を行う
- 事前学習においては、入力文書の一部をランダムに特殊トークンに置き換え、置き換え元のトークンを予測するタスクで学習を行う

結果

- GLUEやSuperGLUEといったタスクでSoTA

[41] Colin Raffel et al. (2020), “Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer” より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

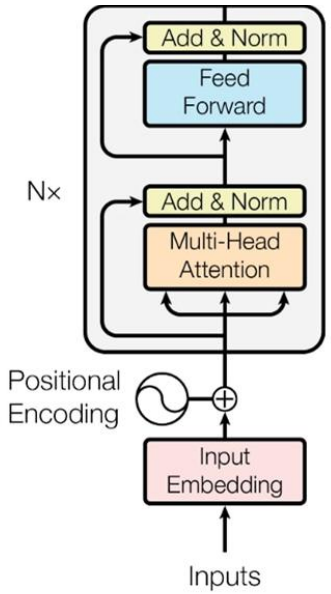
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerの分類

Encoder-only

BERT、RoBERTaなど

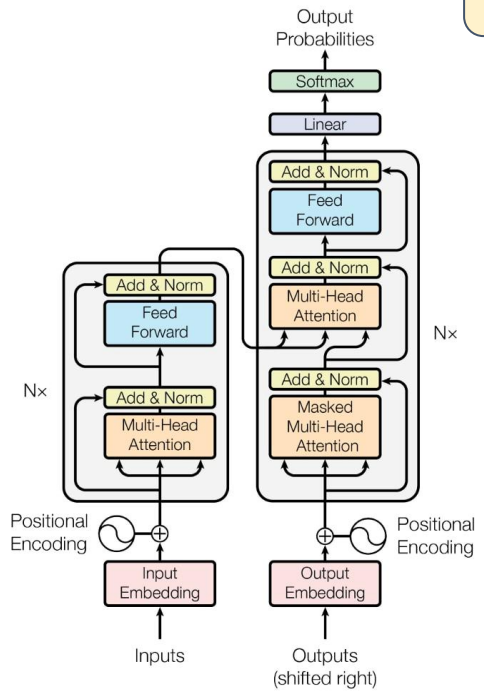
認識系
（クラス分類）



Encoder-Decoder

BART、T5など

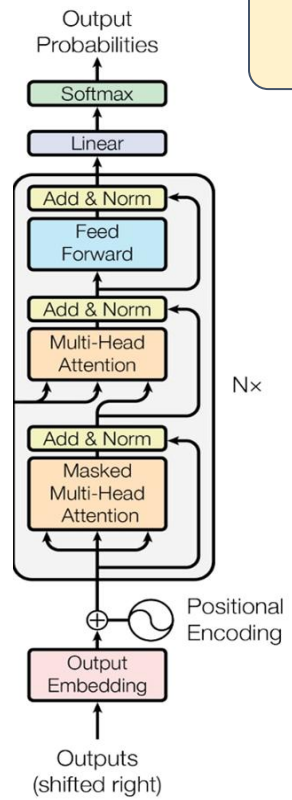
テキスト
生成系



Decoder-only

GPT、Llamaなど

テキスト
生成系



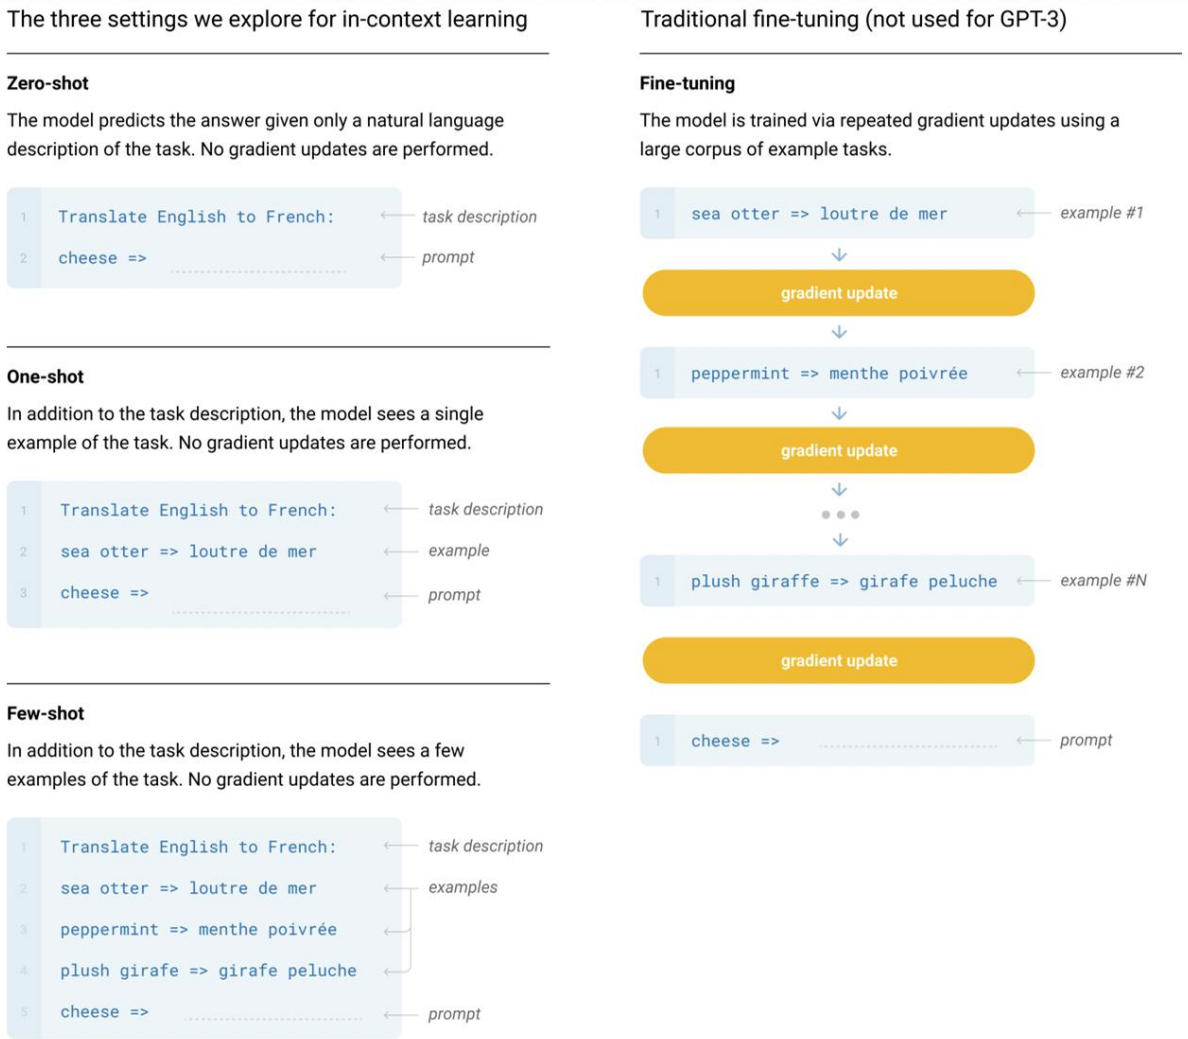
[6] Ashish Vaswani et al. (2017), "Attention Is All You Need", NeurIPS2017 より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

GPT-3：さらにスケールさせたDec-onlyモデル

- “Language Models are Few-Shot Learners”, 2020



方法

- GPT-2の約120倍のパラメータ数を持ったモデルを約14倍のデータで学習を行う
- タスクに関する説明や数ショットの例を入力に加えることで、タスクが解けるようになる文脈内学習(In-context Learning)が可能に

結果

- 数ショットの設定で既存のSoTAに匹敵、あるいは上回る性能を確認
- あまりの性能により、モデルの公開を行わずAPIの公開に止める

[24] Tom Brown et al. (2020), “Language Models are Few-Shot Learners”, NeurIPS2020 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

■補足 |近年公開されるモデルはDec-onlyのモデルが多い

“A Survey of Large Language Models”, 2023

TABLE 5: Model cards of several selected LLMs with public configuration details. Here, PE denotes position embedding, #L denotes the number of layers, #H denotes the number of attention heads, d_{model} denotes the size of hidden states, and MCL denotes the maximum context length during training.

Model	Category	Size	Normalization	PE	Activation	Bias	#L	#H	d_{model}	MCL
GPT3 [55]	Causal decoder	175B	Pre LayerNorm	Learned	GeLU	✓	96	96	12288	2048
PanGU- α [84]	Causal decoder	207B	Pre LayerNorm	Learned	GeLU	✓	64	128	16384	1024
OPT [90]	Causal decoder	175B	Pre LayerNorm	Learned	ReLU	✓	96	96	12288	2048
PaLM [56]	Causal decoder	540B	Pre LayerNorm	RoPE	SwiGLU	×	118	48	18432	2048
BLOOM [78]	Causal decoder	176B	Pre LayerNorm	ALiBi	GeLU	✓	70	112	14336	2048
MT-NLG [113]	Causal decoder	530B	-	-	-	-	105	128	20480	2048
Gopher [64]	Causal decoder	280B	Pre RMSNorm	Relative	-	-	80	128	16384	2048
Chinchilla [34]	Causal decoder	70B	Pre RMSNorm	Relative	-	-	80	64	8192	-
Galactica [35]	Causal decoder	120B	Pre LayerNorm	Learned	GeLU	×	96	80	10240	2048
LaMDA [68]	Causal decoder	137B	-	Relative	GeGLU	-	64	128	8192	-
Jurassic-1 [107]	Causal decoder	178B	Pre LayerNorm	Learned	GeLU	✓	76	96	13824	2048
LLaMA [57]	Causal decoder	65B	Pre RMSNorm	RoPE	SwiGLU	×	80	64	8192	2048
LLaMA 2 [99]	Causal decoder	70B	Pre RMSNorm	RePE	SwiGLU	×	80	64	8192	4096
Falcon [141]	Causal decoder	40B	Pre LayerNorm	RoPE	GeLU	×	60	64	8192	2048
GLM-130B [93]	Prefix decoder	130B	Post DeepNorm	RoPE	GeGLU	✓	70	96	12288	2048
T5 [82]	Encoder-decoder	11B	Pre RMSNorm	Relative	ReLU	×	24	128	1024	512

[26] Wayne Xin Zhao et al. (2023), “A Survey of Large Language Models” より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

正規化の位置に関して

“A Survey of Large Language Models”, 2023

	数式表現	詳細
Post Norm	$\mathrm{Norm}(x + \mathrm{Sublayer}(x))$	• 元々のTransformer同様、残差接続後に正規化を配置 • 出力層付近で勾配が大きくなり学習が不安定になる傾向
Pre Norm	$x + \mathrm{Sublayer}(\mathrm{Norm}(x))$	• 各サブレイヤの前と最終予測の前に正規化を配置 • **性能が低くなるが学習の安定性から、採用されることが多い**
Sandwich Norm	$x + \mathrm{Norm}(\mathrm{Sublayer}(\mathrm{Norm}(x)))$	• 特に残差接続の前で追加の正規化を配置 • 学習が破綻する場合も存在

[26] Wayne Xin Zhao et al. (2023), “A Survey of Large Language Models” を参考

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

位置表現に関して

“より良いTransformerをつくる”, 2022 参考に作成

	概要	詳細
絶対位置表現	各トークンの絶対的な位置を表す何らかの表現(e.g.sin波/cos波)を入力の表現に加える	• 入力の内容とは独立した表現なので、計算速度が速い • 未知の長さの系列の入力に弱い
相対位置表現	トークン同士の相対的な距離をAttention計算時に活用する	• トークン同士の相対的な位置を利用するため、未知の系列長でも頑健性が高い • 入力に固有の値を取るため、追加の計算が必要

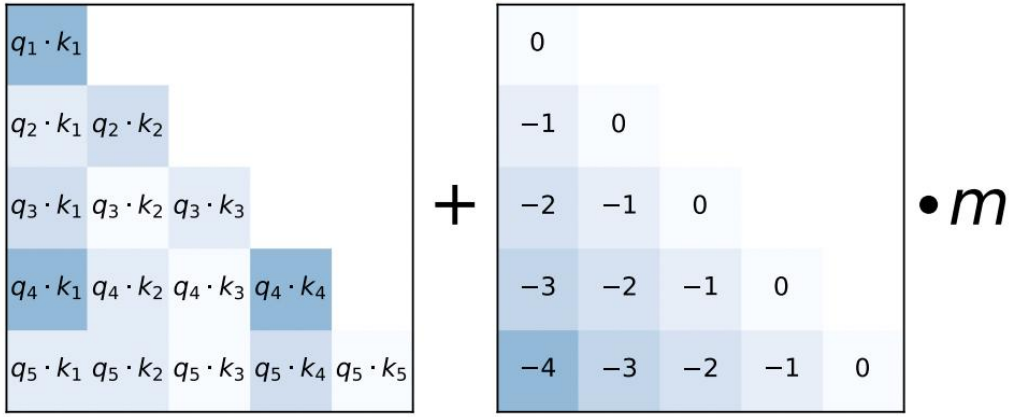
[52] 清野舜 (2022), より良いTransformerをつくる - Speaker Deck を参考

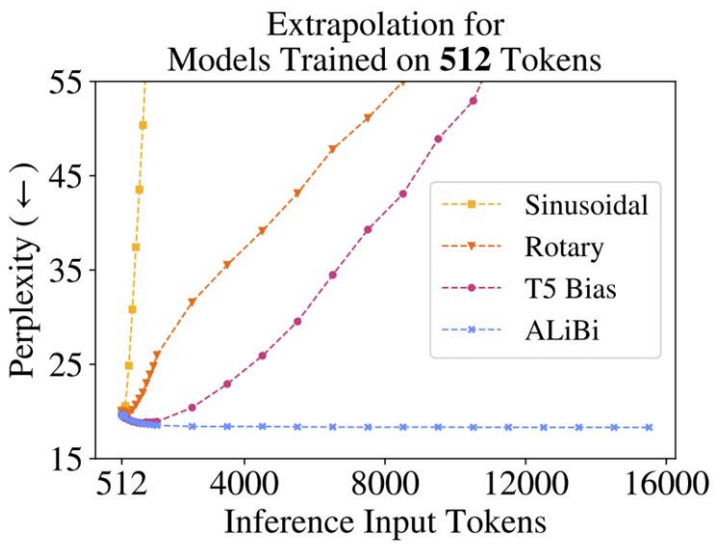
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

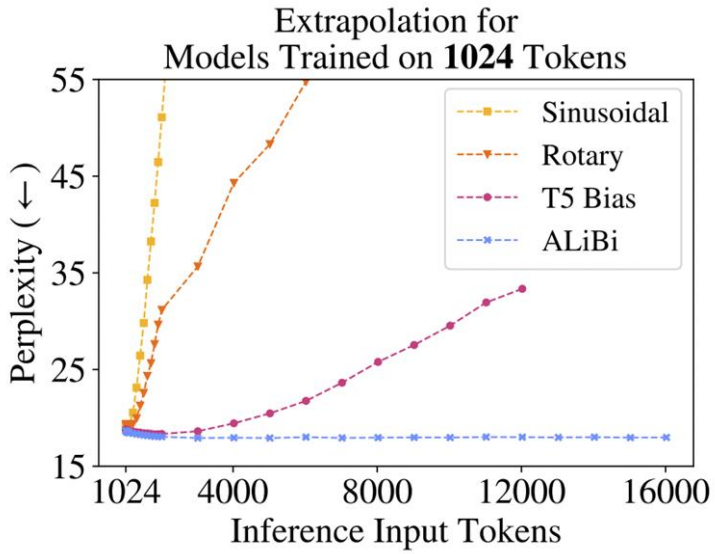
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

ALiBi：距離に線形なバイアスを組み込んだ相対位置埋め込み

“Train Short, Test Long: Attention with Linear Biases Enables Input Length Extrapolation”, ICLR2022







方法

- Attentionスコア計算時にKeyとQueryの相対的な距離に対して線形なペナルティを加える
- 近くのトークン間より遠くのトークン間の方がAttentionスコアが低下する

結果

- 絶対位置表現より性能が良い
- 外挿性能も良い

[53] Ofir Press et al. (2021), “Train Short, Test Long: Attention with Linear Biases Enables Input Length Extrapolation” より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

近年のLLMモデル構造

- 近年のモデルはAttention/Feed Forward/Normalizationに改良がされつつある
  - Potisional Embedding
    - RoPE
  - Attention
    - Grouped Query Attention
    - Sliding Window Attention
    - Multi-head Latent Attention
  - Feed Forward
    - SwiGLU
    - Mixture of Experts
  - Others
    - RMSNorm
- 最新モデルのアーキテクチャの解説については以下を参照
  The Big LLM Architecture Comparison [70]
  https://magazine.sebastianraschka.com/p/the-big-llm-architecture-comparison

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

発展的話題

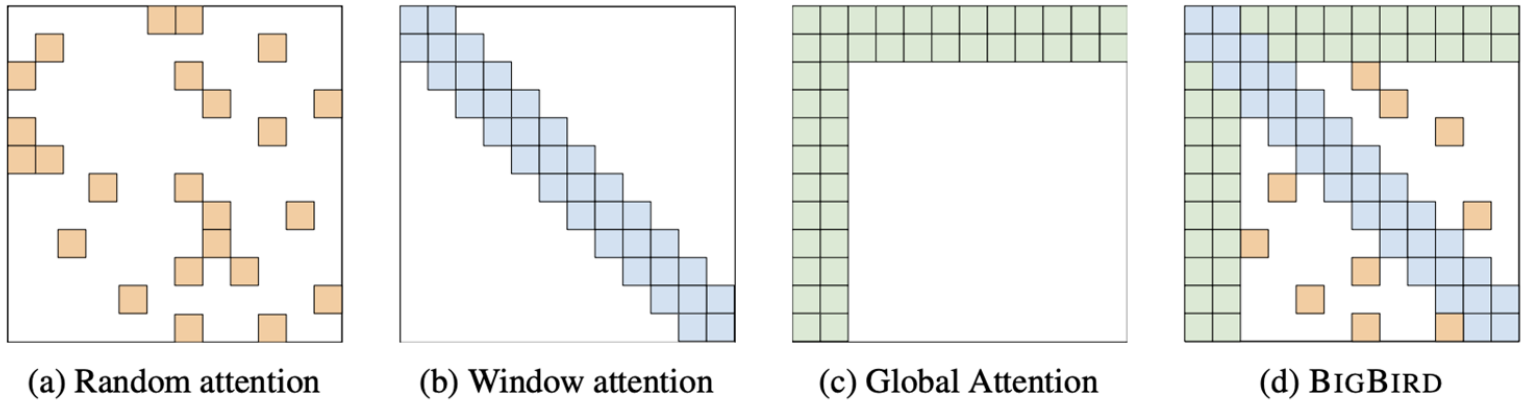
データ	• 主要なデータセット • データ処理(クレンジング、トークナイズ)
モデル	• 主要なモデル • アーキテクチャの構成要素
学習	• Attention • 目的関数
評価、分析	• 評価 • 分析

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Sparse Attention：計算箇所を限定して効率的にAttentionを計算

“Big Bird: Transformers for Longer Sequences”, NeurIPS 2020



(a) Random attention (b) Window attention (c) Global Attention (d) BIGBIRD

問題意識

従来のAttentionでは
系列長に対し2乗の
計算複雑性がかかる

方法

全てのトークンに対して
Attentionを計算するのでなく、局所的に設定したトークンで学習を行い
計算量を削減

類似アイディア：[Iz Beltagy et al. 2020] “Longformer: The Long-Document Transformer” [55]

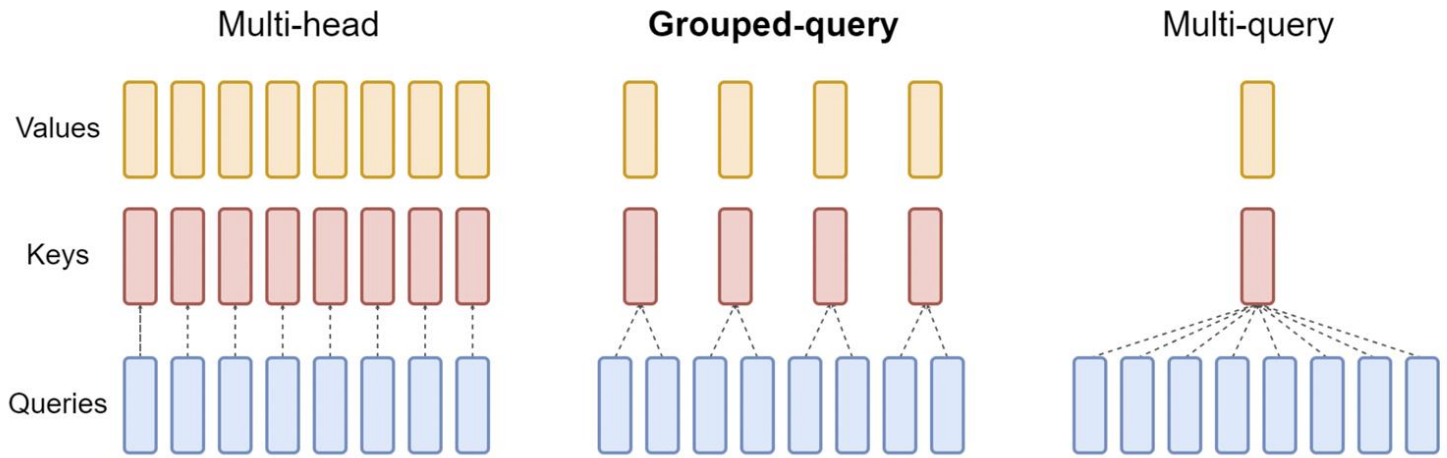
[54] Manzil Zaheer et al. (2020), “Big Bird: Transformers for Longer Sequences” NeurIPS2020 より引用(図)

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Grouped-Query Attention：KeyとValueを複数のヘッドで共有

“GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints”, 2023



問題意識

Multi-headのAttentionではデコードする際に全てのKeyとValueを読み込む必要があり、推論速度のボトルネックになる

方法

KeyとValueをいくつか(Group-query)あるいは一つ(Multi-query)のヘッドで共有してメモリ負荷を削減し、推論速度を向上させる

Llama3などで採用されている

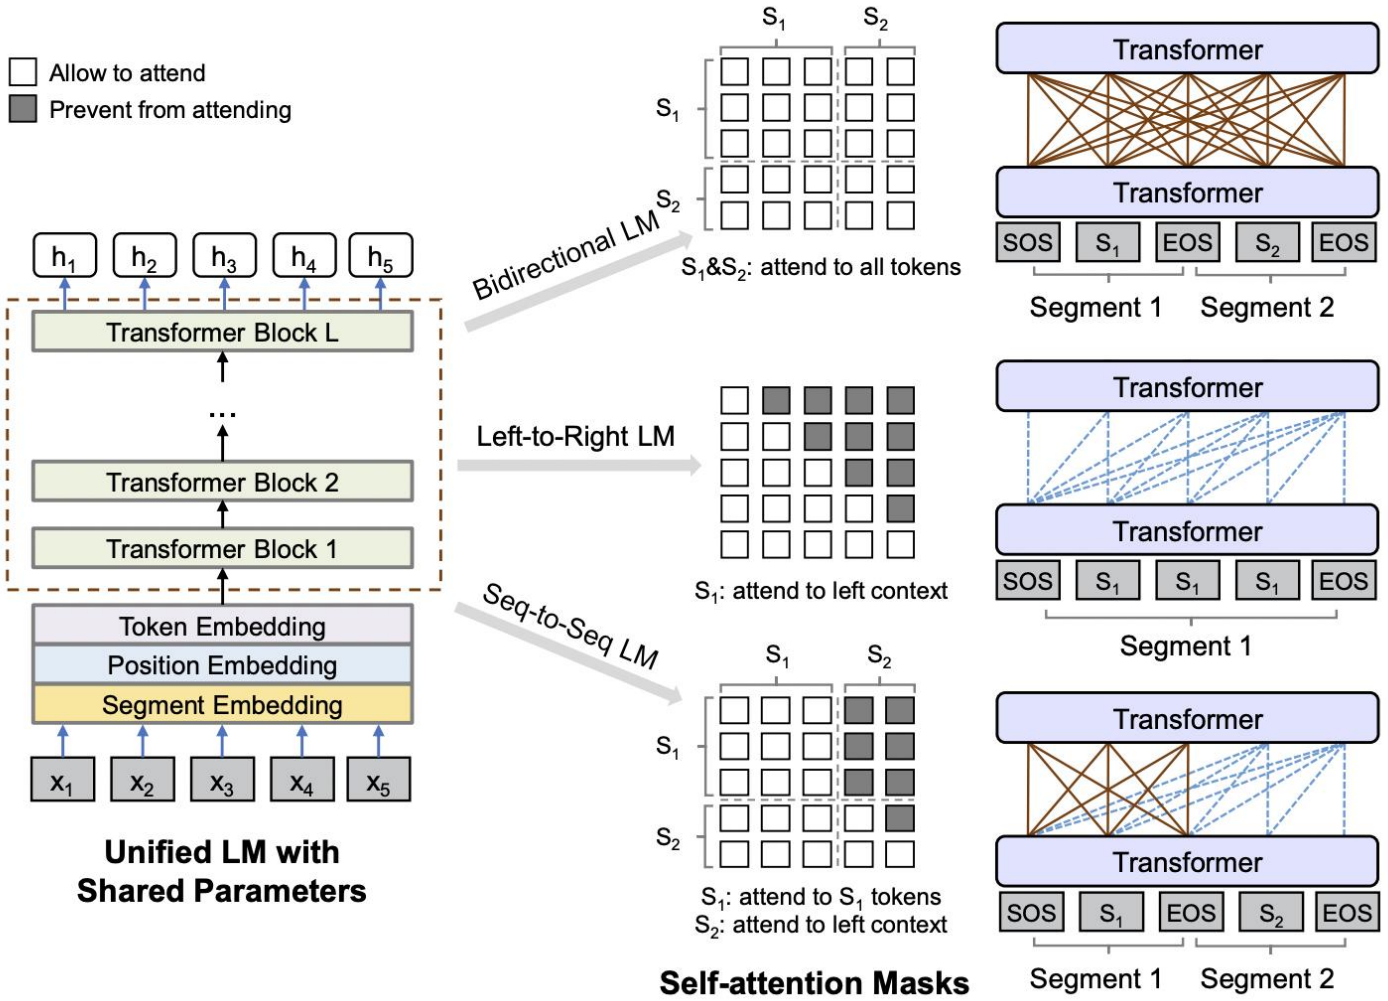
[56] Joshua Ainslie et al. (2023), “GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints” より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is lic

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

UniLM：Attentionのマスク位置を変え、複合的な目的関数を設定

“Unified Language Model Pre-training for Natural Language Understanding and Generation”, NeurIPS2019



方法

- Attentionのマスクされたした領域を変化させることで、双方向言語モデリング、単方向言語モデリング、配列間言語モデリングを組み合わせた複合的な目的関数で事前学習を行う

結果

- GLUEのような識別タスクでBERTに匹敵する性能を示しながら、CNN/DMのような言語生成タスクでSoTA

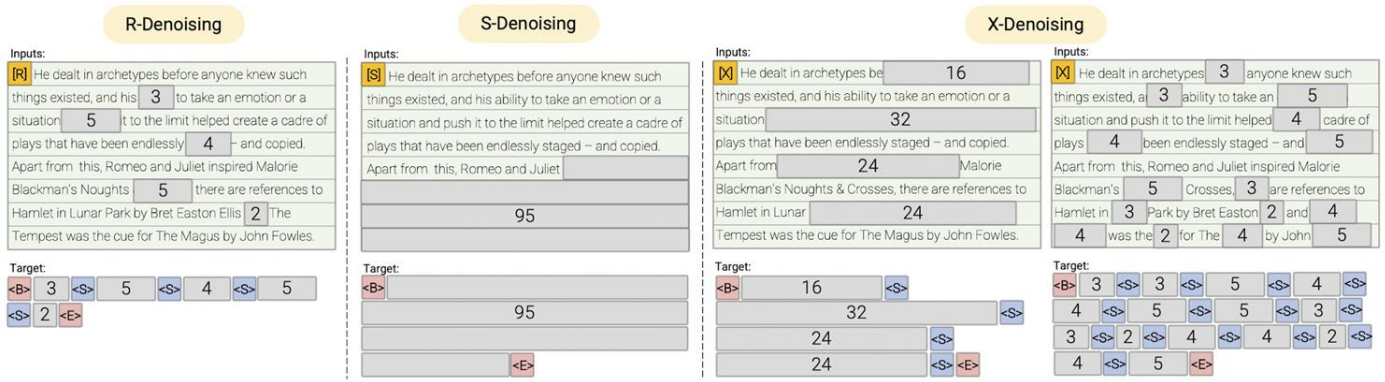
[57] Li Dong et al. (2019), “Unified Language Model Pre-training for Natural Language Understanding and Generation” NeurIPS2019 より引用

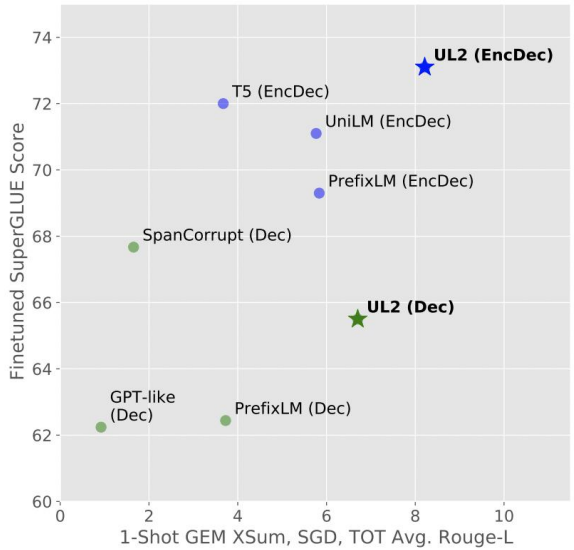
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

UL2：複数のタスクを設定した統一的な目的関数での事前学習

“UL2: Unifying Language Learning Paradigms”, 2022





方法

- T5のような欠落したトークンの予測(R-Denoising,X-Denoising)とGPTのような連続的なトークンの予測を組み合わせたMoD（Mixture-of-Denoisers）と呼ばれる統一的な目的関数で学習
- MoDを継続的な事前学習に用いるUL2R(UL2 Repair)という訓練方法も後に提案

結果

- EncDecとDecの両方のアーキテクチャでバランス良く性能の向上を確認

[58] Yi Tay et al. (2022), “UL2: Unifying Language Learning Paradigms” より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

発展的話題

データ	• 主要なデータセット • データ処理(クレンジング、トークナイズ)
モデル	• 主要なモデル • アーキテクチャの構成要素
学習	• Attention • 目的関数
評価、分析	• 評価 • 分析

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

評価対象の広がり

評価対象	概要	主なデータセット
自然言語理解	• 入力系列の理解を行うタスク • 従来の主な評価の対象	GLUE, SuperGLUE SQuAD, MMLU
ドメイン知識	• 数学や科学、医学など 解答に専門的な知識を要するタスク	MATH, MultiMedQA. APPS, CUAD
倫理性、信頼性	• 社会的なバイアスを含まないか、 どのような特性を持っているかを 検証するタスク	FLASK, TrustGPT, TruthfulQA
ツール活用	• 外部のAPIなどを活用して 解答を作成できるか検証するタスク	ToolBench

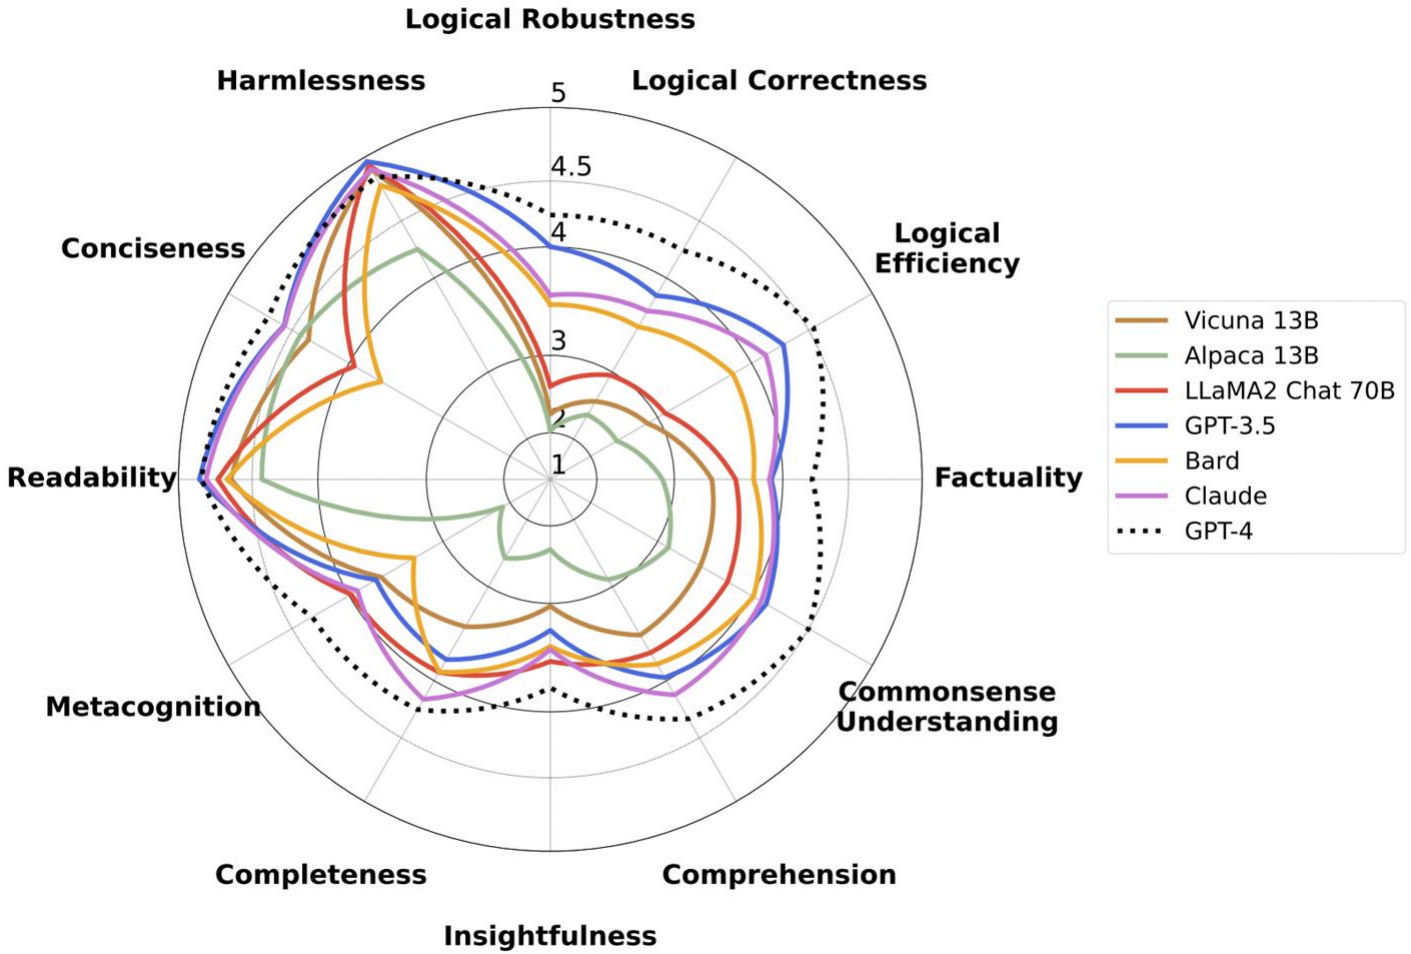
[26] Wayne Xin Zhao et al. (2023), "A Survey of Large Language Models" より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

FLASK：言語モデルの総合的な性能を評価するベンチマーク

“FLASK: Fine-grained Language Model Evaluation based on Alignment Skill Sets”, 2023



- LLMに必要なスキルを定義し、モデルの振る舞いに対して人間またはモデルによるスコアリングを行うベンチマーク
- 主に4つの能力（論理的思考、背景知識、問題解決能力、指示追従性）からなる評価枠組みを構築し、これらを12の詳細なスキル項目に細分化

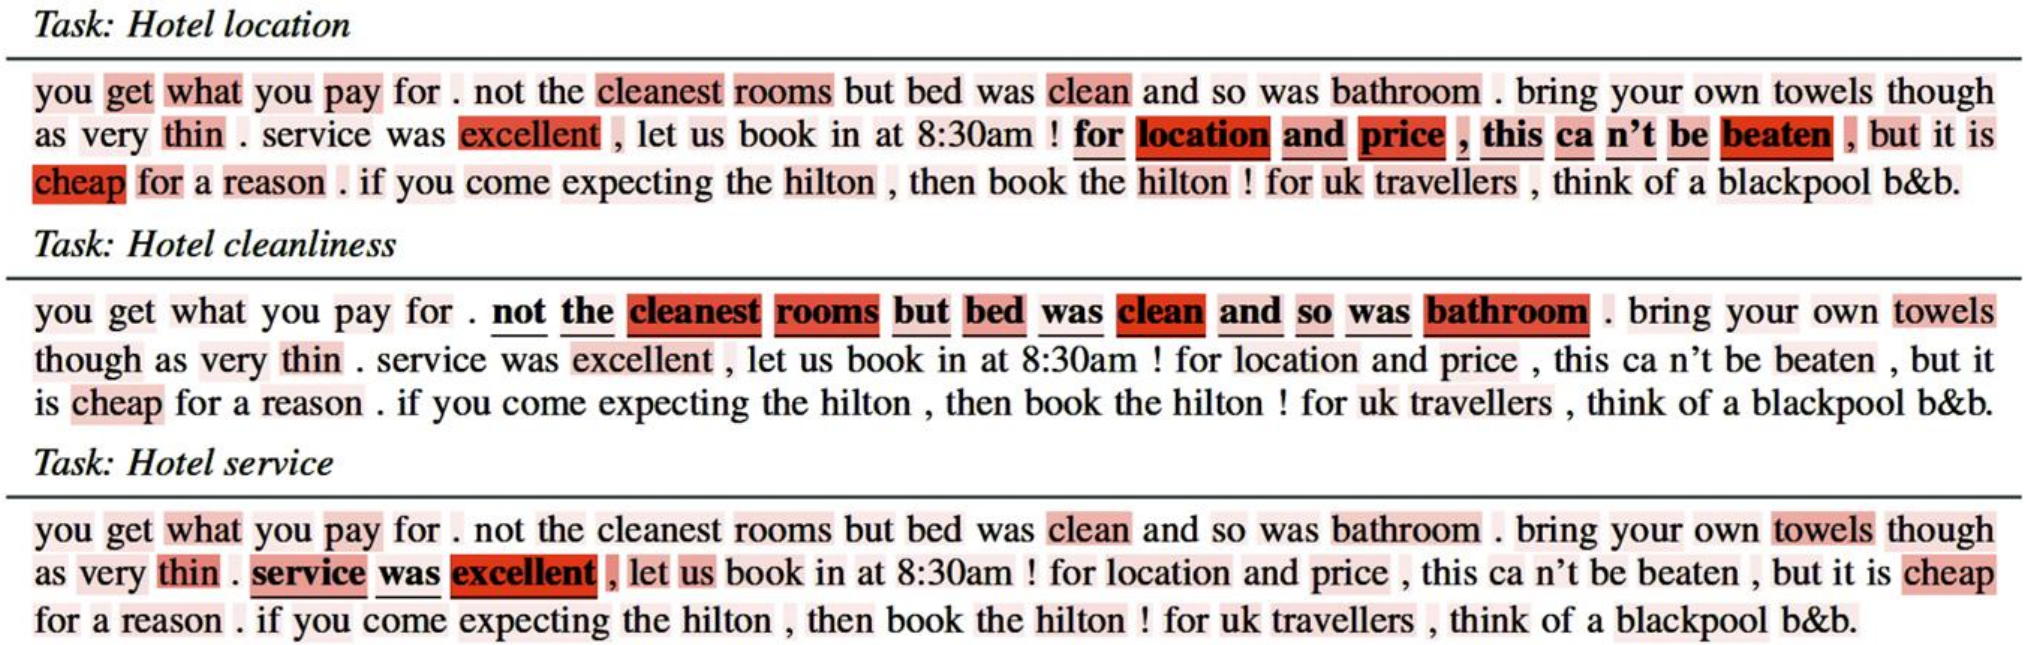
[60] Seonghyeon Ye et al. (2023), “FLASK: Fine-grained Language Model Evaluation based on Alignment Skill Sets” より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Attentionによる可視化分析

“Attention in Natural Language Processing”, 2019



Task: Hotel location

you get what you pay for . not the cleanest rooms but bed was clean and so was bathroom . bring your own towels though as very thin . service was excellent , let us book in at 8:30am ! **for location and price , this ca n’t be beaten** , but it is cheap for a reason . if you come expecting the hilton , then book the hilton ! for uk travellers , think of a blackpool b&b.

Task: Hotel cleanliness

you get what you pay for . **not the cleanest rooms but bed was clean and so was bathroom** . bring your own towels though as very thin . service was excellent , let us book in at 8:30am ! for location and price , this ca n’t be beaten , but it is cheap for a reason . if you come expecting the hilton , then book the hilton ! for uk travellers , think of a blackpool b&b.

Task: Hotel service

you get what you pay for . not the cleanest rooms but bed was clean and so was bathroom . bring your own towels though as very thin . **service was excellent** , let us book in at 8:30am ! for location and price , this ca n’t be beaten , but it is cheap for a reason . if you come expecting the hilton , then book the hilton ! for uk travellers , think of a blackpool b&b.

Fig. 1. Example of attention visualization for an aspect-based sentiment analysis task, from [1, Fig. 6]. Words are highlighted according to attention scores. Phrases in bold are the words considered relevant for the task or human rationales.

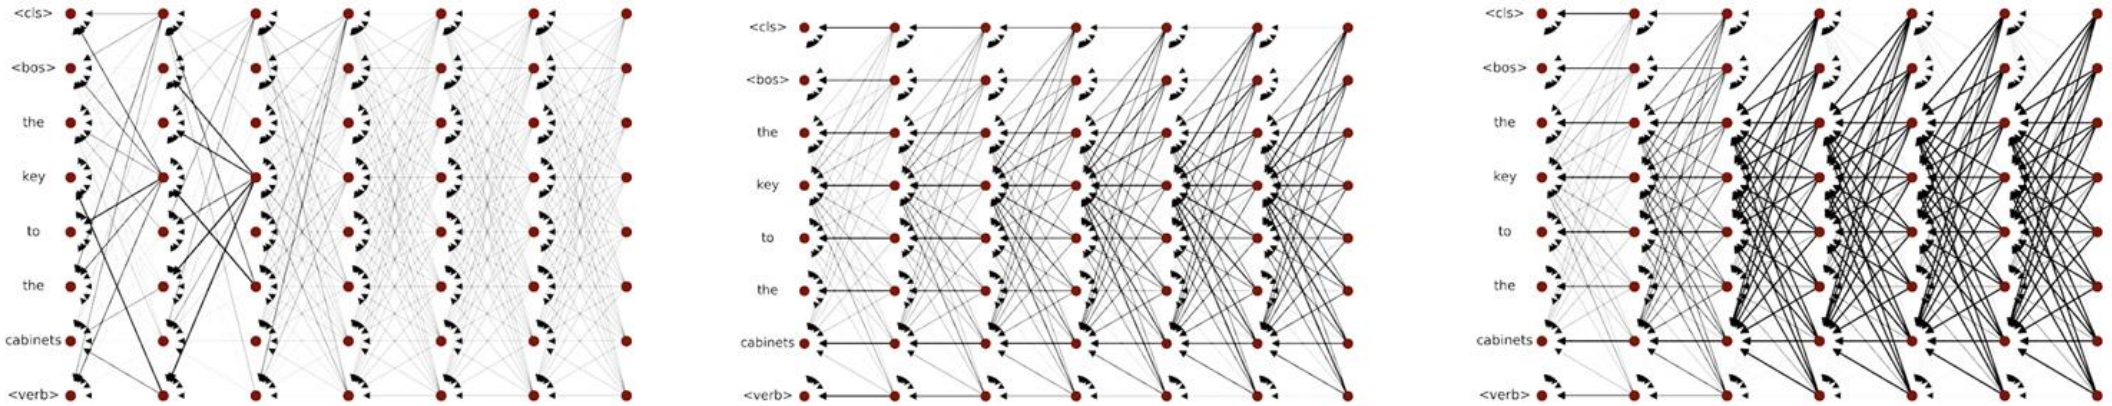
- Attentionの大小は度々可視化され、それをAttention mapと呼ぶ。
  上図のハイライトされているものはAttentionスコアが高い単語である
- 一見Attentionは単語の重要性を表しているように見える一方で、
  Attentionには説明能力はないのではとする立場の論文も複数存在

[61] Andrea Galassi et al. (2019), “Attention in Natural Language Processing” より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Attention Rollout / Flow：Attention mapから入力への寄与を計算

“Quantifying Attention Flow in Transformers”, ACL2020



- 従来のAttentionでは複数の層を経由して情報がやり取りされるので、Attention mapそのままを各状態の入力に対する寄与として解釈するには信頼性が不足
- Attention Rolloutでは、自分より前にある層のAttention mapを掛け合わせていく
- Attention Flowでは、各層のAttentionをフローネットワークとして解釈し入力トークンへの注意の近似を行う

[62] Samira Abnar & Willem Zuidema (2020), “Quantifying Attention Flow in Transformers” ACL2020 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

■補足 | 任意のタスクでAttentionを必ず使うべきとは限らない

“Are Pre-trained Convolutions Better than Pre-trained Transformers?”, ACL2021

Model	CIVILCOMMENT Acc	CIVILCOMMENT F1	WIKITOXIC Acc	WIKITOXIC F1	IMDb Acc	SST-2 Acc	S140 Acc	TREC Acc	News Acc
No pre-training									
Trans.	77.22	85.09	91.93	95.45	84.81	78.44	58.84	78.00	84.25
Light	78.58	85.82	91.05	94.65	**85.88**	81.65	60.64	**82.20**	**87.22**
Dilat.	**79.94**	**86.50**	**92.29**	94.91	85.84	79.01	55.62	79.60	81.24
Dyna.	78.49	84.71	90.06	**95.66**	85.69	**82.80**	**60.84**	80.20	85.13
With pre-training									
Trans.	81.16	86.56	91.46	95.12	**94.16**	92.09	61.65	93.60	93.54
Light	81.47	87.58	93.61	96.48	93.60	**92.20**	61.65	93.60	93.63
Dilat.	81.67	**87.78**	**93.84**	96.21	93.92	92.09	**62.85**	**94.20**	93.26
Dyna.	**81.83**	87.71	93.76	**96.53**	93.35	91.59	62.45	92.40	**93.93**

- 現在において事前学習とTransformerはスタンダードになっているが、これはセットで意味があるのか？
- CNNでも事前学習効果あり
- 一部のタスクでCNNモデルがT5を上回る性能を発揮
- CNNが常にTransformerの代替となるわけではないが、**事前学習というパラダイムシフトとアーキテクチャの変遷は分けて考えるべきと主張**

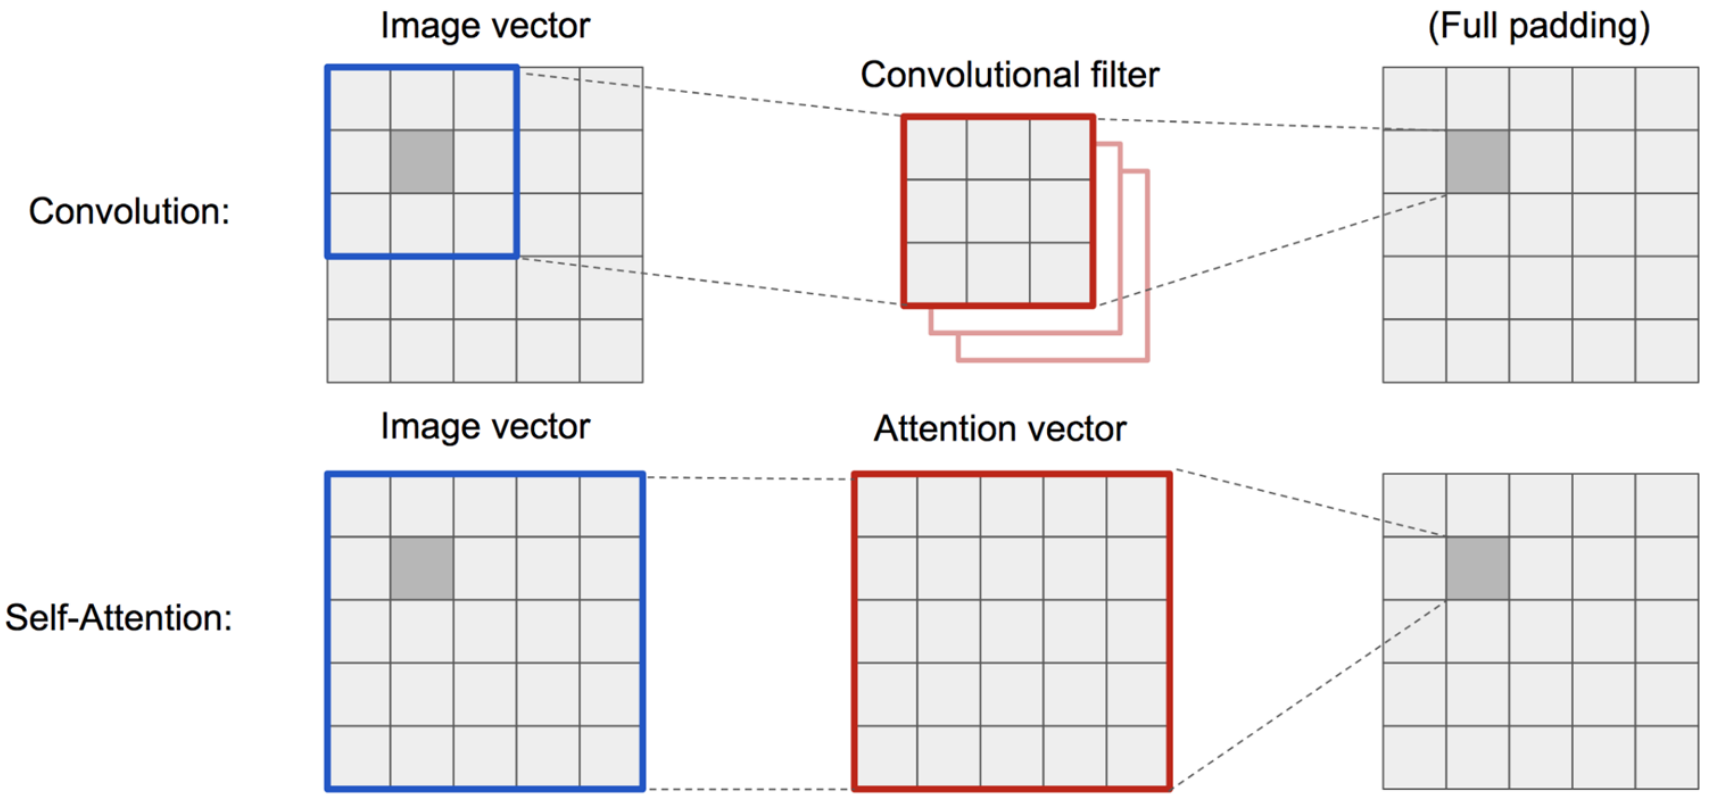
[63] Yi Tay et al. (2021), “Are Pre-trained Convolutions Better than Pre-trained Transformers?” ACL2021 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

■補足 | ConvolutionとSelf Attentionの関係

“On the Relationship between Self-Attention and Convolutional Layers”, ICLR2020



Filter：
　パラメータ（静的）
範囲：
　局所

Filter：
　入力依存（動的）
範囲：
　大域
※ただし相対位置表現を使うとMulti-Head Self-AttentionはConvを内包

[64] Jean-Baptiste et al. (2020), “On the Relationship between Self-Attention and Convolutional Layers” ICLR2020 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

敵対的攻撃、敵対的防御：言語モデルの弱点に関する分析方法

“What are adversarial examples in NLP?”, 2020

■ 極性分析での敵対的攻撃の例

Original Input	Connoisseurs of Chinese film will be pleased to discover that Tian's meticulous talent has not withered during his enforced hiatus.	Prediction: **Positive (77%)**
Adversarial example [Visually similar]	**Aonnoisseurs** of Chinese film will be pleased to discover that Tian's meticulous talent has not withered during his enforced hiatus.	Prediction: **Negative (52%)**
Adversarial example [Semantically similar]	Connoisseurs of Chinese **footage** will be pleased to discover that Tian's meticulous talent has not withered during his enforced hiatus.	Prediction: **Negative (54%)**

問題意識

人間に対しては些細な影響しか与えないような摂動でも、ニューラルネットは大きく影響を受けてしまう場合が存在している

方法

入力の一部を編集させた結果モデルの性能を劣化させる攻撃を検証するとともに、その攻撃による失敗を防ぐ防御方法を検討する

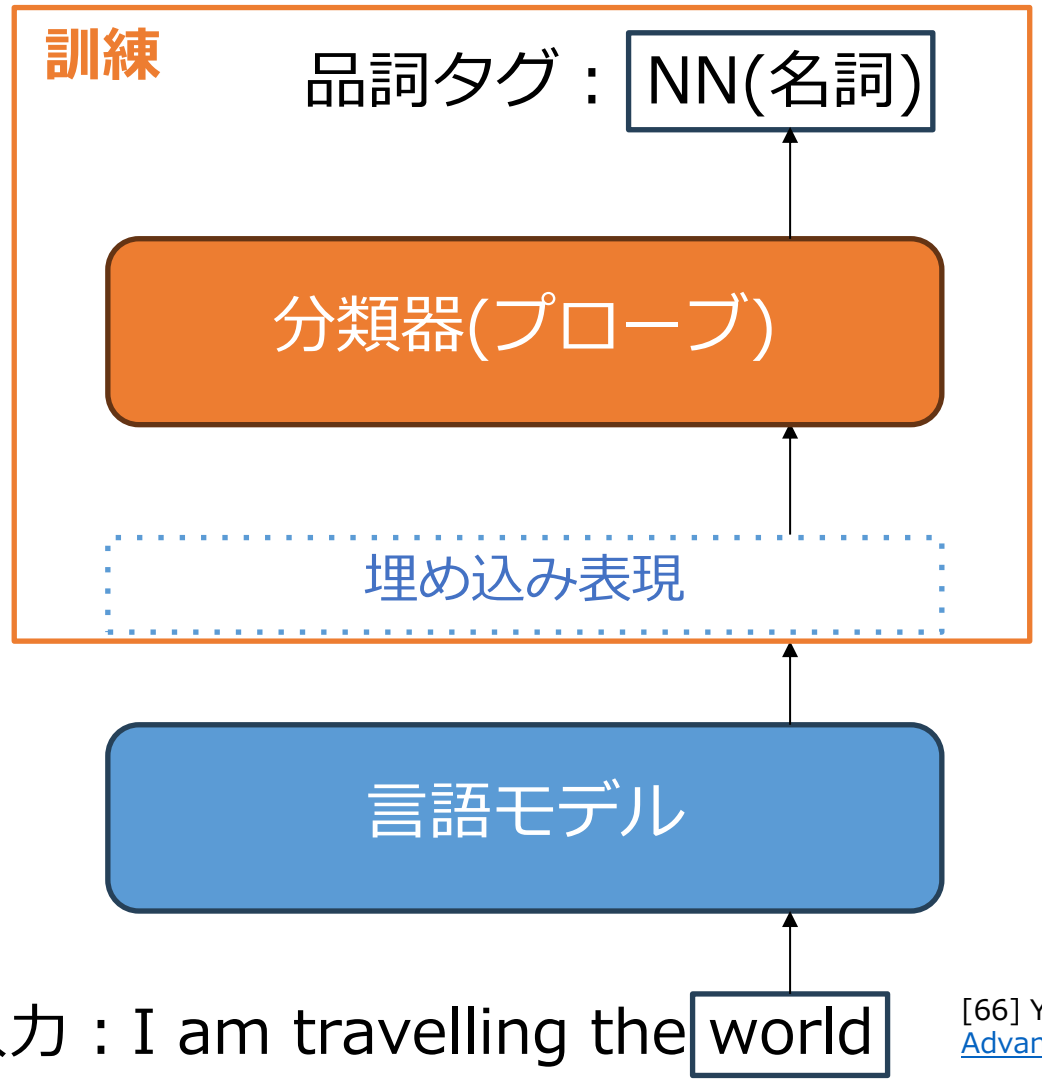
[65] Jack Morris (2020), “What are adversarial examples in NLP?” より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

プロービング：言語モデルが内部的に獲得する能力の分析手法

品詞分類能力についてのプロービングの例



問題意識

言語モデルのタスクの性能は出力によって評価できるが、言語モデルが内部的に獲得している能力は出力によっては簡単に評価できない

方法

ある入力を与えた場合の言語モデルから得られる埋め込み表現から特定のタスク(左図では品詞分類)を行う分類器(プローブ)を訓練した場合のタスクの成功率から埋め込み表現にそのタスクを示す表現がエンコードされているかを検証する

近年はモデルの埋め込み表現に介入を行い、出力への因果関係を調査する場合も多い

[66] Yonatan Belinkov (2022), "Probing Classifiers: Promises, Shortcomings, and Advances" ACL2022 を参考

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

本日のまとめ

大規模言語モデル（LLM）の事前学習について紹介

1. 言語モデルにおけるTransformerの位置づけ
   - Transformerはニューラル言語モデルの一つとして扱われる
   - RNN型言語モデルが抱えていた課題を解決した

2. LLMで主流となっているTransformerモデル構造
   - Self-Attention機構を持つモデル構造であり1ステップで全単語情報と接続できる
   - 課題①の解決: 単語間の長距離依存性が把握できるようになった
   - 課題②の解決: 誤差逆伝播の計算ステップが文長に非依存となり学習安定高速化

3. LLMの事前学習
   - 大規模コーパスによる学習を行うことで、モデルの汎用性を高めている
   - Next Token Predictionという自己教師あり学習により最適化する

4. 発展的話題
   - データ, モデル, 学習, 評価分析についての発展的な話題を解説

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

補足資料

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

モデルごとの学習方法の違い

"A Survey of Large Language Models", 2023

TABLE 5
Detailed optimization settings of several existing LLMs.

Model	Batch Size (#tokens)	Learning Rate	Warmup	Decay Method	Optimizer	Precision Type	Weight Decay	Grad Clip	Dropout
GPT3 (175B)	32K→3.2M	6×10^{-5}	yes	cosine decay to 10%	Adam	FP16	0.1	1.0	-
PanGu-α (200B)	-	2×10^{-5}	-	-	Adam	-	0.1	-	-
OPT (175B)	2M	1.2×10^{-4}	yes	manual decay	AdamW	FP16	0.1	-	0.1
PaLM (540B)	1M→4M	1×10^{-2}	no	inverse square root	Adafactor	BF16	lr^2	1.0	0.1
BLOOM (176B)	4M	6×10^{-5}	yes	cosine decay to 10%	Adam	BF16	0.1	1.0	0.0
MT-NLG (530B)	64 K→3.75M	5×10^{-5}	yes	cosine decay to 10%	Adam	BF16	0.1	1.0	-
Gopher (280B)	3M→6M	4×10^{-5}	yes	cosine decay to 10%	Adam	BF16	-	1.0	-
Chinchilla (70B)	1.5M→3M	1×10^{-4}	yes	cosine decay to 10%	AdamW	BF16	-	-	-
Galactica (120B)	2M	7×10^{-6}	yes	linear decay to 10%	AdamW	-	0.1	1.0	0.1
LaMDA (137B)	256K	-	-	-	-	BF16	-	-	-
Jurassic-1 (178B)	32 K→3.2M	6×10^{-5}	yes	-	-	-	-	-	-
LLaMA (65B)	4M	1.5×10^{-4}	yes	cosine decay to 10%	AdamW	-	0.1	1.0	-
GLM (130B)	0.4M→8.25M	8×10^{-5}	yes	cosine decay to 10%	AdamW	FP16	0.1	1.0	0.1
T5 (11B)	64K	1×10^{-2}	no	inverse square root	AdaFactor	-	-	-	0.1
ERNIE 3.0 Titan (260B)	-	1×10^{-4}	-	-	Adam	FP16	0.1	1.0	-
PanGu-Σ (1.085T)	0.5M	2×10^{-5}	yes	-	Adam	FP16	-	-	-

[26] Wayne Xin Zhao et al. (2023), "A Survey of Large Language Models" より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

モデルごとの細かな要素の違い

“A Survey of Large Language Models”, 2023

TABLE 5: Model cards of several selected LLMs with public configuration details. Here, PE denotes position embedding, #L denotes the number of layers, #H denotes the number of attention heads, d_{model} denotes the size of hidden states, and MCL denotes the maximum context length during training.

Model	Category	Size	Normalization	PE	Activation	Bias	#L	#H	d_{model}	MCL
GPT3 [55]	Causal decoder	175B	Pre LayerNorm	Learned	GeLU	✓	96	96	12288	2048
PanGU- α [84]	Causal decoder	207B	Pre LayerNorm	Learned	GeLU	✓	64	128	16384	1024
OPT [90]	Causal decoder	175B	Pre LayerNorm	Learned	ReLU	✓	96	96	12288	2048
PaLM [56]	Causal decoder	540B	Pre LayerNorm	RoPE	SwiGLU	×	118	48	18432	2048
BLOOM [78]	Causal decoder	176B	Pre LayerNorm	ALiBi	GeLU	✓	70	112	14336	2048
MT-NLG [113]	Causal decoder	530B	-	-	-	-	105	128	20480	2048
Gopher [64]	Causal decoder	280B	Pre RMSNorm	Relative	-	-	80	128	16384	2048
Chinchilla [34]	Causal decoder	70B	Pre RMSNorm	Relative	-	-	80	64	8192	-
Galactica [35]	Causal decoder	120B	Pre LayerNorm	Learned	GeLU	×	96	80	10240	2048
LaMDA [68]	Causal decoder	137B	-	Relative	GeGLU	-	64	128	8192	-
Jurassic-1 [107]	Causal decoder	178B	Pre LayerNorm	Learned	GeLU	✓	76	96	13824	2048
LLaMA [57]	Causal decoder	65B	Pre RMSNorm	RoPE	SwiGLU	×	80	64	8192	2048
LLaMA 2 [99]	Causal decoder	70B	Pre RMSNorm	RePE	SwiGLU	×	80	64	8192	4096
Falcon [141]	Causal decoder	40B	Pre LayerNorm	RoPE	GeLU	×	60	64	8192	2048
GLM-130B [93]	Prefix decoder	130B	Post DeepNorm	RoPE	GeGLU	✓	70	96	12288	2048
T5 [82]	Encoder-decoder	11B	Pre RMSNorm	Relative	ReLU	×	24	128	1024	512

[26] Wayne Xin Zhao et al. (2023), “A Survey of Large Language Models” より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Accessibility of Models

Model	Model Creator	Modality	# Parameters	Tokenizer	Window Size	Access	Total Tokens	Total Queries	Total Cost
J1-Jumbo v1 (178B)	AI21 Labs	Text	178B	AI21	2047	limited	327,443,515	591,384	$10,926
J1-Grande v1 (17B)	AI21 Labs	Text	17B	AI21	2047	limited	326,815,150	591,384	$2,973
J1-Large v1 (7.5B)	AI21 Labs	Text	7.5B	AI21	2047	limited	342,616,800	601,560	$1,128
Anthropic-LM v4-s3 (52B)	Anthropic	Text	52B	GPT-2	8192	closed	767,856,111	842,195	-
BLOOM (176B)	BigScience	Text	176B	BLOOM	2048	open	581,384,088	849,303	4,200 GPU hours
T0++ (11B)	BigScience	Text	11B	T0	1024	open	305,488,229	406,072	1,250 GPU hours
Cohere xlarge v20220609 (52.4B)	Cohere	Text	52.4B	Cohere	2047	limited	397,920,975	597,252	$1,743
Cohere large v20220720 (13.1B)[58]	Cohere	Text	13.1B	Cohere	2047	limited	398,293,651	597,252	$1,743
Cohere medium v20220720 (6.1B)	Cohere	Text	6.1B	Cohere	2047	limited	398,036,367	597,252	$1,743
Cohere small v20220720 (410M)[59]	Cohere	Text	410M	Cohere	2047	limited	399,114,309	597,252	$1,743
GPT-J (6B)	EleutherAI	Text	6B	GPT-J	2048	open	611,026,748	851,178	860 GPU hours
GPT-NeoX (20B)	EleutherAI	Text	20B	GPT-NeoX	2048	open	599,170,730	849,830	540 GPU hours
T5 (11B)	Google	Text	11B	T5	512	open	199,017,126	406,072	1,380 GPU hours
UL2 (20B)	Google	Text	20B	UL2	512	open	199,539,380	406,072	1,570 GPU hours
OPT (66B)	Meta	Text	66B	OPT	2048	open	612,752,867	851,178	2,000 GPU hours
OPT (175B)	Meta	Text	175B	OPT	2048	open	610,436,798	851,178	3,400 GPU hours
TNLG v2 (6.7B)	Microsoft/NVIDIA	Text	6.7B	GPT-2	2047	closed	417,583,950	590,756	-
TNLG v2 (530B)	Microsoft/NVIDIA	Text	530B	GPT-2	2047	closed	417,111,519	590,756	-
GPT-3 davinci v1 (175B)	OpenAI	Text	175B	GPT-2	2048	limited	422,001,611	606,253	$8,440
GPT-3 curie v1 (6.7B)	OpenAI	Text	6.7B	GPT-2	2048	limited	423,016,414	606,253	$846
GPT-3 babbage v1 (1.3B)	OpenAI	Text	1.3B	GPT-2	2048	limited	422,123,900	606,253	$211
GPT-3 ada v1 (350M)	OpenAI	Text	350M	GPT-2	2048	limited	422,635,705	604,253	$169
InstructGPT davinci v2 (175B*)	OpenAI	Text	175B*	GPT-2	4000	limited	466,872,228	599,815	$9,337
InstructGPT curie v1 (6.7B*)	OpenAI	Text	6.7B*	GPT-2	2048	limited	420,004,477	606,253	$840
InstructGPT babbage v1 (1.3B*)	OpenAI	Text	1.3B*	GPT-2	2048	limited	419,036,038	604,253	$210
InstructGPT ada v1 (350M*)	OpenAI	Text	350M*	GPT-2	2048	limited	418,915,281	604,253	$168
Codex davinci v2	OpenAI	Code	Unknown	GPT-2	4000	limited	46,272,590	57,051	$925
Codex cushman v1	OpenAI	Code	Unknown	GPT-2	2048	limited	42,659,399	59,751	$85
GLM (130B)	Tsinghua University	Text	130B	ICE	2048	open	375,474,243	406,072	2,100 GPU hours
YaLM (100B)	Yandex	Text	100B	Yandex	2048	open	378,607,292	405,093	2,200 GPU hours



[67] Percy Liang (2022), "Holistic Evaluation of Language Models" より引用し,一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Reference

[1] 岡崎直観 (2023), 大規模言語モデルの驚異と脅威 - Speaker Deckアクセス日: 2025/10/1

[2] Ilya Sutskever et al. (2014), “sequence to sequence learning with neural networks”, NeurIPS2014

[3] Tomáš Mikolov, et al. (2010), “recurrent neural network based language model”, Proc. Interspeech 2010, 1045-1048

[4] Dzmitry Bahdanau et al. (2014), “Neural machine translation by jointly learning to align and translate”, arXiv:1409.0473

[5] Masaki Hayashi (2022), Transformer と seq2seq with attention の違いは？系列変換モデル【Q and A 記事】 | CVMLエキスパートガイドアクセス日: 2025/10/1

[6] Ashish Vaswani et al. (2017), “Attention Is All You Need”, NeurIPS2017

[7] OpenAI (2023) “GPT-4 Technical Report”, arXiv:2303.08774

[8] OpenAI (2025), “GPT-5 System Card”アクセス日: 2025/10/1

[9] OpenAI (2025), “GPT-5 が登場” アクセス日: 2025/10/1

[10] Google (2025), “Gemini 2.5 tech report” アクセス日: 2025/10/1

[11] OpenAI (2024), “Learning to Reason with LLMs”

[12] Allen Institute for AI, Univ. of Washington, NYU (2025), “2 OLMo 2 Furious”, arXiv: 2501.00656

[13] OpenAI (2025), “gpt-oss-120b & gpt-oss-20b Model Card ”, arXiv: 2508.10925

[14] Qwen (2025), “Qwen3 Technical Report” , arXiv: 2505.09388

[15] Shraddha Anala (2020), ”A Guide to Word Embedding. What are they? How are they more useful… | by Shraddha Anala | Towards Data Science”
アクセス日: 2025/10/1

[16] John Hewitt, Natural Language Processing with Deep Learning CS224N/Ling284 アクセス日:2025/10/1

[17] Raimi Karim (2019) Illustrated: Self-Attention. A step-by-step guide to self-attention… | by Raimi Karim | Medium,
https://medium.com/data-science/illustrated-self-attention-2d627e33b20a アクセス日:2025/9/3

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Reference

[18] Jay Alammar (2018) The Illustrated Transformer – Jay Alammar – Visualizing machine learning one concept at a time. https://jalammar.github.io/illustrated-transformer/ アクセス日:2023/11/19

[19] Mor Geva et al. (2021), “Transformer Feed-Forward Layers Are Key-Value Memories”, Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing, pages 5484–5495

[20] Kaiming He et al. (2016), “Deep Residual Learning for Image Recognition”,2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) pages 770-778

[21] Jimmy Lei Ba et al. (2016), "Layer Normalization”, arXiv:1607.06450

[22] Rishi Bommasani et al. (2021), “On the Opportunities and Risks of Foundation Models”, arXiv:2108.07258

[23] Hugo Touvron et al. (2023), “LLaMA: Open and Efficient Foundation Language Models”, arXiv:2302.13971

[24] Tom Brown et al. (2020), “Language Models are Few-Shot Learners”, NeurIPS2020（図中のfigureはarXiv版より引用）

[25] Luca Soldaini (2023), AI2 Dolma: 3 Trillion Token Open Corpus for LLMs | AI2 Blog, https://blog.allenai.org/dolma-3-trillion-tokens-open-llm-corpus-9a0ff4b8da64 アクセス日:2023/11/19

[26] Wayne Xin Zhao et al. (2023), “A Survey of Large Language Models”, arXiv:2303.18223

[27] Guilherme Penedo et al.(2023), “The RefinedWeb Dataset for Falcon LLM: Outperforming Curated Corpora with Web Data, and Web Data Only” arXiv: 2306.01116

[28] Hugo Touvron et al. (2023), "Llama 2: Open Foundation and Fine-Tuned Chat Models” arXiv:2307.09288

[29] Fuzhao Xue et al. (2023), “To Repeat or Not To Repeat: Insights from Scaling LLM under Token-Crisis”, arXiv:2305.13230

[30] Niklas Muennighoff et al. (2023), “Scaling Data-Constrained Language Models”, arXiv:2305.16264

[31] Stas Bekman (2022) The Technology Behind BLOOM Training https://huggingface.co/blog/bloom-megatron-deepspeed アクセス日: 2023/11/19

[32] suchenxang (2023), metaseq/projects/OPT/chronicles/OPT175B_Logbook.pdf at main · facebookresearch/metaseq · GitHub, https://github.com/facebookresearch/metaseq/blob/main/projects/OPT/chronicles/OPT175B_Logbook.pdf アクセス日:2023/11/19

[33] Diederik P. Kingma & Jimmy Ba, (2014), “Adam: A Method for Stochastic Optimization”, arXiv:1412.6980

[34] Ilya Loshchilov & Frank Hutter, (2017), “Decoupled Weight Decay Regularization”, arXiv:1711.05101

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Reference

[35] Shikoan's ML Blog (2021), Cosine DecayとWarmupを同時にこなすスケジューラー（timm）| Shikoan's ML Blog, https://blog.shikoan.com/?s=Cosine
アクセス日:2023/11/19

[36] Chip Huyen (2019) Evaluation Metrics for Language Modeling, https://thegradient.pub/understanding-evaluation-metrics-for-language-models/
アクセス日:2023/11/19

[37] Kaito Sugimoto (2021) テキスト生成における decoding テクニック: Greedy search, Beam search, Top-K, Top-p https://zenn.dev/hellorusk/articles/1c0bef15057b1d
アクセス日:2023/11/19

[38] mm_0824 (2020) ビームサーチ(Beam Search)を理解する | 楽しみながら理解するAI・機械学習入門 https://data-analytics.fun/2020/12/16/understanding-beamsearch/
アクセス日:2023/11/19

[39] cohere, Temperature, https://docs.cohere.com/docs/temperature, アクセス日:2023/12/1

[40] Hugging Face (2024) "The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale", arXiv:2406.17557

[41] Colin Raffel et al. (2020), "Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer",
The Journal of Machine Learning Research, Volume 21, Issue 1, Article No.: 140, pp 5485–5551

[42] Alexis Conneau et al. (2020), "Unsupervised Cross-lingual Representation Learning at Scale",
Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, pages 8440–8451

[43] Linting Xue et al. (2021), "mT5: A massively multilingual pre-trained text-to-text transformer",
Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, pages 483–498

[44] Leo Gao et al. (2020), "The Pile: An 800GB Dataset of Diverse Text for Language Modeling", arXiv:2101.00027

[45] Weber, et. Al. (2024), "RedPajama: an Open Dataset for Training Large Language Models", NeurIPS2024

[46] Hugging Face (2025 Hugging Face LLM Course アクセス日: 2025/10/1

[47] Linting Xue et al. (2022), "ByT5: Towards a token-free future with pre-trained byte-to-byte models"
Transactions of the Association for Computational Linguistics, vol. 10, pp. 291–306

[48] Jacob Devlin et al. (2019), "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding", Proceedings of NAACL-HLT 2019, pages 4171–4186

[49] Yinhan Liu et al. (2019), "RoBERTa: A Robustly Optimized BERT Pretraining Approach", arXiv:1907.11692

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Reference

[50] Zhenzhong Lan et al. (2020), “ALBERT: A Lite BERT for Self-supervised Learning of Language Representations” ICLR2020

[51] Mike Lewis et al. (2020), “BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension” Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, pages 7871–7880

[52] 清野舜 (2022), より良いTransformerをつくる - Speaker Deck https://speakerdeck.com/butsugiri/yoriliang-itransformerwotukuru アクセス日: 2023/11/19

[53] Ofir Press et al. (2021), “Train Short, Test Long: Attention with Linear Biases Enables Input Length Extrapolation” arXiv:2108.12409

[54] Manzil Zaheer et al. (2020), “Big Bird: Transformers for Longer Sequences” NeurIPS2020

[55] Iz Beltagy et al. (2020), “Longformer: The Long-Document Transformer”, arXiv:2004.05150

[56] Joshua Ainslie et al. (2023), “GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints” arXiv:2305.13245

[57] Li Dong et al. (2019), “Unified Language Model Pre-training for Natural Language Understanding and Generation” NeurIPS2019

[58] Yi Tay et al. (2022), “UL2: Unifying Language Learning Paradigms” arXiv:2205.05131

[59] Yupeng Chang et al. (2023), “A Survey on Evaluation of Large Language Models” arXiv:2307.03109

[60] Seonghyeon Ye et al. (2023), “FLASK: Fine-grained Language Model Evaluation based on Alignment Skill Sets” arXiv:2307.10928

[61] Andrea Galassi et al. (2019), “Attention in Natural Language Processing” arXiv:1902.02181

[62] Samira Abnar & Willem Zuidema (2020), “Quantifying Attention Flow in Transformers” Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, pages 4190–4197

[63] Yi Tay et al. (2021), “Are Pre-trained Convolutions Better than Pre-trained Transformers?” Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing, pages 4349–4359

[64] Jean-Baptiste et al. (2020), “On the Relationship between Self-Attention and Convolutional Layers” ICLR2020

[65] Jack Morris (2020), “What are adversarial examples in NLP?”, https://towardsdatascience.com/what-are-adversarial-examples-in-nlp-f928c574478e アクセス日: 2023/11/19

[66] Yonatan Belinkov (2022), “Probing Classifiers: Promises, Shortcomings, and Advances” Computational Linguistics, Volume 48, Issue 1 - March 2022 pages 207-119

[67] Percy Liang (2022), “Holistic Evaluation of Language Models” arXiv:2211.09110

[68] Marshall Haas (2022), “Sentence Embeddings”

LLM大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Reference

[69] Hugging Face, EPFL (2025) FineWeb2: One Pipeline to Scale Them All — Adapting Pre-Training Data Processing to Every Language, COLM2025

[70] The Big LLM Architecture Comparison https://magazine.sebastianraschka.com/p/the-big-llm-architecture-comparison
アクセス日: 2025/10/1

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO



松尾・岩澤研究室

MATSUO-IWASAWA LAB UTOKYO

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO