注意事項: 本資料の再利用(2次利用)について

- **本資料について**
  - 東京大学 松尾・岩澤研究室が作成し、2025年10月から11月にかけて開催されたLLM大規模言語モデル講座基礎編の講義資料です。
  - クリエイティブ・コモンズのCC BY-NC-SA 4.0 DEED(表示 – 非営利 – 継承 4.0 国際)のライセンス登録をしています。
- **ライセンスの表示について**
  - 各スライドのページ最下部にライセンスの記載があります。再利用時には本ライセンス表示を必ずご記載ください。再利用時に複製が困難な場合は、下記のテキストボックスを利用の上、ハイパーリンクも含めてライセンスの表記をするようお願いします。

    LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
  - 再利用するページに参照論文等の引用がある場合は、巻末にあるReferenceより引用箇所を掲載してください。
- **非営利目的での利用について**　再利用(2次利用)が許諾されています。
- **営利目的での再利用について**　こちらからお問い合わせください。
- **その他**
  - 元の表現が変わらない範囲(フォント、サイズ等)であれば改変可能です。
  - それ以外の改変その他ライセンスについての詳細は、こちらをご覧の上適切な取り扱いをお願いします。

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

スケール則

松尾・岩澤研究室
Matsuo-Iwasawa Lab UTokyo

座学：小島武
演習：余 振軒

許諾なく撮影や第三者
への開示を禁止します

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

小島 武（こじま たけし）

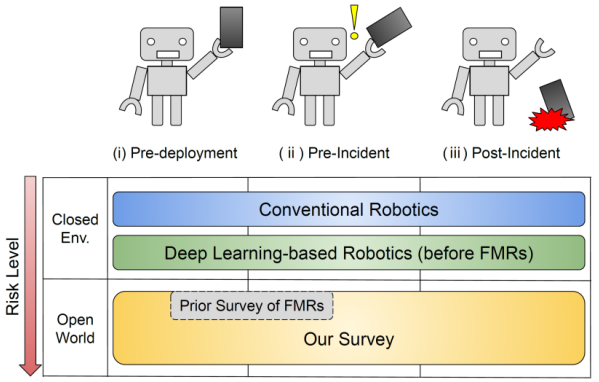
❏略歴

❏2023.3 東京大学大学院 工学系研究科 TMI 博士課程修了

❏2023.4～ 同研究科 特任研究員

❏2025.1～ 同研究科 特任助教

＊以前はITエンジニアをしてました.



https://arxiv.org/abs/2505.12583



https://github.com/kojima-takeshi188/zero_shot_cot

❏活動

Weblab-10Bの開発，岸田総理・石破総理のLLM特別講座で講師担当，LLM開発コンペ2024・2025運営側のコンテンツリーダー，AI白書2025でSafetyの章を執筆

❏研究

LLMの動作原理の理解と制御（Reasoning Model, 多言語等），Safety (Unlearning, 指示追従能力），Transformerモデル構造の改善，などなど + ロボット

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

スケール則（Day4）

- 目的：
  - ○ 言語モデルを**スケール（＝大規模化）**する意義について学ぶ.
- 目標：
  - ○ スケール則とはなにかおよびその重要性を説明できる.
  - ○ スケール則の具体的な求め方を説明、実装できる.
  - ○ 推論時のスケーリングとはなにかについて説明できる.
- 演習：
  - ○ PyTorchでスケール則を実際に求めるコードを実装する

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

目次

○ **スケール則とはなにか**

○ スケール則の使い方

○ スケール則の具体的な求め方

○ 新たなトレンド：推論時のスケーリング

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

スケール＝大規模化

大規模 言語モデル

Day4で(今から)説明します.

＊どうスケールさせるのか？
なぜスケールさせるのか？

Day3で説明しました.

＊近年のLLMで使われている
Transformerモデルは,
ニューラル言語モデルの一種.

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

■ LLM学習フローの中での位置づけ

Step 1

事前学習

Day3（前回） & Day4（本日）& Day5（次回）

大規模コーパスによる自己教師あり学習を通し、大規模言語モデルに
語彙・文法・基本知識といった基礎的な言語理解を獲得させる段階

Step 2

ファインチューニング

Day6

ラベル付きデータによる教師あり学習を通し、事前学習済みモデルの
性能を改善したり、特定のタスクやドメインへの適応を実現する段階

Step 3

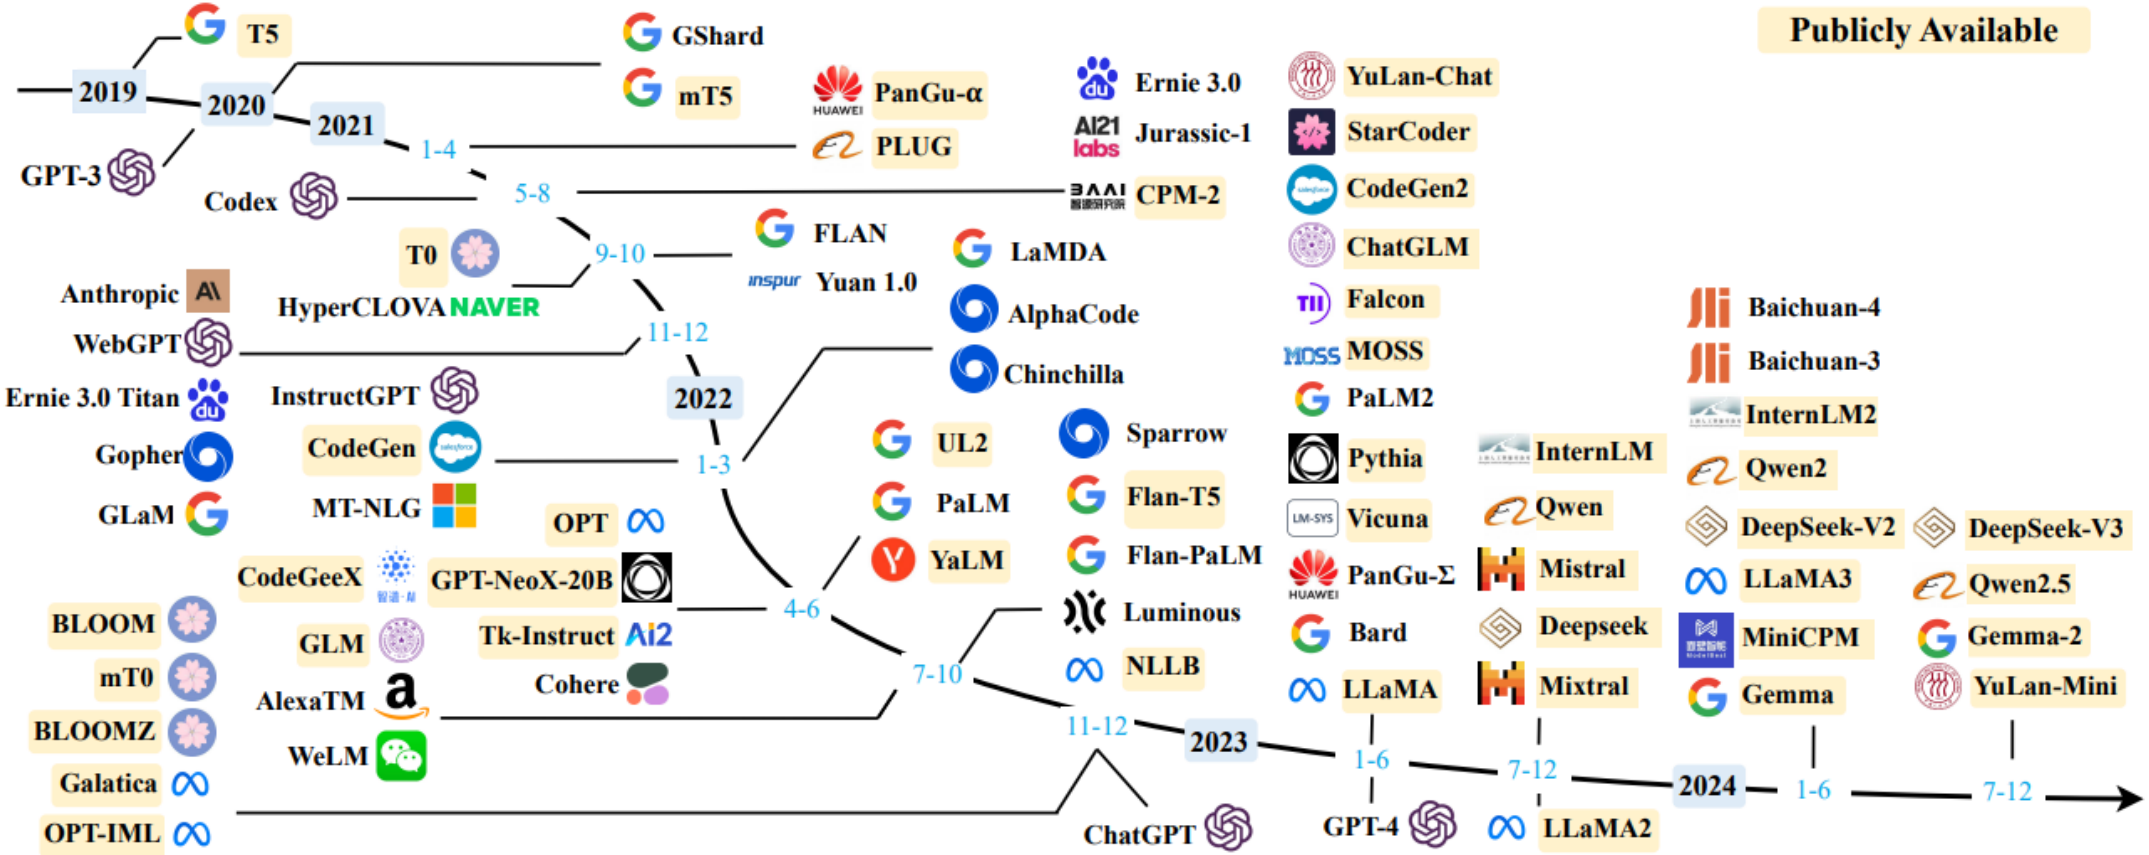
RLHF

Day7

人間からのフィードバックを用いた強化学習を通し、大規模言語モデルの
出力がより人間の価値観に沿ったものとなるよう調整する段階

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

大規模言語モデルの進展



“A Survey of Large Language Models”, 2023 (version 16)

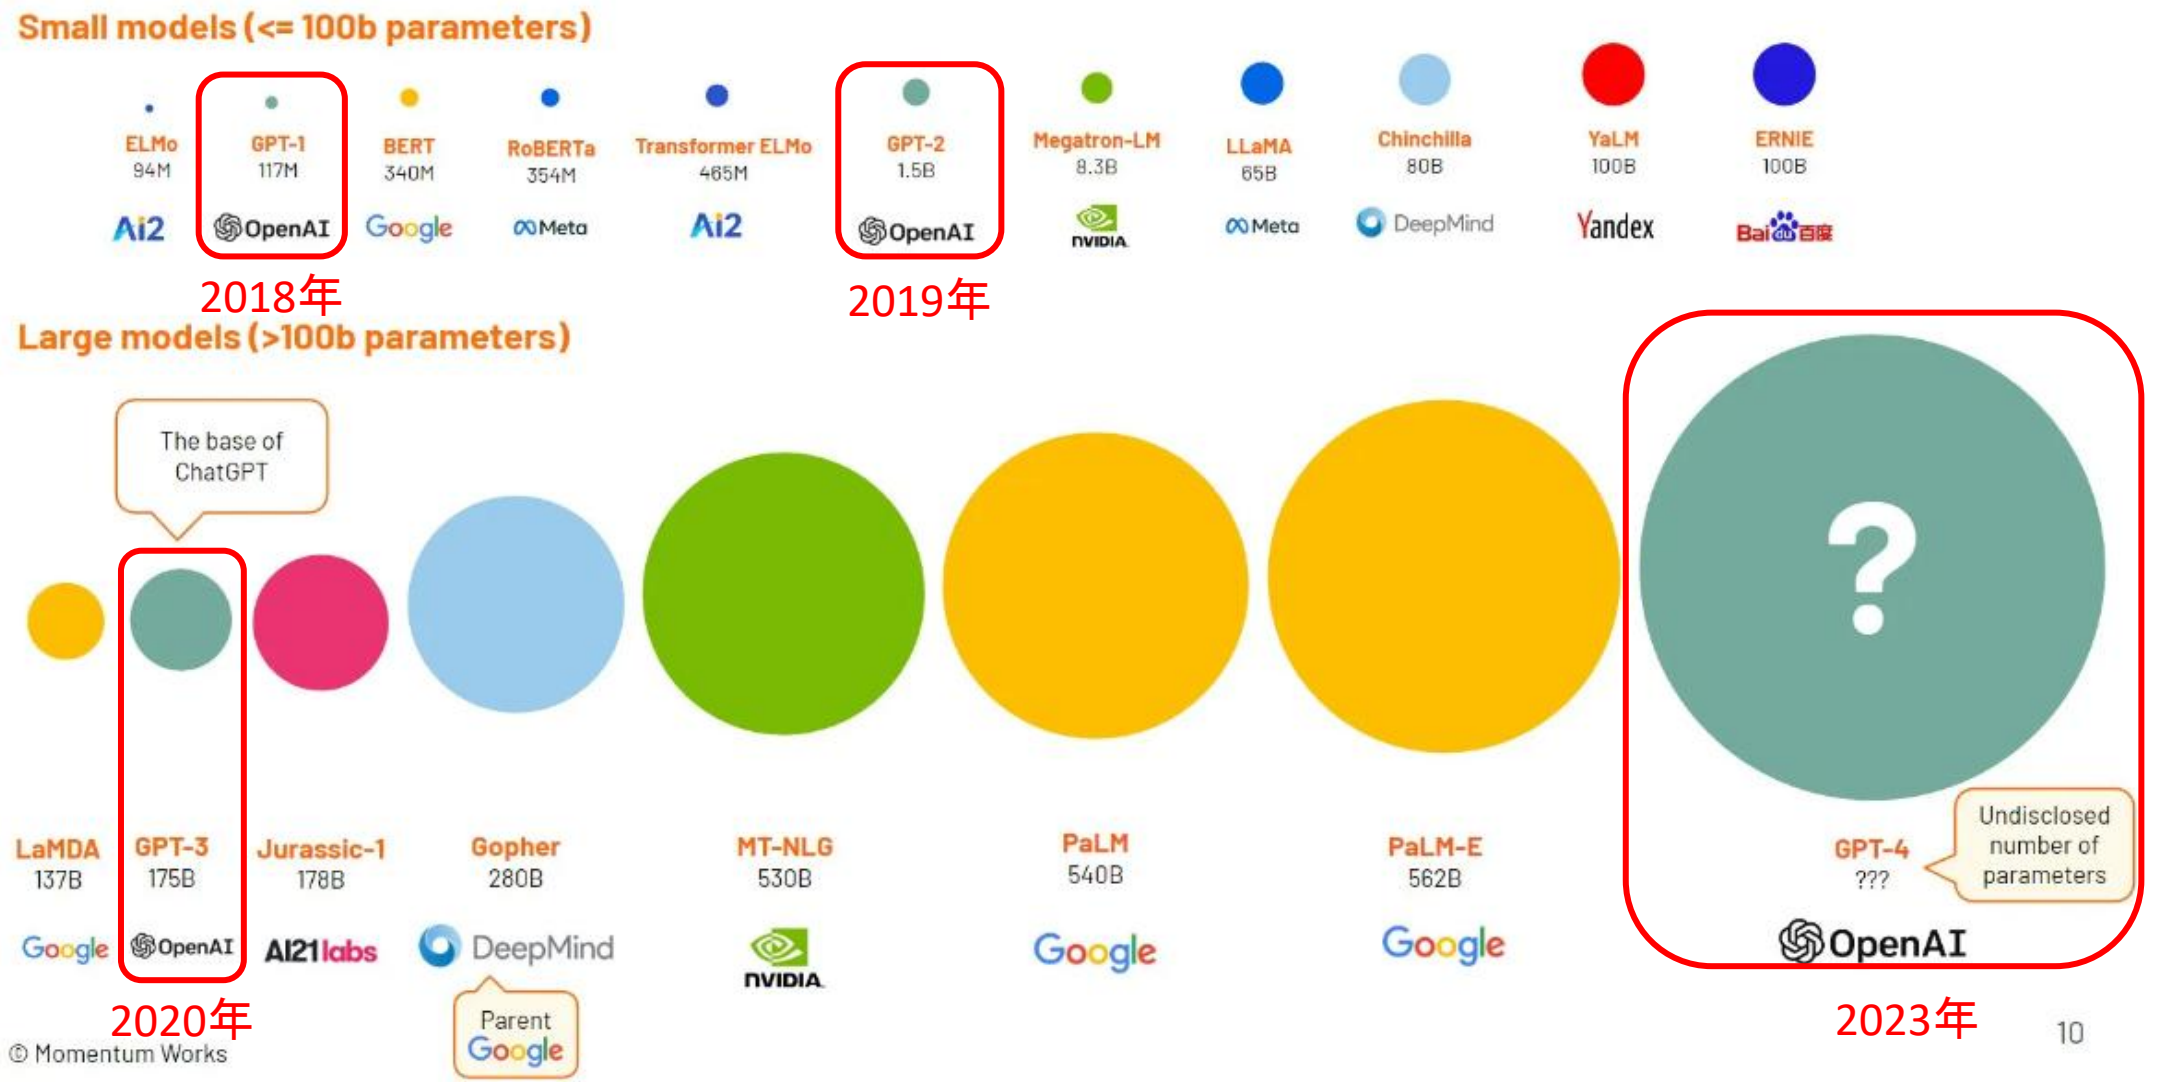
[[48] Zhao+. A Survey of Large Language Models. 2023 より引用

- 2025年以降も、GPT-5、Gemini2.5、GPT-OSS、DeepSeek-R1、Qwen3など多くのLLMが公開されている（継続中）.

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Transformerを使った言語モデルのスケール化[1]



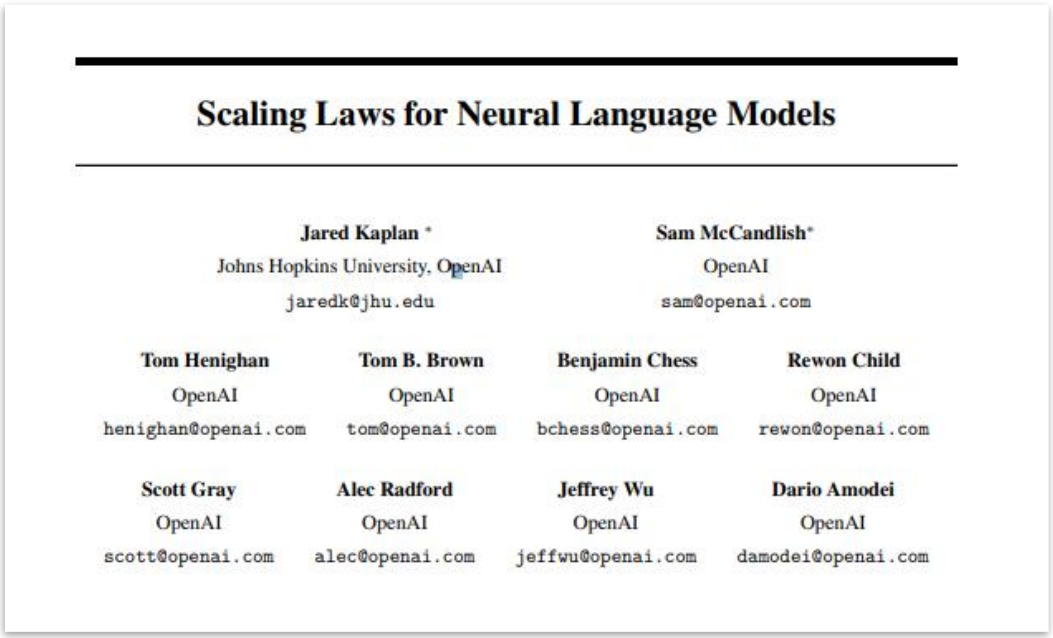
基本的にはいずれも2017年に発明されたTransformerと呼ばれる構造を利用.
GPT-3登場以降，米国企業を中心に複数の研究機関が独自の大規模言語モデルを開発.

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

What is Scaling? Why Scaling?

背景にあるのがスケール則と呼ばれる経験則．下記を中心に説明.

■ 重要論文１



Scaling Laws for Neural Language Models

Jared Kaplan *
Johns Hopkins University, OpenAI
jaredk@jhu.edu

Sam McCandlish*
OpenAI
sam@openai.com

Tom Henighan
OpenAI
henighan@openai.com

Tom B. Brown
OpenAI
tom@openai.com

Benjamin Chess
OpenAI
bchess@openai.com

Rewon Child
OpenAI
rewon@openai.com

Scott Gray
OpenAI
scott@openai.com

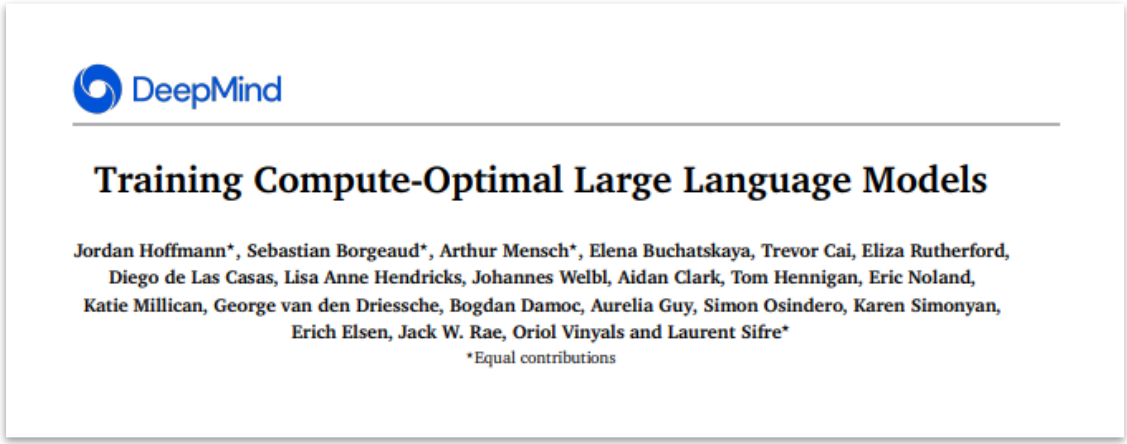
Alec Radford
OpenAI
alec@openai.com

Jeffrey Wu
OpenAI
jeffwu@openai.com

Dario Amodei
OpenAI
damodei@openai.com

2020年1月 by Open AI
(GPT3は2020年6月）

■ 重要論文2



DeepMind

Training Compute-Optimal Large Language Models

Jordan Hoffmann*, **Sebastian Borgeaud***, **Arthur Mensch***, **Elena Buchatskaya, Trevor Cai, Eliza Rutherford, Diego de Las Casas, Lisa Anne Hendricks, Johannes Welbl, Aidan Clark, Tom Hennigan, Eric Noland, Katie Millican, George van den Driessche, Bogdan Damoc, Aurelia Guy, Simon Osindero, Karen Simonyan, Erich Elsen, Jack W. Rae, Oriol Vinyals and Laurent Sifre***

*Equal contributions

2022年 by DeepMind（当時）

[42] Hoffmann+. Training Compute-Optimal Large Language Models. 2022より引用

[3] Kaplan+. Scaling Laws for Neural Language Models. 2020より引用

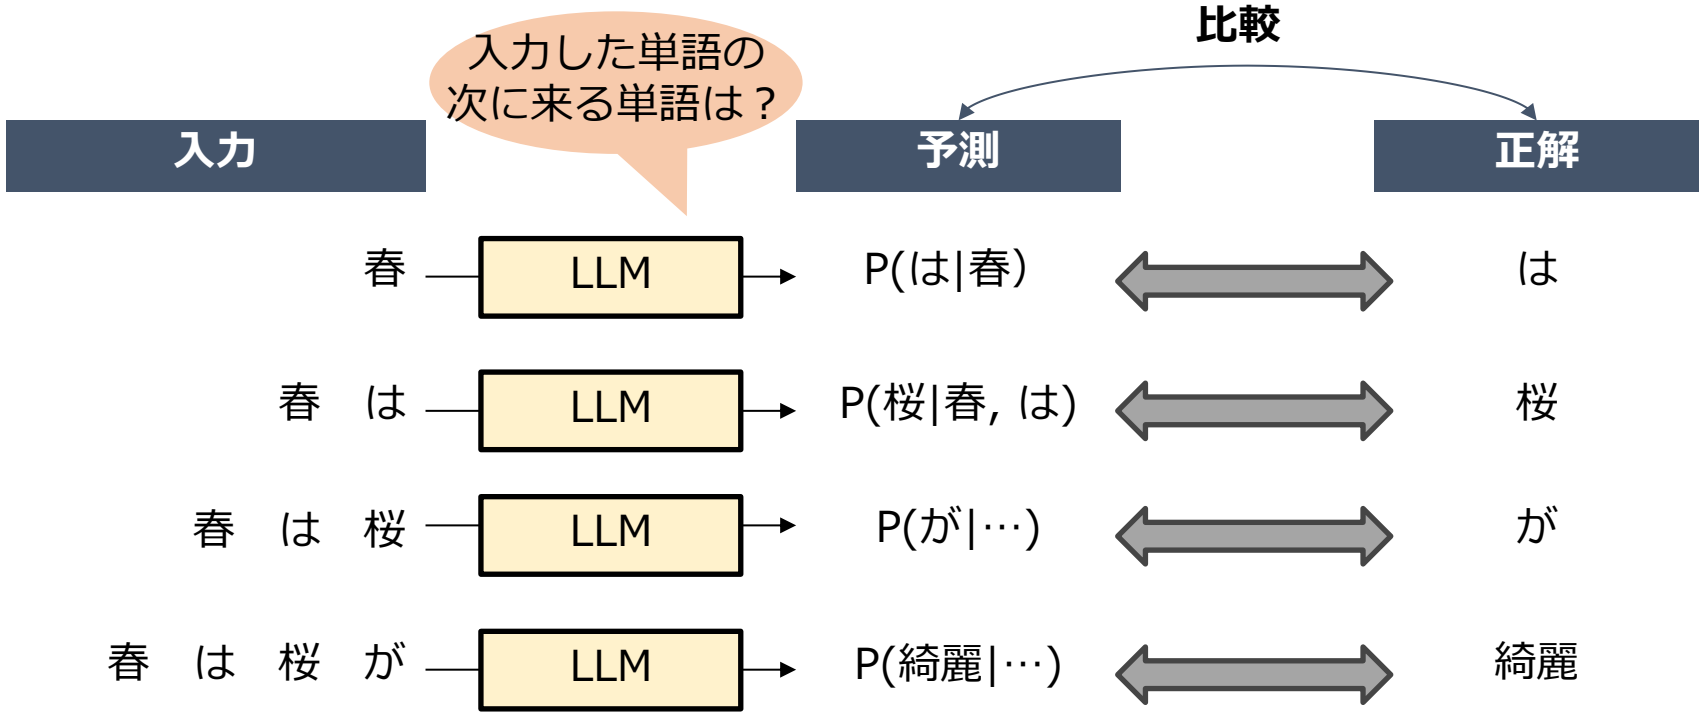
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

事前学習（復習）

事前学習は，Webから収集した大量の文章を使って，次の単語の予測をひたすら行う
事前学習の過程で，読み書きそろばんや世界中のあらゆる知識を学習する

- GPTシリーズを代表とする現代のLLMは，この**事前学習を必ず行う**
- 例えば以下の図のように，「**春は桜が綺麗**」というテキストの事前学習によって，「春」「桜」「綺麗」という言葉の間に強い関係性があること（＝世界の知識）を学ぶ



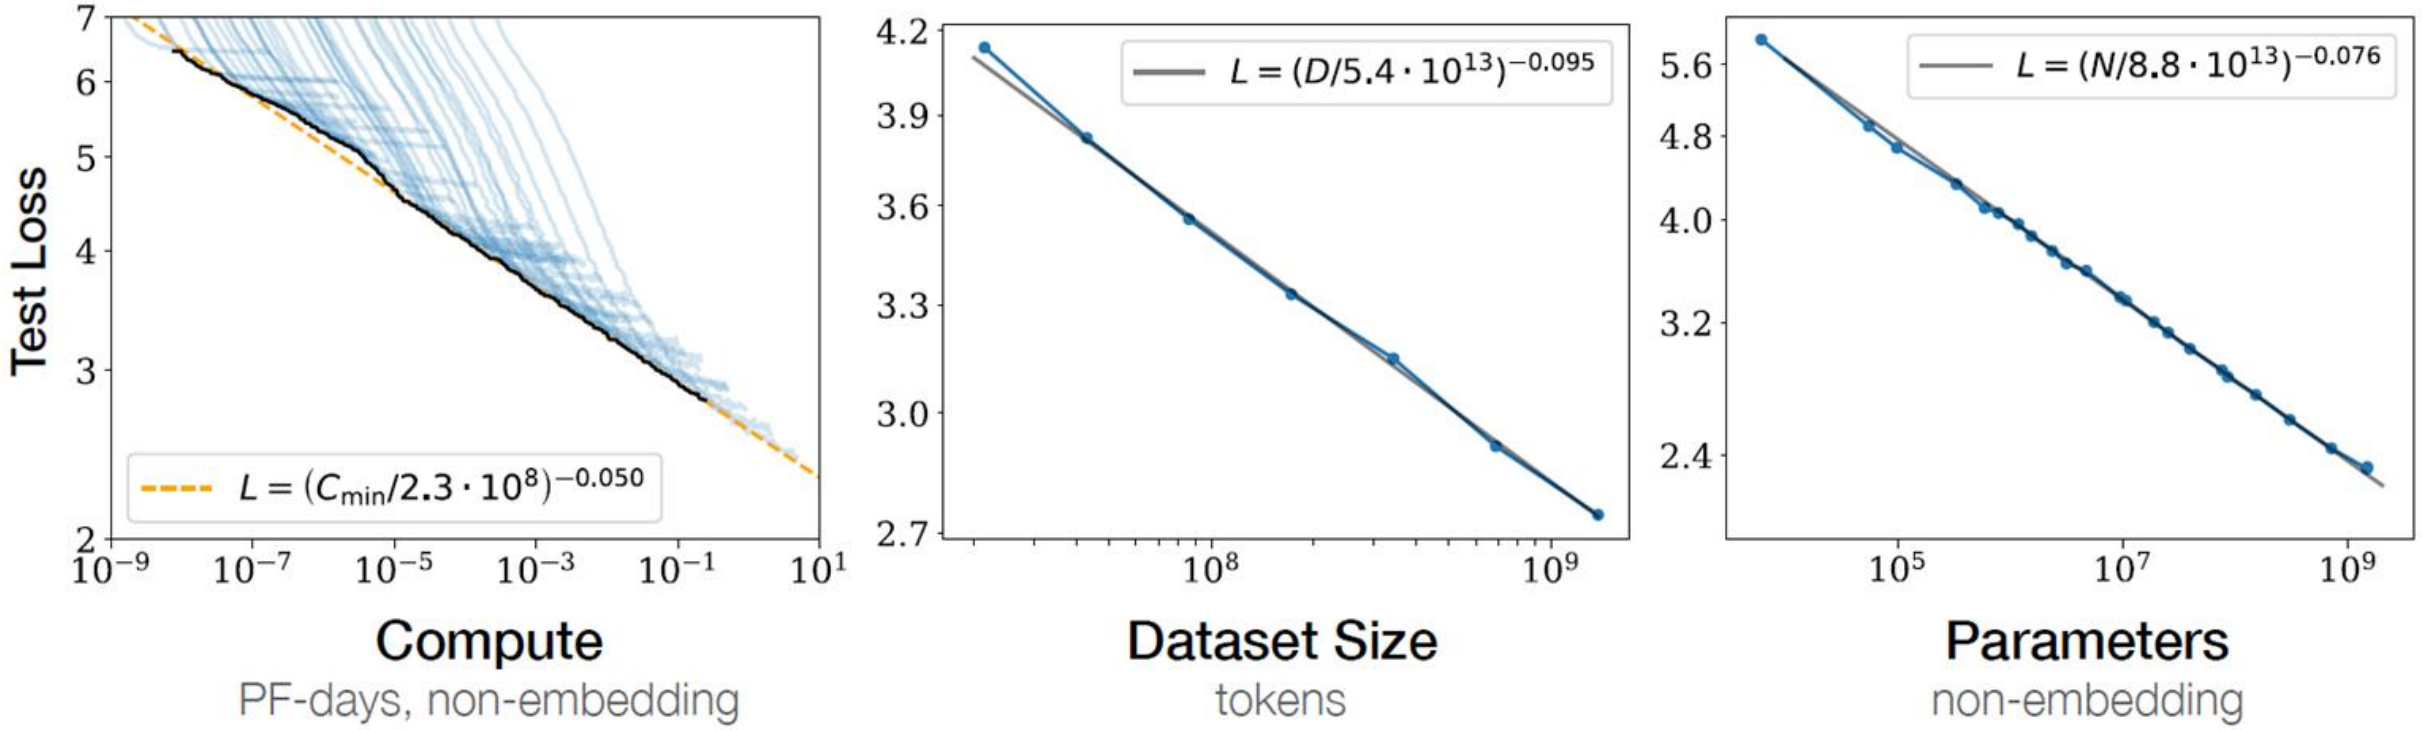
予測と正解との誤差
（＝交差エントロピー）
が小さくなるように
モデルを学習する

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

スケール則（Scaling Law）*Power-Law (べき乗則)とも呼ばれる

計算資源（C）、データセットサイズ（D）、パラメータ数（N）
と誤差（L）の間に成立する経験則

[3] Kaplan+. Scaling Laws for Neural Language Models. 2020より引用



- 各図のデータ点は実測値．ただし他の2変数は十分大きいと仮定．
- いずれの変数もTest Lossとの間に両対数グラフで線形の関係が見られる

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

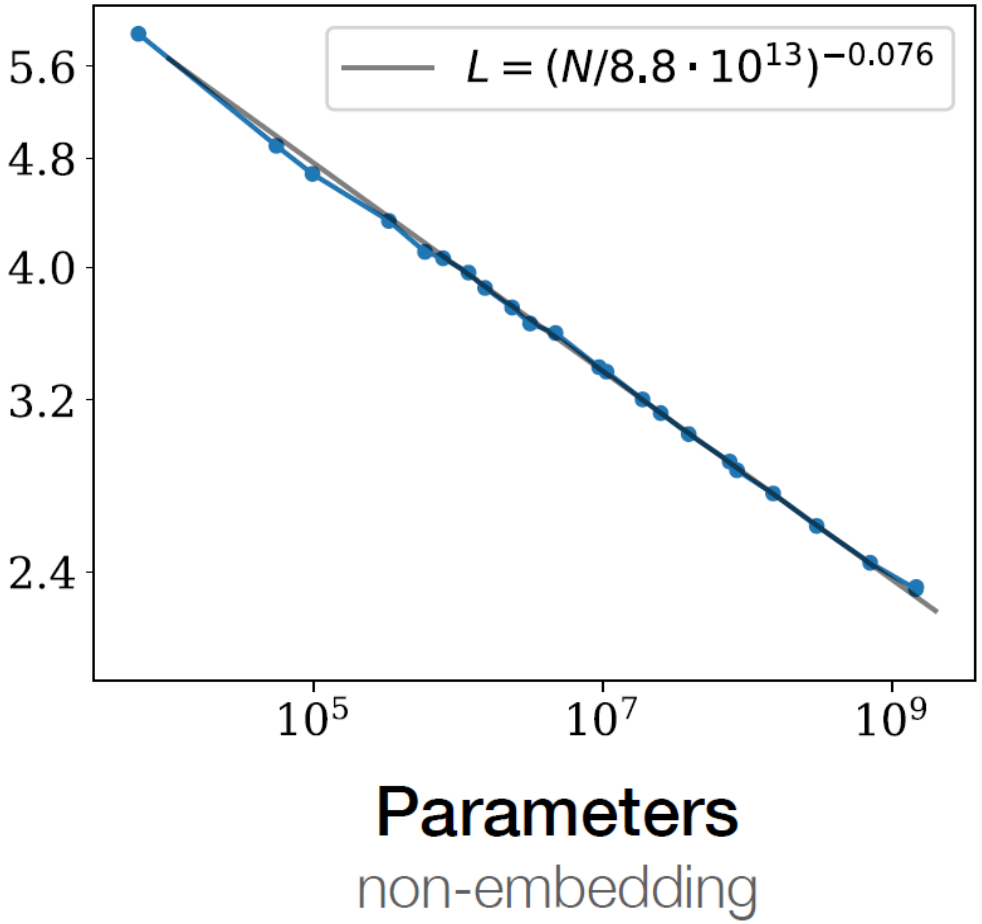
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

スケール則（Scaling Law）

①パラメータ数（N）と誤差（L）の間に成立する関係性.

[3] Kaplan+. Scaling Laws for Neural Language Models. 2020より引用

Loss
=交差エントロピー



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

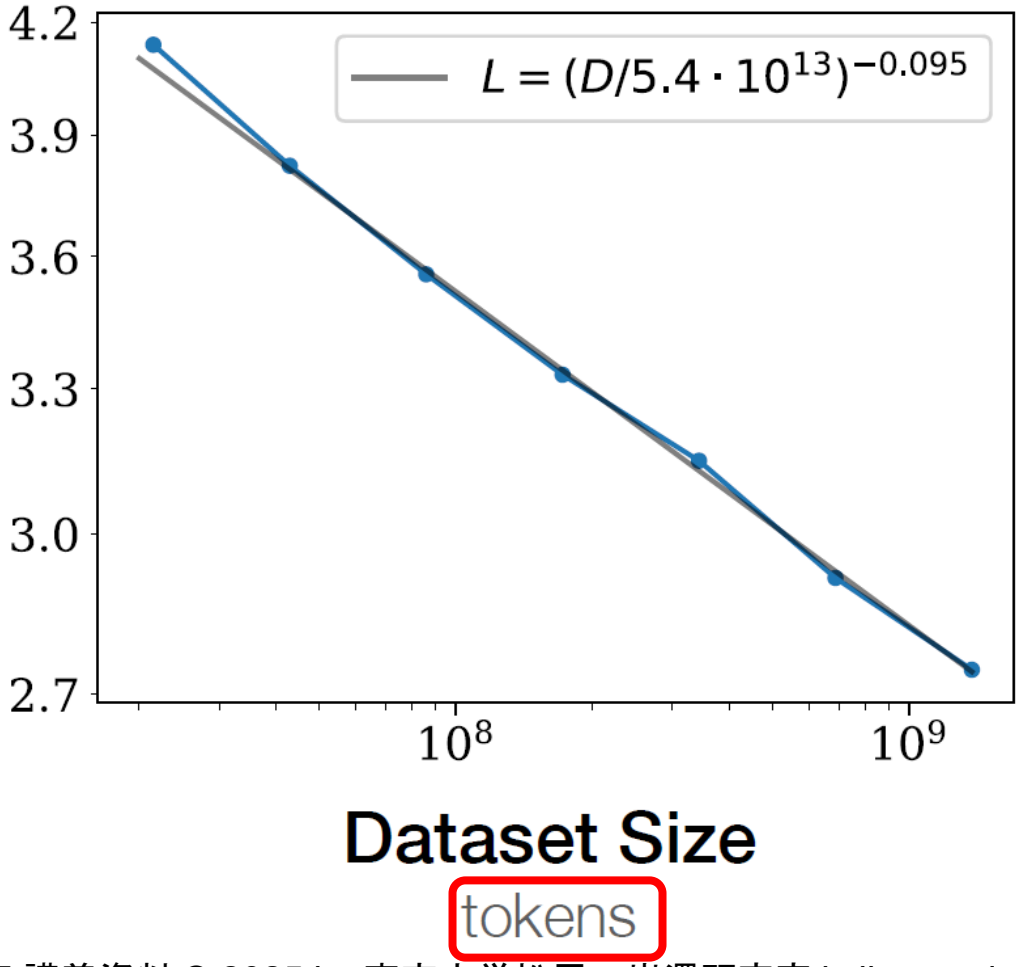
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

スケール則（Scaling Law）

②データセットサイズ（D）と誤差（L）の間に成立する関係性.

[3] Kaplan+. Scaling Laws for Neural Language Models. 2020より引用

Loss
=交差エントロピー



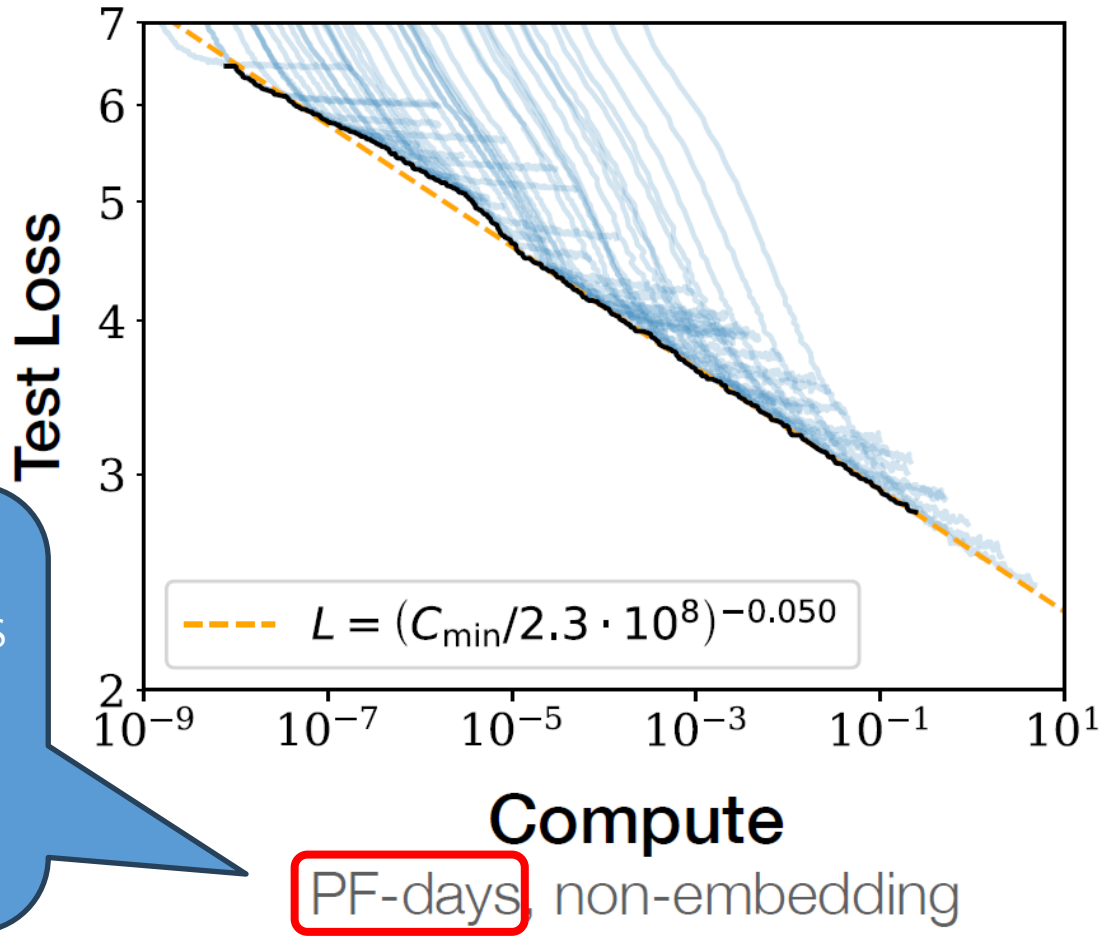
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

スケール則（Scaling Law）

③計算資源（C）と誤差（L）の間に成立する関係性.

[3] Kaplan+. Scaling Laws for Neural Language Models. 2020より引用



PF-days：
Peta FLOPs days（1 Peta FLOPS の処理速度を持つサーバを何日分学習に使ったか）

＊FLOPs：次ページ

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

■補足 | 計算量の単位 FLOPs

・計算量は、合計で何回の浮動小数点演算をおこなうかで表現される

・浮動小数点演算の例：パラメータの足し算，掛け算

・必要な合計計算量を表す単位として紛らわしいが**FLOPs**が使われる

・**FL**oating **P**oints **OP**eration**s**

・スケール則の横軸はこちら

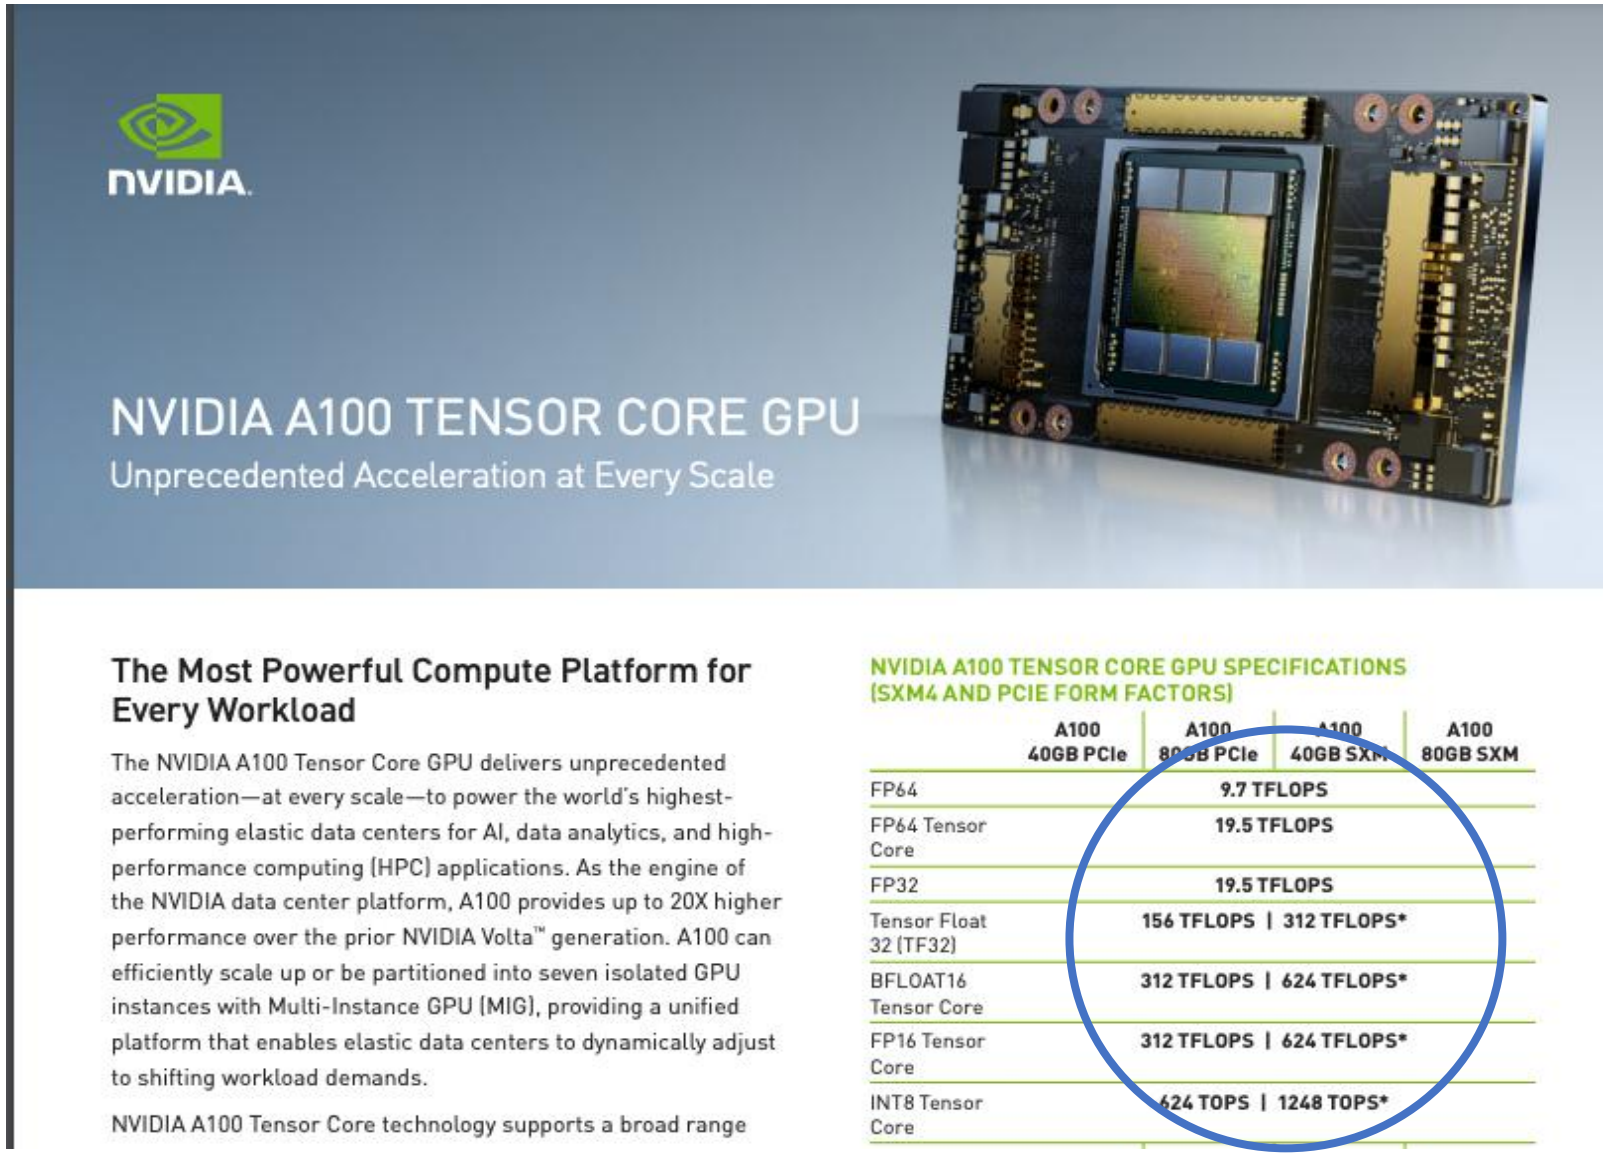
Feed Forward：巨大な２階建てのMLP

$$\underbrace{\mathrm{FFN}(x)}_{\text{出力}} = \underbrace{\max(0,}_{\text{活性化関数（ReLU）}} \underbrace{x}_{\text{入力}} \underbrace{W_1 + b_1)W_2 + b_2}_{\text{学習パラメータ}}$$

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

■ 補足 | FLOPsとFLOPS



NVIDIA

NVIDIA A100 TENSOR CORE GPU

Unprecedented Acceleration at Every Scale

The Most Powerful Compute Platform for Every Workload

The NVIDIA A100 Tensor Core GPU delivers unprecedented acceleration—at every scale—to power the world's highest-performing elastic data centers for AI, data analytics, and high-performance computing (HPC) applications. As the engine of the NVIDIA data center platform, A100 provides up to 20X higher performance over the prior NVIDIA Volta™ generation. A100 can efficiently scale up or be partitioned into seven isolated GPU instances with Multi-Instance GPU (MIG), providing a unified platform that enables elastic data centers to dynamically adjust to shifting workload demands.

NVIDIA A100 Tensor Core technology supports a broad range

NVIDIA A100 TENSOR CORE GPU SPECIFICATIONS (SXM4 AND PCIE FORM FACTORS)

	A100 40GB PCIe	A100 80GB PCIe	A100 40GB SXM	A100 80GB SXM
FP64	9.7 TFLOPS			
FP64 Tensor Core	19.5 TFLOPS			
FP32	19.5 TFLOPS			
Tensor Float 32 (TF32)	156 TFLOPS | 312 TFLOPS*			
BFLOAT16 Tensor Core	312 TFLOPS | 624 TFLOPS*			
FP16 Tensor Core	312 TFLOPS | 624 TFLOPS*			
INT8 Tensor Core	624 TOPS | 1248 TOPS*			

- これはFLOPS:
- Floating Points Operation Per Second
- 単位時間あたりにどれくらい処理できるかのHWの性能

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

■補足 | 大きな数字の表現

- Mega（M）：10^6
- Giga（G）：10^9
- Tera（T）：10^12
- Peta（P）：10^15
- Exa（E）：10^18

・・・・

ちなみに、

- GPT-3の総計算量は、3.14 * 10^23 FLOPs.

（最近のモデルのFLOPsは詳細が非公開なので不明）

[9] Brown+. Language Models are Few-Shot Learners. 2020より引用

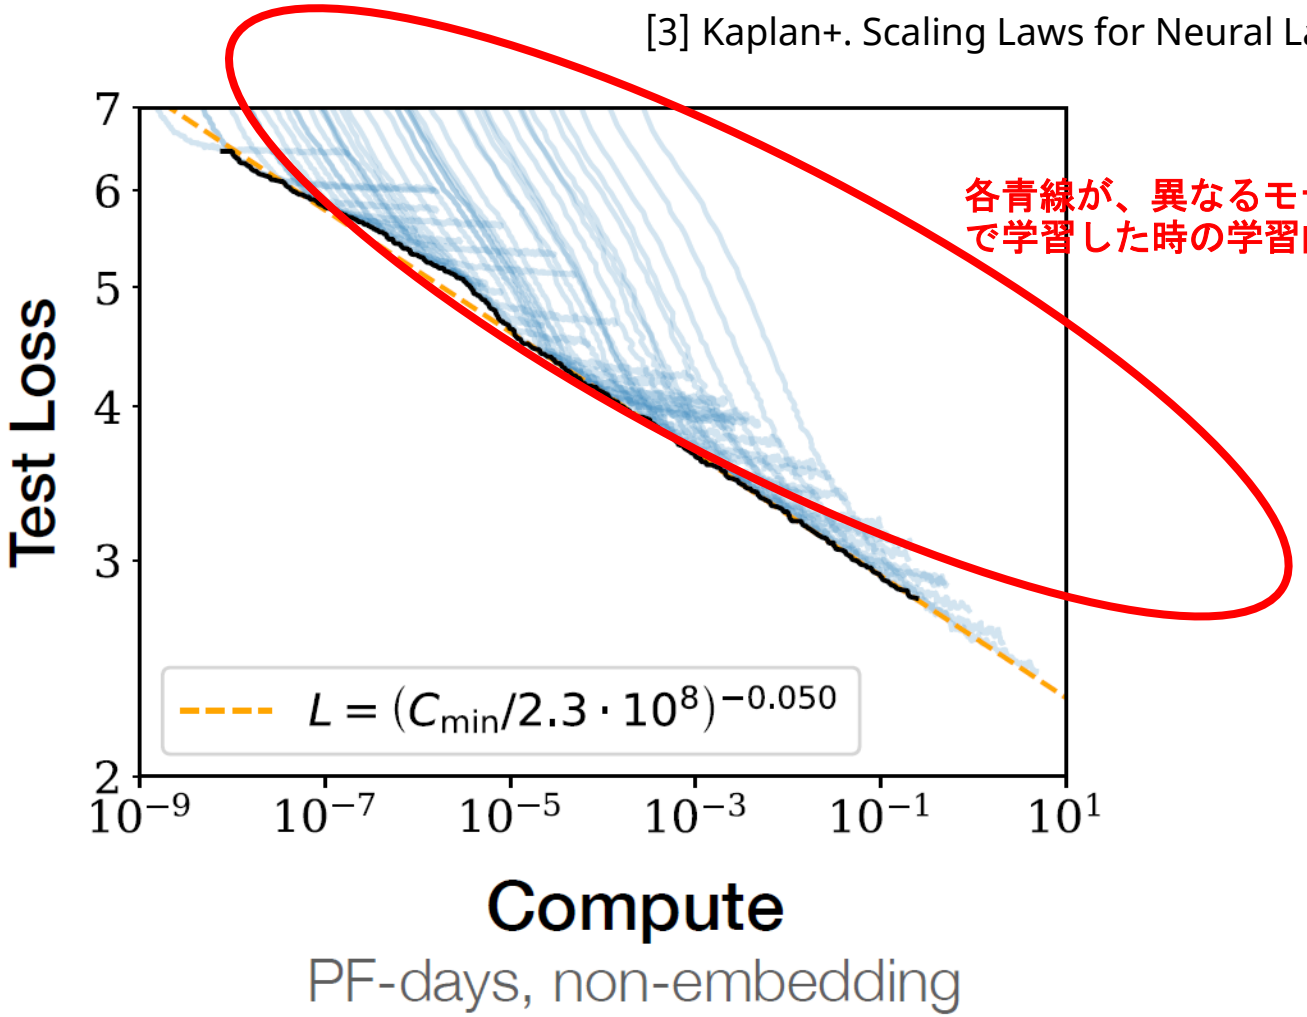
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

スケール則（Scaling Law）

③計算資源（C）と誤差（L）の間に成立する関係性.

[3] Kaplan+. Scaling Laws for Neural Language Models. 2020より引用



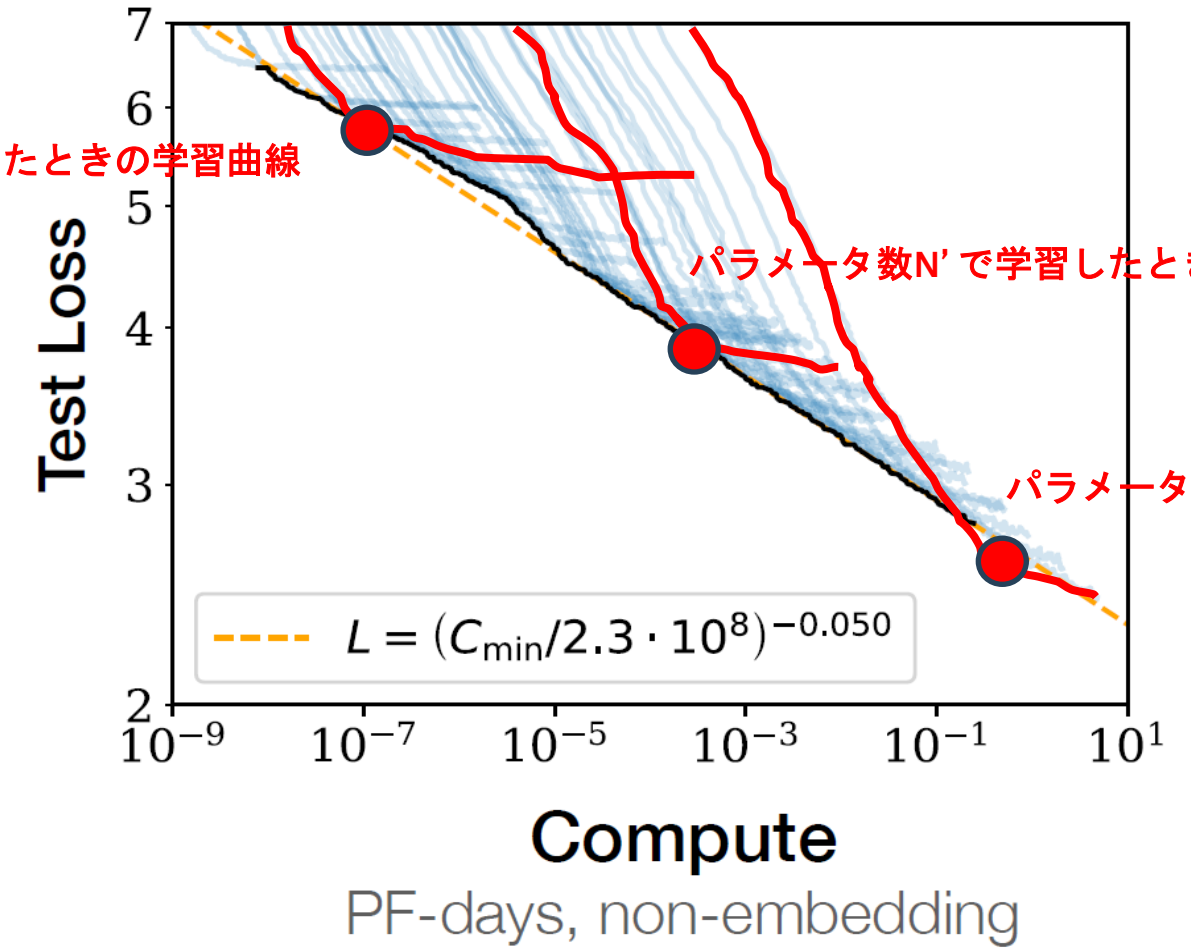
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

スケール則（Scaling Law）

③計算資源（C）と誤差（L）の間に成立する関係性.

[3] Kaplan+. Scaling Laws for Neural Language Models. 2020より引用



パラメータ数Nで学習したときの学習曲線

パラメータ数N’で学習したときの学習曲線

パラメータ数N”で学習したときの学習曲線

*パラメータ数 N <N’ < N”

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

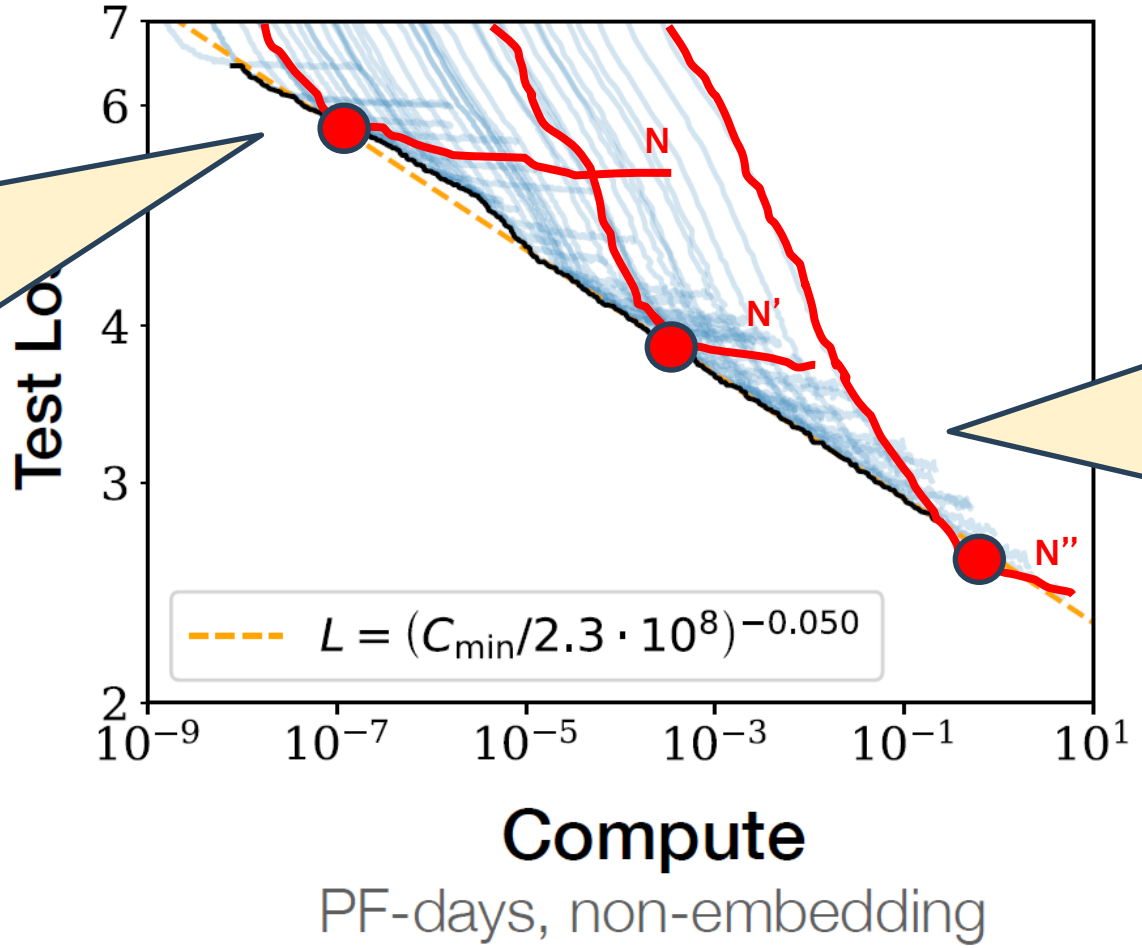
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

スケール則（Scaling Law）

③計算資源（C）と誤差（L）の間に成立する関係性.

[3] Kaplan+. Scaling Laws for Neural Language Models. 2020より引用

モデルサイズが小さいと，少ない計算資源でも速いスピードでLossが下がるが，その後学習を続けてもLossが下がりづらくなる（サチる）



*パラメータ数 N <N' < N''

モデルサイズが大きいと，少ない計算資源ではLossがなかなか下がらないが，学習を続けるとLossが下がり続けて最終的によいパフォーマンスとなる（サチらない）

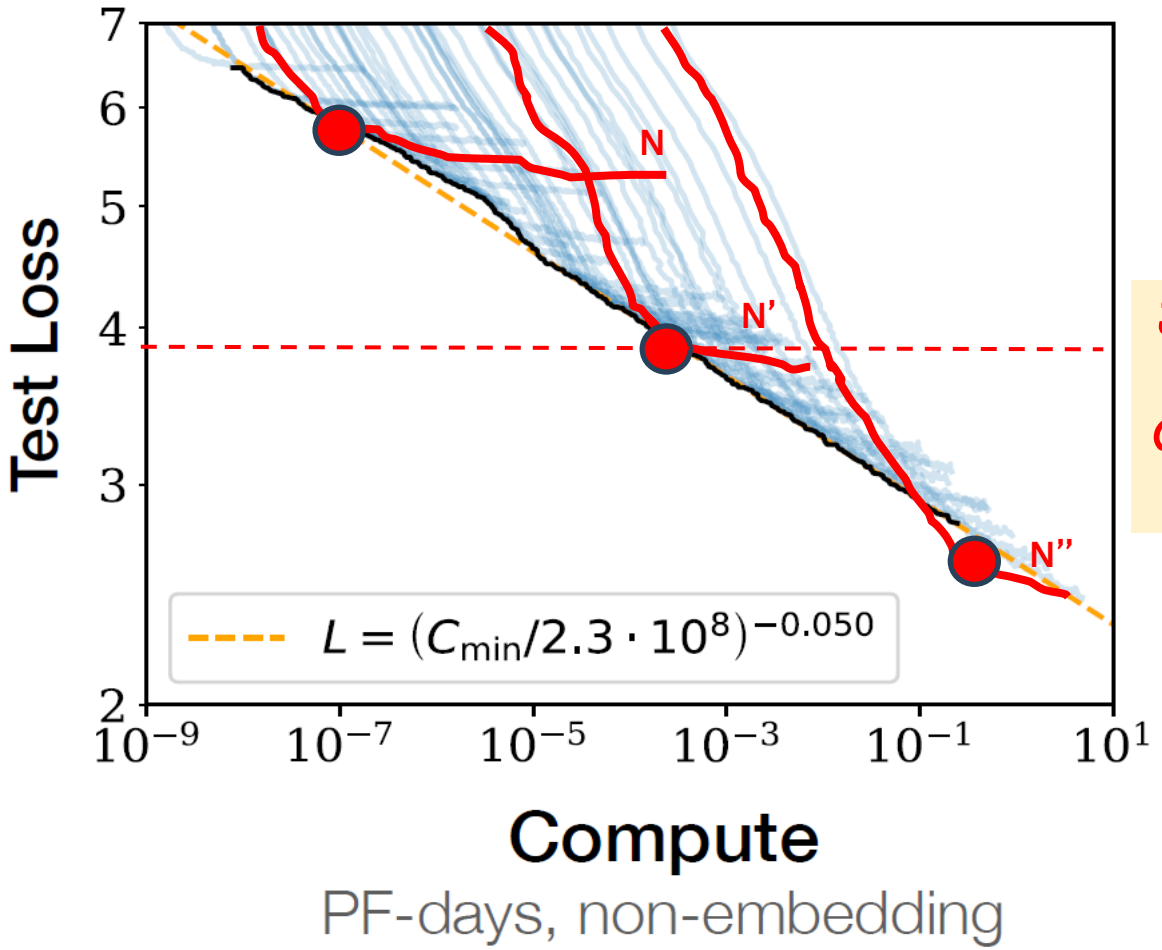
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

スケール則（Scaling Law）

③計算資源（C）と誤差（L）の間に成立する関係性.

[3] Kaplan+. Scaling Laws for Neural Language Models. 2020より引用



*パラメータ数 N <N' < N''

このレベル（横の点線）のLoss（パフォーマンス）を達成するのに最適なモデルサイズは「N'」. NでもN''でもない.

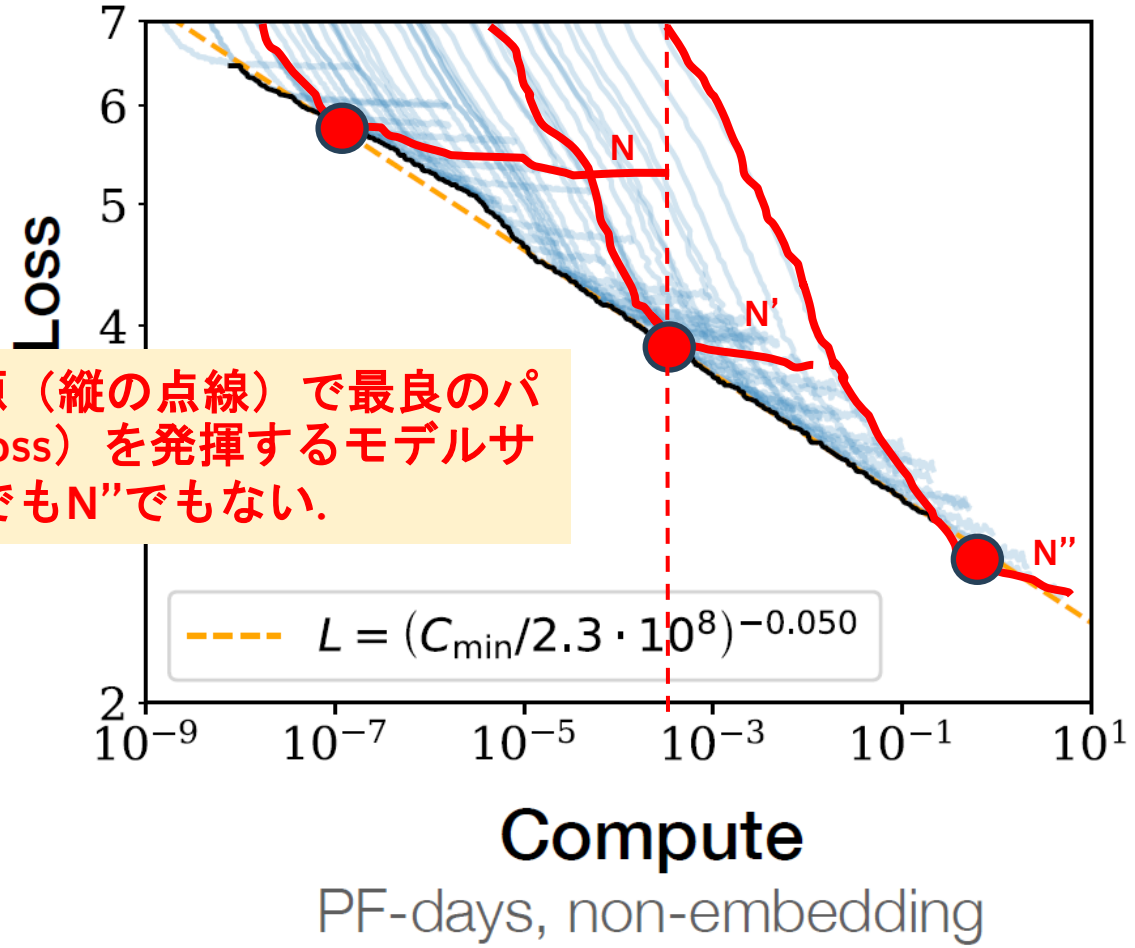
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

スケール則（Scaling Law）

③計算資源（C）と誤差（L）の間に成立する関係性.

[3] Kaplan+. Scaling Laws for Neural Language Models. 2020より引用



限られた計算資源（縦の点線）で最良のパフォーマンス（Loss）を発揮するモデルサイズは「N'」. NでもN''でもない.

***パラメータ数 N <N' < N''**

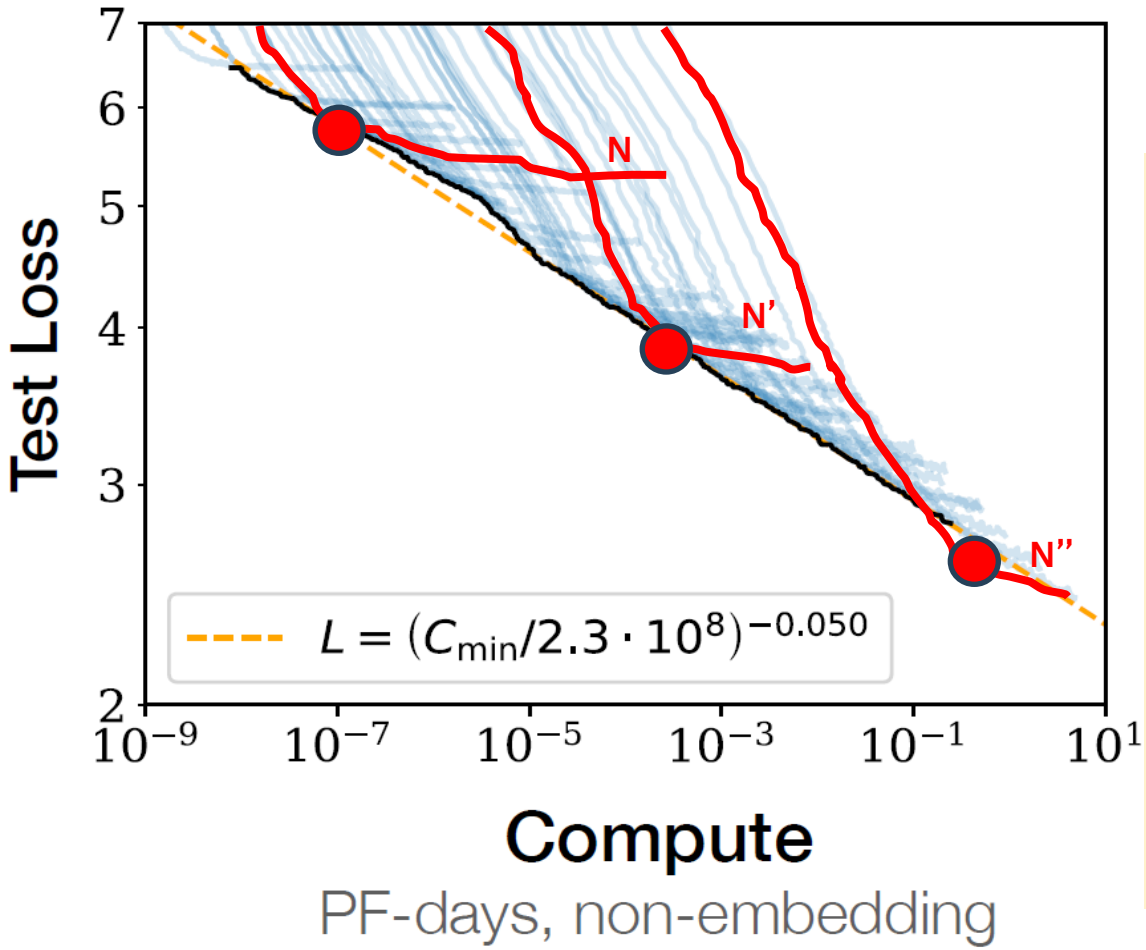
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

スケール則（Scaling Law）

③計算資源（C）と誤差（L）の間に成立する関係性.

[3] Kaplan+. Scaling Laws for Neural Language Models. 2020より引用



*パラメータ数 N <N' < N''

つまり, この直線は「任意の計算資源量が与えられた時に, その計算資源内で最良のパフォーマンスを発揮するパラメータサイズのモデルで到達可能なLoss値(最適点)の集合」を意味する.

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

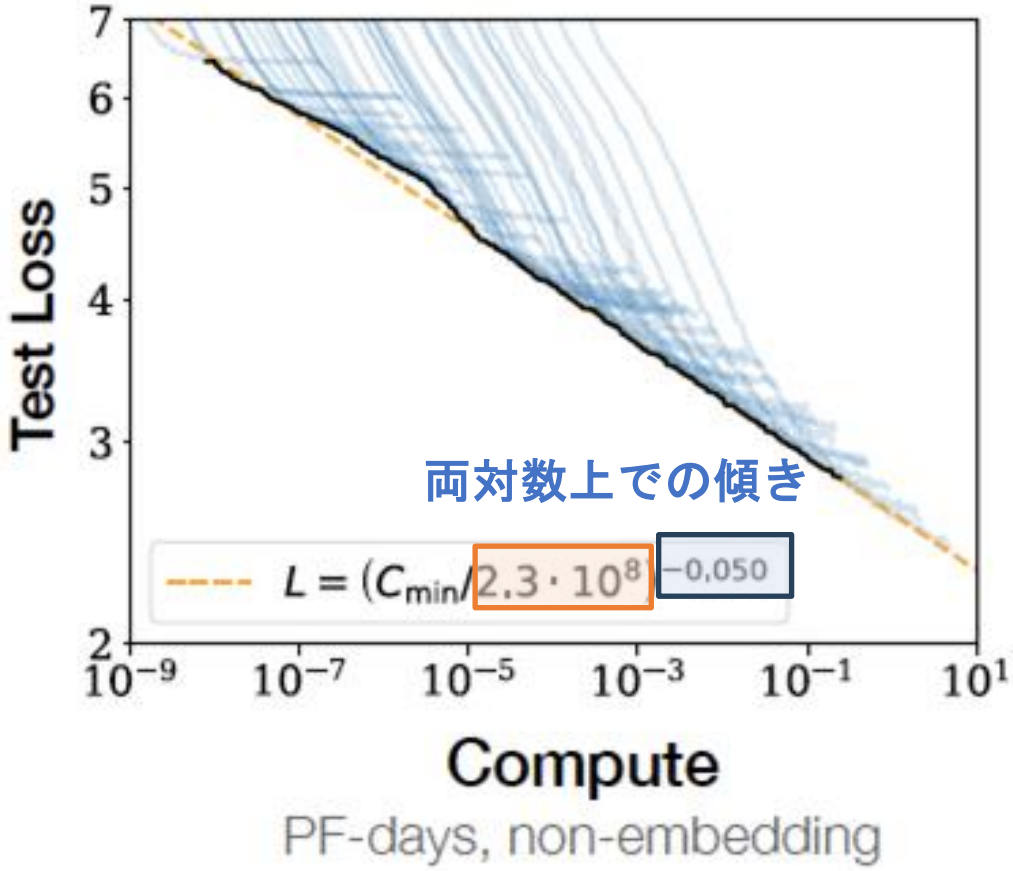
■ 補足 | スケール則（Scaling Law）という名前の由来

[3] Kaplan+. Scaling Laws for Neural Language Models. 2020より引用

べき乗で表現できる

$$L(X) = \left({}^{X_c}/_{X}\right)^{\alpha}$$
$$\log L(X) = \alpha \log X_c - \alpha \log X$$

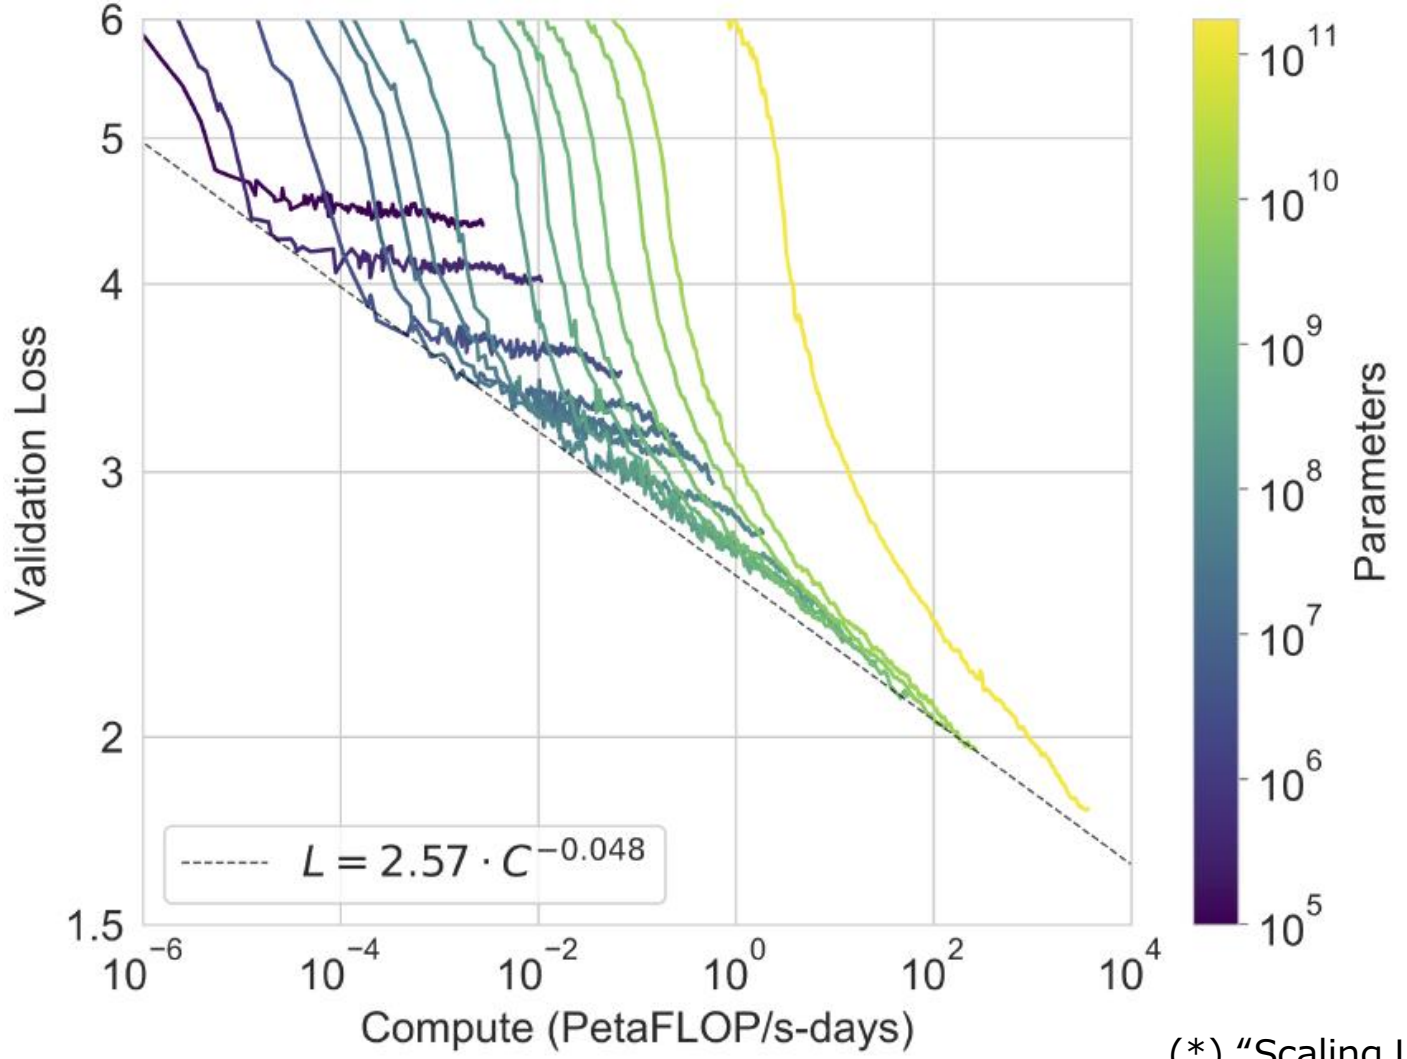
α: 両対数グラフ上での傾き
Xc : 切片（のようなもの）
X : スケール則の変数 (C or D or N)



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

GPT-3でのスケール則 (OpenAI, 2020)

[9] Brown+. Language Models are Few-Shot Learners. 2020より引用



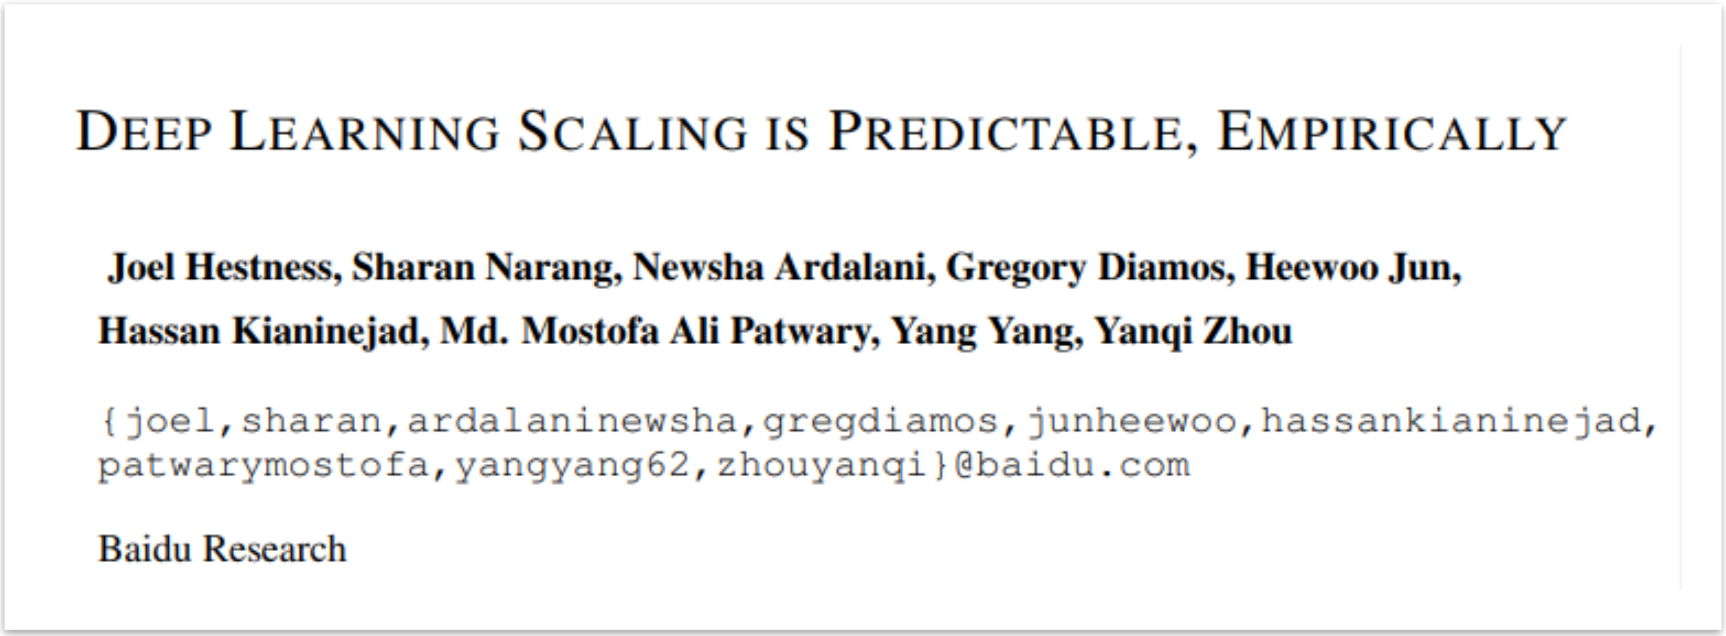
- GPT3でもスケール則が利用されている
- 先行研究(*)よりも２桁オーダー大きい計算量のスケール則を確認した.

(*) “Scaling Laws for Neural Language Models”, 2020

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

■ 補足 | スケーリングは新しい現象？



DEEP LEARNING SCALING IS PREDICTABLE, EMPIRICALLY

Joel Hestness, Sharan Narang, Newsha Ardalani, Gregory Diamos, Heewoo Jun,
Hassan Kianinejad, Md. Mostofa Ali Patwary, Yang Yang, Yanqi Zhou

{joel,sharan,ardalaninewsha,gregdiamos,junheewoo,hassankianinejad,
patwarymostofa,yangyang62,zhouyanqi}@baidu.com

Baidu Research

[8] Hestness+. Deep Learning Scaling is Predictable, Empirically. 2017より引用

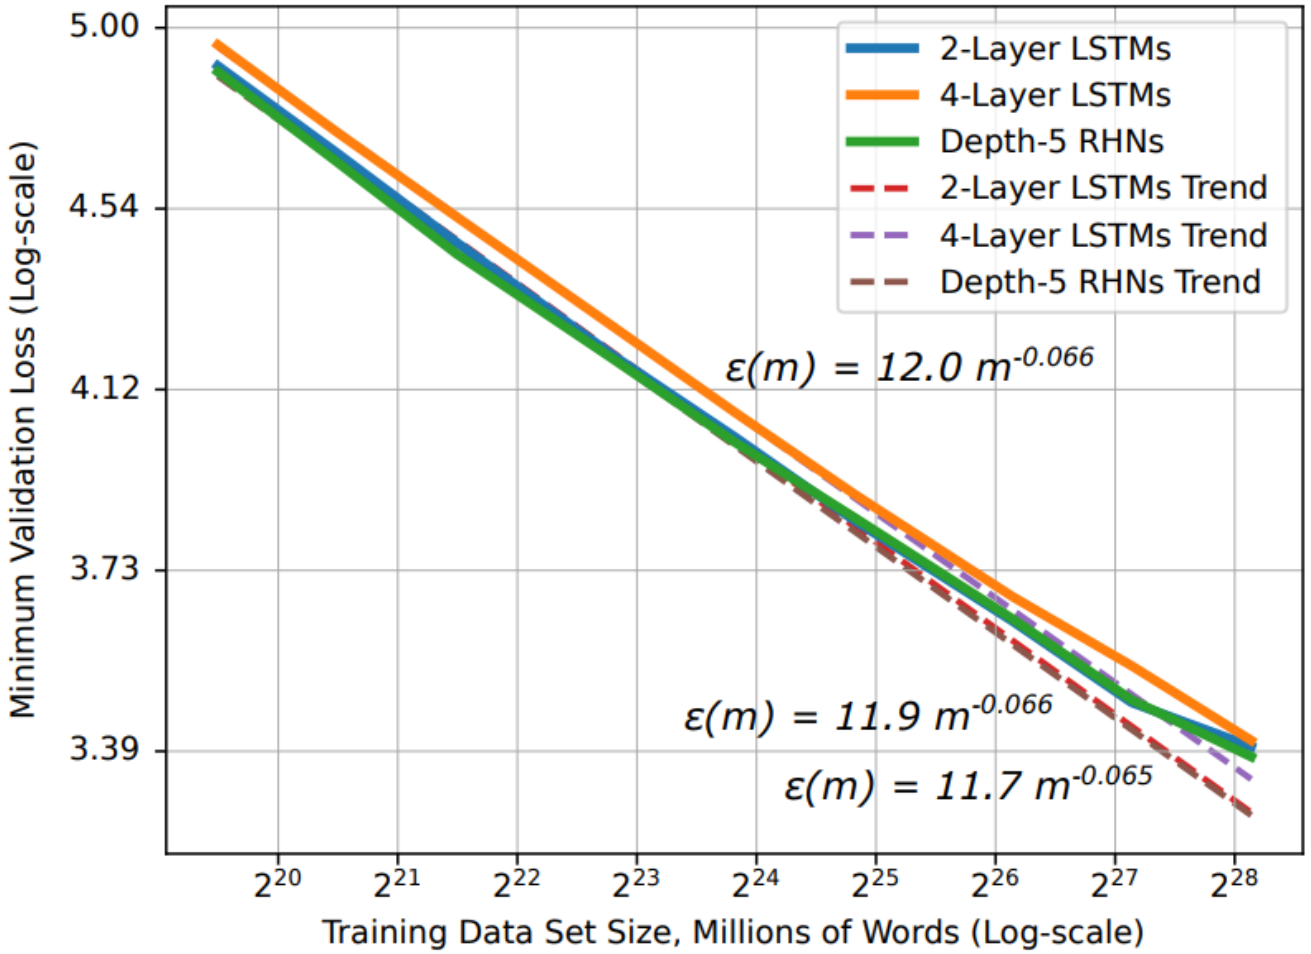
- 少なくとも2017年 by Baidu Researchでは検証されている
- この研究ではスケール則の発生を多数のドメイン（機械翻訳、言語モデリング、画像分類、音声認識など）で検証している。

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

■初期のスケール則 (Baidu, 2017)

LSTM: RNN型言語モデルの一種



[8] Hestness+. Deep Learning Scaling is Predictable, Empirically. 2017より引用

同じ点

データに関するスケール則を検証（モデルも少し）

左はMTの例.

相違点

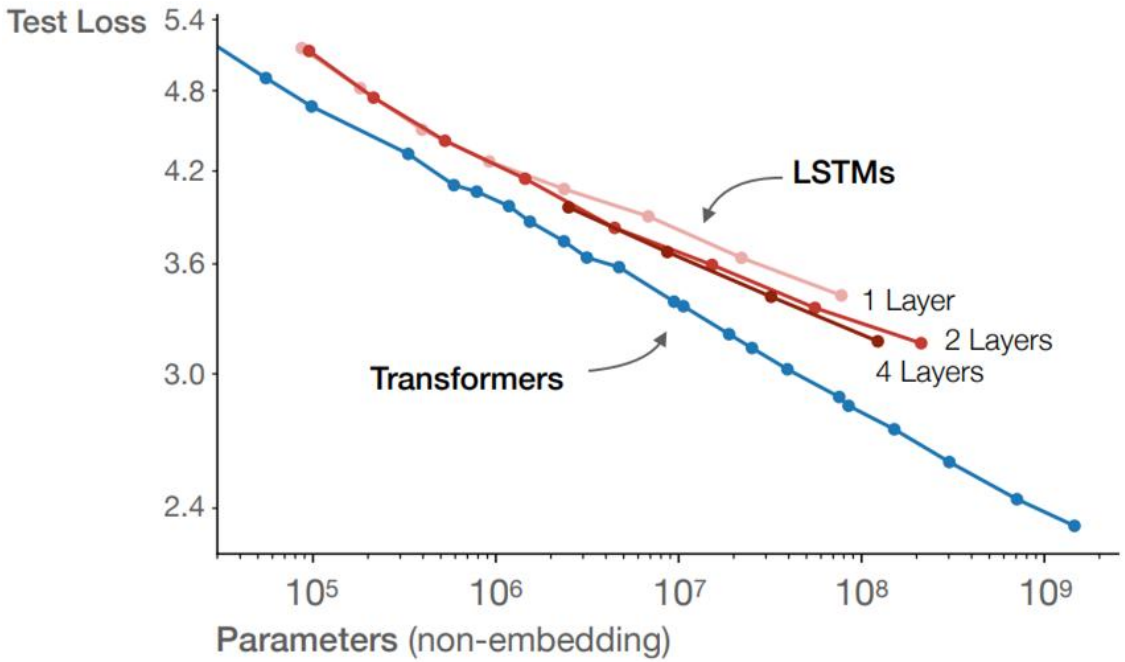
1. 対象モデルが異なる（Transformer以前）
2. 規模が異なる（特にモデル）

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

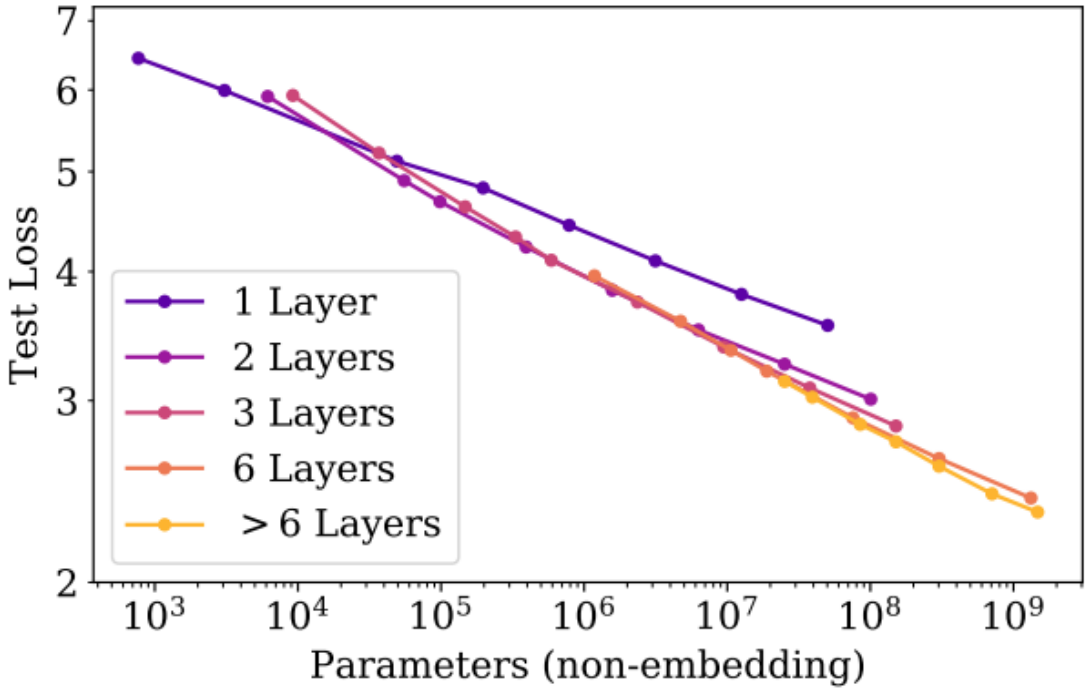
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

異なるモデル構造での検証

モデル構造の探索



深さ



[3] Kaplan+. Scaling Laws for Neural Language Models. 2020より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Mixture of Expert Modelのスケール則

[64] Ludziejewski+. Scaling Laws for Fine-Grained Mixture of Experts. 2024より引用

UNIFIED SCALING LAWS FOR ROUTED LANGUAGE MODELS

Aidan Clark*, Diego de las Casas*, Aurelia Guy*, Arthur Mensch*

Michela Paganini, Jordan Hoffmann, Bogdan Damoc, Blake Hechtman‡, Trevor Cai, Sebastian Borgeaud, George van den Driessche, Eliza Rutherford, Tom Hennigan, Matthew Johnson‡, Katie Millican, Albin Cassirer, Chris Jones, Elena Buchatskaya, David Budden, Laurent Sifre, Simon Osindero, Oriol Vinyals, Jack Rae, Erich Elsen, Koray Kavukcuoglu, Karen Simonyan

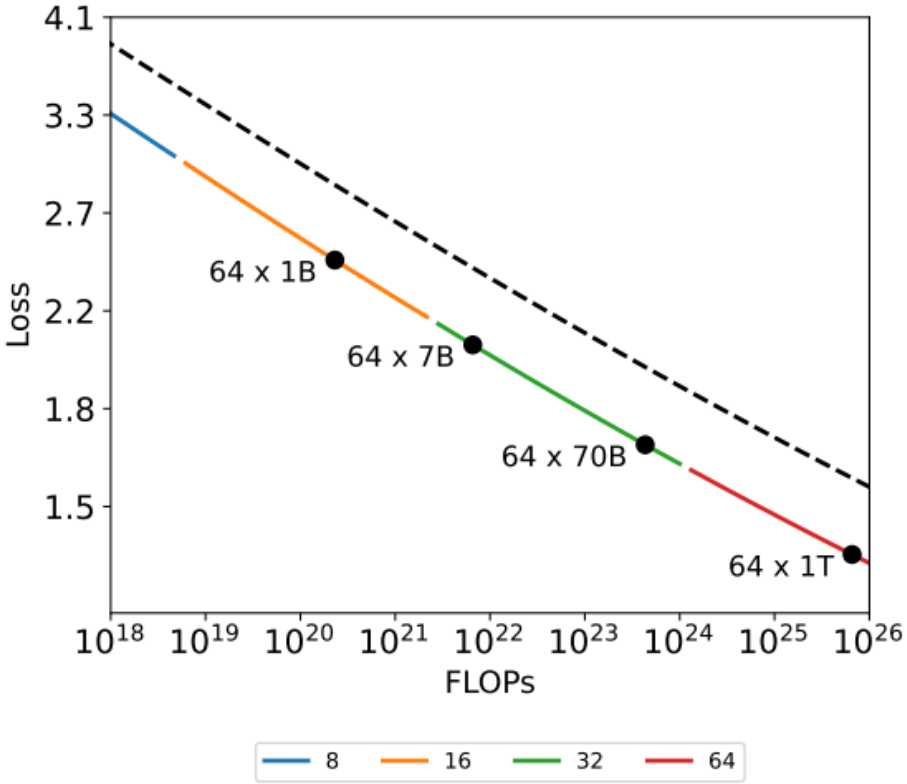
DeepMind Google Research‡

SCALING LAWS FOR FINE-GRAINED MIXTURE OF EXPERTS

Jakub Krajewski * University of Warsaw IDEAS NCBR
Jan Ludziejewski * University of Warsaw IDEAS NCBR
Kamil Adamczewski IDEAS NCBR
Maciej Pióro IPPT PAN IDEAS NCBR

Michał Krutul University of Warsaw IDEAS NCBR
Szymon Antoniak University of Warsaw IDEAS NCBR
Kamil Ciebiera University of Warsaw IDEAS NCBR
Krystian Król University of Warsaw IDEAS NCBR

Tomasz Odrzygóźdź TradeLink
Piotr Sankowski University of Warsaw IDEAS NCBR
Marek Cygan University of Warsaw Nomagic
Sebastian Jaszczur * University of Warsaw IDEAS NCBR



図の点線が普通のTransformer，実践がMixture of Expert (MoE)
Q. MoEとは？ A. Day 5でやります.

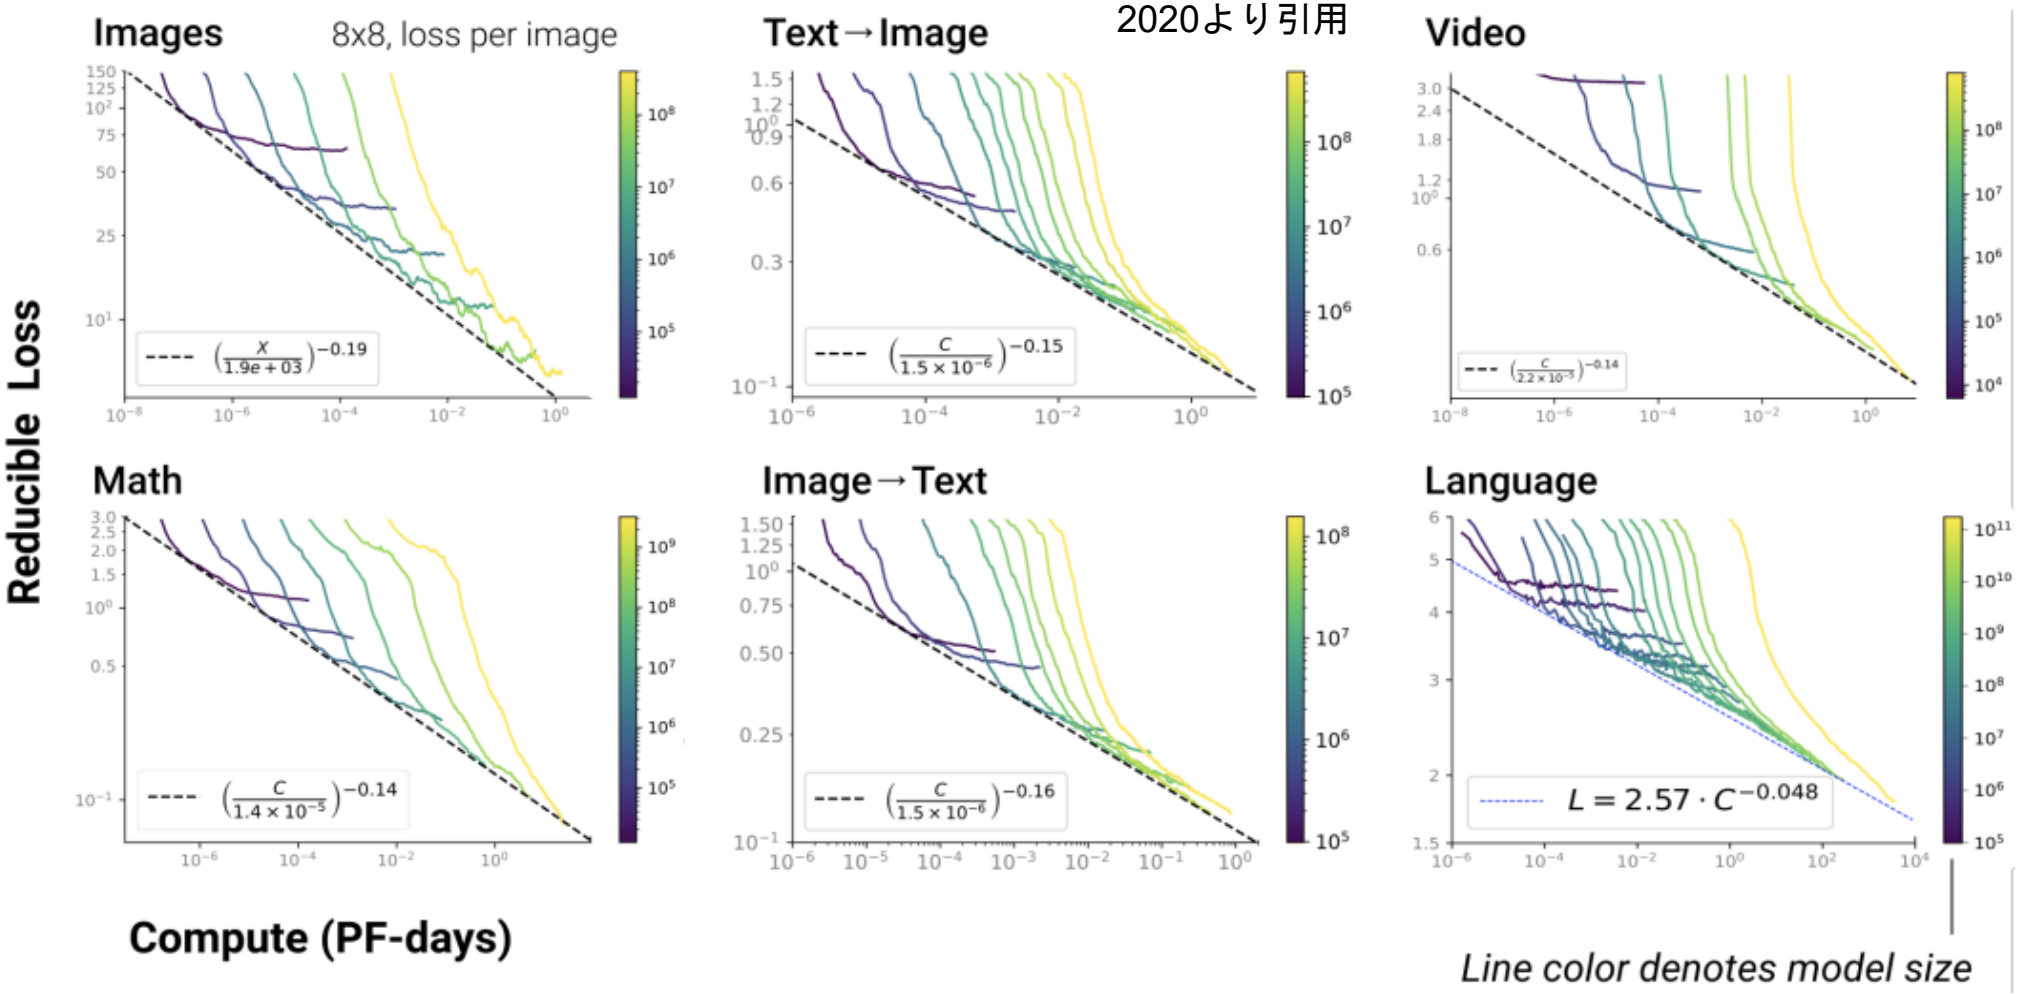
[27] Clark+. Unified Scaling Laws for Routed Language Models. 2022より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

様々なドメインでのスケール則（計算量とLoss）

[11] Henighan+. Scaling Laws for Autoregressive Generative Modeling. 2020より引用



画像生成，マルチモーダル，動画，数理等でも計算量に関するスケール則が成立

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

LLMの学習に必要な計算量とパラメータ数，トークン数の関係

・よく使われる近似式： **6** × **N（パラメータ数）** × **D（トークン数）**

（例）GPT3の場合　175B × 0.3T × 6 ≒ 3.14 * E+23 FLOPs

・なぜ **6** ？A. １パラメータあたりのMLP層における行列演算数が６回だから.

[9] Brown+. Language Models are Few-Shot Learners. 2020より引用

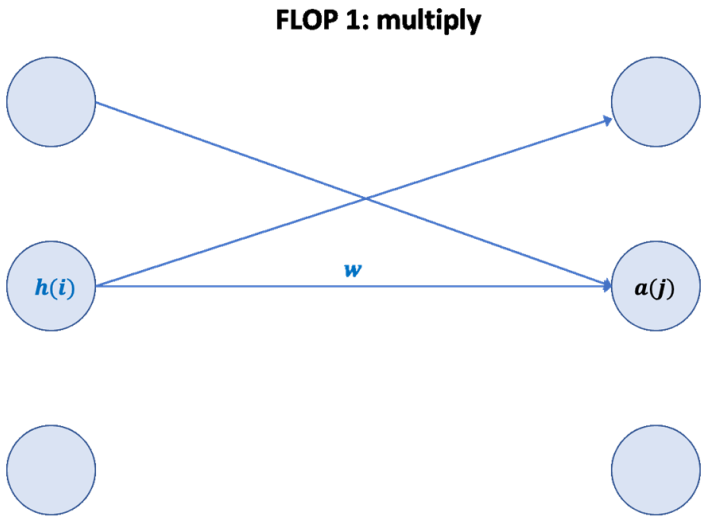
For each example in the batch, the weight *w* generates exactly 6 FLOPs combined in the forward and backward pass:

Forward

1. The unit *i* multiplies its output *h(i)* by *w* to send it to the unit *j*. h(i)とwをかける
2. The unit *j* adds the unit *i*'s contribution to its total input *a(j)*. a(j)に足す

Backward

3. The unit *j* multiplies the incoming loss gradient *dL/da(j)* by *w* to send it back to the unit i. a(j)からの勾配をh(i)に伝える
4. The unit *i* adds the unit *j*'s contribution to its total loss gradient *dL/dh(i)*. その勾配を集約する
5. The unit j multiplies its loss gradient *dL/da(j)* by the unit i's output *h(i)* to compute the loss gradient *dL/dw* **for the given example.** wに対する勾配を計算する
6. (The sneakiest FLOP, IMHO) The weight *w* adds the contribution from step 5 to its loss gradient accumulator *dL/dw* that aggregates gradients **for all examples.** その勾配を集計する



[47] Bahdanau. The FLOPs Calculus of Language Model Training. Medium. 2022より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

■補足 |Attentionは無視してよいのか？

[47] Bahdanau. The FLOPs Calculus of Language Model Training. Medium. 2022より引用
(*) [63] OpenAI. Models overview - OpenAI API Documentation. 2023より引用

・系列長が短い場合,
　MLPの計算量 >> Attention機構の計算量（詳細は上記URLを参照）
・最近は系列長が長くなる傾向にあるので, 無視できなくなってきている可能性が高い.
　・GPT-3：2,049トークン(*)
　・ChatGPT：16,385トークン(*)
　・GPT-4：32,768トークン(*)
・もっと正確な計算式の例：https://github.com/karpathy/nanoGPT/blob/master/scaling_laws.ipynb

```
# embeddings
embeddings = 2 * seq_len * vocab_size * d_model

# attention
# key, query, value projections
attention = 2 * 3 * seq_len * d_model * (key_size * num_heads)
# key @ query logits
attlogits = 2 * seq_len * seq_len * (key_size * num_heads)
# softmax
attsoftmax = 3 * num_heads * seq_len * seq_len # 3* is for subtract (max), exp, divide
# softmax @ value reductions
attvalue = 2 * seq_len * seq_len * (key_size * num_heads)
# final linear
attlinear = 2 * seq_len * (key_size * num_heads) * d_model
att = attention + attlogits + attsoftmax + attvalue + attlinear
# feed forward
dense = 2 * seq_len * (d_model * ffw_size + d_model * ffw_size)
```

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

ミニクイズ

・**前提｜計算環境の計算能力を下記と仮定する**

GPU A100 ×1基： O(E+14 FLOPS)

※ こちらは単位時間あたりの計算量なので大文字

・**クイズ｜A100を1000基使うとして，GPT-3の学習にはどれくらいの学習時間が必要か？**

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

■ ここまでのまとめ | スケール則とはなにか

- スケール則とは計算資源（C）、データセットサイズ（D)、パラメータ数（N）と誤差（L）の間に成立する以下のような経験則
  - $L(X) = \left({}^{X_c}/_{X}\right)^{\alpha}$
  - 冪乗の形をしている

- Transformer以外のモデル，言語以外のタスクでもスケール則は確認されている

- 計算量：FLOPs
  - C（計算量）＝ 6 × N（パラメータ数） × D（トークン数）

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

目次

- スケール則とはなにか
- **スケール則の使い方**
- スケール則の具体的な求め方
- 新たなトレンド：推論時のスケーリング

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

(再掲)スケール則（Scale Law）

[3] Kaplan+. Scaling Laws for Neural Language Models. 2020より引用

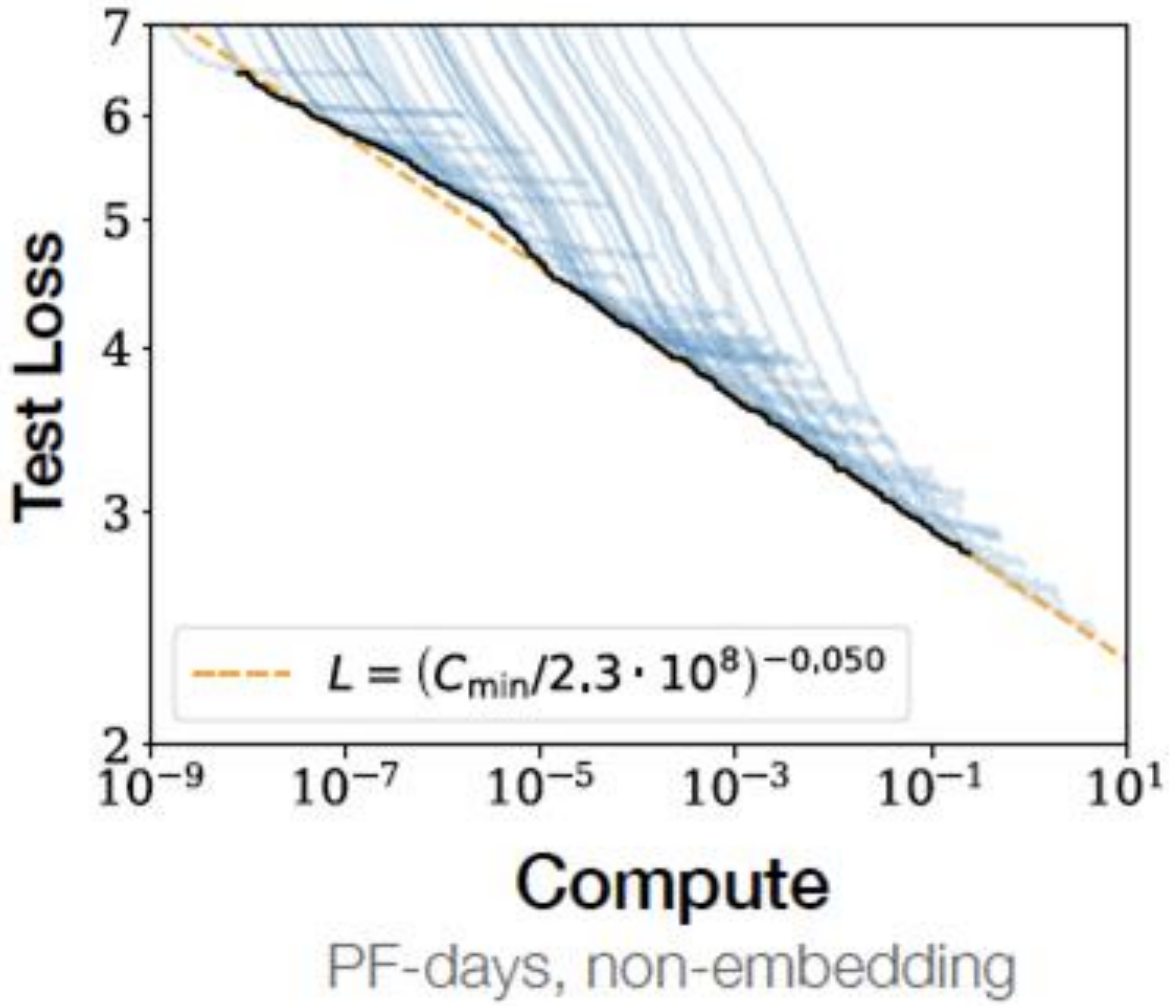
DLにおけるスケール則とは？

1. 計算資源（C）
2. データセットサイズ（D）
3. パラメータ数（N）

と誤差（L）の間に成立する次の経験則.

$$L(X) = \left({X_c}/{X}\right)^{\alpha}$$
$$\log L(X) = \alpha \log X_c - \alpha \, log \, X$$

※ 他2つの変数が十分大きい場合.

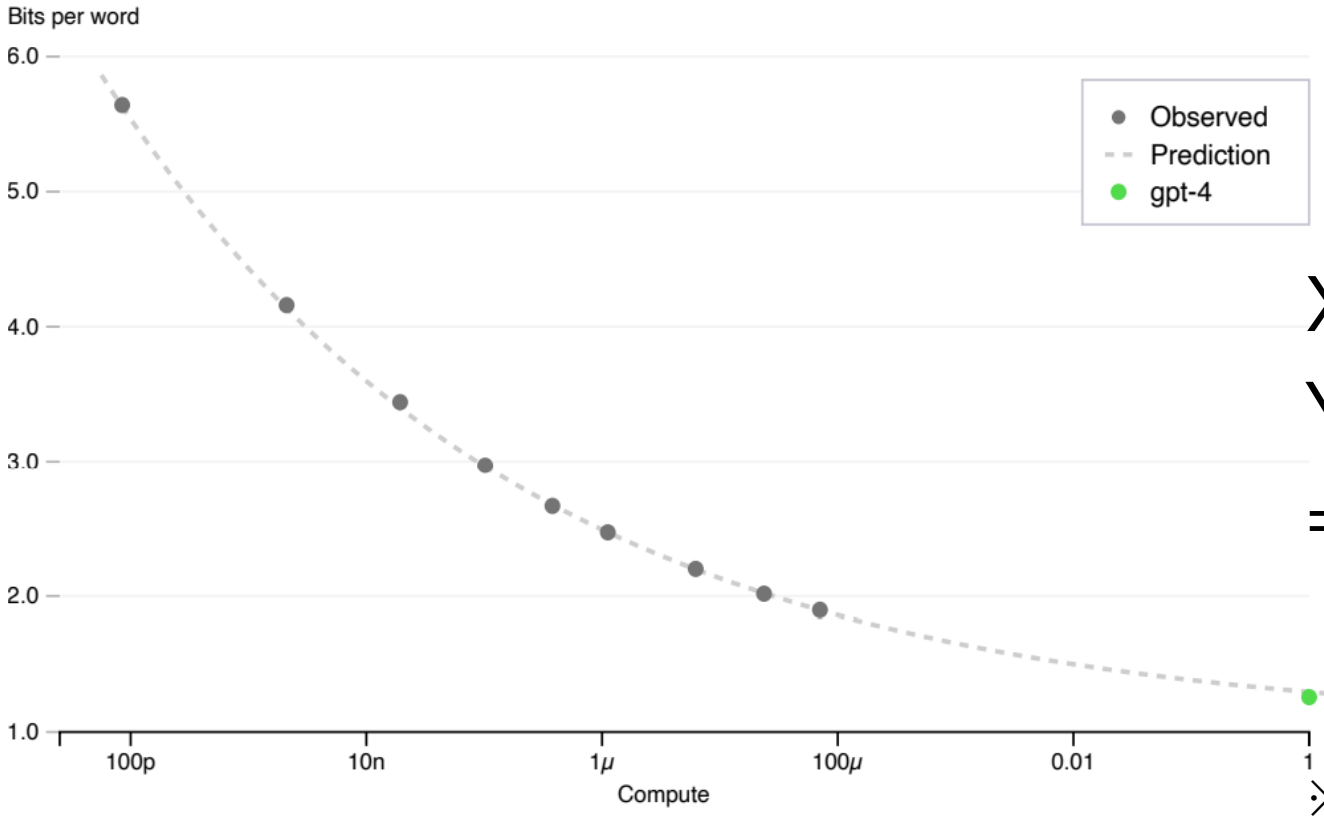


LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

“Scaling laws de-risk investments in large models”

Q. あるモデルを1Tまでスケールするべきか？



X軸：GPT4を1.0とした計算量

Y軸：性能

⇒1/1000程度のモデルまでで
性能を正確に予測できる.

※ GPT-4のパラメタ数は公開されていないがどんなに小さくても10^{10} (10B) より大.
左の図の最小が10^{3}だとしたら10^{13} (1T)

“GPT-4 Technical Report” [13] より抜粋

[13] OpenAI. GPT-4 Technical Report. 2023より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

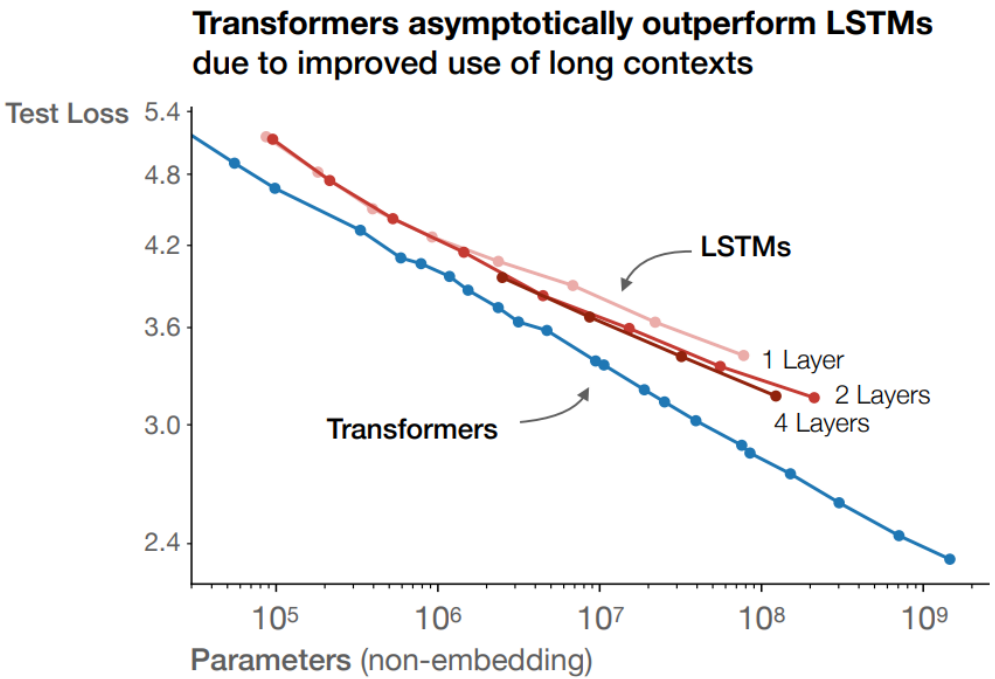
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

より精緻なモデル選択

Q. モデルAとモデルBはどちらが性能がよい？

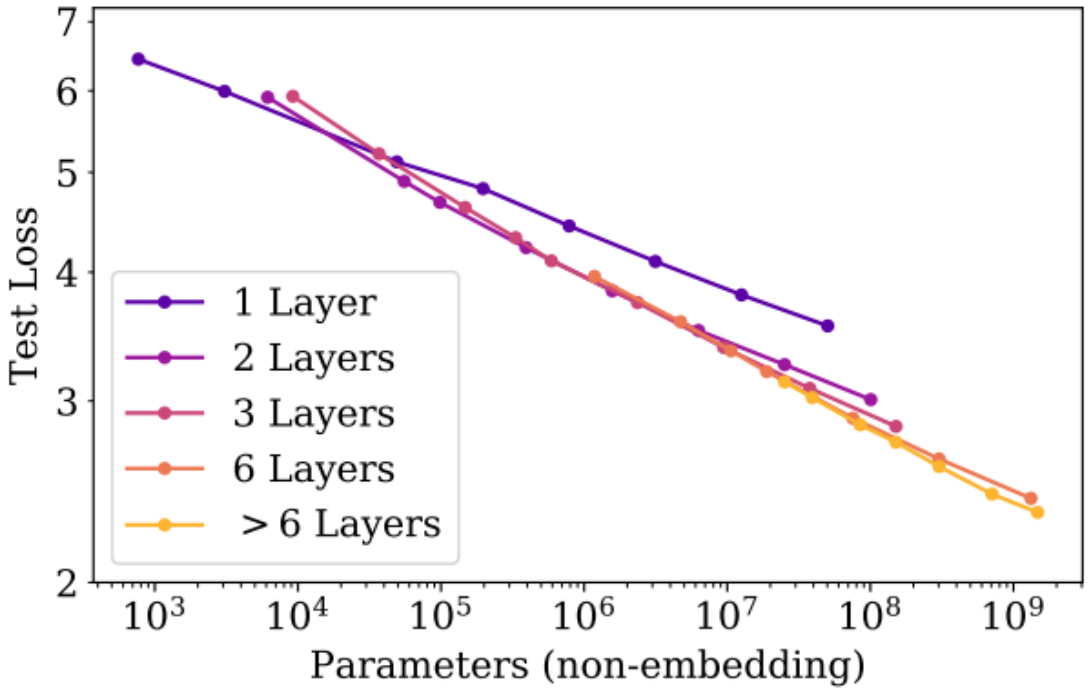
[3] Kaplan+. Scaling Laws for Neural Language Models. 2020 より引用

モデル構造の探索



スケールしてもおそらく
Transformer > LSTM

ハイパラ探索

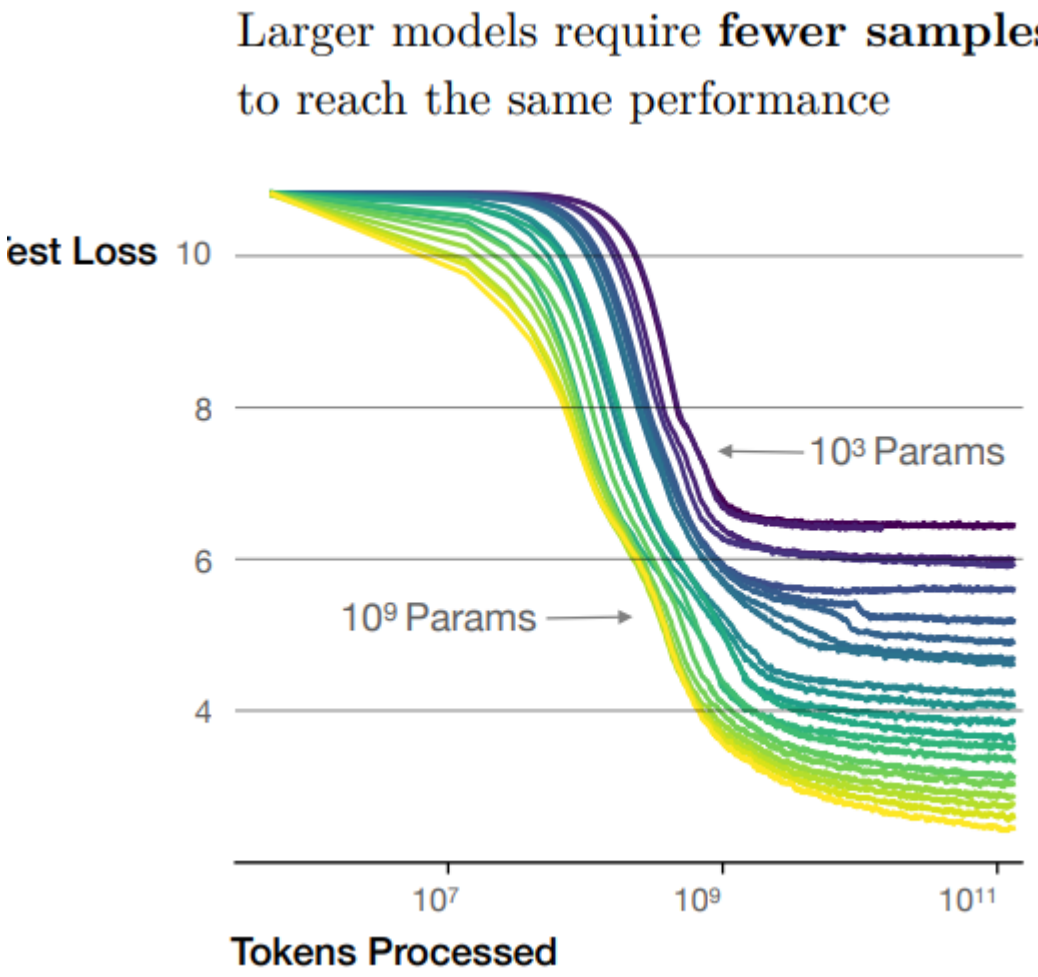


パラメータ小=> 層が少ないほうが良い
パラメータ大=> 層が多いほうが良い

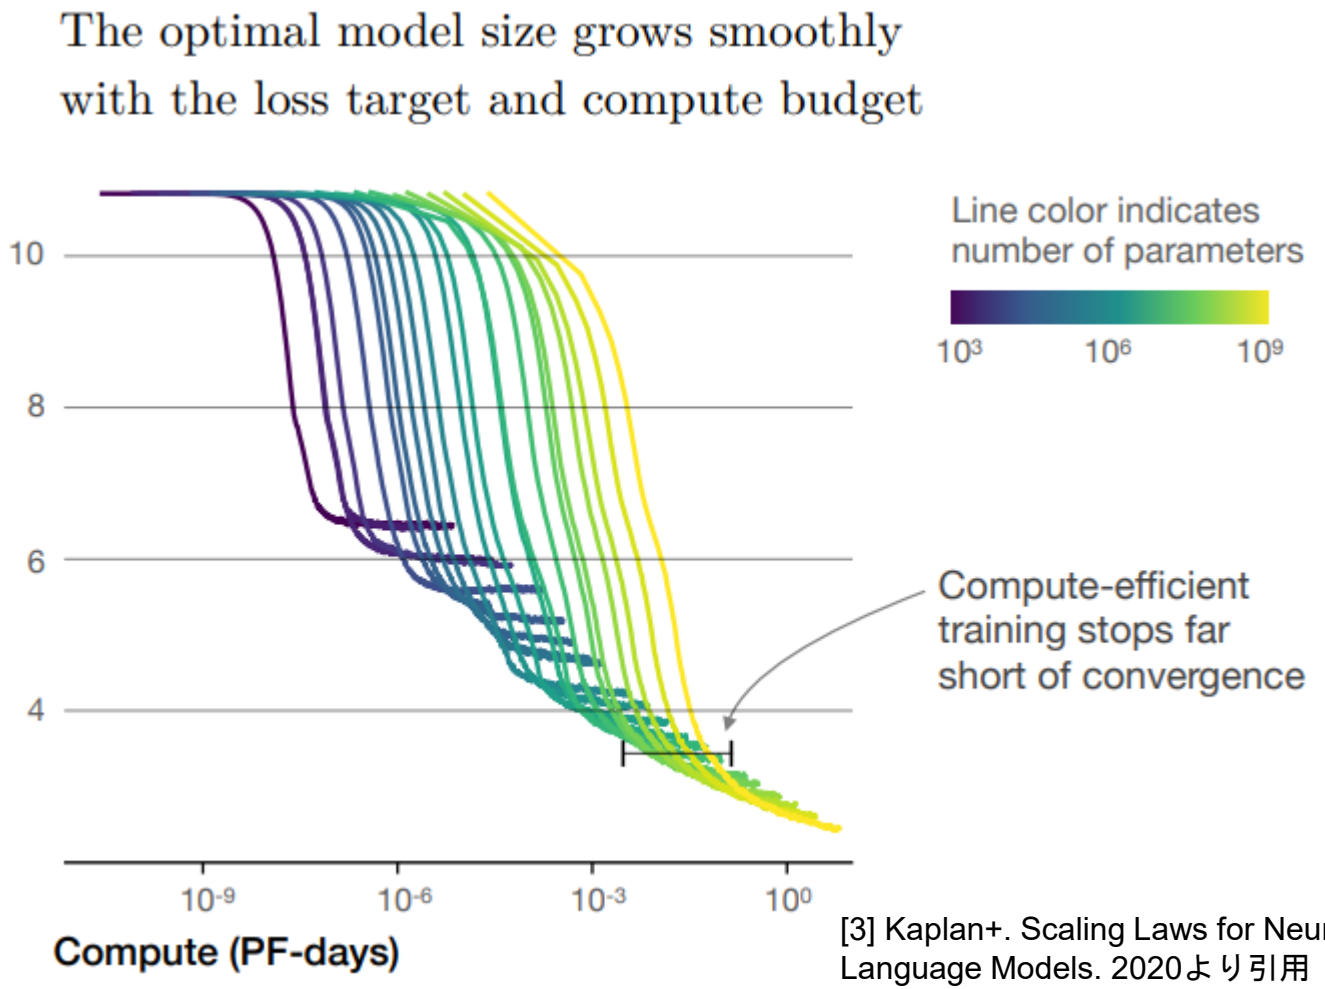
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

スケーリングによって享受できるメリット|効率性



パラメータ数が多いほど
サンプル効率は良い



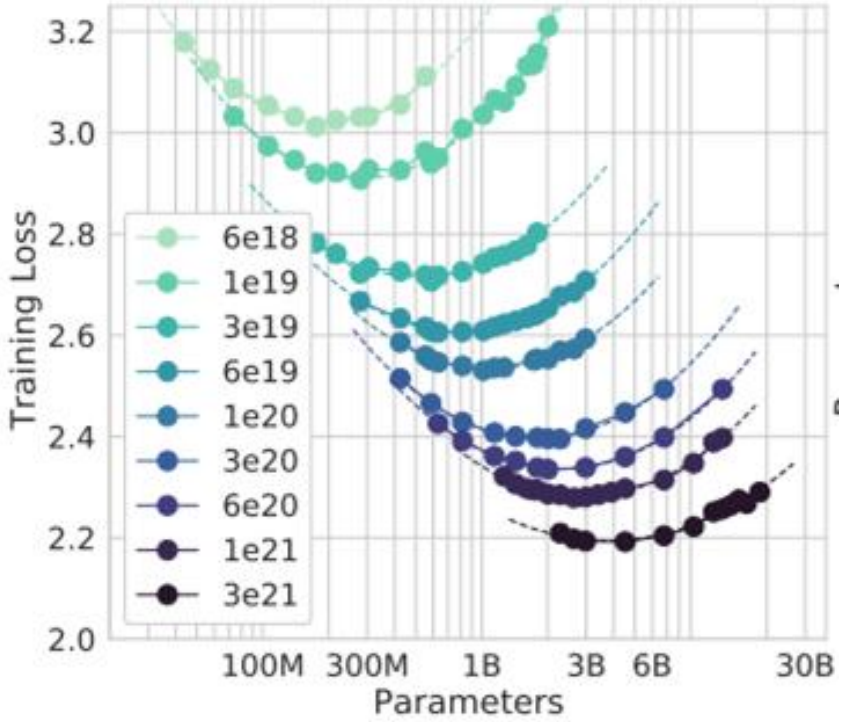
[3] Kaplan+. Scaling Laws for Neural Language Models. 2020より引用

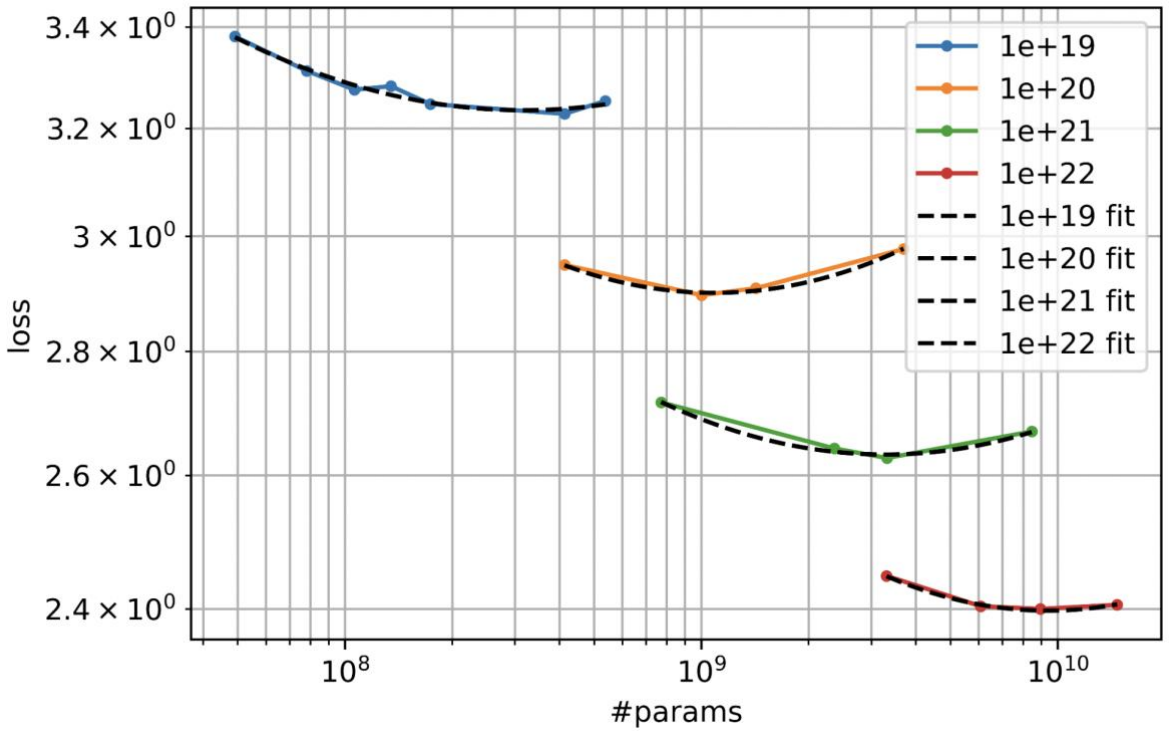
小さなモデルだと学習途中からロスが下がりづらくなる -> ある
ロスを達成するのに小さなモデルで計算を継続するのは非効率

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

与えられた計算量の下で最適なパラメータ数とトークン数を探す





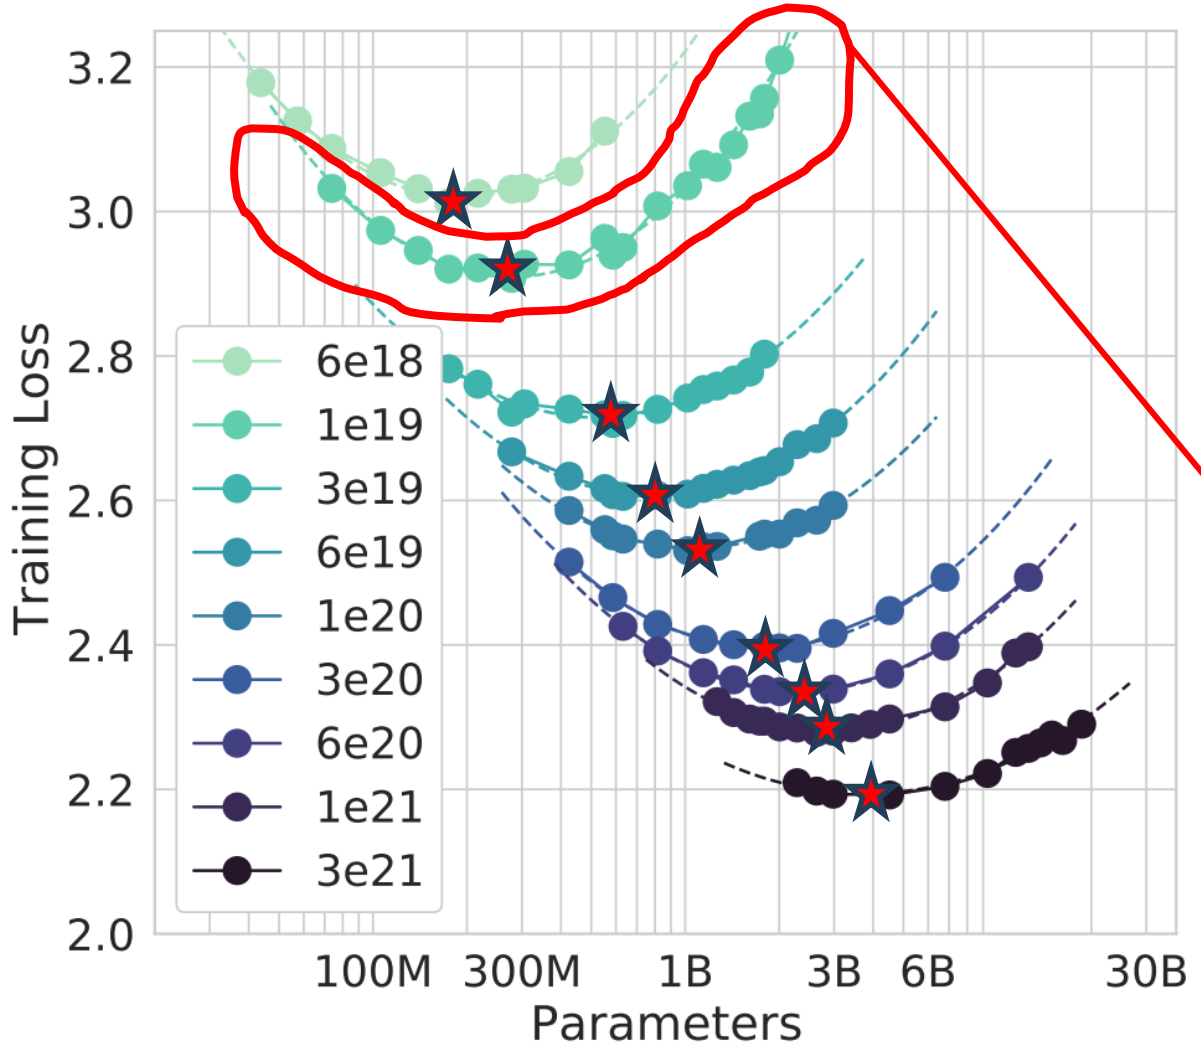
[42] Hoffmann+. Training Compute-Optimal Large Language Models. 2022より引用

- 計算量を固定したときに，パラメータ数とトークン数を変動させた場合のプロット
  - 左：Chinchilla，右：PaLM2
- どの計算量でもUカーブになっており．最適な値がありそうなことがわかる

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Chinchilla：最適計算配分に基づきNとDを決めたモデル



与えられた計算量（この曲線の場合は1e19 FLOPs）のもとで、異なるパラメータのモデル（50M, 100M, 300M, 1B・・・）をそれぞれ学習し、各モデルの最終的なTraining Lossをプロットすると、Uカーブができる。

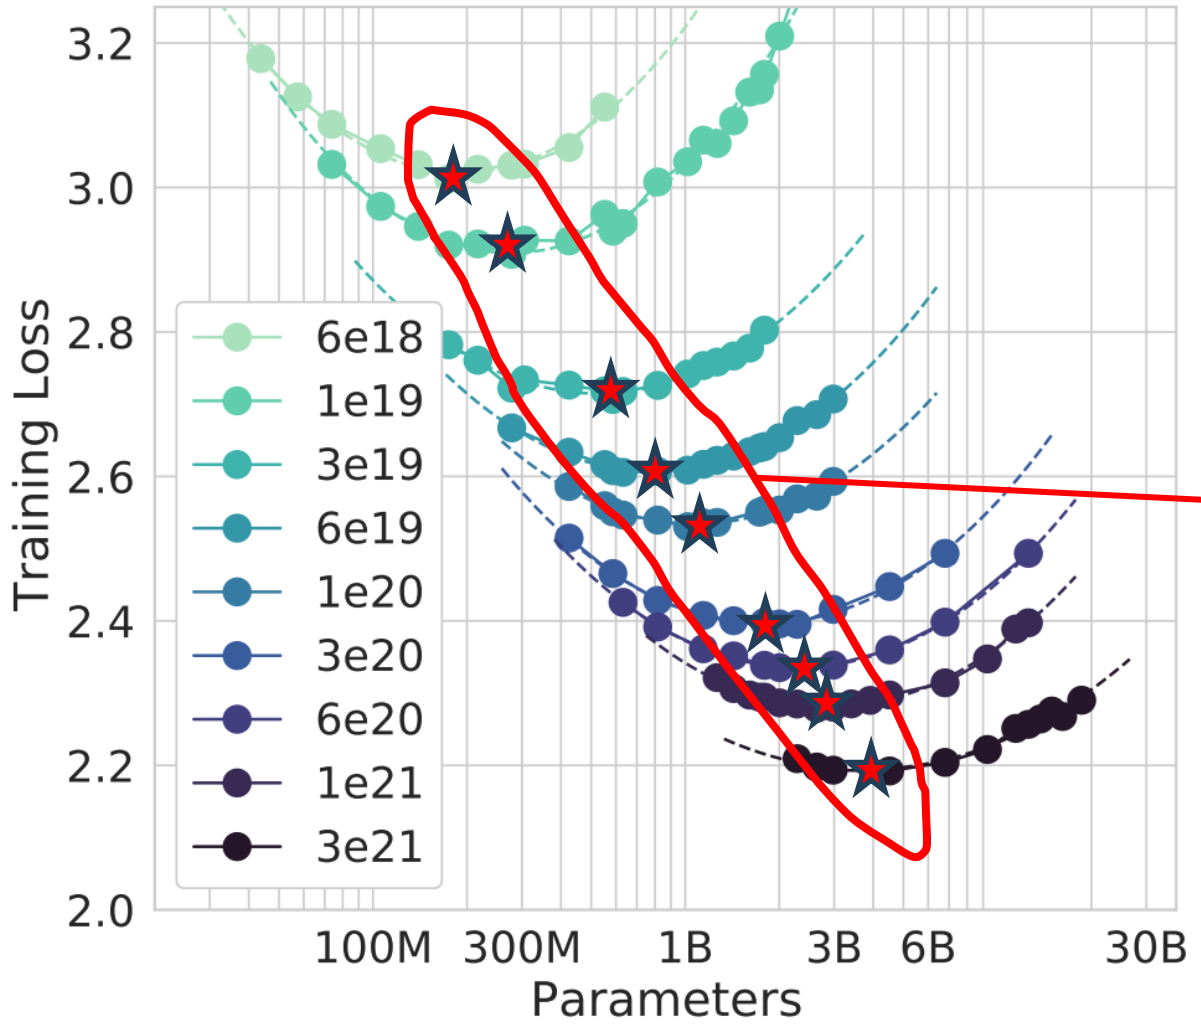
Q：なぜ下にUカーブになるのか？≒なぜ右肩下がりの線にならないのか？
A：大きなパラメータサイズのモデルになるほど、学習初期のLossが下がりづらいから（前頁の右図を参照）。

[42] Hoffmann+. Training Compute-Optimal Large Language Models. 2022より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Chinchilla：最適計算配分に基づきNとDを決めたモデル



各曲線ごとにTraining Lossが最小となるポイントが存在する（図の☆）。これらが、各計算量（各FLOPs）における最適なパラメータサイズ。

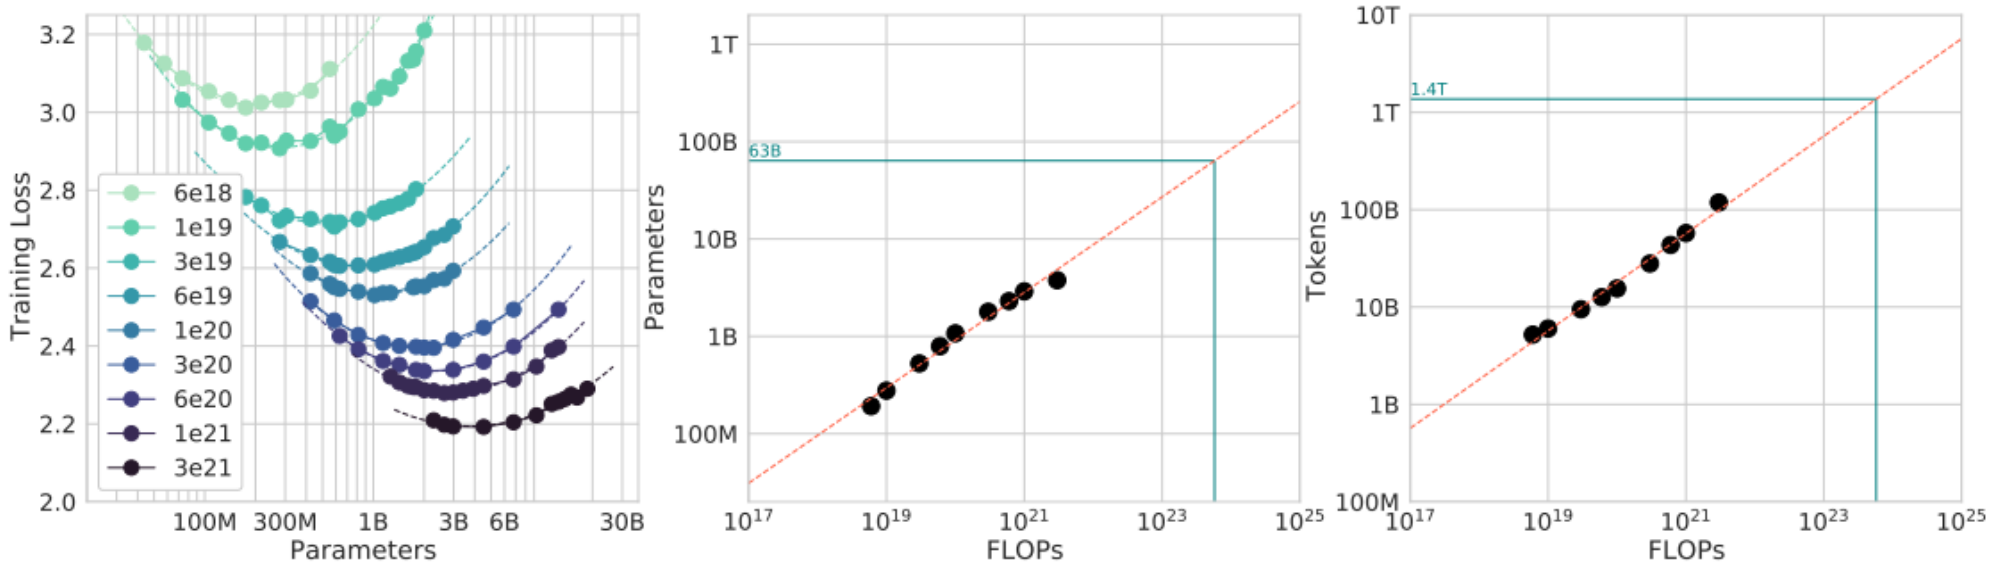
計算量を変えて、同じように曲線を描いて最適なパラメータサイズを出していくと、FLOPsとParameterの間の最適な関係を導出することができる。ほぼ直線の関係であることがわかる。

[42] Hoffmann+. Training Compute-Optimal Large Language Models. 2022より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Chinchilla：最適計算配分に基づきNとDを決めたモデル



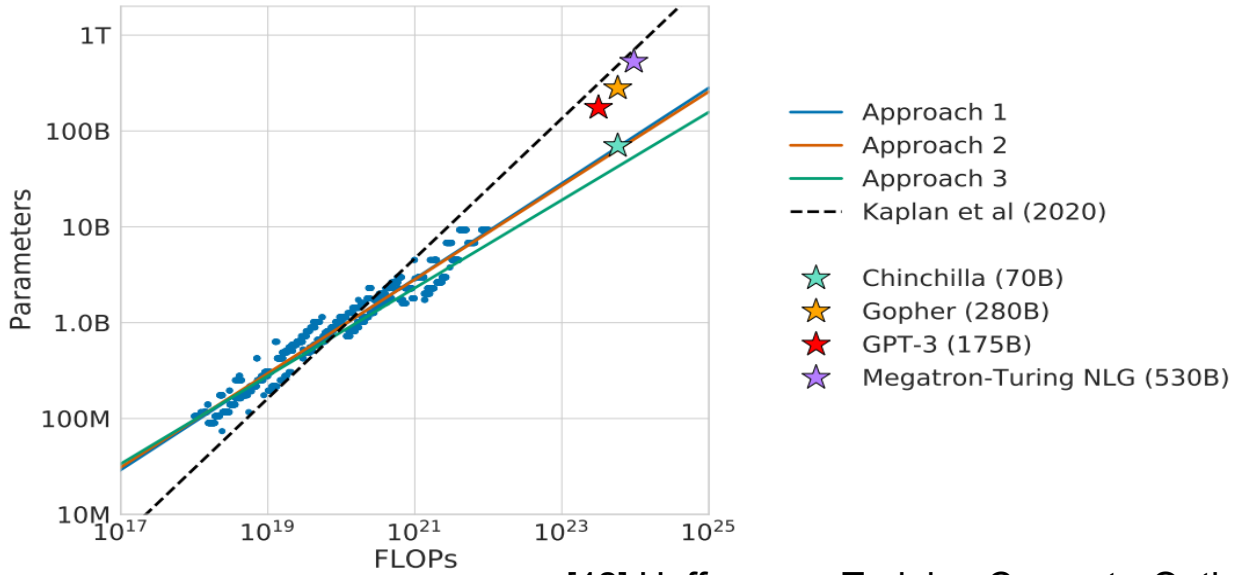
[42] Hoffmann+. Training Compute-Optimal Large Language Models. 2022より引用

- 計算量固定でトークン数とパラメータ数を変動させた結果（左）
  参考）FLOPs ＝ 6 × N（パラメータ数） × D（トークン数）
- この結果を，各FLOPsでの最適なパラメータに直したもの（中央）
- 同様にトークン数について最適な値をもとめたもの（右）

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Chinchilla：最適計算配分に基づきNとDを決めたモデル

Model	Size (# Parameters)	Training Tokens
LaMDA (Thoppilan et al., 2022)	137 Billion	168 Billion
GPT-3 (Brown et al., 2020)	175 Billion	300 Billion
Jurassic (Lieber et al., 2021)	178 Billion	300 Billion
Gopher (Rae et al., 2021)	280 Billion	300 Billion
MT-NLG 530B (Smith et al., 2022)	530 Billion	270 Billion
Chinchilla	70 Billion	1.4 Trillion



データサイズD

トークンを1.4Tまで増加
（同じデータの別サブセット）
※ Gopherの約4.6倍

モデルサイズN

70Bに設定
※ Gopherの約1/4倍

結果

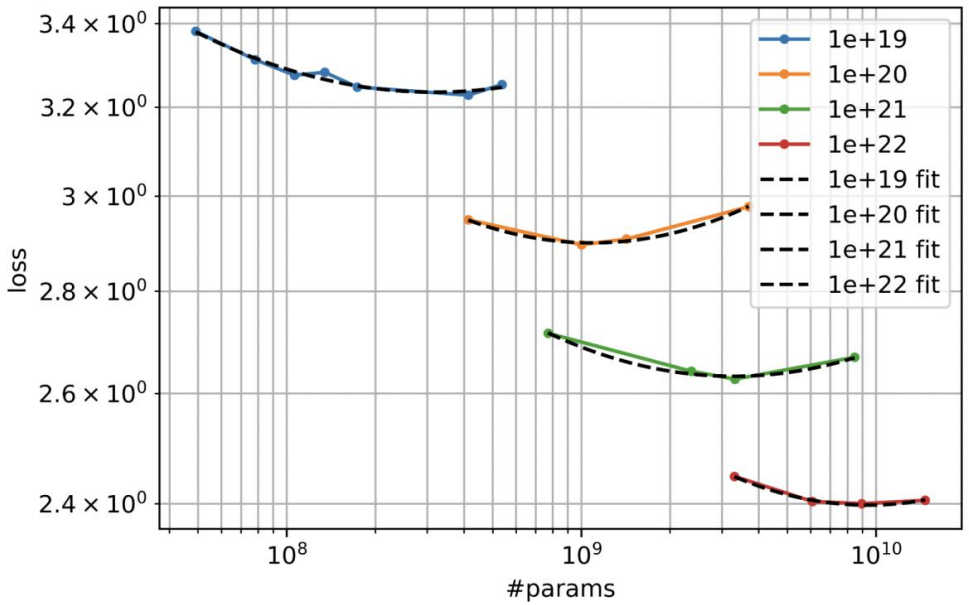
多くのケースでより巨大なモデルに勝利
（発見した関係式の妥当性を示唆）
最適トークン数 = 20 * パラメータ数

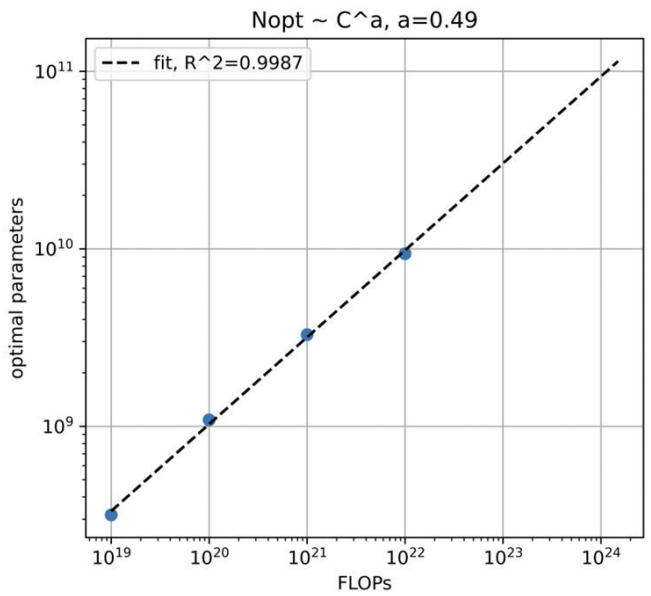
[42] Hoffmann+. Training Compute-Optimal Large Language Models. 2022より引用

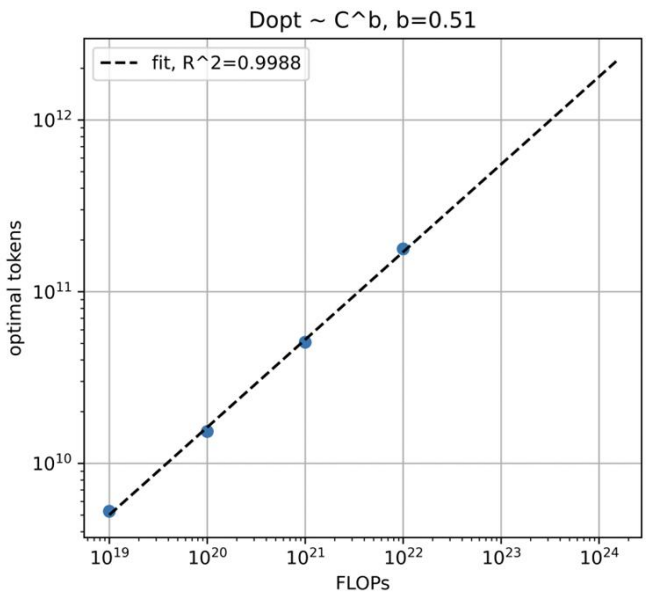
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

PaLM2でのスケール則（Google, 2023）







PaLM2でも同様の実験が行われており，Chinchilla同様のスケール則が確認.

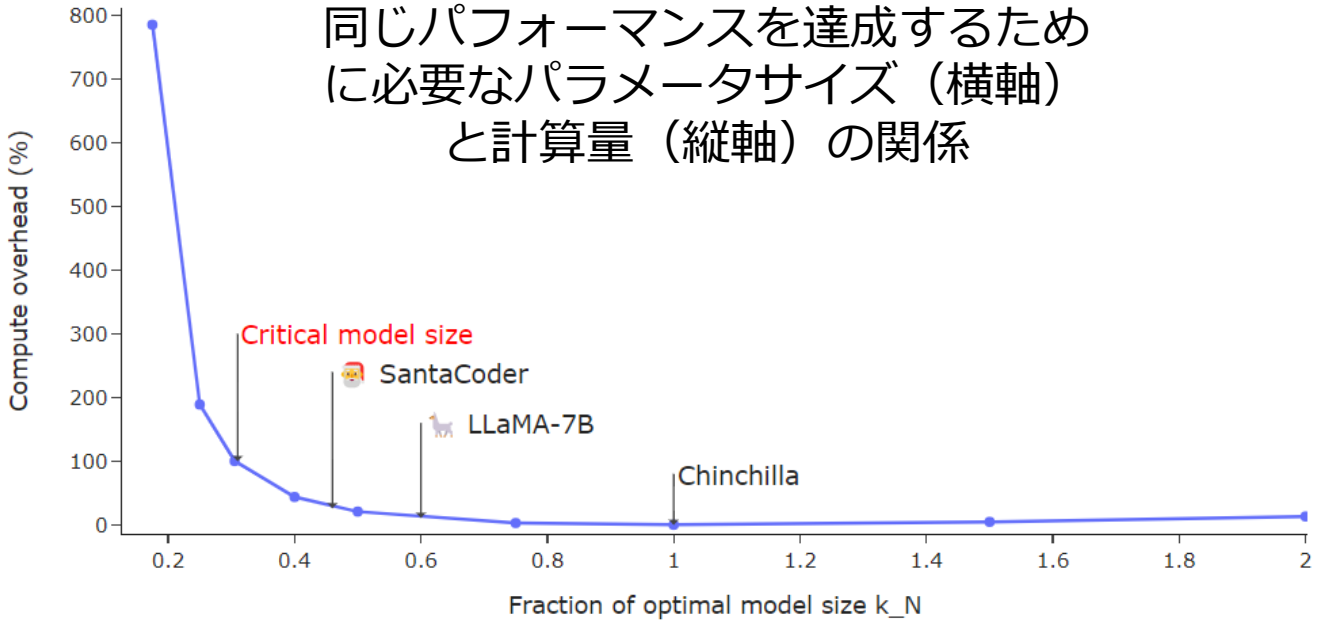
[10] Anil+. PaLM 2 Technical Report. 2023より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Chinchilla則を超えた量の学習

“Go smol or go home, Why we should train smaller LLMs on more tokens”より抜粋

同じパフォーマンスを達成するため
に必要なパラメータサイズ（横軸）
と計算量（縦軸）の関係



[43] de Vries. Go smol or go home, Why we should train smaller LLMs on more tokens. Harm de Vries Blog. 2023より引用

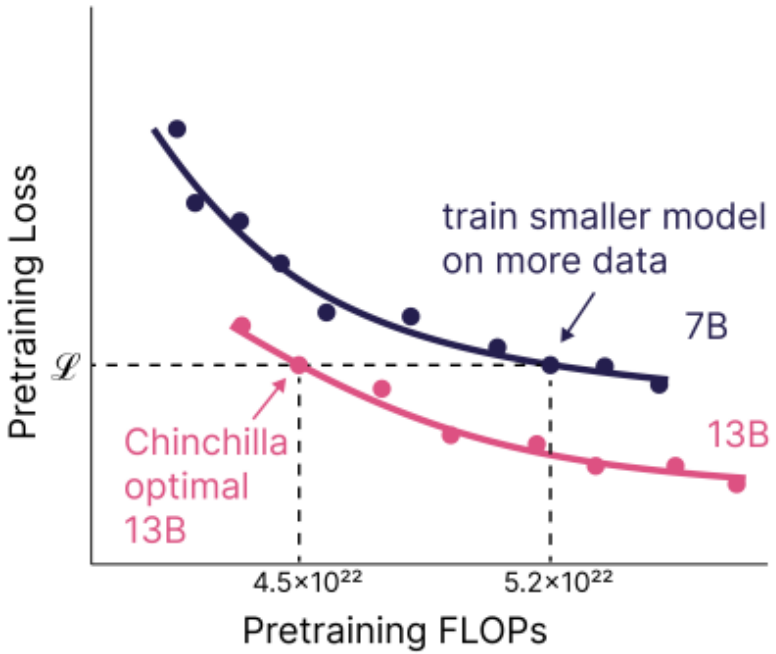
- Chinchilla Trap:
  Chinchillaのモデルサイズ(70B)は大きいため, 推論コストが高い*.
  推論コストも考慮してより小さなモデルを長時間訓練するべきではという意見

- 最適モデルサイズの40-60%以内のモデルサイズを選択して,
  10-42%の計算量の追加で同性能のモデルを学習できるという指摘

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

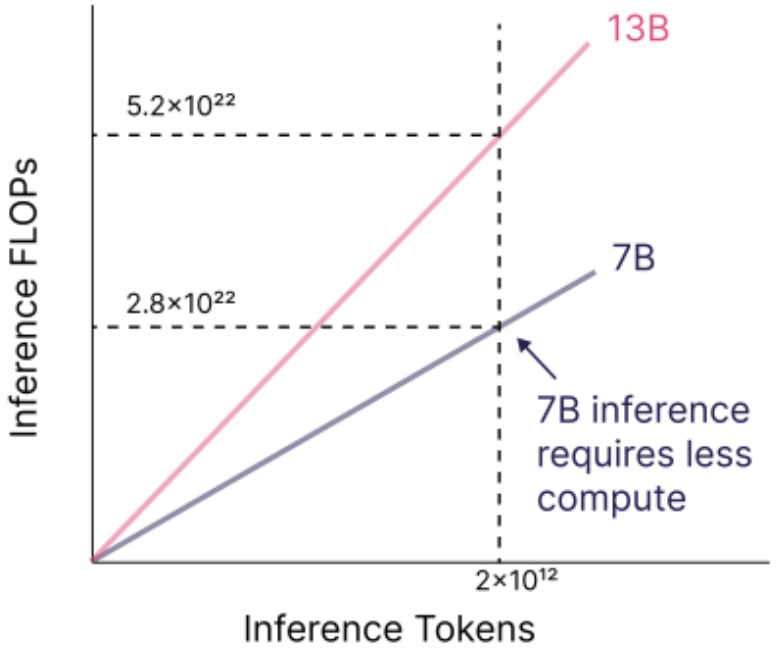
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Q. Chinchilla則は本当に*最適*なのか？



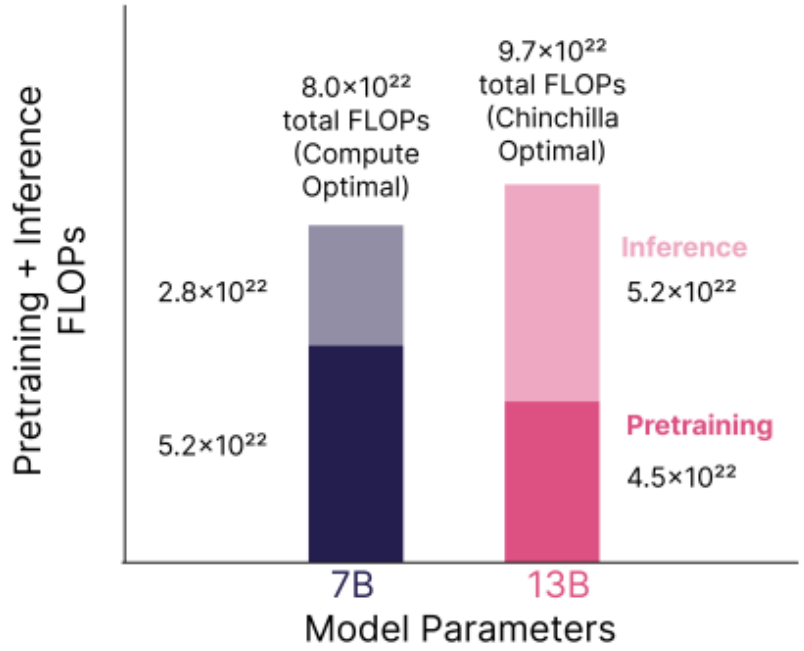
(a)

学習だけを見ると、大きいモデルのほうが小さいモデルよりも同じFLOPsで高い性能を発揮する



(b)

一方で、推論時は、大きいモデルのほうが小さいモデルよりも同じ多くのFLOPsを必要とする学習と推論のトレードオフが発生



(c)

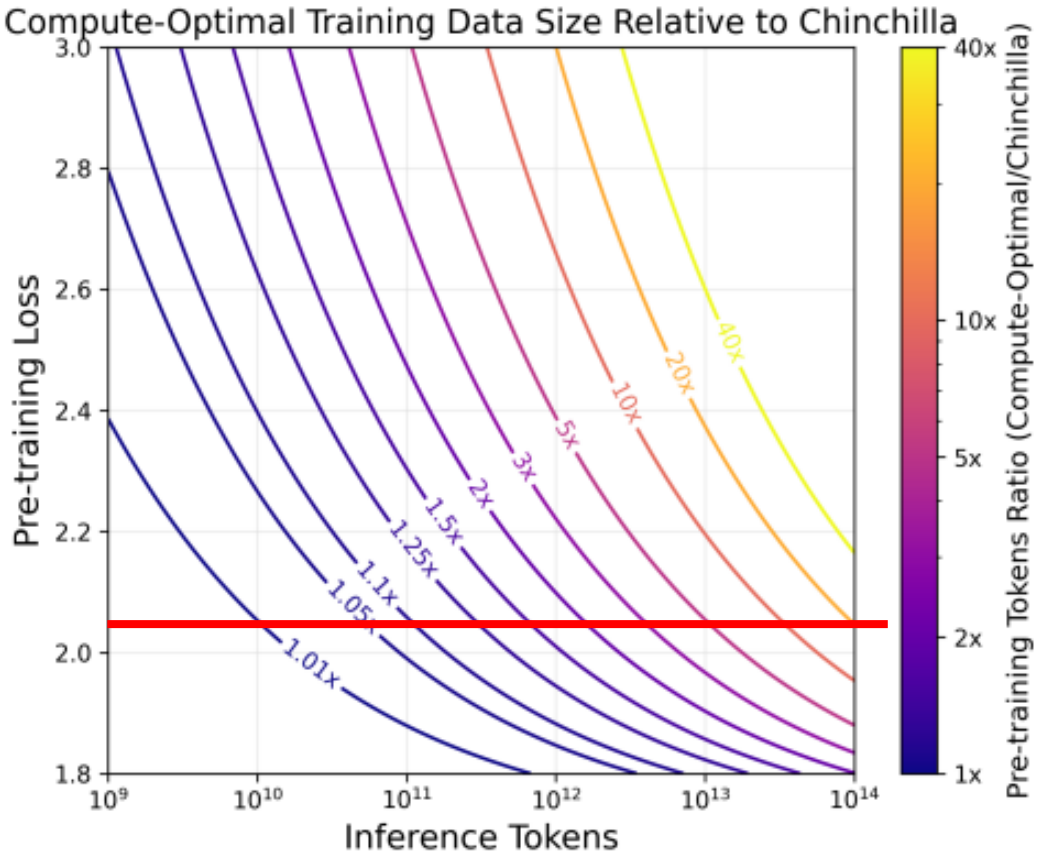
学習と推論の両方のFLOPsを考慮した最適解（トークン数，パラメータ数）を出したほうがいいのでは？

[50] Sardana+. Beyond Chinchilla-Optimal: Accounting for Inference in Language Model Scaling Laws. 2024より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

推論時のコストを考慮した最適なトークン数



推論時のトークン数と達成したい学習Lossを仮定したときの、ライフタイム全体の総FLOPsを最小にするような最適なパラメータ数および学習時のトークン数

$$N^*(\ell, D_{\text{inf}}), D^*_{\text{tr}}(\ell, D_{\text{inf}}) = \underset{N, D_{\text{tr}} | L(N, D_{\text{tr}}) = \ell}{\arg\min} \; 6ND_{\text{tr}} + 2ND_{\text{inf}}. \tag{3}$$

- 横軸：推論時のトークン数の仮定
- 色：学習時のトークン数をChinchillaに対して何倍にするか（1.01 ~ 40）
- 推論回数が多くなるほどライフタイム全体では学習トークン数を増やすほうが有利

[50] Sardana+. Beyond Chinchilla-Optimal: Accounting for Inference in Language Model Scaling Laws. 2024より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

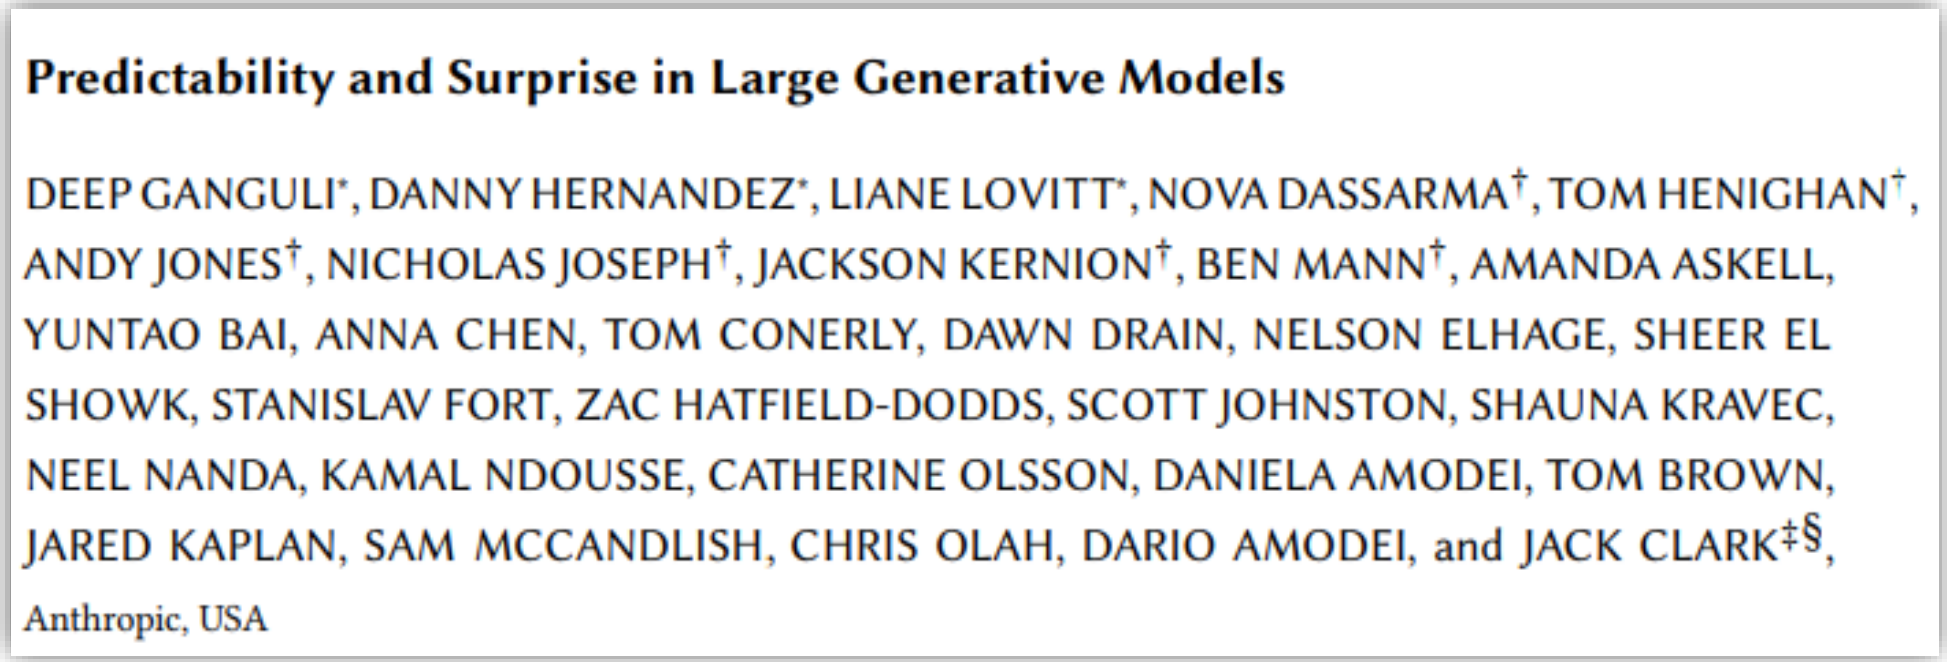
■ 参考 | 様々なモデルのToken to Parameter Ratio (D/N)

	Params (N)	Token (D)	D/N
Gopher	280B	0.3T	1.07
Chinchilla	70B	1.4T	**20.0**
Llama 2	7B	1.8T	**285**
	70B	1.8T	**28.5**
Llama 3	70B	15T	**214.2**
	405B	15T	**37.7**
Qwen 3	32B	36T	**1125**

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

■ 補足 | 予測可能な改善と予測不可能な改善



Predictability and Surprise in Large Generative Models

DEEP GANGULI*, DANNY HERNANDEZ*, LIANE LOVITT*, NOVA DASSARMA†, TOM HENIGHAN†, ANDY JONES†, NICHOLAS JOSEPH†, JACKSON KERNION†, BEN MANN†, AMANDA ASKELL, YUNTAO BAI, ANNA CHEN, TOM CONERLY, DAWN DRAIN, NELSON ELHAGE, SHEER EL SHOWK, STANISLAV FORT, ZAC HATFIELD-DODDS, SCOTT JOHNSTON, SHAUNA KRAVEC, NEEL NANDA, KAMAL NDOUSSE, CATHERINE OLSSON, DANIELA AMODEI, TOM BROWN, JARED KAPLAN, SAM MCCANDLISH, CHRIS OLAH, DARIO AMODEI, and JACK CLARK‡§,

Anthropic, USA

[12] Ganguli+. Predictability and Surprise in Large Generative Models. 2023より引用

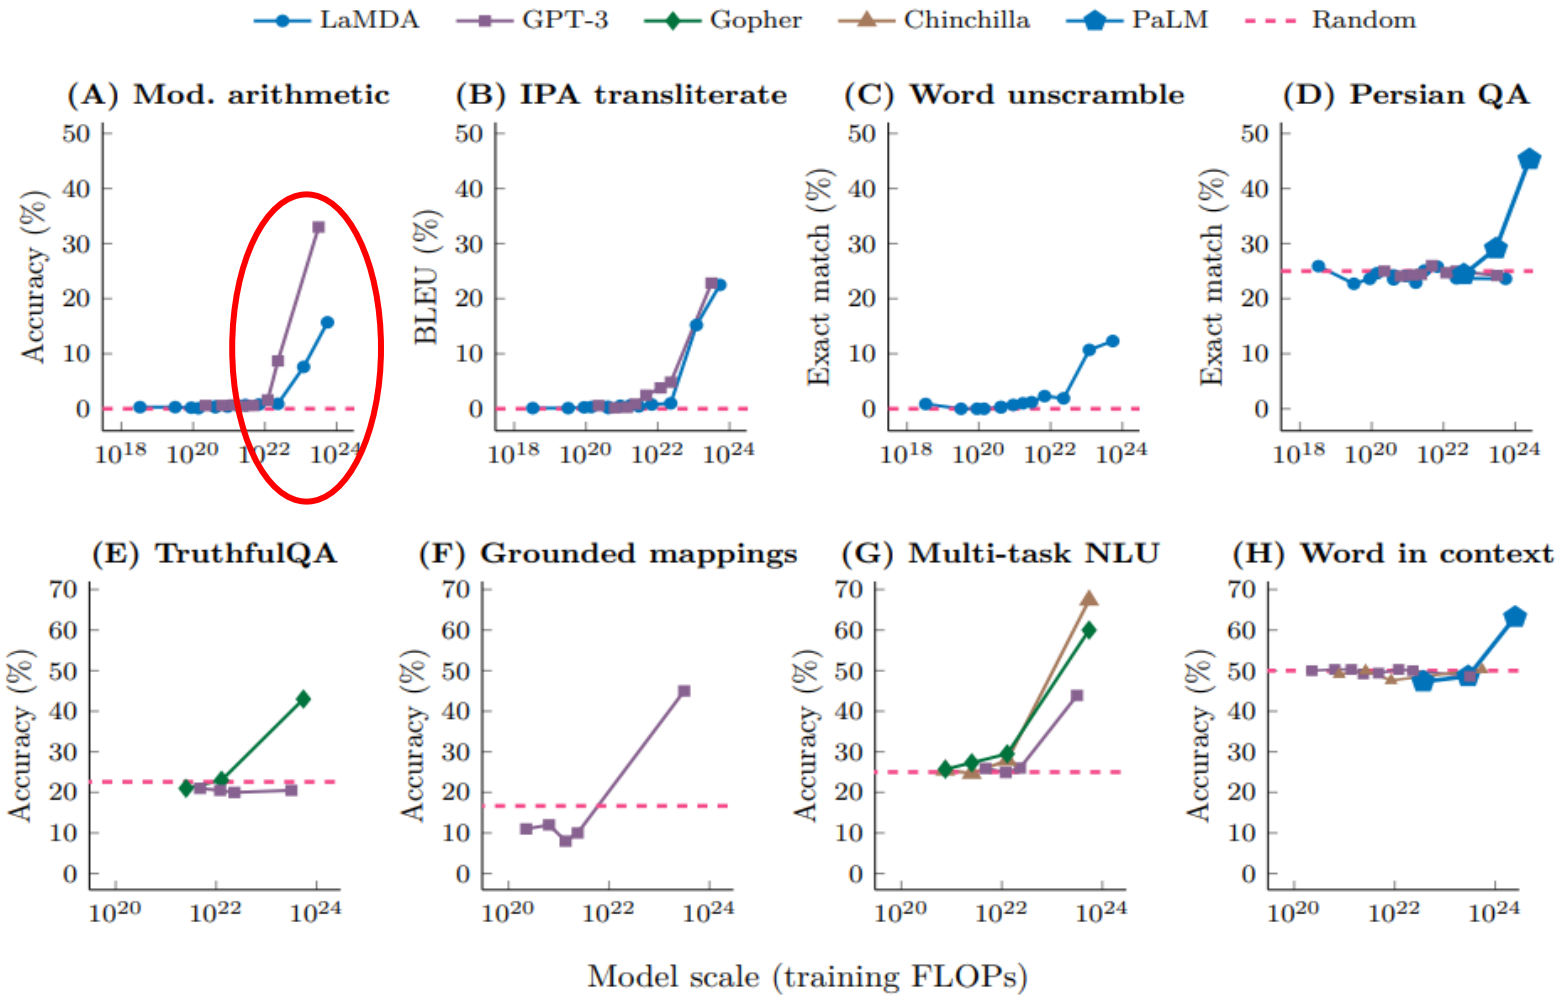
予測可能な例
- スケール則に従った性能の概算
- 一般的な文章の次単語予測精度
- 翻訳タスクやQAタスクでの平均的なスコア改善

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

予測不可能な性質の例 | Emergent Ability

モデルサイズを巨大にすると性能が”突如”大幅に上がるタスクがある

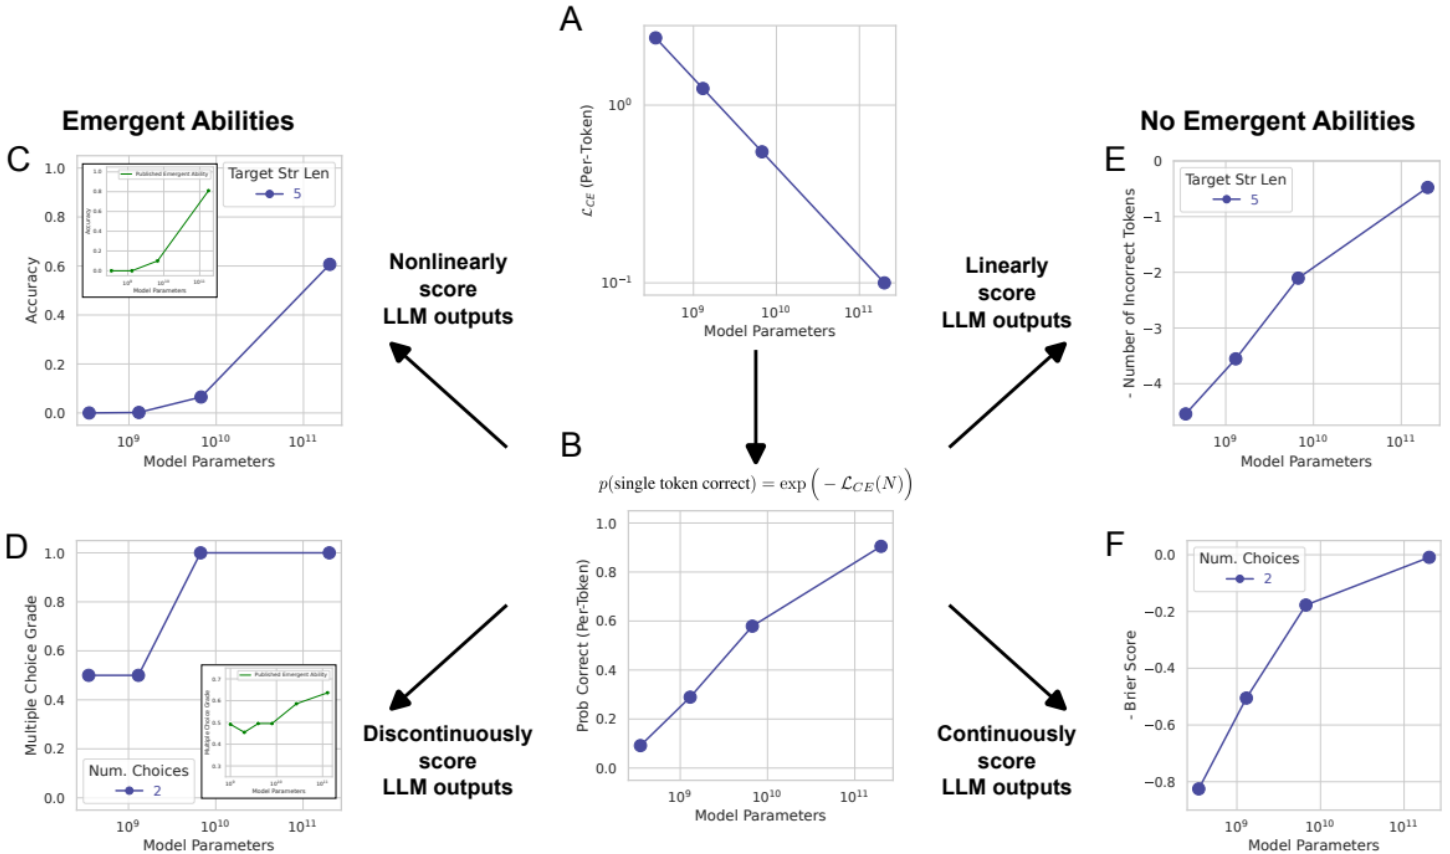


[4] Wei+. Emergent Abilities of Large Language Models. 2022より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

■補足 | 本当に創発能力なのか?



- 本当に「創発」「相転移」しているのかには反論もある
  - 性能の測り方による（左図）
    ※ これは本論文でも言われている
  - 横軸が対数なのは変では
  - そもそも何を持って創発？

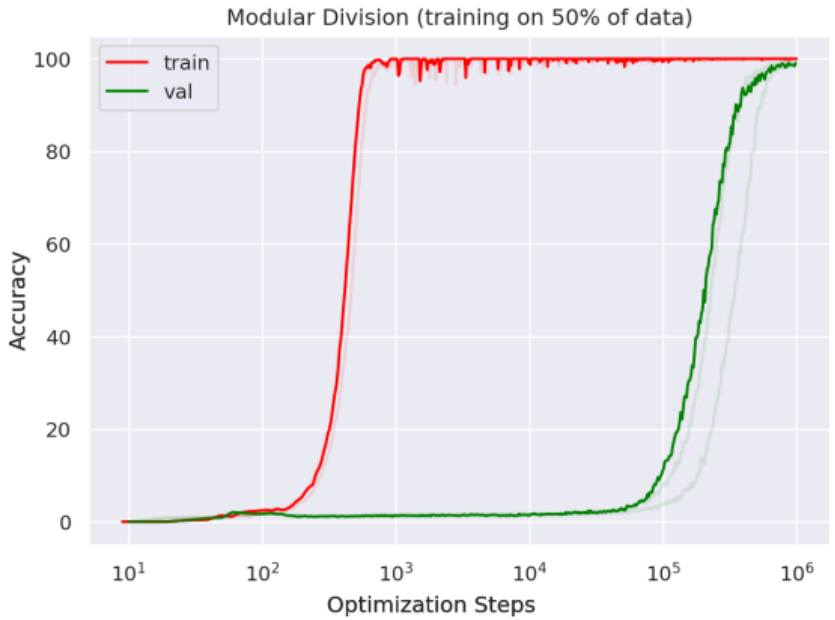
- 巨大モデル|巨大計算で思ったよりできるようになるのは事実

[5] Schaeffer+. Are Emergent Abilities of Large Language Models a Mirage?. 2023より引用

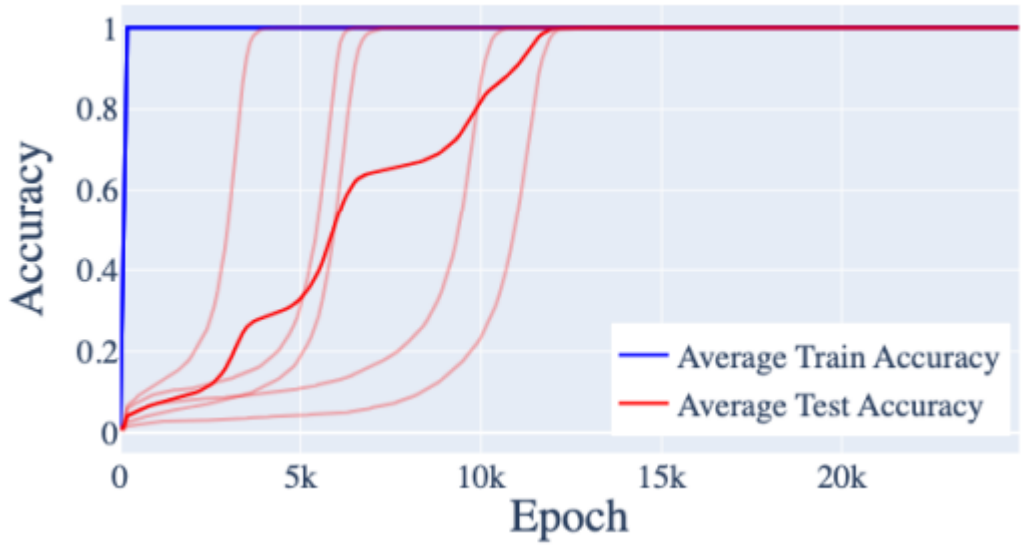
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

予測不可能な性質の例| Grokking

学習を継続すると突然検証データでの正解率が高まる現象
(学習データでの正解率はそれ以前にすでに高い. つまりOverfit後も学習を継続させると発生する現象)
（下記はa○b = c（例：x+y=?）というタスクにおける性能調査）



★	a	b	c	d	e
a	a	d	?	c	d
b	c	d	d	a	c
c	?	e	d	b	d
d	a	?	?	b	c
e	b	b	c	?	a



“Grokking: Generalization Beyond Overfitting on Small Algorithmic Datasets”, 2022

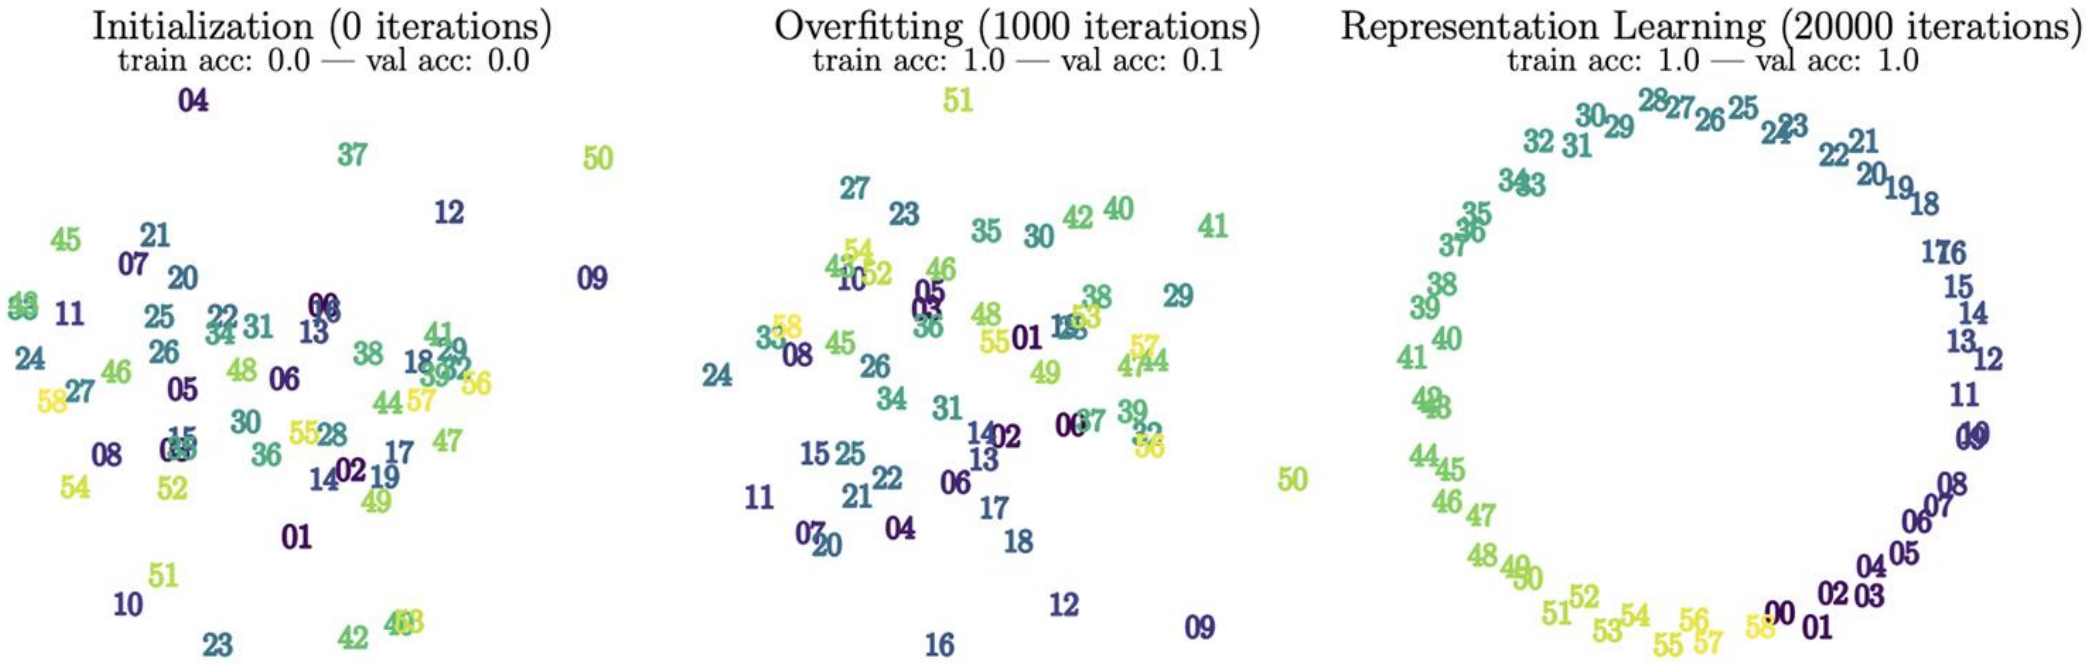
“Progress measures for grokking via mechanistic interpretability”, ICLR2023

[6] Power+. Grokking: Generalization Beyond Overfitting on Small Algorithmic Datasets. 2022より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

■補足 | Grokking中にはモデル内部で何がおこっているのか？



[7] Liu+. Towards Understanding Grokking: An Effective Theory of Representation Learning. 2022より引用

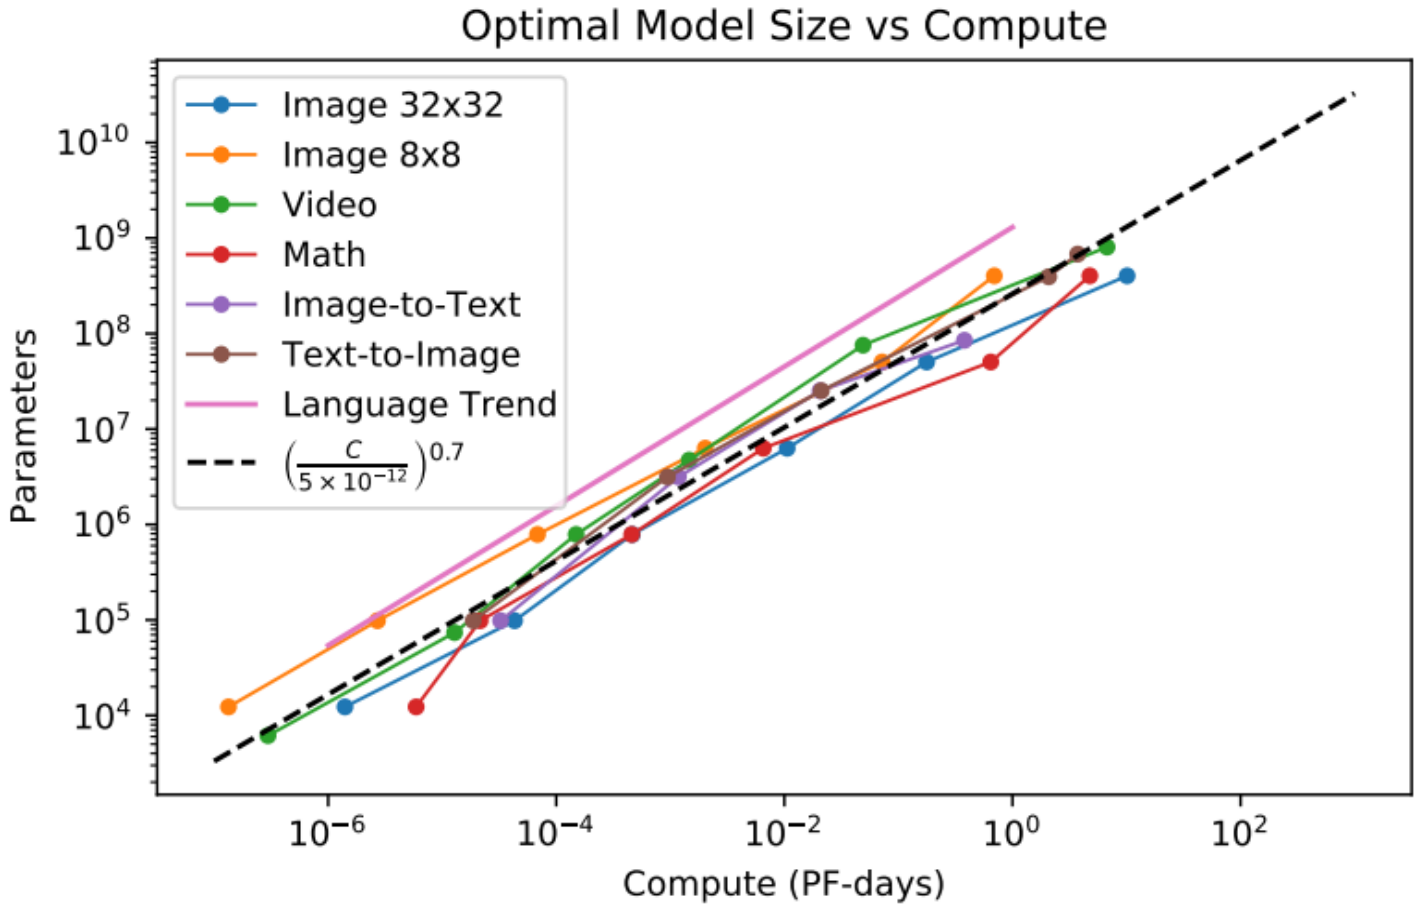
A. 記憶を汎化させている（上は学習過程の可視化）.
過学習中（中央）は覚えているだけだが，汎化後（右）には数字が綺麗に整列.

類似研究：”Progress measures for grokking via mechanistic interpretability”, ICLR2023

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

様々なドメインでのスケール則（計算量とLoss）



[11] Henighan+. Scaling Laws for Autoregressive Generative Modeling. 2020より引用

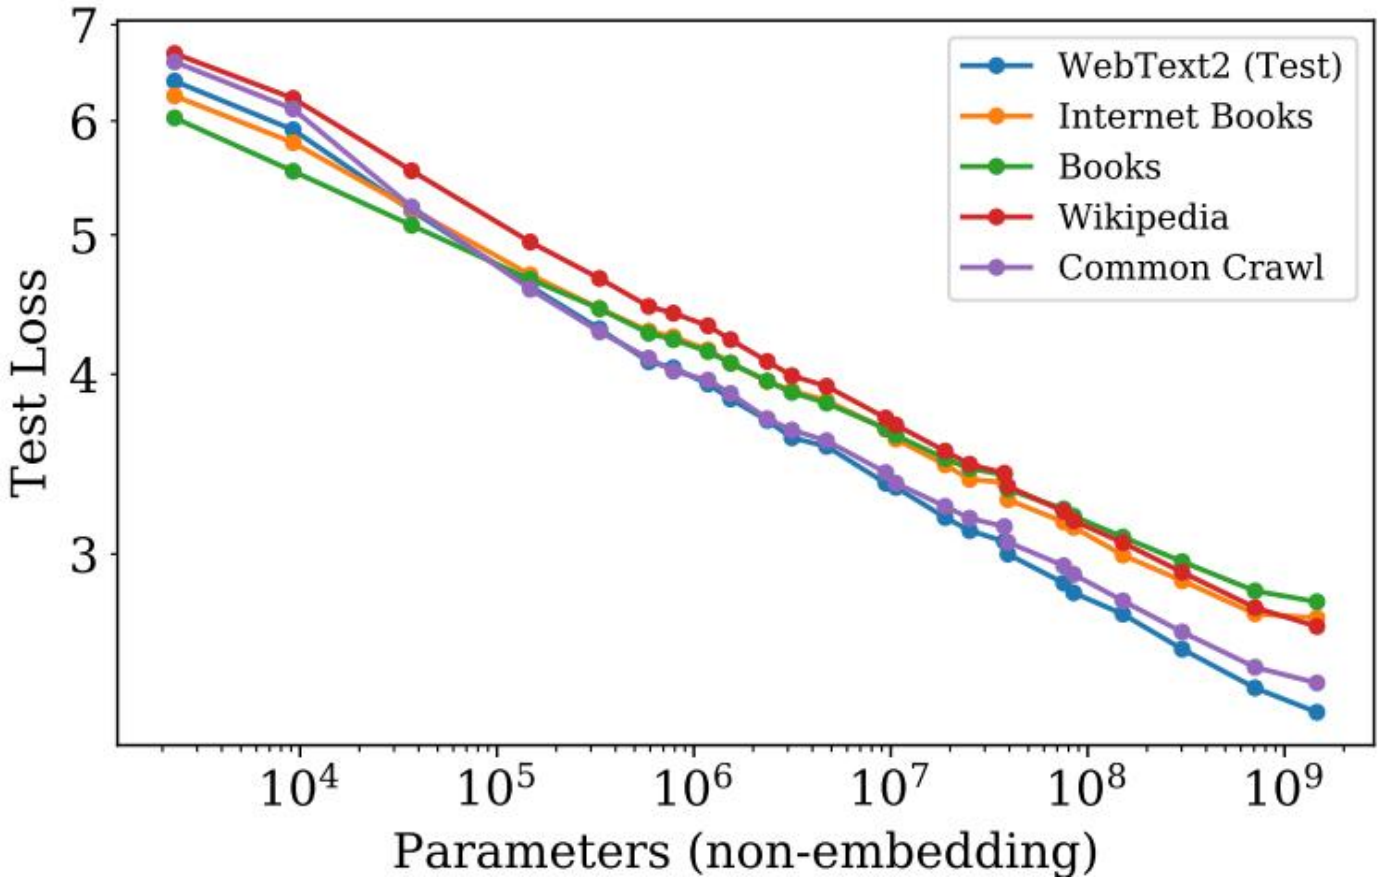
ある計算量が与えられたときの最適なモデルサイズのドメイン間での比較

どのドメインも概ね同じような傾向にある

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

下流タスクの性能とスケール則



[3] Kaplan+. Scaling Laws for Neural Language Models. 2020より引用

- WebText2：通常のテストデータ，それ以外：学習外の(分布外の)データ
- WebText2以外で性能の劣化は見られるもの，オフセットの違い程度で傾向は同じ（傾きもほぼ同じ）

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

スケール則がもたらすもの

下流タスクの性能との関係性

Q. Loss(事前学習の交差エントロピー)が低い＝下流タスクの性能が高い？

- 基本的にはYES.
- 例外もままある(例：下図②～③)
  - タスクの種類や難易度による

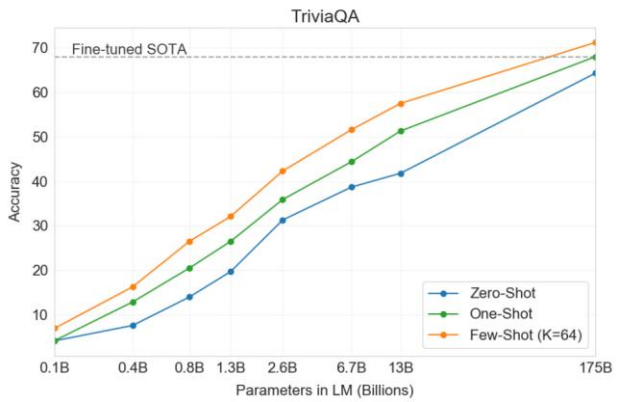
more orders of magnitude, we observe only a slight (if any) departure from the power-law. One might worry that these improvements in cross-entropy loss come only from modeling spurious details of our training corpus. However, we will see in the following sections that improvements in cross-entropy loss lead to consistent performance gains across a broad spectrum of natural language tasks.

"Language Models are Few-Shot Learners", 2020

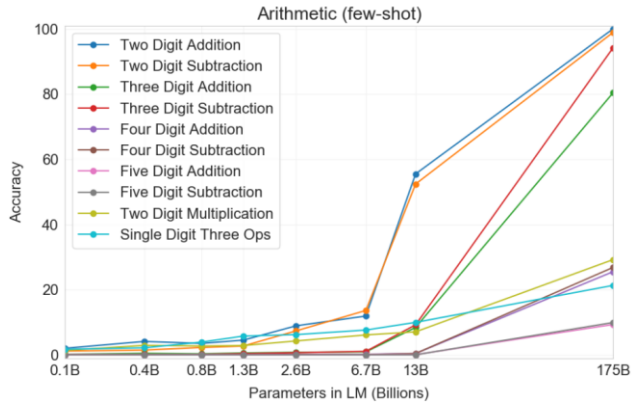
Certain capabilities remain hard to predict. For example, the Inverse Scaling Prize [44] proposed several tasks for which model performance decreases as a function of scale. Similarly to a recent result by Wei et al. [45], we find that GPT-4 reverses this trend, as shown on one of the tasks called Hindsight Neglect [46] in Figure 3.

"GPT-4 Technical Report", 2023

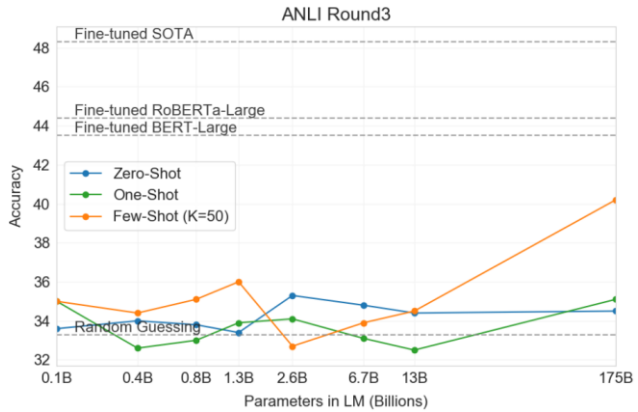
①綺麗に上がる



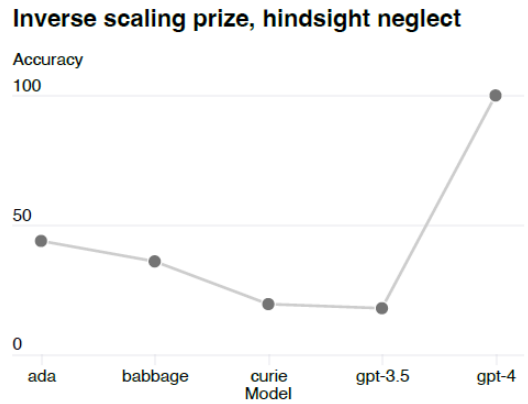
②突然上がる
(Emergent Ability)



③上がらない



④下がって上がる
(Inverse scaling prize)



①～③：[9] Brown+. Language Models are Few-Shot Learners. 2020より引用, ④：[13] OpenAI. GPT-4 Technical Report. 2023より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

スケール則がもたらすもの

下流タスクの性能との関係性

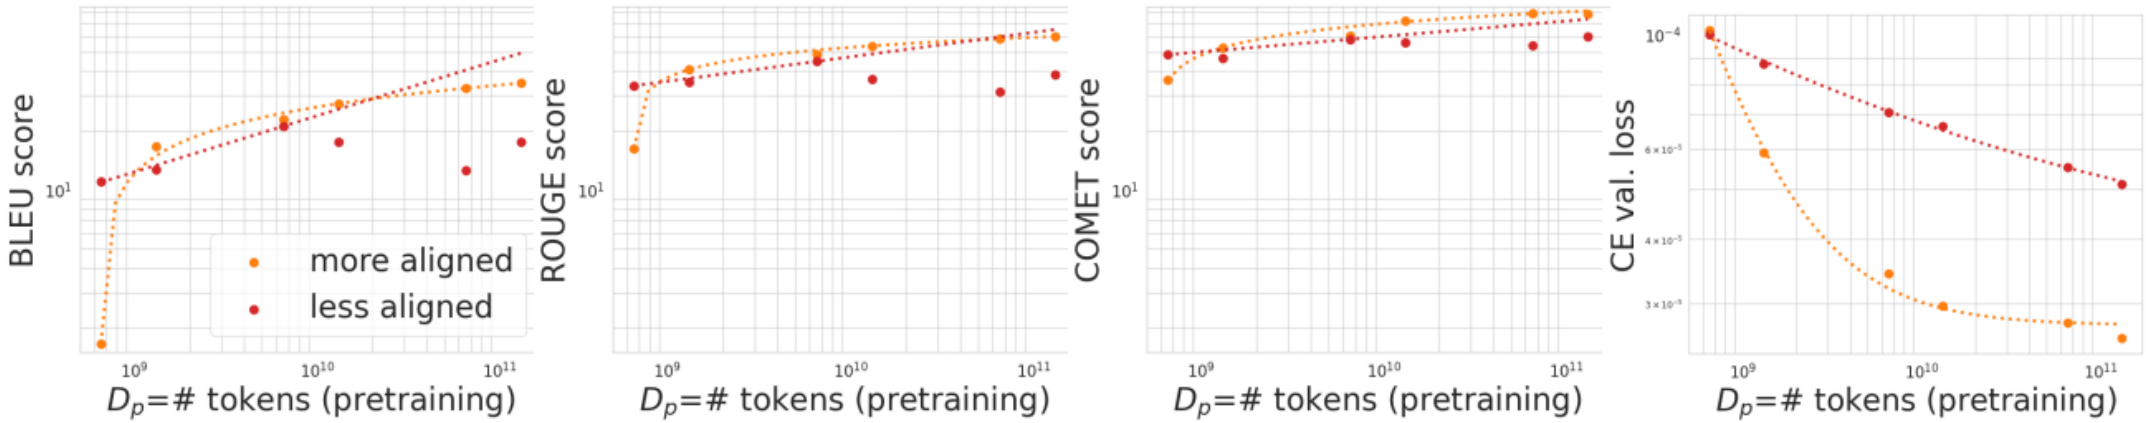


Figure 1: Scaling behavior of BLEU, ROUGE, COMET, and cross-entropy when the pretraining and downstream data are aligned with $\mathcal{A} = 1$ (orange) and $\mathcal{A} = 0.7$ (red). Task: en-to-fr translation.

機械翻訳タスクによる検証結果：事前学習データ(*1)と下流タスクデータ(*2)の分布間の距離(*3)がアラインしている場合は、事前学習データ量と下流タスクの評価値の間にスケール則が成立する。

(*1) MC4 (Multilingual C4) （*2）機械翻訳タスク (*3) Embedding 空間での分布距離を計測

[69] Isik+. Scaling Laws for Downstream Task Performance in Machine Translation. 2024より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

ここまでのまとめ｜スケール則の活用方法の大別

予測可能な性能改善により，次のような問いに答えられる.

- 投資の判断｜より計算機に投資するか？

- 効率的なモデル選択｜パラメータを増やしたときにどちらが良いモデル？

- 効率的な計算資源の利用｜トークンとパラメータのどちらを増やすべき？
  - Chinchilla Optimal: 最適トークン数 = 20 * パラメータ数
  - 推論コストを考えると最適トークン数の係数は変化する

- 下流タスクにスケール則が必ず成立するとは限らない（線形になるとは限らない）

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

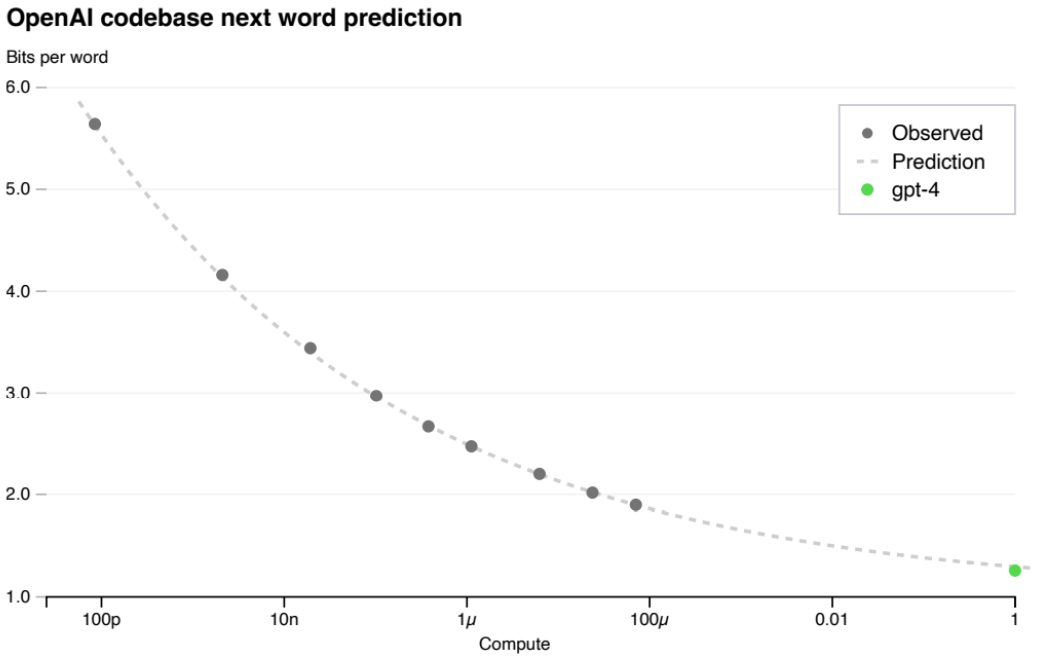
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

目次

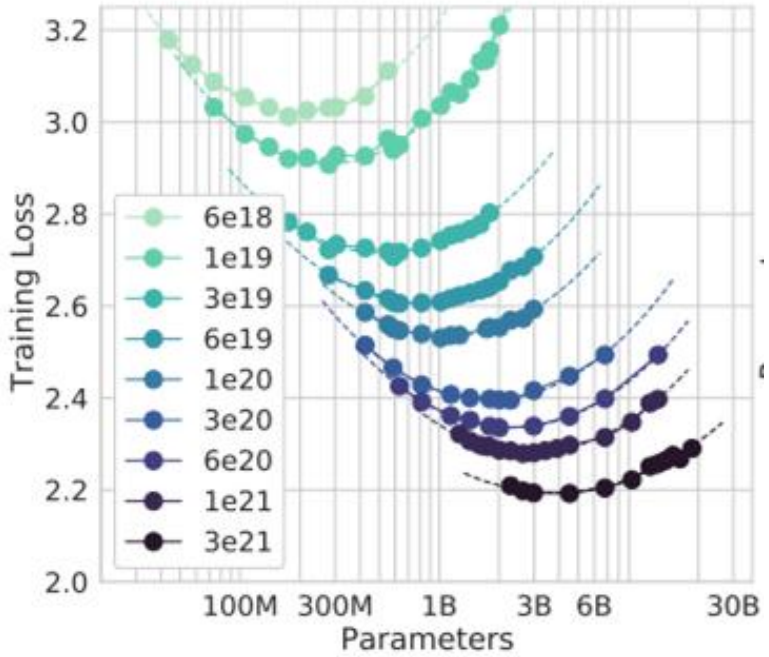
- スケール則とはなにか
- スケール則の使い方
- **スケール則の具体的な求め方**
- 新たなトレンド：推論時のスケーリング

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

スケール則の測り方



“GPT-4 Technical Report” [13]



[42] Hoffmann+. Training Compute-Optimal Large Language Models. 2022より引用

基本的には（比較的）小さないくつかの条件で実験してFittingする

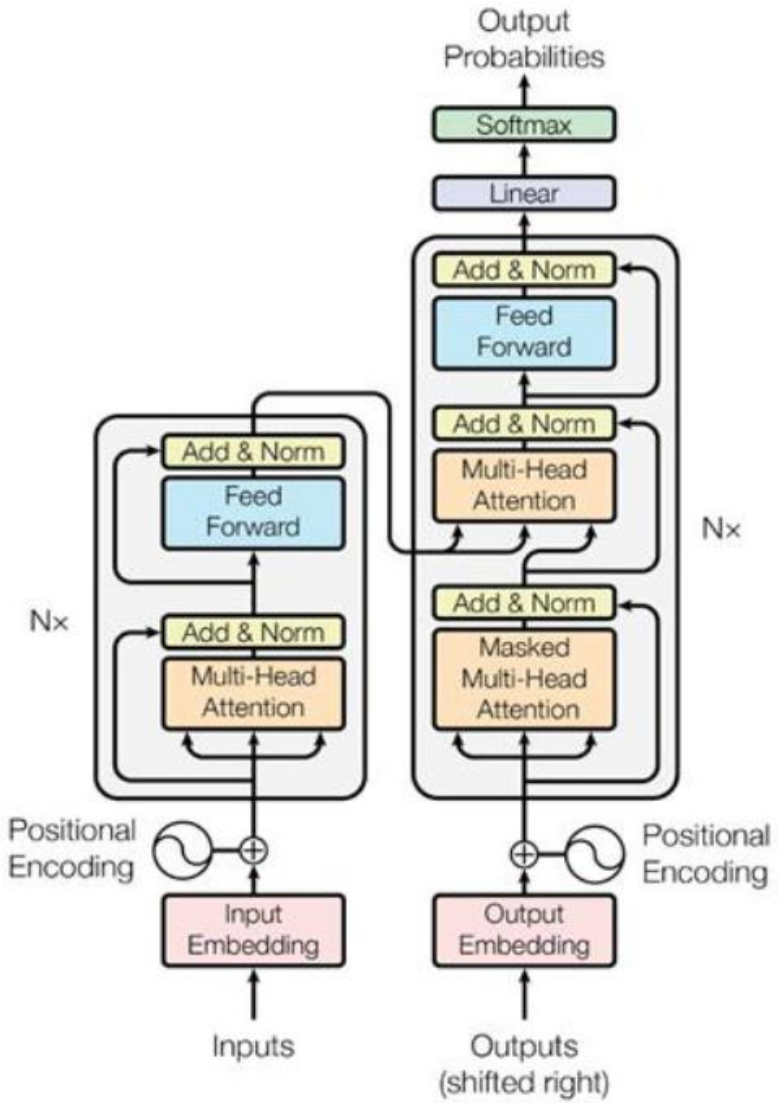
Q. モデルサイズはどう変える？

Q. 学習率などのハイパーパラメータはどう設定する？

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Q1. モデルサイズはどう変化させるのか？



- 層数を増やす
- 埋め込み次元を上げる
- FFNの中間層の次元を大きくする
- ヘッド数を増やす
- Etc…

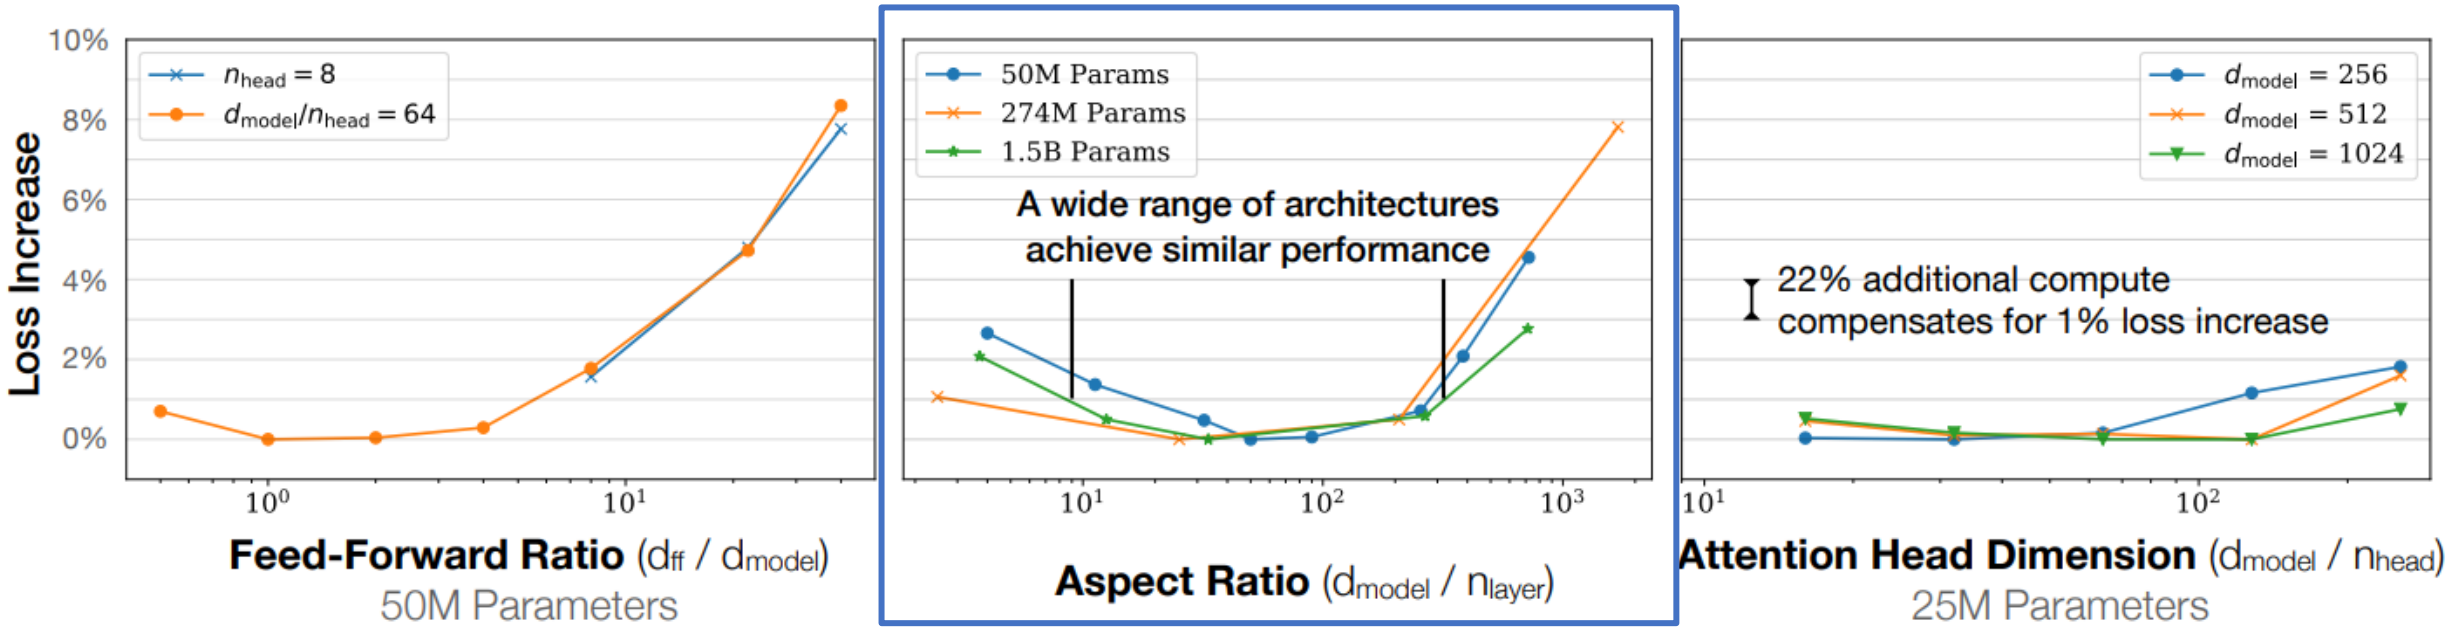
- どれをどのくらいやる？

[65] Vaswani+. Attention Is All You Need. 2017より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

モデルサイズはどう変化させるのか？



元の論文ではパラメータ数を固定したときにネットワークのいくつかの要素をいじって検討している => 結果あんまり大きくは影響ないとの結論

例：**アスペクト比**：埋め込みサイズ / 層数　＊横と縦の比率というイメージ

[3] Kaplan+. Scaling Laws for Neural Language Models. 2020より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

実例１｜Llama 3

	8B	70B	405B
Layers	32	80	126
Model Dimension	4,096	8192	16,384
FFN Dimension	14,336	28,672	53,248
Attention Heads	32	64	128
Key/Value Heads	8	8	8
Peak Learning Rate	3×10^{-4}	1.5×10^{-4}	8×10^{-5}
Activation Function	SwiGLU		
Vocabulary Size	128,000		
Positional Embeddings	RoPE ($\theta = 500,000$)		

[66] AI@Meta+. The Llama 3 Herd of Models. 2024より引用

アスペクト比はそれぞれ128, 102.4 130

Model vs. FFN Dimensionはすべて3.5

ヘッド数もModel Dimensionに対して同様にスケール

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

実例2 | Cerebras GPT

Parameters	Model Dimensions d_{model}	n_{layers}	d_{head}	d_{ffn}	Total tokens	Batch Size (tokens)	Learning Rate (LR)	LR Decay Type
111M	768	10	64	3072	2.2B	246K	6.0E-04	Linear
256M	1088	14	64	4352	5.1B	541K	6.0E-04	Linear
590M	1536	18	128	6144	11.8B	541K	2.0E-04	Linear
1.3B	2048	24	128	8192	26.3B	1.08M	2.0E-04	Cosine
2.7B	2560	32	80	10240	53.0B	1.08M	2.0E-04	Cosine
6.7B	4096	32	128	16384	133.2B	2.13M	1.2E-04	Linear
13B	5120	40	128	20480	257.1B	1.47M→2.21M	1.2E-04	Cosine

[51] Dey+. Cerebras-GPT: Open Compute-Optimal Language Models Trained on the Cerebras Wafer-Scale Cluster. 2023より引用

アスペクト比はそれぞれ76.8, 77.7, 85.3, 85.3 …

Model vs. FFN Dimensionはすべて4.0

ヘッド数はやや不規則に変化

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Q2. ハイパーパラメータをどう変化させるか？

!!!!?

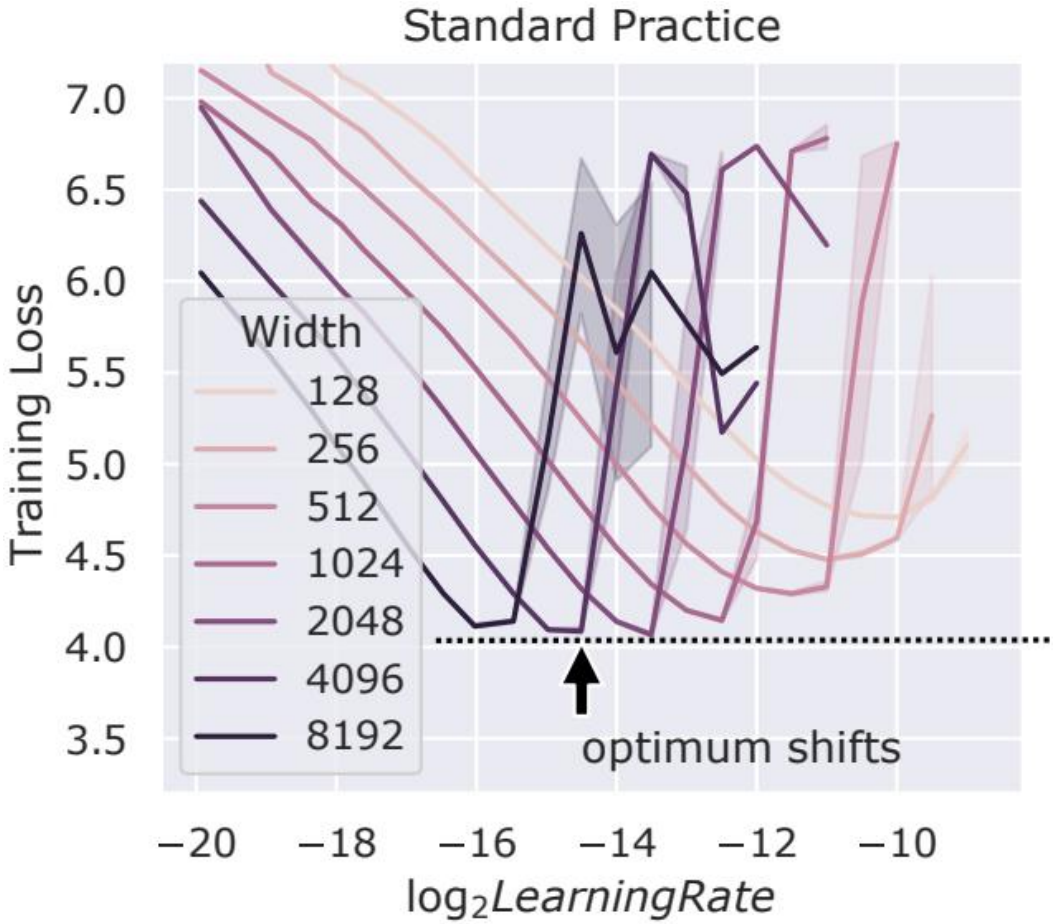
Parameters	Model Dimensions d_{model}	n_{layers}	d_{head}	d_{ffn}	Total tokens	Batch Size (tokens)	Learning Rate (LR)	LR Decay Type
111M	768	10	64	3072	2.2B	246K	6.0E-04	Linear
256M	1088	14	64	4352	5.1B	541K	6.0E-04	Linear
590M	1536	18	128	6144	11.8B	541K	2.0E-04	Linear
1.3B	2048	24	128	8192	26.3B	1.08M	2.0E-04	Cosine
2.7B	2560	32	80	10240	53.0B	1.08M	2.0E-04	Cosine
6.7B	4096	32	128	16384	133.2B	2.13M	1.2E-04	Linear
13B	5120	40	128	20480	257.1B	1.47M→2.21M	1.2E-04	Cosine

[51] Dey+. Cerebras-GPT: Open Compute-Optimal Language Models Trained on the Cerebras Wafer-Scale Cluster. 2023より引用

学習率やスケジューリングがバラバラ
モデルパラメータサイズが大きいほど、学習率は徐々に小さく，バッチサイズは大きくする傾向がある。

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

通常の初期化の場合，最適なハイパラは変動する



- 幅を変化させたときの最適な学習率のプロット
- 幅によって最適なハイパラは変動する（とは言えある程度傾向はある）

経験則として，モデルサイズを大キックした時に学習率は小さく，バッチサイズは大きくすると良い傾向

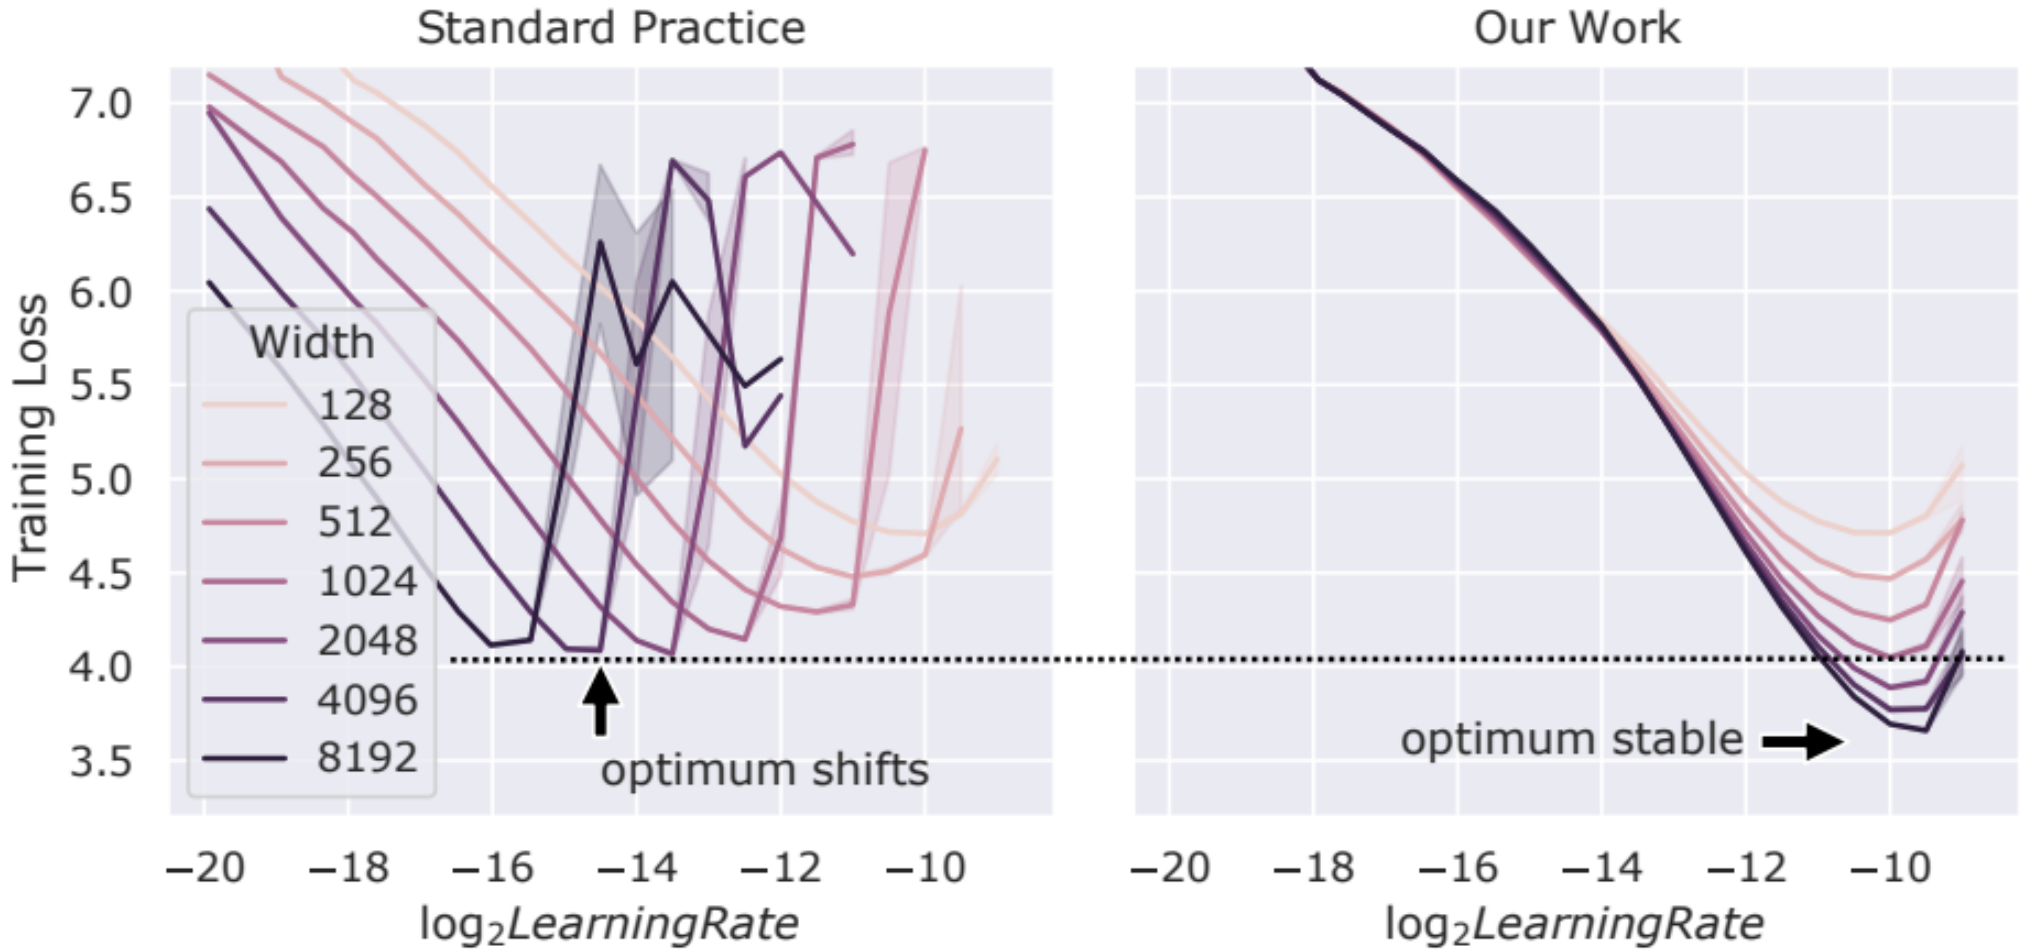
[52] Yang+. Tensor Programs V: Tuning Large Neural Networks via Zero-Shot Hyperparameter Transfer. 2022より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

μTransfer：最適なハイパラの転移可能な方法

μTransferを使えば、モデルサイズが異なっても、ほぼ同じくらいlearning rateの値で最適なLossを達成できる



[52] Yang+. Tensor Programs V: Tuning Large Neural Networks via Zero-Shot Hyperparameter Transfer. 2022より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

μTransfer：最適なハイパラの転移可能な方法

ウェイトの初期化方法と、weightごとのLearning rateの設定方法を以下のように変更する（赤文字）

	Input weights & all biases	Output weights	Hidden weights
Init. Var.	$1/\text{fan_in}$	$1/\text{fan_in}^2$ $(1/\text{fan_in})$	$1/\text{fan_in}$
SGD LR	fan_out (1)	$1/\text{fan_in}$ (1)	1
Adam LR	1	$1/\text{fan_in}$ (1)	$1/\text{fan_in}$ (1)

μTransferable	Not μTransferable	μTransferred *Across*
optimization related, init, parameter multipliers, etc	regularization (dropout, weight decay, etc)	width, depth*, batch size*, training time*, seq length*

[52] Yang+. Tensor Programs V: Tuning Large Neural Networks via Zero-Shot Hyperparameter Transfer. 2022より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

事例｜Cerebras GPT + µTransfer

普通のパラメタ設定

Parameters	Model Dimensions d_{model}	n_{layers}	d_{head}	d_{ffn}	Total tokens	Batch Size (tokens)	Learning Rate (LR)	LR Decay Type
111M	768	10	64	3072	2.2B	246K	6.0E-04	Linear
256M	1088	14	64	4352	5.1B	541K	6.0E-04	Linear
590M	1536	18	128	6144	11.8B	541K	2.0E-04	Linear
1.3B	2048	24	128	8192	26.3B	1.08M	2.0E-04	Cosine
2.7B	2560	32	80	10240	53.0B	1.08M	2.0E-04	Cosine
6.7B	4096	32	128	16384	133.2B	2.13M	1.2E-04	Linear
13B	5120	40	128	20480	257.1B	1.47M→2.21M	1.2E-04	Cosine
111M + µP	768	10	64	3072	2.2B	246K	6.0E-03	Linear
256M + µP	1088	14	64	4352	5.1B	541K	6.0E-03	Linear
590M + µP	1536	18	128	6144	11.8B	541K	6.0E-03	Linear
1.3B + µP	2048	24	128	8192	26.3B	1.08M	6.0E-03	Linear
2.7B + µP	2560	32	80	10240	53.0B	1.08M	6.0E-03	Linear

µTransferを使う場合

[51] Dey+. Cerebras-GPT: Open Compute-Optimal Language Models Trained on the Cerebras Wafer-Scale Cluster. 2023より引用

つまり、小さいモデルで最適なLearning Rateを見つけ、その値を大きいモデルにゼロショットで転移することができる。

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

ここまでのまとめ｜スケール則の求め方

- スケール則を求めるためには基本的にはいくつかの設定で実験を行いフィッティングすればよい.

- しかし，スケールさせるときにはいくつか問題が発生しうる
  - 問題１. モデルサイズをどうスケールさせる？
    - A. だいたい固定の係数を維持しながらスケールする
  - 問題２. モデルサイズをスケールさせるときにハイパラはどう変える？
    - A. 論文によるが，大体学習率は徐々に小さく，バッチサイズは大きくする．μTransferという方法もある.

- スケール則の詳細に更に興味ある方は下記を参照
  - [62] Tatsunori Hashimoto, Percy Liang. CS336: Language Modeling from Scratch. Stanford University. 2024

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

目次

- スケール則とはなにか
- スケール則の使い方
- スケール則の具体的な求め方
- **新たなトレンド：推論時のスケーリング**

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Motivation

問１：「バナナの色は何色ですか？」

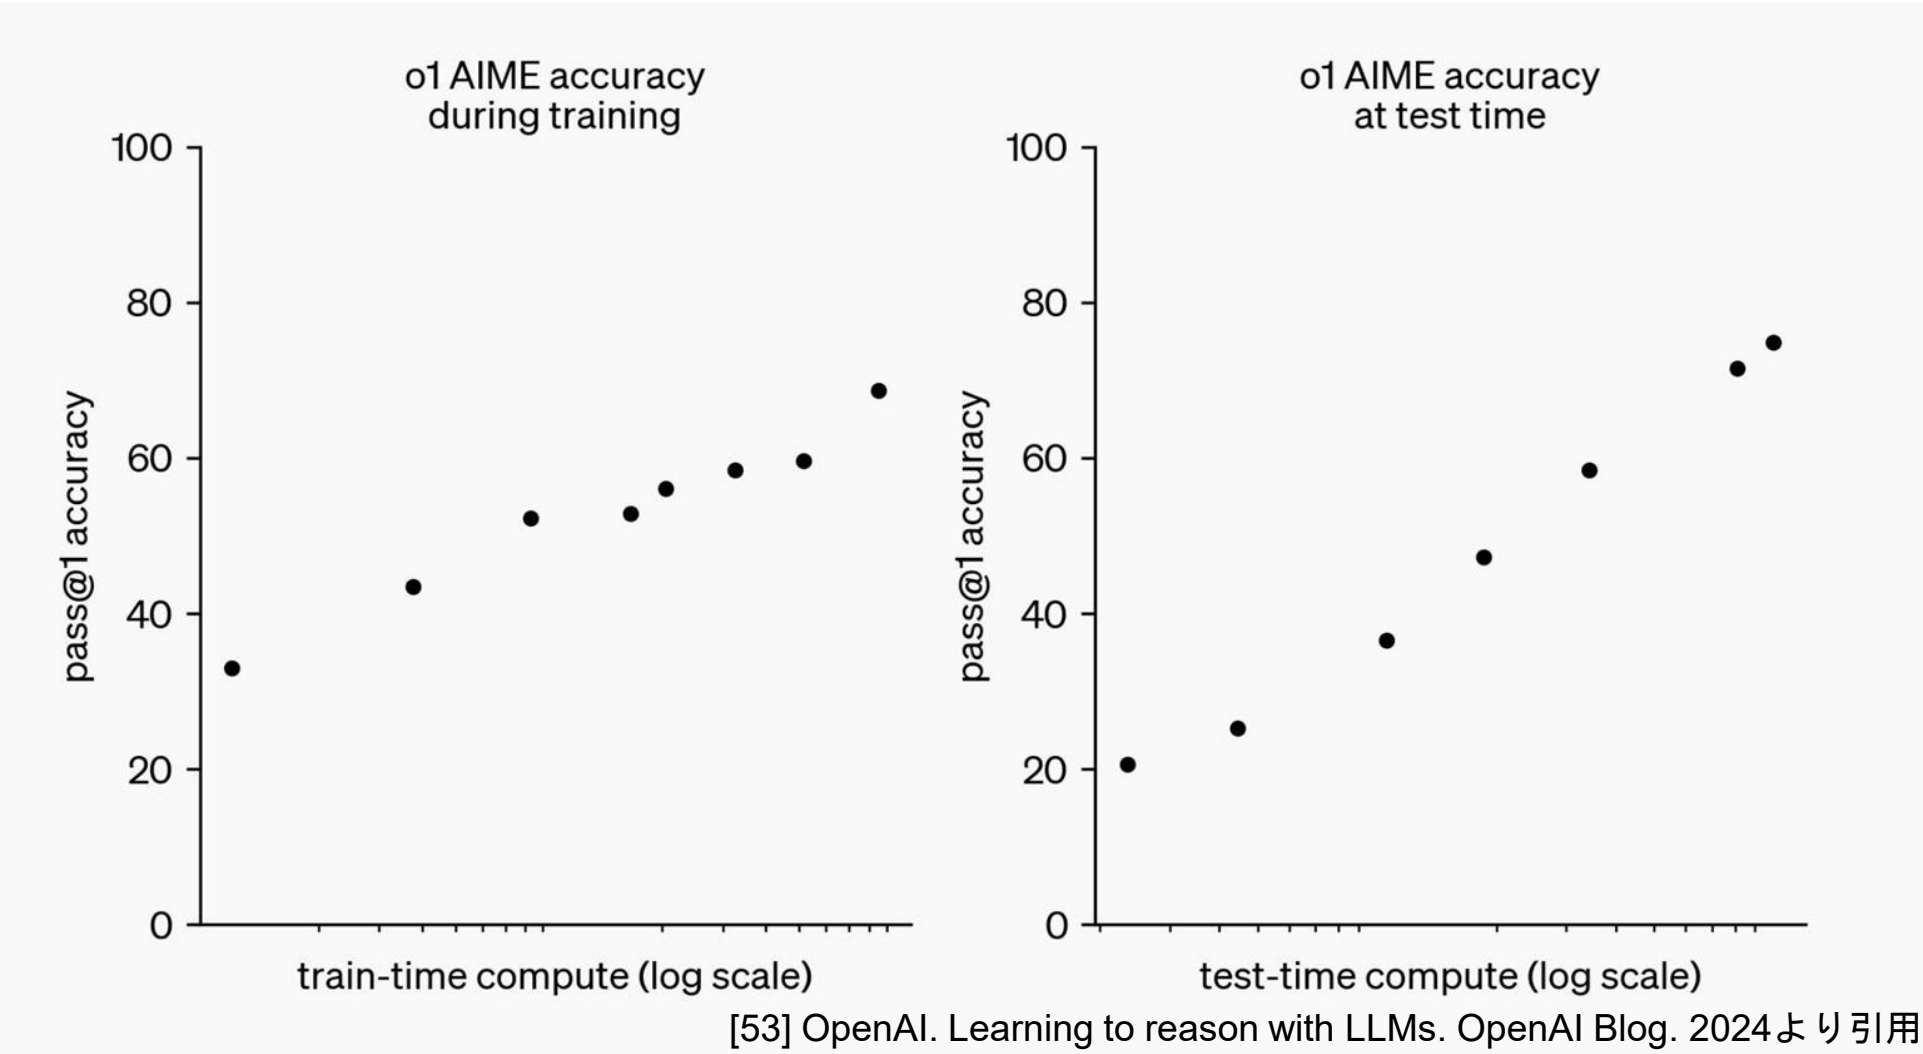
問２：「スケール則の問題は何だと思いますか？」

２つの問いは，必要な思考のプロセスは明らかに異なると思える.
後者は推論時により負荷がかかる.
Q. このような仕組みをLLMでどう実現できるか？
Q. このような仕組みはLLMで効果的か？

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Q. このような仕組みはLLMで効果的か？ A. Yes

- OpenAIが発表したo1もテスト時の推論をスケーリングさせることで性能向上を報告

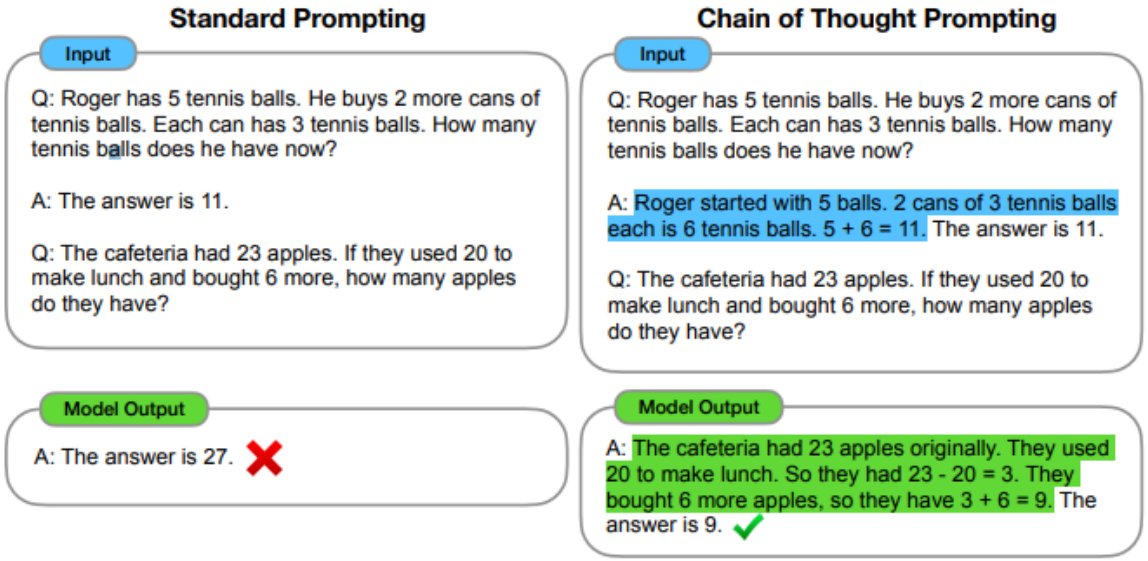


[53] OpenAI. Learning to reason with LLMs. OpenAI Blog. 2024より引用

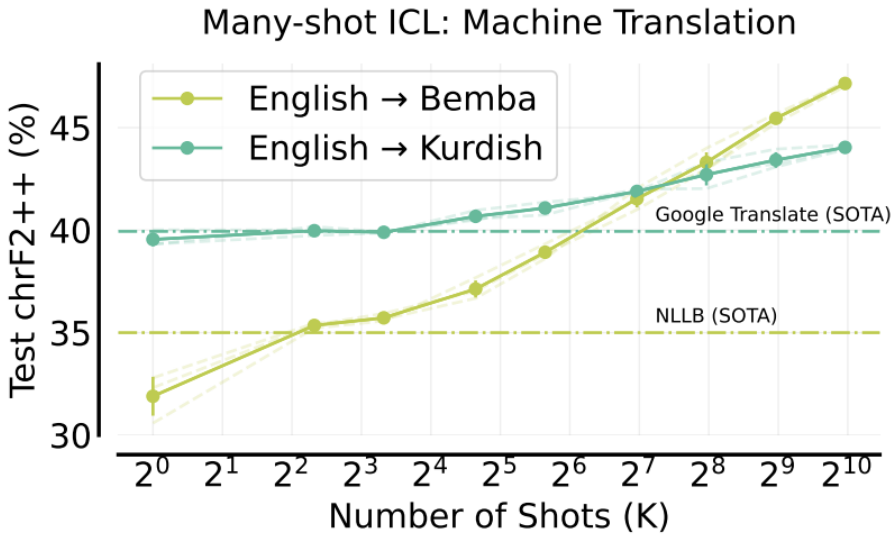
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

（Day 2振り返り）推論時に計算量をスケールさせる方法の例

Chain-of-Thought Prompting



Many-Shot ICL



Promptingにより推論時のトークン数を増やすことで推論時の計算量をスケールさせる試み

[67] Wei+. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. 2022より引用
[68] Agarwal+. Many-Shot In-Context Learning. 2024より引用

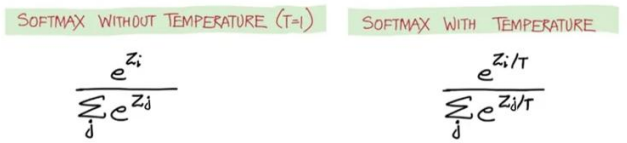
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

（Day 2,3 振り返り）推論時に計算量をスケールさせる方法の例

- **Decodingを複雑にする**
  - 事前学習済みLLMを使って, テキストを出力（デコード）する.
  - デコードには様々な方式が存在する.
    - Greedy Decoding
    - Beam Search
    - Random Sampling
      - Top K / Top P Sampling

評価

- デコード方式③：Random Sampling
  - 次のトークンの生起確率分布に従い, ランダムに選択する.
    - Top_p: 上位p%のトークンから選択する. (例) 0.9
    - Top_k: 上位k個のトークンから選択する. (例) 10
    - Temperature: 0以上の実数(スカラー値). Softmax手前のLogitの分母にかける. Temperature = 1だと普通のSoftmaxと同じ.



Harshit Sharma (2022), "Softmax Temperature" より引用し,一部改変



[38] cohere, Temperature より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

様々なデコーディング方法

- デコード方式の一覧
  - 様々な方式が提案されている

Method	Purpose	Adapter	Extrinsic
Ancestral sampling	$y \sim p_\theta$	–	–
Temperature sampling	$y \sim q(p_\theta)$	Rescale	–
Greedy decoding	$y \leftarrow \max p_\theta$	Argmax (temperature$\rightarrow 0$)	–
Top-k sampling	$y \sim q(p_\theta)$	Truncation (top-k)	–
Nucleus sampling	$y \sim q(p_\theta)$	Truncation (cumulative prob.)	–
Typical sampling	$y \sim q(p_\theta)$	Truncation (entropy)	–
Epsilon sampling	$y \sim q(p_\theta)$	Truncation (probability)	–
η sampling	$y \sim q(p_\theta)$	Truncation (prob. and entropy)	–
Mirostat decoding	Target perplexity	Truncation (adaptive top-k)	–
Basis-aware sampling	$y \sim q(p_\theta)$	Truncation (linear program)	LP Solver
Contrastive decoding	$y \sim q(p_\theta)$	$\log p_{\theta'} - \log p_\theta$ and truncation	Model $p_{\theta'}$
DExperts	$y \sim q_*(\cdot\|x, c)$	$\propto p_\theta \cdot (p_{\theta+}/p_{\theta-})^\alpha$	Models $p_{\theta+}, p_{\theta-}$
Inference-time adaptors	$y \sim q_* \propto R(y)$	$\propto (p_\theta \cdot p_{\theta'})^\alpha$	Model $p_{\theta'}$
Proxy tuning	$y \sim q_*(\cdot\|x, c)$	$\propto p_\theta \cdot (p_{\theta+}/p_{\theta-})^\alpha$	Models $p_{\theta+}, p_{\theta-}$

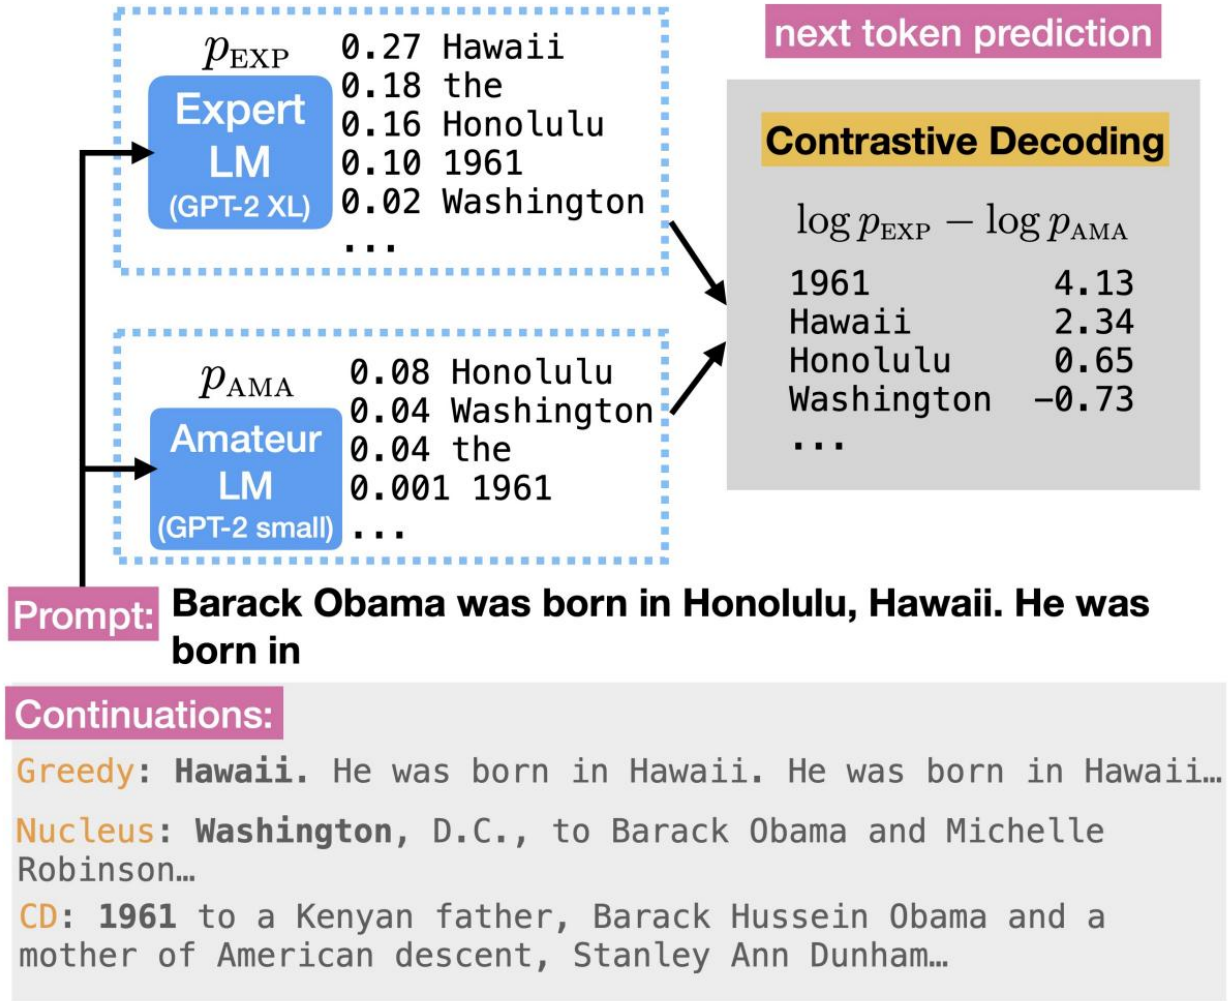
[54] Madaan+. From Decoding to Meta-Generation: Inference-time Algorithms for Large Language Models. 2024より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Contrastive Decoding

- 外部のモデルを使う方法の例
- エキスパートモデルとアマチュアモデルを用いて確率密度比を取ってそこからサンプリングを行う
  - アマチュアモデルには通常エキスとパートモデルよりも少ないパラメータ数のモデルを用いる
- エキスパートモデルの出力をより強調し，アマチュアモデルの出力を減少させるように生成を行う



[55] Li+. Contrastive Decoding: Open-ended Text Generation as Optimization. 2023より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

From Decoding to Meta-Generation

Meta Generationとは？ Token LevelのDecodingだけでなく，文章や段落ごとで生成過程を評価し，生成プロセス全体を最適化する概念

[Submitted on 24 Jun 2024]

From Decoding to Meta-Generation: Inference-time Algorithms for Large Language Models

Sean Welleck, Amanda Bertsch, Matthew Finlayson, Hailey Schoelkopf, Alex Xie, Graham Neubig, Ilia Kulikov, Zaid Harchaoui

1. Generation algorithms
   - Maximization
   - Sampling
   - Controlled generation
2. Meta-generation
   - Programmatic patterns
   - External information
     - Multiple models
     - Tools
     - Environments
3. Efficient generation
   - Optimizing token cost
   - Speeding up generators
   - Speeding up meta-generators

Meta-generator

```
def generate_proof(llm, theorem):
    strategies = [
      "Prove by contradiction.\n",
      "Prove by induction.\n",
    ]
    candidates = [
        llm.generate(strategy + theorem)
        for strategy in strategies
        for sample in range(5)
    ]
    output = llm.generate(
        "Which of the proofs is best?\n"
        + "\n".join(candidates)
    )
    return output
```

Generator

[56] Snell+. Scaling LLM Test-Time Compute Optimally can be More Effective than Scaling Model Parameters. 2024より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Meta-Generationの種類（いずれも推論時に計算量が大きくスケール）

① Parallel search　例：Best-of-N, Self-Consistency

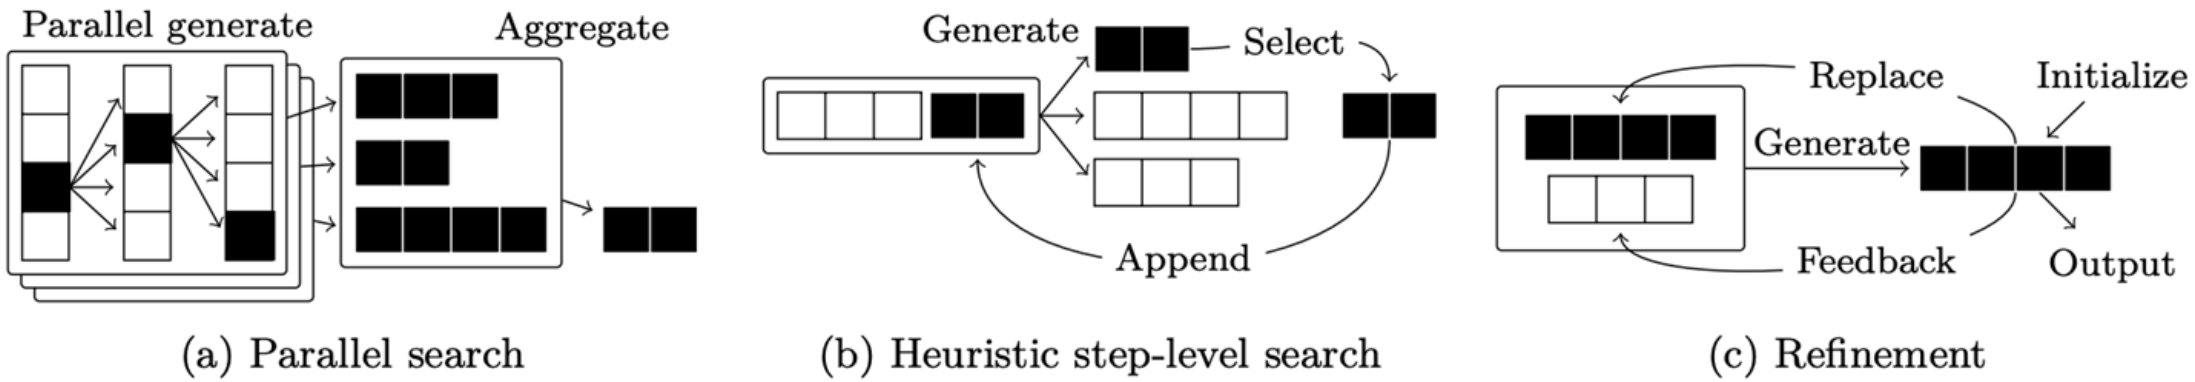
- 並列に複数の候補を生成してスコアリングや多数決などにより生成物を選ぶ

② Step level search　例：Process Reward Model (PRM)

- Stepレベルに評価を行なって生成物を選ぶ

③ Refinement　例：Self-Refine

- 外部/内部のフィードバック結果を用いて，反復的に生成結果を更新する



(a) Parallel search　(b) Heuristic step-level search　(c) Refinement

[54] Madaan+. From Decoding to Meta-Generation: Inference-time Algorithms for Large Language Models. 2024より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

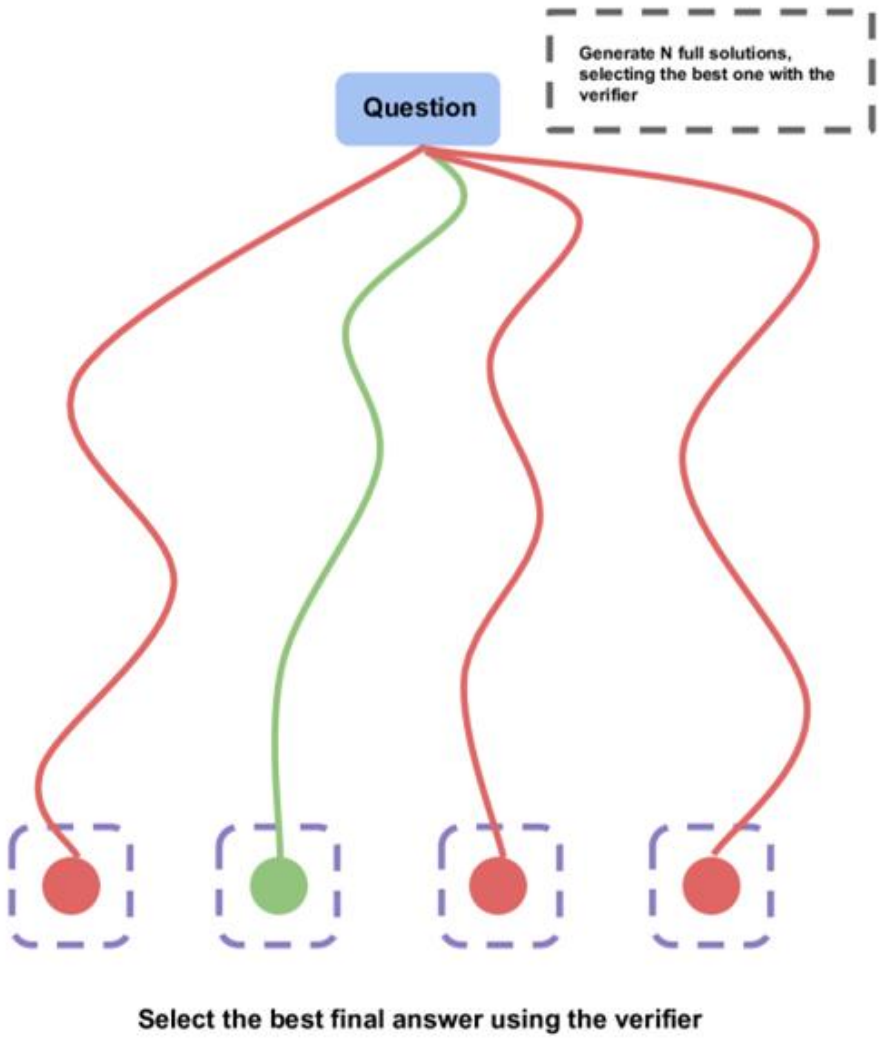
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

① Parallel Searchの方法の例｜Best-of-N

Best-of-N

- N個の回答を出してスコアが一番高いものを選択する

- スコア関数は任意(タスクによって使い分け)
  - 例：LLMのスコアを使う
  - 例：学習した評価器を使う
  - 例：BLUEなど特定の指標を使う



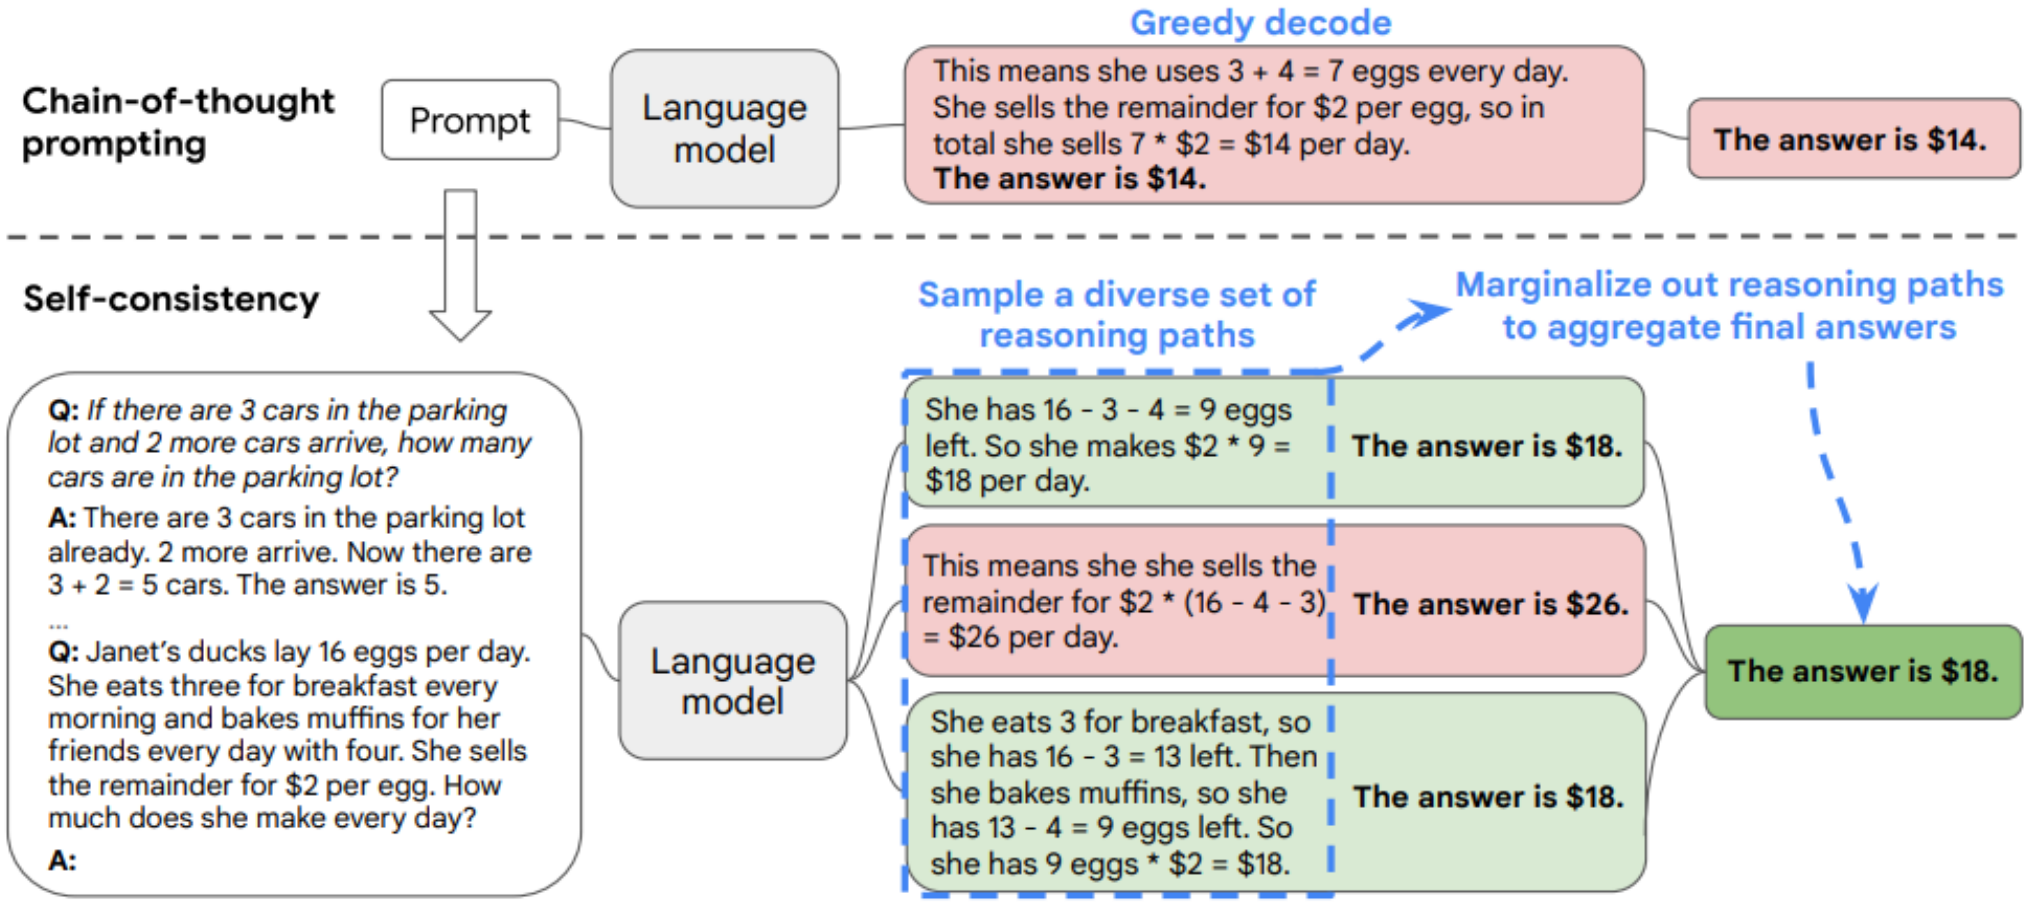
[56] Snell+. Scaling LLM Test-Time Compute Optimally can be More Effective than Scaling Model Parameters. 2024より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

① Parallel Searchの方法の例｜Self-Consistency

Self-Consistency（Day 2のおさらい）

- LMに複数の推論を行わせて（下は3つの例），Majority Voting（多数決）



[58] Wang+. Self-Consistency Improves Chain of Thought Reasoning in Language Models. 2023より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

① Parallel Searchの方法の例｜MBR Decoding

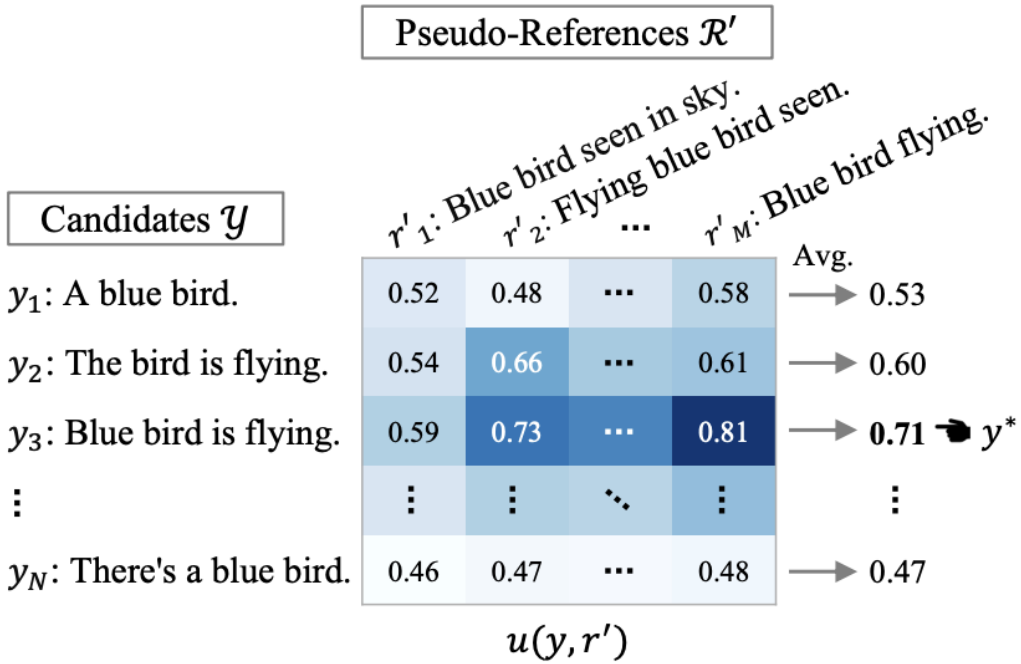
MBR Decoding(Minimum Bayes-Risk Decoding)

- 機械翻訳の際に使用されるデコーディング方法
- 効用関数を用いて出力のクオリティを最大化するようにデコーディング
  - 機械翻訳における効用関数: BLUE, METEOR, BLEURT, COMET
- 詳細が知りたい人は URL

$$y^* = \arg\max_{y \in \mathcal{Y}} \mathbb{E}_{r \sim P_{\text{human}}(\cdot|x)}[u(y, r)].$$

・y：モデルの出力文

- $P_{\text{human}}(\cdot|x)$：人間が生成する文の確率分布
- r：参照文
- u：効用関数



[57] Eikema+. On the True Distribution Approximation of Minimum Bayes-Risk Decoding. 2020より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

① Parallel Searchの他の方法

Aggregation typeやScoringの手法によって様々なアルゴリズムが存在

Algorithm	Aggregation type	Scoring / transforming with
Best-of-N 23	Rerank	LLM score or external score
Noisy-channel 145	Rerank	Log-linear combination score
Majority voting 10	Transform	Empirical vote frequency
Weighted majority voting 190	Transform	Empirical distribution over answers
Self-consistency 194	Transform	Marginal distribution over answers
Universal self-consistency 29	Transform	Answer aggregation using an LLM generator
Branch-Solve-Merge 167	Transform	Answer aggregation using an LLM generator / rule-based parsing
QE-fusion 192	Transform	Answer contains spans from candidates

Table 2: Parallel meta-generators.

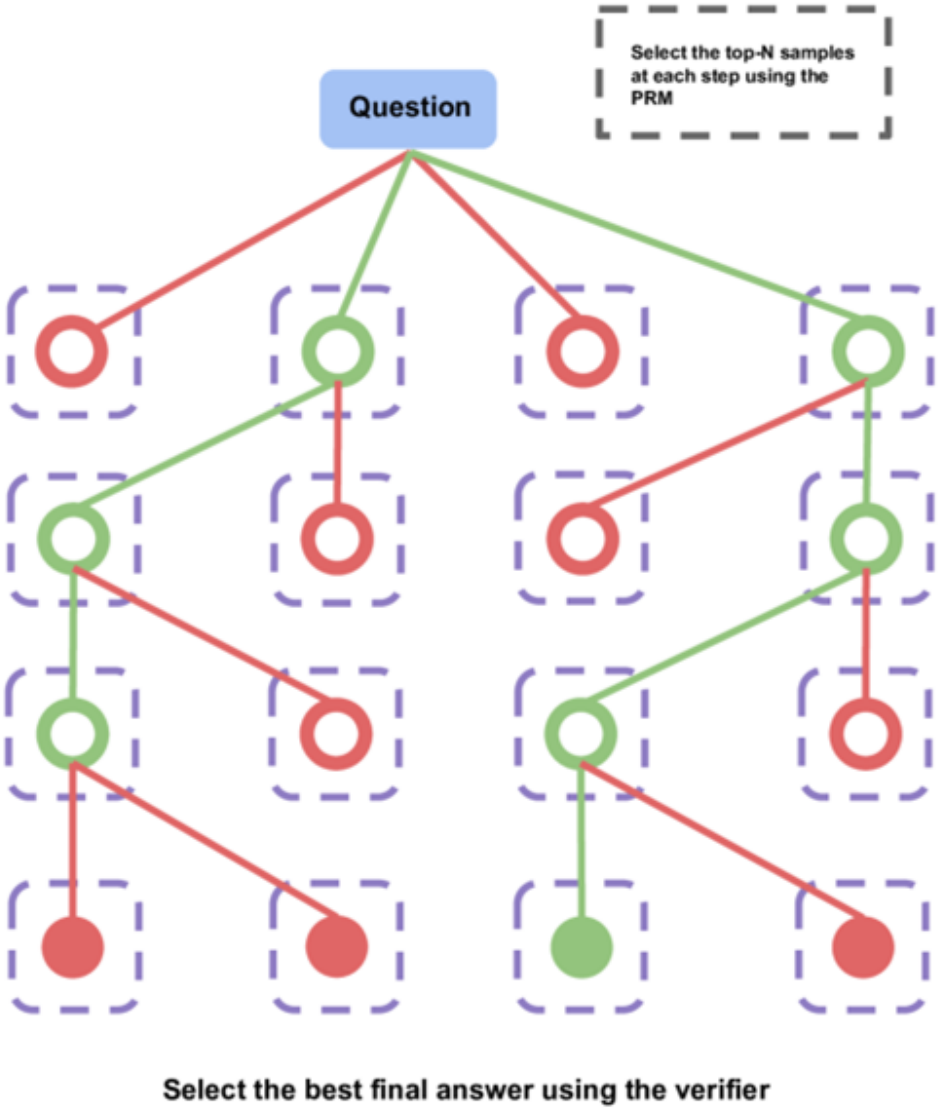
[56] Snell+. Scaling LLM Test-Time Compute Optimally can be More Effective than Scaling Model Parameters. 2024より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

② Step Level Searchの方法の例｜Beam-Search (Step Level)

Beam-Search(Step Level)

- Token LevelのBeam Searchとは異なり，文章や段落単位でサンプリングと評価を行う
- 評価にはPRM(Process Reward Model)を用いて途中結果の評価と選択を行う
- Top-N Samplingによって途中結果を選択



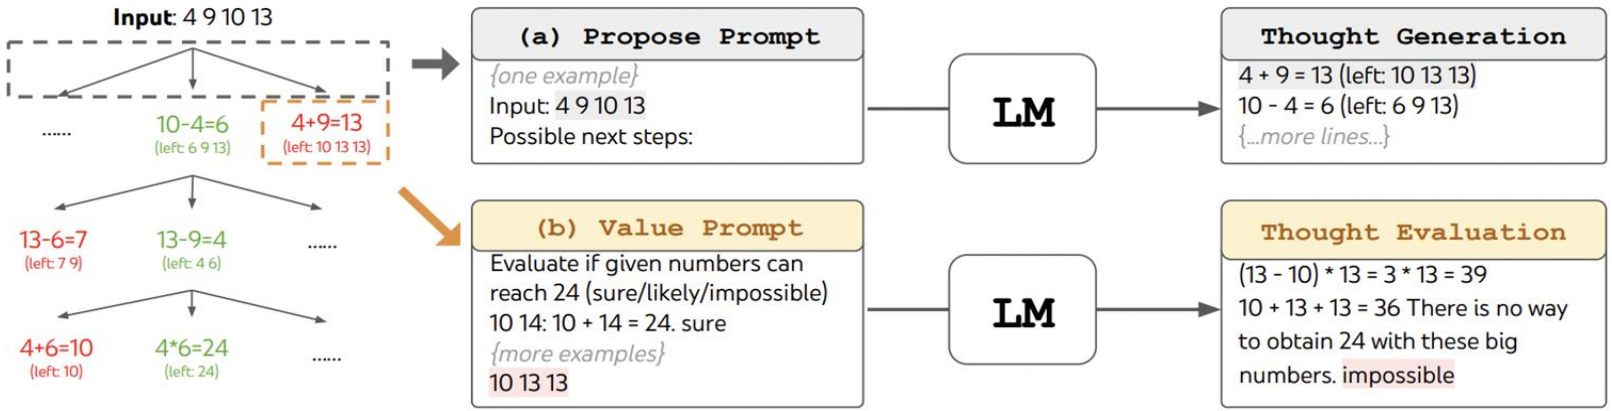
[56] Snell+. Scaling LLM Test-Time Compute Optimally can be More Effective than Scaling Model Parameters. 2024より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

② Step Level Searchの方法の例｜Tree-of-Thought

Tree-of-Thought

- 複数の思考列を一気通貫で出力して評価するSCとは違い，ToTは途中で分岐させる（木探索する）
  - ノードの評価もLMで行う
- Game of 24での例と結果
  - タスク：与えられた4つの数字を四則演算して24を作る
- 戦略的思考が必要なタスクで性能が大幅改善



Method	Success
IO prompt	7.3%
CoT prompt	4.0%
CoT-SC (k=100)	9.0%
ToT (ours) (b=1)	45%
ToT (ours) (b=5)	**74%**

[60] Yao+. Tree of Thoughts: Deliberate Problem Solving with Large Language Models. 2023より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

② Step Level Searchの他の方法

探索方法や検証するステップの違いなどにより様々なアルゴリズムが存在

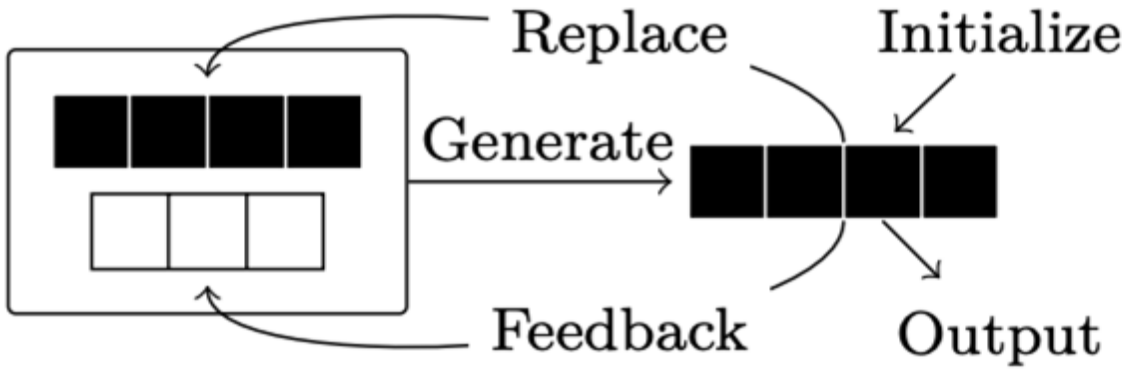
Method	Search	State	Generation	Value $\hat{v}(s_t)$	Tasks
gpt-f proof search [158]	Best-first	Proof-so-far	Proof step	$\log p_\theta$	Formal proving
gpt-f +outcome [158]	Best-first	Proof-so-far	Proof step	$\hat{v}_\phi \approx \mathbb{E}(\texttt{success})$	Formal proving
Proofsize search [159]	Best-first	Proof-so-far	Proof step	$\hat{v}_\phi \approx \mathbb{E}(\texttt{length})$	Formal proving
Stepwise++ [198]	Beam	Proof-so-far	Proof step	$\log p_\theta$ + n-grams	Informal proving
Self-evaluation [203]	Beam	Steps-so-far	Reasoning step	$\log p_\theta$ + LLM	Multi-step correctness
Tree-of-Thought BFS [210]	Beam	Steps-so-far	Generation step	Prompted LLM	Multi-step generation
Tree-of-Thought DFS [210]	DFS	Steps-so-far	Generation step	Prompted LLM	Multi-step generation
Graph-of-Thought [15]	BFS/DFS	Steps-so-far	Generation step	Prompted LLM	Multi-step generation
HyperTree Proof Search [109]	MCTS	Proof-so-far	Proof step	$\hat{v}_\phi \approx \mathbb{E}(\texttt{success})$	Formal proving
AlphaLLM [186]	MCTS	Steps-so-far	Reasoning steps	$\hat{v}_\phi \approx \mathbb{E}(\texttt{correct})$	Multi-step correctness
ThoughtSculpt [34]	MCTS	Steps-so-far	Generation step	Prompted LLM	Multi-step generation

Table 3: Survey of step-level search methods.

[56] Snell+. Scaling LLM Test-Time Compute Optimally can be More Effective than Scaling Model Parameters. 2024より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

③ Refinement



(c) Refinement

[59] Lightman+. Let's Verify Step by Step. 2023より引用

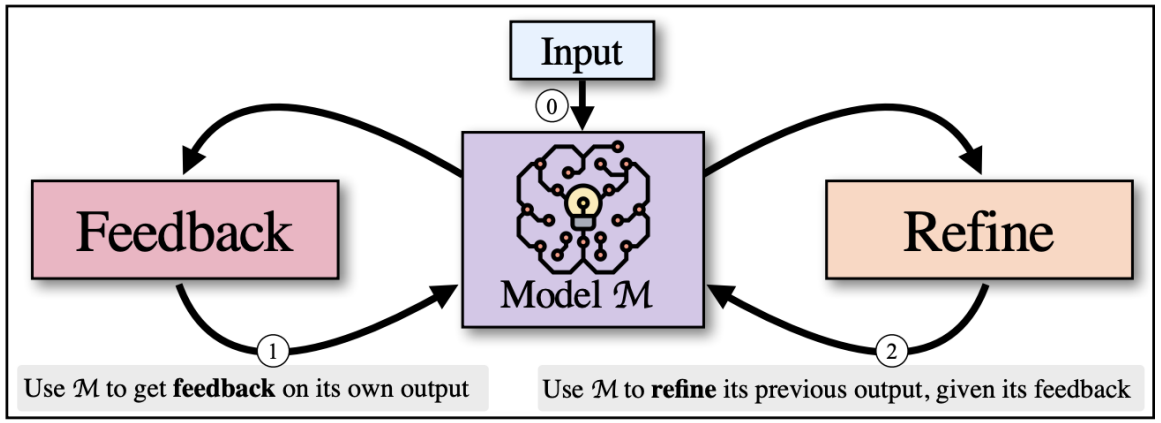
- 一度生成した結果や，その結果に対するフィードバックをもとに再度生成

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

③ Refinementの方法の例 | Self-Refine（Day 2のおさらい）

自分自身を使ってフィードバックを生成して出力を改善



(a) **Dialogue:** x, y_t

```
User: I am interested
in playing Table
tennis.

Response: I'm sure
it's a great way to
socialize, stay active
```

(b) **FEEDBACK** fb

```
Engaging: Provides no
information about table
tennis or how to play it.

User understanding: Lacks
understanding of user's
needs and state of mind.
```

(c) **REFINE** y_{t+1}

```
Response (refined): That's
great to hear (...) ! It's
a fun sport requiring
quick reflexes and good
hand-eye coordination.
Have you played before, or
are you looking to learn?
```

(d) **Code optimization:** x, y_t

```
Generate sum of 1, ..., N
def sum(n):
    res = 0
    for i in range(n+1):
        res += i
    return res
```

(e) **FEEDBACK** fb

```
This code is slow as
it uses brute force.
A better approach is
to use the formula
... (n(n+1))/2.
```

(f) **REFINE** y_{t+1}

```
Code (refined)

def sum_faster(n):
  return (n*(n+1))//2
```

[61] Madaan+. Self-Refine: Iterative Refinement with Self-Feedback. 2023より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

③ Refinementの方法の例 | Self-Refine （Day 2のおさらい）

Task	GPT-3.5 Base	GPT-3.5 +SELF-REFINE	ChatGPT Base	ChatGPT +SELF-REFINE	GPT-4 Base	GPT-4 +SELF-REFINE
Sentiment Reversal	8.8	**30.4** (↑21.6)	11.4	**43.2** (↑31.8)	3.8	**36.2** (↑32.4)
Dialogue Response	36.4	**63.6** (↑27.2)	40.1	**59.9** (↑19.8)	25.4	**74.6** (↑49.2)
Code Optimization	14.8	**23.0** (↑8.2)	23.9	**27.5** (↑3.6)	27.3	**36.0** (↑8.7)
Code Readability	37.4	**51.3** (↑13.9)	27.7	**63.1** (↑35.4)	27.4	**56.2** (↑28.8)
Math Reasoning	**64.1**	**64.1** (0)	74.8	**75.0** (↑0.2)	92.9	**93.1** (↑0.2)
Acronym Generation	41.6	**56.4** (↑14.8)	27.2	**37.2** (↑10.0)	30.4	**56.0** (↑25.6)
Constrained Generation	28.0	**37.0** (↑9.0)	44.0	**67.0** (↑23.0)	15.0	**45.0** (↑30.0)

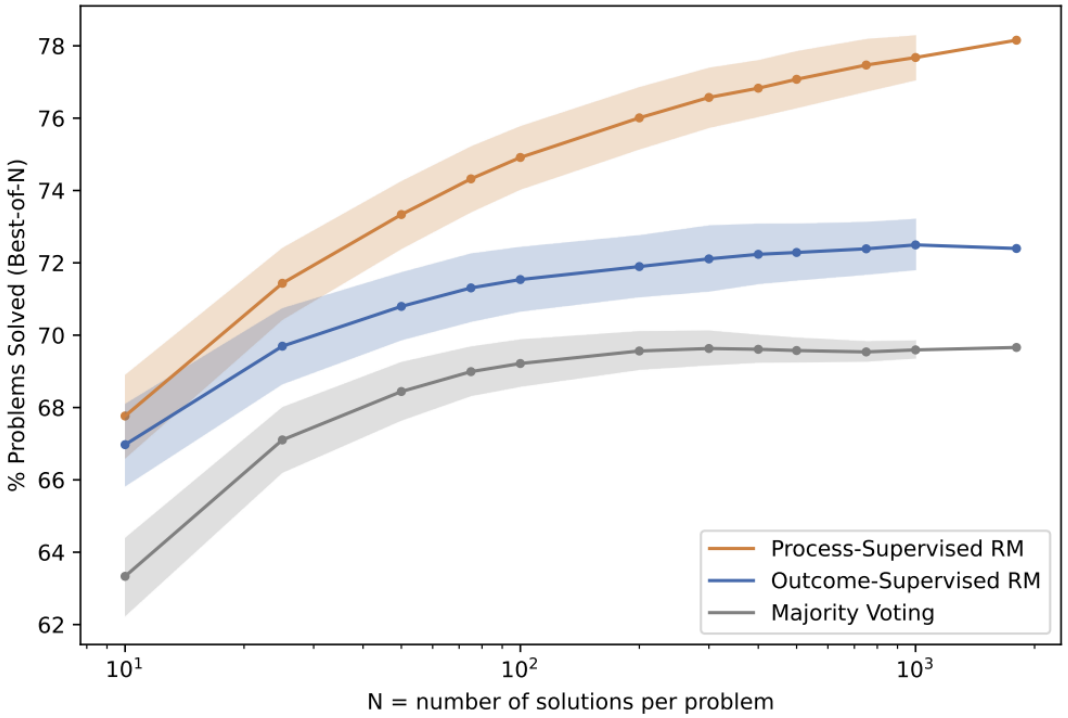
[61] Madaan+. Self-Refine: Iterative Refinement with Self-Feedback. 2023より引用

- 7つのタスクで最大50%近くの精度向上

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Majority Voting vs. Best-of-N (ORM)

	ORM	PRM	Majority Voting
% Solved (Best-of-1860)	72.4	**78.2**	69.6



[59] Lightman+. Let's Verify Step by Step. 2023より引用

Best-of-N (ORM)

- Outcome-supervised Reward Model を使って出力全体を評価

Majority Voting

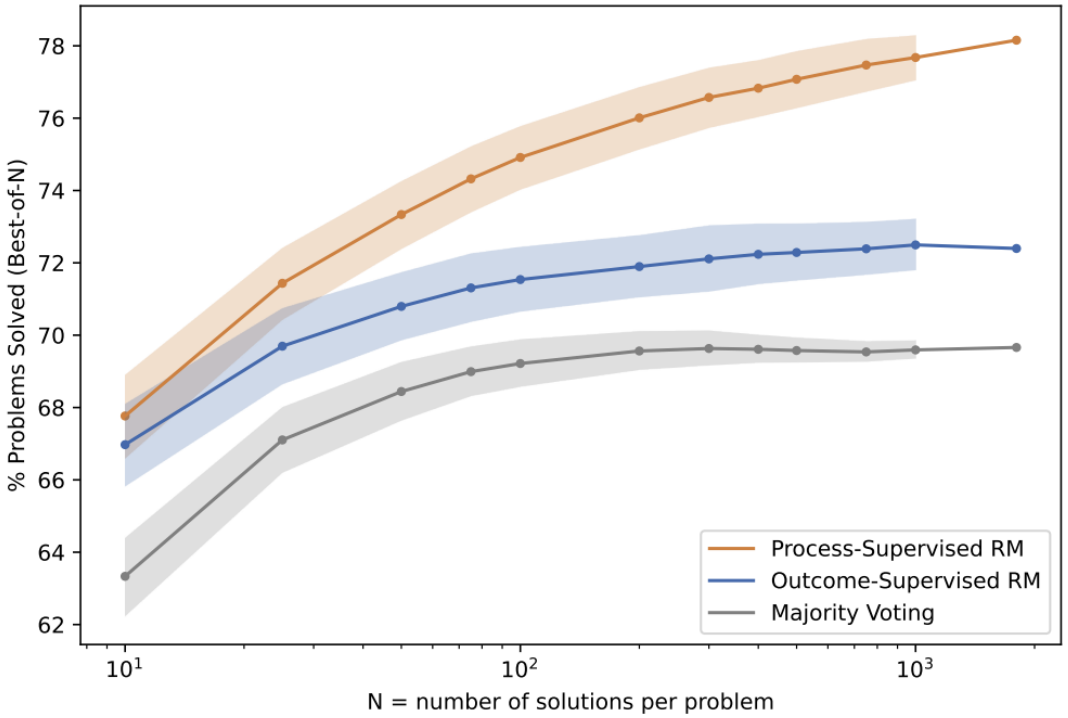
- 多数決して選択

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

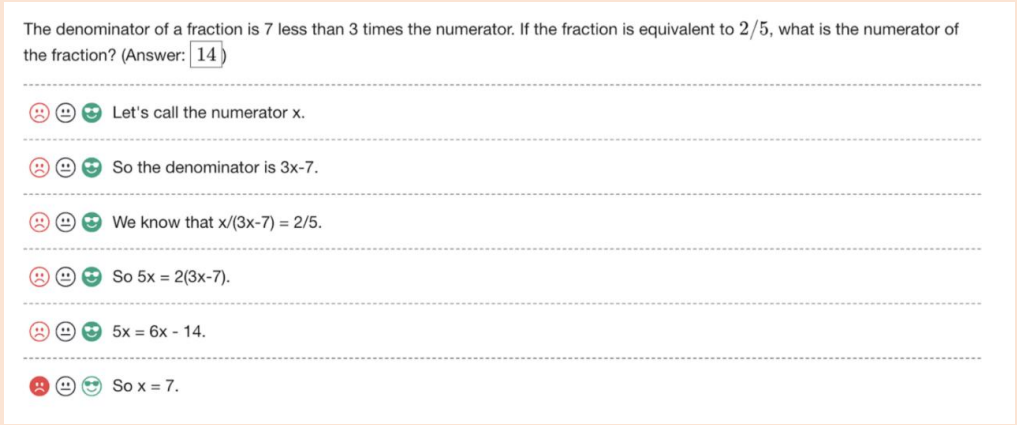
Majority Voting vs. Best-of-N (ORM) vs. Best-of-N (PRM)

	ORM	PRM	Majority Voting
% Solved (Best-of-1860)	72.4	**78.2**	69.6



Best-of-N (PRM)

- Process-supervised Reward Model を利用して途中の仮定を評価



[59] Lightman+. Let's Verify Step by Step. 2023より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Q. 同じ計算資源のとき，パラメータを増やすより有効？

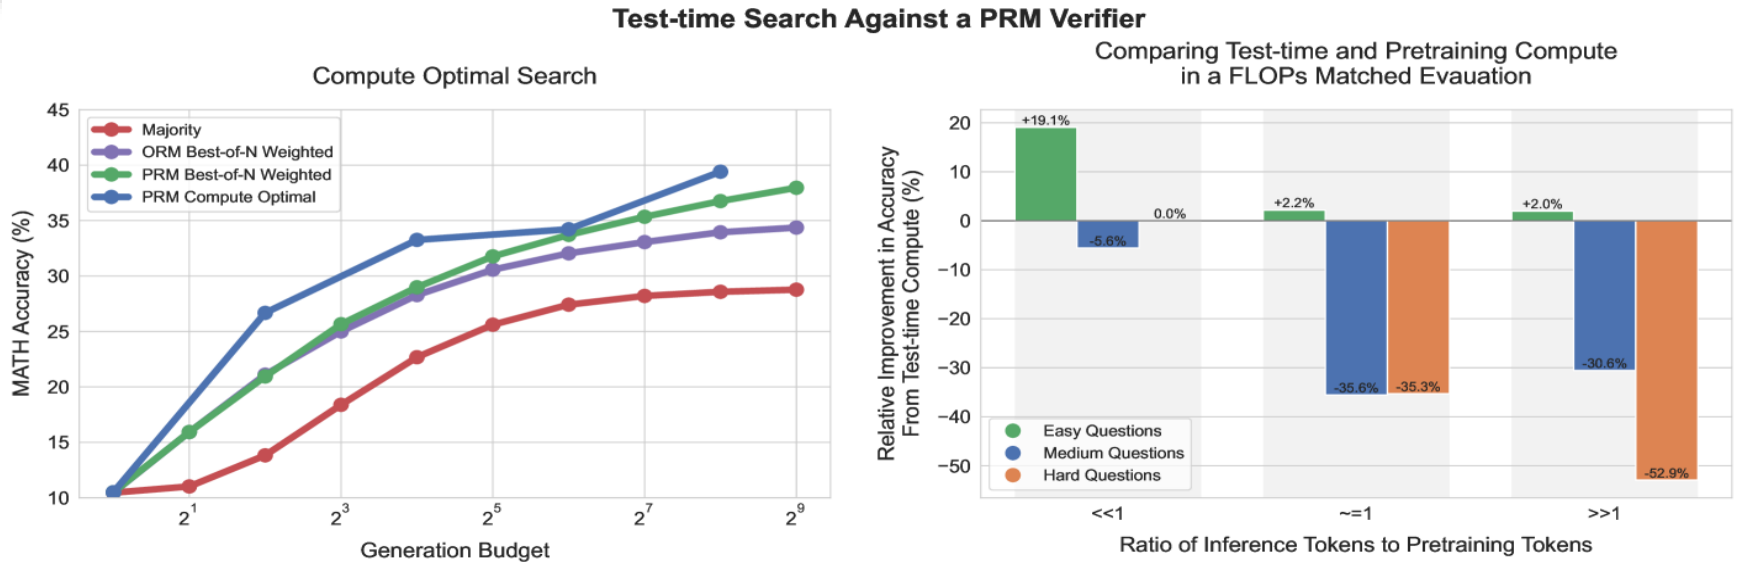
Google DeepMind

2024-8-7

Scaling LLM Test-Time Compute Optimally can be More Effective than Scaling Model Parameters

Charlie Snell[♦, 1], Jaehoon Lee[2], Kelvin Xu[♣, 2] and Aviral Kumar[♣, 2]

[♣]Equal advising, [1]UC Berkeley, [2]Google DeepMind, [♦]Work done during an internship at Google DeepMind



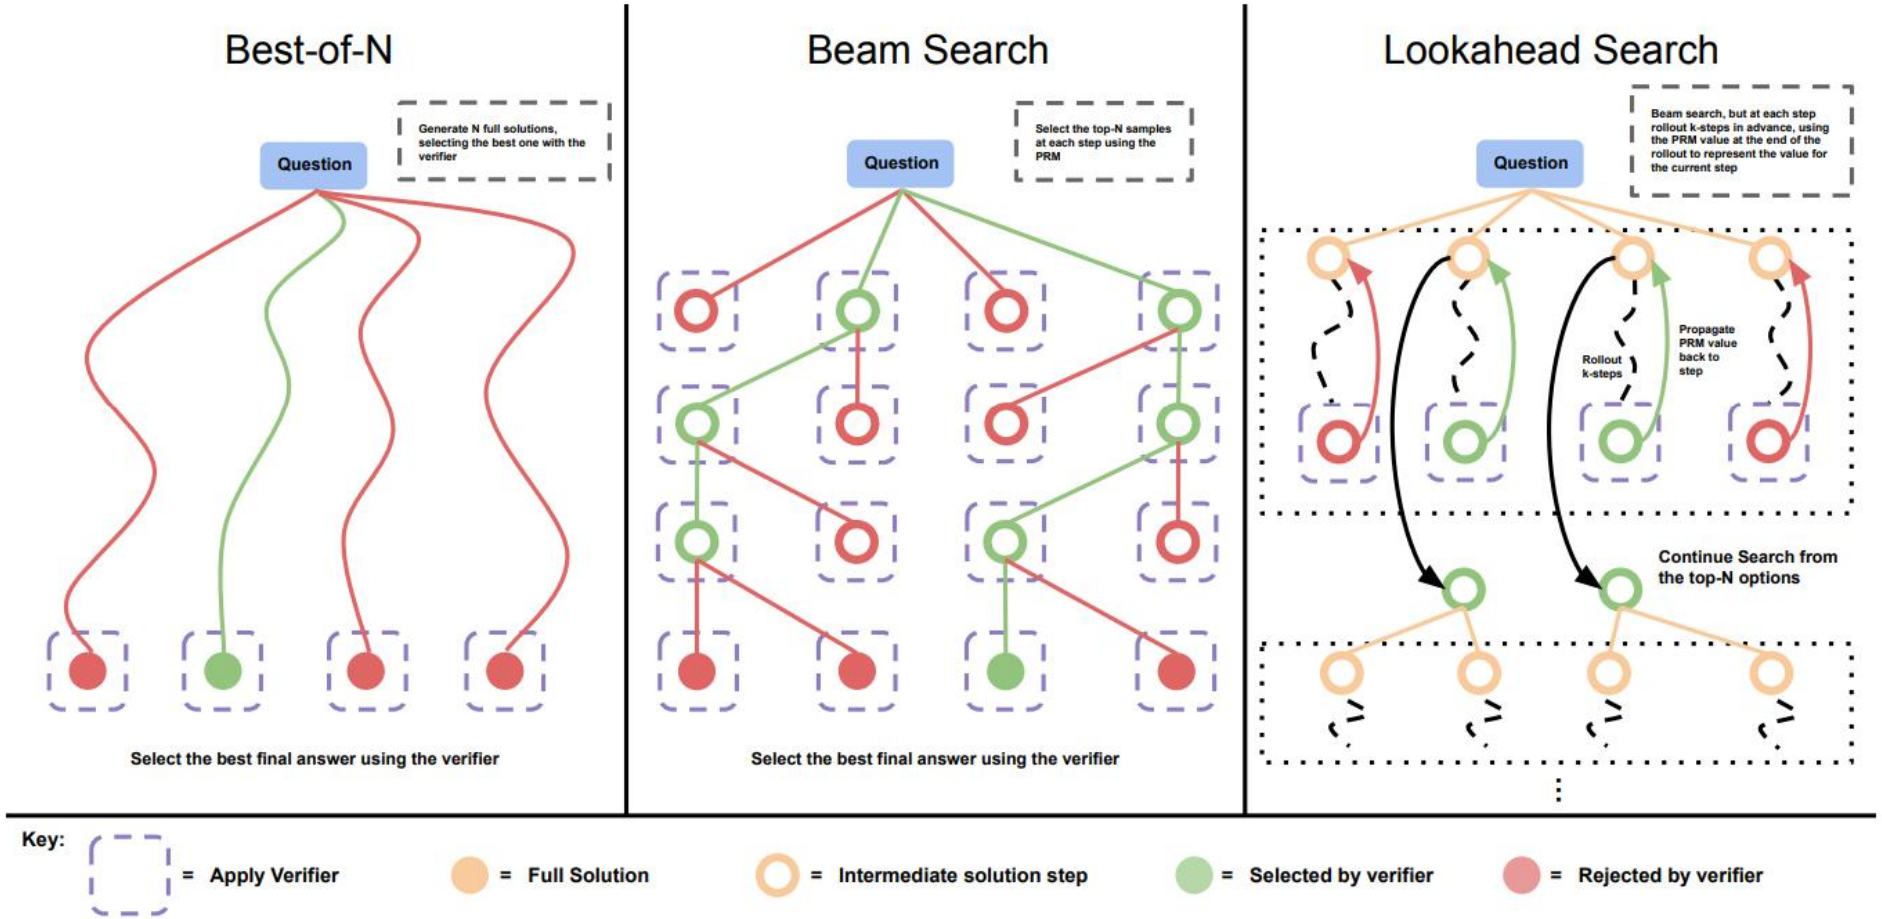
[56] Snell+. Scaling LLM Test-Time Compute Optimally can be More Effective than Scaling Model Parameters. 2024より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Q. 同じ計算資源のとき，パラメータを増やすより有効？

- ランダムサンプリングによる推論回数を増やして、プロセスレベルの報酬モデル (PRM) を用いた推論パス/最終回答の適切な選択をする事で性能が向上.

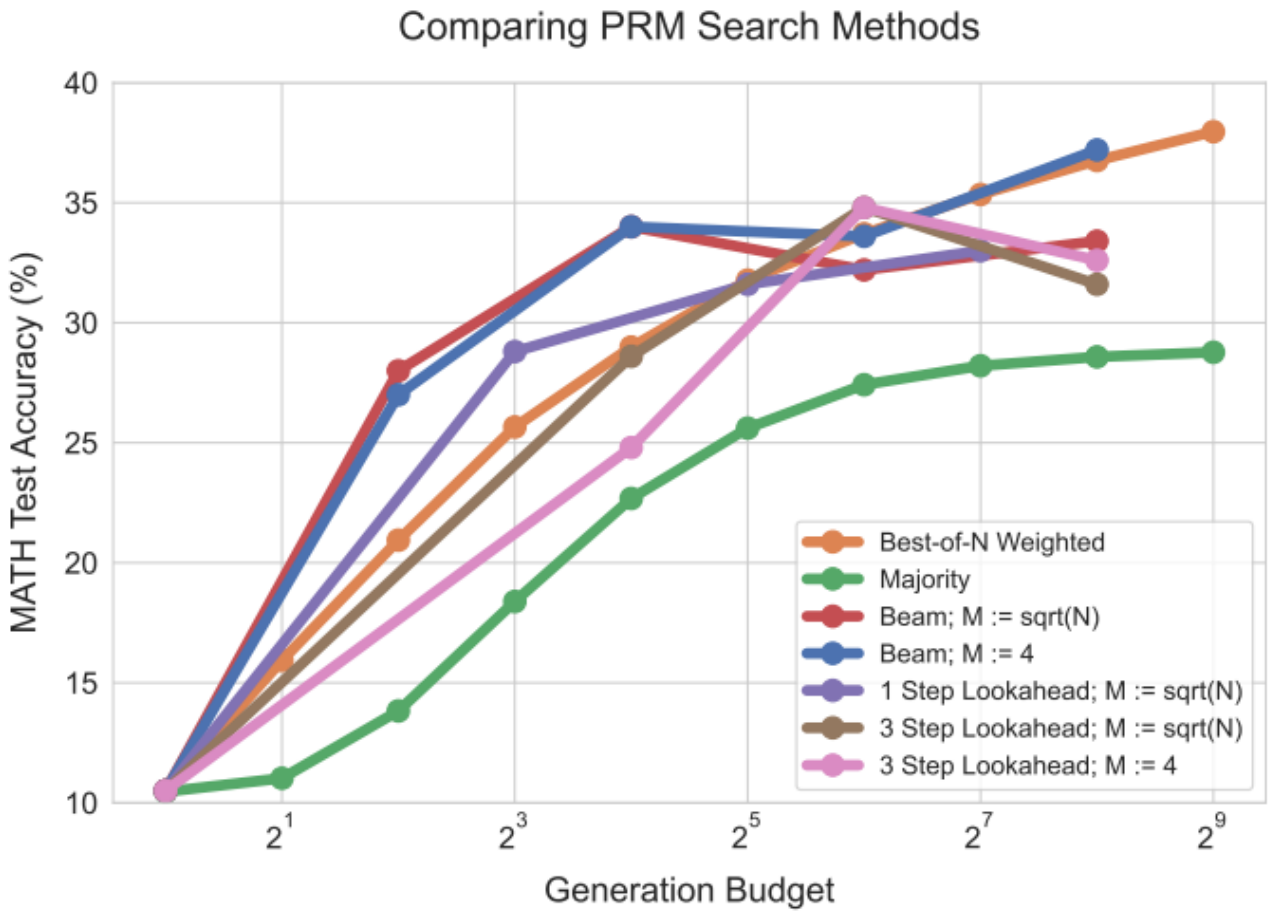


Scaling LLM Test-Time Compute Optimally can be More Effective than Scaling Model Parameters より

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

Q. 同じ計算資源のとき，パラメータを増やすより有効？

- ランダムサンプリングによる推論回数を増やして、プロセスレベルの報酬モデル (PRM) を用いた推論パス/最終回答の適切な選択をする事で性能が向上.



Scaling LLM Test-Time Compute Optimally can be More Effective than Scaling Model Parameters より

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

本日のまとめ

言語モデルのスケール則について紹介しました.

1.スケール則とは何かについて説明しました。
スケール則とは計算資源（C）、データセットサイズ（D)、パラメータ数（N）と誤差（L）の間に成立する経験則；対数グラフ上でほぼ直線の関係が成立する。

2.スケール則の具体的な求め方について説明しました。
スケール則を求めるためには基本的にはいくつかの異なる設定で実験を行いフィッティングする。ハイパラの設定（例：アスペクト比，学習率，バッチサイズ）については様々な知見が論文で発表されている。

3.推論時のスケーリングとはなにかについて説明しました。
訓練時だけでなく，推論時にも計算量をスケールさせることで性能を改善することができる。推論時の工夫：Prompting，Decoding，Meta-Generation

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Reference

[1] Bao Hua Choo. The emergence of Large Language Models (LLMs), The low down. 2023. https://thelowdown.momentum.asia/the-emergence-of-large-language-models-llms/, アクセス日: 2023/11/16

[2] Zhao+. A Survey of Large Language Models. 2023. In arXiv:2303.18223v12

[3] Kaplan+. Scaling Laws for Neural Language Models. 2020. In arXiv:2001.08361

[4] Wei+. Emergent Abilities of Large Language Models. 2022. In arXiv:2206.07682v2

[5] Schaeffer+. Are Emergent Abilities of Large Language Models a Mirage?. 2023. In arXiv:2304.15004v2

[6] Power+. Grokking: Generalization Beyond Overfitting on Small Algorithmic Datasets. 2022. In arXiv:2201.02177v1

[7] Liu+. Towards Understanding Grokking: An Effective Theory of Representation Learning. 2022. In NeurIPS2022

[8] Hestness+. Deep Learning Scaling is Predictable, Empirically. 2017. In arXiv:1712.00409v1

[9] Brown+. Language Models are Few-Shot Learners. 2020. In NeurIPS2020

[10] Anil+. PaLM 2 Technical Report. 2023. In arXiv:2305.10403v3

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Reference

[11] Henighan+. Scaling Laws for Autoregressive Generative Modeling. 2020

[12] Ganguli+. Predictability and Surprise in Large Generative Models. 2023. In arXiv:2202.07785v2

[13] OpenAI. GPT-4 Technical Report. 2023. In arXiv:2303.08774v3

[14] Abhinav Venigalla, Linden Li. Billion-Parameter GPT Training Made Easy. MosaicML. 2022. https://www.mosaicml.com/blog/billion-parameter-gpt-training-made-easy, アクセス日: 2023/11/16

[15] Vaswani+. Attention Is All You Need. 2017. In NeurIPS2017

[16] Jaiyam Sharma. Understanding Attention Mechanism in Transformer Neural Networks. LearnOpenCV. 2022. https://learnopencv.com/attention-mechanism-in-transformer-neural-networks/, アクセス日: 2023/11/16

[17] Villalobos+. Will we run out of data? An analysis of the limits of scaling datasets in Machine Learning. 2022. In arXiv:2211.04325v1

[18] Tay+. Efficient Transformers: A Survey. 2020. In arXiv:2009.06732v3

[19] Child+. Generating Long Sequences with Sparse Transformers. 2019. In arXiv:1904.10509v1

[20] Zahher+. Big Bird: Transformers for Longer Sequences. 2020. In NeurIPS2020

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Reference

[21] Dao+. FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. 2022. In NeurIPS2022

[22] Tri Dao. FlashAttention-2: Faster Attention with Better Parallelism and Work Partitioning. 2023. In arXiv:2307.08691v1

[23] Chen+. Towards Understanding Mixture of Experts in Deep Learning. 2022. In NeurIPS2022

[24] Shazeer+. Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer. 2017. In ICLR

[25] Fedus+. Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity. 2021. In arXiv:2101.03961v3

[26] Rajbhandari+. DeepSpeed-MoE: Advancing Mixture-of-Experts Inference and Training to Power Next-Generation AI Scale. 2022. In ICML2022
Proceedings of the 39th
International Conference on Machine Learning, PMLR 162:18332-18346

[27] Clark+. Unified Scaling Laws for Routed Language Models. 2022. In arXiv:2202.01169v2

[28] Zhai+. An Attention Free Transformer. 2021. In arXiv:2105.14103v2

[29] Peng+. RWKV: Reinventing RNNs for the Transform. 2023. In arXiv:2305.13048v1

[30] Sun+. Retentive Network: A Successor to Transformer for Large Language Models. 2023. In arXiv:2307.08621v4

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Reference

[31] Gu+. Efficiently Modeling Long Sequences with Structured State Spaces. 2022. In ICLR2022

[32] Microsoft. DeepSpeed: 深層学習の訓練と推論を劇的に高速化するフレームワーク. https://www.deepspeed.ai/assets/files/DeepSpeed_Overview_Japanese_2023Jun7th.pdf. アクセス日: 2023/11/16

[33] Rajbhandari+. ZeRO: Memory Optimizations Toward Training Trillion Parameter Models. 2019. In arXiv:1910.02054

[34] Microsoft. DeepSpeed. https://github.com/microsoft/DeepSpeed. アクセス日: 2023/11/16

[35] DeepSpeed Team. Configuration JSON. https://www.deepspeed.ai/docs/config-json/. アクセス日: 2023/11/16

[36] Belkada+. A Gentle Introduction to 8-bit Matrix Multiplication for Transformers at Scale using Hugging Face Transformers, Accelerate and bitsandbytes. Hugging Face Blog. 2022. https://huggingface.co/blog/hf-bitsandbytes-integration#a-gentle-introduction-to-8-bit-matrix-multiplication-for-transformers-at-scale-using-hugging-face-transformers-accelerate-and-bitsandbytes. アクセス日: 2023/11/16

[37] Dettmers+. LLM.int8(): 8-bit Matrix Multiplication for Transformers at Scale. 2022. In NeurIPS2022

[38] Liu+. Do Emergent Abilities Exist in Quantized Large Language Models: An Empirical Study. 2023. In arXiv:2307.08072

[39] Penedo+. The RefinedWeb Dataset for Falcon LLM: Outperforming Curated Corpora with Web Data, and Web Data Only. 2023. In arXiv:2306.01116

[40] Okanohara. MinHashによる高速な類似検索. Preferred Networks Research&Development. 2011. https://tech.preferred.jp/ja/blog/minhash/. アクセス日: 2023/11/16

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Reference

[41] Cossu+. Continual Pre-Training Mitigates Forgetting in Language and Vision. 2022. In arXiv:2205.09357v1

[42] Hoffmann+. Training Compute-Optimal Large Language Models. 2022. In NeurIPS2022

[43] de Vries. Go smol or go home, Why we should train smaller LLMs on more tokens. Harm de Vries Blog. 2023. https://www.harmdevries.com/post/model-size-vs-compute-overhead/. アクセス日: 2023/11/16

[44] Sorscher+. Beyond neural scaling laws: beating power law scaling via data pruning. 2022. In NeurIPS2022

[45] Tirumala+. D4: Improving LLM Pretraining via Document De-Duplication and Diversification. 2023. In arXiv:2308.12284v1

[46] Zhou+. LIMA: Less Is More for Alignment. 2023. In arXiv:2305.11206v1

[47] Bahdanau. The FLOPs Calculus of Language Model Training. Medium. 2022. https://medium.com/@dzmitrybahdanau/the-flops-calculus-of-language-model-training-3b19c1f025e4. アクセス日: 2023/11/16

[48] Zhao+. A Survey of Large Language Models. 2023. In arXiv:2303.18223

[49] Gu+. Mamba: Linear-Time Sequence Modeling with Selective State Spaces. 2023. In arXiv:2312.00752

[50] Sardana+. Beyond Chinchilla-Optimal: Accounting for Inference in Language Model Scaling Laws. 2024. In ICML2024 (arXiv:2401.00448)

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Reference

[51] Dey+. Cerebras-GPT: Open Compute-Optimal Language Models Trained on the Cerebras Wafer-Scale Cluster. 2023. In arXiv:2304.03208

[52] Yang+. Tensor Programs V: Tuning Large Neural Networks via Zero-Shot Hyperparameter Transfer. 2022. In NeurIPS2022

[53] OpenAI. Learning to reason with LLMs. OpenAI Blog. 2024. https://openai.com/index/learning-to-reason-with-llms/ . アクセス日: 2026/05/25

[54] Madaan+. From Decoding to Meta-Generation: Inference-time Algorithms for Large Language Models. 2024. In arXiv:2406.16794

[55] Li+. Contrastive Decoding: Open-ended Text Generation as Optimization. 2023. In ACL2023

[56] Snell+. Scaling LLM Test-Time Compute Optimally can be More Effective than Scaling Model Parameters. 2024. In arXiv:2408.03314

[57] Eikema+. On the True Distribution Approximation of Minimum Bayes-Risk Decoding. 2020. In EMNLP2020

[58] Wang+. Self-Consistency Improves Chain of Thought Reasoning in Language Models. 2023. In ICLR2023

[59] Lightman+. Let's Verify Step by Step. 2023. In ICLR2024 (arXiv:2305.20050)

[60] Yao+. Tree of Thoughts: Deliberate Problem Solving with Large Language Models. 2023. In NeurIPS2023

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO

Reference

[61] Madaan+. Self-Refine: Iterative Refinement with Self-Feedback. 2023

[62] Tatsunori Hashimoto, Percy Liang. CS336: Language Modeling from Scratch. Stanford University. 2024. https://cs336.stanford.edu/

[63] OpenAI. Models overview - OpenAI API Documentation. 2023. https://platform.openai.com/docs/models/overview. アクセス日: 2023/09/14

[64] Ludziejewski+. Scaling Laws for Fine-Grained Mixture of Experts. 2024 . アクセス日: 2026/05/25

[65] Vaswani+. Attention Is All You Need. 2017

[66] AI@Meta+. The Llama 3 Herd of Models. 2024

[67] Wei+. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. 2022

[68] Agarwal+. Many-Shot In-Context Learning. 2024

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO



松尾・岩澤研究室

MATSUO-IWASAWA LAB UTOKYO

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

©MATSUO-IWASAWA LAB, THE UNIVERSITY OF TOKYO