注意事項: 本資料の再利用(2次利用)について

- **本資料について**
  - 東京大学 松尾・岩澤研究室が作成し、2025年10月から11月にかけて開催されたLLM大規模言語モデル講座基礎編の講義資料です。
  - クリエイティブ・コモンズのCC BY-NC-SA 4.0 DEED(表示 – 非営利 – 継承 4.0 国際)のライセンス登録をしています。
- **ライセンスの表示について**
  - 各スライドのページ最下部にライセンスの記載があります。再利用時には本ライセンス表示を必ずご記載ください。再利用時に複製が困難な場合は、下記のテキストボックスを利用の上、ハイパーリンクも含めてライセンスの表記をするようお願いします。

    LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0

  - 再利用するページに参照論文等の引用がある場合は、巻末にあるReferenceより引用箇所を掲載してください。
- **非営利目的での利用について**　再利用(2次利用)が許諾されています。
- **営利目的での再利用について**　こちらからお問い合わせください。
- **その他**
  - 元の表現が変わらない範囲(フォント、サイズ等)であれば改変可能です。
  - それ以外の改変その他ライセンスについての詳細は、こちらをご覧の上適切な取り扱いをお願いします。

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

大規模言語モデル基礎 2025 Autumn Day6

大規模言語モデル Fine-Tuning

松尾研究室
Matsuo Lab The University Of Tokyo

講義パート：中筋 渉太

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

Day6 講師 自己紹介

- 中筋 渉太 (NAKASUJI, Shota)
- Co-Founder, CIO at SPEQTRA Investment Research Pte. Ltd.
- シンガポールにて、資産運用系スタートアップを共同創業、データサイエンス・AIを活用したクオンツリサーチが専門

- **経歴**:
  - 2023年3月 東京大学工学部物理工学科卒業
  - 2025年3月 同大学大学院工学系研究科修了

- **松尾研関連**:
  - 共同研究プロジェクトPM
  - クオンツ運用プロジェクトPM
  - GCI講座 TA・講師
  - 「画像認識」講座 教材開発
  - 「金融市場取引と機械学習」講座 監修・講師



遠い昔のGCI講座海外研修より

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

大規模言語モデル Fine-Tuning

目次

01 Day6 イントロダクション

02 **大規模言語モデルの Fine-Tuning**

03 **Instruction Tuning**

04 **Parameter Efficient Fine-Tuning**

05 Day6 まとめ

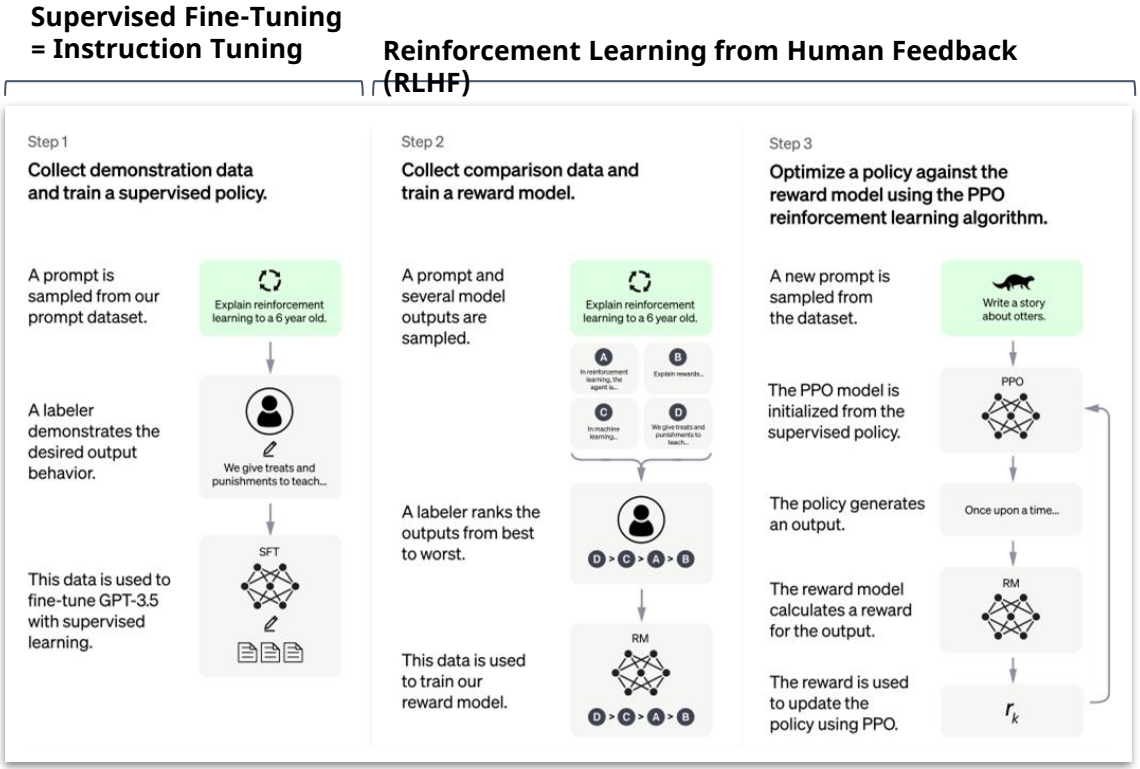
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

LLM Fine-Tuning における問題意識

問題意識	解決の方向性
- 大規模言語モデルの性能改善や様々なタスク・ドメインへの適応を実現したい - 莫大なリソースを要する Pre-Training は多くの主体にとってハードルが高い	- **Fine-Tuning** によって事前学習済みモデルの性能改善やタスク・ドメイン適応を実現 - 特に **Instruction Tuning** によって、対話性能や Zero/Few-shot 性能を向上
- 大規模言語モデルは膨大なパラメータを有するため、Fine-Tuning であっても全てのパラメータを扱えない場合がある - Catastrophic Forgetting や過学習で、事前学習モデルの性能を毀損する恐れ	- 追加的に設定したパラメータや、一部のパラメータのみを訓練・更新の対象とすることで、効率的な Fine-Tuning を実現 - このような手法を特に **Parameter Efficient Fine-Tuning (PEFT)** と呼ぶ

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

LLM Fine-Tuning 事例 | ChatGPT



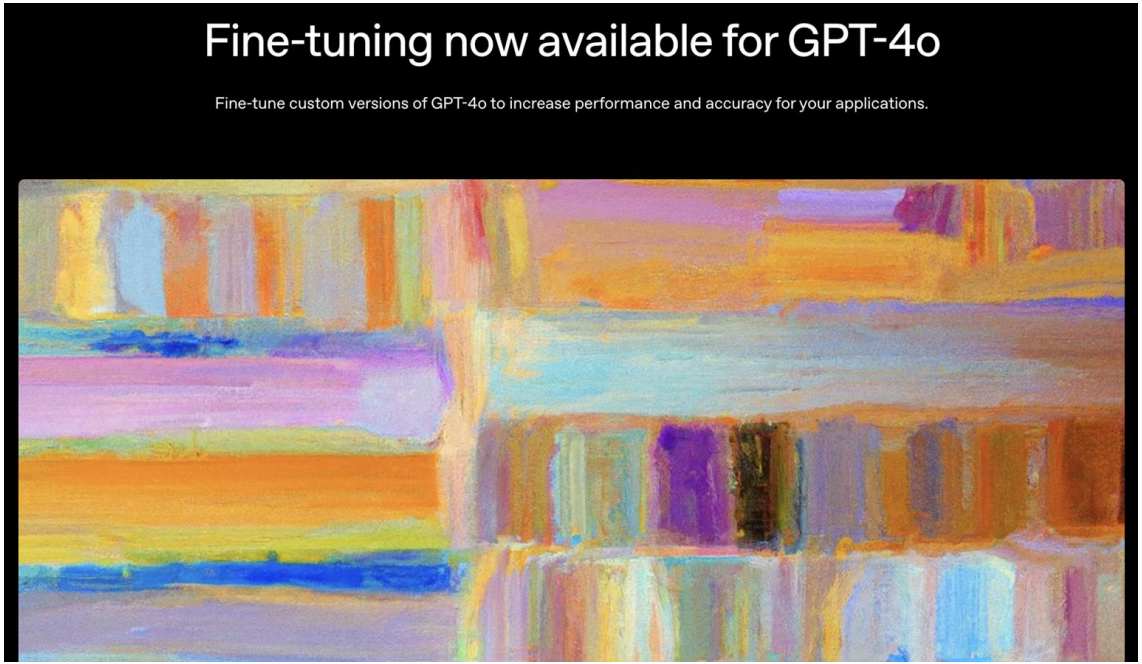
- 事前学習済みLLMは高い性能を示すが、必ずしも人間の価値観に沿った出力をしない
- **ChatGPT**では **InstructGPT** 論文※で提案された手法に則って、上記の問題に対処
- 具体的に以下を組み合わせ、人間の価値観への調整を実現
  - **Supervised Fine-Tuning = Instruction Tuning**
  - **RLHF**

[2] Ouyang, Long, et al. (2022), "Training language models to follow instructions with human feedback" より引用

[1] OpenAI(2023), "Introducing ChatGPT"より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

LLM Fine-Tuning 事例｜OpenAI API Fine-Tuning



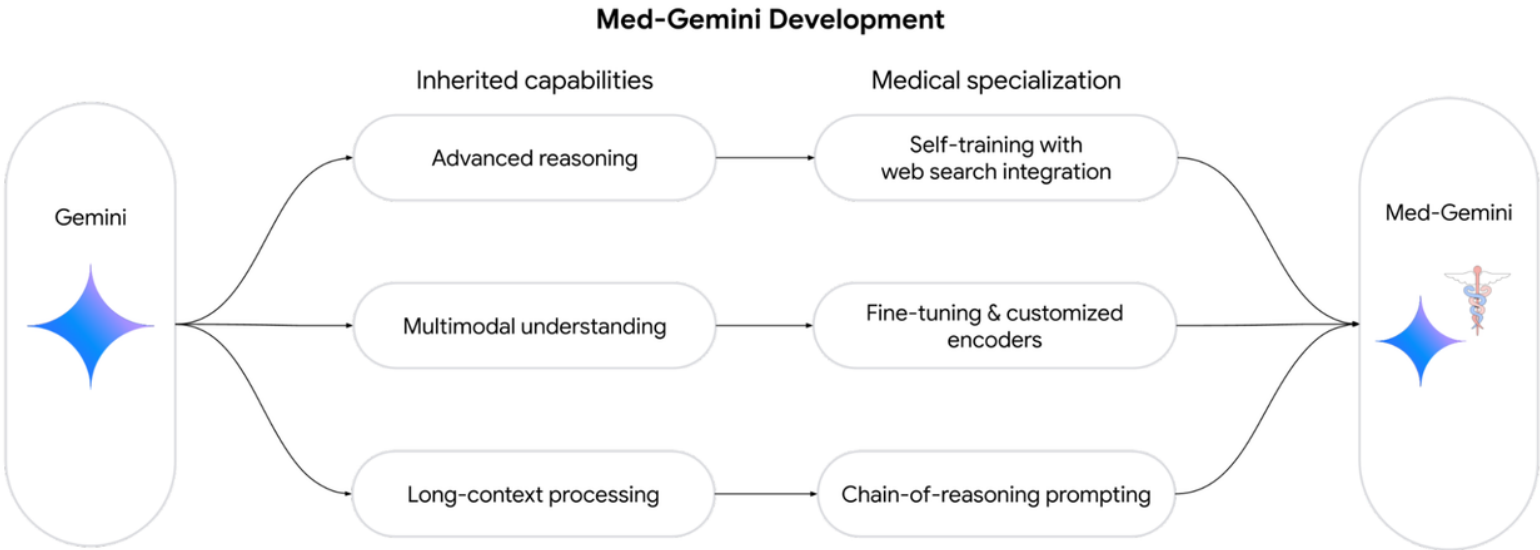
[3] OpenAI(2024), “Fine-tuning now available for GPT-4o” より引用

- **OpenAI API** では、**Fine-Tuning** 機能が提供
- 自前のデータセットを用いた **Fine-Tuning** が実施可能
- 以下のような用途が例示
  - 出力フォーマットの固定
  - 画像理解＋テキスト出力
  - レイアウト一貫性の強化
- **Prompting** と比較して、以下のような利点が例示
  - トークン・処理時間節約
  - 応答の品質・制御性向上

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

LLM Fine-Tuning 事例 | Med-Gemini

- **Med-Gemini**※ :
  - Google が開発した大規模言語モデル **Gemini** を医療向けに特化させたモデル
  - 医療領域でのマルチモーダル能力が強化され、各種ベンチで強力な結果を報告



[4] Saab, Khaled, et al.(2024), “Capabilities of gemini models in medicine.” より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

大規模言語モデル基礎 Day6 の目標

Goal 1	大規模言語モデルの典型的な訓練フローにおいて、**Fine-Tuning** が **Pre-Training** や **RLHF・DPO** に対してどう位置付けられるか説明できる
Goal 2	大規模言語モデルの **Fine-Tuning** において、特に重要なアプローチである **Instruction Tuning** や **PEFT** が既存手法に対してどう異なるか説明できる
Goal 3	**Instruction Tuning** および **PEFT** について、その目的や内容を十分に理解した上で実際にそれらを実装し、大規模言語モデルの性能改善を実現できる

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

大規模言語モデル Fine-Tuning

目次

01 Day6 イントロダクション

02 **大規模言語モデルの Fine-Tuning**

03 **Instruction Tuning**

04 **Parameter Efficient Fine-Tuning**

05 Day6 まとめ

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

LLM 訓練フローにおける Fine-Tuning

x : 次ページで整理

Step 1

Pre-Training

大規模コーパスによる自己教師あり学習を通して、言語モデルに語彙・文法・知識といった基本的な言語理解を獲得させる段階

1

Step 2

Supervised Fine-Tuning

ラベル付きデータによる教師あり学習を通し、言語モデルの性能を改善したり、特定のタスクやドメインへの適応を実現する段階

Step 3

RLHF・DPO etc.

人間の選好にもとづく後段の最適化を通じて、言語モデルの出力がより人間の価値観に沿ったものとなるよう調整する段階

2

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

Pre-Training vs. Fine-Tuning / Post-Training

：今回のトピック

	① Pre-Training	② Fine-Tuning / Post-Training
目的	- 語彙・文法・知識・推論能力などの言語能力を、言語モデルに導入	- 事前学習済みモデルの性能改善や、 様々なタスクに対する適応を実現
一般的な手法	- 自己教師あり学習 - Next Token Prediction - Masked Language Model	- 教師あり学習 - 下流タスクへの特化 - Instruction Tuning - RLHF・DPO etc.
データ	- 大規模データセット - 例 CommonCrawl (GPT-3): 410B tokens (570GB)	- 小規模データセット - 例 LIMA: 1000サンプル (3MB) - 人間・モデルによるフィードバック

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

大規模言語モデルの Fine-Tuning

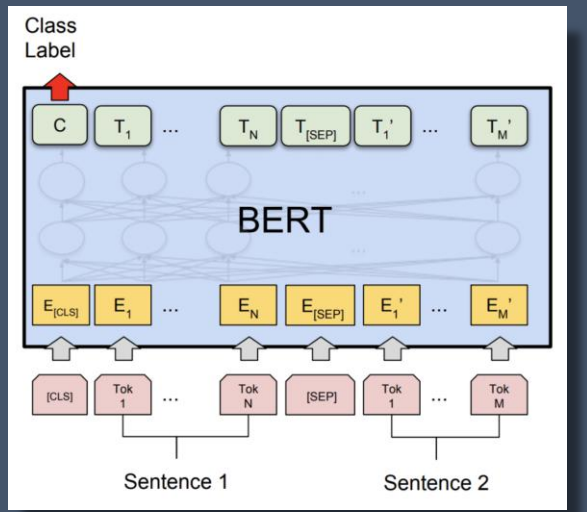
	従来的な Fine-Tuning	大規模言語モデルの Fine-Tuning
主目的	- 事前学習済みモデルをベースとし、特定の下流タスクを高い精度で解けるモデルを効率的に獲得	- 事前学習済みモデルの出力内容や形式を用途に応じて調整・制御 - 事前学習済みモデルの未知タスクに対するZero/Few-shot性能を改善
A タスク設計	- 解きたいタスクで教師あり学習 - 例: 感情分析・自然言語推論	- 指示文を入力、それに対する理想的な出力文を正解として教師あり学習 (**Instruction Tuning**)
B 重み更新	- 事前学習済みモデルの各層内の全てのパラメータについて更新を実施 (対比的に**Full-FT**と呼ぶことがある)	- 別途設定した追加パラメータや、一部のパラメータのみを更新 (**Parameter Efficient Fine-Tuning**)

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

Ⓐ Fine-Tuning のタスク設計

従来的な Fine-Tuning

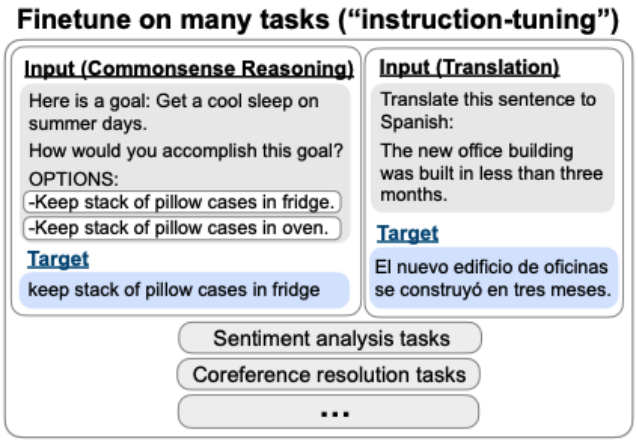
- 特定の下流タスクで教師あり学習を実施
- 主に下流タスク用の特殊トークンを活用



[5] PyTorch Tutorial, "Dynamic Quantization on BERT"より引用

Instruction Tuning

- 指示文に対して、理想的な出力文を正解とする教師あり学習を実施
- 様々なタスクがこの入出力形式に内包



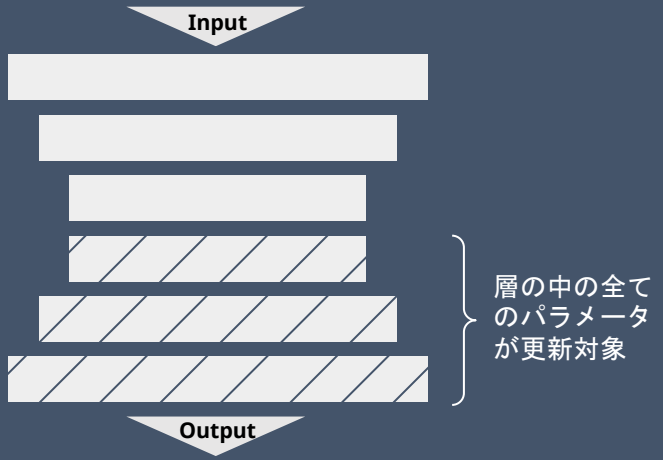
[6] Wei, Jason, et al.(2021) "Finetuned language models are zero-shot learners." arXiv preprint arXiv:2109.01652 (2021). より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

B Fine-Tuning の重み更新

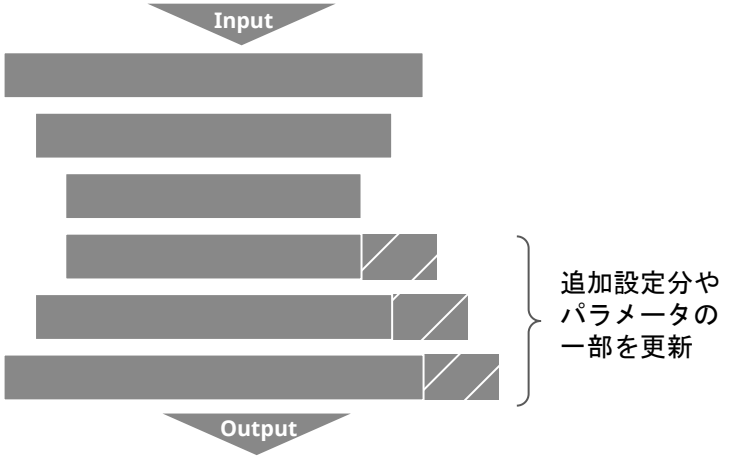
従来的な Fine-Tuning (Full-FT)

- 事前学習済みモデルが持つ各層内の全てのパラメータについて、更新を実施
- より確実な性能改善が期待される一方、より多くの計算リソースを必要とする



Parameter Efficient Fine-Tuning (PEFT)

- 追加的に設定したパラメータや、一部のパラメータのみを訓練・更新
- 適切に用いることができれば、少ないリソースで性能改善を達成できる



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

大規模言語モデル Fine-Tuning

目次

01 Day6 イントロダクション

02 大規模言語モデルの Fine-Tuning

03 **Instruction Tuning**

04 Parameter Efficient Fine-Tuning

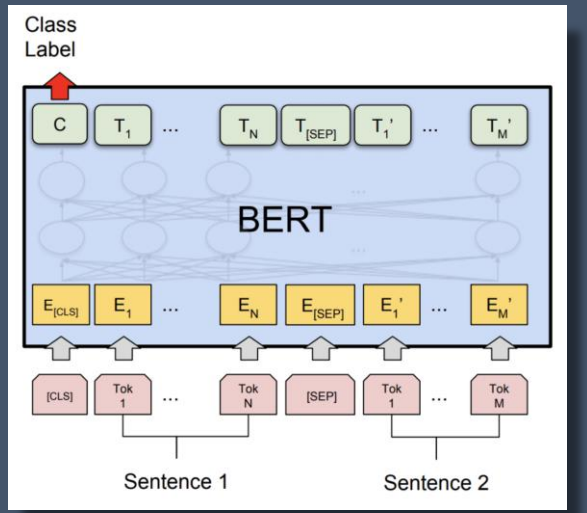
05 Day6 まとめ

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

Ⓐ Fine-Tuning のタスク設計 (再掲)

従来的な Fine-Tuning

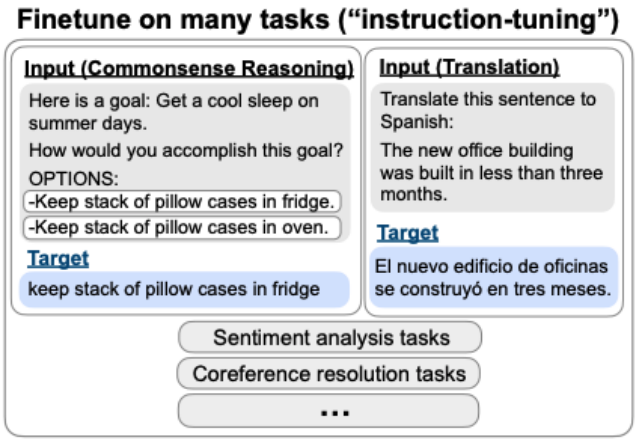
- 特定の下流タスクで教師あり学習を実施
- 主に下流タスク用の特殊トークンを活用



[5] PyTorch Tutorial "Dynamic Quantization on BERT"より引用

Instruction Tuning

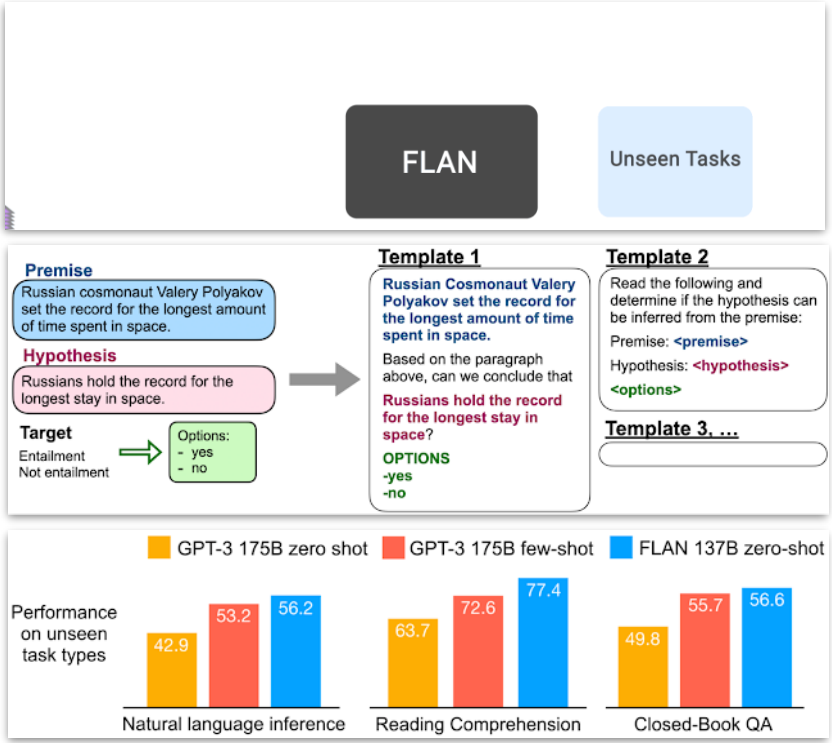
- 指示文に対して、理想的な出力文を正解とする教師あり学習を実施
- 様々なタスクがこの入出力形式に内包



[6] Wei, Jason, et al. "Finetuned language models are zero-shot learners." (2021). より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

Instruction Tuning 概要 | FLAN論文による提案



[7] Google Research(2021), "Introducing FLAN: More generalizable Language Models with Instruction Fine-Tuning"より引用

- Wei, Jason, et al. "**Finetuned language models are zero-shot learners**." arXiv preprint arXiv:2109.01652 (2021).
- 様々なタスクを指示・回答という入出力形式に統一したデータセットによって、言語モデルを Fine-Tuning する手法を提案 (**Instruction Tuning**)
- このように Fine-Tuning されたモデルは評価に用いられた25のタスクの内、
  - 21タスクで、Zero-shot性能が向上
  - 20タスクで、よりパラメータ数の多いGPT-3と比べ、より高いZero-shot性能

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

Instruction Tuning 概要 | タスク構成と入出力例

	入力 (Instruction)	出力 (Instance)
構成	- タスクを指定する指示文 - (Optional) 付随する補足情報	- 与えられた指示文に対する、理想的な回答例
具体例 (FLAN※)	- "Víte, rozhodl jsem se, že si pořídím psa. Translate to English" - "i'm 10x cooler than all of you! What is the sentiment of this tweet?"	- "You know, I decided to get a dog." - "positive"

[8] HuggingFace, "flan2021_submix_original" より引用

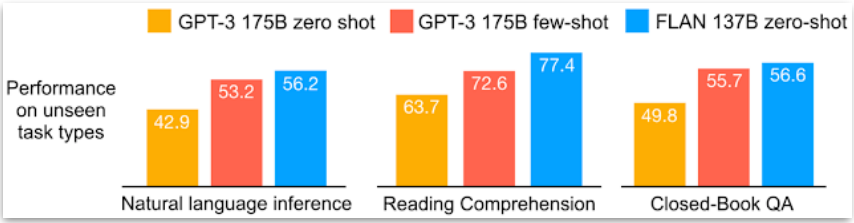
xx：元データでの記述
xx：テンプレートにより付加した指示部分

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

Instruction Tuning の有効性

Zero-shot性能の向上

- **FLAN**※1
  - 137Bモデルに対して、Instruction Tuning を適用し、GPT-3と比較
  - パラメータ数で大幅に勝る GPT-3 の Zero-shot および Few-shot 性能を超える Zero-shot 性能を示した



[6] Wei, Jason, et al. (2021), "Finetuned language models are zero-shot learners" より引用

指示応答性能の向上

- **Alpaca**※2
  - Meta社 が 開発した LLaMA 7Bモデルに Instruction Tuning を適用
  - パラメータ数で大幅に勝る GPT-3.5 と同程度の指示応答挙動に改善
    - 入力例: What is an alpaca? How is it different from a llama?
    - 出力例: An alpaca is domesticated species of South American camelid, related to the llama and the vicuna. It is smaller than a llama, and has finer and softer fleece. ...

[9] Taori, Rohan, et al. (2023), "Alpaca" より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

Instruction Tuning の難しさ

：次ページ以降で詳解

データセット作成上の困難

- Instruction Tuning によって望ましい挙動を実現するためには、**高品質**かつ**無害**なデータセットの用意が必要
  ➢ 人力で作成するのがよい?
- 一方、指示に含まれる個別のタスクや形式の**多様性**の重要性も指摘されている
  ➢ 既存のデータセットを活用?
- そうした様々な観点を考慮に入れてデータセットを構築するためには、多くの人的・技術的リソースを要する
  ➢ データセットもLLMで生成?

知識は導入可能か

- **LIMA (2023)**[10]
  - Fine-Tuning は、事前学習で獲得された知識・能力を”引き出す”ことで性能改善を実現しているとする、**Superficial Alignment Hypothesis** を提唱
- **Kung and Peng (2023)**[9]
  - Instruction Tuning による性能改善がタスクの理解を通じてではなく、出力形式といった表面的事項の学習に起因する可能性を指摘

[9] Taori, Rohan, et al. (2023), "Alpaca" より引用
[10] Zhou, Chunting, et al. (2023), "Lima: Less is more for alignment" より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

Instruction データセット作成上の要点

データの質	- **LIMA**[10]: Instruction Tuning ではデータの量より質が重要だと主張 - 1000件と少量の高品質データを用いた Instruction Tuning のみにより、RLHF で訓練されたモデルよりも高品質な回答を生成できたことを報告
データの無害性	- 事前学習済みモデルについて懸念される有害な出力を抑制するため、Instruction Tuning では有害なデータを避けて学習を実施したい - **Llama 2**[11]: 無害なデータセット構築の実例を提示 (次ページで詳解)
指示形式の多様性	- タスクごとの指示形式の多様化により、未知タスクに対する性能が向上 [12]

[10] Zhou, Chunting, et al. (2023), "Lima: Less is more for alignment" より引用
[11] Touvron, Hugo, et al. (2023), "Llama 2: Open foundation and fine-tuned chat models" より引用
[12] Sanh, Victor, et al. (2021), "Multitask prompted training enables zero-shot task generalization" より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

Instruction データセット構築事例 | Llama2

Llama2 とは[11]

- Meta 社が開発・公開する大規模言語モデル
  で、7B, 13B, 70Bのバリエーションを含む
- 事前学習済みモデルに加えて、Instruction Tuning および RLHF の適用モデルも提供
- 安全性の向上を目的として、人間による
  アノテーションや評価を積極的に採用

アノテーターの選定・指示

- アノテーターが様々なデータ作成
  タスクに取り組む上での資質と適性を
  評価するため、複数のテストを実施
- 選定されたアノテーターに、以下を
  満たす指示文・回答の作成を依頼
  - Informative
  - Relevant
  - Harmless
  - Truthful
  - Clear
- 例: 指示文作成で避けるべき項目
  - 犯罪行為の助長
  - 攻撃的な言動の助長

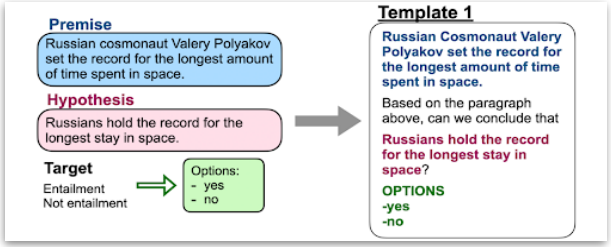
[11] Touvron, Hugo, et al. (2023), "Llama 2: Open foundation and fine-tuned chat models" より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

Instruction データセットの構築手法

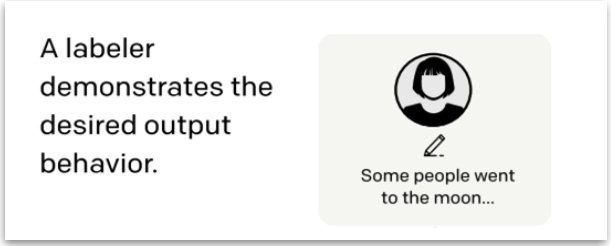
ラベル付きデータセットの統合

- 既存のラベル付きデータセットを、テンプレートを用いて変換
- **FLAN**[6] : 62個のデータセットを統合



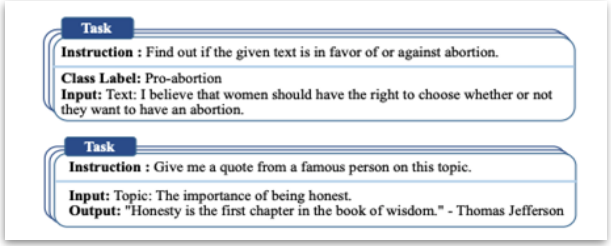
人間によるデータ作成

- 指示文に対する回答を人間が作成
- **InstructGPT**[2] : 人間が作成した指示文に対し、人間が回答を作成



LLMによるデータ生成

- 指示文に対する回答をLLMが生成
- **Self-Instruct**[13] : LLMによる指示文と回答の生成フレームワークを提案



[2] Ouyang, Long, et al. (2022), "Training language models to follow instructions with human feedback" より引用
[6] Wei, Jason, et al. (2021), "Finetuned language models are zero-shot learners" より引用
[13] Wang, Yizhong, et al. (2022), arXiv:2212.10560 より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

大規模言語モデル Fine-Tuning

目次

01 Day6 イントロダクション

02 LLM Fine-Tuning

03 Instruction Tuning

04 **Parameter Efficient Fine-Tuning**

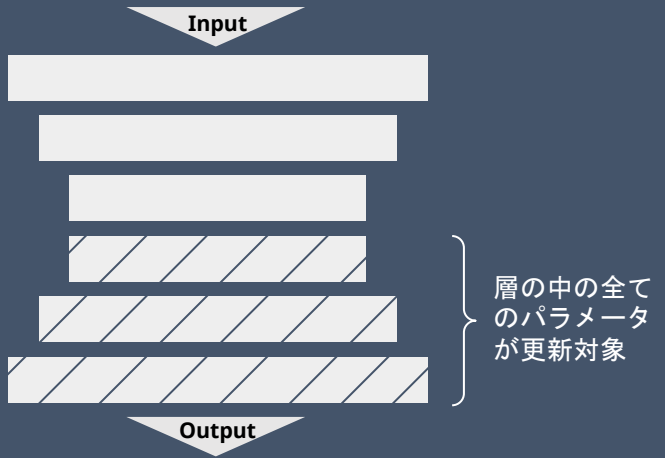
05 Day6 まとめ

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

B Fine-Tuning の重み更新 (再掲)

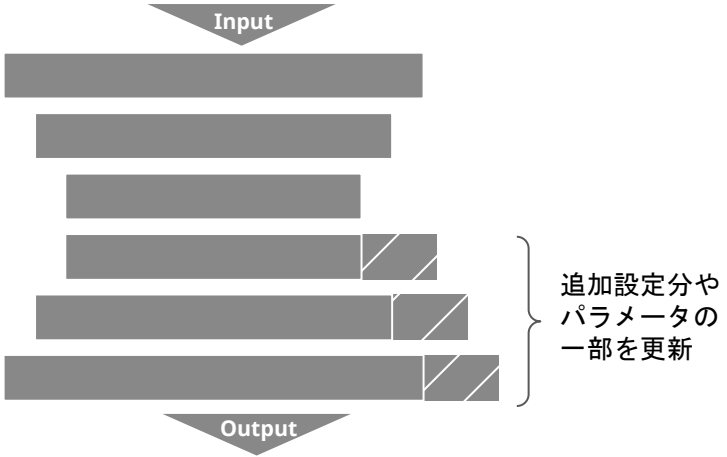
従来的な Fine-Tuning (Full-FT)

- 事前学習済みモデルが持つ各層内の全てのパラメータについて、更新を実施
- より確実な性能改善が期待される一方、より多くの計算リソースを必要とする



Parameter Efficient Fine-Tuning (PEFT)

- 追加的に設定したパラメータや、一部のパラメータのみを訓練・更新
- 適切に用いることができれば、少ないリソースで性能改善を達成できる



LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

Full-FT vs. Parameter Efficient Fine-Tuning

: 次ページで詳解

	Full-FT	Parameter Efficient Fine-Tuning (PEFT)
概要	- 事前学習済みモデルの全パラメータについて、別タスクで更新を実施	- 追加的に設定したパラメータや、一部のパラメータのみで更新を実施
計算リソース	- 大規模なモデルでは、莫大な計算リソースが必要 - 例 GPT-3 : 1.2TBのGPUメモリ	- 大規模なモデルについても、限定的な計算リソースで性能改善を実現 - 例 GPT-3 LoRA : 350GBのGPUメモリ※
保存領域	- 元モデルと同サイズのパラメータを保存するため、大きな領域が必要 - 例 GPT-3 : 350GBの保存領域	- 更新部分のパラメータのみを保存すればよく、小さな保存領域で十分 - 例 GPT-3 LoRA: 35MBの保存領域[14]

[14] Hu, Edward J., et al. (2021), "LoRA: Low-rank adaptation of large language models" より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

PEFT によるGPUメモリ使用量の削減

- 7Bモデルの 16-bit Fine-Tuning を想定し、Full-FT と PEFT のGPUメモリ使用量を概算比較
- 以下で、**全パラメータ数 N_{all} = 7B, 浮動小数点数のサイズ size(float) = 2byte** の状況に対応

VRAM by Steps	Estimation	Full-FT (N_{train} : 7B)	PEFT (N_{train}: 1M)
Model Loading	size(float) * N_{all}	~ 13GB	~ 13GB
Backward (Gradients)	size(float) * N_{train}	**~ 13GB**	**~ 2MB**
Optimizer (Adam)	2 * size(float) * N_{train}	**~ 26GB**	**~ 4MB**
Total	(※ 上記の他に、batch sizeに比例して増加するForward分やライブラリ確保領域がある)	**~ 52GB + α**	**~ 13GB + α**

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

PEFT 手法を評価する上での主要な観点

性能改善	- Full-FT を実施した場合と比べて、性能改善に大きな劣化がないか - 事前学習済みモデルのサイズに依らず、性能改善が実現されるか
運用性	- 更新する※パラメータが少なく、小さいストレージで運用が可能か - それができると複数モデルの並列運用やバージョニングが容易に
訓練効率	- 学習する※パラメータが少なく、小さいGPUメモリでも実現可能か - GPUの効率的な活用によって高速化が可能な手法となっているか
推論効率	- **追加するパラメータ**が多いことで、推論コストを増大させないか - 入力文の系列長が長くなることで、推論コストを増大させないか

※「学習するパラメータは少ないが、それに基づいて多くのパラメータが更新される」ということがあるため、
「更新するパラメータ」と「学習するパラメータ」という似たような表現も、ここでは区別して使っている。

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

様々な PEFT 手法

	運用性	訓練効率	推論効率
Method	**Storage**	**Memory**	**Inference overhead**
Adapters (Houlsby et al., 2019)	yes	yes	Extra FFN
AdaMix (Wang et al., 2022)	yes	yes	Extra FFN
SparseAdapter (He et al., 2022b)	yes	yes	Extra FFN
Cross-Attn tuning (Gheini et al., 2021)	yes	yes	No overhead
BitFit (Ben-Zaken et al., 2021)	yes	yes	No overhead
DiffPruning (Guo et al., 2020)	yes	no	No overhead
Fish-Mask (Sung et al., 2021)	yes	maybe[5]	No overhead
LT-SFT (Ansell et al., 2022)	yes	maybe[5]	No overhead
Prompt Tuning (Lester et al., 2021)	yes	yes	Extra input
Prefix-Tuning (Li and Liang, 2021)	yes	yes	Extra input
Spot (Vu et al., 2021)	yes	yes	Extra input
IPT (Qin et al., 2021)	yes	yes	Extra FFN and input
MAM Adapter (He et al., 2022a)	yes	yes	Extra FFN and input
Parallel Adapter (He et al., 2022a)	yes	yes	Extra FFN
Intrinsinc SAID (Aghajanyan et al., 2020)	no	no	No overhead

Extra FFN :
FFN層の追加によって、
推論にオーバーヘッド

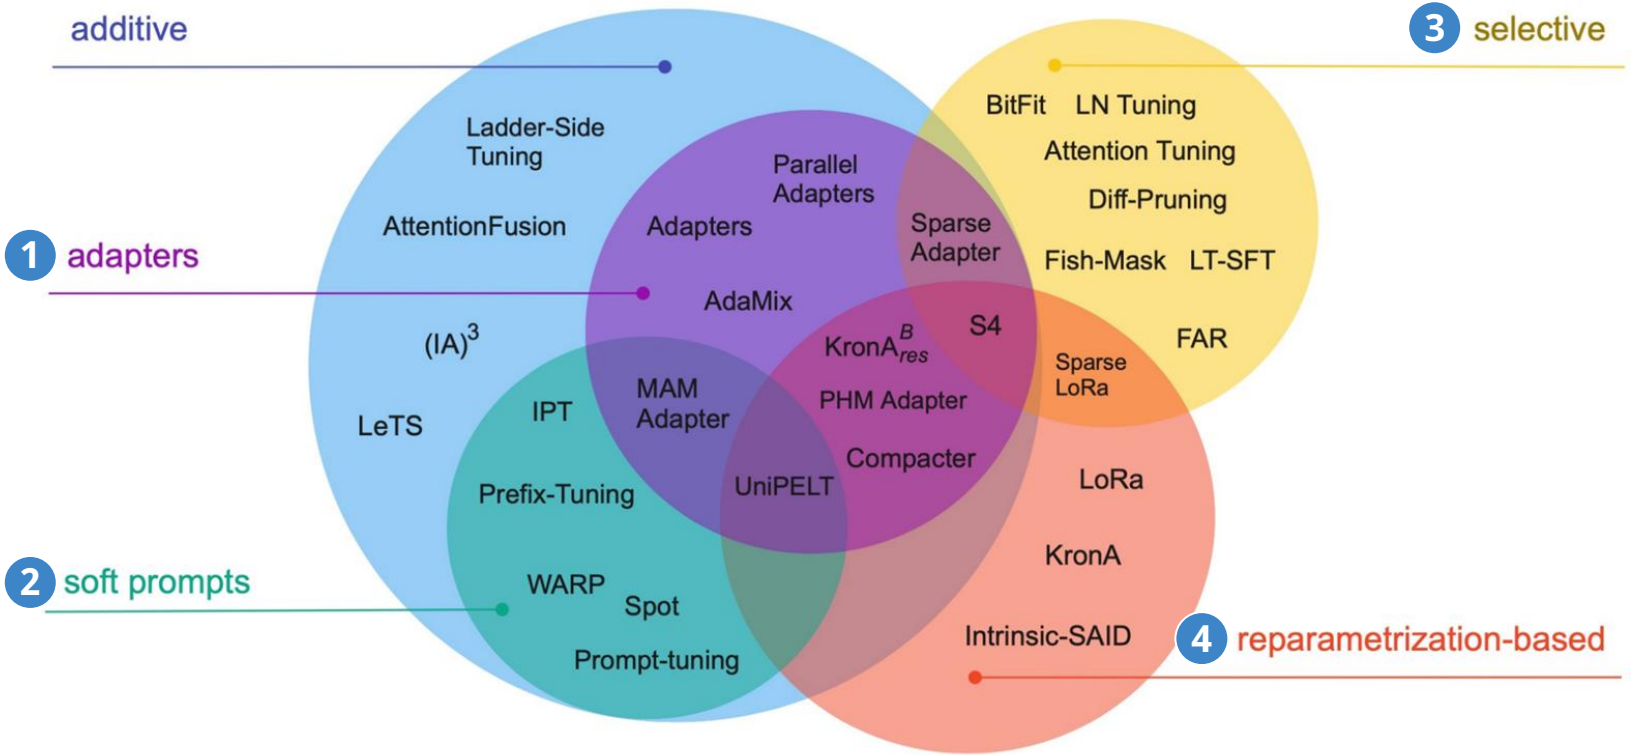
No overhead :
推論にオーバーヘッド
を伴わない手法

Extra input :
入力系列への追加で、
推論にオーバーヘッド

[15] Lialin, Vladislav, et al. (2023), "Scaling down to scale up: A guide to parameter-efficient fine-tuning" より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

PEFT 手法のカテゴリー分類



[15] Lialin, Vladislav, et al. (2023), "Scaling down to scale up: A guide to parameter-efficient fine-tuning" より引用

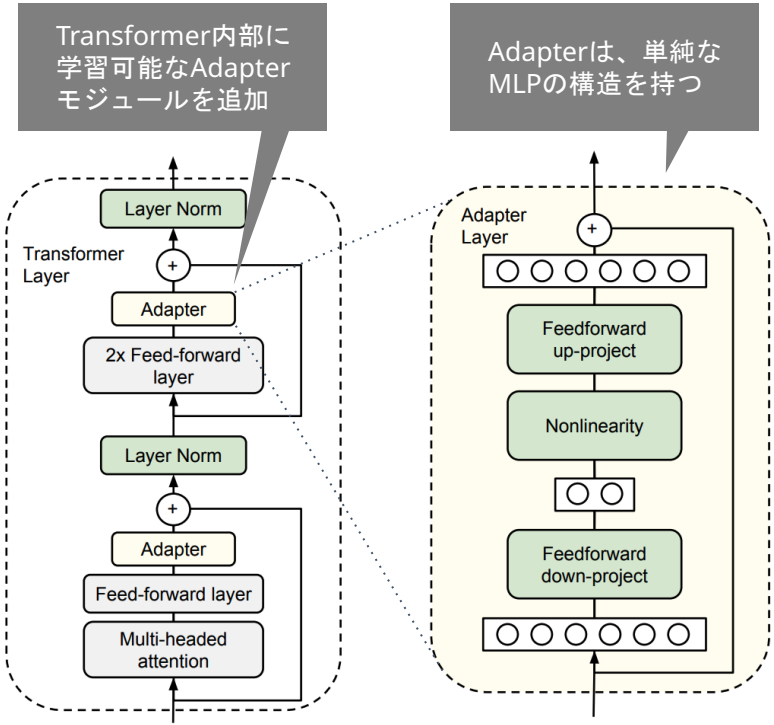
LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

PEFT 手法の代表的なカテゴリー

	概要	代表例
1 Adapter型	Transformer内部にMLP層(Adapter)を追加し、それのみの学習を実施	**Adapter** (2019)
2 Soft Prompt型	入力系列にタスクごとのベクトル(Soft Prompt) を付加し、学習を実施	**Prompt Tuning** (2021)
3 Selective型	事前学習済みモデルが持つパラメータのうち、一部のみで学習を実施	**BitFit** (2021)
4 Reparametrization型	行列分解に基づき、再パラメータ化された重みについて学習を実施	**LoRA** (2021)

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

1 Adapter型 | Adapter (2019)



[16] Houlsby, Neil, et al. (2019), "Parameter-efficient transfer learning for NLP" より引用し、一部改変

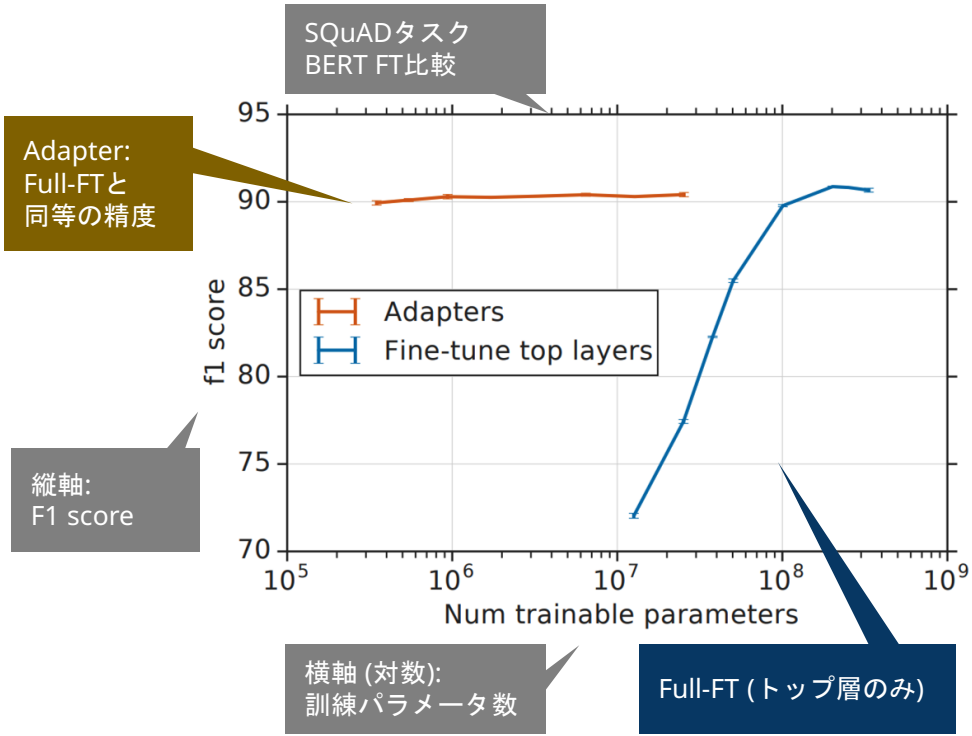
- Transformer内部に学習可能なAdapterモジュールを追加・学習
- 追加位置の異なる亜種が存在
(例: Parallell Adapter※は左図とは異なり、並列的にAdapterを追加)
- Adapterは単純なMLPの構造を持

```
def transformer_block_with_adapter(x):
    residual = x
    x = SelfAttention(x)
    x = FFN(x)   # adapter
    x = LN(x + residual)
    residual = x
    x = FFN(x)   # transformer FFN
    x = FFN(x)   # adapter
    x = LN(x + residual)
    return x
```

[17] He, Junxian, et al. (2021), "Towards a unified view of parameter-efficient transfer learning" より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

❶ Adapter型 | Adapter (2019)

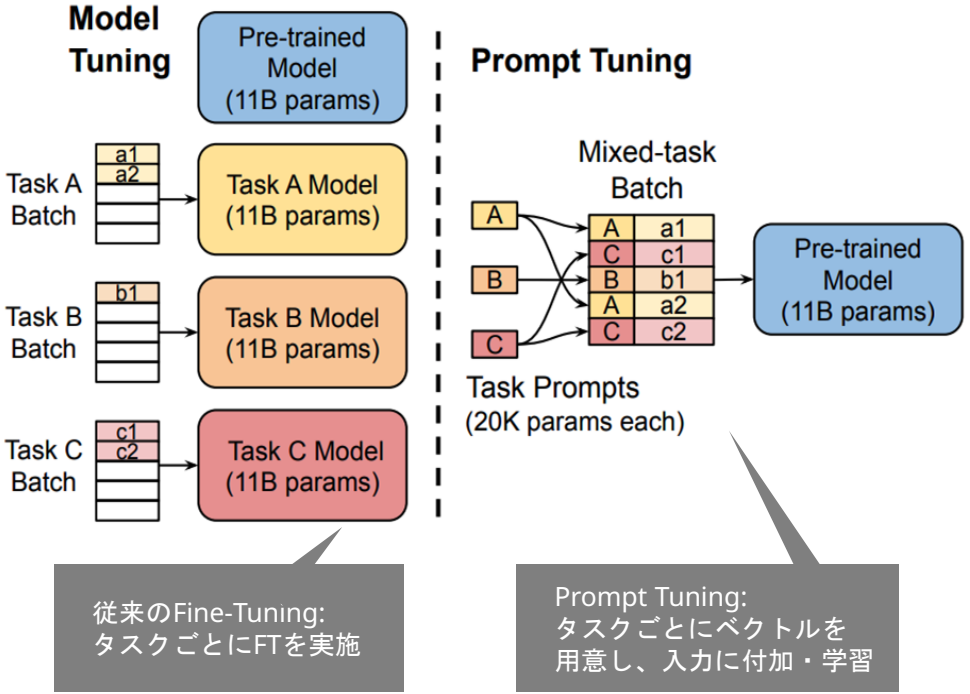


[16] Houlsby, Neil, et al. (2019), "Parameter-efficient transfer learning for NLP" より引用

- **Pros**
  - Full-FT に対し10^{-1}から10^{-2}ほど小さい訓練パラメータ数で、
    Full-FT と同等の精度 (左図)
  - Adapter のみ保存すればよく、柔軟に付け替え対応が可能
- **Cons**
  - Adapter が追加されることで、推論にオーバーヘッドが発生

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

❷ Soft-Prompt型 | Prompt Tuning (2021)



- 各タスクに対応したベクトル (**Soft Prompt**) を入力系列に付加し、そのパラメータを学習
- **Soft Prompt** は、文章の形で設計されたプロンプト (Hard Prompt) に対する呼び方・考え方
- つまり、各タスクごとに特化したプロンプトエンジニアリングを学習していると捉えることが可能

```
def soft_prompted_model(input_ids):
    x = Embed(input_ids)
    x = concat([soft_prompt, x], dim=seq)
    return model(x)
```

[18] Lester, Brian, et al. (2021), "The power of scale for parameter-efficient prompt tuning" より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

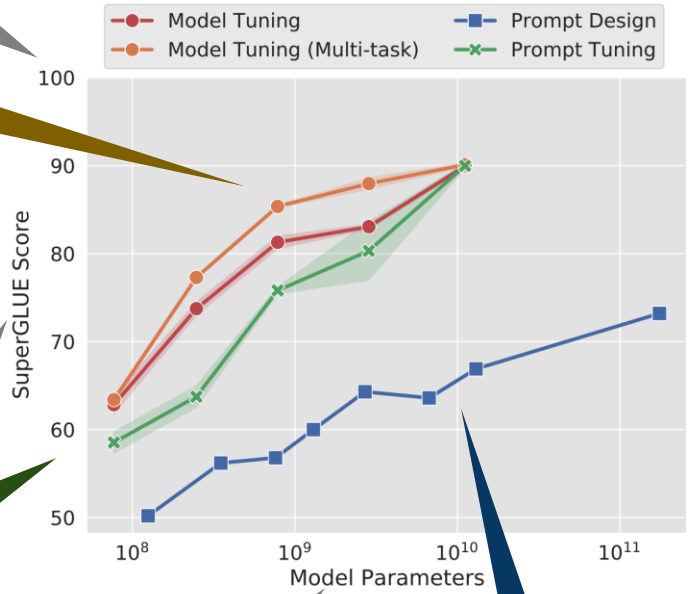
❷ Soft-Prompt型 | Prompt Tuning (2021)

SuperGLUEベンチマークによる比較

T5 Full-FT
赤: タスクごと
橙: マルチタスク

縦軸:
SuperGLUE Score

T5 Prompt Tuning



横軸 (対数):
全パラメータ数

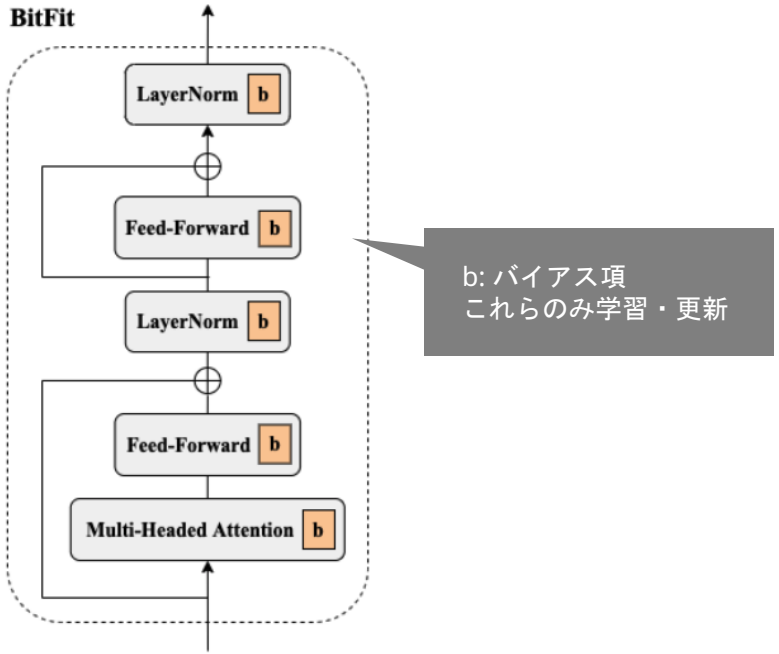
GPT-3 Few-shot

[18] Lester, Brian, et al. (2021), "The power of scale for parameter-efficient prompt tuning"
より引し、一部改変

- **Pros**
  - モデルサイズが大きい場合、Prompt Tuning は Full-FT と同等の精度 (左図)
  - T5-XXL (11B)で Soft Prompt の長さを100とすると、訓練するパラメータ数は 4096 * 100 これはFull-FTの0.007%に相当
- **Cons**
  - Soft Prompt が入力系列を圧迫
  - プロンプトエンジニアリングの拡張として捉えると、解釈性に欠けた結果となっている

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

❸ Selective型｜BitFit (2021)



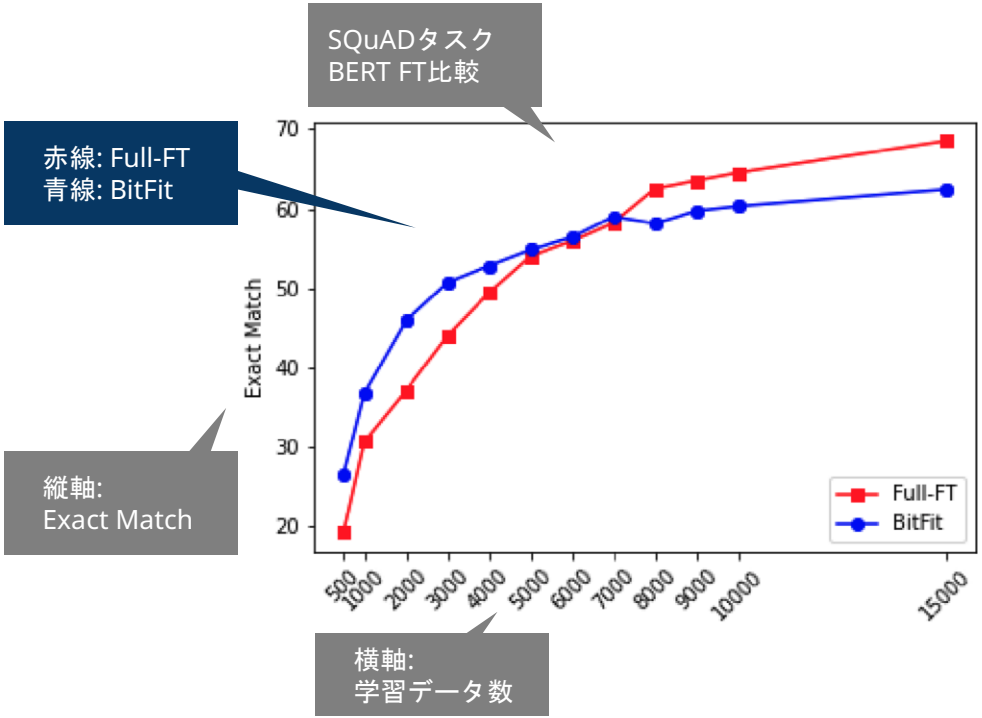
[19] Zaken, Elad Ben, et al. (2021), "BitFit: Simple parameter-efficient fine-tuning for transformer-based masked language-models" より引用し、一部改変

- Transformerの各モジュールに含まれる、バイアス項のみについて学習・更新を実施
- 具体的に、以下に含まれているバイアス項が該当
  - Attention
  - Feed-Forward Network
  - Layer Normalization

```
params = (p for n, p
          in model.named_parameters()
          if "bias" in n)
optimizer = Optimizer(params)
```

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

❸ Selective型｜BitFit (2021)



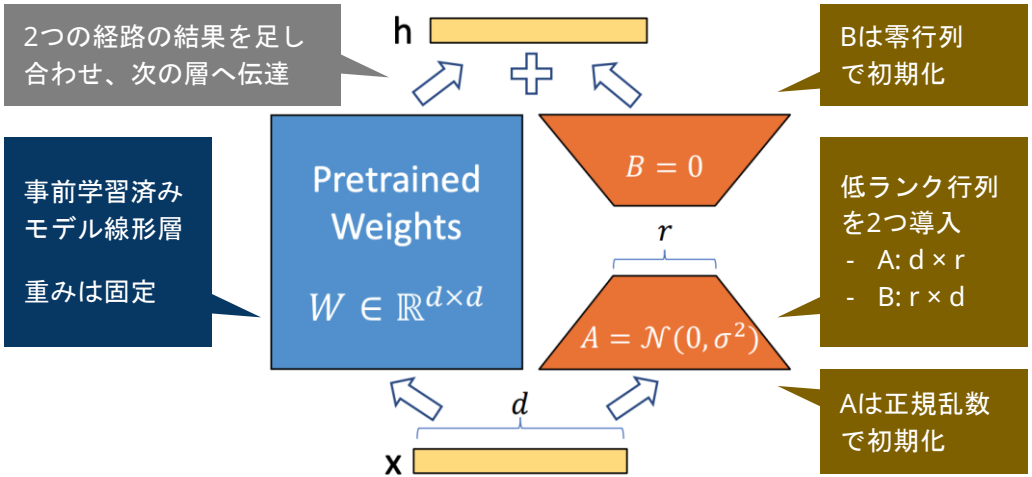
[19] Zaken, Elad Ben, et al. (2021), "BitFit: Simple parameter-efficient fine-tuning for transformer-based masked language-models" より引用し、一部改変

- **Pros**
  - 学習データ数が小さい領域では、BitFitがFull-FTよりも高い精度を示した (左図)
  - BERT(Base)モデルで、BitFitによる訓練パラメータ数は、Full-FTに対して0.1%ほど
- **Cons**
  - GPT-3 といった、より大規模なモデルでは、Full-FT や他のPEFT手法よりも精度が劣る[14]

[14] Hu, Edward J., et al. (2021), "LoRA: Low-rank adaptation of large language models" より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

❹ Reparametrization型 | LoRA (2021)



[14] Hu, Edward J., et al. (2021), "LoRA: Low-rank adaptation of large language models" より引用し、一部改変

- Fine-Tuning によって更新された重み W は一般に、元の重み W_0 と増分重み ΔWの和として表せる

$$W = W_0 + \Delta W$$

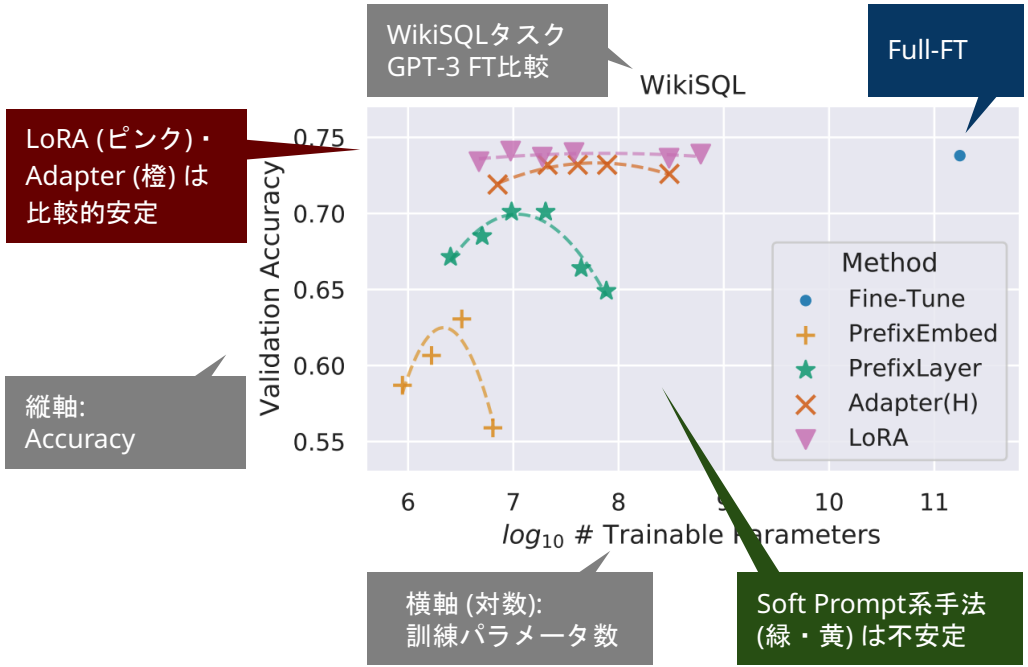
- LoRAでは、この増分重み ΔW を2つの低ランク行列A, Bの積とし、それらについて学習を実施

$$\Delta W = BA$$

```
def lora_linear(x):
    h = x @ W # regular linear
    h += x @ W_A @ W_B # low-rank update
    return scale * h
```

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

❹ Reparametrization型 | LoRA (2021)



[14] Hu, Edward J., et al. (2021), "LoRA: Low-rank adaptation of large language models" より引用し、一部改変

- **Pros**
  - Full-FTに対し10^{-2}から10^{-4}ほど小さい訓練パラメータ数で、Full-FTと同等の精度 (左図)
  - 推論時には、得られた重みを元の重みに予め足しておけば、オーバーヘッドが生じない
- **Cons**
  - 特に難易度の高いタスク (例 GSM8k, 数学的推論) で、Full-FTに対して著しい性能の劣後が生じうる※

[20] anyscale (2023), "Fine-Tuning LLMs: LoRA or Full-Parameter? An in-depth Analysis with Llama 2"

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

❹ Reparametrization型 | LoRA (2021)

- Q. 訓練パラメータ数を一定としたとき、LoRAを適用する層の
  種類をより増やすべきか、ランクrをより大きく取るべきか
- A. LoRAを適用する層の種類を増やした方が、ランクrが小さく なっても、より高い性能となることが示された
- ※ LoRA論文ではAttentionモジュール内を適用対象としたが、
  その後の研究では他の線形層も対象と

Weight Type
- q: Query projection
- k: Key projection
- v: Value projection
- o: Output projection

訓練パラメータ数を18Mに固定

	# of Trainable Parameters = 18M						
Weight Type Rank r	W_q 8	W_k 8	W_v 8	W_o 8	W_q, W_k 4	W_q, W_v 4	W_q, W_k, W_v, W_o 2
WikiSQL (±0.5%)	70.4	70.0	73.0	73.2	71.4	**73.7**	**73.7**
MultiNLI (±0.1%)	91.0	90.8	91.0	91.3	91.3	91.3	**91.7**

[14] Hu, Edward J., et al. (2021), "LoRA: Low-rank adaptation of large language models" より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

❹ Reparametrization型 | LoRA (2021)

- Q. LoRAを適用する層の種類を固定して考える場合に、
  ランクrはどの程度の値を設定する必要があるか
- A. LoRAのランクrは、2から8の範囲で性能が高い結果
- ※ (タスク依存だが) ランク1で十分な性能が出る場合も
  経験的には、ランク8程度の設定が推奨されている

	Weight Type	$r=1$	$r=2$	$r=4$	$r=8$	$r=64$
WikiSQL(±0.5%)	W_q	68.8	69.6	70.5	70.4	70.0
	W_q, W_v	73.4	73.3	73.7	73.8	73.5
	W_q, W_k, W_v, W_o	74.1	73.7	74.0	74.0	73.9
MultiNLI (±0.1%)	W_q	90.7	90.9	91.1	90.7	90.7
	W_q, W_v	91.3	91.4	91.3	91.6	91.4
	W_q, W_k, W_v, W_o	91.2	91.7	91.7	91.5	91.4

[14] Hu, Edward J., et al. (2021), "LoRA: Low-rank adaptation of large language models" より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

❹ Reparametrization型 | LoRAの派生アプローチ

	目的	手法
QLoRA	さらに少ない計算リソースによっても LoRA による Fine-Tuning を実現したい	LoRAに4ビット量子化等のテクニックを適用し、メモリ使用量をさらに削減
AdaLoRA	LoRA において、全ての層のランクが単一の値に制限されている問題の解決	増分重みの特異値分解に基づいて、層ごとのランクを適応的に変化させる
LoRA-Pro	Full-FTの勾配を近似できていない問題を緩和し、Full-FTとの性能差を詰める	LoRAの2つの低ランク行列の勾配がフル勾配に整合するよう理論的に最適調整

[21] Dettmers, Tim, et al. (2023), "QLoRA: Efficient finetuning of quantized LLMs" より引用

[22] Zhang, Qingru, et al. (2023), "Adaptive budget allocation for parameter-efficient fine-tuning" より引用

[23] Wang, Zhengbo, et al. (2024), "LoRA-Pro: Are low-rank adapters properly optimized?" より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

代表的な PEFT 手法の比較

	Adapter	Prompt Tuning	BitFit	LoRA
性能改善	○ (タスクに依存)	△ 不安定な傾向	△ 大規模モデルで劣化	○ (タスクに依存)
運用性 (更新率※)	○ (0.1 - 6 %)	○ (0.1 %)	○ (0.05 - 0.1 %)	○ (~0.5 %)
訓練効率 (訓練率※)	○ (0.1 - 6 %)	○ (0.1 %)	○ (0.05 - 0.1 %)	○ (0.01 - 0.5 %)
推論効率	△ 推論時間が増加	△ 入力系列長を圧迫	○ (変化なし)	○ (変化なし)

[15] Lialin, Vladislav, et al. (2023), "Scaling down to scale up: A guide to parameter-efficient fine-tuning" より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

大規模言語モデル Fine-Tuning

目次

01 Day6 イントロダクション

02 LLM Fine-Tuning

03 Instruction Tuning

04 Parameter Efficient Fine-Tuning

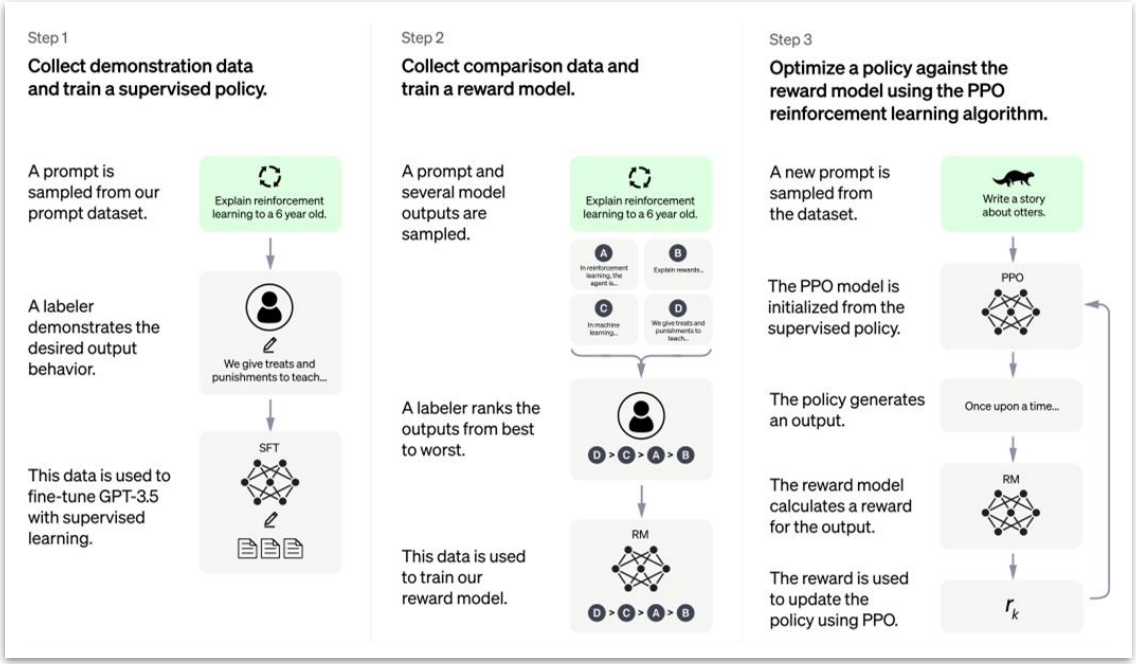
05 Day6 まとめ

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

LLM Fine-Tuning 事例振り返り | ChatGPT

Supervised Fine-Tuning = Instruction Tuning

Reinforcement Learning from Human Feedback (RLHF)



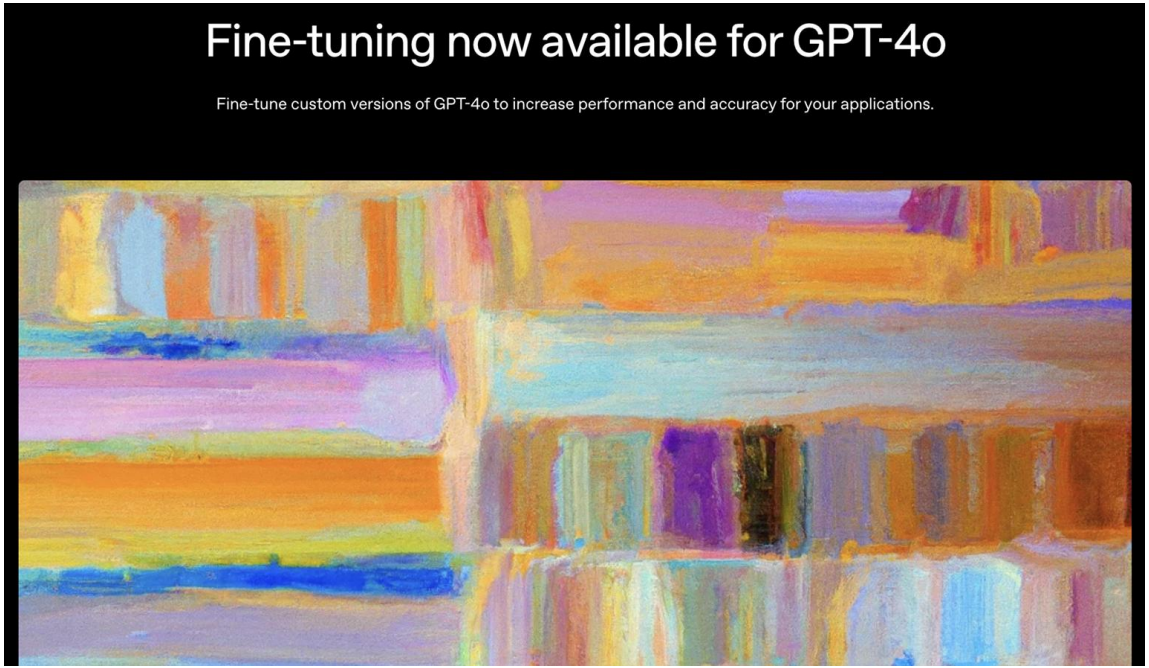
- **ChatGPT** では **InstructGPT** 論文※で提案されたフローに則って、以下の手法を採用
  - **Supervised Fine-Tuning = Instruction Tuning**
  - **RLHF**
- **InstructGPT** では、人間が Instruction Tuning 用に 1万件強のデータを作成
- これにより、人間的な価値観への出力の調整を実現

[2] Ouyang, Long, et al. (2022), "Training language models to follow instructions with human feedback" より引用

[1] OpenAI(2023), "Introducing ChatGPT"より引用し、一部改変

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

LLM Fine-Tuning 事例｜OpenAI API Fine-Tuning



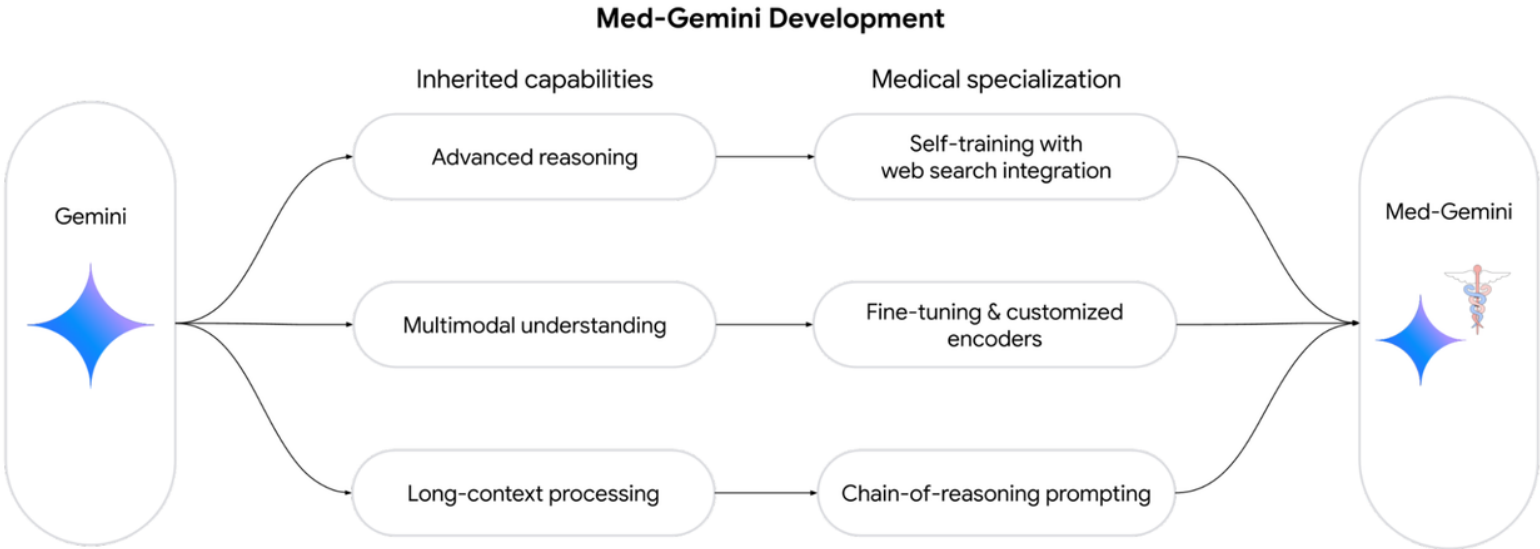
[3] OpenAI(2024), “Fine-tuning now available for GPT-4o” より引用

- **OpenAI API** では、**Fine-Tuning** 機能が提供
- 自前のデータセットを用いた **Fine-Tuning** が実施可能
- 以下のような用途が例示
  - 出力フォーマットの固定
  - 画像理解＋テキスト出力
  - レイアウト一貫性の強化
- **Prompting** と比較して、以下のような利点が例示
  - トークン・処理時間節約
  - 応答の品質・制御性向上

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

LLM Fine-Tuning 事例 | Med-Gemini

- **Med-Gemini**※ :
  - Google が開発した大規模言語モデル **Gemini** を医療向けに特化させたモデル
  - 医療領域でのマルチモーダル能力が強化され、各種ベンチで強力な結果を報告



[4] Saab, Khaled, et al. (2024), "Capabilities of gemini models in medicine" より引用

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

5. Day6 まとめ

大規模言語モデル基礎 Day6 の目標

Goal 1	大規模言語モデルの典型的な訓練フローにおいて、**Fine-Tuning** が **Pre-Training** や **RLHF・DPO** に対してどう位置付けられるか説明できる
Goal 2	大規模言語モデルの **Fine-Tuning** において、特に重要なアプローチである **Instruction Tuning** や **PEFT** が既存手法に対してどう異なるか説明できる
Goal 3	**Instruction Tuning** および **PEFT** について、その目的や内容を十分に理解した上で実際にそれらを実装し、大規模言語モデルの性能改善を実現できる

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

大規模言語モデル Fine-Tuning

目次

01 Day6 イントロダクション

02 **大規模言語モデルの Fine-Tuning**

03 **Instruction Tuning**

04 **Parameter Efficient Fine-Tuning**

05 Day6 まとめ

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

References

[1] OpenAI (2023), "Introducing ChatGPT", https://openai.com/ja-JP/index/chatgpt/ アクセス日:2026/5/24

[2] Ouyang, Long, et al. (2022), "Training language models to follow instructions with human feedback", Advances in Neural Information Processing Systems 35, pp. 27730-27744

[3] OpenAI (2024), "Fine-tuning now available for GPT-4o", https://openai.com/ja-JP/index/gpt-4o-fine-tuning/ アクセス日:2026/5/24

[4] Saab, Khaled, et al. (2024), "Capabilities of gemini models in medicine", arXiv:2404.18416

[5] PyTorch Tutorial, "Dynamic Quantization on BERT", https://docs.pytorch.org/tutorials/index.html アクセス日:2026/5/24

[6] Wei, Jason, et al. (2021), "Finetuned language models are zero-shot learners", arXiv:2109.01652

[7] Google Research (2021), "Introducing FLAN: More generalizable Language Models with Instruction Fine-Tuning", https://research.google/blog/introducing-flan-more-generalizable-language-models-with-instruction-fine-tuning/ アクセス日:2026/5/24

[8] HuggingFace, "flan2021_submix_original", https://huggingface.co/datasets/conceptofmind/flan2021_submix_original アクセス日:2026/5/24

[9] Taori, Rohan, et al. (2023), "Alpaca", Stanford Center for Research on Foundation Models, https://crfm.stanford.edu/2023/03/13/alpaca.html アクセス日:2026/5/24

[10] Zhou, Chunting, et al. (2023), "Lima: Less is more for alignment", arXiv:2305.11206

[11] Touvron, Hugo, et al. (2023), "Llama 2: Open foundation and fine-tuned chat models", arXiv:2307.09288

[12] Sanh, Victor, et al. (2021), "Multitask prompted training enables zero-shot task generalization", arXiv:2110.08207

[13] Wang, Yizhong, et al. (2022), arXiv:2212.10560

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO

References

[14] Hu, Edward J., et al. (2021), "LoRA: Low-rank adaptation of large language models", arXiv:2106.09685

[15] Lialin, Vladislav, Vijeta Deshpande, and Anna Rumshisky (2023), "Scaling down to scale up: A guide to parameter-efficient fine-tuning", arXiv:2303.15647

[16] Houlsby, Neil, et al. (2019), "Parameter-efficient transfer learning for NLP", International Conference on Machine Learning, PMLR

[17] He, Junxian, et al. (2021), "Towards a unified view of parameter-efficient transfer learning", arXiv:2110.04366

[18] Lester, Brian, Rami Al-Rfou, and Noah Constant (2021), "The power of scale for parameter-efficient prompt tuning", arXiv:2104.08691

[19] Zaken, Elad Ben, Shauli Ravfogel, and Yoav Goldberg (2021), "BitFit: Simple parameter-efficient fine-tuning for transformer-based masked language-models", arXiv:2106.10199

[20] anyscale (2023), "Fine-Tuning LLMs: LoRA or Full-Parameter? An in-depth Analysis with Llama 2", https://www.anyscale.com/blog/fine-tuning-llms-lora-or-full-parameter-an-in-depth-analysis-with-llama-2 アクセス日:2026/5/24

[21] Dettmers, Tim, et al. (2023), "QLoRA: Efficient finetuning of quantized LLMs", arXiv:2305.14314

[22] Zhang, Qingru, et al. (2023), "Adaptive budget allocation for parameter-efficient fine-tuning", arXiv:2303.10512

[23] Wang, Zhengbo, et al. (2024), "LoRA-Pro: Are low-rank adapters properly optimized?", arXiv:2407.18242

LLM 大規模言語モデル講座 講義資料 © 2025 by 東京大学松尾・岩澤研究室 is licensed under CC BY-NC-ND 4.0
©MATSUO-IWASAWA LAB, THE UNIVERSITY F TOKYO